

Analisi esplorativa dei dati in psicologia

Modulo introduttivo

Corrado Caudek

26 luglio 2026

1. Analisi esplorativa dei dati in psicologia

Modulo introduttivo a fondamenti, R ed EDA

Questo sito fa parte del progetto editoriale associato al manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza*. Il suo obiettivo è aiutarti a capire **come nascono i dati psicologici**, come prepararli con **R** e come esplorarli prima di costruire un modello statistico.

Non sono richieste esperienze precedenti di programmazione o conoscenze statistiche avanzate. Il percorso è pensato per studenti e ricercatori di area psicologica che vogliono acquisire una competenza pratica essenziale, senza trasformarsi in programmatori.

i L'obiettivo non è memorizzare R

Puoi usare documentazione, esempi e assistenti di intelligenza artificiale per generare o correggere il codice. Devi però comprendere abbastanza della sintassi da verificare:

- quali dati vengono usati;
- quale operazione viene eseguita;
- come sono trattati i valori mancanti;
- se il risultato risponde davvero alla domanda.

Che cosa imparerai

Alla fine del modulo dovresti essere in grado di:

- riconoscere come vengono generati i dati in una ricerca psicologica;
- distinguere costrutti, variabili, misure e unità di analisi;
- comprendere e modificare codice R semplice;
- importare, organizzare, pulire e trasformare piccoli dataset;
- produrre tabelle, sintesi descrittive e grafici;
- esplorare distribuzioni, anomalie e relazioni tra variabili;
- documentare un'analisi in modo trasparente e riproducibile;
- preparare dati e domande per l'inferenza statistica e bayesiana.

Come è organizzato il modulo

Il sito è diviso in tre parti.

Parte	Funzione didattica
Fondamenti	Capire da dove vengono i dati, che cosa rappresentano e quali conclusioni possono sostenere.
R	Acquisire la sintassi e gli strumenti minimi per lavorare con i dati e controllare il codice prodotto anche con l'aiuto dell'AI.
EDA	Esplorare, visualizzare e descrivere i dati prima dell'inferenza formale.

Se parti da zero, segui l'ordine:

Fondamenti $\rightarrow$ R $\rightarrow$ EDA.

Se conosci già alcuni argomenti, puoi usare i capitoli anche come materiale di consultazione.

Prerequisiti

Non sono richiesti prerequisiti formali.

Per iniziare servono:

- interesse per la ricerca psicologica;
- disponibilità a eseguire e modificare esempi;
- un computer su cui installare R e gli strumenti descritti nei capitoli dedicati.

La parte **Fondamenti** è concettuale e può essere letta senza software. Le parti **R** ed **EDA** richiedono invece un ambiente di lavoro configurato.

Collegamento con il progetto editoriale

Questo modulo non sostituisce il manuale e non costituisce un prerequisito obbligatorio per leggerlo. Offre il supporto metodologico e operativo necessario soprattutto a chi vuole eseguire le analisi e comprendere i dati prima della modellizzazione.

Le risorse del progetto hanno funzioni complementari:

Risorsa	Funzione
Manuale UTET	Nucleo concettuale del ragionamento e del workflow bayesiano.
Companion	Laboratorio operativo per modelli, diagnostica, brms e Stan.
Probabilità per la psicologia	Richiamo su probabilità, distribuzioni, verosimiglianza e teorema di Bayes.
Inferenza frequentista	Termine di confronto per stime, intervalli, test e potenza.
Questo sito	Fondamenti dei dati, sintassi essenziale di R e analisi esplorativa.

Prima di un modello, questo sito invita a chiedersi:

- da dove provengono i dati;
- che cosa misurano;
- quali trasformazioni hanno subito;
- quali anomalie e strutture contengono;
- quali conclusioni descrittive, associative o causali sono giustificate.

Come usare questo sito

Quando incontri un esempio in R:

1. esegui;
2. identifica l'oggetto su cui lavora;
3. osserva il risultato;
4. modifica un elemento;
5. spiega che cosa è cambiato e perché;
6. controlla eventuali valori mancanti, avvisi o errori.

Puoi chiedere a un assistente AI di spiegare, completare o correggere il codice. La responsabilità dell'analisi rimane però di chi la esegue: un comando che funziona non è necessariamente un comando appropriato.

Da dove iniziare

Inizia dalla [Prefazione](#), che presenta il metodo di lavoro, oppure passa direttamente alla sezione [Fondamenti](#).

Feedback

Errori, passaggi poco chiari e problemi nel codice possono essere segnalati tramite il repository GitHub o con il pulsante *Segnala un problema* presente nelle pagine del sito.

Licenza

I materiali sono distribuiti con licenza [CC BY-NC-ND 4.0](#).

Prefazione

Questo sito raccoglie materiali metodologici e operativi collegati al manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza*. Il manuale costituisce il nucleo concettuale del progetto e può essere letto autonomamente. Questo modulo diventa particolarmente utile quando si vuole lavorare direttamente con i dati e seguire le implementazioni del Companion.

Prima di stimare un modello occorre capire:

- come sono stati generati i dati;
- che cosa rappresentano le variabili;
- come organizzare e controllare il dataset;
- quali caratteristiche emergono da tabelle e grafici;
- quali domande il disegno consente realmente di affrontare.

Il percorso è costruito attorno a tre attività: **pensare, fare e guardare**.

Pensare: dati, misure e disegni

La parte **Fondamenti** affronta le questioni preliminari a qualsiasi analisi.

Che cosa significa quantificare un costrutto psicologico? Qual è l'unità di analisi? Come vengono selezionati i partecipanti? Quali conclusioni descrittive, associative o causali sono sostenute dal disegno?

Una procedura statistica può essere eseguita correttamente e produrre comunque una conclusione poco informativa, se la variabile non rappresenta adeguatamente il costrutto o se il disegno non identifica il confronto di interesse.

Per questo motivo, la prima competenza richiesta non è tecnica. È la capacità di collegare:

domanda $\longrightarrow$ disegno $\longrightarrow$ misura $\longrightarrow$ dati.

Fare: usare R senza diventare programmatori

La parte **R** fornisce gli strumenti minimi per lavorare con i dati in modo trasparente e riproducibile.

L'obiettivo non è memorizzare l'intero linguaggio, scrivere algoritmi complessi o sviluppare software. Al termine del percorso dovresti saper:

- leggere un comando semplice;
- riconoscere oggetti, funzioni e argomenti;
- modificare nomi di variabili e opzioni;
- importare e trasformare piccoli dataset;
- comprendere messaggi di errore elementari;
- controllare che il codice esegua davvero l'operazione richiesta;

- conservare un documento riproducibile dell'analisi.

Questa è una **competenza operativa e di controllo**. È sufficiente per usare esempi, documentazione e assistenti AI senza dipendere ciecamente dal codice generato.

💡 Usare l'AI come assistente

Un assistente AI può aiutarti a:

- spiegare un comando;
- proporre una trasformazione;
- correggere un errore;
- adattare un grafico;
- commentare un risultato.

Per ottenere una risposta controllabile, indica sempre:

- struttura e nomi delle variabili;
- risultato desiderato;
- pacchetti che intendi usare;
- trattamento dei valori mancanti;
- eventuali vincoli sul formato dell'output.

Esegui poi il codice un passaggio alla volta e verifica gli oggetti prodotti. Il fatto che il codice funzioni senza errori non dimostra che l'analisi sia corretta.

Guardare: esplorare prima di modellizzare

La parte **EDA** (*Exploratory Data Analysis*) è dedicata all'esplorazione critica dei dati prima dell'inferenza formale.

Tabelle e grafici servono a esaminare:

- distribuzioni e variabilità;
- valori mancanti;
- osservazioni insolite;
- differenze tra gruppi;
- relazioni tra variabili;
- possibili errori di codifica;
- caratteristiche che il modello dovrà spiegare.

L'EDA non è una procedura automatica per «verificare le assunzioni» né una ricerca indiscriminata di risultati interessanti. È un dialogo disciplinato tra domanda, dati e rappresentazioni.

Una media può nascondere asimmetria o sottogruppi. Un coefficiente di correlazione può nascondere una relazione non lineare. Un grafico può rivelare che l'unità di analisi è stata interpretata in modo sbagliato.

L'obiettivo non è produrre molti grafici, ma porre domande migliori.

Perché questi materiali sono riuniti?

Programmazione, misurazione e statistica descrittiva non sono fasi indipendenti.

Ogni analisi richiede una sequenza simile:

domanda → dati ordinati → esplorazione → modello → controllo.

La domanda stabilisce che cosa vogliamo apprendere. Il disegno e la misura determinano quali dati vengono prodotti. R consente di organizzare e documentare le operazioni. L'EDA mostra quali strutture il modello dovrà rappresentare.

Solo dopo questi passaggi ha senso affrontare l'inferenza formale.

Il progetto complessivo

Questo sito fa parte di un insieme di risorse con funzioni complementari.

Risorsa	Contenuto principale	Collegamento
Manuale UTET	Ragionamento bayesiano, modellizzazione e workflow scientifico	Guida al manuale
Questo sito	Dati, misurazione, R essenziale e analisi esplorativa	utet-eda
Probabilità per la psicologia	Probabilità condizionata, distribuzioni, verosimiglianza e teorema di Bayes	utet-prob
Inferenza frequentista	Stime, intervalli di confidenza, test e potenza	utet-frequentista
Companion	Implementazione dei modelli con R, brms e Stan; diagnostica e controlli predittivi	utet-companion

Il manuale cartaceo è pensato per essere letto autonomamente. I moduli online permettono di recuperare prerequisiti, eseguire il codice e approfondire gli aspetti computazionali.

A chi è destinato

Il modulo è rivolto principalmente a:

- studenti di psicologia che iniziano l'analisi dei dati;
- lettori del manuale senza esperienza di R;
- ricercatori che vogliono consolidare un workflow riproducibile;
- persone che usano strumenti AI e desiderano controllare il codice prodotto.

Non sono richieste conoscenze pregresse di programmazione o statistica avanzata.

Come procedere

Se parti da zero, il percorso consigliato è:

1. **Fondamenti**, per comprendere dati, misure e disegni;
2. **R**, per acquisire la sintassi operativa essenziale;
3. **EDA**, per descrivere e visualizzare i dati.

I capitoli possono anche essere consultati singolarmente durante il lavoro pratico.

Per ogni esempio:

1. esegui il codice;
2. descrivi a parole che cosa fa;
3. modifica un elemento;
4. osserva il risultato;
5. controlla se l'output risponde alla domanda.

Il codice, da solo, non costituisce una spiegazione. La competenza consiste nel collegare ogni istruzione a una scelta sui dati e a una domanda di ricerca.

Parte I.

Fondamenti

Pensare prima di calcolare.

i In sintesi

Questa parte introduce le domande che precedono qualsiasi analisi dei dati. Prima di usare R, costruire un grafico o stimare un modello, occorre capire quale fenomeno si vuole studiare, come sono state prodotte le osservazioni, che cosa rappresentano le variabili e quali conclusioni il disegno consente di sostenere.

L'obiettivo non è anticipare le tecniche statistiche, ma costruire il quadro concettuale necessario per usarle in modo scientificamente sensato.

Pensare prima di calcolare

Nel linguaggio quotidiano, i dati vengono spesso immaginati come numeri già disponibili in una tabella. Nella ricerca psicologica, invece, un dataset è il punto di arrivo di molte decisioni. Prima che compaia una singola riga, qualcuno ha formulato una domanda, definito una popolazione, scelto un disegno, selezionato partecipanti o unità di osservazione, stabilito come misurare i fenomeni e deciso come codificare le risposte.

Queste decisioni non costituiscono una premessa esterna all'analisi. Determinano il significato dei dati e delimitano ciò che possiamo apprendere da essi.

Supponiamo di voler studiare la relazione tra stress accademico e qualità del sonno negli studenti universitari. Non basta raccogliere due punteggi e calcolare una correlazione. Dobbiamo chiarire che cosa intendiamo per stress, come viene misurato il sonno, quali studenti entrano nello studio, in quale periodo vengono osservati e quale popolazione dovrebbe essere rappresentata. Dobbiamo inoltre distinguere una semplice associazione dalla conclusione più forte secondo cui lo stress produrrebbe un cambiamento nel sonno.

Un calcolo può essere eseguito correttamente e rispondere comunque a una domanda mal definita. Un grafico può essere elegante e rappresentare una misura poco valida. Una stima può essere molto precisa e riferirsi a un campione selezionato. Un modello può convergere senza rappresentare adeguatamente il processo psicologico che gli viene attribuito.

Per questo motivo, il percorso comincia dai fondamenti e non dalla sintassi di R.

Dai fenomeni psicologici ai dati

Molti oggetti della psicologia non sono direttamente osservabili. Attenzione, ansia, motivazione, memoria, impulsività e benessere sono costrutti teorici. Entrano nel dataset attraverso risposte a questionari, comportamenti, tempi di reazione, giudizi di osservatori, prestazioni e segnali fisiologici.

Il passaggio dal fenomeno al dato può essere rappresentato come una sequenza:

fenomeno → domanda → disegno → misurazione → dati.

Ogni passaggio restringe il significato di ciò che osserviamo. La domanda seleziona un aspetto del fenomeno. Il disegno stabilisce quali confronti siano possibili. La misurazione traduce il costrutto in indicatori. Il dataset conserva il risultato di queste operazioni, ma non sempre ne conserva automaticamente la storia.

Quando riceviamo un file già pronto, è facile dimenticare questo percorso e trattare le colonne come entità naturali. Una variabile chiamata *stress* sembra rappresentare direttamente lo stress; una colonna numerica sembra autorizzare il calcolo della media; più righe sembrano indicare più informazioni indipendenti. Queste conclusioni possono essere sbagliate.

La prima competenza nell'analisi dei dati consiste quindi nel ricostruire che cosa rappresentano righe, colonne e valori.

Quattro passaggi concettuali

I capitoli di questa Parte seguono una progressione. Non costituiscono un elenco di definizioni da memorizzare, ma quattro prospettive da applicare ogni volta che si incontra un nuovo dataset.

Capitolo	Domanda centrale	Funzione nel percorso
Capitolo 2	Che cos'è un dato?	Introduce popolazione, campione, unità di analisi, variabile, parametro, statistica e incertezza.
Capitolo 3	Come sono state generate le osservazioni?	Collega campionamento, assegnazione, struttura dei dati, generalizzazione e causalità.
Capitolo 4	Che cosa significa il valore osservato?	Distingue costrutto, operazionalizzazione, indicatore, punteggio, affidabilità e validità.
Capitolo 5	Quale processo può generare il pattern?	Introduce il passaggio dalla descrizione dei dati alla modellizzazione dei processi psicologici.

Il primo capitolo costruisce il lessico minimo. Il secondo mostra che il modo in cui i dati vengono raccolti determina le conclusioni giustificate. Il terzo affronta il problema centrale della psicologia quantitativa: il rapporto tra costrutti e punteggi. Il quarto sposta infine l'attenzione dalla descrizione di un pattern alla formulazione di un processo capace di generarlo.

La progressione può essere letta anche come un aumento graduale delle pretese scientifiche. Prima descriviamo che cosa è stato osservato. Poi chiediamo a chi e a quali condizioni la descrizione possa essere estesa. Successivamente valutiamo se i valori rappresentino davvero i costrutti dichiarati. Solo allora possiamo proporre modelli esplicativi.

Un esempio che accompagna la Parte

La relazione tra stress accademico e qualità del sonno accompagnerà diversi capitoli perché permette di vedere come una stessa domanda cambi significato quando cambiano disegno, misura e obiettivo.

Possiamo limitarci a descrivere quanto siano diffusi livelli elevati di stress in uno specifico gruppo di studenti. Possiamo studiare se stress e sonno varino insieme. Possiamo osservare le stesse persone nel tempo per capire se una variabile preceda l'altra. Possiamo infine valutare un intervento progettato per ridurre lo stress e verificare se il sonno cambi di conseguenza.

Queste domande non richiedono soltanto analisi statistiche differenti. Richiedono soprattutto dati generati in modi differenti.

Anche la misurazione modifica il problema. Lo stress può essere rappresentato da un singolo item, da una scala composta, da un diario giornaliero o da indicatori fisiologici. La qualità del sonno può essere descritta mediante ore dichiarate, valutazioni soggettive, risvegli o dati strumentali. Due studi che usano la stessa parola possono quindi osservare aspetti differenti del fenomeno.

Un modello esplicativo aggiunge un ulteriore livello. Potremmo ipotizzare che lo stress aumenti la ruminazione serale e che la ruminazione interferisca con il sonno. Questa proposta non deriva automaticamente da una correlazione. Richiede una teoria, misure adatte e un disegno capace di distinguere il processo da spiegazioni alternative.

L'esempio mostra perché l'analisi non inizia dal comando da eseguire. Inizia dalla relazione tra la domanda e i dati necessari per affrontarla.

Il rapporto con R e con l'EDA

La Parte dedicata a R introdurrà gli strumenti necessari per lavorare con i dati in modo riproducibile. Impareremo a creare e ispezionare oggetti, selezionare variabili, trasformare tabelle, trattare valori mancanti e produrre rappresentazioni grafiche.

Queste operazioni non saranno presentate come esercizi di programmazione autonomi. Ogni comando dovrà essere collegato al significato dei dati. Se una persona compare più volte, per esempio, dovremo preservare l'identificatore che lega le osservazioni. Se una colonna numerica contiene categorie ordinate, dovremo evitare di interpretarla automaticamente come una misura continua. Se alcuni valori mancano, dovremo capire come e perché siano diventati mancanti prima di eliminarli da un calcolo.

L'uso di un assistente AI non modifica questa responsabilità. L'AI può generare rapidamente una sintassi corretta, ma non conosce automaticamente l'unità di analisi, la validità della misura o la logica del disegno. Chi analizza i dati deve saper verificare se il codice rispetti queste caratteristiche.

La Parte dedicata all'EDA mostrerà poi come osservare distribuzioni, differenze, relazioni e anomalie. L'esplorazione sarà più informativa proprio perché sapremo che cosa rappresentano le variabili e quali strutture del disegno devono rimanere visibili.

Il percorso complessivo diventa quindi:

domanda → dati comprensibili → esplorazione → modello → controllo.

Il rapporto con il manuale e il Companion

Il manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza* sviluppa il quadro concettuale della modellizzazione bayesiana. Il Companion mostra come costruire, stimare e controllare modelli con R, brms e Stan. Questo sito prepara quel lavoro concentrandosi su ciò che viene prima del modello.

L'inferenza bayesiana rappresenta l'incertezza sui parametri e sulle predizioni in modo esplicito. Non può però correggere automaticamente una misura che non rappresenta il costrutto, un campione che non rappresenta la popolazione o un disegno che non identifica il confronto causale.

Una distribuzione a posteriori può essere calcolata con grande precisione rispetto a un problema scientifico mal posto. Per questo il progetto editoriale non separa la statistica dalla metodologia. Imparare a ragionare con l'incertezza significa anche riconoscere l'incertezza introdotta dalla selezione, dalla misurazione, dal contesto e dalle assunzioni teoriche.

Come leggere questa Parte

La Parte può essere letta interamente prima di iniziare R oppure consultata durante il lavoro pratico. La seconda modalità è spesso utile: quando una variabile non è chiara, si può tornare al capitolo sulla misurazione; quando le righe non sembrano indipendenti, al capitolo sul disegno; quando un grafico mostra un pattern interessante, al capitolo sui modelli.

Alla fine del percorso, l'obiettivo non è ricordare una lunga lista di termini. È acquisire un'abitudine di lettura. Di fronte a un dataset dovremmo riuscire a ricostruire quale fenomeno viene studiato, chi o che cosa è stato osservato, come sono stati prodotti i valori e quale tipo di conclusione sia proporzionato alle informazioni disponibili.

Questa abitudine protegge dal rischio più comune nell'analisi dei dati: ottenere una risposta tecnicamente corretta a una domanda che i dati non potevano realmente affrontare.

2. Concetti chiave

In sintesi

Prima di usare R, costruire grafici o stimare modelli, bisogna chiarire che cosa rappresentano i dati. In psicologia, i numeri non sono osservazioni neutrali: derivano da una domanda di ricerca, da un disegno, da strumenti di misura e da decisioni operative. Questo capitolo introduce il lessico necessario per passare da un fenomeno psicologico a una matrice di dati interpretabile.

Introduzione

Quando si apre un dataset, è naturale guardare subito le colonne, calcolare qualche statistica descrittiva o produrre un grafico. Dal punto di vista scientifico, però, l'analisi comincia prima del file. Occorre capire quale fenomeno si vuole studiare, quali unità sono state osservate, come sono state definite le variabili e a quale popolazione si vorrebbero riferire le conclusioni.

Il filo conduttore del capitolo è semplice: i dati acquistano significato soltanto quando sappiamo da dove provengono e che cosa rappresentano. Questa idea accompagnerà l'intero percorso, dal disegno di ricerca alla misurazione, dalla preparazione dei dati all'analisi esplorativa e, infine, alla costruzione dei modelli.

Due significati di statistica

Il termine *statistica* può indicare sia la disciplina che studia come raccogliere, organizzare, analizzare e interpretare i dati, sia un valore numerico calcolato su un campione, come una media, una deviazione standard o una correlazione.

Nel primo senso, la statistica è un metodo di ragionamento. Nel secondo, una statistica è un riassunto dei dati osservati.

Prerequisiti

Non sono richieste conoscenze tecniche di statistica o di R. È sufficiente avere familiarità con domande empiriche tipiche della psicologia, per esempio se lo stress accademico sia associato alla qualità del sonno oppure se un intervento riduca i sintomi d'ansia.

Per un approfondimento facoltativo si possono consultare *Horoscopes*, discusso nell'ultimo capitolo di McElreath (2020), e *The Effect: An Introduction to Research Design and Causality*, in particolare il capitolo dedicato ai treatment effects.

Panoramica del capitolo

Il capitolo segue il percorso che trasforma un fenomeno in dati analizzabili. Partiremo dalla domanda di ricerca, distingueremo unità statistiche, osservazioni e variabili, chiariremo il rapporto

tra popolazione e campione e introdurremo parametri, statistiche, variabilità e bias. Nella parte finale distingueremo descrizione, stima e inferenza e vedremo perché un'associazione osservata non autorizza automaticamente una conclusione causale.

Preparazione del notebook

Questo capitolo è concettuale e non richiede di eseguire codice. Gli esempi preparano però il vocabolario che useremo nei capitoli su R, sulla struttura dei dataset e sull'analisi esplorativa.

2.1. Perché partire dai concetti chiave

Un dataset è il risultato di una sequenza di decisioni. Un fenomeno viene considerato rilevante, trasformato in una domanda di ricerca e collegato a persone, situazioni o comportamenti osservabili. Le osservazioni vengono poi registrate come variabili e organizzate in una matrice di dati. Soltanto a quel punto possono essere descritte, esplorate e usate per costruire inferenze.

Ogni passaggio introduce delle scelte. Alcune riguardano il disegno dello studio, altre la misurazione, altre ancora il modo in cui i dati vengono codificati e analizzati. I dati non sono quindi indipendenti dal contesto in cui sono stati prodotti (Johnson et al., 2022).

Idea guida

Una buona analisi non inizia chiedendosi quale tecnica applicare, ma che cosa rappresentino i dati e quali conclusioni possano sostenere.

2.2. Un esempio guida: stress accademico e sonno

Useremo come esempio ricorrente una domanda apparentemente semplice:

Gli studenti universitari che riportano livelli più alti di stress accademico dormono peggio?

Per trasformarla in uno studio bisogna precisare diversi aspetti. La popolazione potrebbe comprendere gli studenti di un singolo corso, di un ateneo o tutti gli studenti universitari. Lo stress accademico potrebbe indicare il carico di studio, la pressione percepita o l'ansia da prestazione. Anche *dormire peggio* può riferirsi a meno ore di sonno, a una qualità soggettiva inferiore o a un maggior numero di risvegli.

La modalità di raccolta modifica ulteriormente il significato dei dati. Un questionario, un diario del sonno e un dispositivo indossabile non producono osservazioni equivalenti. Infine, occorre stabilire se lo scopo sia descrivere un'associazione oppure sostenere che lo stress provochi un peggioramento del sonno.

Il passaggio da una domanda intuitiva a un dataset richiede dunque molte specificazioni. Questo è particolarmente importante in psicologia, dove si studiano spesso costrutti che non sono osservabili direttamente, come stress, ansia, autostima, benessere e motivazione.

2.3. Fenomeni, domande e dati

Un *fenomeno* è qualcosa che vogliamo comprendere: un comportamento, un processo mentale, una differenza tra gruppi, un cambiamento nel tempo o una relazione tra variabili. Una *domanda di ricerca* traduce quel fenomeno in una forma che può essere discussa empiricamente.

Nel nostro esempio, il fenomeno generale riguarda il rapporto tra vita accademica e benessere. Una domanda empirica potrebbe chiedere se esista un'associazione tra stress accademico percepito e qualità del sonno.

I *dati* sono le osservazioni raccolte per affrontare la domanda. Possono essere numeri, categorie, risposte testuali, tempi di reazione, punteggi di questionari, scelte comportamentali o misure fisiologiche. Ciò che li rende scientificamente utili non è il fatto che siano numerici, ma il collegamento con una domanda e una procedura di raccolta esplicita.

Errore comune

Un numero non è automaticamente più scientifico di una descrizione verbale. Diventa informativo soltanto quando sappiamo che cosa rappresenta, come è stato ottenuto e quali limiti interpretativi comporta.

2.4. Unità statistiche, osservazioni e variabili

L'*unità statistica* è l'entità sulla quale vengono raccolte le informazioni. In molti studi psicologici coincide con una persona, ma può essere anche una coppia, una classe, una seduta terapeutica, una risposta a un item, una prova sperimentale o un gruppo.

Un'*osservazione* è un'informazione registrata su una determinata unità. Una *variabile* è invece una caratteristica che può assumere valori diversi tra unità o tra occasioni di misura.

Nello studio su stress e sonno, le unità potrebbero essere gli studenti. Per ciascuno potremmo osservare il punteggio di stress, le ore di sonno, la qualità soggettiva del sonno, l'età, il genere, il corso di laurea e il numero di esami imminenti.

Esempio

Se osserviamo 120 studenti e registriamo per ciascuno stress percepito, ore di sonno e qualità del sonno, abbiamo 120 unità statistiche. In una tabella ordinaria ogni riga rappresenta uno studente e ogni colonna una variabile.

2.5. La matrice dei dati

Nelle analisi introduttive, i dati sono spesso organizzati in una tabella in cui le righe rappresentano le unità statistiche e le colonne le variabili.

id_studente	stress	ore_sonno	qualita_sonno	genere	esami_imminenti
1	18	6.5	3	F	2
2	27	5.0	2	M	4

Questa struttura è alla base di molte operazioni in R: selezionare colonne, filtrare righe, calcolare statistiche descrittive, costruire grafici e stimare modelli. Una tabella ben ordinata, tuttavia, non garantisce che i dati siano adeguati alla domanda. Le variabili devono essere definite con chiarezza, le osservazioni devono avere una qualità sufficiente e il campione deve essere pertinente rispetto alla popolazione di interesse.



Collegamento con R

Nei capitoli su R e dplyr la matrice dei dati diventerà un oggetto da selezionare, filtrare, trasformare, raggruppare e riassumere. Qui interessa soprattutto il significato scientifico delle righe e delle colonne.

2.6. Popolazione e campione

La *popolazione* è l'insieme delle unità alle quali vorremmo riferire le conclusioni. Il *campione* è l'insieme delle unità effettivamente osservate.

Nel nostro esempio, la popolazione potrebbe comprendere gli studenti di uno specifico corso, tutti gli studenti di un ateneo oppure una popolazione universitaria più ampia. Queste formulazioni non sono equivalenti. Se i dati provengono soltanto dagli studenti di un singolo corso, non è automatico che il risultato descriva tutti gli studenti universitari.

La qualità del passaggio dal campione alla popolazione dipende dal modo in cui il campione è stato formato.



Generalizzazione

Generalizzare significa usare ciò che abbiamo osservato nel campione per ragionare su una popolazione più ampia. Un campione numeroso non è necessariamente rappresentativo, e un campione non rappresentativo può produrre conclusioni molto precise ma fuorvianti.

2.6.1. Campioni e rappresentatività

Un campione è rappresentativo quando riflette la popolazione rispetto agli aspetti rilevanti per la domanda. In psicologia sono frequenti i campioni di convenienza, composti per esempio da studenti reclutati durante le lezioni, volontari online o persone disponibili in un contesto specifico.

Questi campioni possono essere utili, soprattutto nelle fasi esplorative, ma limitano le generalizzazioni. Il punto non è escluderli sempre, bensì dichiarare con precisione quali conclusioni consentano e quali no.

2.7. Parametri e statistiche

Un *parametro* è una caratteristica numerica della popolazione. Una *statistica* è una quantità numerica calcolata sul campione.

Immaginiamo di voler conoscere la media delle ore di sonno degli studenti universitari italiani durante la sessione d'esame. La media nella popolazione è un parametro. Se osserviamo 120 studenti e calcoliamo la loro media, otteniamo una statistica campionaria.

Parametro e statistica

Il parametro è ciò che vorremmo conoscere nella popolazione. La statistica è ciò che possiamo calcolare dai dati osservati. L'inferenza nasce dalla distanza tra queste due quantità.

La statistica campionaria raramente coincide esattamente con il parametro. Ripetendo lo studio con un altro campione, otterremmo probabilmente un valore diverso. Questa variabilità tra campioni è una delle fonti fondamentali dell'incertezza statistica.

2.8. Variabilità e incertezza

La variabilità è una caratteristica normale dei dati psicologici. Le persone differiscono tra loro, cambiano nel tempo e reagiscono in modo diverso a contesti simili. Anche studiando lo stesso fenomeno, non osserviamo sempre gli stessi valori.

L'incertezza non deriva soltanto dal fatto che osserviamo un campione invece dell'intera popolazione. I costrutti psicologici vengono misurati in modo imperfetto, i dati possono contenere errori o valori mancanti, il disegno può introdurre distorsioni e ogni modello statistico semplifica il fenomeno.

L'analisi statistica serve anche a rendere esplicita questa incertezza. Nel progetto bayesiano essa verrà rappresentata direttamente mediante distribuzioni di probabilità. Per ora è sufficiente riconoscere che non costituisce un difetto occasionale dei dati, ma una condizione ordinaria del ragionamento empirico.

2.9. Bias: quando i dati si spostano in una direzione

La variabilità non è l'unico problema. Un campione, una misura o un procedimento possono essere sistematicamente distorti. Con *bias* indichiamo una distorsione che tende a spostare i risultati in una determinata direzione.

Nello studio su stress e sonno, potrebbe verificarsi un bias se rispondessero soprattutto gli studenti più stressati, se venissero inclusi soltanto quelli presenti a lezione o se la qualità del sonno fosse misurata con una domanda ambigua. Anche la desiderabilità sociale può modificare le risposte. Raccogliere dati soltanto durante la settimana degli esami e interpretarli come rappresentativi dell'intero semestre produrrebbe un'altra forma di distorsione.

Comprendere chi ha raccolto i dati, in quale momento, con quali strumenti e secondo quali criteri è quindi essenziale (Johnson et al., 2022). Nei capitoli successivi distingueremo i bias che derivano dal disegno, dalla misurazione e dalle decisioni prese durante la preparazione dei dati.

Errore comune

Aumentare la dimensione del campione può ridurre la variabilità campionaria, ma non elimina automaticamente il bias. Un campione molto grande e distorto può produrre una stima estremamente precisa della quantità sbagliata.

2.10. Variabili: significato e ruolo nella domanda

Una variabile può essere numerica o categoriale, osservata direttamente oppure costruita a partire da più risposte. Per interpretarla occorre considerare sia il tipo di informazione sia il ruolo che svolge nella domanda.

Le ore di sonno sono una misura quantitativa. Il genere, quando viene registrato mediante categorie, è una variabile categoriale. Una valutazione della qualità del sonno su pochi livelli ordinati può essere trattata come variabile ordinale.

Nella domanda «lo stress accademico è associato alla qualità del sonno?», lo stress svolge il ruolo di variabile esplicativa o predittiva e la qualità del sonno quello di variabile esito. Questa distinzione organizza l'analisi, ma non stabilisce da sola una relazione causale.

i Variabile indipendente e variabile dipendente

Nei disegni sperimentali si parla spesso di variabile indipendente e variabile dipendente. La prima è manipolata dal ricercatore e la seconda costituisce l'esito osservato. Negli studi osservazionali è generalmente più prudente parlare di variabile esplicativa o predittiva e di variabile esito.

2.11. Descrivere, stimare e inferire

Una stessa matrice di dati può essere usata per scopi differenti.

Descrivere significa riassumere ciò che è stato osservato nel campione attraverso medie, frequenze, distribuzioni, grafici e identificazione di osservazioni insolite. *Stimare* significa usare il campione per ottenere un valore riferito a una quantità della popolazione, come una media o una differenza tra medie. *Inferire* significa formulare conclusioni più generali tenendo conto dell'incertezza, delle assunzioni e dei limiti del disegno.

L'analisi esplorativa si concentra soprattutto sulla descrizione di distribuzioni, pattern, anomalie e possibili relazioni. Anche una descrizione richiede però attenzione concettuale. Un grafico può mostrare un'associazione, ma il suo significato dipende dal campione, dalla misura e dal modo in cui lo studio è stato costruito.

2.12. Effetti e causalità: una cautela iniziale

Nel linguaggio psicologico e statistico, la parola *effetto* può essere ambigua. A volte indica semplicemente una differenza o un'associazione osservata; altre volte suggerisce una relazione causale.

Se gli studenti con stress più elevato riportano una qualità del sonno inferiore, abbiamo osservato un'associazione. Per sostenere che lo stress provochi il peggioramento del sonno, occorre però considerare il disegno e le spiegazioni alternative. Carico di lavoro, salute mentale precedente, abitudini di studio e condizioni economiche potrebbero influenzare entrambe le variabili (Huntington-Klein, 2021).

Il tema sarà approfondito nei capitoli sul disegno di ricerca e sulla causalità. Per ora è sufficiente ricordare che i modelli statistici possono quantificare le associazioni, ma non producono da soli le condizioni necessarie per una conclusione causale.

2.13. Collegamento con il resto del percorso

I concetti introdotti qui ricompariranno in tutte le parti del sito. Il capitolo sul disegno di ricerca esaminerà come vengono generati i dati e quali inferenze siano autorizzate. Quello sulla misurazione discuterà che cosa rappresentino i valori osservati. Nei capitoli su R e dplyr impareremo a organizzare e controllare la matrice dei dati, mentre la parte EDA mostrerà come descrivere distribuzioni, anomalie e relazioni prima di costruire un modello.

Il modulo sulla probabilità fornirà il linguaggio necessario per rappresentare formalmente l'incertezza. Quello frequentista mostrerà come stime, intervalli e test vengano valutati attraverso campionamenti ripetuti. Il manuale e il Companion svilupperanno infine la modellizzazione bayesiana.

Collegamento con il manuale bayesiano

L'inferenza bayesiana non elimina i problemi di disegno, campionamento o misurazione. Li incorpora in un ragionamento probabilistico che richiede comunque di sapere che cosa è stato osservato, che cosa resta incerto e quali assunzioni collegano i dati alle conclusioni.

Riflessioni conclusive

I dati psicologici sono il risultato di un percorso che va dal fenomeno alla domanda, dalla domanda alla misura, dalla misura alla matrice dei dati e dalla matrice all'interpretazione. In ogni passaggio, le decisioni influenzano ciò che sarà possibile concludere.

Il messaggio centrale è che analizzare dati non significa soltanto applicare correttamente una procedura. Significa capire se quella procedura sia appropriata alla domanda, ai dati e al modo in cui sono stati prodotti. Prima di calcolare bisogna interpretare; prima di interpretare bisogna sapere che cosa si sta osservando.

Domande da portare con sé

Quando leggi o costruisci un dataset, chiediti quale sia la popolazione di interesse, quale campione sia stato osservato, quali variabili rappresentino il fenomeno e quali fonti di incertezza o bias limitino le conclusioni.

Esercizi

1. Nel caso dello studio su stress accademico e sonno, identifica il fenomeno generale, una possibile domanda di ricerca e almeno tre variabili osservabili.
2. Spiega la differenza tra popolazione e campione usando un esempio diverso da quello discusso nel capitolo.
3. Che differenza c'è tra un parametro e una statistica? Perché questa distinzione è importante per l'inferenza?
4. Immagina che uno studio sul benessere degli studenti recluti soltanto partecipanti volontari tramite un annuncio online. Quali bias potrebbero emergere?
5. Perché un campione molto grande non garantisce necessariamente conclusioni valide?

2. Concetti chiave

6. In che senso una variabile può essere definita dal tipo di informazione che contiene e dal ruolo che svolge nella domanda?
7. Spiega la differenza tra descrivere, stimare e inferire.
8. Perché osservare un'associazione tra due variabili non basta per concludere che una causa l'altra?

Soluzioni

1. Il fenomeno generale è il rapporto tra vita accademica e benessere. Una possibile domanda è se gli studenti con maggiore stress accademico riportino una qualità del sonno inferiore. Tra le variabili osservabili potrebbero comparire stress percepito, ore di sonno, qualità soggettiva del sonno, numero di esami imminenti e anno di corso.
2. La popolazione è l'insieme al quale si vorrebbero riferire le conclusioni; il campione è l'insieme osservato. Se si studia l'uso dei social media negli adolescenti italiani, la popolazione può comprendere tutti gli adolescenti italiani, mentre il campione potrebbe essere costituito da 300 studenti reclutati in alcune scuole.
3. Un parametro descrive una caratteristica della popolazione; una statistica è la corrispondente quantità calcolata nel campione. L'inferenza usa le statistiche osservate per ragionare sui parametri non osservati, tenendo conto dell'incertezza.
4. Potrebbe emergere un bias di autoselezione: parteciperebbero soprattutto studenti interessati al tema, particolarmente motivati oppure con esperienze molto positive o negative. Potrebbero inoltre essere esclusi studenti con minore accesso alle comunicazioni online o minore disponibilità di tempo.
5. Un campione grande riduce spesso la variabilità casuale, ma non elimina una selezione distorta, una misura inadeguata o un errore sistematico. Può quindi produrre una stima molto precisa ma riferita alla quantità sbagliata.
6. Il tipo di informazione riguarda il formato della variabile, per esempio numerico, categoriale o ordinale. Il ruolo riguarda la funzione nella domanda, come predittore, esito, variabile di controllo o possibile confondente.
7. Descrivere significa riassumere ciò che è osservato nel campione. Stimare significa usare il campione per ottenere un valore riferito alla popolazione. Inferire significa formulare conclusioni più generali tenendo conto dell'incertezza, delle assunzioni e dei limiti del disegno.
8. L'associazione potrebbe dipendere da variabili non considerate, selezione, errori di misura o causalità inversa. Una conclusione causale richiede informazioni aggiuntive sul disegno e sulle spiegazioni alternative.

Punti chiave

I dati acquistano significato dal legame con una domanda, una misura e un disegno. Righe e colonne di un dataset rappresentano unità e variabili, non semplici contenitori numerici. Il campione non coincide con la popolazione, una statistica non coincide con il parametro e un'associazione non coincide con una relazione causale. Variabilità e bias sono problemi distinti: la prima produce oscillazioni casuali, il secondo una distorsione sistematica.

i Ambiente di sviluppo

Il capitolo non richiede pacchetti o codice R. Le informazioni sull'ambiente di lavoro diventeranno rilevanti nella parte dedicata a R.

Bibliografia

3. Disegno della ricerca: quali conclusioni sono giustificate dai dati?

In sintesi

Da sapere I dati non parlano da soli: il loro significato dipende dal modo in cui persone, condizioni e misure sono state selezionate. Il campionamento riguarda soprattutto la possibilità di generalizzare; l'assegnazione alle condizioni riguarda soprattutto la credibilità delle conclusioni causali.

Da saper fare Ricostruire come un dataset è stato generato; distinguere popolazione target, popolazione accessibile e campione; riconoscere studi descrittivi, osservazionali e sperimentali; formulare conclusioni proporzionate al disegno.

Introduzione

Nel capitolo precedente abbiamo seguito il percorso che conduce da un fenomeno psicologico a una matrice di dati. Abbiamo visto che una riga non è semplicemente una sequenza di numeri: rappresenta un'unità osservata in circostanze precise, mediante procedure e strumenti determinati.

Ora facciamo un passo indietro. Prima di descrivere una distribuzione o costruire un grafico, dobbiamo capire come quelle righe siano entrate nel dataset. La stessa correlazione tra stress accademico e qualità del sonno può avere significati molto diversi se proviene da volontari reclutati durante la sessione d'esame, da un'indagine probabilistica nazionale, da misure ripetute durante un semestre o da un esperimento controllato.

La domanda guida del capitolo è quindi:

Quali conclusioni sono giustificate dal processo che ha generato questi dati?

L'analisi esplorativa aiuta a riconoscere regolarità e anomalie. R permette di organizzare, trasformare e visualizzare le osservazioni. L'inferenza statistica rappresenta l'incertezza. Nessuna di queste attività, tuttavia, può trasformare automaticamente un campione selezionato in una popolazione rappresentativa o un'associazione osservata in una relazione causale.

Prerequisiti

È sufficiente conoscere i concetti introdotti in Capitolo 2: popolazione, campione, unità di analisi, variabile, osservazione, parametro e statistica campionaria.

La discussione sui campioni WEIRD e sulla replicabilità in psicologia fornisce un contesto più ampio (Henrich et al., 2010; Youyou et al., 2023), ma non è necessaria per seguire l'argomentazione.

Panoramica del capitolo

Il capitolo parte dalla relazione tra domanda e disegno, distingue il campionamento dall'assegnazione alle condizioni e mostra come studi descrittivi, osservazionali e sperimentali sostengano conclusioni differenti. Successivamente esamina bias, validità, replicazione e struttura dei dati. L'ultima parte collega queste idee all'EDA e al workflow bayesiano: prima di scegliere un modello, occorre sapere quale processo dovrebbe rappresentare.

Preparazione del notebook

Questo capitolo è concettuale e non richiede l'esecuzione di codice. Nei capitoli successivi useremo R per ispezionare la struttura dei dataset, descrivere i campioni e rendere visibili differenze, dipendenze e possibili problemi di qualità.

3.1. Il disegno viene prima dell'analisi

Supponiamo di osservare che gli studenti con più stress accademico riportano una qualità del sonno peggiore. La frase sembra semplice, ma contiene molte decisioni implicite. Dobbiamo sapere quali studenti sono stati osservati, come sono stati reclutati, in quale periodo sono state raccolte le risposte, come sono stati misurati stress e sonno e se le osservazioni provengono da un unico momento o da misure ripetute.

Queste informazioni non sono dettagli amministrativi. Determinano che cosa significhi il risultato. Se i partecipanti sono volontari di un solo corso universitario, possiamo descrivere quel campione, ma la generalizzazione a tutti gli studenti richiede ulteriori argomenti. Se stress e sonno sono misurati nello stesso momento, possiamo studiarne l'associazione, ma non stabilire quale variabile venga prima. Se una condizione viene manipolata e assegnata casualmente, una conclusione causale diventa più credibile, almeno nel contesto definito dall'esperimento.

Il disegno collega quindi la domanda scientifica, il processo di raccolta e il tipo di conclusione che possiamo sostenere.

Principio guida

L'analisi statistica quantifica ciò che è stato reso osservabile dal disegno. Non amplia retroattivamente ciò che il disegno consente di apprendere.

3.2. Una domanda, disegni differenti

Consideriamo la domanda:

Gli studenti con livelli più elevati di stress accademico riportano una qualità del sonno peggiore?

Può essere affrontata in modi differenti.

Disegno	Che cosa viene osservato	Conclusione prudente
Descrittivo	Stress e sonno in un campione definito	«Nel campione, stress e sonno hanno queste distribuzioni.»

3. Disegno della ricerca: quali conclusioni sono giustificate dai dati?

Disegno	Che cosa viene osservato	Conclusione prudente
Trasversale	Stress e sonno misurati nello stesso momento	«Nel campione, le due variabili sono associate.»
Longitudinale	Le stesse variabili misurate in più momenti	«I cambiamenti o i livelli precedenti di una variabile sono associati a quelli successivi dell'altra.»
Sperimentale	Una condizione viene manipolata e assegnata	«Nelle condizioni dello studio, la manipolazione ha prodotto una differenza nell'esito.»

La tabella non stabilisce una gerarchia assoluta. Un'indagine descrittiva ben campionata può essere molto più informativa di un piccolo esperimento artificiale per stimare la prevalenza di un fenomeno. Un esperimento controllato può offrire una forte identificazione causale, ma dire poco su persone e contesti molto diversi da quelli studiati.

La qualità di un disegno dipende dalla domanda a cui deve rispondere.

3.3. Popolazione target, popolazione accessibile e campione

La **popolazione target** è l'insieme di unità a cui vorremmo riferire la conclusione. Potrebbero essere tutti gli studenti universitari italiani, gli iscritti a uno specifico ateneo oppure gli studenti che affrontano una determinata fase del percorso accademico.

La **popolazione accessibile** comprende invece le unità che possiamo realisticamente raggiungere. Se diffondiamo un questionario attraverso la piattaforma di un singolo insegnamento, la popolazione accessibile è molto più ristretta di tutti gli studenti universitari.

Il **campione** è formato dalle unità effettivamente osservate. È generalmente ancora più selezionato, perché non tutte le persone raggiungibili vengono invitate, accettano di partecipare o completano lo studio.

Queste tre popolazioni non coincidono automaticamente. La distanza tra loro deve essere descritta, non nascosta dietro un numero elevato di partecipanti.

Esempio

Uno studio svolto su studenti di psicologia di un solo ateneo durante la settimana precedente agli esami può offrire informazioni utili su quel contesto. Non autorizza però, senza ulteriori argomenti o repliche, affermazioni su tutti gli studenti universitari o sullo stress in ogni periodo dell'anno.

3.4. Campionamento e generalizzazione

Il **campionamento** è il processo con cui alcune unità vengono incluse e altre escluse dall'osservazione. La domanda centrale non è soltanto quanti partecipanti siano presenti, ma attraverso quale meccanismo siano entrati nel campione.

Nel campionamento probabilistico, ogni unità della popolazione possiede una probabilità nota e positiva di essere selezionata. Un campione casuale semplice richiede una lista adeguata della

popolazione. Un campione stratificato garantisce una rappresentazione pianificata di sottogruppi rilevanti. Un campionamento a grappoli seleziona unità collettive, come scuole o classi, e introduce una dipendenza che dovrà essere considerata anche nell'analisi.

Questi metodi non producono campioni perfettamente identici alla popolazione. Rendono però esplicito il meccanismo di selezione e permettono di valutare l'errore di campionamento in modo controllato.

Nella ricerca psicologica è frequente il campionamento di convenienza: partecipano persone facilmente raggiungibili, come studenti, utenti di una piattaforma o volontari reclutati online (Peterson & Merunka, 2014). Questa scelta può essere ragionevole per studi preliminari, sviluppo di procedure o analisi di meccanismi. Diventa problematica quando le conclusioni vengono estese a popolazioni che il campione non rappresenta.

La discussione sui campioni WEIRD mostra quanto cultura, istruzione, età, condizioni economiche e contesto istituzionale possano limitare l'universalità apparente di risultati ottenuti in gruppi molto selezionati (Henrich et al., 2010).

Grande non significa rappresentativo

Aumentare il numero di persone reclutate con lo stesso meccanismo riduce spesso la variabilità campionaria, ma non elimina una distorsione sistematica. Un campione enorme può stimare con grande precisione una quantità riferita a una popolazione diversa da quella che interessa.

Quando il campionamento di convenienza è inevitabile, la soluzione non consiste nel dichiararlo e dimenticarlo. Occorre descrivere accuratamente chi ha partecipato, limitare il linguaggio delle conclusioni, confrontare il campione con la popolazione target e cercare repliche in contesti differenti.

3.5. Campionamento e assegnazione rispondono a domande diverse

Due processi vengono spesso confusi.

Il **campionamento** determina chi entra nello studio e riguarda soprattutto la generalizzazione dalla parte osservata alla popolazione di interesse.

L'**assegnazione alle condizioni** determina quale esperienza riceve ciascun partecipante e riguarda soprattutto la comparabilità dei gruppi e la credibilità dell'inferenza causale.

Uno studio può avere assegnazione casuale ma campionamento di convenienza. In questo caso, il confronto tra condizioni può sostenere una conclusione causale per le persone e le circostanze studiate, mentre la generalizzazione a popolazioni più ampie rimane incerta.

Al contrario, un'indagine può usare un buon campionamento probabilistico ma essere puramente osservazionale. Può quindi descrivere bene una popolazione senza dimostrare che una variabile causi l'altra.

Due domande da tenere separate

Chi è rappresentato dal campione? riguarda il campionamento.

Che cosa rende confrontabili le condizioni? riguarda l'assegnazione e il controllo del disegno.

3.6. Bias: una distorsione del processo

La variabilità casuale produce risultati differenti da campione a campione. Il **bias** introduce invece una distorsione sistematica collegata al modo in cui i dati vengono selezionati, prodotti, registrati o interpretati.

Forma di bias	Come può comparire
Selezione	Alcune persone hanno probabilità maggiori di entrare nello studio.
Autoselezione	La decisione di partecipare è collegata al fenomeno studiato.
Non risposta	Chi non completa lo studio differisce sistematicamente da chi risponde.
Contesto	Momento, luogo o modalità di raccolta influenzano le osservazioni.
Osservatore	Aspettative o conoscenze influenzano somministrazione, valutazione o codifica.

Nel nostro esempio, gli studenti più stressati potrebbero non trovare il tempo per rispondere. In tal caso il campione potrebbe sottorappresentare proprio i livelli di stress più elevati. Raccogliere più risposte attraverso lo stesso canale renderebbe la stima più stabile, ma non necessariamente meno distorta.

Il bias non è sempre eliminabile. Deve però essere anticipato nel disegno, documentato durante la raccolta e considerato nell'interpretazione.

3.7. Descrivere, associare e spiegare

Uno studio **descrittivo** rappresenta come si distribuisce un fenomeno. Può stimare, per esempio, il livello medio di stress, la sua variabilità o la frequenza di punteggi molto elevati. La descrizione non è un'attività inferiore all'inferenza: senza una buona descrizione rischiamo di costruire modelli su dati che non abbiamo compreso.

Uno studio **osservazionale** esamina relazioni tra variabili senza assegnare direttamente le condizioni. Se stress e sonno vengono misurati nello stesso momento, una correlazione mostra che le variabili cambiano insieme nel campione. Non stabilisce se lo stress peggiori il sonno, se il sonno insufficiente aumenti lo stress o se entrambe le variabili dipendano da altre condizioni.

Uno studio **longitudinale** aggiunge l'ordine temporale. Se lo stress misurato a ottobre è associato al sonno di novembre, sappiamo che la misura dello stress precede l'esito. La precedenza temporale è necessaria per molte affermazioni causali, ma non è sufficiente: carico di lavoro, salute, condizioni economiche o tratti individuali potrebbero influenzare entrambe le variabili.

Disegni di coorte e caso-controllo organizzano l'osservazione in modi più specifici. Una coorte segue persone nel tempo per osservare l'insorgenza o il cambiamento di un esito. Uno studio caso-controllo parte invece dalla presenza dell'esito e ricostruisce esposizioni o caratteristiche precedenti. Entrambi possono essere molto informativi, ma richiedono attenzione a selezione, misurazione e ricordo.

3.8. Esperimenti e inferenza causale

In un esperimento il ricercatore manipola una condizione e osserva le conseguenze su un esito. La forza del disegno non deriva dalla parola *esperimento*, ma dalla combinazione di manipolazione, confronto e assegnazione.

La manipolazione definisce la differenza che dovrebbe produrre l'effetto. Il gruppo o la condizione di controllo mostra che cosa accade senza quella differenza, o con un'alternativa appropriata. L'assegnazione casuale rende i gruppi comparabili prima del trattamento in senso probabilistico, distribuendo tra le condizioni caratteristiche note e non note.

La randomizzazione non garantisce che ogni piccolo campione sia perfettamente bilanciato. Rende però plausibile attribuire differenze sistematiche successive alla manipolazione, purché procedure, abbandoni, aderenza e misure non introducano nuove distorsioni.

Le aspettative possono influenzare partecipanti, ricercatori e valutatori. Le procedure di cecità cercano di ridurre questa possibilità, quando sono praticabili. In alcuni studi il partecipante può ignorare la condizione assegnata; in altri anche chi somministra o valuta può non conoscere l'assegnazione. Quando la cecità non è possibile, le aspettative devono essere considerate esplicitamente come parte del disegno.

Il test statistico non crea causalità

Una differenza statisticamente significativa non trasforma gruppi osservazionali in condizioni sperimentali. L'interpretazione causale dipende dal processo che ha prodotto il confronto, non dal valore- p o dal tipo di modello utilizzato.

3.9. Disegni tra partecipanti ed entro partecipanti

In un disegno **between-subjects**, persone differenti partecipano a condizioni differenti. Ogni partecipante vive una sola condizione. Questo riduce contaminazione, apprendimento e memoria tra condizioni, ma lascia che le differenze individuali contribuiscano alla variabilità del confronto.

In un disegno **within-subjects**, le stesse persone partecipano a più condizioni. Ogni partecipante funge così da proprio riferimento e il confronto può risultare più preciso. Lo svantaggio è che l'esperienza di una condizione può modificare la risposta alla successiva attraverso pratica, affaticamento, memoria o effetti residui.

Il controbilanciamento distribuisce ordini differenti tra i partecipanti e riduce la confusione tra effetto della condizione ed effetto dell'ordine. Non elimina però ogni possibile effetto di trascinamento; la scelta del disegno deve dipendere dal fenomeno e dalla durata delle conseguenze della manipolazione.

Questa distinzione ha anche conseguenze sulla struttura del dataset. In un disegno tra partecipanti, ogni persona può comparire in una sola condizione. In un disegno entro partecipanti, la stessa persona produce più osservazioni, che non sono indipendenti e devono mantenere un identificatore comune.

3.10. Tre dimensioni della validità

La **validità interna** riguarda la credibilità della spiegazione causale. Chiede se la differenza osservata possa essere attribuita al trattamento oppure a confondenti, aspettative, abbandoni, cambiamenti procedurali o altre spiegazioni.

La **validità esterna** riguarda la possibilità di trasferire il risultato ad altre persone, situazioni, periodi o culture. Un esperimento molto controllato può identificare bene un effetto nelle condizioni studiate e avere, allo stesso tempo, una portata limitata fuori dal laboratorio.

La **validità di costrutto** riguarda il rapporto tra le operazioni osservate e i concetti teorici. Un questionario chiamato «stress» non misura automaticamente ogni aspetto dello stress accademico; una manipolazione potrebbe modificare ansia da valutazione, attivazione fisiologica o pressione sociale senza rappresentare il costrutto più ampio.

Le tre dimensioni non si compensano automaticamente. Un disegno può essere forte su una dimensione e debole su un'altra. Il capitolo successivo approfondirà la validità di costrutto attraverso il problema della misurazione.

3.11. Replicazione e portata delle conclusioni

Un singolo studio osserva una particolare combinazione di persone, misure, contesto e decisioni analitiche. La replicazione serve a capire quali aspetti del risultato rimangano stabili quando alcune di queste condizioni vengono ripetute o modificate (Youyou et al., 2023).

Una replicazione diretta cerca di mantenere il più possibile le procedure originarie. È utile per verificare se il risultato ricompare nelle stesse condizioni operative. Una replicazione concettuale cambia misura, campione o procedura mantenendo l'idea teorica centrale. È più informativa sulla portata della spiegazione, ma rende più difficile identificare la ragione di eventuali differenze.

La replicazione non è quindi una semplice votazione tra «successo» e «fallimento». È parte dell'accumulo dell'evidenza e aiuta a distinguere risultati legati a una configurazione molto specifica da regolarità che si mantengono attraverso contesti differenti.

3.12. Dal disegno al dataset

Prima di eseguire un'analisi esplorativa dobbiamo ricostruire il percorso che ha prodotto il file. Dobbiamo sapere che cosa rappresenta ogni riga, se la stessa persona compare più volte, come sono state codificate le condizioni, quali unità sono state escluse e in quali momenti sono state raccolte le misure.

Queste informazioni determinano anche le operazioni in R. Raggruppare per gruppo presuppone che l'etichetta identifichi correttamente la condizione. Calcolare una media per riga o per partecipante richiede di conoscere l'unità di analisi. Trattare tutte le righe come indipendenti può essere scorretto quando provengono dalla stessa persona, classe, famiglia o struttura organizzativa.

L'EDA non comincia quindi con `summary()` o `ggplot()`. Comincia dalla documentazione del disegno.

i Scheda minima prima dell'analisi

Prima di lavorare su un dataset dovrebbe essere possibile formulare, in poche frasi, chi è stato osservato, come è avvenuta la selezione, quale unità rappresenta una riga, quando sono state raccolte le misure e quale confronto il disegno rende interpretabile.

3.13. Collegamento con il workflow bayesiano

Un modello bayesiano rende esplicita l'incertezza sui parametri e sulle predizioni, condizionatamente alla prior, alla verosimiglianza e ai dati. Questa rappresentazione non comprende automaticamente ogni incertezza introdotta dal disegno.

Una distribuzione a posteriori molto concentrata può descrivere con precisione il parametro del modello per un campione selezionato. Non dimostra che il campione rappresenti la popolazione target. Un modello gerarchico può rappresentare dipendenze tra scuole o partecipanti, ma soltanto se tali strutture sono state registrate e incluse. Una probabilità a posteriori elevata per una differenza non trasforma un confronto osservazionale in un effetto causale.

Il disegno definisce dunque il problema che il modello può affrontare. Il workflow bayesiano aggiunge una rappresentazione coerente dell'incertezza, controlli predittivi e possibilità di confrontare modelli; non sostituisce la qualità della raccolta e della misurazione.

Riflessioni conclusive

I dati hanno una storia. Prima di descriverli o modellarli, dobbiamo sapere chi è stato osservato, come sono state assegnate le condizioni, quando sono state raccolte le misure e quali unità sono tra loro dipendenti.

Il campionamento determina soprattutto la portata della generalizzazione. L'assegnazione e il controllo determinano soprattutto la credibilità di una conclusione causale. Studi descrittivi, osservazionali, longitudinali e sperimentali non rappresentano versioni più o meno sofisticate della stessa domanda: rispondono a domande differenti.

L'analisi più avanzata non può recuperare informazioni che il disegno non ha prodotto. Può però rendere più trasparenti le assunzioni, quantificare l'incertezza appropriata e mostrare quali conclusioni rimangano compatibili con i dati.

Nel prossimo capitolo passeremo dal processo che seleziona le osservazioni al processo che assegna loro un significato numerico: la misurazione dei costrutti psicologici.

Esercizi

1. Uno studio vuole stimare lo stress medio degli studenti universitari italiani, ma recluta volontari attraverso un corso di psicometria di un singolo ateneo. Identifica popolazione target, popolazione accessibile e campione. Quale conclusione sarebbe proporzionata al disegno?
2. In uno studio trasversale, stress e qualità del sonno risultano correlati. Formula una conclusione giustificata e due spiegazioni causali che i dati non permettono di distinguere.

3. *Disegno della ricerca: quali conclusioni sono giustificate dai dati?*

3. Perché aumentare la numerosità di un campione di convenienza non elimina necessariamente il bias di selezione?
4. Uno studio usa un campione di convenienza, ma assegna casualmente i partecipanti a intervento e controllo. Che cosa sostiene la randomizzazione? Che cosa non risolve il campionamento?
5. Confronta un disegno between-subjects e uno within-subjects per valutare una tecnica di rilassamento. Quale struttura avrà il dataset nei due casi?
6. Perché la precedenza temporale osservata in uno studio longitudinale non è sufficiente a dimostrare causalità?
7. Un esperimento di laboratorio usa una manipolazione ben controllata, ma soltanto studenti giovani di un unico corso. Quale dimensione della validità appare più forte e quale richiede maggiore cautela?
8. Prima di analizzare un dataset trovi più righe per ogni identificatore di partecipante. Quale informazione sul disegno devi recuperare prima di calcolare statistiche o costruire grafici?

 Soluzioni

1. La popolazione target è costituita dagli studenti universitari italiani. La popolazione accessibile comprende gli studenti raggiunti attraverso quel corso e quell'ateneo. Il campione include soltanto chi accetta e completa lo studio. È giustificato descrivere il campione; una generalizzazione all'intera popolazione richiede molta cautela.
2. Possiamo affermare che, nel campione e nel momento osservato, livelli maggiori di stress sono associati a una peggiore qualità del sonno. Non possiamo distinguere se lo stress peggiori il sonno, se il sonno insufficiente aumenti lo stress o se una terza variabile influenzi entrambi.
3. La numerosità riduce la variabilità casuale, ma non modifica il meccanismo che rende alcune persone più probabili di altre nel campione. Molte osservazioni selezionate nello stesso modo possono produrre una stima molto precisa ma sistematicamente distorta.
4. La randomizzazione rende più credibile il confronto causale tra intervento e controllo per le persone studiate. Non garantisce che queste persone rappresentino tutti gli studenti, altre fasce d'età o altri contesti.
5. Nel disegno between-subjects ogni partecipante appartiene a una sola condizione. Nel disegno within-subjects ogni partecipante produce più osservazioni e deve mantenere lo stesso identificatore; le righe riferite alla stessa persona sono dipendenti.
6. Una variabile può precederne un'altra ed essere comunque associata a confondenti che producono entrambe. L'ordine temporale elimina alcune spiegazioni, ma non tutte.
7. La validità interna può essere forte grazie al controllo e alla randomizzazione. La validità esterna richiede cautela perché campione e contesto sono molto circoscritti.
8. Occorre sapere se le righe rappresentano momenti, condizioni, prove o misure differenti della stessa persona. Questa informazione determina l'unità di analisi e impedisce di trattare osservazioni dipendenti come indipendenti.

i Punti chiave

- Il disegno stabilisce quali conclusioni sono sostenute dai dati.
- Popolazione target, popolazione accessibile e campione non coincidono automaticamente.
- Il campionamento riguarda soprattutto la generalizzazione; l'assegnazione riguarda soprattutto la causalità.
- Una grande numerosità non elimina un bias sistematico.
- Studi descrittivi, osservazionali, longitudinali e sperimentali rispondono a domande differenti.
- La randomizzazione aumenta la credibilità causale, ma non garantisce la generalizzabilità.
- Validità interna, esterna e di costrutto devono essere valutate separatamente.
- La struttura del dataset riflette il disegno e determina quali operazioni in R siano appropriate.

i Ambiente di sviluppo

Il capitolo non richiede pacchetti aggiuntivi. Le informazioni sull'ambiente R possono essere ottenute con:

```
sessionInfo()
```

Bibliografia

4. Misurare i costrutti psicologici

In sintesi

Da sapere In psicologia, un costrutto come ansia, motivazione o benessere non viene osservato direttamente. Viene collegato a risposte, comportamenti o segnali attraverso una procedura di misurazione. Il punteggio ottenuto acquista significato soltanto entro questa relazione teorica e operativa.

Da saper fare Distinguere costrutto, operazionalizzazione, indicatore e dato; separare affidabilità e validità; riconoscere errore casuale e distorsione sistematica; comprendere quali operazioni sono coerenti con una scala; valutare criticamente item Likert, punteggi aggregati e codice R che li tratta come numeri.

Introduzione

Prima di calcolare una media, costruire un grafico o stimare un modello, dobbiamo chiederci che cosa rappresentino i numeri presenti nel dataset. In psicologia questa domanda è particolarmente importante, perché molti fenomeni di interesse non sono direttamente osservabili. Non vediamo l'ansia, la motivazione, l'impulsività o il benessere nello stesso modo in cui osserviamo la lunghezza di un oggetto. Vediamo risposte a domande, scelte, tempi di reazione, errori, comportamenti, giudizi di osservatori e segnali fisiologici.

La misurazione è il processo che collega questi eventi osservabili a un concetto teorico. Ogni collegamento è parziale e dipende dal contesto. Un questionario sullo stress, un diario giornaliero e un indicatore fisiologico possono riguardare lo stesso tema generale, ma non misurano necessariamente la stessa cosa.

La domanda guida del capitolo è:

Quale argomento ci permette di interpretare un valore osservato come informazione su un costrutto psicologico?

Una risposta adeguata non può limitarsi al nome della variabile. Deve spiegare come il costrutto è stato definito, come è stato trasformato in osservazioni, quali errori possono intervenire e quali conclusioni sono sostenute dai punteggi.

Prerequisiti

È utile avere letto Capitolo 2 e Capitolo 3. Il primo distingue fenomeno, variabile, unità di analisi, popolazione e campione; il secondo mostra come il disegno delimiti le conclusioni sostenute dai dati.

Le letture di approfondimento su fondamenti della misurazione, replicabilità e livelli di scala sono Maul et al. (2016), Lilienfeld & Strother (2020) e Stevens (1946).

Panoramica del capitolo

Il capitolo segue il percorso che conduce dal costrutto al dato. Chiarisce innanzitutto la differenza tra costrutto, operazionalizzazione, indicatore e punteggio. Introduce poi l'errore di misura e distingue il punteggio vero della teoria classica dei test dal costrutto psicologico. Su questa base affronta affidabilità e validità, discute il significato dei livelli di scala e dedica particolare attenzione agli item Likert e ai punteggi aggregati. Le ultime sezioni collegano la misurazione all'EDA, al codice R e alla modellizzazione bayesiana.

i Preparazione del notebook

Il capitolo è prevalentemente concettuale. L'unico esempio in R usa funzioni di base e non richiede pacchetti aggiuntivi. Il suo scopo non è insegnare una tecnica di ricodifica, ma mostrare che una codifica numerica incorpora assunzioni sul significato delle distanze tra categorie.

4.1. Dal costrutto al dato osservato

Consideriamo la domanda:

Gli studenti che sperimentano più stress accademico dormono peggio?

La domanda contiene almeno due costrutti: **stress accademico** e **qualità del sonno**. Per studiarli dobbiamo decidere che cosa significhino nel contesto della ricerca e quali osservazioni possano fornire informazioni su di essi.

Per lo stress potremmo usare un questionario sulla pressione percepita, il numero di scadenze imminenti, un diario giornaliero o un indicatore fisiologico. Per il sonno potremmo registrare le ore dichiarate, una valutazione soggettiva, i risvegli notturni oppure dati provenienti da un dispositivo indossabile. Queste scelte non sono equivalenti. Ognuna mette in primo piano un aspetto del fenomeno e ne lascia altri sullo sfondo.

La relazione tra teoria e dati può essere descritta attraverso quattro passaggi.

Passaggio	Significato	Esempio
Costrutto	Concetto teorico che vogliamo comprendere	Stress accademico
Operazionalizzazione	Regola con cui il costrutto viene reso osservabile	Somministrare una scala di dieci item riferita all'ultima settimana
Indicatore	Risposta, comportamento o segnale registrato	Risposte ai dieci item
Dato o punteggio	Valore memorizzato per una specifica unità	Punteggio totale pari a 27

Il punteggio 27 non è lo stress dello studente. È il risultato prodotto da uno strumento, da una modalità di somministrazione e da una regola di calcolo. Può essere informativo sullo stress soltanto se esistono buone ragioni per collegare quel punteggio al costrutto.

! Il nome della colonna non dimostra che cosa è stato misurato

Chiamare una variabile **stress** non stabilisce che essa rappresenti adeguatamente lo stress accademico. Il significato dipende dagli item, dal periodo di riferimento, dalla popolazione, dal contesto e dalla regola con cui le risposte sono state trasformate in un punteggio.

4.2. Due relazioni da non confondere

Per comprendere la misurazione dobbiamo tenere separate due relazioni.

La prima collega il **costrutto** agli **indicatori**. È una relazione teorica: perché una risposta, un comportamento o un segnale dovrebbe informarci sul fenomeno psicologico?

La seconda collega il **punteggio osservato** alla componente stabile e all'errore prodotti dalla procedura. È una relazione statistica: quanto cambierebbe il punteggio se la misurazione fosse ripetuta in condizioni equivalenti?

Confondere queste due relazioni porta a pensare che una misura stabile rappresenti necessariamente il costrutto giusto. Non è così. Uno strumento può produrre risultati molto coerenti e misurare sistematicamente qualcosa di diverso da ciò che interessa.

4.3. Punteggio osservato, punteggio vero ed errore

Nella teoria classica dei test, il punteggio osservato viene rappresentato come:

$$X = T + E,$$

dove X è il punteggio osservato, T è il **punteggio vero** ed E è l'errore di misura.

Questa equazione è semplice, ma il termine *punteggio vero* può trarre in inganno. T non è il valore puro o direttamente nascosto del costrutto psicologico. È il valore medio che la stessa persona otterrebbe attraverso un numero ideale di ripetizioni equivalenti della medesima procedura di misurazione.

Se uno studente compila ripetutamente la stessa scala in condizioni realmente equivalenti, i punteggi potrebbero variare per distrazione, comprensione momentanea, stanchezza o altre influenze accidentali. Il punteggio vero è il centro teorico di questa distribuzione di punteggi, non una misura completa e infallibile dello stress.

! Punteggio vero e costrutto non sono sinonimi

Una bilancia sempre spostata di due chilogrammi può produrre misure molto stabili. Il suo punteggio vero, nel senso della procedura ripetuta, rimane però sistematicamente distorto. Allo stesso modo, una scala psicologica può essere affidabile e avere un punteggio vero ben definito senza rappresentare adeguatamente il costrutto che intendiamo studiare.

L'equazione $X = T + E$ descrive soprattutto l'errore casuale entro una procedura. Non rappresenta automaticamente distorsioni sistematiche, ambiguità teoriche o differenze di significato tra gruppi.

4.4. Errore casuale e distorsione sistematica

Un punteggio può differire dalla quantità che ci interessa per ragioni differenti.

L'**errore casuale** produce fluttuazioni non perfettamente prevedibili. Una persona può essere più stanca, leggere rapidamente un item o premere un tasto in ritardo. Ripetendo la misura, queste influenze tendono a cambiare e aumentano la variabilità dei punteggi.

La **distorsione sistematica** sposta invece le osservazioni in una direzione collegata alla procedura. Una traduzione può rendere alcuni item più severi, un questionario può indurre risposte socialmente desiderabili oppure un dispositivo può registrare sistematicamente valori superiori a quelli di riferimento.

La distinzione è importante perché raccogliere più dati riduce spesso l'incertezza dovuta al rumore casuale, ma non elimina automaticamente una distorsione sistematica. Una misura può diventare estremamente precisa intorno a un'interpretazione sbagliata.

4.5. Affidabilità: quanto sono riproducibili i punteggi?

L'affidabilità riguarda la coerenza dei punteggi prodotti da una procedura in condizioni definite. Non è una proprietà assoluta dello strumento, indipendente da popolazione, contesto e uso.

Una scala può mostrare buona coerenza tra item in un campione universitario e funzionare diversamente in un campione clinico. Una valutazione comportamentale può avere elevato accordo tra osservatori addestrati e accordo molto più basso tra osservatori senza formazione. Una misura può essere stabile nel giro di pochi minuti ma cambiare legittimamente dopo una settimana, perché il fenomeno stesso è variabile.

Per questo è più preciso parlare di **affidabilità dei punteggi in una particolare applicazione** che di strumento semplicemente affidabile.

Le verifiche più comuni riguardano aspetti diversi. La stabilità temporale chiede se i punteggi rimangano simili quando il costrutto dovrebbe essere stabile. L'accordo tra valutatori chiede se osservatori differenti codifichino gli stessi eventi in modo simile. La coerenza interna studia quanto gli item di una scala condividano informazione, ma non dimostra da sola che misurino un unico costrutto o che il punteggio sia valido.

! Affidabilità elevata non significa validità elevata

Item molto simili possono produrre una coerenza interna elevata anche se coprono una porzione ristretta del costrutto. Ripetere quasi la stessa domanda rende le risposte coerenti, ma non necessariamente complete o teoricamente appropriate.

Una bassa affidabilità rende più difficile distinguere differenze reali dal rumore e può indebolire le associazioni osservate. Tuttavia, correggere o modellare l'errore casuale non risolve una definizione inadeguata del costrutto.

4.6. Validità: che cosa autorizzano i punteggi?

La validità riguarda la qualità dell'interpretazione e dell'uso dei punteggi. Non è un'etichetta definitiva applicata una volta per tutte a un questionario.

La domanda non è semplicemente:

Questo test è valido?

La domanda più precisa è:

Quali evidenze sostengono questa interpretazione di questi punteggi, in questa popolazione, per questo scopo?

Una scala sullo stress può essere adeguata per confrontare medie di gruppi universitari e non essere sufficientemente precisa per prendere decisioni cliniche individuali. Può funzionare durante la sessione d'esame e richiedere una nuova valutazione in un contesto lavorativo. Può essere interpretata in modo comparabile in due gruppi oppure contenere item che assumono significati differenti.

La validazione costruisce quindi un argomento. Dobbiamo verificare se il contenuto degli item rappresenti il dominio del costrutto, se la struttura dei punteggi sia coerente con la teoria, se le relazioni con altre variabili seguano aspettative plausibili e se interpretazioni alternative siano state considerate.

i Validità convergente e discriminante

Una misura di stress dovrebbe essere associata ad altri indicatori dello stress in modo coerente con la teoria. Dovrebbe però anche essere distinguibile da costrutti vicini, come ansia generale, umore negativo o carico di lavoro.

Una correlazione elevata con qualsiasi variabile psicologica non è automaticamente una prova di validità.

4.7. Lo stesso punteggio deve avere lo stesso significato?

Confrontare persone o gruppi presuppone che il punteggio rappresenti il costrutto in modo sufficientemente simile.

Un item come «mi sento sopraffatto dagli impegni» può essere interpretato diversamente da studenti, lavoratori e persone con responsabilità di cura. Una risposta pari a 4 potrebbe quindi non indicare lo stesso livello del costrutto nei diversi gruppi.

Questo problema viene studiato attraverso concetti come **equivalenza della misura, invarianza e funzionamento differenziale degli item**. In un capitolo introduttivo non occorre stimare questi modelli, ma è essenziale comprendere la domanda:

Le differenze nei punteggi riflettono differenze nel costrutto oppure differenze nel modo in cui lo strumento funziona?

Senza questa cautela, un confronto tra gruppi può attribuire al fenomeno psicologico una differenza prodotta dalla lingua, dal contesto, dalle norme sociali o dalla comprensione degli item.

4.8. Che cosa permettono di affermare i numeri?

Una variabile numerica in R non è necessariamente una misura quantitativa. I valori possono rappresentare categorie, ordini, differenze o rapporti. La tassonomia classica di Stevens (1946) distingue scale nominali, ordinali, a intervalli e di rapporti.

Scala	Informazione preservata	Esempio psicologico	Operazioni generalmente interpretabili
Nominale	Identità e differenza tra categorie	Condizione sperimentale	Frequenze e proporzioni
Ordinale	Ordine tra categorie	Gravità lieve, moderata, severa	Frequenze ordinate, quantili e ranghi
A intervalli	Differenze comparabili	Punteggio standardizzato	Medie, differenze e deviazioni standard
Di rapporti	Differenze e rapporti rispetto a uno zero non arbitrario	Tempo di reazione	Operazioni precedenti e rapporti

La classificazione è uno strumento di ragionamento, non un algoritmo che decide automaticamente l'analisi. Anche quando una variabile possiede proprietà metriche, dobbiamo considerare distribuzione, precisione, valori possibili e domanda scientifica.

4.8.1. Scale nominali

Una scala nominale assegna osservazioni a categorie senza un ordine intrinseco. Se codifichiamo controllo con 0 e intervento con 1, i numeri funzionano come etichette. La media della variabile coincide con la proporzione di osservazioni codificate come 1, ma non rappresenta una posizione psicologica intermedia tra controllo e intervento.

4.8.2. Scale ordinali

Una scala ordinale conserva l'ordine, ma non garantisce distanze uguali. Sappiamo che *molto* indica più di *abbastanza*, ma non sappiamo se la differenza psicologica tra *per nulla* e *poco* sia uguale a quella tra *abbastanza* e *molto*.

4.8.3. Scale a intervalli

In una scala a intervalli, le differenze hanno un significato stabile, mentre lo zero è convenzionale. Molti punteggi standardizzati vengono interpretati in questo modo. Possiamo confrontare una differenza di 10 punti con un'altra differenza di 10 punti, ma non concludere che un punteggio di 80 rappresenti il doppio del costrutto di un punteggio di 40.

4.8.4. Scale di rapporti

Una scala di rapporti possiede uno zero non arbitrario che rende interpretabili i rapporti. Un tempo di reazione di 800 millisecondi dura il doppio di uno di 400 millisecondi. Questo non implica, però, che la persona abbia il doppio della difficoltà cognitiva: la proprietà metrica del dato non determina da sola il significato psicologico.

 Il doppio del punteggio non è necessariamente il doppio del costrutto

Dire che 30 è il doppio di 15 è un'affermazione aritmetica. Dire che una persona possiede il doppio dello stress richiede una scala di rapporti del costrutto, una condizione raramente giustificata per i punteggi psicologici.

4.9. Le trasformazioni rivelano le assunzioni

Un modo per comprendere una scala è chiedersi quali trasformazioni conservino l'informazione rilevante.

Per una variabile nominale possiamo cambiare le etichette. Per una variabile ordinale possiamo ricodificare le categorie purché l'ordine venga preservato. Una scala a intervalli consente un cambiamento lineare di unità e origine, come nel passaggio da Celsius a Fahrenheit. Una scala di rapporti consente il cambiamento dell'unità, ma non uno spostamento arbitrario dello zero.

L'esempio seguente mostra che una ricodifica monotona conserva l'ordine delle risposte, ma modifica le distanze e quindi la media.

```
risposte <- c(2, 3, 4, 3, 5, 2, 4, 3, 4, 5)

ricodifica <- c(
  `1` = 1,
  `2` = 2,
  `3` = 4,
  `4` = 7,
  `5` = 11
)

risposte_ricodificate <- unname(
  ricodifica[as.character(risposte)]
)

c(
  media_originale = mean(risposte),
  media_ricodificata = mean(risposte_ricodificate)
)
```

media_originale	media_ricodificata
3.5	5.9


```
identical(
  order(risposte),
  order(risposte_ricodificate)
)
```

```
[1] TRUE
```

L'ordine è preservato, mentre la media cambia perché dipende dalle distanze numeriche. Il codice non dimostra che la media sia sempre inappropriata per dati ordinali. Rende visibile l'assunzione aggiuntiva necessaria per interpretarla.

4.10. Item Likert e punteggi aggregati

Un **item Likert** presenta categorie ordinate, come *per nulla d'accordo*, *poco d'accordo*, *abbastanza d'accordo* e *molto d'accordo*. Il singolo item è ordinale: l'ordine è noto, le distanze psicologiche non lo sono.

Una **scala Likert** combina più item, spesso attraverso una somma o una media. Il punteggio aggregato può assumere molti valori e comportarsi in modo più regolare del singolo item. Per questa ragione viene spesso trattato come approssimativamente continuo o intervallato.

Questa scelta può essere ragionevole, ma non deriva automaticamente dal fatto che siano stati sommati più numeri. Richiede che gli item siano collegati a un costrutto interpretabile, che la regola di composizione sia giustificata e che il comportamento del punteggio sia esaminato.

È quindi utile distinguere sempre ciò che viene analizzato. Una tabella delle frequenze è spesso la prima rappresentazione appropriata per un singolo item. Per un punteggio aggregato possiamo considerare media e deviazione standard, ma dovremmo anche osservare distribuzione, limiti della scala, effetti di pavimento o soffitto e presenza di combinazioni di risposte molto diverse che producono lo stesso totale.

Una posizione pragmatica

Trattare un punteggio Likert aggregato come approssimativamente intervallato è una decisione modellistica. Può essere utile e robusta in molte applicazioni, ma deve essere distinta dall'affermazione più forte secondo cui le distanze psicologiche sarebbero note e perfettamente uguali.

4.11. Self-report, comportamento e fisiologia

Le misure self-report forniscono accesso a esperienze soggettive che non potrebbero essere osservate direttamente. Sono però influenzate da memoria, desiderabilità sociale, interpretazione degli item, stanchezza e stile di risposta.

Le misure comportamentali e fisiologiche vengono talvolta considerate più oggettive. In realtà sono più direttamente osservabili, ma non automaticamente più valide. Un tempo di reazione lento può riflettere minore attenzione, maggiore cautela, difficoltà del compito, affaticamento o una strategia differente. Una variazione della frequenza cardiaca può dipendere da stress, attività fisica, postura, farmaci o caratteristiche individuali.

Nessun indicatore interpreta se stesso. La scelta tra self-report, comportamento e fisiologia dipende dalla teoria e dalla domanda. Usare più metodi può essere informativo proprio perché ciascuno rende visibile una parte differente del fenomeno.

4.12. Variabili discrete, continue e risoluzione

Il livello di scala non esaurisce le proprietà di una variabile.

Una variabile **discreta** assume valori separati, come il numero di errori o di parole ricordate. Una variabile **continua** può assumere, almeno idealmente, qualsiasi valore in un intervallo, come la durata o una misura fisiologica.

Nella pratica, ogni strumento possiede una risoluzione. Un tempo registrato al millisecondo viene memorizzato mediante valori discreti, pur rappresentando una durata concettualmente continua. Un punteggio totale può assumere molti valori, ma rimanere limitato da un minimo e un massimo.

Queste caratteristiche influenzano grafici e modelli. I conteggi hanno uno zero e non possono assumere valori negativi. Le proporzioni sono vincolate. I tempi di reazione sono spesso asimmetrici. Un punteggio con pochi valori possibili non dovrebbe essere trattato come se provenisse da una misura continua senza verificare le conseguenze della scelta.

4.13. Misurazione ed esplorazione dei dati

L'EDA deve rispettare il significato della variabile.

Per una categoria nominale, una tabella di frequenza o un grafico a barre mostra quante osservazioni appartengano a ciascun gruppo. Per una variabile ordinale, l'ordine delle categorie deve essere conservato. Per una misura quantitativa, istogrammi, densità, boxplot e statistiche di posizione e dispersione possono descrivere la distribuzione.

La prima operazione non dovrebbe però essere scelta soltanto dal tipo registrato in R. Una colonna numerica può contenere codici nominali, categorie ordinali o punteggi quantitativi. Prima di eseguire `mean()` dobbiamo sapere come sono stati prodotti i valori.

💡 Controllare il codice generato dall'AI

Se un assistente propone:

```
mean(dati$qualita_sonno, na.rm = TRUE)
```

devi verificare almeno tre cose: se `qualita_sonno` è un singolo item o un punteggio aggregato, che cosa rappresentano i numeri e perché i valori mancanti possono essere esclusi.

Il comando può essere sintatticamente corretto e statisticamente poco informativo.

4.14. Misurazione e modellizzazione bayesiana

Il progetto bayesiano distingue con particolare chiarezza ciò che osserviamo da ciò che vogliamo conoscere. Questa distinzione è già il cuore della misurazione.

Un modello può rappresentare esplicitamente un costrutto latente, l'errore di misura o le differenze tra item e persone. Può inoltre propagare questa incertezza fino alle conclusioni sui parametri e sulle predizioni. Ciò è più informativo che trattare ogni punteggio come perfettamente osservato.

Tuttavia, un modello sofisticato non crea automaticamente una buona misura. Se gli item non rappresentano il costrutto, se funzionano diversamente tra gruppi o se il disegno non raccoglie gli indicatori necessari, la distribuzione a posteriori sarà precisa rispetto a un problema mal definito.

Nel Companion questi temi riappariranno nei modelli gerarchici, nei modelli latenti e nei controlli predittivi. In questo modulo è sufficiente trattenere un principio:

l'incertezza statistica sui parametri e l'incertezza sul significato delle misure sono problemi distinti, anche quando vengono rappresentati nello stesso modello.

4.15. Teoria, misura e dati

Teoria e misurazione formano un ciclo.

La teoria chiarisce il costrutto e suggerisce quali indicatori dovrebbero rispondere a determinate condizioni. Il disegno stabilisce come raccogliere osservazioni informative. La misura produce punteggi. L'EDA mostra come questi punteggi si distribuiscano, quali anomalie contengano e se si comportino in modo plausibile. Il modello formalizza le relazioni attese e i controlli mostrano dove la rappresentazione non è adeguata.

Quando gli indicatori non si comportano come previsto, non dobbiamo concludere automaticamente che la teoria sia falsa o che i dati siano sbagliati. Può essere necessario rivedere la definizione del costrutto, la procedura di misurazione, il disegno o il modello.

Riflessioni conclusive

La misurazione è il punto in cui un concetto teorico entra nel dataset. Un punteggio non possiede significato psicologico per il solo fatto di essere numerico. Diventa informativo attraverso un argomento che collega costrutto, operazionalizzazione, indicatori, procedura e uso previsto.

Abbiamo distinto il costrutto dal punteggio vero della teoria classica dei test. Abbiamo visto che l'affidabilità riguarda la riproducibilità dei punteggi in condizioni definite, mentre la validità riguarda le interpretazioni e gli usi sostenuti dalle evidenze. Abbiamo inoltre chiarito che la codifica numerica non determina automaticamente il livello di scala e che item Likert e punteggi aggregati richiedono considerazioni differenti.

Nel lavoro con R e con gli assistenti AI, questa competenza è essenziale. Un comando può funzionare perfettamente e riassumere la variabile sbagliata, applicare operazioni prive di significato o nascondere differenze nel funzionamento della misura.

Il capitolo successivo completerà la parte sui fondamenti discutendo la relazione tra associazione e causalità. L'EDA potrà poi iniziare da una base più solida: non soltanto quali valori sono presenti, ma che cosa possono ragionevolmente rappresentare.

Esercizi

1. Per una scala che misura lo stress accademico, distingui costrutto, operazionalizzazione, indicatore e dato osservato.
2. Perché il punteggio vero della teoria classica dei test non coincide necessariamente con il valore del costrutto psicologico?
3. Costruisci un esempio di misura affidabile ma non valida. Spiega separatamente perché è affidabile e perché l'interpretazione non è valida.
4. Una scala produce punteggi simili a distanza di una settimana, ma alcuni item vengono interpretati diversamente da studenti italiani e studenti internazionali. Quale proprietà appare buona e quale problema rimane aperto?
5. Un ricercatore afferma che un punteggio di stress pari a 30 rappresenta il doppio dello stress di un punteggio pari a 15. Quale proprietà della scala sarebbe necessaria per sostenere questa conclusione?
6. Considera il codice:

```
mean(dati$accordo, na.rm = TRUE)
```

Quali informazioni sulla variabile e sui valori mancanti devi conoscere prima di interpretare il risultato?

7. Spiega perché un singolo item Likert e la media di dieci item non dovrebbero essere trattati automaticamente nello stesso modo.
8. Un tempo di reazione possiede uno zero non arbitrario. Perché questo non rende immediata la sua interpretazione come misura dell'attenzione?

Soluzioni

1. Il costrutto è lo stress accademico. L'operazionalizzazione specifica, per esempio, una scala di dieci item riferita all'ultima settimana. Gli indicatori sono le risposte ai singoli item. Il dato può essere una risposta particolare oppure il punteggio aggregato ottenuto da uno studente.
2. Il punteggio vero è il valore medio atteso in ripetizioni equivalenti della stessa procedura. Può includere una distorsione stabile e dipende dallo strumento adottato. Il costrutto è invece il concetto teorico che la procedura cerca di rappresentare.
3. Una scala può produrre punteggi quasi identici in somministrazioni ripetute, mostrando elevata stabilità. Può però contenere item che misurano soprattutto ansia generale invece dello stress accademico. I punteggi sono affidabili, ma l'interpretazione desiderata non è adeguatamente sostenuta.
4. La stabilità temporale sembra buona. Rimane un problema di equivalenza o invarianza della misura: lo stesso punteggio potrebbe non avere lo stesso significato nei due gruppi linguistici e culturali.
5. Sarebbe necessaria una scala di rapporti del costrutto, con uno zero non arbitrario e rapporti interpretabili. Questa proprietà non è generalmente giustificata per i punteggi psicologici.

6. Occorre sapere se accordo è una categoria nominale, un item ordinale o un punteggio aggregato; che cosa significano i numeri; quanti valori mancano; perché mancano; e se escluderli modifica la popolazione rappresentata dal calcolo.
7. Il singolo item contiene poche categorie ordinate e non garantisce distanze uguali. Un punteggio aggregato assume più valori e può comportarsi in modo più regolare, ma richiede comunque una giustificazione teorica e psicometrica della combinazione degli item.
8. Il tempo è quantitativo e consente rapporti tra durate. Il collegamento con l'attenzione rimane però teorico: un tempo più lungo può dipendere anche da cautela, difficoltà, affaticamento, strategia o problemi motori.

i Punti chiave

- Un costrutto psicologico non viene osservato direttamente.
- Operazionalizzazione, indicatore e dato sono passaggi distinti.
- Il punteggio vero della teoria classica dei test non è il costrutto latente.
- L'affidabilità riguarda la coerenza dei punteggi in condizioni definite.
- La validità riguarda l'interpretazione e l'uso dei punteggi.
- Una misura affidabile può non essere valida.
- Lo stesso punteggio deve avere significato comparabile tra persone e gruppi.
- La codifica numerica non determina automaticamente il livello di scala.
- Il singolo item Likert è ordinale; un punteggio aggregato può essere trattato come approssimativamente continuo soltanto con una giustificazione.
- L'EDA e il codice R devono rispettare il significato della misura.

i Ambiente di sviluppo

Il capitolo usa soltanto funzioni incluse in R base. Le informazioni sull'ambiente possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
Platform: aarch64-apple-darwin23
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Zagreb
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods   base
```

```
loaded via a namespace (and not attached):
 [1] compiler_4.6.1 fastmap_1.2.0 cli_3.6.6 tools_4.6.1
 [5] htmltools_0.5.9 otel_0.2.0 yaml_2.3.12 rmarkdown_2.31
 [9] knitr_1.51 jsonlite_2.0.0 xfun_0.60 digest_0.6.39
[13] rlang_1.3.0 evaluate_1.0.5
```

Bibliografia

5. Dalla descrizione alla spiegazione: modelli e processi psicologici

In sintesi

Da sapere L'analisi esplorativa descrive regolarità nei dati, mentre un modello rende esplicite ipotesi su come tali regolarità possano essere generate. Descrizione, predizione e spiegazione sono obiettivi collegati ma distinti. Un modello formale può contribuire a una spiegazione soltanto se le sue componenti hanno un significato teorico, producono conseguenze controllabili e vengono confrontate con spiegazioni alternative.

Da saper fare Distinguere un pattern osservato dal processo che potrebbe produrlo; riconoscere variabili osservate e componenti latenti; spiegare intuitivamente il modello di Rescorla–Wagner e il Drift Diffusion Model; comprendere il ruolo dell'EDA e dell'inferenza bayesiana nella costruzione e nel controllo dei modelli.

Introduzione

Nei capitoli precedenti abbiamo seguito il percorso che conduce da una domanda psicologica a un dataset. Il disegno stabilisce quali confronti siano giustificati; la misurazione collega costrutti teorici e indicatori osservabili. Rimane ora una domanda ulteriore:

Perché i dati mostrano proprio quei pattern?

L'analisi esplorativa può rivelare che gli studenti con livelli più elevati di stress dormono meno, che una distribuzione presenta due gruppi distinti o che una condizione sperimentale produce risposte più lente. Queste osservazioni sono importanti, ma non spiegano ancora il processo che le ha generate.

Una spiegazione richiede un'ipotesi più articolata. Lo stress potrebbe aumentare la ruminazione serale, che a sua volta ostacola il sonno. Tempi di risposta più lunghi potrebbero dipendere da un'elaborazione più lenta, da una maggiore cautela oppure da processi percettivi e motori estranei alla decisione. Ciascuna ipotesi organizza il fenomeno in modo diverso e suggerisce dati, manipolazioni e previsioni differenti.

Un **modello** rende questa organizzazione esplicita. Se è formulato con sufficiente precisione, permette di simulare dati, stimare parametri e controllare se le conseguenze dell'ipotesi assomiglino alle osservazioni.

Prerequisiti

È utile avere letto Capitolo 3 e Capitolo 4. Il primo chiarisce il rapporto tra disegno e conclusioni causali; il secondo distingue costrutti, indicatori, punteggi osservati ed errore di misura. Le letture di approfondimento su modelli cognitivi e spiegazione meccanicistica sono Soto et al. (2023), Marr (2010), Bechtel (2009) e Povich (2025).

Panoramica del capitolo

Il capitolo distingue innanzitutto descrizione, predizione e spiegazione. Introduce poi il modello come rappresentazione selettiva di un processo e chiarisce la relazione tra variabili osservate e componenti latenti. La parte centrale discute che cosa renda un modello potenzialmente esplicativo, presenta i livelli di analisi di Marr e usa Rescorla–Wagner e il Drift Diffusion Model come esempi intuitivi. Le sezioni finali mostrano come EDA, simulazione, inferenza bayesiana e controllo predittivo collaborino nella valutazione di un modello.

Preparazione del notebook

Il capitolo è concettuale e non richiede l'esecuzione di codice. I modelli verranno implementati nel Companion con R e Stan. Qui è più importante comprendere che cosa rappresentano le equazioni e quali osservazioni potrebbero metterle in difficoltà.

5.1. Perché parlare di modelli prima di imparare R?

A prima vista, la modellizzazione può sembrare un argomento prematuro. Il sito deve ancora introdurre oggetti, funzioni, tabelle e grafici in R. Tuttavia, conoscere fin dall'inizio la destinazione del percorso evita che l'analisi dei dati venga ridotta a una raccolta di comandi.

Calcolare una media, costruire un istogramma o stimare una correlazione non costituisce un fine autonomo. Queste operazioni aiutano a comprendere che cosa il modello dovrà rappresentare. Una distribuzione asimmetrica può rendere poco plausibile una verosimiglianza normale; differenze marcate tra persone possono suggerire una struttura gerarchica; una relazione curva può mostrare che una retta non è sufficiente.

L'EDA osserva la superficie empirica del fenomeno. La modellizzazione propone un processo capace di generare una superficie simile. R è lo strumento con cui rendiamo riproducibili entrambi i passaggi.

Idea guida

Un modello non è soltanto una formula applicata ai dati. È un insieme esplicito di assunzioni su quali componenti esistano, come interagiscano e quali osservazioni dovrebbero produrre.

5.2. Descrivere, predire e spiegare

Descrizione, predizione e spiegazione possono usare gli stessi dati e persino la stessa equazione, ma rispondono a domande differenti.

La **descrizione** organizza ciò che è stato osservato. Possiamo affermare che la media delle ore di sonno è 6.4, che i punteggi di stress sono asimmetrici o che stress e sonno sono negativamente associati. Una buona descrizione rende visibili distribuzione, variabilità, casi insoliti e differenze tra sottogruppi.

La **predizione** usa informazioni disponibili per anticipare osservazioni non ancora note. Un modello potrebbe prevedere la qualità del sonno a partire da stress, carico di studio e uso serale dello smartphone. La qualità predittiva richiede una verifica su dati nuovi o su osservazioni non utilizzate per adattare il modello.

La **spiegazione** propone invece un'organizzazione del processo. Non chiede soltanto se lo stress predica il sonno, ma attraverso quale sequenza di attività, rappresentazioni o condizioni la relazione potrebbe emergere.

Obiettivo	Domanda centrale	Criterio principale
Descrizione	Che cosa osserviamo?	Rappresentazione fedele e comprensibile dei dati
Predizione	Quanto bene anticipiamo dati nuovi?	Accuratezza fuori campione
Spiegazione	Quale processo può generare il pattern?	Conseguenze teoriche controllabili e confronto con alternative

Le tre attività non sono antagoniste. Una spiegazione che produce previsioni sistematicamente errate è poco convincente. Una buona predizione, però, non identifica automaticamente il processo corretto. Regolarità diverse possono produrre la stessa accuratezza predittiva.

 Una correlazione non è ancora una spiegazione

Una correlazione tra stress e sonno non distingue se lo stress riduca il sonno, se il sonno insufficiente aumenti lo stress o se entrambe le variabili dipendano da un'altra condizione. Il pattern restringe le possibilità, ma non determina da solo il processo generatore.

5.3. Che cos'è un modello?

Un modello è una rappresentazione intenzionalmente semplificata. Se riproducesse ogni dettaglio della realtà, sarebbe difficile da comprendere quanto il fenomeno stesso. Il suo valore deriva dalla scelta di quali elementi mantenere e quali trascurare.

Un semplice modello di stress e sonno potrebbe assumere che lo stress aumenti la ruminazione e che la ruminazione riduca la qualità del sonno. Dovrebbe inoltre riconoscere che sonno e ruminazione dipendono da altre influenze non rappresentate. Una versione formale specificherebbe la direzione delle relazioni, il modo in cui vengono combinate e una distribuzione per la variabilità residua.

La formalizzazione obbliga a rispondere a domande che una teoria soltanto verbale può lasciare vaghe. L'effetto è lineare? È immediato o ritardato? È uguale per tutte le persone? Quali osservazioni sarebbero improbabili se il modello fosse adeguato?

Un modello non è quindi vero o falso in modo assoluto. Può essere utile per una domanda, una scala temporale e un livello di analisi, e insufficiente per altri scopi. La valutazione riguarda ciò che il modello rende visibile, le conseguenze che produce e gli errori sistematici che lascia nei dati.

5.4. Variabili osservate e componenti latenti

La psicologia lavora spesso con processi che non vengono osservati direttamente. Vediamo risposte, scelte, tempi, errori e punteggi; inferiamo attenzione, memoria, aspettative, cautela o apprendimento.

Una **variabile osservata** è registrata nel dataset. Una **componente latente** appartiene invece al modello e viene collegata alle osservazioni attraverso assunzioni precise.

Questa distinzione riprende il capitolo sulla misurazione. Un punteggio non coincide con il costrutto che dovrebbe rappresentare. Analogamente, il parametro di un modello cognitivo non coincide automaticamente con un processo psicologico soltanto perché gli è stato assegnato un nome suggestivo.

! Il nome del parametro non ne dimostra il significato

Chiamare un parametro «attenzione», «cautela» o «tasso di apprendimento» non prova che esso isoli quel processo. L'interpretazione dipende dalle equazioni, dal disegno, dalla qualità della misura e dalla capacità di distinguere il parametro da spiegazioni alternative.

Due modelli differenti possono produrre pattern molto simili. Anche all'interno dello stesso modello, combinazioni diverse di parametri possono talvolta generare dati difficili da distinguere. Prima di interpretare un parametro occorre quindi chiedersi se i dati e il disegno contengano informazione sufficiente per identificarlo.

5.5. Modelli fenomenologici, processuali e meccanicistici

Un modello **fenomenologico** descrive una regolarità osservata senza impegnarsi necessariamente su come venga prodotta. Una curva può rappresentare con precisione la relazione tra intensità di uno stimolo e risposta percepita pur lasciando aperto il processo sottostante.

Un modello **processuale** specifica una dinamica che trasforma stati precedenti, input o informazioni in nuovi stati e risposte. Rescorla–Wagner descrive come un'aspettativa cambi dopo ogni esito; il Drift Diffusion Model descrive come l'evidenza si accumuli durante una decisione.

Un modello può contribuire a una spiegazione **meccanicistica** quando identifica componenti organizzate e attività capaci di produrre il fenomeno (Bechtel, 2009). In psicologia tali componenti possono essere biologiche, cognitive, comportamentali o distribuite tra persona e ambiente.

Queste categorie non devono diventare etichette rigide. Un'equazione dinamica non è automaticamente una spiegazione meccanicistica. Per svolgere una funzione esplicativa, il modello deve collegarsi a una teoria, produrre conseguenze discriminanti e chiarire quali interventi o nuove osservazioni lo distinguerebbero dalle alternative.

i Formalizzare non significa dimostrare

Una teoria formale è più facile da criticare perché espone le proprie assunzioni. L'eleganza matematica, tuttavia, non garantisce che le componenti corrispondano al processo psicologico reale.

5.6. I livelli di analisi di Marr

La distinzione proposta da Marr (2010) aiuta a capire in quale senso un modello spiega.

Al **livello computazionale** chiediamo quale problema il sistema affronti e quale obiettivo realizzi. Un sistema decisionale, per esempio, deve scegliere tra alternative sulla base di informazioni incerte.

Al **livello algoritmico** chiediamo quali rappresentazioni e trasformazioni consentano di risolvere quel problema. Una possibile ipotesi è che l'evidenza venga accumulata gradualmente fino al raggiungimento di una soglia.

Al **livello implementativo** chiediamo come il processo sia realizzato fisicamente, per esempio attraverso circuiti neurali e dinamiche fisiologiche.

Livello	Domanda	Esempio nella decisione
Computazionale	Quale problema viene risolto?	Scegliere l'alternativa meglio sostenuta dalle prove
Algoritmico	Quali rappresentazioni e operazioni vengono usate?	Accumulare evidenza fino a una soglia
Implementativo	Come viene realizzato fisicamente il processo?	Dinamiche dei sistemi neurali coinvolti

Un modello cognitivo può essere informativo al livello computazionale o algoritmico senza specificare ogni dettaglio neurale. Non bisogna però confondere i livelli: una buona descrizione algoritmica non costituisce automaticamente una teoria completa dell'implementazione biologica.

5.7. Rescorla–Wagner: apprendere dall'errore di previsione

Il modello di Rescorla–Wagner rappresenta l'apprendimento associativo come aggiornamento di un'aspettativa sulla base dell'errore di previsione (Soto et al., 2023).

In una forma semplificata:

$$V_{t+1} = V_t + \alpha (\lambda_t - V_t).$$

V_t rappresenta l'aspettativa prima dell'esito, λ_t rappresenta l'esito osservato e la differenza $\lambda_t - V_t$ è l'errore di previsione. Il parametro α , compreso nella versione elementare tra 0 e 1, stabilisce quanto rapidamente l'aspettativa venga aggiornata.

Se l'esito coincide quasi con l'aspettativa, l'errore è piccolo e l'aggiornamento è limitato. Se l'esito è sorprendente, l'errore è grande e il cambiamento è maggiore.

Questa equazione trasforma una teoria verbale in una sequenza eseguibile. Dati gli esiti e un valore di α , possiamo generare l'intero percorso delle aspettative. Il modello produce quindi previsioni temporali, non soltanto un'associazione media tra esperienza e comportamento.

Il parametro α non deve però essere interpretato automaticamente come una caratteristica pura e stabile della persona. Può dipendere dal compito, dalla codifica degli stimoli, dal rumore, dalle assunzioni del modello e dalla quantità di dati disponibili.

5.8. Drift Diffusion Model: scomporre una decisione

Il Drift Diffusion Model descrive alcune decisioni a due alternative come un processo di accumulo rumoroso di evidenza. La risposta viene emessa quando l'evidenza raggiunge una delle due soglie.

Il modello permette di distinguere componenti che una semplice media dei tempi di reazione confonderebbe. Il **tasso di deriva** rappresenta la velocità e la direzione media con cui si accumula informazione. La **separazione delle soglie** rappresenta quanta evidenza viene richiesta prima di rispondere e quindi il grado di cautela. Il **punto di partenza** rappresenta un'eventuale preferenza iniziale. Il **tempo di non decisione** raccoglie le componenti percettive e motorie che precedono o seguono l'accumulo.

Questa scomposizione mostra perché lo stesso pattern osservato possa avere spiegazioni differenti. Tempi più lunghi possono derivare da evidenza meno informativa, da una strategia più cauta o da un aumento del tempo percettivo e motorio. L'accuratezza e l'intera distribuzione dei tempi aiutano a distinguere queste possibilità meglio della sola media.

Un esempio psicologico

Se partecipanti sottoposti a stress rispondono più lentamente, il dato descrittivo non indica quale processo sia cambiato. Il DDM consente di formulare ipotesi distinte: accumulo più lento, soglie più distanti, bias iniziale differente oppure maggiore tempo di non decisione.

Il modello non garantisce che queste componenti corrispondano perfettamente a moduli cognitivi isolati. La loro interpretazione deve essere sostenuta da manipolazioni, simulazioni, studi di recupero dei parametri e confronti con modelli alternativi.

5.9. Dalla teoria verbale alla teoria eseguibile

Una teoria verbale può affermare che «gli individui imparano soprattutto dagli eventi sorprendenti». Il modello di Rescorla-Wagner specifica come calcolare la sorpresa e come essa modifichi l'aspettativa a ogni prova.

Questo passaggio rende possibili attività che una formulazione vaga non consente. Possiamo simulare che cosa dovrebbe accadere in una nuova sequenza di eventi, individuare casi in cui il modello fallisce e confrontare versioni differenti della stessa idea.

Una teoria eseguibile non sostituisce la riflessione concettuale. La rende più esigente. Ogni simbolo richiede un significato; ogni equazione implica una struttura; ogni previsione può essere confrontata con i dati.

Il Companion sviluppa questa progressione nei capitoli dedicati al passaggio dalla descrizione alla spiegazione, alla costruzione di modelli dinamici e al modello di Rescorla-Wagner.

5.10. Il ruolo dell'EDA

L'EDA precede e accompagna la modellizzazione. Prima della stima, aiuta a capire che cosa il modello dovrà riprodurre. Dopo la stima, aiuta a confrontare dati osservati e dati simulati dal modello.

Una media può nascondere code lunghe, sottogruppi o variazioni nel tempo. Un modello adattato soltanto alla media può quindi risultare corretto rispetto a una sintesi e inadeguato rispetto al comportamento complessivo.

Nel caso del DDM, osservare separatamente distribuzioni dei tempi corretti ed errati può essere più informativo della sola media. Nel caso di un modello di apprendimento, la traiettoria prova per prova rivela aspetti che una media finale non mostra.

! L'EDA non sceglie automaticamente il modello

I pattern esplorativi suggeriscono quali caratteristiche richiedano una spiegazione, ma non determinano una sola teoria. La scelta deve combinare conoscenza sostantiva, disegno, misurazione, simulazione e confronto tra conseguenze alternative.

5.11. Il ruolo dell'inferenza bayesiana

Una volta specificato un modello generativo, l'inferenza bayesiana rappresenta l'incertezza sui suoi parametri condizionatamente alla prior, alla verosimiglianza e ai dati.

In forma generale:

$$p(\theta \mid y) \propto p(y \mid \theta)p(\theta).$$

La distribuzione a posteriori descrive quali valori dei parametri siano compatibili con il modello, la prior e le osservazioni. Non dimostra che il modello rappresenti il vero processo cognitivo.

Per valutare il modello dobbiamo anche generare conseguenze osservabili. Le distribuzioni predittive permettono di simulare dati e chiedere se il modello riproduca gli aspetti importanti delle osservazioni. Se fallisce sistematicamente, la posterior può essere calcolata con precisione e il modello rimanere inadeguato.

Il workflow bayesiano può essere descritto come un ciclo. Si specifica il processo generativo, si controllano le implicazioni della prior, si stimano i parametri, si confrontano predizioni e dati e si modifica il modello quando gli errori rivelano assunzioni insufficienti.

⚠ Una posterior precisa non convalida il meccanismo

L'incertezza sui parametri è condizionata al modello. Se due processi differenti producono dati simili o se il disegno non distingue i parametri, una posterior apparentemente informativa può sostenere un'interpretazione psicologica troppo forte.

5.12. Modelli, riproducibilità e generalizzazione

La formalizzazione può migliorare la riproducibilità perché rende esplicite assunzioni, equazioni, parametri e previsioni. Un altro ricercatore può simulare il modello, applicarlo a nuovi dati e verificare dove fallisce.

Questo vantaggio non elimina la necessità di replicare persone, contesti e manipolazioni. Un modello stimato con successo in un compito specifico può non generalizzare ad altri compiti o popolazioni. Parametri con lo stesso nome possono assumere significati differenti quando cambiano la procedura e la misura.

La riproducibilità computazionale chiede se l'analisi possa essere rieseguita. La replicabilità empirica chiede se il pattern ritorni in nuovi dati. La generalizzazione teorica chiede se lo stesso processo spieghi fenomeni e contesti più ampi. Un buon progetto deve distinguere queste tre domande.

5.13. Una sequenza di lavoro

Il percorso costruito finora può essere letto come un ciclo:

fenomeno → domanda → disegno → misurazione → EDA → modello → controllo.

Il ciclo non termina con la stima. Un errore predittivo può rivelare un problema di misura; un parametro non identificabile può richiedere un disegno più informativo; un pattern inatteso può suggerire una nuova teoria. La ricerca procede attraverso revisioni successive, non mediante l'applicazione lineare di una tecnica.

Nei capitoli successivi impareremo a usare R per organizzare e osservare i dati. Oggetti, funzioni, trasformazioni e grafici saranno introdotti come strumenti di questo ciclo, non come esercizi di programmazione fine a se stessi.

Riflessioni conclusive

Descrivere significa rendere visibile un pattern. Predire significa anticipare nuove osservazioni. Spiegare significa proporre un processo capace di generare quel pattern e distinguerlo da alternative plausibili.

Un modello formalizza questa proposta attraverso componenti, relazioni e assunzioni. In psicologia tali componenti sono spesso latenti e non devono essere identificate ingenuamente con i nomi assegnati ai parametri. Il loro significato dipende dal disegno, dalla misurazione e dalle conseguenze empiriche del modello.

Rescorla–Wagner mostra come una teoria dell'apprendimento possa diventare una regola dinamica di aggiornamento. Il Drift Diffusion Model mostra come tempi e accuratezza possano essere scomposti in processi differenti. In entrambi i casi, la formalizzazione permette di simulare e controllare la teoria, ma non ne garantisce la correttezza.

L'EDA e l'inferenza bayesiana svolgono ruoli complementari. La prima mostra quali caratteristiche dei dati richiedano una spiegazione; la seconda rappresenta l'incertezza sui parametri e produce predizioni condizionate al modello. Il controllo predittivo richiude il ciclo, mostrando dove il modello riesce e dove deve essere rivisto.

Esercizi

1. Un campione mostra una correlazione negativa tra stress e ore di sonno. Formula una descrizione, una previsione e una possibile spiegazione del risultato.
2. Perché un modello con elevata accuratezza predittiva non identifica necessariamente il processo psicologico corretto?

3. Che differenza c'è tra una variabile osservata e una componente latente? Fornisci un esempio tratto dalla misurazione o dalla decisione.
4. In che senso un modello fenomenologico può essere utile senza essere una spiegazione del processo?
5. Nel modello di Rescorla–Wagner, che cosa accade all'aspettativa quando l'esito coincide con ciò che era già previsto?
6. Due gruppi hanno tempi medi di risposta differenti. Quali spiegazioni distinte può formulare il Drift Diffusion Model?
7. Perché una distribuzione a posteriori molto concentrata non dimostra che il modello cognitivo sia corretto?
8. In che modo l'EDA può contribuire sia prima sia dopo la stima di un modello?

Soluzioni

1. Una descrizione afferma che, nel campione, valori maggiori di stress sono associati a meno ore di sonno. Una previsione usa lo stress per anticipare le ore di sonno in nuovi casi. Una spiegazione potrebbe proporre che lo stress aumenti la ruminazione serale, che a sua volta ostacola il sonno. Questa è soltanto una possibile spiegazione e richiede dati ulteriori.
2. Il modello può sfruttare regolarità stabili senza rappresentare il meccanismo che lo produce. Modelli con strutture teoriche differenti possono ottenere previsioni simili.
3. Una variabile osservata è registrata direttamente, come una risposta o un tempo di reazione. Una componente latente appartiene al modello, come il livello di ansia o il tasso di accumulo dell'evidenza, ed è inferita attraverso le osservazioni e le assunzioni.
4. Può sintetizzare con precisione una relazione, facilitare la comunicazione e produrre buone previsioni. Non specifica necessariamente quali componenti e attività generino la relazione.
5. L'errore di previsione è nullo o molto piccolo. Di conseguenza, l'aspettativa cambia poco o non cambia.
6. I gruppi potrebbero differire nella velocità di accumulo dell'evidenza, nella cautela espressa dalla distanza tra le soglie, nel punto di partenza oppure nel tempo percettivo e motorio non legato alla decisione.
7. La posterior è condizionata al modello. Può essere precisa anche se il modello trascura un processo rilevante, se i parametri sono interpretati male o se un modello alternativo produce dati simili.
8. Prima della stima, l'EDA mostra distribuzioni, dipendenze, anomalie e dinamiche che il modello dovrebbe rappresentare. Dopo la stima, permette di confrontare dati osservati e simulazioni predittive e di localizzare gli errori del modello.

Punti chiave

- Descrizione, predizione e spiegazione rispondono a domande differenti.
- Un modello è una rappresentazione selettiva e controllabile di un processo.

- Le componenti latenti non vengono osservate direttamente e il loro nome non ne garantisce l'interpretazione.
- Un modello computazionale non è automaticamente meccanicistico o corretto.
- I livelli computazionale, algoritmico e implementativo distinguono domande esplicative differenti.
- Rescorla–Wagner formalizza l'apprendimento attraverso l'errore di previsione.
- Il DDM separa accumulo dell'evidenza, cautela, bias iniziale e tempo di non decisione.
- L'EDA mostra ciò che il modello deve spiegare; il controllo predittivo mostra dove fallisce.
- L'inferenza bayesiana rappresenta l'incertezza condizionatamente al modello, ma non convalida automaticamente il processo ipotizzato.

i Ambiente di sviluppo

Il capitolo non richiede pacchetti aggiuntivi. Le informazioni sull'ambiente R possono essere ottenute con:

```
sessionInfo()
```

Bibliografia

Parte II.

R

i In sintesi

Questa Parte non insegna a programmare in senso professionale e non offre una guida completa a R. Introduce il modo di pensare necessario per trasformare una domanda in una sequenza di operazioni, leggere il codice prodotto anche con l'aiuto dell'AI e verificare che dati, trasformazioni e risultati corrispondano realmente all'analisi desiderata. L'obiettivo non è scrivere tutto il codice da soli. È mantenere il controllo scientifico del lavoro.

Perché R rimane importante

Gli assistenti di intelligenza artificiale possono generare codice, spiegare errori, adattare grafici e proporre trasformazioni. Questo rende meno necessario memorizzare molti dettagli sintattici, ma non rende meno importante comprendere ciò che il codice fa.

Chi presenta un risultato deve sapere quali dati sono stati usati, quali osservazioni sono state incluse o escluse, come sono state costruite le variabili e quale operazione ha prodotto una tabella o un grafico. Deve inoltre distinguere una difficoltà tecnica da una decisione metodologica.

R è utile perché rende queste operazioni esplicite. Una trasformazione eseguita attraverso il codice lascia una traccia controllabile. Se il progetto è organizzato correttamente, la stessa procedura può essere rieseguita quando cambiano i dati, verificata da un'altra persona e integrata nel documento che presenta i risultati.

R non è quindi il fine del percorso. È l'ambiente in cui il passaggio dalla domanda all'analisi può diventare trasparente:

domanda → dati → operazioni → risultato → interpretazione.

Imparare a descrivere una procedura

La competenza fondamentale non consiste nel ricordare molte funzioni. Consiste nel saper descrivere una procedura in modo sufficientemente preciso da poterla tradurre in codice e controllare dopo l'esecuzione.

Di fronte a un compito dovremmo riuscire a stabilire quale sia l'input, quale trasformazione debba essere applicata, quali condizioni debbano essere rispettate e quale output ci aspettiamo.

Supponiamo di voler calcolare la qualità media del sonno per anno di corso. Prima di pensare alla sintassi dobbiamo chiarire che ogni riga rappresenta uno studente, che anno definisce i gruppi, che `qualita_sonno` è la variabile da riassumere e che i valori mancanti devono essere contati prima di essere esclusi dal calcolo.

La procedura può essere formulata così:

Parti dalla tabella degli studenti, forma i gruppi definiti dall'anno di corso, conta quante osservazioni possiedono una misura del sonno e calcola la media separatamente per ciascun gruppo.

Questa descrizione contiene la logica dell'analisi. R e l'AI devono tradurla in una forma eseguibile senza modificarne implicitamente il significato.

Usare l'AI senza delegare l'analisi

L'AI è particolarmente efficace quando riceve una descrizione concreta del problema. Una richiesta generica come «analizza questi dati» obbliga l'assistente a inventare decisioni su variabili, esclusioni, mancanti, pacchetti e output.

Una richiesta controllabile specifica invece la struttura del dataset, l'unità rappresentata dalle righe, i nomi e il significato delle variabili, il risultato desiderato e i controlli da includere.

Il contributo dell'AI riguarda soprattutto la traduzione tra linguaggio naturale e sintassi. La responsabilità metodologica rimane del ricercatore. L'assistente non conosce automaticamente il disegno dello studio, la validità delle misure, il significato dei codici o la ragione per cui una soglia dovrebbe essere usata.

Per questo motivo non useremo codice che non siamo in grado di spiegare almeno a grandi linee. Non è necessario ricordare ogni argomento di una funzione, ma deve essere possibile riconoscere:

- da quale oggetto parte il codice;
- quali righe, colonne o valori modifica;
- quali osservazioni entrano nel risultato;
- quale nuovo oggetto o output produce;
- quale controllo mostra che l'operazione ha funzionato come previsto.

Questa breve lista è necessaria perché costituisce un protocollo operativo da applicare a ogni soluzione generata dall'AI.

Il controllo viene prima dell'interpretazione

Un codice che termina senza errori non è necessariamente corretto.

Può usare la variabile sbagliata, trattare codici categoriali come quantità, eliminare osservazioni senza renderlo evidente o calcolare una statistica su un sottoinsieme diverso da quello richiesto. Può anche produrre un grafico elegante che suggerisce una conclusione non sostenuta dal disegno.

Il controllo deve accompagnare ogni trasformazione. Dopo un filtro verifichiamo quante righe rimangono. Dopo la creazione di una variabile esaminiamo i valori prodotti. Dopo una sintesi controlliamo quale unità rappresenti ciascuna riga. Prima di interpretare un grafico contiamo quante osservazioni vi entrano.

Il principio generale sarà:

operazione → conseguenza attesa → controllo osservabile.

L'AI può essere invitata a produrre questi controlli. Non dovrebbe limitarsi a fornire il risultato finale.

Un percorso deliberatamente essenziale

Questa Parte introduce soltanto ciò che serve per iniziare a lavorare con dati psicologici e affrontare la successiva sezione dedicata all'EDA.

Non studieremo la programmazione avanzata, lo sviluppo di software o tutte le possibilità del linguaggio. Non sarà necessario imparare cicli complessi, metaprogrammazione, sistemi di classi o costruzione di pacchetti.

Il percorso privilegia invece pochi concetti trasferibili a qualunque linguaggio: oggetti, input, trasformazioni, condizioni, sequenze, output e controlli. R fornisce la notazione concreta con cui applicarli ai dati.

Questa scelta non riduce il rigore. Elimina ciò che non è necessario per concentrare l'attenzione sulle decisioni che determinano il significato dell'analisi.

Mappa della Parte

I capitoli seguono il percorso che conduce da una domanda formulata in linguaggio naturale a un'analisi documentata e riproducibile.

Capitolo	Funzione nel percorso	Domanda guida
Capitolo 6	Tradurre un compito in input, operazioni e output	Che cosa sta facendo il codice?
Capitolo 7	Organizzare file, cartelle e dipendenze	Da che cosa dipende l'analisi?
Capitolo 8	Importare e controllare una tabella	I dati ottenuti corrispondono a ciò che lo studio dovrebbe contenere?
Capitolo 9	Trasformare righe, colonne e valori	Che cosa cambia dopo ogni operazione?
Capitolo 10	Rendere visibili distribuzioni e relazioni	Che cosa voglio mostrare e quale grafico lo rende visibile?
Capitolo 11	Collegare testo, codice e risultati	Il percorso può essere ricostruito dall'inizio?
Capitolo 12	Scegliere e dichiarare strumenti esterni	Quali dipendenze sono realmente necessarie?

La sequenza è progressiva, ma i capitoli possono essere consultati anche durante il lavoro. Un problema di percorso rimanda all'ambiente; una tabella inattesa ai controlli d'importazione; una pipeline poco chiara al capitolo su `dp1yr`; un grafico difficile da interpretare al capitolo su `ggplot2`.

Dal progetto alla tabella

Il lavoro comincia da una cartella di progetto. Al suo interno devono essere riconoscibili i dati originali, i documenti che contengono il codice e gli output prodotti.

Una procedura riproducibile non dipende da oggetti creati casualmente nella Console o da file collocati in una cartella personale. Usa percorsi relativi e può essere eseguita nuovamente dopo il riavvio di R.

L'importazione rappresenta il primo vero passaggio analitico. Il fatto che un file sia stato letto senza errori non dimostra che la tabella sia corretta. Occorre confrontare righe, colonne, tipi e valori con ciò che sappiamo del disegno e della misurazione.

Questa attenzione protegge da un errore frequente: iniziare a trasformare o visualizzare dati che non sono stati ancora compresi.

Dalla tabella alla trasformazione

Una volta controllata la tabella, `dplyr` permette di descrivere trasformazioni mediante pochi verbi. Selezionare colonne, filtrare righe, creare variabili e produrre riepiloghi sono operazioni semplici, ma incorporano decisioni sostantive.

Un filtro modifica il campione analizzato. Una ricodifica introduce una nuova definizione. Una sintesi modifica l'unità rappresentata dalle righe. Il codice deve rendere visibili queste conseguenze e conservarne una traccia.

L'AI può costruire una pipeline, ma la richiesta deve stabilire quali trasformazioni siano necessarie e quali non debbano essere introdotte.

Dalla trasformazione alla rappresentazione

`ggplot2` verrà usato per tradurre una domanda esplorativa in una rappresentazione. Non impareremo tutte le geometrie o le opzioni grafiche. Ci concentreremo sulla scelta di ciò che deve diventare visibile.

Un istogramma mostra la forma di una distribuzione. Le barre mostrano la composizione di categorie. Punti e boxplot rendono visibili differenze e variabilità tra gruppi. Un diagramma di dispersione mostra come due misure cambino insieme.

Il grafico non parla da solo. Deve essere letto alla luce dell'unità di analisi, dei valori mancanti e del disegno. Un'associazione visiva non diventa una relazione causale perché è rappresentata con chiarezza.

Dall'analisi al documento

Quarto riunisce domanda, codice, risultato e interpretazione in un unico documento eseguibile. Il render da una sessione pulita verifica che l'analisi non dipenda da passaggi nascosti.

Il documento finale non deve essere un deposito di output. Ogni tabella e figura deve rispondere a una domanda e ogni interpretazione deve poter essere collegata al codice che ha prodotto l'evidenza.

Quando il codice proviene dall'AI, Quarto offre il luogo in cui sottoporlo a controllo. Le dipendenze diventano visibili, gli errori possono essere localizzati e il testo può essere confrontato con i risultati aggiornati.

Come lavorare con i capitoli

Il modo più utile per studiare questa Parte è procedere per piccole variazioni. Esegui un esempio, descrivi a parole che cosa fa, modifica un elemento e osserva che cosa cambia.

Quando usi l'AI, chiedi una soluzione semplice, limitata agli strumenti già introdotti e accompagnata da controlli. Se una risposta introduce un nuovo pacchetto, una soglia o un'esclusione, chiedi quale problema risolva e quale effetto abbia sui dati.

Non è necessario partire da una pagina vuota. È normale adattare esempi, documentazione e codice generato. La competenza consiste nel sapere quali parti possono cambiare senza alterare la domanda e quali modifiche rappresentano invece una nuova decisione analitica.

Che cosa dovrebbe rimanere

Alla fine della Parte non sarà importante ricordare ogni comando. Sarà importante riconoscere la struttura di un'analisi.

Di fronte a un blocco di codice dovremmo saper identificare l'input, la trasformazione e l'output. Di fronte a una tabella dovremmo sapere che cosa rappresenta una riga. Di fronte a un filtro dovremmo chiedere quanti casi esclude. Di fronte a un grafico dovremmo sapere quale caratteristica rende visibile. Di fronte a un errore dovremmo localizzare la dipendenza o il passaggio che lo produce.

Soprattutto, dovremmo essere in grado di usare l'AI come assistente senza trasferirle la responsabilità scientifica dell'analisi.

Queste competenze sono sufficienti per iniziare la Parte dedicata all'analisi esplorativa dei dati. Da quel momento R verrà usato per osservare distribuzioni, variabilità, relazioni e anomalie, mantenendo sempre visibile il percorso che conduce dai dati all'interpretazione.

6. Pensare in operazioni: la sintassi essenziale di R

In sintesi

Da sapere Per usare R non è necessario imparare a programmare in senso professionale. È però necessario saper trasformare una domanda in una sequenza di operazioni: identificare i dati in ingresso, specificare che cosa deve essere modificato o calcolato, stabilire eventuali condizioni e controllare il risultato.

Da saper fare Leggere un breve blocco di codice come una procedura; riconoscere oggetti, funzioni, argomenti, condizioni e risultati; descrivere con precisione un compito a un assistente AI; verificare che il codice prodotto usi i dati corretti e non introduca trasformazioni inattese.

Introduzione

Questo capitolo non è una guida completa a R. Non presenta tutte le strutture del linguaggio e non chiede di memorizzare una lunga serie di comandi. Esistono manuali e corsi specifici per chi vuole approfondire la programmazione.

Qui l'obiettivo è diverso. Vogliamo acquisire il modo di pensare necessario per usare R come strumento di analisi e per collaborare in modo responsabile con un assistente AI.

Quando chiediamo a R di calcolare una media, selezionare alcuni partecipanti o costruire una nuova variabile, stiamo descrivendo una procedura. Dobbiamo sapere da quali dati parte, quali operazioni compie, in quale ordine le esegue e che cosa restituisce. La sintassi è il modo in cui questa procedura viene scritta.

Un assistente AI può tradurre una descrizione precisa in codice. Non può però decidere autonomamente che cosa rappresentino le righe, quali valori siano plausibili, perché alcuni dati manchino o quale risultato risponda davvero alla domanda scientifica.

La competenza essenziale consiste quindi nel saper passare in entrambe le direzioni:

domanda in linguaggio naturale $\longleftrightarrow$ sequenza di operazioni $\longleftrightarrow$ codice R.

Prerequisiti

Non sono richieste conoscenze precedenti di programmazione. È utile ricordare dalla Parte sui fondamenti che una riga rappresenta un'unità osservata, una colonna rappresenta una variabile e un valore numerico deve essere interpretato alla luce del disegno e della misurazione.

Panoramica del capitolo

Il capitolo introduce un metodo generale per leggere e progettare una procedura di analisi. Partiremo dalla distinzione tra input e output, vedremo come R conserva risultati in oggetti e come le funzioni trasformano gli input. Affronteremo poi l'ordine delle operazioni, le condizioni logiche e i controlli. Soltanto dopo useremo questi concetti per formulare richieste efficaci a un assistente AI e verificare il codice ricevuto.

Preparazione del notebook

Gli esempi usano soltanto funzioni incluse in R base. Esegui ogni blocco separatamente e osserva che cosa compare nell'ambiente e nella console. Non cercare di memorizzare i comandi: prova invece a spiegare con una frase che cosa entra, che cosa accade e che cosa viene prodotto.

6.1. Prima del codice: descrivere il compito

Supponiamo di avere un dataset chiamato `dati_studenti` e di voler conoscere la media della qualità del sonno.

Prima di scrivere codice possiamo formulare la procedura:

Prendi la variabile `qualita_sonno` dal dataset `dati_studenti`, escludi dal calcolo i valori mancanti e restituisci la media.

Questa frase contiene già quasi tutto ciò che serve. Identifica l'input, specifica la variabile, descrive l'operazione, stabilisce come trattare un caso particolare e indica l'output atteso.

In R la stessa procedura può essere scritta così:

```
mean(  
  dati_studenti$qualita_sonno,  
  na.rm = TRUE  
)
```

Capire il codice non significa ricordare ogni simbolo. Significa riconoscere la procedura espressa dalla sintassi.

Prima di chiedere aiuto a un'AI, è quindi utile rispondere a quattro domande:

Domanda	Esempio
Qual è l'input?	Il data frame <code>dati_studenti</code>
Quale parte dell'input interessa?	La colonna <code>qualita_sonno</code>
Quale operazione deve essere eseguita?	Calcolare la media
Quali condizioni o controlli servono?	Gestire e contare i valori mancanti

Queste domande valgono in R, Python, Julia e in quasi ogni altro linguaggio. Cambia la notazione, non la struttura del problema.

6.2. Oggetti: dare un nome a un risultato

R conserva dati e risultati in **oggetti**. Un oggetto permette di assegnare un nome a qualcosa che vogliamo usare in seguito.

```
punteggio_stress <- 18
```

La riga si legge:

Calcola il valore a destra e salvalo con il nome `punteggio_stress`.

La freccia `<-` non esegue un'analisi statistica. Registra un risultato nello stato corrente del lavoro.

Possiamo poi usare quel nome in una nuova operazione:

```
punteggio_stress + 2
```

L'idea importante non è la freccia in sé. È la possibilità di costruire una procedura per passaggi, assegnando nomi comprensibili ai risultati intermedi.

```
punteggi <- c(18, 22, 19, 25)
media_stress <- mean(punteggi)
```

La prima riga crea i dati in ingresso. La seconda applica un'operazione e conserva il risultato.

Nomi come `x`, `a1` o `temp` possono essere comodi per chi scrive velocemente, ma rendono più difficile controllare il codice. In un'analisi riproducibile, `punteggi_stress` e `media_stress` comunicano già una parte del ragionamento.

! Un oggetto non è il fenomeno

Un oggetto chiamato `stress` non è lo stress psicologico. È un valore o una colonna che abbiamo deciso di interpretare in quel modo. Il significato scientifico viene dal disegno e dalla misurazione, non dal nome assegnato in R.

6.3. Funzioni: trasformare un input

Una **funzione** descrive un'operazione. Riceve uno o più input e restituisce un risultato.

```
mean(c(18, 22, 19, 25))
```

La funzione è `mean()`. L'input è il vettore creato da `c()`. L'output è un singolo numero.

La struttura generale è:

```
funzione(input, altre_opzioni)
```

Possiamo leggere molti comandi R chiedendoci:

Quale funzione viene applicata a quale oggetto?

```
length(punteggi)
mean(punteggi)
sd(punteggi)
summary(punteggi)
```

Le quattro righe usano lo stesso input e pongono domande differenti: quanti valori contiene, qual è la media, quanto sono dispersi e quale riepilogo generale possiamo ottenere.

Una funzione non modifica necessariamente l'oggetto originario. Spesso produce un nuovo risultato. Se vogliamo conservarlo, dobbiamo assegnarlo a un nome.

```
deviazione_stress <- sd(punteggi)
```

Questa distinzione è importante quando si legge codice generato dall'AI: dobbiamo capire quali oggetti vengono soltanto consultati e quali risultati vengono salvati o sovrascritti.

6.4. Argomenti: precisare il comportamento

Le funzioni possiedono **argomenti** che specificano come deve essere eseguita l'operazione.

```
mean(punteggi, na.rm = TRUE)
```

L'argomento `na.rm = TRUE` chiede di rimuovere i valori mancanti dal calcolo.

```
punteggi <- c(18, 22, NA, 25)

mean(punteggi)
mean(punteggi, na.rm = TRUE)
```

La seconda istruzione produce un numero perché esclude NA. Questo non significa che l'esclusione sia automaticamente corretta. Il codice risolve un problema computazionale; il ricercatore deve ancora affrontare il problema metodologico.

Dobbiamo sapere quanti valori mancano, perché mancano e quali osservazioni vengono effettivamente usate. Un buon assistente AI dovrebbe aiutarci a effettuare questi controlli, non soltanto aggiungere `na.rm = TRUE`.

 Una soluzione sintattica può nascondere una decisione

`na.rm = TRUE` evita che il risultato sia NA, ma modifica l'insieme dei dati usati nel calcolo. Ogni opzione che cambia i dati o il comportamento di una funzione deve poter essere spiegata.

6.5. Data frame: casi e variabili

Per l'analisi dei dati, l'oggetto centrale è il **data frame**. È una tabella in cui le righe rappresentano unità osservate e le colonne rappresentano variabili.

```
dati_studenti <- data.frame(
  id = 1:5,
  stress = c(18, 22, 19, 25, 21),
  qualita_sonno = c(7, 6, 8, 5, NA)
)
```

La sintassi crea una tabella, ma la struttura scientifica viene dal disegno. In questo esempio assumiamo che ogni riga rappresenti uno studente e che `id` identifichi l'unità osservata.

Possiamo esaminare l'oggetto con:

```
str(dati_studenti)
summary(dati_studenti)
```

`str()` mostra come R ha memorizzato colonne e tipi di dato. `summary()` produce un riepilogo. Questi controlli precedono l'analisi perché una colonna può essere stata letta come testo, un codice numerico può rappresentare una categoria e una variabile può contenere valori mancanti inattesi.

Per indicare una singola colonna si usa spesso `$`:

```
dati_studenti$stress
```

La riga si legge:

Prendi la variabile `stress` dal data frame `dati_studenti`.

Non serve conoscere tutti i modi possibili per selezionare una colonna. In questo momento è sufficiente riconoscere la relazione tra tabella e variabile.

6.6. Tipi di dato: che cosa può significare un valore?

R deve sapere come trattare ciò che incontra. Un valore può essere numerico, testuale, logico o categorico. Può anche essere mancante.

Il tipo informatico non coincide automaticamente con il significato scientifico. I numeri 1 e 2 possono essere quantità, categorie o codici. La stringa "alto" può rappresentare un livello ordinato oppure una semplice etichetta.

```
str(dati_studenti)
```

Questo comando mostra il tipo assegnato da R. Il controllo successivo spetta a noi: quel tipo è coerente con il significato della variabile?

Per esempio, se `gruppo` è codificato con 0 e 1, R può trattarlo come numerico. Il ricercatore deve sapere che i valori sono etichette di condizioni e non quantità psicologiche.

La domanda corretta non è soltanto:

R ha letto la colonna come numero?

È anche:

Che cosa rappresentano questi numeri e quali operazioni hanno senso?

6.7. Sequenze: un'analisi è un ordine di passaggi

Il risultato di una procedura dipende dall'ordine delle operazioni.

Supponiamo di voler descrivere la qualità del sonno soltanto per gli studenti con stress superiore a 20. La procedura è:

1. partire dal dataset;
2. conservare le righe che soddisfano la condizione;
3. selezionare la variabile di interesse;
4. calcolare il riepilogo.

Con funzioni di R base possiamo scrivere:

```
studenti_stress_alto <- subset(  
  dati_studenti,  
  stress > 20  
)  
  
summary(  
  studenti_stress_alto$qualita_sonno  
)
```

La prima istruzione produce un nuovo data frame. La seconda usa quel risultato.

La **pipe** `|>` permette di scrivere la stessa idea come un flusso:

```
dati_studenti |>  
  subset(stress > 20) |>  
  summary()
```

La pipe si legge come *poi passa il risultato al passaggio successivo*. Il suo valore didattico non sta nel risparmiare caratteri, ma nel rendere visibile la sequenza.

Questa versione produce il riepilogo di tutte le colonne del sottoinsieme. Se desideriamo soltanto `qualita_sonno`, dobbiamo specificarlo. Il codice deve corrispondere esattamente alla procedura immaginata.

Tradurre il codice in frasi

Quando ricevi un blocco dall'AI, leggi ogni passaggio come una frase:

Parti da questi dati.
Conserva queste righe.
Usa questa variabile.
Calcola questo risultato.

Se non riesci a formulare una frase per una riga, chiedi una spiegazione prima di usarla.

6.8. Condizioni: decidere quali casi soddisfano una regola

Molte operazioni dipendono da una condizione che può essere vera o falsa.

```
dati_studenti$stress > 20
```

R confronta ogni valore con 20 e produce una sequenza di TRUE e FALSE. Questa sequenza può essere usata per selezionare righe.

Gli operatori essenziali sono pochi:

Operatore	Domanda
> e <	Il valore è maggiore o minore?
>= e <=	Il valore supera o raggiunge una soglia?
==	Il valore è uguale a quello indicato?
!=	Il valore è diverso?
&	Entrambe le condizioni sono vere?
	Almeno una delle condizioni è vera?

Per esempio:

```
dati_studenti$stress > 20 &
  dati_studenti$qualita_sonno < 7
```

La sintassi è semplice; la decisione sostantiva può non esserlo. Perché è stata scelta la soglia 20? È definita prima dell'analisi? Produce un gruppo interpretabile? Quanti casi vengono esclusi?

L'AI può scrivere la condizione. Non può giustificare una soglia se non le forniamo il contesto scientifico.

6.9. Input, trasformazione e output

Quasi ogni blocco di codice può essere compreso attraverso tre elementi:

input → trasformazione → output.

Consideriamo:

```
media_sonno <- mean(
  dati_studenti$qualita_sonno,
  na.rm = TRUE
)
```

L'input è la colonna `qualita_sonno`. La trasformazione consiste nell'escludere i valori mancanti e calcolare la media. L'output è un numero salvato in `media_sonno`.

Questa lettura permette di controllare anche procedure più lunghe. Dopo ogni passaggio possiamo chiederci quale oggetto sia stato prodotto e se possieda la struttura attesa.

```
studenti_stress_alto <- subset(  
  dati_studenti,  
  stress > 20  
)  
  
nrow(studenti_stress_alto)  
summary(studenti_stress_alto)
```

Il controllo `nrow()` mostra quante righe sono rimaste. `summary()` permette di verificare se il sottoinsieme appare plausibile. Non dobbiamo aspettare il risultato finale per accorgerci che una condizione ha escluso quasi tutti i dati.

6.10. Controllare una procedura

Un codice che termina senza errori non è necessariamente corretto. Il controllo deve avvenire a più livelli.

Dobbiamo verificare che i nomi esistano, che i tipi di dato siano appropriati e che l'output abbia forma e dimensione attese. Dobbiamo poi controllare che le operazioni corrispondano alla domanda e che esclusioni, ricodifiche e valori mancanti siano documentati.

Un controllo minimo del dataset può essere:

```
str(dati_studenti)  
summary(dati_studenti)  
nrow(dati_studenti)
```

Se applichiamo un filtro:

```
studenti_stress_alto <- subset(  
  dati_studenti,  
  stress > 20  
)  
  
nrow(dati_studenti)  
nrow(studenti_stress_alto)
```

Il confronto rende visibile l'effetto dell'operazione.

! Verificare significa produrre evidenza

Non basta dire «il codice sembra giusto». Un controllo mostra concretamente quanti casi sono rimasti, quali valori sono stati creati, quali categorie esistono e se il risultato cambia come previsto quando modifichiamo l'input.

6.11. Gli errori come informazioni

Un messaggio di errore indica che R non ha potuto completare una procedura. Non è un giudizio sul ricercatore e non richiede di modificare istruzioni a caso.

Se scriviamo:

```
media_sonno
```

prima di avere creato l'oggetto, R segnala che l'oggetto non è stato trovato. Il messaggio suggerisce di controllare il nome e i passaggi precedenti.

Se chiediamo una media di valori testuali, il problema non riguarda necessariamente `mean()`. Potrebbe indicare che la colonna è stata importata con il tipo sbagliato oppure che non rappresenta una quantità.

Il metodo di diagnosi consiste nel localizzare il passaggio, identificare l'input ricevuto dalla funzione e controllare se possiede il tipo e la struttura richiesti.

Una richiesta utile all'AI è:

Spiega questo errore senza riscrivere subito tutto il codice. Indica quale oggetto o passaggio devo controllare e proponi un comando semplice per verificare la tua ipotesi.

In questo modo l'assistente contribuisce alla diagnosi invece di sostituire un blocco opaco con un altro blocco opaco.

6.12. Come formulare una richiesta all'AI

Una richiesta generica come «fammi l'analisi» lascia troppe decisioni implicite. L'assistente dovrà indovinare struttura dei dati, variabili, trattamento dei mancanti, pacchetti e forma del risultato.

Una richiesta controllabile descrive invece il problema come una procedura.

Struttura di un prompt utile

Puoi usare una formulazione di questo tipo:

Ho un data frame R chiamato `dati_studenti`. Ogni riga rappresenta uno studente. Le variabili rilevanti sono `stress` e `qualita_sonno`; entrambe sono punteggi numerici e possono contenere NA.

Voglio calcolare numerosità, media e deviazione standard di `qualita_sonno` per gli studenti con `stress > 20`. Usa soltanto R base e codice semplice. Salva il sottoinsieme in un nuovo oggetto senza modificare il dataset originale.

Spiega ogni passaggio in linguaggio naturale. Aggiungi controlli che mostrino quanti casi vengono esclusi e quanti valori mancanti entrano nel calcolo. Non interpretare psicologicamente il risultato.

Il prompt comunica unità di analisi, nomi, tipi di variabile, obiettivo, condizione, gestione degli oggetti, vincoli tecnici e controlli desiderati.

Questa precisione non serve soltanto a ottenere codice migliore. Costringe anche chi formula la richiesta a chiarire l'analisi prima di eseguirla.

6.13. Come verificare il codice ricevuto

Dopo aver ricevuto il codice, non è necessario comprenderne ogni dettaglio interno. È necessario però ricostruirne la logica.

Per ogni blocco dovremmo riuscire a stabilire quale oggetto usa, quale nuovo oggetto produce, quali righe o colonne modifica, come gestisce i mancanti e quale output restituisce.

È utile chiedere all'AI di separare la procedura in passaggi e di includere controlli intermedi. Possiamo anche richiedere una versione più semplice quando propone funzioni o pacchetti non ancora introdotti.

Un buon messaggio di revisione può essere:

Riscrivi la soluzione usando il minor numero possibile di concetti nuovi. Non usare una funzione che non sia necessaria. Dopo ogni trasformazione mostra un controllo dell'oggetto prodotto.

Se l'assistente modifica il dataset originale, possiamo chiedere:

Conserva i dati originali e salva ogni trasformazione importante in un oggetto con un nome descrittivo.

Se propone una soglia o elimina valori mancanti senza giustificazione:

Indica quali decisioni analitiche hai introdotto e separale dalle operazioni puramente tecniche.

 L'AI non conosce ciò che non le dici

Un assistente può inferire il significato di una variabile dal nome, ma questa inferenza può essere sbagliata. Deve ricevere informazioni sull'unità di analisi, sulla codifica, sulla scala di misura e sul disegno quando queste influenzano l'operazione.

6.14. Un esempio completo

Creiamo un piccolo dataset:

```
dati_studenti <- data.frame(  
  id = 1:6,  
  stress = c(18, 22, 19, 25, 21, NA),  
  qualita_sonno = c(7, 6, 8, 5, NA, 6)  
)
```

La domanda è:

Qual è la qualità media del sonno tra gli studenti con stress superiore a 20?

La procedura può essere descritta così: controllare la struttura, selezionare i casi, verificare quanti casi rimangono, contare i valori mancanti e calcolare la media.


```

str(dati_studenti)

studenti_stress_alto <- subset(
  dati_studenti,
  stress > 20
)

nrow(studenti_stress_alto)

sum(
  is.na(studenti_stress_alto$qualita_sonno)
)

mean(
  studenti_stress_alto$qualita_sonno,
  na.rm = TRUE
)

```

Ogni riga ha una funzione riconoscibile. `str()` controlla l'input. `subset()` applica la condizione. `nrow()` mostra l'effetto del filtro. `is.na()` identifica i mancanti e `sum()` li conta. `mean()` produce infine la statistica richiesta.

L'esempio è semplice, ma contiene una decisione che deve essere giustificata: la soglia `stress > 20`. Il codice può applicarla; il metodo di ricerca deve spiegare perché quella soglia sia appropriata.

6.15. Che cosa non serve ancora

Per usare R in questo modulo non è necessario conoscere cicli, ricorsione, programmazione orientata agli oggetti, metaprogrammazione o sviluppo di pacchetti. Non è necessario neppure memorizzare tutte le varianti disponibili per selezionare, trasformare o riassumere dati.

Nei capitoli successivi introdurremo soltanto gli strumenti che rendono più chiari e riproducibili compiti ricorrenti. Useremo `dplyr` per esprimere trasformazioni di tabelle, `ggplot2` per costruire grafici e `Quarto` per integrare codice, risultati e spiegazioni.

Il criterio sarà sempre lo stesso: introdurre una nuova sintassi soltanto quando rende più comprensibile un'operazione necessaria.

Riflessioni conclusive

La competenza iniziale in R non consiste nel ricordare molti comandi. Consiste nel vedere un'analisi come una procedura composta da input, operazioni, condizioni, risultati e controlli.

Gli oggetti assegnano nomi ai dati e ai risultati intermedi. Le funzioni trasformano gli input. Gli argomenti precisano il comportamento. Le condizioni selezionano casi. La sequenza stabilisce l'ordine delle operazioni. I controlli mostrano se la procedura ha prodotto ciò che ci aspettavamo.

Queste idee appartengono alla programmazione in generale e rimangono valide anche quando l'AI genera la sintassi. Anzi, diventano ancora più importanti: per chiedere codice utile dobbiamo descrivere chiaramente il problema; per usarlo responsabilmente dobbiamo saperne ricostruire la logica.

Nel prossimo capitolo collocheremo queste operazioni in un ambiente di lavoro ordinato. File, cartelle, progetti e documenti riproducibili permetteranno di conservare non soltanto il risultato, ma l'intero percorso che lo ha prodotto.

Esercizi

1. Leggi il codice seguente e descrivilo usando le parole *input*, *operazione* e *output*.

```
punteggi <- c(20, 16, 23, 25, 11, NA)
media_punteggi <- mean(punteggi, na.rm = TRUE)
```

2. Nel codice precedente, quale decisione viene nascosta dall'argomento `na.rm = TRUE`? Quale controllo aggiungeresti prima della media?
3. Considera:

```
dati_studenti |>
  subset(stress > 20) |>
  summary()
```

Quali righe vengono escluse? Il riepilogo riguarda una sola variabile o l'intero sottoinsieme? Quale controllo useresti per conoscere la numerosità finale?

4. L'AI propone di sostituire il dataset originale con il risultato di un filtro:

```
dati_studenti <- subset(dati_studenti, stress > 20)
```

Quale rischio introduce questa scelta? Formula una richiesta che chieda di conservare i dati originali.

5. Trasforma la richiesta «calcola la media del sonno» in un prompt che specifichi il nome del data frame, l'unità di analisi, la variabile, il trattamento dei mancanti, l'output e almeno un controllo.
6. Un codice termina senza errori ma restituisce una media pari a 1.4 per una variabile che codifica 1 = controllo e 2 = intervento. Il problema è sintattico o interpretativo? Che cosa dovrebbe essere calcolato per descrivere la variabile?
7. R riceve una colonna come testo e `mean()` produce un avviso. Quali due ipotesi controlleresti prima di chiedere all'AI di convertire automaticamente la colonna in numeri?
8. Scrivi in linguaggio naturale una procedura che, partendo da un data frame, selezioni un gruppo, conti i casi, controlli i valori mancanti e calcoli una statistica descrittiva. Non scrivere codice.

Soluzioni

1. L'input è il vettore `punteggi`. L'operazione consiste nell'escludere i valori mancanti e calcolare la media. L'output viene salvato nell'oggetto `media_punteggi`.
2. La media usa soltanto i valori osservati. Prima del calcolo possiamo contare i mancanti con `sum(is.na(punteggi))` e chiederci perché manchino.
3. Vengono conservate soltanto le righe con `stress > 20`; le righe con condizione falsa o non valutabile non entrano nel sottoinsieme. `summary()` riepiloga tutte le colonne rimaste. `nrow()` mostra la numerosità finale.

4. Il dataset originale viene sovrascritto e non è più disponibile con lo stesso nome. Possiamo chiedere: «Non modificare `dati_studenti`; salva il sottoinsieme in un nuovo oggetto chiamato `studenti_stress_alto`».
5. Un esempio è: «Ho un data frame chiamato `dati_studenti`, con una riga per studente. Calcola la media di `qualita_sonno`. La variabile è numerica e può contenere NA. Prima conta i valori mancanti e mostra quanti casi entrano nel calcolo. Usa R base, salva il risultato in `media_sonno` e spiega ogni passaggio».
6. Il codice può essere sintatticamente corretto, ma la media dei codici non descrive in modo trasparente la composizione dei gruppi. Sono più appropriate frequenze e proporzioni.
7. Dobbiamo controllare se la colonna contiene numeri memorizzati come testo oppure categorie o annotazioni che non dovrebbero essere convertite. Dobbiamo inoltre cercare simboli, separatori decimali o codici dei mancanti.
8. Una possibile procedura è: partire dal dataset originale; conservare le righe appartenenti al gruppo di interesse in un nuovo oggetto; contare le righe rimaste; contare i mancanti nella variabile; calcolare la statistica sui valori disponibili; conservare e descrivere il risultato.

i Punti chiave

- Un compito deve essere descritto prima di essere tradotto in codice.
- La struttura fondamentale è input, trasformazione e output.
- Gli oggetti conservano dati e risultati con un nome.
- Le funzioni applicano operazioni; gli argomenti ne precisano il comportamento.
- Le condizioni producono decisioni vere o false per ciascuna osservazione.
- L'ordine dei passaggi modifica il risultato.
- Un codice senza errori può essere metodologicamente sbagliato.
- I controlli intermedi rendono visibili esclusioni, trasformazioni e valori mancanti.
- Un buon prompt descrive dati, obiettivo, vincoli e verifiche richieste.
- L'AI genera sintassi; il ricercatore mantiene la responsabilità dell'analisi.

i Ambiente di sviluppo

Il capitolo usa soltanto R base. Le informazioni sull'ambiente possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
```

```
Platform: aarch64-apple-darwin23
```

```
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Zagreb
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
loaded via a namespace (and not attached):
```

```
[1] compiler_4.6.1 fastmap_1.2.0 cli_3.6.6 tools_4.6.1  
[5] htmltools_0.5.9 ote1_0.2.0 yam1_2.3.12 rmarkdown_2.31  
[9] knitr_1.51 jsonlite_2.0.0 xfun_0.60 digest_0.6.39  
[13] rlang_1.3.0 evaluate_1.0.5
```

7. Un ambiente di lavoro riproducibile

In sintesi

Da sapere Un'analisi dipende non soltanto dal codice, ma anche da file, cartelle, pacchetti e oggetti presenti nella sessione. Un progetto riproducibile rende esplicite queste dipendenze e permette di ricostruire il percorso dai dati originali ai risultati.

Da saper fare Organizzare una cartella di progetto, usare percorsi relativi, distinguere dati originali e dati trasformati, riavviare R ed eseguire il lavoro dall'inizio, descrivere con precisione all'AI la struttura reale dei file.

Introduzione

Quando un'analisi non funziona, il problema non è sempre statistico. Il codice può cercare un file nella cartella sbagliata, dipendere da un oggetto creato ore prima oppure usare un pacchetto che non è stato caricato. Sul computer dell'autore tutto sembra funzionare; su quello di un collega, o dopo qualche settimana, il percorso non può più essere ricostruito.

Questi problemi hanno una caratteristica comune: una parte della procedura è rimasta implicita.

Un ambiente di lavoro ben organizzato rende invece visibile da dove provengono i dati, quali file contengono il codice, dove vengono salvati i risultati e quali passaggi devono essere eseguiti. L'obiettivo non è costruire una struttura perfetta o complessa. È permettere a una persona di rispondere alla domanda:

Partendo soltanto da questa cartella, posso ricostruire il risultato?

La stessa domanda vale quando il codice viene scritto con l'aiuto dell'AI. L'assistente può proporre comandi, ma non vede automaticamente il contenuto del computer e può inventare nomi o percorsi plausibili. Per ottenere una soluzione utile dobbiamo descrivere la struttura reale del progetto e controllare che il codice la rispetti.

Prerequisiti

È utile avere letto Capitolo 6. In particolare, occorre riconoscere che un'analisi è una sequenza di input, trasformazioni, output e controlli.

Panoramica del capitolo

Il capitolo presenta il progetto come unità minima del lavoro riproducibile. Vedremo perché i percorsi devono essere relativi alla cartella del progetto, perché i dati originali non vanno modificati direttamente e perché la sessione di R non deve contenere informazioni indispensabili non espresse

nel codice. Concluderemo formulando richieste efficaci all'AI per diagnosticare problemi di file, cartelle e dipendenze.

Preparazione del notebook

Gli esempi richiedono soltanto R e un progetto aperto in RStudio o Positron. Non è necessario creare subito una struttura complessa. È sufficiente una cartella dedicata contenente un file `.Rproj`, un documento Quarto e una sottocartella per i dati.

7.1. Il progetto è l'unità del lavoro

Un'analisi non coincide con un singolo script. Comprende almeno i dati in ingresso, le istruzioni che li trasformano, il testo che documenta le decisioni e gli output prodotti.

In RStudio, un progetto è una cartella associata a un file con estensione `.Rproj`. Aprire quel file stabilisce la radice del lavoro: tutti i percorsi possono essere descritti a partire da quella cartella.

Una struttura minima può essere:

```
progetto_stress_sonno/  
  progetto_stress_sonno.Rproj  
  data/  
    raw/  
      stress_sonno_originale.csv  
    processed/  
      stress_sonno_pulito.csv  
  output/  
    report.qmd
```

Non esiste una struttura obbligatoria per ogni ricerca. Questa è utile perché rende immediata una distinzione: ciò che è stato ricevuto rimane in `data/raw`, ciò che è stato prodotto dall'analisi può essere salvato in `data/processed` o `output`, mentre `report.qmd` contiene il percorso riproducibile.

Il criterio non è il numero di cartelle. È la possibilità di capire che funzione abbia ciascun file.

Una cartella per ogni progetto

Lavorare direttamente in Desktop, Download o in una cartella generica chiamata R mescola analisi, versioni e dati differenti. Una cartella dedicata rende più semplice descrivere il progetto, condividerlo e controllarlo.

7.2. I nomi devono comunicare una funzione

Un nome utile anticipa il ruolo del file. `stress_sonno_originale.csv` comunica più di `dati1.csv`; `report_edo.qmd` comunica più di `nuovo_finale.qmd`.

È preferibile usare nomi brevi, minuscoli e privi di spazi o caratteri speciali:

```
stress_sonno_originale.csv  
stress_sonno_pulito.csv  
report_eda.qmd
```

Il vantaggio non è soltanto tecnico. Quando chiediamo aiuto all'AI, un nome chiaro riduce l'ambiguità. Possiamo indicare esattamente quale file è l'input e quale dovrebbe essere l'output.

Nomi come `analisi_finale_vera_2.qmd` segnalano invece che le versioni non sono governate da una procedura chiara. In un progetto riproducibile, il documento viene aggiornato e il risultato viene rigenerato; non si accumulano copie manuali per ricordare quale fosse quella corretta.

7.3. Percorsi relativi: descrivere la posizione nel progetto

Un percorso assoluto include la posizione completa sul computer:

```
/Users/maria/Desktop/progetto_stress_sonno/data/raw/stress_sonno_originale.csv
```

Quel percorso contiene informazioni locali: il nome dell'utente, la posizione sul desktop e la struttura del computer. Spostando la cartella o condividendola, il codice smette di funzionare.

Un percorso relativo parte invece dalla radice del progetto:

```
data/raw/stress_sonno_originale.csv
```

Il significato è:

Dalla cartella principale del progetto, entra in `data`, poi in `raw`, e usa questo file.

La struttura interna può quindi essere trasferita su un altro computer senza modificare il codice.

```
file.exists("data/raw/stress_sonno_originale.csv")
```

`file.exists()` non importa i dati. Verifica che il percorso indicato corrisponda a un file realmente presente. È un controllo semplice ma importante, soprattutto prima di chiedere all'AI di correggere un errore di importazione.

⚠ Evitare `setwd()` nei documenti condivisi

Un comando come

```
setwd("/Users/maria/Desktop/progetto_stress_sonno")
```

rende il documento dipendente dal computer di Maria. Aprire il progetto e usare percorsi relativi elimina questa dipendenza nascosta.

Il pacchetto `here` può aiutare nei progetti complessi, ma non è indispensabile per comprendere il principio. Prima di introdurre un nuovo pacchetto è sufficiente saper usare correttamente percorsi relativi.

7.4. I dati originali non si correggono a mano

Il file originale dovrebbe essere conservato così come è stato ricevuto, scaricato o esportato. Se contiene errori, codici particolari o valori da riclassificare, le correzioni devono comparire nel codice.

Il percorso diventa:

dati originali → trasformazioni documentate → dati analitici.

Supponiamo che `stress_sonno_originale.csv` contenga un valore 999 usato per indicare una risposta mancante. Aprire il file e cancellare manualmente quei valori produce una versione corretta, ma nasconde l'operazione. Un'altra persona non può sapere che cosa è stato modificato né ripetere la procedura su una nuova esportazione.

Il codice deve invece rendere visibile la trasformazione. Il file originale rimane intatto e la versione pulita può essere rigenerata.

Questa regola protegge anche dagli errori prodotti dall'AI. Un assistente può proporre di sovrascrivere il file di partenza per comodità. È preferibile chiedere esplicitamente:

Conserva il file originale e salva il risultato trasformato con un nome differente.

7.5. La sessione di R è temporanea

Durante il lavoro, R conserva oggetti in memoria. Possiamo creare un dataset, un grafico o un risultato e continuare a usarli finché la sessione rimane aperta.

Il rischio nasce quando un documento funziona soltanto perché un oggetto è già presente. Il codice visibile non contiene più tutti i passaggi necessari.

Supponiamo che `dati_puliti` sia stato creato nella console il giorno precedente. Un blocco può funzionare:

```
mean(dati_puliti$stress, na.rm = TRUE)
```

ma il documento non mostra come `dati_puliti` sia stato ottenuto. Dopo il riavvio, l'oggetto non esiste e la procedura si interrompe.

Il controllo decisivo consiste nel riavviare R ed eseguire il documento dall'inizio. Se tutto funziona in una sessione vuota, le dipendenze principali sono espresse nel codice.

! Il test della sessione pulita

Prima di considerare conclusa un'analisi:

1. salva i file;
2. riavvia R;
3. esegui o renderizza il documento dall'inizio;
4. verifica che dati e output vengano ricreati senza interventi manuali.

Questo controllo è più informativo del fatto che l'ultima riga funzioni nella sessione corrente.

È inoltre preferibile non dipendere dal salvataggio automatico dello spazio di lavoro in `.RData`. Un progetto dovrebbe ricreare gli oggetti eseguendo il codice, non recuperandoli da una memoria precedente.

7.6. Installare e usare un pacchetto sono operazioni diverse

I pacchetti aggiungono funzioni a R. L'installazione scarica il pacchetto sul computer:

```
install.packages("readr")
```

Di norma questa operazione viene eseguita una sola volta e non deve comparire nel documento analitico.

L'uso di una funzione del pacchetto avviene invece durante l'analisi:

```
readr::read_csv(  
  "data/raw/stress_sonno_originale.csv"  
)
```

La notazione `readr::read_csv()` rende esplicito da quale pacchetto proviene la funzione. In alternativa, possiamo caricare il pacchetto con `library(readr)` e usare successivamente `read_csv()`.

Per chi sta imparando, la forma `pacchetto::funzione()` è spesso più facile da controllare perché rende visibile la dipendenza nel punto in cui viene usata.

L'AI può proporre pacchetti non necessari oppure funzioni appartenenti a pacchetti non installati. Una richiesta utile è:

Usa R base o i pacchetti già presenti nel progetto. Se introduci un nuovo pacchetto, spiega perché è necessario e indica da quale pacchetto proviene ogni funzione non standard.

7.7. Orientarsi prima di analizzare

Quando un progetto viene aperto, pochi controlli permettono di capire dove ci troviamo e quali file sono disponibili.

```
getwd()  
list.files()  
list.files("data/raw")  
file.exists(  
  "data/raw/stress_sonno_originale.csv"  
)
```

`getwd()` mostra la cartella di lavoro. In un progetto dovrebbe coincidere con la radice prevista. `list.files()` mostra il contenuto di una cartella. `file.exists()` controlla un percorso specifico.

Questi comandi non risolvono il problema, ma producono evidenza. Se l'importazione fallisce, possiamo distinguere un file inesistente da un errore nel contenuto o nella funzione utilizzata.

7. Un ambiente di lavoro riproducibile

Un metodo utile è procedere dal generale allo specifico:

cartella del progetto → sottocartella → file → contenuto.

Prima si verifica la posizione, poi l'esistenza del file, infine si esamina il modo in cui viene letto.

7.8. Chiedere aiuto all'AI senza lasciare vuoti

Una richiesta come «R non trova il file» contiene poche informazioni. L'assistente potrebbe proporre `setwd()`, inventare un percorso o supporre una struttura diversa da quella reale.

Una richiesta più utile descrive il progetto e riporta l'errore:

Un prompt per diagnosticare un percorso

Sto lavorando in un progetto R. La radice contiene `report.qmd` e la cartella `data/raw`. Il file si chiama esattamente `stress_sonno_originale.csv`.

Il comando `file.exists("data/raw/stress_sonno_originale.csv")` restituisce `FALSE`. Non voglio usare `setwd()` né percorsi assoluti. Indicami una sequenza breve di controlli per capire se il problema è nel nome, nella cartella o nella radice del progetto. Non inventare percorsi diversi da quelli che ho indicato.

La richiesta specifica struttura, nome esatto, risultato di un controllo e vincoli della soluzione. In questo modo l'AI può contribuire a una diagnosi invece di sostituire un percorso errato con un altro.

Quando l'assistente propone codice, dobbiamo confrontarlo con la cartella reale. Un nome plausibile come `data/clean/` non esiste soltanto perché appare ordinato. Se il progetto usa `data/processed/`, il codice deve rispettare quella scelta.

Un secondo prompt utile riguarda la riproducibilità:

Un prompt per controllare il progetto

Esamina questa sequenza di codice e indicami tutte le dipendenze non esplicite: oggetti che devono già esistere, pacchetti necessari, file esterni e percorsi locali. Proponi poi controlli minimi per verificare ogni dipendenza in una sessione R appena riavviata.

La domanda importante non è «puoi far funzionare questo codice?», ma «da che cosa dipende e come posso controllarlo?».

7.9. Un flusso minimo riproducibile

Immaginiamo di voler importare il file originale, controllarne la struttura e produrre una copia trasformata.

La procedura in linguaggio naturale è:

Verifica che il file esista. Importalo senza modificare l'originale. Controlla righe, colonne e tipi delle variabili. Esegui trasformazioni esplicite. Salva il risultato in una posizione distinta. Riavvia R e verifica che la sequenza ricrei lo stesso output.

Il codice specifico dipenderà dalle trasformazioni richieste, ma l'algoritmo rimane stabile.

Possiamo iniziare con:

```
percorso_input <-  
  "data/raw/stress_sonno_originale.csv"  
  
file.exists(percorso_input)
```

Diamo un nome al percorso perché venga usato in modo coerente. Se il file non esiste, l'analisi deve fermarsi e il problema va risolto prima dell'importazione.

Dopo l'importazione controlleremo almeno struttura e dimensioni:

```
str(dati)  
dim(dati)
```

Solo successivamente applicheremo le trasformazioni e creeremo un nuovo file o un nuovo oggetto. Il risultato non deve sostituire silenziosamente l'input.

Questa sequenza è semplice, ma esprime una mentalità generale: ogni passaggio importante deve poter essere osservato e ricostruito.

7.10. Che cosa non serve ancora

Non è necessario imparare sistemi complessi di gestione delle dipendenze, automazione dei workflow o controllo di versione prima di iniziare. Strumenti come Git, `renv`, pipeline e ambienti containerizzati diventano utili in progetti più ampi, ma non sono prerequisiti per i capitoli successivi.

In questa fase bastano poche abitudini solide: una cartella dedicata, percorsi relativi, dati originali conservati, trasformazioni espresse nel codice e una verifica in sessione pulita.

L'ambiente deve ridurre l'incertezza, non aggiungere complessità.

Riflessioni conclusive

Un progetto riproducibile rende esplicito ciò da cui dipende l'analisi. La cartella del progetto stabilisce un punto di riferimento comune; i percorsi relativi permettono di spostare e condividere il lavoro; la separazione tra dati originali e trasformati conserva la storia delle operazioni; la sessione pulita verifica che gli oggetti possano essere ricreati.

Questi principi precedono qualsiasi tecnica statistica. Una media o un grafico non sono riproducibili se non sappiamo quale file sia stato usato o quali passaggi abbiano prodotto il dataset.

L'AI può aiutare a diagnosticare percorsi, organizzare cartelle e individuare dipendenze. Per farlo bene deve ricevere una descrizione fedele del progetto. Il ricercatore deve poi confrontare ogni suggerimento con i file realmente presenti e rifiutare soluzioni che introducono percorsi locali, oggetti impliciti o modifiche non documentate.

Nel prossimo capitolo applicheremo questa struttura al primo vero input dell'analisi: l'importazione e l'ispezione dei dati.

Esercizi

1. Osserva questa struttura:

```
progetto/  
  progetto.Rproj  
  data/  
    partecipanti.csv  
    analisi.qmd
```

Quale percorso relativo deve usare `analisi.qmd` per riferirsi al file CSV?

2. Perché questo comando rende il documento difficile da condividere?

```
setwd("C:/Users/Anna/Desktop/progetto")
```

3. Un file originale contiene un codice errato. Spiega perché è preferibile correggerlo attraverso il codice e salvare un nuovo file invece di modificare direttamente l'originale.
4. Un documento usa l'oggetto `dati_puliti`, ma non contiene il codice che lo crea. Perché può funzionare nella sessione corrente e fallire dopo il riavvio?
5. Spiega la differenza tra:

```
install.packages("readr")
```

e:

```
readr::read_csv("data/raw/dati.csv")
```

6. `file.exists("data/raw/dati.csv")` restituisce `FALSE`. Formula tre controlli da eseguire prima di modificare il codice di importazione.
7. L'AI propone di salvare i dati puliti nello stesso file da cui sono stati letti. Scrivi una richiesta che corregga questa scelta e preservi l'input.
8. Formula un prompt che chieda all'AI di controllare se un blocco di codice dipende da oggetti, pacchetti o file non dichiarati.

Soluzioni

1. Il percorso relativo è `"data/partecipanti.csv"`.
2. Il percorso contiene il nome dell'utente e una posizione specifica del computer di Anna. Su un altro computer o dopo lo spostamento della cartella non sarà valido. Aprendo il progetto è possibile usare percorsi relativi senza `setwd()`.
3. La modifica manuale nasconde che cosa sia stato cambiato e impedisce di ripetere la correzione su una nuova copia dei dati. Il codice documenta la trasformazione e permette di rigenerare il file analitico conservando l'originale.
4. L'oggetto può essere rimasto in memoria da un comando eseguito in precedenza. Dopo il riavvio la memoria è vuota e il documento non possiede più l'input necessario.

5. `install.packages()` scarica e installa il pacchetto sul computer. `readr::read_csv()` usa una funzione del pacchetto durante l'analisi e rende esplicita la provenienza della funzione.
6. Possiamo verificare la radice con `getwd()`, elencare il contenuto con `list.files("data/raw")` e controllare il nome esatto, comprese maiuscole, estensione ed eventuali spazi.
7. Una possibile richiesta è: «Non sovrascrivere il file in `data/raw`. Conserva l'originale e salva la versione trasformata in `data/processed/dati_puliti.csv`. Mostra esplicitamente il percorso di input e quello di output».
8. Una possibile formulazione è: «Individua nel codice tutti gli oggetti che devono già esistere, i pacchetti richiesti e i file esterni. Per ciascuna dipendenza, indica un controllo semplice che posso eseguire dopo avere riavviato R. Non riscrivere l'analisi finché non hai spiegato le dipendenze».

i Punti chiave

- Il progetto è l'unità minima di un'analisi riproducibile.
- I percorsi relativi descrivono i file rispetto alla radice del progetto.
- `setwd()` e i percorsi assoluti introducono dipendenze locali.
- I dati originali devono rimanere intatti.
- Le trasformazioni devono essere espresse nel codice.
- La sessione di R è temporanea e non deve contenere passaggi indispensabili nascosti.
- Un documento deve funzionare dopo il riavvio di R.
- Installare un pacchetto e usarne le funzioni sono operazioni differenti.
- L'AI deve ricevere la struttura reale del progetto e non deve inventare file o cartelle.
- La diagnosi procede dalla posizione del progetto all'esistenza e al contenuto del file.

i Ambiente di sviluppo

Il capitolo usa soltanto funzioni incluse in R base. Le informazioni sulla sessione possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
Platform: aarch64-apple-darwin23
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Zagreb
```

```
tzcode source: internal
```

7. Un ambiente di lavoro riproducibile

```
attached base packages:
[1] stats      graphics  grDevices  utils      datasets  methods   base

loaded via a namespace (and not attached):
 [1] compiler_4.6.1 fastmap_1.2.0 cli_3.6.6      tools_4.6.1
 [5] htmltools_0.5.9 ote1_0.2.0    yaml_2.3.12    rmarkdown_2.31
 [9] knitr_1.51      jsonlite_2.0.0 xfun_0.60      digest_0.6.39
[13] rlang_1.3.0     evaluate_1.0.5
```

8. Dal file alla tabella controllata

In sintesi

Da sapere Importare un file significa trasformarlo in un oggetto che R può usare. Non significa ancora avere dati pronti per l'analisi. Prima di procedere dobbiamo confrontare la tabella ottenuta con ciò che sappiamo dello studio: numero e significato delle righe, variabili attese, tipi, categorie, intervalli plausibili e valori mancanti.

Da saper fare Descrivere l'importazione come una sequenza di controlli; verificare il percorso prima di leggere il file; ispezionare struttura e contenuto della tabella; riconoscere segnali d'allarme; formulare all'AI una richiesta che includa aspettative e verifiche, non soltanto il comando di importazione.

Introduzione

Nel capitolo precedente abbiamo organizzato il lavoro come un progetto riproducibile. Sappiamo ora dove devono trovarsi i dati originali, perché i percorsi devono essere relativi e perché ogni trasformazione deve poter essere ricostruita.

Il passo successivo consiste nel portare un file dentro R. L'operazione tecnica è spesso semplice. Il passaggio scientificamente importante viene subito dopo: stabilire se l'oggetto importato corrisponde davvero ai dati che pensiamo di avere.

Un file può essere letto senza errori e produrre comunque una tabella sbagliata. Il separatore può non essere riconosciuto; una colonna numerica può diventare testo; codici come 999 possono essere scambiati per valori reali; categorie equivalenti possono comparire con grafie diverse; alcune variabili attese possono mancare.

Per questo motivo il capitolo non presenta un catalogo di funzioni di importazione. Introduce una routine generale:

localizzare → importare → ispezionare → confrontare con le attese → decidere.

L'AI può scrivere la sintassi di ogni passaggio. Le aspettative con cui confrontare il risultato devono però provenire dal ricercatore, dal disegno e dalla documentazione dello studio.

Prerequisiti

È utile avere letto Capitolo 6 e Capitolo 7. Il primo introduce input, trasformazioni, output e controlli; il secondo stabilisce come organizzare file e percorsi in un progetto riproducibile.

Panoramica del capitolo

Partiremo da una descrizione esplicita della tabella attesa. Verificheremo poi l'esistenza del file, lo importeremo con un percorso relativo e controlleremo dimensioni, nomi, tipi, valori mancanti e contenuti plausibili. Infine vedremo come trasformare questi controlli in una richiesta efficace all'AI e come distinguere un problema tecnico da un problema metodologico.

Preparazione del notebook

Gli esempi usano un file ipotetico chiamato `stress_sonno_originale.csv`, collocato in `data/raw/`. I blocchi di importazione sono mostrati come codice da adattare e non vengono eseguiti durante il rendering del capitolo.

Per i file CSV useremo `readr::read_csv()`. Se i dati sono in formato Excel, SPSS o in un altro formato, la logica dei controlli rimane identica; cambierà soltanto la funzione che traduce il file in una tabella.

8.1. Prima dell'importazione: che cosa ci aspettiamo?

Un controllo è possibile soltanto se abbiamo un'aspettativa.

Supponiamo che lo studio riguardi 120 studenti e che ogni partecipante debba comparire una sola volta. Il file dovrebbe contenere almeno un identificatore, un punteggio di stress, una misura della qualità del sonno e una variabile relativa al gruppo o al genere. Potremmo inoltre sapere che lo stress varia da 0 a 40 e la qualità del sonno da 1 a 10.

Queste informazioni costituiscono una descrizione minima della tabella attesa:

Aspetto	Attesa
Unità di analisi	Uno studente per riga
Numerosità approssimativa	Circa 120 righe
Variabili indispensabili	<code>id</code> , <code>stress</code> , <code>qualita_sonno</code> , <code>genere</code>
Intervallo di <code>stress</code>	Da 0 a 40
Intervallo di <code>qualita_sonno</code>	Da 1 a 10
Codici mancanti nel file originale	Vuoto oppure 999, secondo il codebook

La tabella non deve necessariamente coincidere perfettamente con queste attese. Una differenza indica però qualcosa da comprendere prima dell'analisi.

Senza aspettative, comandi come `str()` e `summary()` producono informazioni ma non consentono di decidere se il risultato sia corretto.

Il controllo è un confronto

Non basta osservare che il dataset contiene 118 righe. Dobbiamo sapere se 118 è il numero previsto, se due partecipanti non hanno completato lo studio oppure se due righe sono andate perdute durante l'importazione.

8.2. Verificare il percorso prima di leggere

Definiamo il percorso relativo una sola volta:

```
percorso_input <-  
  "data/raw/stress_sonno_originale.csv"
```

Possiamo quindi controllare se il file esiste:

```
file.exists(percorso_input)
```

Se il risultato è `FALSE`, non serve modificare subito la funzione di importazione. Il problema si trova prima: il nome, la cartella o la radice del progetto non corrispondono a ciò che abbiamo indicato.

Possiamo fermare esplicitamente la procedura:

```
if (!file.exists(percorso_input)) {  
  stop(  
    "File non trovato: ",  
    percorso_input  
  )  
}
```

Il significato algoritmico è generale:

Prima di eseguire un'operazione, verifica che una condizione necessaria sia soddisfatta.
Se non lo è, interrompi la procedura con un messaggio comprensibile.

Questo principio è più importante della specifica sintassi di `if` e `stop()`.

8.3. Importare significa creare un oggetto

Per un file CSV possiamo usare:

```
dati <- readr::read_csv(  
  percorso_input,  
  show_col_types = FALSE  
)
```

La procedura si legge:

Leggi il file indicato da `percorso_input`, trasformalo in una tabella R e salva il risultato nell'oggetto `dati`.

È utile mantenere separati il percorso e l'oggetto. Il primo identifica l'input esterno; il secondo contiene la rappresentazione importata.

`readr::read_csv()` è soltanto una delle possibili funzioni. Per un file Excel potremmo usare `readxl::read_excel()`; per un file SPSS, `haven::read_sav()`. Non occorre memorizzare tutte queste varianti. È sufficiente saper indicare all'AI il formato reale e chiedere una funzione appropriata, senza modificare il resto della procedura di controllo.

 Il successo dell'importazione non convalida i dati

Se il comando termina senza errori, sappiamo soltanto che R ha prodotto un oggetto. Non sappiamo ancora se le colonne siano state separate correttamente, se i tipi siano appropriati o se i valori abbiano il significato previsto.

8.4. Primo controllo: forma e identità della tabella

I primi comandi devono rispondere a domande semplici: quante righe e colonne sono state importate, come si chiamano le variabili e che cosa appare nelle prime osservazioni?

```
dim(dati)
names(dati)
head(dati)
```

`dim()` restituisce il numero di righe e colonne. `names()` mostra i nomi delle variabili. `head()` presenta le prime righe.

Questi controlli sono complementari. Un dataset con 120 righe e una sola colonna è sospetto se il questionario conteneva venti variabili. I nomi possono rivelare che il file importato appartiene a un'altra fase dello studio. Le prime righe possono mostrare che l'intestazione è stata interpretata come un'osservazione oppure che la prima colonna contiene numeri di riga esportati per errore.

La domanda non è soltanto «che cosa vedo?», ma:

Ciò che vedo è compatibile con il file e con il disegno che mi aspetto?

`View(dati)` può essere utile per un'ispezione manuale. Non sostituisce però i controlli scritti, perché un'altra persona non può riprodurre ciò che abbiamo notato guardando lo schermo.

8.5. Secondo controllo: struttura e tipi

R assegna un tipo informatico a ogni colonna. Possiamo esaminarlo con:

```
str(dati)
```

Se `stress` deve contenere un punteggio numerico ma compare come testo, dobbiamo individuarne la causa prima di convertirlo. Potrebbero esserci valori come "non risponde", separatori decimali inattesi o annotazioni inserite nel file.

Se `genere` è registrato con i numeri 1, 2 e 3, R può considerarlo numerico. Dal punto di vista scientifico, però, quei numeri potrebbero essere codici nominali.

Il tipo assegnato da R e il livello di misura sono quindi due domande differenti:

Come è stata memorizzata la colonna?

Che cosa rappresentano i suoi valori?

La prima domanda riguarda il software. La seconda riguarda il codebook e il capitolo sulla misurazione.

8.6. Terzo controllo: le variabili indispensabili esistono?

Possiamo dichiarare i nomi necessari:

```
variabili_richieste <- c(
  "id",
  "stress",
  "qualita_sonno",
  "genere"
)
```

Poi possiamo cercare quelle mancanti:

```
setdiff(
  variabili_richieste,
  names(dati)
)
```

Se il risultato è `character(0)`, tutte le variabili richieste sono presenti. Se compaiono uno o più nomi, il dataset non corrisponde alla struttura attesa oppure i nomi differiscono.

Il significato dell'operazione è:

Confronta l'insieme delle variabili necessarie con l'insieme delle colonne presenti e restituisci ciò che manca.

Questa è un'idea algoritmica molto generale. Prima di eseguire una procedura, si verifica che gli input richiesti siano disponibili.

Possiamo trasformare il controllo in una condizione che interrompe l'analisi:

```
variabili_mancanti <- setdiff(
  variabili_richieste,
  names(dati)
)

if (length(variabili_mancanti) > 0) {
  stop(
    "Variabili mancanti: ",
    paste(
      variabili_mancanti,
      collapse = ", "
    )
  )
}
```

Non è necessario memorizzare subito `paste()` o `collapse`. È sufficiente riconoscere che il codice costruisce un messaggio con i nomi mancanti.

8.7. Quarto controllo: valori mancanti e codici speciali

In R un valore mancante riconosciuto è rappresentato da NA. Possiamo contare i mancanti in ogni colonna con:

```
colSums(is.na(dati))
```

Per una singola variabile:

```
sum(is.na(dati$qualita_sonno))  
mean(is.na(dati$qualita_sonno))
```

La prima istruzione conta i mancanti; la seconda ne calcola la proporzione.

Questi risultati non spiegano perché i valori manchino. Inoltre, un file può usare codici come 999, -99, "missing" o "non risponde". Finché non vengono dichiarati come mancanti durante l'importazione o trasformati esplicitamente, R li considera valori osservati.

Prima di ricodificare dobbiamo consultare il codebook o la documentazione dello studio. Un valore 999 potrebbe essere un codice mancante, ma potrebbe anche essere un valore legittimo in un'altra variabile.

! Non indovinare i codici mancanti

L'AI può riconoscere che 999 sembra sospetto, ma non può stabilirne il significato senza documentazione. Chiedile di mostrare dove compare e come ricodificarlo soltanto dopo che ne hai verificato il significato.

8.8. Quinto controllo: categorie e intervalli plausibili

Per una variabile categorica possiamo vedere i valori presenti e le loro frequenze:

```
table(  
  dati$genere,  
  useNA = "ifany"  
)
```

Il risultato può mostrare categorie come "F", "f", "Femmina" e "female". R le considera differenti. La loro eventuale unificazione richiede una decisione esplicita.

Per una variabile numerica possiamo iniziare con:

```
summary(dati$stress)  
summary(dati$qualita_sonno)
```

`summary()` mostra minimo, quartili, mediana, media, massimo ed eventuali mancanti. Se `stress` dovrebbe variare tra 0 e 40, un massimo pari a 999 segnala un problema da approfondire.

Possiamo rendere esplicito il controllo dell'intervallo:

```
dati$stress < 0 |
  dati$stress > 40
```

L'espressione produce TRUE per i valori fuori dall'intervallo atteso. Per contarli:

```
sum(
  dati$stress < 0 |
  dati$stress > 40,
  na.rm = TRUE
)
```

Ancora una volta, il codice non decide che cosa fare di questi valori. Li rende visibili. Potrebbero essere errori, codici speciali o osservazioni che richiedono una verifica nel materiale originale.

8.9. L'identificatore e l'unità di analisi

Se ogni riga dovrebbe rappresentare una persona, l'identificatore dovrebbe essere presente e normalmente non dovrebbe ripetersi.

```
anyDuplicated(dati$id)
```

Un risultato pari a 0 indica che non sono state trovate duplicazioni. Un valore maggiore di zero segnala la posizione della prima ripetizione.

Una duplicazione non è automaticamente un errore. In uno studio longitudinale o entro partecipanti, la stessa persona deve comparire in più righe. Il controllo serve quindi a collegare la tabella al disegno:

Una riga rappresenta una persona, una misurazione, una prova oppure una combinazione di persona e momento?

Questo è un esempio importante di limite dell'automazione. L'AI può trovare identificatori ripetuti; soltanto la documentazione dello studio permette di stabilire se siano corretti.

8.10. Dai controlli alla decisione

Al termine dell'ispezione, non dobbiamo avere necessariamente una tabella perfetta. Dobbiamo avere una diagnosi.

Possiamo scoprire che il file è quello giusto ma contiene due categorie scritte in modo incoerente. Possiamo trovare codici mancanti che devono essere ricodificati. Possiamo accorgerci che una variabile attesa non è stata esportata o che il numero di righe non coincide con il registro dei partecipanti.

La decisione successiva dipende dal problema. Alcune trasformazioni possono essere documentate nel codice. Altre richiedono di recuperare il file corretto, consultare il codebook o contattare chi ha raccolto i dati.

L'algoritmo generale è:

osservare una discrepanza → formulare una spiegazione → cercare evidenza → correggere o documentare.

Non bisogna trasformare automaticamente ogni valore insolito in NA né uniformare categorie soltanto perché sembrano simili.

8.11. Salvare una versione trasformata

I controlli che non modificano il dataset non richiedono un nuovo file. Se invece ricodifichiamo valori, rinominiamo colonne o costruiamo nuove variabili, possiamo salvare una versione elaborata in una posizione distinta:

```
percorso_output <-  
  "data/processed/stress_sonno_controllato.csv"  
  
readr::write_csv(  
  dati_controllati,  
  percorso_output  
)
```

Il file originale rimane in data/raw/. Il codice documenta come viene creato dati_controllati, mentre data/processed/ contiene un output rigenerabile.

Salvare una copia non sostituisce il codice. Senza la procedura che la produce, la versione elaborata è soltanto un secondo file di origine incerta.

8.12. Chiedere all'AI una procedura controllabile

Una richiesta poco informativa è:

Importa e pulisci questo dataset.

La parola *pulisci* può includere decisioni molto diverse. L'AI potrebbe rinominare colonne, eliminare righe, convertire tipi o sostituire mancanti senza rendere chiare le assunzioni.

Una richiesta migliore separa importazione, controlli e trasformazioni:

Un prompt per importare e controllare

Sto lavorando in un progetto R. Il file CSV si trova in data/raw/stress_sonno_originale.csv e ogni riga dovrebbe rappresentare uno studente. Le variabili indispensabili sono id, stress, qualita_sonno e genere. stress dovrebbe variare da 0 a 40 e qualita_sonno da 1 a 10. Il codebook usa 999 come valore mancante soltanto per queste due scale.

Scrivi codice R semplice che:

1. verifichi l'esistenza del file;
2. lo importi con readr::read_csv() senza modificare l'originale;
3. mostri dimensioni, nomi e struttura;

4. segnali variabili mancanti, identificatori duplicati, valori mancanti e valori fuori intervallo;
5. non corregga o elimini nulla automaticamente.

Spiega ogni controllo in linguaggio naturale e separa chiaramente i problemi osservati dalle trasformazioni eventualmente consigliate.

La richiesta fornisce ciò che l'AI non può ricavare dalla sintassi: unità di analisi, variabili attese, intervalli plausibili e significato del codice speciale.

Se l'assistente propone di correggere il dataset, possiamo chiedere una seconda fase:

Ora proponi trasformazioni esplicite soltanto per i problemi confermati. Conserva l'oggetto originale, crea `dati_controllati` e mostra dopo ogni passaggio un controllo che documenti l'effetto.

8.13. Un controllo minimo completo

Il seguente blocco riassume la procedura per il file ipotetico:

```
percorso_input <-
  "data/raw/stress_sonno_originale.csv"

if (!file.exists(percorso_input)) {
  stop(
    "File non trovato: ",
    percorso_input
  )
}

dati <- readr::read_csv(
  percorso_input,
  show_col_types = FALSE
)

dim(dati)
names(dati)
head(dati)
str(dati)

variabili_richieste <- c(
  "id",
  "stress",
  "qualita_sonno",
  "genere"
)

setdiff(
  variabili_richieste,
  names(dati)
)
```

```
colSums(is.na(dati))

table(
  dati$genere,
  useNA = "ifany"
)

summary(dati$stress)
summary(dati$qualita_sonno)

anyDuplicated(dati$id)
```

Non è necessario imparare il blocco a memoria. Dobbiamo saperne ricostruire la logica:

Trova il file. Interrompi se non esiste. Importalo. Controlla forma, nomi e struttura. Confronta le colonne con quelle necessarie. Esamina mancanti, categorie, intervalli e identificatori.

La sequenza può essere adattata a qualunque dataset modificando le aspettative.

8.14. Errori frequenti e diagnosi

Se il dataset contiene una sola colonna, il file potrebbe usare un separatore diverso da quello atteso. La risposta corretta non è procedere con l'analisi, ma esaminare il file e scegliere la funzione o gli argomenti appropriati.

Se una variabile numerica viene letta come testo, occorre cercare valori non numerici, separatori decimali o codici speciali. Convertirla immediatamente può trasformare informazioni problematiche in nuovi mancanti senza spiegazione.

Se una categoria attesa non compare, le possibili spiegazioni includono un filtro precedente, un errore di esportazione o un campione differente da quello previsto. Aggiungere manualmente la categoria non risolve il problema.

Se il numero di righe è inatteso, dobbiamo confrontarlo con il registro dello studio e verificare duplicazioni, mancate importazioni o righe aggiuntive.

In tutti questi casi, il messaggio generale è lo stesso:

Prima di correggere, identifica quale aspettativa è stata violata e cerca la causa della discrepanza.

8.15. Che cosa non serve ancora

Non è necessario costruire un sistema completo di validazione automatica, imparare espressioni regolari o usare pacchetti specializzati per il controllo dei dati. Questi strumenti diventano utili nei progetti più grandi.

Per questo modulo sono sufficienti pochi controlli leggibili, scelti in base al disegno e al codebook. La semplicità è un vantaggio se rende chiaro che cosa viene verificato.

Nel capitolo successivo useremo `dplyr` per selezionare righe e colonne, creare variabili e produrre riepiloghi. Quelle trasformazioni saranno affidabili soltanto se la tabella iniziale è stata compresa e controllata.

Riflessioni conclusive

Importare un file significa tradurlo in un oggetto R. Il passaggio decisivo consiste nel verificare che quella traduzione conservi la struttura e il significato attesi.

I controlli iniziali riguardano forma, nomi, tipi, variabili indispensabili, valori mancanti, categorie, intervalli plausibili e unità di analisi. Nessuno di questi controlli è puramente meccanico: ciascuno richiede un confronto con il disegno, la misurazione e la documentazione dello studio.

L'AI può generare una procedura efficace soltanto se le forniamo queste aspettative. Chiederle di «pulire i dati» senza specificarle significa delegare decisioni che potrebbero modificare il campione e il significato delle variabili. È preferibile chiedere prima una diagnosi, poi autorizzare trasformazioni esplicite e controllate.

La mentalità da conservare è semplice: non fidarsi del fatto che il file sia stato letto; produrre evidenza che la tabella corrisponda a ciò che dovrebbe rappresentare.

Esercizi

1. Un file dovrebbe contenere 250 partecipanti e 30 variabili. Dopo l'importazione, `dim(dati)` restituisce 250 1. Quale aspettativa è stata violata e quale possibile causa controlleresti per prima?
2. Spiega la differenza tra queste due domande: «R ha memorizzato `genere` come numero?» e «I numeri presenti in `genere` rappresentano una quantità?».
3. Il comando seguente restituisce "qualita_sonno":

```
setdiff(
  c("id", "stress", "qualita_sonno"),
  names(dati)
)
```

Che cosa significa? Perché non dovresti creare automaticamente una colonna vuota con quel nome?

4. Una scala dovrebbe variare da 0 a 40 e contiene il valore 999. Quali spiegazioni considereresti prima di trasformarlo in NA?
5. `anyDuplicated(dati$id)` restituisce un valore maggiore di zero. Perché questo risultato può indicare un errore in uno studio trasversale ma essere previsto in uno studio longitudinale?
6. Formula un prompt per l'AI che chieda di importare un file e diagnosticare i problemi senza modificare o eliminare automaticamente alcuna osservazione.
7. L'AI propone di convertire direttamente una colonna testuale in numerica. Quali controlli dovrebbe mostrare prima della conversione?
8. Descrivi in linguaggio naturale un algoritmo che parta da un percorso e termini con una decisione documentata sulla possibilità di usare la tabella per l'analisi.

Soluzioni

1. È stata violata l'aspettativa sul numero di colonne. Una causa probabile è il mancato riconoscimento del separatore del file. Bisogna esaminare il formato e la prima riga prima di proseguire.
2. La prima domanda riguarda il tipo informatico assegnato da R. La seconda riguarda il significato scientifico dei valori. Codici numerici possono rappresentare categorie nominali e non quantità.
3. La variabile richiesta non è presente nella tabella. Potrebbe esserci un errore nel nome, nel file esportato o nella documentazione. Creare una colonna vuota nasconderebbe il problema senza recuperare i dati mancanti.
4. 999 potrebbe essere un codice di mancata risposta, un errore di inserimento, un codice proveniente da un altro sistema oppure un valore appartenente a una colonna importata male. Il codebook e il file originale devono stabilirne il significato.
5. Se ogni riga dovrebbe rappresentare una persona, un identificatore ripetuto è incoerente con l'unità di analisi. Se ogni persona produce più misure, la ripetizione è necessaria e deve essere accompagnata da una variabile che distingua tempi o condizioni.
6. Il prompt dovrebbe specificare percorso, formato, unità di analisi, variabili attese, intervalli e codici mancanti. Dovrebbe chiedere controlli e un rapporto delle discrepanze, vietando trasformazioni automatiche.
7. Dovrebbe mostrare i valori distinti o almeno quelli non convertibili, verificare separatori decimali e codici speciali, contare quanti valori diventerebbero mancanti e confrontare il risultato con il codebook.
8. Verificare l'esistenza del file; importarlo in un nuovo oggetto; controllare dimensioni, nomi e tipi; confrontare le colonne con quelle attese; esaminare mancanti, categorie, intervalli e identificatori; documentare le discrepanze; correggere soltanto problemi confermati oppure interrompere l'analisi.

Punti chiave

- Un file importato non è automaticamente pronto per l'analisi.
- Ogni controllo confronta i dati osservati con un'aspettativa dichiarata.
- Il percorso deve essere verificato prima dell'importazione.
- Il successo del comando indica soltanto che R ha creato un oggetto.
- Forma, nomi, tipi e contenuti della tabella devono essere controllati separatamente.
- I codici numerici non sono necessariamente quantità.
- I valori mancanti e quelli fuori intervallo richiedono documentazione, non correzioni automatiche.
- La presenza di identificatori duplicati va interpretata alla luce dell'unità di analisi.
- L'AI deve ricevere struttura attesa, codebook e vincoli sulle trasformazioni.
- È preferibile chiedere prima una diagnosi e poi una correzione documentata.

i Ambiente di sviluppo

Gli esempi di importazione usano il pacchetto `readr`. Le informazioni sulla sessione possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
Platform: aarch64-apple-darwin23
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Zagreb
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
loaded via a namespace (and not attached):
```

```
[1] compiler_4.6.1 fastmap_1.2.0 cli_3.6.6 tools_4.6.1
[5] htmltools_0.5.9 otl_0.2.0 yamll_2.3.12 rmarkdown_2.31
[9] knitr_1.51 jsonlite_2.0.0 xfun_0.60 digest_0.6.39
[13] rlang_1.3.0 evaluate_1.0.5
```

9. Trasformare tabelle con dplyr

In sintesi

Da sapere Una trasformazione dei dati è una procedura che modifica righe, colonne o valori per produrre una nuova tabella. `dplyr` rende questa procedura leggibile attraverso pochi verbi. La sintassi è utile perché rende esplicite le decisioni, non perché debba essere memorizzata.

Da saper fare Leggere una pipeline come una sequenza di operazioni; riconoscere quali righe, colonne e valori cambiano; produrre semplici riepiloghi per gruppi; controllare numerosità e valori mancanti; descrivere all'AI una trasformazione senza delegarle decisioni metodologiche implicite.

Introduzione

Dopo avere importato e controllato un dataset, raramente lo analizziamo esattamente nella forma in cui è stato ricevuto. Potremmo aver bisogno di conservare soltanto alcune variabili, lavorare su un sottoinsieme di osservazioni, creare un indicatore o calcolare una sintesi per gruppi.

Queste operazioni vengono spesso chiamate *manipolazione dei dati*. Il termine può suggerire un'attività tecnica e quasi neutrale. In realtà, ogni trasformazione incorpora una decisione. Filtrare significa stabilire quali casi entrano nell'analisi. Creare una variabile significa definire una nuova rappresentazione delle informazioni disponibili. Raggruppare significa decidere quali osservazioni debbano essere confrontate o riassunte insieme.

Il pacchetto `dplyr` è utile perché esprime tali decisioni attraverso pochi verbi. In questo capitolo non cercheremo di imparare tutto il pacchetto. Useremo soltanto le operazioni necessarie per comprendere e controllare una trasformazione semplice.

La domanda guida sarà:

Quale tabella entra, quali operazioni vengono applicate e quale tabella deve uscire?

Prerequisiti

È utile avere letto Capitolo 6, Capitolo 7 e Capitolo 8. Dovresti riconoscere la struttura input-trasformazione-output, sapere che cosa rappresentano righe e colonne e avere già controllato il file importato.

Panoramica del capitolo

Partiremo dalla struttura ordinata di una tabella e leggeremo la pipe come una sequenza algoritmica. Vedremo poi quattro operazioni essenziali: scegliere colonne, scegliere righe, creare variabili e

produrre riepiloghi. L'ultima parte mostrerà come controllare una pipeline e come formulare richieste all'AI che mantengano esplicite unità di analisi, esclusioni e trattamento dei valori mancanti.

i Preparazione del notebook

Gli esempi richiedono dplyr. Il dataset didattico viene creato direttamente nel documento, in modo che ogni blocco possa essere riprodotto senza file esterni.

```
library(dplyr)

studenti <- tibble(
  id = 1:10,
  genere = c(
    "F", "F", "M", "F", "M",
    "F", "M", "F", "M", "F"
  ),
  corso = c(
    "psicologia", "psicologia", "scienze",
    "psicologia", "scienze", "psicologia",
    "psicologia", "scienze", "psicologia",
    "scienze"
  ),
  stress = c(
    18, 25, 21, 30, 16,
    28, 24, NA, 19, 27
  ),
  sonno_ore = c(
    7.2, 6.1, 6.8, 5.4, 7.5,
    5.9, 6.2, 6.7, NA, 5.8
  )
)
```

9.1. Una tabella ordinata rende visibile l'unità di analisi

Gli strumenti di dplyr funzionano in modo particolarmente chiaro quando ogni colonna rappresenta una variabile, ogni riga rappresenta un'osservazione e ogni cella contiene un valore.

Nel dataset `studenti`, ogni riga rappresenta uno studente. `id` identifica l'unità osservata; `corso` e `genere` sono variabili categoriali; `stress` e `sonno_ore` sono misure numeriche.

```
glimpse(studenti)
```

```
Rows: 10
Columns: 5
$ id      <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10
$ genere  <chr> "F", "F", "M", "F", "M", "F", "M", "F", "M", "F"
$ corso    <chr> "psicologia", "psicologia", "scienze", "psicologia", "scienz~
$ stress   <dbl> 18, 25, 21, 30, 16, 28, 24, NA, 19, 27
$ sonno_ore <dbl> 7.2, 6.1, 6.8, 5.4, 7.5, 5.9, 6.2, 6.7, NA, 5.8
```

Questa organizzazione è una convenzione pratica, non una proprietà naturale dei dati. In uno studio longitudinale, per esempio, la stessa persona potrebbe comparire in più righe perché l'unità osservata è una combinazione di persona e momento. Prima di trasformare una tabella dobbiamo quindi sapere che cosa rappresenta una riga.

9.2. La pipe rappresenta una sequenza

La pipe `|>` passa il risultato di un'operazione a quella successiva. Il suo significato può essere letto come *poi*.

```
studenti |>
  filter(stress >= 20) |>
  select(id, stress, sonno_ore)
```

```
# A tibble: 6 x 3
      id stress sonno_ore
  <int> <dbl>    <dbl>
1     2    25      6.1
2     3    21      6.8
3     4    30      5.4
4     6    28      5.9
5     7    24      6.2
6    10    27      5.8
```

La procedura è:

Parti da `studenti`. Poi conserva le righe con `stress` almeno pari a 20. Poi conserva le colonne `id`, `stress` e `sonno_ore`.

La pipe non aggiunge capacità statistiche. Rende visibile l'ordine delle trasformazioni.

Possiamo rappresentare qualsiasi pipeline attraverso:

tabella iniziale → operazione 1 → operazione 2 → tabella finale.

Quando il codice è prodotto dall'AI, questa lettura è il primo controllo. Se non sappiamo spiegare una riga con una frase, non sappiamo ancora quali dati stiamo analizzando.

9.3. Quattro verbi essenziali

Per le trasformazioni introduttive sono sufficienti quattro idee.

Verbo	Cambia	Domanda
<code>select()</code>	Colonne	Quali variabili devono rimanere?
<code>filter()</code>	Righe	Quali osservazioni devono rimanere?

Verbo	Cambia	Domanda
<code>mutate()</code>	Valori o nuove colonne	Quale nuova informazione viene calcolata?
<code>summarise()</code>	Granularità della tabella	Quale sintesi deve sostituire le osservazioni?

`group_by()` non produce da solo una sintesi. Indica a `summarise()` che il calcolo deve essere ripetuto separatamente per ciascun gruppo.

Questi verbi descrivono la logica della procedura. I loro argomenti specificano i dettagli.

9.4. Scegliere colonne con `select()`

`select()` conserva le variabili necessarie.

```
studenti |>
  select(id, stress, sonno_ore)
```

```
# A tibble: 10 x 3
      id stress sonno_ore
  <int> <dbl>    <dbl>
1     1     18        7.2
2     2     25        6.1
3     3     21        6.8
4     4     30        5.4
5     5     16        7.5
6     6     28        5.9
7     7     24        6.2
8     8     NA        6.7
9     9     19        NA
10    10     27        5.8
```

Il numero delle righe non cambia. Cambia soltanto l'insieme delle colonne.

Questa operazione può semplificare una tabella molto ampia, ma eliminare una variabile troppo presto può rendere impossibile un controllo successivo. Per esempio, perdere `id` rende più difficile individuare duplicazioni o ritrovare un'osservazione problematica.

Una richiesta all'AI dovrebbe quindi specificare non soltanto quali variabili servano per il calcolo, ma anche quali debbano essere conservate per documentare il risultato.

9.5. Scegliere righe con `filter()`

`filter()` valuta una condizione per ogni riga e conserva quelle per cui la condizione è vera.

```
studenti |>
  filter(stress >= 20)
```

9. Trasformare tabelle con dplyr

```
# A tibble: 6 x 5
  id genere corso      stress sonno_ore
<int> <chr> <chr>    <dbl>    <dbl>
1     2 F     psicologia 25      6.1
2     3 M     scienze    21      6.8
3     4 F     psicologia 30      5.4
4     6 F     psicologia 28      5.9
5     7 M     psicologia 24      6.2
6    10 F     scienze    27      5.8
```

La soglia 20 non è una scelta tecnica di dplyr. Deve provenire dalla domanda, dal disegno o da una regola definita prima dell'analisi.

Possiamo combinare condizioni:

```
studenti |>
  filter(
    stress >= 20,
    sonno_ore < 6.5
  )
```

```
# A tibble: 5 x 5
  id genere corso      stress sonno_ore
<int> <chr> <chr>    <dbl>    <dbl>
1     2 F     psicologia 25      6.1
2     4 F     psicologia 30      5.4
3     6 F     psicologia 28      5.9
4     7 M     psicologia 24      6.2
5    10 F     scienze    27      5.8
```

Le due condizioni separate da una virgola devono essere entrambe vere.

Quando la variabile usata nel filtro contiene NA, la condizione non può essere valutata come vera o falsa. Quelle righe non vengono conservate.

```
studenti |>
  filter(is.na(stress))
```

```
# A tibble: 1 x 5
  id genere corso      stress sonno_ore
<int> <chr> <chr>    <dbl>    <dbl>
1     8 F     scienze    NA      6.7
```

Prima e dopo un filtro è utile contare le righe:

```
studenti_stress_alto <- studenti |>
  filter(stress >= 20)

nrow(studenti)
```



```
[1] 10
```

```
nrow(studenti_stress_alto)
```

```
[1] 6
```

Il confronto rende visibile l'effetto della decisione. Dire soltanto che «sono stati esclusi i casi non pertinenti» nasconde quante osservazioni siano state rimosse e per quale ragione.

 Filtrare modifica il campione analizzato

Una condizione sintatticamente corretta può produrre un campione diverso da quello definito nel disegno. Prima di usare un filtro, occorre sapere perché quei casi devono essere esclusi e documentare quanti ne vengono rimossi.

9.6. Creare una variabile con `mutate()`

`mutate()` calcola una nuova colonna oppure sostituisce i valori di una colonna esistente.

```
studenti |>
  mutate(
    sonno_insufficiente = sonno_ore < 6
  ) |>
  select(
    id,
    sonno_ore,
    sonno_insufficiente
  )
```

```
# A tibble: 10 x 3
   id sonno_ore sonno_insufficiente
<int>   <dbl> <lgl>
1     1     7.2 FALSE
2     2     6.1 FALSE
3     3     6.8 FALSE
4     4     5.4 TRUE
5     5     7.5 FALSE
6     6     5.9 TRUE
7     7     6.2 FALSE
8     8     6.7 FALSE
9     9     NA    NA
10    10     5.8 TRUE
```

La nuova variabile vale TRUE quando le ore di sonno sono inferiori a 6, FALSE negli altri casi osservati e NA quando `sonno_ore` è mancante.

Il codice traduce una regola:

Confronta ogni valore con la soglia 6 e registra il risultato.

9. Trasformare tabelle con `dplyr`

La regola è trasparente, ma la soglia deve essere giustificata. Creare categorie a partire da una misura continua riduce informazione e può introdurre confini arbitrari. Non dovrebbe essere fatto soltanto perché rende più semplice una tabella o un grafico.

Dopo `mutate()` dobbiamo controllare i valori prodotti:

```
studenti |>
  mutate(
    sonno_insufficiente = sonno_ore < 6
  ) |>
  count(
    sonno_insufficiente,
    .drop = FALSE
  )
```

```
# A tibble: 3 x 2
  sonno_insufficiente     n
  <lgl>                <int>
1 FALSE                 6
2 TRUE                  3
3 NA                    1
```

`count()` mostra quante righe appartengono a ciascun valore, compresi i mancanti.

! Una nuova colonna è una nuova definizione

`mutate()` esegue la regola indicata, ma non ne dimostra la validità. Il ricercatore deve poter spiegare che cosa rappresenta la nuova variabile, perché viene costruita e quali informazioni vengono perse.

9.7. Ridurre la tabella con `summarise()`

`summarise()` sostituisce molte osservazioni con una o più statistiche.

```
studenti |>
  summarise(
    n_righe = n(),
    n_sonno_osservato = sum(!is.na(sonno_ore)),
    sonno_medio = mean(
      sonno_ore,
      na.rm = TRUE
    )
  )
```

```
# A tibble: 1 x 3
  n_righe n_sonno_osservato sonno_medio
  <int>      <int>          <dbl>
1     10             9          6.4
```

La tabella iniziale contiene dieci righe. Il risultato ne contiene una, perché le osservazioni vengono riassunte.

La distinzione tra `n_righe` e `n_sonno_osservato` rende esplicito che la media non usa tutti i partecipanti. `na.rm = TRUE` consente il calcolo sui valori disponibili, ma non sostituisce il controllo dei mancanti.

Una sintesi dovrebbe dichiarare almeno quante osservazioni contribuiscono al risultato. Una media senza numerosità può sembrare più informativa di quanto sia.

9.8. Produrre sintesi per gruppi

Per calcolare la stessa sintesi separatamente per ciascun corso, possiamo raggruppare la tabella prima di usare `summarise()`.

```
studenti |>
  group_by(corso) |>
  summarise(
    n_righe = n(),
    n_stress_osservato = sum(!is.na(stress)),
    stress_medio = mean(
      stress,
      na.rm = TRUE
    )
  )
```

```
# A tibble: 2 x 4
  corso      n_righe n_stress_osservato stress_medio
<chr>      <int>          <int>          <dbl>
1 psicologia     6              6             24
2 scienze       4              3            21.3
```

La procedura è:

Dividi le righe in base a corso. All'interno di ogni gruppo conta le righe, conta i valori osservati e calcola la media.

Il risultato contiene una riga per gruppo. La granularità della tabella è cambiata: non rappresenta più singoli studenti, ma corsi.

Questa trasformazione è semplice e concettualmente importante. Dopo una sintesi, le colonne non devono essere interpretate come se rappresentassero ancora dati individuali.

i Contare è spesso il primo riepilogo

Per una variabile categoriale, `count()` offre una forma abbreviata e leggibile:

```
studenti |>
  count(corso, genere)
```

```
# A tibble: 4 x 3
  corso      genere      n
  <chr>    <fct> <int>
1 psicologia fem     6
1 psicologia mas     6
2 scienze   fem     3
2 scienze   mas     3
```

```
<chr>      <chr> <int>
1 psicologia F      4
2 psicologia M      2
3 scienze   F      2
4 scienze   M      2
```

Prima di confrontare medie tra gruppi è utile sapere quanti casi appartengano a ciascuna combinazione.

9.9. Una pipeline completa

Supponiamo di voler rispondere alla domanda:

Qual è la qualità media del sonno nei diversi corsi, tra gli studenti che possiedono sia il punteggio di stress sia la misura del sonno?

Possiamo costruire una nuova tabella senza modificare l'originale:

```
sonno_per_corso <- studenti |>
  filter(
    !is.na(stress),
    !is.na(sonno_ore)
  ) |>
  group_by(corso) |>
  summarise(
    n = n(),
    sonno_medio = mean(sonno_ore),
    sonno_sd = sd(sonno_ore)
  )

sonno_per_corso
```

```
# A tibble: 2 x 4
  corso      n sonno_medio sonno_sd
  <chr>  <int>      <dbl>    <dbl>
1 psicologia    5      6.16    0.658
2 scienze      3      6.7     0.854
```

La pipeline elimina le righe incomplete rispetto alle due variabili, forma gruppi definiti dal corso e produce tre statistiche per ciascun gruppo.

Il codice non spiega perché siano necessari dati completi su `stress`, dato che la sintesi finale usa soltanto `sonno_ore`. Questa incongruenza deve attirare l'attenzione. Se la domanda riguarda soltanto il sonno per corso, escludere chi non possiede il punteggio di stress modifica inutilmente il campione.

Una versione coerente con la domanda è:

```

sonno_per_corso <- studenti |>
  filter(!is.na(sonno_ore)) |>
  group_by(corso) |>
  summarise(
    n = n(),
    sonno_medio = mean(sonno_ore),
    sonno_sd = sd(sonno_ore)
  )

sonno_per_corso

```

```

# A tibble: 2 x 4
  corso      n sonno_medio sonno_sd
<chr>    <int>      <dbl>    <dbl>
1 psicologia     5      6.16     0.658
2 scienze       4      6.7      0.698

```

L'esempio mostra perché leggere una pipeline come procedura sia più importante che riconoscerne la sintassi. Un'operazione può essere eseguita correttamente e non essere necessaria per la domanda.

9.10. Controllare una trasformazione

Una pipeline importante dovrebbe lasciare evidenza dei propri effetti. I controlli dipendono dall'operazione.

Dopo un filtro, confrontiamo la numerosità iniziale e finale. Dopo `select()`, controlliamo i nomi delle colonne. Dopo `mutate()`, esaminiamo i valori della nuova variabile. Dopo `summarise()`, verifichiamo quale unità rappresenti ciascuna riga del risultato.

Un controllo semplice della pipeline precedente può essere:

```

studenti |>
  summarise(
    n_totale = n(),
    n_sonno_osservato = sum(!is.na(sonno_ore)),
    n_sonno_mancante = sum(is.na(sonno_ore))
  )

```

```

# A tibble: 1 x 3
  n_totale n_sonno_osservato n_sonno_mancante
  <int>      <int>          <int>
1     10           9            1

```

```
sonno_per_corso
```

```

# A tibble: 2 x 4
  corso      n sonno_medio sonno_sd
<chr>    <int>      <dbl>    <dbl>
1 psicologia     5      6.16     0.658
2 scienze       4      6.7      0.698

```

9. Trasformare tabelle con `dplyr`

Non esiste un unico comando che convalidi ogni trasformazione. Il controllo deve mostrare ciò che l'operazione avrebbe potuto alterare.

Il principio generale è:

trasformazione $\longrightarrow$ conseguenza attesa $\longrightarrow$ controllo osservabile.

9.11. Descrivere il compito all'AI

Una richiesta come «fammi una tabella con `dplyr`» lascia implicite troppe decisioni. L'assistente non sa quale sia l'unità di analisi, quali casi debbano essere inclusi o perché una variabile debba essere ricodificata.

Una richiesta controllabile può essere formulata così:

Un prompt per una pipeline semplice

Ho una tabella R chiamata `studenti`, con una riga per studente. Le variabili rilevanti sono `id`, `corso`, `stress` e `sonno_ore`.

Voglio una tabella con una riga per corso che riporti il numero totale di studenti, il numero di valori osservati di `sonno_ore`, la media e la deviazione standard di `sonno_ore`. Non escludere una riga a causa di valori mancanti in variabili che non entrano nel calcolo.

Usa `dplyr`, non modificare `studenti` e salva il risultato in `sonno_per_corso`. Spiega come cambia l'unità rappresentata dalle righe e aggiungi un controllo dei valori mancanti.

Il prompt specifica input, unità di analisi, variabili, output, trattamento dei mancanti, vincoli e controlli. L'AI deve tradurre la procedura in sintassi, non inventarne la logica.

Se il codice ricevuto è troppo complesso, possiamo chiedere:

Riscrivi la soluzione usando soltanto `filter()`, `select()`, `mutate()`, `group_by()`, `summarise()` e `count()`. Elimina ogni passaggio non necessario e spiega che cosa cambia dopo ciascun verbo.

9.12. Leggere criticamente il codice generato

Consideriamo:

```
studenti |>
  filter(
    stress > 20,
    sonno_ore > 6
  ) |>
  group_by(corso) |>
  summarise(
    stress_medio = mean(stress)
  )
```

La sintassi è valida. La procedura conserva soltanto persone con stress superiore a 20 e più di sei ore di sonno, poi calcola lo stress medio per corso.

Prima di usarla dobbiamo chiedere perché siano state introdotte quelle soglie, che cosa accada ai mancanti, quanti casi rimangano e se il campione risultante corrisponda alla domanda.

Una richiesta di revisione può essere:

Elenca tutte le decisioni analitiche contenute nella pipeline. Distingui quelle necessarie dalla sintassi tecnica. Mostra la numerosità prima e dopo ogni filtro e non modificare le condizioni senza spiegare perché.

Questo tipo di richiesta trasforma l'AI in uno strumento di audit del codice, non soltanto in un generatore.

9.13. Che cosa non serve ancora

Non è necessario imparare tutte le funzioni di selezione, ricodifica, unione e riorganizzazione disponibili in `dplyr` e nel `tidyverse`. Non è necessario neppure produrre pipeline molto compatte.

Per i capitoli successivi bastano poche operazioni leggibili. Quando servirà combinare tabelle o modificarne la forma, introdurremo il concetto nel contesto del problema specifico.

La semplicità non consiste nel ridurre il numero di righe a ogni costo. Consiste nel rendere evidente la relazione tra domanda, trasformazione e controllo.

Riflessioni conclusive

`dplyr` permette di descrivere una trasformazione come una sequenza di verbi. `select()` decide quali colonne rimangono, `filter()` quali righe rimangono, `mutate()` quali valori vengono creati e `summarise()` quale nuova unità viene rappresentata dalla tabella finale.

La pipe rende visibile l'ordine delle operazioni. Questa trasparenza è particolarmente importante quando la sintassi viene generata dall'AI. Il ricercatore deve comunque stabilire soglie, esclusioni, variabili da conservare, significato delle nuove colonne e trattamento dei mancanti.

Una pipeline è adeguata quando ogni passaggio è necessario per la domanda e quando le sue conseguenze sono controllate. Il fatto che il codice funzioni indica soltanto che R ha eseguito le istruzioni.

Nel capitolo successivo applicheremo lo stesso modo di pensare alla visualizzazione. Un grafico verrà costruito come una sequenza di scelte su dati, variabili e rappresentazioni, non come un oggetto decorativo.

Esercizi

1. Descrivi in linguaggio naturale questa pipeline, indicando input, effetto di ogni verbo e unità rappresentata dal risultato:

9. Trasformare tabelle con dplyr

```
studenti |>
  filter(!is.na(stress)) |>
  group_by(corso) |>
  summarise(
    n = n(),
    stress_medio = mean(stress)
  )
```

2. Il dataset contiene 200 righe. Dopo un filtro ne rimangono 73. Quali informazioni devi ottenere prima di considerare appropriata la trasformazione?
3. Spiega perché questa operazione può essere metodologicamente problematica anche se la sintassi è corretta:

```
studenti |>
  mutate(
    stress_alto = stress >= 20
  )
```

4. Modifica la seguente sintesi in modo che riporti anche il numero di valori osservati e mancanti:

```
studenti |>
  summarise(
    sonno_medio = mean(
      sonno_ore,
      na.rm = TRUE
    )
  )
```

5. L'AI propone di filtrare contemporaneamente i mancanti di `stress`, `sonno_ore` e `genere`, ma la tabella finale usa soltanto `sonno_ore` e `corso`. Quale problema introduce la proposta?
6. Formula un prompt che chieda una tabella con una riga per corso, media del sonno, deviazione standard, numerosità utilizzata e controllo dei mancanti. Specifica che il dataset originale non deve essere modificato.
7. Dopo `summarise()` ottieni una riga per corso. Perché non puoi più interpretare ogni riga come uno studente?
8. Quale controllo assoceresti a ciascuna operazione: `filter()`, `select()`, `mutate()` e `summarise()`?

Soluzioni

1. L'input è `studenti`. `filter()` conserva le righe in cui `stress` è osservato. `group_by()` forma gruppi in base al corso. `summarise()` sostituisce le righe individuali con numerosità e media per gruppo. Il risultato contiene una riga per corso.
2. Occorre sapere quale condizione è stata applicata, perché è giustificata, quanti casi sono stati esclusi per ciascuna ragione, se i gruppi sono stati alterati e se i casi rimasti rappresentano ancora la popolazione analitica prevista.
3. La soglia 20 può essere arbitraria. La trasformazione riduce una misura numerica a due categorie e perde informazione. Deve essere sostenuta da una definizione teorica, clinica o progettuale.

4. Una possibile soluzione è:

```
studenti |>
  summarise(
    n_totale = n(),
    n_sonno_osservato =
      sum(!is.na(sonno_ore)),
    n_sonno_mancante =
      sum(is.na(sonno_ore)),
    sonno_medio = mean(
      sonno_ore,
      na.rm = TRUE
    )
  )
```

5. Esclude osservazioni per informazioni che non sono necessarie alla domanda finale. Il campione viene ridotto senza motivo e può cambiare composizione.
6. Il prompt deve specificare `studenti` come input, una riga per studente, `corso` come variabile di raggruppamento, `sonno_ore` come variabile da riassumere, gestione esplicita dei mancanti, nome del nuovo oggetto e divieto di sovrascrivere l'originale.
7. `summarise()` aggrega tutte le osservazioni dello stesso corso. I valori della riga descrivono il gruppo e non una singola persona.
8. Dopo `filter()` si confrontano le numerosità; dopo `select()` si controllano i nomi delle colonne; dopo `mutate()` si esaminano valori e frequenze della nuova variabile; dopo `summarise()` si verifica l'unità rappresentata da ogni riga e il numero di osservazioni usate.

i Punti chiave

- Una trasformazione modifica righe, colonne, valori o granularità della tabella.
- La pipe rende visibile l'ordine delle operazioni.
- `select()` agisce sulle colonne e `filter()` sulle righe.
- `mutate()` crea una nuova definizione operativa.
- `summarise()` cambia l'unità rappresentata dalla tabella.
- I filtri e le soglie sono decisioni metodologiche, non dettagli sintattici.
- `na.rm = TRUE` deve essere accompagnato dal conteggio dei valori utilizzati.
- Ogni trasformazione importante richiede un controllo osservabile.
- L'AI deve tradurre una procedura dichiarata, non inventare esclusioni o ricodifiche.
- Una pipeline corretta è composta soltanto dai passaggi necessari alla domanda.

i Ambiente di sviluppo

Il capitolo usa `dplyr`. Le informazioni sull'ambiente possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
Platform: aarch64-apple-darwin23
```

9. Trasformare tabelle con dplyr

```
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; LAPACK
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Zagreb
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
other attached packages:
```

```
[1] dplyr_1.2.1
```

```
loaded via a namespace (and not attached):
```

```
[1] digest_0.6.39    utf8_1.2.6      R6_2.6.1        fastmap_1.2.0  
[5] tidyselect_1.2.1 xfun_0.60       magrittr_2.0.5  glue_1.8.1  
[9] tibble_3.3.1     knitr_1.51      pkgconfig_2.0.3 htmltools_0.5.9  
[13] rmarkdown_2.31  generics_0.1.4  lifecycle_1.0.5 cli_3.6.6  
[17] vctrs_0.7.3     withr_3.0.3     compiler_4.6.1  tools_4.6.1  
[21] pillar_1.11.1   evaluate_1.0.5  yaml_2.3.12     otel_0.2.0  
[25] rlang_1.3.0     jsonlite_2.0.0
```

10. Rendere visibili i dati con ggplot2

In sintesi

Da sapere Un grafico è una rappresentazione selettiva dei dati. Prima di scrivere codice bisogna decidere quale caratteristica si vuole rendere visibile: la forma di una distribuzione, la composizione di un campione, una differenza tra gruppi o una relazione tra variabili.

Da saper fare Scegliere una rappresentazione coerente con la domanda e con il tipo di variabili; leggere il codice come una sequenza di decisioni visive; verificare quali osservazioni entrano nel grafico; distinguere ciò che il grafico mostra da ciò che non permette di concludere; formulare richieste precise a un assistente AI.

Introduzione

Un grafico non serve innanzitutto a rendere più gradevole un risultato. Serve a rendere visibile una struttura che una tabella di numeri mostra con maggiore difficoltà.

Possiamo voler osservare dove si concentrano i punteggi, quanto variano, se esistono valori insoliti, come differiscono alcuni gruppi oppure se due variabili cambiano insieme. Ciascuna domanda richiede una rappresentazione diversa.

La scelta del grafico precede quindi la sintassi. Prima di chiedere a R o a un assistente AI di produrre una figura, dobbiamo poter completare la frase:

Voglio rendere visibile...

Per esempio:

Voglio rendere visibile la forma della distribuzione dello stress.

oppure:

Voglio rendere visibile come qualità del sonno e stress variano insieme.

Soltanto dopo possiamo scegliere assi, punti, barre o intervalli.

ggplot2 è utile perché costruisce il grafico come una sequenza di decisioni esplicite. Non occorre conoscere tutte le sue possibilità. Per questo modulo è sufficiente comprendere il rapporto tra dati, variabili e segni grafici.

Prerequisiti

È utile avere letto Capitolo 6, Capitolo 8 e Capitolo 9. Dovresti saper riconoscere l'unità di analisi, controllare la struttura di una tabella e leggere una pipeline come una sequenza di trasformazioni.

Panoramica del capitolo

Il capitolo parte dalla domanda esplorativa e mostra come tradurla in una rappresentazione. Useremo quattro situazioni ricorrenti: osservare una distribuzione, contare categorie, confrontare gruppi e studiare una relazione tra variabili numeriche. La parte finale è dedicata al controllo del grafico e all'uso dell'AI.

Preparazione del notebook

Gli esempi usano `ggplot2` e un piccolo dataset simulato. Il seme casuale rende i dati riproducibili.

```

library(ggplot2)

set.seed(2026)

n <- 80

studenti <- data.frame(
  id = seq_len(n),
  anno = factor(
    sample(
      c("primo", "secondo", "terzo"),
      size = n,
      replace = TRUE
    ),
    levels = c("primo", "secondo", "terzo")
  ),
  stress = round(
    pmin(
      pmax(rnorm(n, mean = 24, sd = 6), 8),
      40
    )
  ),
  sonno_ore = round(
    pmin(
      pmax(rnorm(n, mean = 6.5, sd = 1.1), 3.5),
      9.5
    ),
    1
  )
)

studenti$qualita_sonno <- round(
  pmin(
    pmax(
      9 -
        0.12 * studenti$stress +
        rnorm(n, mean = 0, sd = 1.1),
      1
    ),
    10
  ),
  1
)

studenti$sonno_ore[c(8, 41)] <- NA
studenti$qualita_sonno[17] <- NA

```

Prima di costruire un grafico controlliamo sempre la tabella:

```
str(studenti)
```

```
'data.frame': 80 obs. of 5 variables:
 $ id      : int  1 2 3 4 5 6 7 8 9 10 ...
 $ anno    : Factor w/ 3 levels "primo","secondo",...: 1 1 1 2 1 3 3 1 3 2 ...
 $ stress   : num  23 17 18 25 18 23 25 23 22 14 ...
 $ sonno_ore : num  6.4 5.3 7.1 7.5 6.9 6.9 6.7 NA 5.1 7.8 ...
 $ qualita_sonno: num  7.1 7.6 8 7.2 9.2 6.3 3.2 5.6 5.5 7 ...
```

```
colSums(is.na(studenti))
```

```
      id      anno      stress      sonno_ore qualita_sonno
      0         0         0         2         1
```

10.1. Dal quesito alla rappresentazione

La scelta del grafico dipende da ciò che vogliamo osservare e dalla natura delle variabili.

Domanda	Informazione da rendere visibile	Rappresentazione utile
Come si distribuisce lo stress?	Forma, centro, dispersione e valori insoliti	Istogramma
Quanti studenti appartengono a ogni anno?	Frequenze delle categorie	Barre
Come variano le ore di sonno tra gli anni?	Distribuzioni entro gruppi	Punti e boxplot
Stress e qualità del sonno cambiano insieme?	Relazione tra due misure numeriche	Diagramma di dispersione

Questa tabella non è una regola automatica. È un punto di partenza. Il grafico deve essere valutato osservando il risultato: una rappresentazione formalmente appropriata può comunque nascondere sottogruppi, pochi casi o valori mancanti.

10.2. La struttura minima di un grafico

In ggplot2 descriviamo tre elementi:

1. la tabella da usare;
2. il collegamento tra variabili e proprietà visive;
3. il segno grafico con cui rappresentare le osservazioni.


La forma minima è:

```
ggplot(
  dati,
  aes(x = variabile_x, y = variabile_y)
```

```
) +  
  geom_qualsa()
```

Per esempio:

```
ggplot(  
  studenti,  
  aes(  
    x = stress,  
    y = qualita_sonno  
  )  
) +  
  geom_point(na.rm = TRUE)
```



Il significato è:

Usa la tabella `studenti`. Colloca `stress` sull'asse orizzontale e `qualita_sonno` su quello verticale. Rappresenta ogni riga completa con un punto.

Il simbolo `+` aggiunge un elemento al grafico. Non è necessario ricordare tutte le geometrie. È più importante sapere che cosa rappresenta ciascun segno.

! Il codice deve poter essere tradotto in una frase

Di fronte a un grafico prodotto dall'AI dovresti riuscire a dire quale tabella entra, quale variabile compare su ciascun asse e che cosa rappresenta ogni punto, barra o intervallo.

10.3. Osservare una distribuzione

Per comprendere una variabile numerica dobbiamo vedere come i valori sono distribuiti, non soltanto conoscerne la media.

```
ggplot(  
  studenti,  
  aes(x = stress)  
) +  
  geom_histogram(  
    binwidth = 3,  
    boundary = 0  
  ) +  
  labs(  
    x = "Punteggio di stress",  
    y = "Numero di studenti"  
  )  
)
```




Figura 10.1.: Distribuzione dei punteggi di stress nel campione.

L'istogramma suddivide l'intervallo dei valori e conta quante osservazioni cadono in ciascuna zona. Permette di chiedersi se la distribuzione sia concentrata o dispersa, simmetrica o asimmetrica, continua oppure formata da gruppi distinti.

La scelta dell'ampiezza degli intervalli modifica l'aspetto del grafico. Intervalli molto larghi cancellano dettagli; intervalli troppo stretti enfatizzano oscillazioni casuali. Non esiste un valore corretto in assoluto. È opportuno provare alcune scelte ragionevoli e verificare che l'interpretazione generale non dipenda da una sola di esse.

La domanda da porre all'AI non dovrebbe quindi essere soltanto «crea un istogramma», ma:

Proponi un'ampiezza iniziale coerente con l'intervallo della scala e mostrami come confrontarla con almeno un'alternativa.

10.4. Contare categorie

Per una variabile categoriale, la prima informazione è spesso il numero di osservazioni in ciascuna categoria.

```
ggplot(
  studenti,
  aes(x = anno)
) +
  geom_bar() +
  labs(
    x = "Anno di corso",
    y = "Numero di studenti"
  )
```




Figura 10.2.: Numero di studenti per anno di corso.

Ogni barra rappresenta un conteggio. Il grafico descrive la composizione del campione, non una proprietà media degli studenti.

È importante distinguere questo caso da una tabella che contiene già valori aggregati. `geom_bar()` conta le righe della tabella originale. Se abbiamo calcolato prima una media per gruppo, la figura rappresenta una sintesi e non più osservazioni individuali.

Questa distinzione è concettuale: prima di leggere una barra dobbiamo sapere se la sua altezza deriva da un conteggio o da una statistica calcolata in precedenza.

10.5. Confrontare gruppi senza nascondere i dati

Supponiamo di voler confrontare le ore di sonno tra gli anni di corso.

```
ggplot(
  studenti,
  aes(
    x = anno,
    y = sonno_ore
  )
) +
  geom_boxplot(
    outlier.shape = NA,
    na.rm = TRUE
  ) +
  geom_jitter(
    width = 0.12,
    height = 0,
    alpha = 0.65,
    na.rm = TRUE
  ) +
  labs(
    x = "Anno di corso",
    y = "Ore di sonno"
  )
)
```




Figura 10.3.: Distribuzione delle ore di sonno per anno di corso.

Il boxplot riassume posizione e dispersione. I punti mostrano invece le osservazioni individuali e rendono visibile la numerosità dei gruppi.

La combinazione è utile perché una sintesi può nascondere aspetti importanti. Due gruppi possono avere la stessa mediana e distribuzioni differenti; un gruppo può contenere molti meno casi; alcuni valori possono essere isolati.

Il grafico non stabilisce che l'anno di corso produca differenze nel sonno. Mostra come i valori osservati si distribuiscono nei gruppi definiti dal dataset.

⚠ Un punto distante non è automaticamente un errore

Un valore isolato può derivare da un errore, ma può anche essere un'osservazione reale. Il grafico segnala il caso da controllare; non autorizza a eliminarlo.

10.6. Studiare una relazione

Quando entrambe le variabili sono numeriche, ogni osservazione può essere rappresentata mediante una coppia di coordinate.

```
ggplot(
  studenti,
  aes(
    x = stress,
    y = qualita_sonno
  )
) +
  geom_point(
    alpha = 0.7,
    na.rm = TRUE
  ) +
  labs(
    x = "Punteggio di stress",
    y = "Qualità del sonno (1-10)"
  )
)
```




Figura 10.4.: Relazione osservata tra stress e qualità del sonno.

10. Rendere visibili i dati con ggplot2

Il diagramma di dispersione rende visibili direzione, variabilità, eventuali curve, gruppi e osservazioni insolite. Una singola correlazione numerica non mostra tutte queste caratteristiche.

Possiamo aggiungere una linea che sintetizza una tendenza lineare:

```
ggplot(  
  studenti,  
  aes(  
    x = stress,  
    y = qualita_sonno  
  )  
) +  
  geom_point(  
    alpha = 0.7,  
    na.rm = TRUE  
  ) +  
  geom_smooth(  
    method = "lm",  
    se = TRUE,  
    na.rm = TRUE  
  ) +  
  labs(  
    x = "Punteggio di stress",  
    y = "Qualità del sonno (1-10)"  
  )  
)
```




Figura 10.5.: Relazione tra stress e qualità del sonno con una sintesi lineare.

La linea non è la relazione stessa. È una sintesi costruita sotto l'assunzione che una retta sia una rappresentazione utile del pattern medio. La fascia esprime incertezza sulla linea stimata, non la dispersione di tutte le possibili osservazioni individuali.

Prima di interpretarla dobbiamo verificare se il pattern appare approssimativamente lineare e se pochi punti esercitano un'influenza eccessiva.

! Vedere un'associazione non significa vedere una causa

Il grafico può mostrare che stress e qualità del sonno cambiano insieme nel campione. La direzione causale dipende dal disegno e non viene determinata dalla pendenza della linea.

10.7. Colori e pannelli devono rappresentare una domanda

Un elemento visivo può essere collegato a una variabile oppure usato soltanto per rendere leggibile il grafico.

```
ggplot(
  studenti,
  aes(
    x = stress,
    y = qualita_sonno,
    colour = anno
  )
) +
  geom_point()
```

Qui il colore rappresenta anno. Il grafico aggiunge una domanda: la relazione appare differente nei diversi anni di corso?

Se invece il colore viene specificato come proprietà fissa, non porta nuova informazione:

```
geom_point(colour = "grey40")
```

Questa distinzione è importante quando si controlla codice prodotto dall'AI. Colori, forme e pannelli non dovrebbero essere aggiunti senza uno scopo. Troppe codifiche simultanee possono rendere il grafico più difficile da leggere e suggerire differenze che non sono centrali per la domanda.

Il faceting può ripetere la stessa rappresentazione per sottogruppi. È utile quando il confronto tra pannelli è davvero necessario, ma diventa poco informativo se ciascun pannello contiene pochi casi. In questo capitolo non è necessario impararne la sintassi: è sufficiente riconoscere che suddividere il grafico equivale a suddividere l'informazione disponibile.

10.8. Etichette: descrivere ciò che viene mostrato

Un grafico dovrebbe poter essere compreso senza conoscere i nomi interni delle colonne.

```
ggplot(
  studenti,
  aes(
    x = stress,
    y = qualita_sonno
```

```
)  
) +  
  geom_point(  
    alpha = 0.7,  
    na.rm = TRUE  
  ) +  
  labs(  
    title = "Stress accademico e qualità del sonno",  
    subtitle = "Ogni punto rappresenta uno studente",  
    x = "Punteggio di stress",  
    y = "Qualità del sonno percepita (1-10)"  
  )  
)
```




Figura 10.6.: Grafico con etichette che descrivono variabili e unità.

Le etichette devono chiarire il costrutto operativo, la scala e l'unità rappresentata dai segni grafici. Scrivere soltanto `stress` o `score` obbliga il lettore a ricostruire informazioni che dovrebbero essere esplicite.

La personalizzazione estetica viene dopo. Un tema più pulito può migliorare la leggibilità, ma non corregge una scelta sbagliata delle variabili o una sintesi fuorviante.

10.9. Quante osservazioni entrano nel grafico?

ggplot2 può escludere le righe in cui manca una variabile necessaria. Usare `na.rm = TRUE` evita l'avviso, ma non rende irrilevante l'esclusione.

Prima di un grafico tra stress e qualità del sonno possiamo contare:

```
nrow(studenti)
```

```
[1] 80
```

```
sum(
  complete.cases(
    studenti[c(
      "stress",
      "qualita_sonno"
    )]
  )
)
```

```
[1] 79
```

Il primo valore è la numerosità del dataset. Il secondo è il numero di righe rappresentabili nel grafico.

Questa informazione dovrebbe accompagnare la lettura, soprattutto quando i mancanti sono numerosi o distribuiti in modo diverso tra gruppi.

Una figura non mostra automaticamente ciò che è stato escluso.

10.10. Controllare un grafico prodotto dall'AI

Il controllo può essere organizzato attorno a tre domande.

10.10.1. Che cosa entra?

Dobbiamo identificare il dataset, eventuali filtri, aggregazioni e valori mancanti. Se l'AI calcola prima medie per gruppo, il grafico non contiene più i dati individuali.

10.10.2. Che cosa viene rappresentato?

Dobbiamo sapere che cosa compare sugli assi e che cosa significano colori, forme, dimensioni o pannelli. Ogni elemento visivo dovrebbe corrispondere a una variabile o a una scelta di leggibilità.

10.10.3. Che cosa possiamo concludere?

Dobbiamo separare descrizione, associazione e causalità. Una linea crescente non dimostra un effetto causale; una differenza visiva non sostituisce la quantificazione dell'incertezza; un grafico esplorativo non costituisce da solo una conferma.

💡 Un prompt per ottenere un grafico semplice

Ho un data frame R chiamato `studenti`, con una riga per studente. `stress` e `qualita_sonno` sono punteggi numerici; `anno` è una variabile categoriale

ordinata.

Voglio esplorare la relazione tra `stress` e `qualita_sonno`. Usa `ggplot2` e produci un diagramma di dispersione semplice. Non aggregare i dati e non applicare filtri. Mostra anche una linea lineare come sintesi, ma spiega che non implica causalità.

Conta prima quante righe complete entrano nel grafico. Usa etichette leggibili e spiega con una frase che cosa rappresenta ogni strato. Evita personalizzazioni non necessarie.

La richiesta specifica la domanda, l'unità di analisi, il tipo delle variabili, ciò che non deve essere modificato e i controlli richiesti.


Se il codice ricevuto è troppo complesso, possiamo chiedere:

Riscrivi il grafico usando soltanto `ggplot()`, `aes()`, la geometria necessaria e `labs()`. Elimina colori, temi e trasformazioni che non aggiungono informazione alla domanda.

10.11. Salvare il grafico in modo riproducibile

Un grafico può essere assegnato a un oggetto:

```
grafico_stress_sonno <- ggplot(  
  studenti,  
  aes(  
    x = stress,  
    y = qualita_sonno  
  )  
) +  
  geom_point(  
    alpha = 0.7,  
    na.rm = TRUE  
  ) +  
  labs(  
    x = "Punteggio di stress",  
    y = "Qualità del sonno (1-10)"  
  )  
  
grafico_stress_sonno
```

Può quindi essere salvato attraverso il codice:

```
ggsave(
  filename =
    "output/grafico_stress_sonno.png",
  plot = grafico_stress_sonno,
  width = 7,
  height = 5,
  dpi = 300
)
```

Il percorso è relativo al progetto. Salvare mediante codice permette di ricreare la figura quando cambiano dati o analisi. Uno screenshot conserva soltanto una versione manuale e non documenta il processo che l'ha prodotta.

10.12. Che cosa non serve ancora

Non è necessario conoscere tutte le geometrie, le scale, i temi e le estensioni di ggplot2. Non è necessario costruire figure editoriali complesse né memorizzare la posizione di ogni argomento.

Per affrontare i capitoli EDA basta saper formulare una domanda visiva, riconoscere il tipo delle variabili, controllare quali dati entrano nella figura e leggere il codice come una rappresentazione di tali decisioni.

Quando servirà un grafico specifico, l'AI o la documentazione potranno fornire la sintassi. La responsabilità del ricercatore rimarrà la scelta di ciò che deve essere visibile e l'interpretazione proporzionata al disegno.

Riflessioni conclusive

Un grafico è una selezione. Decide quali variabili rappresentare, quali osservazioni includere, quali differenze enfatizzare e quali dettagli lasciare sullo sfondo.

ggplot2 rende queste decisioni esplicite attraverso una struttura semplice: una tabella, un collegamento tra variabili e proprietà visive, e un segno grafico. Non è necessario conoscere l'intera grammatica per controllare un grafico. È necessario saper spiegare che cosa rappresenta ogni elemento.

L'AI può tradurre una domanda in codice, ma la qualità della figura dipende dalla precisione della richiesta. Dobbiamo specificare l'unità di analisi, il tipo delle variabili, la caratteristica che vogliamo osservare, le trasformazioni consentite e i controlli sui dati mancanti.

Nei capitoli EDA useremo queste rappresentazioni per studiare distribuzioni, posizione, dispersione, relazioni e osservazioni insolite. La domanda rimarrà la stessa: che cosa vogliamo rendere visibile e quale conclusione è giustificata da ciò che vediamo?

Esercizi

1. Considera il codice:

```
ggplot(  
  studenti,  
  aes(  
    x = stress,  
    y = sonno_ore  
  )  
) +  
  geom_point()
```

Descrivi la tabella usata, le variabili sugli assi e ciò che rappresenta ogni punto.

2. Quale rappresentazione useresti per osservare la distribuzione dei punteggi di stress? Quale useresti per confrontare le ore di sonno nei tre anni di corso?
3. Perché un grafico a barre delle medie può essere meno informativo di un grafico che mostra anche le osservazioni individuali?
4. Un assistente AI aggiunge `colour = anno` a un diagramma tra stress e qualità del sonno. Quale nuova domanda introduce questa scelta?
5. Prima di produrre un grafico, il dataset contiene 200 righe; nel grafico ne entrano 143. Quali cause controlleresti?
6. Una linea lineare appare decrescente. Formula una conclusione descrittiva appropriata e una conclusione causale non giustificata.
7. L'AI produce un grafico con punti, linee, colori, forme e pannelli. Scrivi una richiesta che chieda di semplificarlo mantenendo soltanto gli elementi necessari alla domanda.
8. Formula un prompt completo per visualizzare una distribuzione numerica. Specifica dataset, variabile, unità di analisi, controllo dei mancanti e confronto tra due scelte ragionevoli degli intervalli.

💡 Soluzioni

1. La tabella è `studenti`. `stress` compare sull'asse orizzontale e `sonno_ore` su quello verticale. Ogni punto rappresenta una riga completa del dataset, cioè uno studente con entrambe le misure osservate.
2. Per lo stress è utile un istogramma. Per confrontare le ore di sonno tra gli anni è utile mostrare i punti per gruppo, eventualmente insieme a un boxplot.
3. Le sole medie nascondono numerosità, dispersione, asimmetria e valori insoliti. Gruppi con distribuzioni molto differenti possono avere la stessa media.
4. Introduce la domanda se la relazione tra stress e qualità del sonno presenti pattern differenti nei diversi anni di corso.
5. Controllerei valori mancanti nelle variabili rappresentate, filtri applicati prima del grafico, aggregazioni, valori non finiti ed eventuali esclusioni effettuate dalla geometria.
6. Conclusione descrittiva: nel campione, valori maggiori di stress tendono a essere associati a una qualità del sonno più bassa. Conclusione non giustificata: aumentare lo stress causa una riduzione della qualità del sonno.
7. Una possibile richiesta è: «Mantieni soltanto le variabili necessarie alla domanda. Usa punti per le osservazioni e, se utile, una sola linea di sintesi. Elimina colori, forme e pannelli che non rappresentano un confronto richiesto. Spiega che cosa rimane e perché».
8. Il prompt dovrebbe specificare che ogni riga rappresenta un'unità osservata, indicare la variabile numerica, chiedere il conteggio dei mancanti e un istogramma senza filtri. Dovrebbe inoltre chiedere di confrontare due ampiezze ragionevoli degli intervalli e di descrivere quali caratteristiche della distribuzione rimangono stabili.

i Punti chiave

- La scelta del grafico parte dalla domanda, non dalla sintassi.
- Un grafico rende visibile soltanto una parte dell'informazione disponibile.
- La struttura minima collega una tabella, alcune variabili e un segno grafico.
- Istogrammi, barre, punti e boxplot rispondono a domande differenti.
- Una sintesi grafica non deve nascondere numerosità e variabilità.
- Colori e pannelli devono rappresentare una domanda, non soltanto decorare.
- I valori mancanti possono ridurre silenziosamente il numero di osservazioni rappresentate.
- Una linea di tendenza sintetizza un pattern e non dimostra causalità.
- L'AI deve ricevere unità di analisi, tipi di variabili, domanda e controlli richiesti.
- Salvare il grafico mediante codice rende la figura riproducibile.

i Ambiente di sviluppo

Il capitolo usa `ggplot2`. Le informazioni sull'ambiente possono essere ottenute con:

```
sessionInfo()
```

R version 4.6.1 (2026-06-24)

Platform: aarch64-apple-darwin23

10. *Rendere visibili i dati con ggplot2*

Running under: macOS Tahoe 26.5.2

Matrix products: default

BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib

LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; LAPACK

locale:

[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8

time zone: Europe/Zagreb

tzcode source: internal

attached base packages:

[1] stats graphics grDevices utils datasets methods base

other attached packages:

[1] ggplot2_4.0.3

loaded via a namespace (and not attached):

[1] vctrs_0.7.3	nlme_3.1-170	cli_3.6.6	knitr_1.51
[5] rlang_1.3.0	xfun_0.60	otel_0.2.0	generics_0.1.4
[9] S7_0.2.2	jsonlite_2.0.0	labeling_0.4.3	glue_1.8.1
[13] htmltools_0.5.9	scales_1.4.0	rmarkdown_2.31	grid_4.6.1
[17] tibble_3.3.1	evaluate_1.0.5	fastmap_1.2.0	yaml_2.3.12
[21] lifecycle_1.0.5	compiler_4.6.1	dplyr_1.2.1	RColorBrewer_1.1-3
[25] pkgconfig_2.0.3	mgcv_1.9-4	lattice_0.22-9	farver_2.1.2
[29] digest_0.6.39	R6_2.6.1	tidyselect_1.2.1	splines_4.6.1
[33] pillar_1.11.1	magrittr_2.0.5	Matrix_1.7-6	withr_3.0.3
[37] tools_4.6.1	gtable_0.3.6		

11. Quarto: rendere esplicito il percorso dell'analisi

i In sintesi

Da sapere Un documento Quarto riunisce nello stesso luogo la domanda, il codice, i risultati e la loro interpretazione. Il suo valore non dipende dalla quantità di opzioni tecniche utilizzate, ma dalla possibilità di ricostruire l'analisi dall'inizio e di controllare il legame tra ogni risultato e il codice che lo ha prodotto.

Da saper fare Riconoscere le parti essenziali di un file `.qmd`; distinguere il lavoro temporaneo svolto nella Console dal codice necessario al documento; organizzare i chunk in base alla loro funzione; eseguire il render da una sessione pulita; controllare il codice prodotto con l'aiuto dell'AI.

Introduzione

Nei capitoli precedenti abbiamo imparato a descrivere un'analisi come una sequenza di input, trasformazioni, output e controlli. Quarto permette di conservare questa sequenza insieme alla spiegazione del suo significato.

Un risultato incollato in un documento di testo mostra soltanto il punto di arrivo. Un documento Quarto può mostrare anche da quali dati il risultato provenga, quali operazioni siano state applicate e quale interpretazione venga proposta. Il documento diventa così una traccia controllabile del ragionamento.

Questa funzione è particolarmente importante quando parte del codice viene generata con l'aiuto di un assistente AI. Non è indispensabile avere scritto personalmente ogni istruzione. È indispensabile, però, che il documento renda possibile rispondere a domande come queste: quali dati sono stati usati? Quali casi sono stati esclusi? Quale oggetto produce il risultato? L'interpretazione è coerente con ciò che è stato calcolato?

La domanda guida del capitolo è:

Un'altra persona potrebbe ricostruire e controllare questa conclusione partendo dal documento?

Quarto appartiene alla tradizione del *literate programming*, nella quale codice e spiegazione vengono sviluppati insieme (Dogucu, 2024). In questo modulo adotteremo una versione molto concreta di tale principio:

domanda → dati → operazioni → risultato → interpretazione.

💡 Prerequisiti

È utile avere letto Capitolo 7, Capitolo 8, Capitolo 9 e Capitolo 10. Quarto non sostituisce l'organizzazione del progetto o il controllo dei dati: li rende visibili nel documento finale.

Panoramica del capitolo

Il capitolo presenta Quarto come un ambiente per costruire un'analisi eseguibile. Vedremo le tre componenti essenziali di un file `.qmd`, il ruolo dei chunk, la differenza tra Console e documento, il significato del render e il modo in cui figure, tabelle e citazioni entrano nell'argomentazione. L'ultima parte propone un protocollo per usare l'AI senza perdere il controllo del processo.

i Preparazione del notebook

Per seguire il capitolo è sufficiente avere un progetto R contenente un file `.qmd`. Non è necessario usare configurazioni avanzate. Il test decisivo sarà chiudere o riavviare la sessione R e verificare che il documento possa essere renderizzato dall'inizio.

11.1. Un documento Quarto è un'analisi eseguibile

Un file `.qmd` combina tre elementi.

Elemento	Funzione
Metadati YAML	Identificano il documento e il formato da produrre
Testo Markdown	Spiega domanda, scelte, risultati e limiti
Chunk di codice	Eseguono le operazioni e producono evidenza

Questi elementi non sono tre parti indipendenti. Il testo introduce una domanda; il chunk produce un risultato pertinente; il testo successivo interpreta quel risultato.

Un documento minimo combina metadati, domanda, codice e interpretazione. I metadati possono essere:

```
---  
title: "Analisi preliminare"  
format: html  
---
```

Nel corpo del documento compare prima la domanda:

Domanda. Come si distribuiscono i punteggi di stress nel campione?

Segue un chunk R che produce l'evidenza pertinente. Per evitare che questo esempio venga eseguito durante il rendering del presente capitolo, mostriamo soltanto il contenuto che andrebbe inserito nel chunk:

```
#| label: fig-stress
#| fig-cap: "Distribuzione dei punteggi di stress."

ggplot(
  dati,
  aes(x = stress)
) +
  geom_histogram()
```

Dopo il risultato viene l'interpretazione:

La distribuzione mostra...

Non è necessario memorizzare subito tutta la sintassi. È più importante riconoscere la struttura logica: la domanda precede il codice e l'interpretazione segue il risultato.

! Il documento non è un contenitore di output

Un grafico o una tabella non dovrebbero comparire soltanto perché il codice li produce. Ogni output deve svolgere una funzione nell'argomentazione e deve essere richiamato e interpretato nel testo.

11.2. Il chunk come unità di lavoro controllabile

Un chunk contiene una parte eseguibile dell'analisi. Può importare dati, controllarne la struttura, trasformare una tabella, produrre una sintesi oppure costruire un grafico.

La domanda più utile non è «quali opzioni possiede un chunk?», ma:

Quale funzione svolge questo chunk nel percorso dell'analisi?

Un chunk ben progettato dovrebbe avere uno scopo riconoscibile. Per esempio:

Importare il file controllato e verificare le dimensioni.

oppure:

Produrre il grafico che mostra la relazione tra stress e qualità del sonno.

Un'etichetta aiuta a identificare il passaggio. All'interno di un chunk R potremmo scrivere:

```
#| label: controllo-dati

dim(dati)
str(dati)
```

L'etichetta è utile quando il render segnala un errore e quando una figura o una tabella deve essere richiamata nel testo.

Le altre opzioni servono soprattutto a distinguere ciò che viene **eseguito** da ciò che viene **mostrato**. `eval: false` mostra un esempio senza eseguirlo. `echo: false` esegue il codice ma non lo mostra.

11. Quarto: rendere esplicito il percorso dell'analisi

nel risultato finale. `include: false` esegue un passaggio necessario senza mostrare né codice né output.

Queste opzioni non devono nascondere problemi. Disattivare messaggi o avvisi può rendere il documento più leggibile soltanto dopo averne compreso il significato.

 Nascondere non significa risolvere

`warning: false` elimina un avviso dal documento finale, ma non corregge la causa che lo ha prodotto. Prima di nascondere un messaggio occorre stabilire perché compaia e se il risultato rimanga affidabile.

11.3. La Console serve a esplorare, il documento a ricostruire

La Console è utile per provare rapidamente un comando, controllare il nome di una variabile o capire un messaggio di errore. Il suo contenuto, però, è temporaneo.

Se creiamo `dati_puliti` nella Console e poi lo usiamo in un chunk, il documento può funzionare durante la sessione corrente. Quando Quarto esegue il render in una nuova sessione, quell'oggetto non esiste.

Il principio è semplice:

Tutto ciò che è necessario per ottenere il risultato deve essere creato o caricato dal documento oppure da file esplicitamente richiamati.

La Console può essere usata come spazio di prova. Quando il passaggio è stato compreso e verificato, il codice necessario deve entrare nel flusso riproducibile.

Questa distinzione è importante anche con l'AI. Incollare una soluzione nella Console può produrre immediatamente un risultato, ma lascia poche tracce. Inserire il codice in un chunk permette di rileggerlo, commentarlo, modificarlo e rieseguirlo insieme al resto dell'analisi.

11.4. Il render è un test di ricostruzione

Il comando di render esegue il documento dall'inizio e produce l'output richiesto, per esempio HTML, PDF o Word.

Il render non è soltanto un'operazione editoriale. È un controllo:

file del progetto + codice dichiarato → documento completo.

Se il documento funziona soltanto dopo avere eseguito manualmente alcuni comandi, la procedura contiene dipendenze nascoste. Se cerca un file attraverso un percorso assoluto, dipende da uno specifico computer. Se un pacchetto è necessario ma non viene mai richiamato, il risultato dipende dalla sessione corrente.

Il controllo finale dovrebbe essere:

1. salvare i file;
2. riavviare R;
3. eseguire il render;

4. leggere il documento prodotto;
5. verificare che risultati e testo siano ancora coerenti.

La riproducibilità non garantisce la correttezza. Un errore può essere eseguito perfettamente ogni volta. La riproducibilità rende però l'errore osservabile, localizzabile e correggibile.

11.5. Ogni risultato deve avere una provenienza

In un documento scientifico, figure e tabelle non sono decorazioni. Sono elementi dell'argomentazione.

Una figura etichettata può essere richiamata nel testo. Nel chunk che la produce inseriamo:

```
#| label: fig-stress-sonno
#| fig-cap: "Relazione osservata tra stress e qualità del sonno."

ggplot(
  dati,
  aes(
    x = stress,
    y = qualita_sonno
  )
) +
  geom_point()
```

Nel testo possiamo quindi scrivere:

Come mostra la **?@fig-stress-sonno**, ...

La stessa logica vale per una tabella. Nel chunk che la produce inseriamo:

```
#| label: tbl-descrittive
#| tbl-cap: "Statistiche descrittive del campione."

knitr::kable(tabella_descrittive)
```

Nel testo possiamo scrivere:

La **?@tbl-descrittive** riporta...

L'etichetta stabilisce un legame stabile tra codice, risultato e testo. Se la figura cambia posizione o numerazione, il riferimento viene aggiornato automaticamente.

Il punto centrale non è il prefisso `fig-` o `tbl-`. È la possibilità di rispondere alla domanda:

Quale codice ha prodotto l'evidenza che sto interpretando?

11.6. Testo e codice devono controllarsi a vicenda

Un documento può essere eseguito correttamente e contenere una narrazione non aggiornata.

Supponiamo che il codice iniziale escluda i partecipanti con meno di dieci prove valide e che, dopo una revisione, la soglia venga portata a otto. Se il testo continua a parlare di dieci prove, il documento è computazionalmente riproducibile ma scientificamente incoerente.

Dopo ogni modifica sostanziale dobbiamo quindi controllare sia il codice sia la prosa. Numerosità, nomi dei gruppi, soglie, statistiche e interpretazioni devono corrispondere ai risultati attuali.

Quando possibile, alcuni valori possono essere inseriti nel testo direttamente dal calcolo. Questa tecnica riduce gli errori di trascrizione, ma non sostituisce la lettura critica. Un numero aggiornato automaticamente può continuare a essere interpretato in modo improprio.

! Il render controlla l'esecuzione, non l'interpretazione

Quarto può verificare che il codice venga eseguito. Non può stabilire se una frase causale sia giustificata dal disegno o se una media rappresenti adeguatamente la variabile.

11.7. Formule e citazioni sostengono l'argomentazione

Le formule permettono di esprimere una relazione con precisione. Le citazioni permettono di rendere visibile la provenienza di un'affermazione.

In Quarto, una formula può essere inserita nel testo o presentata separatamente. Non occorre imparare subito tutta la sintassi LaTeX; è sufficiente riconoscere che la notazione deve essere leggibile e coerente con la spiegazione. L'appendice [?@sec-apx-latex-math](#) offre i dettagli necessari quando serviranno.

Le citazioni dipendono da un file bibliografico dichiarato nel documento o nel progetto. Nel testo possiamo usare una citazione narrativa, `@dogucu2024reproducibility`, oppure una citazione tra parentesi, `[@dogucu2024reproducibility]`.

La bibliografia finale viene generata a partire dai lavori effettivamente citati. Anche qui il vantaggio non è soltanto tecnico: il documento conserva il collegamento tra affermazione e fonte.

11.8. Usare l'AI dentro un flusso Quarto

L'AI può aiutare a scrivere un chunk, interpretare un errore, migliorare una tabella o proporre una struttura del documento. Il suo contributo diventa controllabile quando viene inserito in un flusso esplicito.

Una richiesta utile descrive il contesto del documento, non soltanto il comando desiderato.

💡 Un prompt per un chunk controllabile

Sto lavorando in un documento Quarto all'interno di un progetto R. Il data frame `studenti` viene creato in un chunk precedente e contiene una riga per studente.

Scrivi un chunk R che produca una tabella con una riga per corso, il numero di valori osservati di `sonno_ore`, la media e la deviazione standard. Non modificare

studenti e non escludere righe per variabili che non entrano nel calcolo.

Assegna un'etichetta `tbl-sonno-corso`, aggiungi una didascalia e mostra un controllo dei valori mancanti prima della tabella. Spiega in linguaggio naturale che cosa rappresenta ogni riga del risultato.

Il prompt specifica la posizione del chunk nel flusso, l'input, l'unità di analisi, il risultato, i vincoli e i controlli.

Dopo avere ricevuto il codice, occorre verificare almeno quattro aspetti: che gli oggetti esistano nel documento, che le trasformazioni corrispondano alla domanda, che le esclusioni siano visibili e che il testo interpreti correttamente l'output.

Se il codice usa oggetti non definiti, possiamo chiedere:

Elenca tutte le dipendenze di questo chunk e indica in quale punto del documento devono essere create.

Se il chunk è troppo complesso:

Riscrivi il passaggio usando soltanto funzioni già introdotte e separa preparazione, controllo e output.

Se l'assistente produce anche un'interpretazione:

Distingui ciò che è mostrato direttamente dal risultato da ciò che richiederebbe assunzioni ulteriori sul disegno o sulla causalità.

11.9. Un protocollo essenziale

Il lavoro con Quarto può essere organizzato in un ciclo breve.

Prima si formula la domanda in prosa. Poi si inserisce il codice che produce l'evidenza pertinente. Si controlla l'output, si scrive l'interpretazione e infine si esegue il render dall'inizio.

formulare → eseguire → controllare → interpretare → renderizzare.

Se il render fallisce, il messaggio indica spesso quale dipendenza manca. Se il render riesce ma il risultato è inatteso, il problema riguarda dati, trasformazioni o assunzioni. Se il risultato è corretto ma il testo non lo descrive adeguatamente, il problema è interpretativo.

Quarto non elimina questi livelli. Li riunisce nello stesso luogo e permette di distinguerli.

11.10. Diagnosticare un errore senza riscrivere tutto

Quando il render si interrompe, la prima informazione utile è il nome del chunk. Per questo le etichette sono importanti.

Un messaggio come `object 'dati' not found` indica che l'oggetto non è stato creato nel flusso eseguito. `cannot open file` indica generalmente un problema di percorso o di nome. Un pacchetto non trovato segnala una dipendenza non disponibile. Un blocco che appare come testo invece di essere eseguito suggerisce un problema nella delimitazione del chunk.

11. Quarto: rendere esplicito il percorso dell'analisi

La strategia generale è la stessa introdotta nei capitoli precedenti:

localizzare il passaggio → identificare l'input → controllare la dipendenza → correggere → renderizzare di nuovo

Una richiesta utile all'AI è:

Spiega l'errore a partire dal chunk indicato. Non riscrivere l'intero documento. Identifica l'oggetto, il file o il pacchetto mancante e proponi il controllo minimo che permetta di verificare la diagnosi.

11.11. Trasparenza sull'uso dell'AI

Quando l'AI contribuisce in modo sostanziale alla scrittura del codice o del testo, può essere opportuno dichiararne l'uso. La forma dipende dalle regole del corso, della rivista o dell'istituzione.

Una nota trasparente può indicare lo strumento utilizzato, il tipo di contributo ricevuto e il modo in cui il risultato è stato verificato. L'aspetto essenziale è non attribuire all'assistente la responsabilità scientifica dell'analisi.

La responsabilità rimane di chi presenta il lavoro, perché soltanto l'autore può verificare il rapporto tra domanda, disegno, dati, codice e conclusioni.

11.12. Che cosa non serve ancora

Non è necessario conoscere tutti i formati di output, le opzioni globali, i sistemi di caching, i filtri Pandoc o le estensioni di Quarto. Questi strumenti sono utili per progetti più complessi, ma non sono necessari per costruire un rapporto riproducibile.

Per questo modulo bastano:

- un file `.qmd` all'interno di un progetto;
- testo che spiega domanda e interpretazione;
- chunk con uno scopo riconoscibile;
- etichette per gli output importanti;
- percorsi relativi;
- un render completo da una sessione pulita.

La documentazione ufficiale di Quarto rimane la fonte appropriata quando sarà necessario cercare una specifica opzione tecnica.

Riflessioni conclusive

Quarto trasforma l'analisi da una sequenza di operazioni temporanee in un documento eseguibile. Dati, trasformazioni, risultati e interpretazioni possono essere letti nello stesso ordine in cui vengono prodotti.

Il valore del documento non dipende dalla complessità della sintassi. Dipende dalla chiarezza con cui ogni chunk svolge una funzione, ogni output è collegato al codice che lo produce e ogni interpretazione rimane proporzionata all'evidenza.

Il render da una sessione pulita è il controllo tecnico centrale. Mostra se il risultato può essere ricostruito senza oggetti nascosti o interventi manuali. Non garantisce che il ragionamento sia corretto, ma rende possibile controllarlo.

Quando viene usata l'AI, Quarto diventa anche il luogo in cui il contributo automatico viene sottoposto a verifica. L'assistente può proporre sintassi e soluzioni; il ricercatore deve ricostruirne la logica, controllarne le dipendenze e assumersi la responsabilità dell'interpretazione.

Esercizi

1. Spiega perché un documento che funziona soltanto dopo avere creato un oggetto nella Console non è ancora riproducibile.
2. Considera un chunk che produce una tabella, ma non è preceduto da alcuna domanda e non viene commentato nel testo. Quale parte dell'argomentazione manca?
3. Un chunk contiene `warning: false`. Quali controlli devi effettuare prima di considerare appropriata questa opzione?
4. Descrivi la differenza tra il ruolo della Console e quello del documento Quarto.
5. Dopo una modifica del codice, la numerosità del campione passa da 180 a 142, ma il testo continua a riportare 180. Il render termina senza errori. Il documento è riproducibile? È coerente?
6. Formula un prompt che chieda all'AI di produrre un chunk Quarto con un grafico, specificando input, variabili, unità di analisi, etichetta, didascalia e controllo dei mancanti.
7. Il render segnala object `'dati_puliti'` not found. Descrivi una procedura di diagnosi che non richieda di riscrivere l'intero documento.
8. Perché una relazione causale non diventa giustificata soltanto perché il grafico e il modello che la accompagnano sono perfettamente riproducibili?

Soluzioni

1. L'oggetto esiste soltanto nella memoria della sessione corrente. Una nuova sessione non possiede il passaggio che lo ha prodotto. Il codice necessario deve essere inserito nel documento o in un file esplicitamente richiamato.
2. Manca il collegamento tra risultato e domanda. Il lettore non sa perché la tabella sia stata prodotta, che cosa dovrebbe mostrare e quale conclusione ne venga tratta.
3. Occorre eseguire il chunk mostrando l'avviso, comprenderne la causa, verificare che non indichi un errore nei dati o nella procedura e documentare l'eventuale decisione di nascondere nel report finale.
4. La Console è uno spazio temporaneo per prove e diagnosi. Il documento conserva i passaggi necessari a ricostruire l'analisi e li collega al testo e agli output.
5. Il documento può essere computazionalmente riproducibile perché esegue sempre lo stesso codice, ma non è coerente: la narrazione non è stata aggiornata rispetto al risultato corrente.

11. Quarto: rendere esplicito il percorso dell'analisi

6. Il prompt deve indicare il data frame, ciò che rappresenta una riga, le variabili da collocare sugli assi, il tipo di grafico desiderato, il divieto di aggregare o filtrare se non richiesto, il conteggio delle righe complete e le opzioni `label` e `fig-cap`.
7. Individuare il chunk in cui l'oggetto viene usato; cercare nel documento dove dovrebbe essere creato; verificare che il chunk precedente venga eseguito; controllare eventuali errori o condizioni che impediscono l'assegnazione; riavviare R e renderizzare nuovamente.
8. La riproducibilità mostra come il risultato sia stato ottenuto. La causalità dipende dal disegno, dall'assegnazione, dal controllo dei confondenti e dalla qualità della misurazione. Un'analisi osservazionale può essere perfettamente riproducibile e non identificare un effetto causale.

Punti chiave

- Un documento Quarto collega domanda, codice, risultato e interpretazione.
- YAML, testo e chunk svolgono funzioni differenti ma coordinate.
- Ogni chunk dovrebbe avere uno scopo riconoscibile.
- La Console è temporanea; il documento deve contenere i passaggi necessari.
- Il render da una sessione pulita verifica la ricostruibilità dell'analisi.
- Figure e tabelle devono essere collegate al codice e richiamate nel testo.
- La riproducibilità non garantisce correttezza o causalità.
- Il testo deve essere aggiornato quando cambiano dati, filtri o risultati.
- L'AI deve ricevere contesto, input, vincoli e controlli richiesti.
- La responsabilità dell'interpretazione rimane dell'autore.

Ambiente di sviluppo

Le informazioni sulla sessione possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
Platform: aarch64-apple-darwin23
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; LAPACK
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Zagreb
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods   base
```

```
loaded via a namespace (and not attached):
```

```
[1] compiler_4.6.1 fastmap_1.2.0 cli_3.6.6      tools_4.6.1
```

```
[5] htmltools_0.5.9 otl_0.2.0      yaml_2.3.12      rmarkdown_2.31
[9] knitr_1.51      jsonlite_2.0.0  xfun_0.60        digest_0.6.39
[13] rlang_1.3.0     evaluate_1.0.5
```

Bibliografia

12. Pacchetti: scegliere e dichiarare gli strumenti

In sintesi

Da sapere Un pacchetto estende R con funzioni, dati e documentazione. Usarlo significa aggiungere una dipendenza all'analisi. La domanda importante non è quanti pacchetti conoscere, ma perché ne serve uno, quali funzioni vengono usate e se il documento può essere eseguito in una sessione pulita.

Da saper fare Distinguere installazione e uso; riconoscere da quale pacchetto proviene una funzione; limitare le dipendenze agli strumenti necessari; diagnosticare gli errori più comuni; chiedere all'AI soluzioni coerenti con i pacchetti già adottati nel progetto.

Introduzione

R contiene già molte funzioni. Altre vengono distribuite attraverso i **pacchetti**, cioè raccolte organizzate di codice, documentazione e, talvolta, dati di esempio.

Nei capitoli precedenti abbiamo usato `readr` per importare file, `dplyr` per trasformare tabelle e `ggplot2` per costruire grafici. Questi pacchetti non sono semplici accessori. Fanno parte della procedura da cui dipendono i risultati.

Quando leggiamo:

```
dplyr::filter(dati, stress > 20)
```

la parte più importante non è ricordare i due punti doppi. È riconoscere che l'operazione `filter()` viene fornita da `dplyr` e che il documento dipende dalla disponibilità di quel pacchetto.

La domanda guida del capitolo è:

Quali strumenti esterni usa l'analisi, perché sono necessari e come possiamo rendere esplicita questa dipendenza?

Un assistente AI può suggerire rapidamente nuovi pacchetti. Può però introdurre molti senza necessità, mescolare approcci differenti o proporre funzioni inesistenti. Il ricercatore deve saper chiedere una soluzione semplice e verificare che ogni dipendenza sia reale, appropriata e dichiarata.

Prerequisiti

È utile avere letto Capitolo 7 e Capitolo 11. Un pacchetto è una delle dipendenze che devono essere disponibili quando il documento viene eseguito dall'inizio in una sessione pulita.

Panoramica del capitolo

Il capitolo presenta i pacchetti come strumenti modulari. Distingueremo installazione e uso, vedremo due modi per richiamare una funzione, discuteremo gli errori più frequenti e costruiremo un criterio per decidere se introdurre una nuova dipendenza. La parte finale mostra come formulare richieste all'AI e come verificare un documento Quarto che utilizza pacchetti esterni.

i Preparazione del notebook

Gli esempi vengono mostrati come codice non eseguibile. Non è necessario installare nuovi pacchetti per leggere il capitolo. Nel progetto reale, installa soltanto gli strumenti che servono ai capitoli e alle analisi che stai effettivamente eseguendo.

12.1. Un pacchetto risponde a una necessità

Prima di introdurre un pacchetto dovremmo poter descrivere la capacità che ci manca.

Per esempio:

Devo leggere un file CSV in una tabella R.

Devo trasformare una tabella mediante operazioni leggibili.

Devo rappresentare graficamente una distribuzione.

A queste necessità possono corrispondere `readr`, `dplyr` e `ggplot2`. La scelta nasce dal compito, non dalla popolarità del pacchetto.

Un pacchetto contiene generalmente funzioni, documentazione ed esempi. Può offrire una soluzione più chiara o affidabile di quella che scriveremmo da zero. Introduce però anche una dipendenza: il pacchetto deve essere disponibile, la funzione deve essere usata correttamente e il suo comportamento deve essere compreso abbastanza da controllarne il risultato.

! Un pacchetto è una scelta metodologica e tecnica

Adottare un pacchetto significa scegliere un insieme di strumenti e convenzioni. La scelta dovrebbe semplificare il lavoro o rendere più chiaro il codice, non aggiungere complessità senza beneficio.

In questo modulo useremo pochi pacchetti e li introdurremo soltanto quando rispondono a un bisogno concreto. Non è necessario conoscere l'ecosistema completo di R.

12.2. Installare e usare sono passaggi differenti

L'**installazione** rende il pacchetto disponibile sul computer:

```
install.packages("dplyr")
```

12. Pacchetti: scegliere e dichiarare gli strumenti

Di norma viene eseguita una volta, fuori dal documento analitico. Inserire `install.packages()` in un file Quarto significa chiedere al render di modificare l'ambiente del computer, scaricando software durante l'esecuzione. Questa operazione non è necessaria per produrre l'analisi e può fallire per assenza di connessione o permessi.

L'uso del pacchetto avviene durante ogni sessione in cui servono le sue funzioni. Possiamo caricarlo:

```
library(dplyr)
```

oppure richiamare direttamente una funzione:

```
dplyr::filter(  
  dati,  
  stress > 20  
)
```

La distinzione algoritmica è semplice:

installare = rendere lo strumento disponibile sul computer

usare = richiamare lo strumento durante l'analisi

Se il pacchetto non è installato, nessuna delle due forme può funzionare. Se è installato ma non caricato, la forma `pacchetto::funzione()` rimane disponibile.

12.3. Due modi per rendere disponibile una funzione

Caricare un pacchetto con `library()` rende le sue funzioni richiamabili direttamente:

```
library(dplyr)  
  
filter(  
  dati,  
  stress > 20  
)
```

Questa forma è comoda quando molte funzioni dello stesso pacchetto vengono usate ripetutamente. In un documento Quarto, i pacchetti principali possono essere caricati in un chunk iniziale.

La forma esplicita:

```
dplyr::filter(  
  dati,  
  stress > 20  
)
```

mostra invece l'origine della funzione nel punto in cui viene usata. È utile quando la funzione compare poche volte, quando il nome può essere ambiguo oppure quando vogliamo rendere immediatamente visibile la dipendenza.

Non esiste una regola assoluta secondo cui una forma sia sempre migliore. La scelta deve favorire la leggibilità.

Situazione	Scelta generalmente chiara
Molte funzioni dello stesso pacchetto	Caricare il pacchetto all'inizio
Una funzione usata una sola volta	<code>pacchetto::funzione()</code>
Nomi potenzialmente ambigui	<code>pacchetto::funzione()</code>
Capitolo didattico breve	Forma che rende più facile riconoscere l'origine

L'importante è evitare che il codice dipenda da un pacchetto caricato accidentalmente nella sessione e mai dichiarato nel documento.

12.4. La provenienza della funzione fa parte del significato

Pacchetti differenti possono contenere funzioni con lo stesso nome. Il caso non rappresenta necessariamente un errore, ma richiede di sapere quale funzione venga eseguita.

Se R segnala che una funzione è stata *masked*, sta comunicando che il nome esiste in più pacchetti caricati e che una versione prevale sull'altra.

La soluzione non consiste nel nascondere automaticamente il messaggio. Dobbiamo stabilire quale funzione sia necessaria e, se serve, renderne esplicita la provenienza:

```
dplyr::filter(
  dati,
  stress > 20
)
```

Questa forma evita che il significato del codice cambi in funzione dell'ordine con cui i pacchetti sono stati caricati.

Una domanda utile da rivolgere all'AI è:

Indica da quale pacchetto proviene ogni funzione non appartenente a R base e segnala eventuali nomi che possono entrare in conflitto.

12.5. Un errore indica quale dipendenza manca

Gli errori relativi ai pacchetti possono essere letti come una procedura diagnostica.

Se:

```
library(dplyr)
```

produce un messaggio simile a:

```
there is no package called 'dplyr'
```

il pacchetto non è disponibile nell'installazione corrente di R. Occorre installarlo prima di eseguire nuovamente il documento.

Se invece R segnala:

```
could not find function "filter"
```

le possibili spiegazioni includono un pacchetto non caricato, un nome errato oppure una funzione appartenente a un altro pacchetto.

Il metodo generale è:

identificare la funzione → identificare il pacchetto → verificare l'installazione → verificare il richiamo.

Non è necessario modificare molte righe a caso. È sufficiente localizzare la dipendenza.

Chiedere una diagnosi all'AI

Una richiesta utile è:

R segnala `could not find function "..."`. Non riscrivere l'analisi. Indicami prima a quale pacchetto dovrebbe appartenere la funzione, come verificare se il pacchetto è installato e come richiamare esplicitamente la funzione.

12.6. Scegliere il minor numero di strumenti necessari

L'AI può proporre una soluzione che usa un nuovo pacchetto per ogni piccola operazione. Il codice può funzionare, ma il progetto diventa più difficile da comprendere e riprodurre.

Prima di accettare una nuova dipendenza possiamo porci tre domande:

1. il pacchetto risolve un problema che esiste davvero;
2. la stessa operazione è già disponibile con gli strumenti adottati;
3. il vantaggio ottenuto giustifica la nuova dipendenza.

Per esempio, se il progetto usa già `dplyr`, non è necessariamente utile introdurre un altro pacchetto soltanto per rinominare una colonna. Se una funzione specialistica esegue invece un'operazione difficile da implementare e ampiamente controllata, il nuovo pacchetto può essere appropriato.

Il criterio non è usare sempre R base. È evitare dipendenze che non migliorano chiarezza, affidabilità o capacità analitica.

Più pacchetti non significa analisi più avanzata

Una lunga lista di `library()` può indicare un progetto sofisticato, ma può anche indicare che il codice è stato assemblato senza un disegno coerente. Ogni pacchetto dovrebbe avere una funzione riconoscibile nel workflow.

12.7. Pacchetti in un documento Quarto

Un documento Quarto deve dichiarare gli strumenti da cui dipende. Se molti chunk usano `dplyr` e `ggplot2`, possiamo caricarli in un chunk iniziale:

```
#| label: packages-load
#| message: false

library(dplyr)
library(ggplot2)
```

L'opzione `message: false` può evitare che i messaggi di caricamento compaiano nel report finale. Prima di nasconderli è però opportuno leggerli almeno una volta, perché possono segnalare conflitti o altre informazioni utili.

Quando una funzione viene usata soltanto in un punto, possiamo evitare il caricamento globale:

```
readr::read_csv(
  "data/raw/questionario.csv"
)
```

Il documento dovrebbe essere renderizzato dopo avere riavviato R. Questo controllo verifica che nessun pacchetto necessario sia disponibile soltanto perché caricato manualmente in precedenza.

Un chunk iniziale non deve contenere `install.packages()`. L'installazione appartiene alla preparazione del computer; il documento deve invece dichiarare che cosa usa durante l'analisi.

12.8. Versioni e riproducibilità

Il comportamento di un pacchetto può cambiare tra versioni. Nella maggior parte degli esercizi introduttivi non è necessario gestire ambienti complessi, ma è utile registrare le informazioni sulla sessione quando un risultato deve essere conservato o condiviso.

```
sessionInfo()
```

Il risultato include la versione di R, il sistema operativo e i pacchetti caricati.

Per controllare un singolo pacchetto possiamo usare:

```
packageVersion("dplyr")
```

Queste informazioni aiutano a diagnosticare differenze tra computer. Non dimostrano che il codice sia corretto, ma rendono più chiaro l'ambiente in cui è stato eseguito.

Strumenti come `renv` possono congelare le dipendenze di progetti più complessi. Non sono necessari per questo modulo. Il principio da trattenere è che la versione del software fa parte del contesto computazionale dell'analisi.

12.9. Formulare richieste controllabili all'AI

Un prompt come:

Scrivi il codice R per questa analisi.

lascia all'assistente la scelta degli strumenti. Il risultato può introdurre pacchetti sconosciuti e incompatibili con il resto del progetto.

Una richiesta più precisa può essere:

💡 Un prompt per limitare le dipendenze

Scrivi una soluzione in R usando soltanto R base, dplyr, ggplot2 e readr. Non introdurre altri pacchetti senza spiegare quale problema aggiuntivo risolvano.

Usa la forma `pacchetto::funzione()` per le funzioni che compaiono una sola volta o che possono avere nomi ambigui. Alla fine elenca i pacchetti effettivamente necessari e indica quali righe del codice dipendono da ciascuno.

Se l'AI propone un nuovo pacchetto, possiamo chiedere:

Confronta questa soluzione con una versione basata sui pacchetti già usati nel progetto. Spiega quale vantaggio concreto offre la nuova dipendenza.

Se riceviamo codice da una fonte esterna:

Identifica tutte le funzioni non appartenenti a R base, associa ciascuna al pacchetto corretto e segnala eventuali funzioni che non riesci a verificare.

L'obiettivo non è vietare nuovi strumenti, ma impedire che vengano introdotti senza una ragione visibile.

12.10. Controllare il codice ricevuto

Dopo avere ricevuto una soluzione, dobbiamo poter rispondere a domande semplici.

Quali pacchetti sono necessari? Dove vengono dichiarati? Sono usati davvero? Esistono funzioni con nomi ambigui? Il documento funziona dopo il riavvio? Una soluzione più semplice produrrebbe lo stesso risultato?

Possiamo cercare nel documento le istruzioni `library()` e le forme `pacchetto::funzione()`. Dobbiamo però anche controllare funzioni richiamate senza prefisso, perché potrebbero dipendere da un pacchetto caricato in precedenza.

Una procedura utile è:

inventario delle funzioni → associazione ai pacchetti → rimozione delle dipendenze inutili → render in sessione p

Questo controllo è particolarmente importante quando il codice è stato composto a partire da più risposte dell'AI. Risposte differenti possono adottare ecosistemi e convenzioni differenti senza segnalarlo.

12.11. Un esempio di revisione

Supponiamo che l'AI proponga:

```
library(tidyverse)
library(janitor)
library(skimr)

dati <- read_csv(
  "data/raw/questionario.csv"
)

dati <- clean_names(dati)

skim(dati)
```

Il codice può essere utile, ma introduce un insieme ampio di dipendenze. Prima di accettarlo dobbiamo chiarire l'obiettivo.

Se vogliamo soltanto importare il file e controllarne la struttura, può essere sufficiente:

```
dati <- readr::read_csv(
  "data/raw/questionario.csv",
  show_col_types = FALSE
)

names(dati)
str(dati)
summary(dati)
```

La seconda versione non è universalmente migliore. È più coerente con un obiettivo limitato e usa strumenti già introdotti. `janitor` e `skimr` potrebbero diventare utili in un progetto più ampio, ma dovrebbero essere aggiunti per una necessità esplicita.

Il confronto mostra il criterio generale:

Prima definisci ciò che vuoi ottenere; poi scegli il minor insieme di strumenti che lo rende chiaro e controllabile.

12.12. Che cosa non serve imparare qui

Non è necessario conoscere la struttura interna dei pacchetti, svilupparne uno, pubblicarlo su CRAN o studiare tutti i sistemi di gestione delle versioni.

Non è necessario neppure memorizzare quali pacchetti contengano ogni possibile funzione. La documentazione e l'AI possono aiutare a localizzare lo strumento. La competenza richiesta è verificare la provenienza della funzione e giudicare se la nuova dipendenza sia necessaria.

Per i capitoli successivi bastano pochi strumenti stabili: R base, `readr`, `dplyr`, `ggplot2` e i pacchetti specificamente richiesti dalle analisi.

Riflessioni conclusive

I pacchetti rendono R un ambiente estendibile. Permettono di riutilizzare strumenti sviluppati e documentati da altre persone, ma introducono dipendenze che devono essere dichiarate e controllate.

Installare significa rendere un pacchetto disponibile sul computer. Caricarlo o usare `pacchetto::funzione()` significa richiamarlo durante l'analisi. La forma esplicita è particolarmente utile quando vogliamo mostrare la provenienza di una funzione o evitare conflitti.

La scelta più importante non riguarda la sintassi. Riguarda il rapporto tra compito e strumento. Un nuovo pacchetto è giustificato quando rende possibile o più chiara un'operazione necessaria. Non è giustificato soltanto perché l'AI lo ha suggerito.

La verifica finale rimane il render da una sessione pulita. Se il documento dichiara tutte le dipendenze e usa soltanto strumenti necessari, il percorso computazionale diventa più semplice da comprendere, condividere e correggere.

Esercizi

1. Spiega la differenza tra installare un pacchetto e usarlo durante una sessione R. Perché `install.packages()` non dovrebbe comparire normalmente nel documento Quarto?
2. Confronta:

```
library(readr)
read_csv("data/raw/dati.csv")
```

con:

```
readr::read_csv(
  "data/raw/dati.csv"
)
```

Quale dipendenza viene resa più visibile nella seconda forma?

3. R segnala `could not find function "filter"`. Descrivi una procedura diagnostica prima di modificare l'intera analisi.
4. Un messaggio informa che `filter()` è stato mascherato da un altro pacchetto. Quale forma del comando rende non ambiguo il comportamento?
5. L'AI propone cinque pacchetti per importare un file, rinominare due colonne e produrre un riepilogo. Quali domande useresti per decidere se siano tutti necessari?
6. Formula un prompt che chieda una soluzione usando soltanto R base, `readr`, `dplyr` e `ggplot2`, richiedendo una giustificazione per ogni eventuale pacchetto aggiuntivo.
7. Un documento funziona nella sessione corrente, ma dopo il riavvio segnala che una funzione non esiste. Quale dipendenza nascosta è probabile?
8. Perché conoscere la versione dei pacchetti può essere utile senza garantire che l'analisi sia scientificamente corretta?

Soluzioni

1. L'installazione scarica il pacchetto e lo rende disponibile sul computer. L'uso avviene durante l'esecuzione mediante `library()` o `pacchetto::funzione()`. `install.packages()` modifica l'ambiente e può richiedere rete e permessi; non è un passaggio analitico da ripetere a ogni render.
2. La seconda forma mostra direttamente che `read_csv()` proviene da `readr`. Non dipende dal fatto che il pacchetto sia stato precedentemente caricato con `library()`.
3. Verificare il nome della funzione, identificare il pacchetto a cui appartiene, controllare se il pacchetto è installato e poi usare `library(dplyr)` oppure `dplyr::filter()`.
4. `dplyr::filter(...)` indica esplicitamente quale funzione deve essere eseguita.
5. Chiederei quale problema risolva ciascun pacchetto, se la stessa operazione sia disponibile negli strumenti già adottati, se il vantaggio giustifichi la dipendenza e se tutti i pacchetti vengano realmente usati.
6. Il prompt dovrebbe elencare i pacchetti ammessi, vietare dipendenze aggiuntive non motivate e chiedere alla fine un inventario dei pacchetti e delle funzioni utilizzate.
7. Una funzione proveniva probabilmente da un pacchetto caricato manualmente nella sessione ma non dichiarato nel documento.
8. Le versioni aiutano a ricostruire l'ambiente computazionale e a spiegare differenze tra esecuzioni. Non stabiliscono se il disegno, la misura, le trasformazioni o l'interpretazione siano appropriati.

Punti chiave

- Un pacchetto aggiunge capacità a R e introduce una dipendenza.
- La scelta del pacchetto deve partire dal compito.
- Installare e usare un pacchetto sono operazioni differenti.
- `pacchetto::funzione()` rende esplicita la provenienza della funzione.
- I conflitti tra nomi richiedono una scelta consapevole, non soltanto la soppressione del messaggio.
- Una nuova dipendenza deve offrire un vantaggio concreto.
- `install.packages()` non appartiene normalmente al documento analitico.
- Il render in sessione pulita verifica che i pacchetti necessari siano dichiarati.
- L'AI deve rispettare l'insieme di strumenti scelto per il progetto.
- Versioni e sessione documentano l'ambiente, ma non convalidano il ragionamento scientifico.

Ambiente di sviluppo

Le informazioni sulla sessione e sui pacchetti caricati possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
Platform: aarch64-apple-darwin23
Running under: macOS Tahoe 26.5.2
```

12. Pacchetti: scegliere e dichiarare gli strumenti

```
Matrix products: default
BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; LAPACK

```

locale:

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8

```

time zone: Europe/Zagreb
tzcode source: internal

attached base packages:

```
[1] stats      graphics  grDevices  utils      datasets  methods    base

```

loaded via a namespace (and not attached):

```
[1] compiler_4.6.1 fastmap_1.2.0 cli_3.6.6      tools_4.6.1
[5] htmltools_0.5.9 ote1_0.2.0    yaml_2.3.12   rmarkdown_2.31
[9] knitr_1.51      jsonlite_2.0.0 xfun_0.60     digest_0.6.39
[13] rlang_1.3.0     evaluate_1.0.5

```

Parte III.

Statistica descrittiva ed EDA

Comprendere che cosa mostrano i dati prima di chiedere loro di sostenere una conclusione.

i In sintesi

Questa Parte introduce la statistica descrittiva e l'analisi esplorativa dei dati come un unico percorso. L'obiettivo non è produrre automaticamente tabelle e grafici, ma comprendere che cosa rappresenti il dataset analitico, come siano distribuiti i valori, quali relazioni siano visibili e quanto le conclusioni dipendano dalle decisioni prese durante la preparazione.

L'EDA non sostituisce la teoria, il disegno o l'inferenza. Li mette alla prova sul terreno concreto dei dati.

Dai dati raccolti ai dati comprensibili

Una raccolta di dati non diventa automaticamente evidenza scientifica quando viene importata in R.

Il file può contenere codici speciali, risposte duplicate, valori mancanti, errori di registrazione e variabili costruite secondo regole non ancora documentate. Può inoltre mescolare persone, prove o momenti di misura che non appartengono alla stessa unità di analisi.

Prima di calcolare una media o costruire un grafico dobbiamo quindi stabilire che cosa rappresenti una riga, quali osservazioni appartengano al campione analitico e come siano state ottenute le variabili centrali.

Questo passaggio non è una preparazione puramente tecnica. Determina quale popolazione venga descritta e quale significato possano avere le statistiche successive.

Il percorso della Parte può essere rappresentato così:

domanda → dataset analitico → distribuzioni → relazioni → interpretazione.

Ogni freccia contiene decisioni che devono rimanere visibili.

Esplorare non significa lasciare che i dati decidano

L'espressione "lasciare parlare i dati" può essere utile per ricordare che i risultati inattesi non devono essere ignorati. Può però suggerire erroneamente che i dati possiedano un significato indipendente dalle domande, dalle misure e dal disegno.

Un istogramma non spiega da solo perché una distribuzione sia asimmetrica. Un punto isolato non stabilisce se sia un errore. Una correlazione non sceglie la direzione causale. Ogni osservazione viene interpretata attraverso ciò che sappiamo del processo di raccolta.

L'EDA è quindi un dialogo tra aspettative ed evidenza. La teoria e il disegno indicano che cosa dovremmo osservare; i dati mostrano se queste aspettative siano compatibili con ciò che è stato effettivamente raccolto.

Quando emerge una discrepanza, le possibili risposte sono diverse. Potremmo avere trovato un errore, un limite della misura, una caratteristica rara della popolazione o un segnale che la domanda iniziale era troppo semplice. L'EDA non sceglie automaticamente tra queste spiegazioni. Le rende discutibili e controllabili.

La distribuzione come idea centrale

Il concetto più importante della Parte è quello di **distribuzione**.

Una distribuzione descrive quali valori compaiono e come le osservazioni si ripartiscono tra essi. Include la forma, la regione in cui i valori si concentrano, la loro dispersione, gli eventuali limiti della scala e le osservazioni lontane dalle altre.

Media, mediana, deviazione standard e intervallo interquartile sono riassunti della distribuzione. Non la sostituiscono.

Questa distinzione è essenziale perché la stessa media può descrivere dati molto differenti. Un gruppo può essere concentrato intorno al centro; un altro può contenere valori molto bassi e molto alti. Soltanto osservando anche la dispersione e la forma comprendiamo che cosa il centro rappresenti.

La deviazione standard riceverà particolare attenzione. Non verrà trattata come un numero prodotto da una formula, ma come una misura della distanza dei valori dalla media. Comprendere questa idea prepara la standardizzazione, il confronto con il modello normale e gran parte della modellizzazione statistica successiva.

Descrivere è già una scelta

Una statistica descrittiva può sembrare neutrale. In realtà, la sua utilità dipende dalla variabile e dalla domanda.

Per una categoria vogliamo sapere quali modalità compaiano e quanto siano frequenti. Per una variabile ordinale dobbiamo conservare l'ordine senza assumere automaticamente distanze uguali. Per una misura numerica osserviamo insieme forma, posizione e dispersione.

Anche la scelta di un grafico seleziona un aspetto dei dati. Una barra rende visibile una frequenza; un istogramma mostra una distribuzione; uno scatterplot conserva l'accoppiamento tra due misure. Una figura delle sole medie può facilitare un confronto, ma nascondere la sovrapposizione e la variabilità individuale.

La domanda da porre non è quindi:

Qual è il grafico corretto per questa variabile?

È piuttosto:

Quale caratteristica voglio rendere visibile, e quale informazione rischio di nascondere?

Dalla singola variabile alla distribuzione congiunta

Il percorso comincia con una variabile alla volta. Questo permette di comprendere valori possibili, mancanti, concentrazioni, dispersione ed eventuali anomalie prima di introdurre relazioni più complesse.

Quando passiamo a due variabili, l'oggetto cambia. La relazione dipende dalle coppie osservate nelle stesse unità di analisi. Uno scatterplot mostra questa distribuzione congiunta; la correlazione di Pearson ne riassume soltanto la componente lineare.

Il coefficiente deve quindi venire dopo il grafico. Una relazione può essere curva, dipendere da un sottogruppo o essere dominata da pochi casi. Un valore di correlazione, da solo, non permette di ricostruire queste caratteristiche.

La trattazione teorica di covarianza, correlazione e distribuzioni di probabilità appartiene al modulo *utet-prob*. In questa Parte quei concetti vengono usati per leggere dati reali e valutarne i limiti.

Il confine con la causalità

L'EDA può mostrare che due variabili cambiano insieme. Non può stabilire automaticamente che una produca il cambiamento dell'altra.

Una domanda causale richiede di definire un intervento, un'alternativa, un esito, un intervallo temporale e una popolazione. Richiede inoltre un disegno o assunzioni che rendano identificabile il confronto.

Per questo la causalità verrà richiamata soltanto come limite interpretativo. L'EDA può controllare la sequenza temporale, la composizione dei gruppi, le perdite e le incoerenze tra dati e disegno. Non può eliminare da sola il confondimento o scegliere automaticamente le variabili per un aggiustamento.

Il percorso completo di analisi causale appartiene al Companion. Qui impariamo soprattutto a riconoscere quando una frase descrive un'associazione e quando sta formulando una conclusione più forte di quanto i dati permettano.

Pulire senza rendere invisibili le decisioni

I dati grezzi non sono immediatamente utilizzabili. Ignorare codici speciali, duplicazioni e valori impossibili può produrre risultati fortemente distorti.

Non esiste però un algoritmo universale di pulizia. Un valore raro può essere un errore oppure una caratteristica autentica della popolazione. Una riga duplicata può derivare da un invio accidentale oppure rappresentare una misura ripetuta prevista dal disegno. Un'esclusione può migliorare la coerenza tecnica e contemporaneamente ridurre la rappresentatività del campione.

La preparazione deve quindi seguire una sequenza argomentata:

discrepanza → verifica → decisione → controllo dell'effetto.

Lo stesso principio verrà applicato agli outlier. I criteri statistici possono segnalare osservazioni inattese, ma non stabiliscono quali casi eliminare. Quando più decisioni sono ragionevoli, confronteremo i risultati mediante analisi di sensibilità.

Un richiamo limitato ai dati mancanti

I dati mancanti costituiscono un tema ampio, collegato al processo di raccolta, alla selezione e ai metodi di stima. Una trattazione adeguata supererebbe gli obiettivi introduttivi di questo modulo.

La Parte manterrà quindi soltanto alcuni principi essenziali. I codici speciali devono essere riconosciuti e trasformati in valori mancanti quando il codebook lo richiede. Ogni tabella e grafico deve rendere visibile quante osservazioni contribuiscano al risultato. L'esclusione dei casi incompleti non deve essere trattata come un'operazione neutrale.

Quando la mancata osservazione è consistente o differisce tra gruppi, sarà necessario ricorrere a una trattazione più avanzata.

EDA, modelli e inferenza

L'esplorazione precede la modellizzazione, ma non serve soltanto a controllare una lista di assunzioni.

Permette di comprendere quali caratteristiche un modello dovrà rappresentare: simmetria o asimmetria, limiti della scala, code, sottogruppi, relazioni lineari o curve, variabilità costante o differente tra regioni dei dati.

La distribuzione normale verrà richiamata con questa funzione. Non verrà ripetuta come capitolo di probabilità. Sarà usata come modello di riferimento per comprendere meglio la deviazione standard e confrontare una forma teorica con quella osservata.

Nel workflow bayesiano, questa logica verrà sviluppata attraverso i controlli predittivi: il modello genera dati simulati e il ricercatore li confronta con quelli osservati. L'EDA costituisce una preparazione a questo modo di ragionare, ma non deve essere confusa con il controllo formale di un modello già specificato.

Il ruolo di R e dell'AI

R rende visibile la sequenza che conduce dal dataset analitico ai risultati. In questa Parte verrà usato per calcolare riassunti, costruire grafici, identificare discrepanze e confrontare decisioni alternative.

La sintassi rimarrà in secondo piano. Ogni operazione dovrà poter essere descritta come:

domanda → input → rappresentazione o riassunto → controllo → interpretazione.

L'AI può generare il codice e suggerire controlli. Non conosce però automaticamente il significato delle variabili, la popolazione di interesse, le regole di scoring o la ragione per cui un'osservazione dovrebbe essere esclusa.

Le richieste rivolte all'assistente dovranno quindi specificare unità di analisi, valori possibili, trattamento dei mancanti, risultato desiderato e controlli da effettuare. Quando una risposta introduce una soglia, un filtro o una ricodifica, dovremo chiederne la giustificazione e misurarne l'effetto.

Mappa della Parte

Il percorso segue la progressiva costruzione di una descrizione controllabile dei dati.

Capitolo	Funzione nel percorso	Domanda guida
Capitolo 13	Definire il dataset analitico	Quale tabella risponde alla domanda?
Capitolo 14	Rendere visibili e giustificare le trasformazioni	Quali discrepanze richiedono un intervento?
Capitolo 15	Esplorare una variabile alla volta	Come sono ripartiti i valori?

Capitolo	Funzione nel percorso	Domanda guida
Capitolo 16	Valutare la fedeltà delle rappresentazioni	Che cosa rende visibile il grafico e che cosa nasconde?
Capitolo 17	Comprendere distribuzione, centro e dispersione	Dove stanno i valori e quanto sono distanti?
Capitolo 18	Confrontare i dati con un modello di forma	In quale modo la distribuzione differisce dalla normale?
Capitolo 19	Esplorare la distribuzione congiunta	Come variano insieme due misure?
Capitolo 20	Stabilire il limite interpretativo dell'EDA	Quando un'associazione non basta per parlare di effetto?
Capitolo 21	Diagnosticare osservazioni inattese	Perché un caso appare anomalo e quanto influenza il risultato?

La tabella non rappresenta una checklist rigida. L'EDA è iterativa. Un grafico può farci tornare alla pulizia; una correlazione può rivelare un sottogruppo; un outlier può richiedere di consultare nuovamente il protocollo o la misura.

Che cosa dovrebbe rimanere

Al termine della Parte, lo studente non dovrebbe ricordare soltanto formule e nomi di grafici.

Dovrebbe essere in grado di guardare una variabile e chiedersi quali valori siano possibili, quali siano osservati e quali manchino. Dovrebbe sapere che una media senza dispersione descrive poco, che una deviazione standard acquista significato soltanto nell'unità e nella forma della variabile, e che una correlazione senza scatterplot può nascondere la relazione che pretende di riassumere.

Dovrebbe inoltre riconoscere che pulizia, esclusioni e gestione degli outlier non sono procedure automatiche. Sono decisioni che modificano il dataset e devono essere motivate, documentate e sottoposte a controlli di sensibilità.

Soprattutto, dovrebbe riuscire a distinguere ciò che i dati mostrano direttamente da ciò che richiede un modello, un disegno o un'ipotesi causale ulteriore.

Questa distinzione prepara il passaggio alla modellizzazione statistica senza trasformare l'EDA in un rituale preliminare. Guardare i dati significa comprendere quale evidenza possediamo, quale abbiamo perso e quali domande possiamo ragionevolmente porre.

13. Preparare l'analisi esplorativa

In sintesi

Da sapere La Parte su R ha mostrato come organizzare file, dichiarare dipendenze e rendere riproducibile il codice. L'analisi esplorativa richiede ora un passaggio ulteriore: definire con precisione **quale tabella** verrà esplorata e perché essa sia adeguata alla domanda.

Da saper fare Specificare l'unità di analisi, delimitare il campione analitico, ricostruire la provenienza delle variabili, distinguere dati originali e dataset analitico, pianificare controlli e rappresentazioni prima di produrre risultati.

Introduzione

Nei capitoli precedenti abbiamo già discusso cartelle di progetto, percorsi relativi, conservazione dei dati originali, documenti Quarto e render da una sessione pulita. Non ripeteremo qui quelle istruzioni.

La nuova domanda è scientifica prima ancora che tecnica:

Quale insieme di osservazioni e variabili deve essere esplorato per rispondere alla domanda che ci interessa?

Un file originale può contenere più popolazioni, più momenti di misura, item singoli, punteggi aggregati, informazioni amministrative e variabili che non appartengono alla stessa analisi. Anche un file già “pulito” può quindi essere troppo ampio o organizzato a un livello diverso da quello richiesto.

L'EDA non inizia quando scegliamo un istogramma. Inizia quando definiamo il **dataset analitico**: la tabella costruita per una domanda specifica, con un'unità di analisi dichiarata, criteri di inclusione espliciti e variabili il cui significato è documentato.

Prerequisiti

Questo capitolo presuppone i principi discussi in Capitolo 7, Capitolo 8 e Capitolo 11. Per interpretare correttamente unità, variabili e campione sono inoltre rilevanti Capitolo 3 e Capitolo 4.

Panoramica del capitolo

Il capitolo chiarisce la differenza tra file sorgente, dati preparati e dataset analitico. Mostra poi come definire l'unità di analisi, il campione e la provenienza delle variabili. L'ultima parte trasforma queste decisioni in un piano di esplorazione e in una richiesta controllabile da rivolgere all'AI.

Preparazione del notebook

Apri il documento Quarto destinato all'EDA e inserisci all'inizio una breve descrizione della domanda, dell'unità di analisi e del dataset utilizzato. Non serve creare nuove cartelle o duplicare file se il progetto è già organizzato secondo i criteri della Parte precedente.

13.1. Il dataset analitico non coincide necessariamente con il file

È utile distinguere tre oggetti.

Il **file sorgente** è ciò che è stato ricevuto o esportato dal sistema di raccolta. Deve essere conservato senza modifiche manuali.

I **dati preparati** derivano da operazioni necessarie per rendere coerenti nomi, codici, tipi e valori mancanti. Le trasformazioni devono essere documentate e ripetibili.

Il **dataset analitico** è la tabella effettivamente usata per affrontare una domanda. Può coincidere con i dati preparati, ma può anche contenerne soltanto una parte oppure avere una struttura differente.

Supponiamo che il file sullo stress e sul sonno contenga tre rilevazioni per ogni studente. Se la domanda riguarda le differenze individuali alla prima rilevazione, il dataset analitico avrà una riga per studente e userà soltanto quel momento. Se la domanda riguarda il cambiamento nel tempo, le tre righe devono rimanere e l'unità osservata diventa la combinazione di persona e momento.

Non esiste quindi un dataset “pulito” valido per ogni analisi. Esiste una versione adeguata a uno scopo dichiarato.

La preparazione dei dati dipende dalla domanda

La stessa operazione può essere necessaria per un'analisi e inappropriata per un'altra. Aggregare tre rilevazioni in una media può essere utile per descrivere un livello medio individuale, ma distrugge l'informazione temporale necessaria a studiare il cambiamento.

13.2. L'unità di analisi viene prima delle statistiche

La prima frase del piano di analisi dovrebbe stabilire che cosa rappresenta una riga.

Una riga può rappresentare una persona, una prova, una sessione, una coppia, una classe oppure una misurazione effettuata in un determinato momento. Questa scelta determina quali osservazioni siano indipendenti, quali variabili possano essere confrontate e quale significato abbiano numerosità, medie e grafici.

Nel progetto su stress e sonno potremmo scrivere:

Nel dataset analitico, ogni riga rappresenta uno studente osservato in un'unica rilevazione.

Oppure:

Ogni riga rappresenta una misurazione giornaliera; lo stesso studente compare in più righe ed è identificato dalla variabile `id`.

Le due tabelle possono contenere colonne con gli stessi nomi, ma richiedono analisi differenti.

Prima di procedere dovremmo quindi verificare che gli identificatori e il numero di righe siano compatibili con l'unità dichiarata. Se non lo sono, non bisogna correggere automaticamente la tabella: occorre tornare al disegno e ricostruirne la struttura.

13.3. Il campione analitico è il risultato di decisioni

Il campione raccolto e il campione effettivamente analizzato possono non coincidere. Alcune persone possono non aver completato la procedura, alcune osservazioni possono essere tecnicamente non valide e alcune variabili possono essere disponibili soltanto per una parte dei partecipanti.

Ogni criterio di inclusione o esclusione modifica la popolazione descritta dai risultati. Per questo non basta applicare un filtro; bisogna poter spiegare perché venga applicato e quale effetto produca.

Nel report è utile conservare una breve sequenza numerica:

osservazioni disponibili → osservazioni escluse con motivazione → osservazioni usate.

Se 150 studenti hanno iniziato lo studio, 138 hanno completato il questionario e 124 possiedono entrambe le misure necessarie per un grafico, i tre numeri rispondono a domande differenti. Non devono essere sostituiti da una generica frase come “sono stati rimossi i dati mancanti”.

L'EDA dovrebbe mostrare anche dove si verificano le perdite. Se i mancanti sono più frequenti tra gli studenti con livelli elevati di stress, il dataset analitico può rappresentare un gruppo diverso da quello inizialmente reclutato.

13.4. Le variabili hanno una provenienza

Ogni variabile usata nell'EDA dovrebbe poter essere ricondotta alla sua origine.

stress potrebbe essere un item singolo, la somma di dieci risposte oppure il risultato di un modello psicometrico. `qualita_sonno` potrebbe essere una valutazione soggettiva da 1 a 10 o un punteggio composito. Due colonne con nomi intuitivi possono quindi richiedere interpretazioni molto differenti.

Per ogni variabile centrale dobbiamo sapere:

- da quale osservazione o colonna originale deriva;
- quali trasformazioni sono state applicate;
- quale intervallo di valori è possibile;
- che cosa significa un valore mancante;
- quale livello di misura è ragionevole attribuirle.

Questa lista rimane utile perché funziona come una scheda minima del significato della variabile, non come un catalogo di operazioni tecniche.

Una trasformazione semplice può essere documentata direttamente nel codice. Una trasformazione concettualmente importante, come la costruzione di un punteggio composito, richiede anche una spiegazione nel testo.

⚠ Un nome leggibile non sostituisce la documentazione

Rinominare Q12 come `stress` migliora la leggibilità del codice, ma non dimostra che l'item rappresenti adeguatamente lo stress. La rinomina deve essere coerente con questionario, codebook e definizione del costrutto.

13.5. Una scheda minima dell'analisi

Prima dei primi grafici conviene scrivere una breve scheda. Non è un documento burocratico: è un contratto tra domanda, dati e operazioni.

Elemento	Esempio
Domanda	Come sono distribuiti stress e qualità del sonno e come variano insieme nel campione?
Unità di analisi	Uno studente per riga
Campione analitico	Studenti con identificatore valido; i mancanti vengono descritti separatamente per ciascuna variabile
Variabili centrali	<code>stress</code> , <code>qualita_sonno</code> , <code>anno</code>
Provenienza	Punteggi costruiti secondo le regole del questionario
Strutture da conservare	Identificatore e anno di corso
Prime verifiche	Numerosità, duplicati, tipi, valori possibili e mancanti
Prime rappresentazioni	Distribuzioni separate, confronto per anno e diagramma di dispersione

La scheda può essere modificata quando emergono problemi o nuove domande. Ogni modifica sostanziale dovrebbe però essere visibile, perché rappresenta un cambiamento nel problema affrontato.

13.6. Pianificare l'EDA senza predeterminare i risultati

L'analisi esplorativa è aperta alle caratteristiche inattese dei dati, ma non deve essere priva di struttura.

Un piano iniziale può stabilire che osserveremo la completezza delle variabili, le distribuzioni marginali, le differenze tra gruppi definiti dal disegno e le relazioni tra le misure centrali. Non sappiamo in anticipo che cosa emergerà, ma sappiamo perché ciascuna rappresentazione viene prodotta.

Il ciclo può essere descritto così:

domanda → rappresentazione → pattern osservato → nuova domanda → controllo.

Se un istogramma suggerisce due gruppi distinti, possiamo chiederci se corrispondano a diverse condizioni o a un errore di codifica. Se un punto appare isolato, possiamo tornare all'osservazione

originale e verificarne la provenienza. Se una relazione cambia tra anni di corso, possiamo produrre rappresentazioni separate.

L'esplorazione diventa problematica quando ogni pattern viene trattato come una scoperta confermata. I risultati suggeriti dai dati devono essere distinti dalle domande formulate prima di osservarli.

13.7. Un registro delle decisioni

Durante l'EDA emergono spesso decisioni che non erano previste: una categoria è scritta in due modi, una scala contiene un codice speciale, una rilevazione appare duplicata o un grafico rivela un valore impossibile.

È utile mantenere un breve registro nel documento o in un file associato. Per ogni decisione dovremmo annotare che cosa è stato osservato, quale spiegazione è stata verificata, quale intervento è stato effettuato e come è cambiato il dataset.

Per esempio:

Tre valori pari a 999 nella variabile `stress` sono stati ricodificati come mancanti perché il codebook identifica 999 come codice di non risposta. Il numero di valori osservati è passato da 138 a 135.

Questa frase documenta evidenza, fonte della decisione, trasformazione ed effetto. È molto più informativa di “sono stati puliti i dati”.

Il registro non deve diventare lungo se le decisioni sono poche. Deve però impedire che trasformazioni importanti rimangano nascoste tra le righe di codice.

13.8. Quando fermarsi e tornare indietro

L'EDA non deve sempre proseguire fino al grafico finale. Alcune discrepanze richiedono di interrompere l'analisi.

Se il numero delle righe non corrisponde al disegno, se un identificatore dovrebbe essere unico ma compare più volte, se una variabile centrale è assente o se i suoi valori non corrispondono alla scala prevista, la priorità è ricostruire il problema.

In questi casi, aggiungere codice per “sistemare” la tabella può rendere il risultato più ordinato ma meno affidabile.

Un buon workflow ammette il ritorno a passaggi precedenti:

disegno ↔ documentazione ↔ preparazione ↔ EDA.

Questa reversibilità distingue un'analisi controllata da una sequenza lineare di comandi applicati fino a ottenere un output.

13.9. Chiedere all'AI un piano, non soltanto codice

In questa fase, una richiesta utile all'AI non dovrebbe cominciare da “scrivi una pipeline”. È preferibile chiedere prima una rappresentazione del problema.

 Un prompt per preparare l'EDA

Non scrivere ancora codice. Aiutami a definire il dataset analitico per questa domanda: voglio descrivere stress accademico e qualità del sonno e studiarne l'associazione in un campione di studenti.

Il file contiene una riga per studente, un identificatore, dieci item di stress, un punteggio di sonno, anno di corso e alcuni valori mancanti. Elenca le informazioni che devo verificare su unità di analisi, costruzione del punteggio di stress, criteri di inclusione, valori mancanti e intervalli plausibili.

Non inventare regole di scoring o soglie. Segnala chiaramente quali informazioni devono provenire dal codebook o dal protocollo dello studio. Proponi infine una sequenza minima di controlli e grafici, spiegando a quale domanda risponde ciascuno.

Dopo avere verificato il piano, possiamo chiedere il codice per un passaggio alla volta. Questa separazione riduce il rischio che l'assistente introduca decisioni non dichiarate mentre costruisce la sintassi.

13.10. Un percorso minimo per il report

Il report EDA può seguire una struttura semplice.

Dopo la domanda e la descrizione del dataset analitico, documentiamo numerosità, unità e mancanti. Esaminiamo poi separatamente le variabili centrali, confrontiamo eventuali gruppi definiti dal disegno e infine osserviamo le relazioni tra variabili.

Il percorso non deve diventare una successione meccanica di grafici. Ogni risultato dovrebbe condurre a una frase che distingua:

ciò che è visibile nei dati;

l'ipotesi che potrebbe spiegarlo;

il controllo necessario prima di accettare quell'ipotesi.

Questa distinzione prepara il passaggio dall'esplorazione alla modellizzazione senza confondere osservazioni e spiegazioni.

Riflessioni conclusive

La struttura tecnica del progetto è già stata definita nella Parte su R. Il compito di questo capitolo è trasformarla in una struttura analitica.

Il dataset da esplorare non è semplicemente il file disponibile. È una tabella costruita per una domanda, con un'unità di analisi, un campione e variabili documentate. Le esclusioni, le aggregazioni e la costruzione dei punteggi determinano ciò che i grafici e le statistiche potranno mostrare.

Prima dell'EDA dobbiamo quindi formulare una scheda minima dell'analisi e rendere visibile la provenienza dei dati. Durante l'esplorazione dobbiamo registrare le decisioni e accettare la possibilità di tornare alla documentazione o alla preparazione quando emerge una discrepanza.

L'AI può aiutare a organizzare il piano e successivamente tradurlo in codice. Non deve inventare l'unità di analisi, le regole di scoring o i criteri di esclusione.

Nel capitolo successivo affronteremo in modo operativo la qualità dei dati e le trasformazioni necessarie prima di descriverne distribuzioni e relazioni.

Esercizi

1. Un file contiene tre rilevazioni per ciascuno studente. Formula due domande che richiedano dataset analitici differenti e descrivi che cosa rappresenterebbe una riga in ciascun caso.
2. Distingui file sorgente, dati preparati e dataset analitico per uno studio che raccoglie dieci item di stress e costruisce un punteggio totale.
3. Il campione iniziale comprende 180 persone, ma un grafico ne rappresenta 127. Quali quantità e motivazioni devono essere documentate prima di interpretarlo?
4. Perché rinominare Q12 come stress non è sufficiente a stabilire il significato della variabile?
5. Scrivi una scheda minima per un'EDA della relazione tra ore di sonno e benessere, specificando domanda, unità, campione, variabili, mancanti e prime rappresentazioni.
6. L'AI propone di calcolare la media dei dieci item di stress e di escludere chi possiede almeno un item mancante. Quali informazioni devi recuperare prima di accettare la proposta?
7. Un istogramma mostra due gruppi distinti. Formula due possibili spiegazioni e, per ciascuna, un controllo da eseguire prima di interpretare il pattern.
8. Trasforma la richiesta «fammi l'EDA del dataset» in un prompt che chieda prima un piano e vieti all'AI di inventare soglie, regole di scoring o esclusioni.

Soluzioni

1. Una domanda sul livello medio individuale può richiedere una riga per studente, dopo una sintesi delle rilevazioni giustificata. Una domanda sul cambiamento richiede una riga per combinazione di studente e momento, conservando l'identificatore ripetuto.
2. Il file sorgente contiene le risposte come esportate. I dati preparati contengono nomi e codici coerenti e mancanti riconosciuti. Il dataset analitico contiene gli item e il punteggio costruito secondo la regola pertinente alla domanda, insieme alle osservazioni incluse.
3. Devono essere documentati il numero iniziale, le esclusioni applicate, i mancanti nelle variabili rappresentate e il numero finale. Occorre inoltre verificare se le esclusioni cambino la composizione del campione.
4. Il nuovo nome migliora la leggibilità, ma il significato dipende dal contenuto dell'item, dal periodo di riferimento, dalla scala di risposta e dalla validità dell'interpretazione.
5. La scheda deve dichiarare chi o che cosa rappresenta una riga, quali persone entrano, come vengono misurate le due variabili, come saranno descritti i mancanti e quali grafici rispondono alle domande iniziali.
6. Servono la regola ufficiale di scoring, l'eventuale presenza di item invertiti, il numero minimo di risposte richieste, il significato dei mancanti e l'effetto dell'esclusione sulla numerosità e sul campione.

7. I gruppi potrebbero corrispondere a condizioni reali oppure a codifiche differenti della stessa misura. Nel primo caso si controlla una variabile di gruppo; nel secondo si esaminano valori originali, tipi e procedure di importazione.
8. Il prompt deve descrivere domanda, struttura nota del file e variabili centrali; chiedere le informazioni ancora necessarie, una sequenza motivata di controlli e grafici, e vietare trasformazioni non sostenute da protocollo o codebook.

i Punti chiave

- La struttura tecnica del progetto è una premessa già acquisita.
- Il dataset analitico è definito rispetto a una domanda.
- L'unità di analisi stabilisce che cosa rappresenta una riga.
- Il campione analitico deve essere ricostruito attraverso quantità e motivazioni.
- Ogni variabile centrale deve avere una provenienza documentata.
- Un piano EDA organizza le domande senza predeterminare i risultati.
- Le decisioni emerse durante l'esplorazione devono lasciare una traccia.
- Alcune discrepanze richiedono di interrompere l'analisi e tornare alla documentazione.
- L'AI dovrebbe aiutare prima a definire il piano e soltanto dopo a scrivere il codice.
- Grafici e statistiche devono essere collegati alla domanda e al dataset che li ha prodotti.

i Ambiente di sviluppo

Il capitolo non richiede pacchetti aggiuntivi. Le informazioni sulla sessione possono essere ottenute con:

```
sessionInfo()
```


14. Pulire i dati senza nascondere le decisioni

i In sintesi

Da sapere I dati grezzi non sono normalmente pronti per l'analisi. Codici speciali, duplicazioni, errori di registrazione, categorie incoerenti e valori mancanti possono deformare distribuzioni, associazioni e composizione del campione. La pulizia è quindi necessaria, ma non è un procedimento automatico: ogni intervento richiede una giustificazione legata al disegno, al codebook e alla provenienza dei dati.

Da saper fare Distinguere un'anomalia da un errore confermato; diagnosticare prima di correggere; quantificare l'effetto di esclusioni e ricodifiche; confrontare dati grezzi e dati preparati; documentare le decisioni; chiedere all'AI controlli e proposte senza autorizzarla a modificare automaticamente il dataset.

Introduzione

Il file prodotto da un questionario, da un laboratorio o da una piattaforma online è un punto di partenza, non il dataset finale.

Una colonna può contenere 999 per indicare una risposta mancante. La stessa categoria può essere registrata come F, f e femmina. Una persona può comparire due volte perché ha riaperto il questionario. Un tempo di risposta molto breve può derivare da una prova anticipata, da un errore tecnico oppure da una risposta realmente eccezionale.

Se questi problemi vengono ignorati, le statistiche descrittive non rappresentano fedelmente né le osservazioni raccolte né la popolazione a cui vorremmo riferirci. Una media può essere trascinata da codici speciali trattati come numeri reali; una relazione può dipendere da poche righe duplicate; l'eliminazione automatica dei casi incompleti può lasciare nel campione soprattutto i partecipanti più facili da misurare.

La pulizia è dunque indispensabile. Tuttavia, non esiste un comando capace di distinguere automaticamente ciò che è errato da ciò che è raro, ciò che manca per caso da ciò che manca in modo sistematico, o una duplicazione accidentale da una misura ripetuta prevista dal disegno.

La domanda centrale non è:

Come posso rendere il dataset ordinato?

È piuttosto:

Quale trasformazione è giustificata dall'evidenza disponibile, e come modifica ciò che il dataset rappresenta?

 Prerequisiti

Il capitolo prosegue il lavoro iniziato in Capitolo 13. Presuppone inoltre i principi di progettazione, misurazione e riproducibilità discussi in Capitolo 3, Capitolo 4 e Capitolo 11.

Panoramica del capitolo

Partiremo dalla distinzione tra dato insolito ed errore confermato. Vedremo poi come codici mancanti, duplicazioni, categorie incoerenti ed esclusioni possano alterare i risultati. Un piccolo esempio in R mostrerà una procedura basata su diagnosi, decisione, trasformazione e validazione. Concluderemo collegando la pulizia ai gradi di libertà del ricercatore e alla crisi della replicabilità.

 Preparazione del notebook

Gli esempi usano `dplyr` e un dataset didattico costruito nel documento. Le anomalie sono intenzionali. Alcune possono essere risolte perché il testo fornisce il codebook o una verifica della fonte; altre devono rimanere segnalate finché non disponiamo di evidenza sufficiente.

```
library(dplyr)

dati_grezzi <- data.frame(
  id = c(
    "S01", "S02", "S03", "S03",
    "S04", "S05", "S06", "S07"
  ),
  data_compilazione = as.Date(c(
    "2026-03-01", "2026-03-01",
    "2026-03-02", "2026-03-04",
    "2026-03-03", "2026-03-03",
    "2026-03-04", "2026-03-05"
  )),
  anno = c(
    "primo", "primo", "secondo", "secondo",
    "terzo", "primo", "terzo", "terzo"
  ),
  genere = c(
    "F", "femmina", "M", "M",
    "F", "non indicato", "f", "maschio"
  ),
  stress = c(
    7, 999, 5, 6,
    11, 8, NA, 3
  ),
  sonno_ore = c(
    6.5, 7.2, 5.8, 6.0,
    5.1, -99, 8.0, 28
  )
)
```

14.1. I dati grezzi possono produrre risultati plausibili e sbagliati

Il pericolo più evidente è un errore che interrompe il codice. Più insidioso è un dato problematico che R riesce comunque a elaborare.

Se calcoliamo direttamente la media di `stress`, il codice 999 viene trattato come un punteggio reale:

```
mean(
  dati_grezzi$stress,
  na.rm = TRUE
)
```

```
[1] 148.4286
```

R non conosce il questionario. Dal suo punto di vista, 999 è un numero come gli altri. Il risultato è tecnicamente corretto rispetto ai valori presenti nella colonna, ma non descrive lo stress degli studenti.

Lo stesso problema si verifica con -99 nelle ore di sonno. Una statistica può quindi essere calcolata senza messaggi di errore e risultare profondamente distorta.

Questo esempio chiarisce perché l'ispezione dei dati non sia una formalità. Prima di descrivere una variabile dobbiamo sapere quali valori sono possibili, quali codici possiedono un significato speciale e come la colonna è stata prodotta.

14.2. Un'anomalia è una domanda, non una correzione

Un valore fuori dall'intervallo previsto segnala una discrepanza. Non ne stabilisce la causa.

Il punteggio `stress = 11` è incompatibile con una scala da 1 a 10. Potrebbe derivare da un errore di trascrizione, da una regola di scoring diversa da quella documentata oppure dall'importazione della colonna sbagliata. Il valore `sonno_ore = 28` sembra implausibile come media giornaliera, ma non sappiamo ancora se rappresenti una risposta errata, una misura settimanale oppure un problema di unità.

La prima operazione deve rendere visibili i casi:

```
dati_grezzi |>
  filter(
    stress < 1 |
    stress > 10 |
    sonno_ore < 0 |
    sonno_ore > 16
  )
```

	id	data_compilazione	anno	genere	stress	sonno_ore
1	S02	2026-03-01	primo	femmina	999	7.2
2	S04	2026-03-03	terzo	F	11	5.1
3	S05	2026-03-03	primo	non indicato	8	-99.0
4	S07	2026-03-05	terzo	maschio	3	28.0

Il filtro non “pulisce” nulla. Produce una lista di osservazioni che richiedono una verifica.

! Segnalare prima di modificare

Un valore insolito non deve essere eliminato, troncato o sostituito soltanto perché disturba il riepilogo. L'intervento è giustificato quando possiamo collegarlo a una regola del codebook, a una verifica del dato originale o a un criterio definito dal disegno.

La distinzione fondamentale è quindi tra **anomalia osservata** ed **errore confermato**. L'anomalia nasce dal confronto con un'aspettativa; l'errore richiede evidenza sulla causa.

14.3. La pulizia è un processo di inferenza

Ogni decisione di pulizia contiene un ragionamento.

Quando troviamo due righe con lo stesso identificatore, osserviamo una duplicazione. Per stabilire se sia un problema dobbiamo sapere che cosa rappresenta una riga. In uno studio longitudinale, identificatori ripetuti sono necessari. In un questionario trasversale con una sola compilazione prevista, possono indicare un invio ripetuto.

Quando troviamo 999, osserviamo un valore estremo. Soltanto il codebook può dirci che significa “nessuna risposta”. Quando troviamo categorie scritte in modi diversi, dobbiamo verificare che siano davvero etichette equivalenti e non categorie che il ricercatore sta unificando per comodità.

La sequenza appropriata è:

discrepanza → ipotesi sulla causa → evidenza → decisione → controllo dell'effetto.

Chiamare tutto questo “pulizia” può farlo apparire come un lavoro di manutenzione. In realtà, è una forma di inferenza sul processo che ha generato i dati.

14.4. Correzioni sostenute dal codebook

Supponiamo che il codebook specifichi che 999 nella scala di stress e -99 nelle ore di sonno indicano risposte mancanti. In questo caso la ricodifica è giustificata:

```
dati_preparati <- dati_grezzi |>
  mutate(
    stress = na_if(stress, 999),
    sonno_ore = na_if(sonno_ore, -99)
  )
```

Non stiamo eliminando osservazioni. Stiamo correggendo il significato informatico di due codici: da numeri apparentemente osservati a valori mancanti.

Dopo la trasformazione dobbiamo verificare il risultato:

```
dati_preparati |>
  summarise(
    n_stress_mancante =
      sum(is.na(stress)),
    n_sonno_mancante =
      sum(is.na(sonno_ore))
  )
```

```
      n_stress_mancante n_sonno_mancante
1                    2                1
```

Il controllo mostra quante celle sono state ricodificate. Nel registro delle decisioni dovremmo indicare la fonte della regola, non soltanto il comando usato.

14.5. Categorie incoerenti e perdita di informazione

Nel dataset, F, f e femmina sembrano indicare la stessa categoria; analogamente, M e maschio sembrano equivalenti. Poiché questa corrispondenza è confermata dal questionario, possiamo uniformare le etichette:

```
dati_preparati <- dati_preparati |>
  mutate(
    genere = case_when(
      genere %in%
        c("F", "f", "femmina") ~
          "femmina",
      genere %in%
        c("M", "m", "maschio") ~
          "maschio",
      TRUE ~ genere
    )
  )
```

La clausola finale conserva le categorie che non abbiamo autorizzazione a modificare. In particolare, non indicato non viene trasformato automaticamente in altro, perché le due espressioni possono avere significati differenti.

```
dati_preparati |>
  count(genere)
```

```
      genere n
1    femmina 4
2    maschio 3
3 non indicato 1
```

Una ricodifica può sembrare innocua, ma modifica la composizione delle categorie. Il controllo dopo la trasformazione deve quindi mostrare non soltanto che il codice ha funzionato, ma anche quali frequenze ha prodotto.

14.6. Duplicazioni e unità di analisi

Nel nostro esempio S03 compare due volte. Il protocollo stabilisce che ogni studente debba comparire una sola volta e che, in caso di invio ripetuto accidentale, venga conservata la compilazione più recente.

Questa regola permette di applicare una trasformazione esplicita:

```
dati_preparati <- dati_preparati |>
  arrange(
    id,
    desc(data_compilazione)
  ) |>
  distinct(
    id,
    .keep_all = TRUE
  )
```

L'ordinamento decrescente colloca per prima la compilazione più recente; `distinct()` conserva quella riga.

Il codice non rende la regola automaticamente corretta. La sua giustificazione proviene dal protocollo. Con una domanda diversa potremmo conservare entrambe le compilazioni, confrontarle oppure escludere il partecipante. Queste alternative produrrebbero dataset differenti.

Dopo la decisione controlliamo che l'unità di analisi prevista sia stata ottenuta:

```
dati_preparati |>
  summarise(
    n_righe = n(),
    n_id = n_distinct(id),
    duplicazioni =
      n() - n_distinct(id)
  )
```

	n_righe	n_id	duplicazioni
1	7	7	0

14.7. I valori mancanti possono cambiare la popolazione osservata

Dopo avere ricodificato i codici speciali, alcune righe non possiedono entrambe le misure. Una soluzione rapida consiste nel conservare soltanto i casi completi:

```
dati_completi <- dati_preparati |>
  filter(
    !is.na(stress),
    !is.na(sonno_ore)
  )
```

Il codice è semplice. La decisione non lo è.

Se la probabilità di avere dati completi differisce tra gruppi, il nuovo campione può rappresentare una popolazione diversa. Nel dataset didattico possiamo controllare la completezza per anno:

```
dati_preparati |>
  mutate(
    completo =
      complete.cases(
        stress,
        sonno_ore
      )
  ) |>
  count(
    anno,
    completo
  )
```

	anno	completo	n
1	primo	FALSE	2
2	primo	TRUE	1
3	secondo	TRUE	1
4	terzo	FALSE	1
5	terzo	TRUE	2

Se gli studenti del primo anno hanno più valori mancanti, l'analisi dei soli casi completi li rappresenterà meno. Le stime non saranno distorte soltanto perché il campione è più piccolo; potranno esserlo perché il meccanismo che determina l'assenza dei dati è collegato alle caratteristiche che vogliamo studiare.

La completezza non è neutralità

L'eliminazione dei casi incompleti non “toglie soltanto i mancanti”. Separa le persone che hanno fornito tutte le informazioni da quelle che non le hanno fornite. Prima di procedere dobbiamo chiederci se questa separazione sia plausibilmente irrilevante per la domanda.

In un capitolo introduttivo non è necessario scegliere subito una tecnica avanzata per i dati mancanti. È necessario evitare che l'esclusione avvenga in modo silenzioso e descrivere come cambia il campione.

14.8. Valori estremi: errore, rarità o parte della popolazione?

La pulizia viene talvolta descritta come eliminazione degli *outlier*. Questa formulazione è pericolosa perché confonde una posizione statistica con un errore.

Una persona può avere un punteggio molto lontano dagli altri e appartenere comunque alla popolazione di interesse. Eliminandola, rendiamo il campione più omogeneo ma forse meno rappresentativo. In psicologia clinica, del lavoro o dello sviluppo, proprio i casi rari possono essere sostantivamente importanti.

Un valore estremo dovrebbe quindi attivare tre domande narrative. È possibile secondo lo strumento di misura? È coerente con le altre informazioni sulla stessa osservazione? La conclusione cambia se lo includiamo oppure lo escludiamo?

L'ultima domanda introduce l'**analisi di sensibilità**. Quando più decisioni sono ragionevoli, possiamo mostrare come cambiano le descrizioni sotto alternative trasparenti, invece di scegliere in segreto quella che produce il risultato preferito.

Nel nostro esempio, `stress = 11` e `sonno_ore = 28` rimangono segnalati finché non controlliamo la fonte. Non devono entrare nelle statistiche come se fossero valori validi, ma non devono neppure essere corretti per intuizione.

14.9. Dalla verifica della fonte alla correzione

Supponiamo di tornare ai questionari originali. Verifichiamo che per S04 il valore corretto dello stress sia 1, mentre per S07 le ore di sonno siano 8, non 28.

A questo punto la correzione può essere espressa nel codice:

```
dati_preparati <- dati_preparati |>
  mutate(
    stress = if_else(
      id == "S04" &
        stress == 11,
      1,
      stress
    ),
    sonno_ore = if_else(
      id == "S07" &
        sonno_ore == 28,
      8,
      sonno_ore
    )
  )
```

La condizione identifica in modo preciso le celle corrette. Nel registro scriveremo che i valori sono stati verificati sulla fonte originale.

Una correzione manuale nel file avrebbe potuto produrre lo stesso dataset, ma avrebbe cancellato la storia della decisione. Il codice conserva invece la relazione tra valore osservato, evidenza e intervento.

14.10. Validare significa confrontare prima e dopo

La pulizia non termina quando il codice viene eseguito. Dobbiamo verificare che il dataset risultante rispetti le aspettative e che le trasformazioni non abbiano prodotto conseguenze inattese.


```

dati_preparati |>
  summarise(
    n_righe = n(),
    n_id = n_distinct(id),
    stress_fuori_intervallo =
      sum(
        stress < 1 |
        stress > 10,
        na.rm = TRUE
      ),
    sonno_fuori_intervallo =
      sum(
        sonno_ore < 0 |
        sonno_ore > 16,
        na.rm = TRUE
      ),
    stress_mancante =
      sum(is.na(stress)),
    sonno_mancante =
      sum(is.na(sonno_ore))
  )

```

```

  n_righe n_id stress_fuori_intervallo sonno_fuori_intervallo stress_mancante
1       7    7                      0                      0                2
  sonno_mancante
1                1

```

Questo controllo risponde a domande locali. Per valutare l'effetto complessivo dobbiamo confrontare anche numerosità e composizione:

```

data.frame(
  versione = c(
    "grezzi",
    "preparati"
  ),
  n_righe = c(
    nrow(dati_grezzi),
    nrow(dati_preparati)
  ),
  n_id = c(
    dplyr::n_distinct(
      dati_grezzi$id
    ),
    dplyr::n_distinct(
      dati_preparati$id
    )
  )
)

```

```

  versione n_righe n_id

```

14. Pulire i dati senza nascondere le decisioni

1	grezzi	8	7
2	preparati	7	7

In un progetto reale confronteremmo anche distribuzioni, frequenze dei gruppi e percentuali di dati mancanti. La domanda è se il cambiamento osservato corrisponda esattamente alle decisioni documentate.

14.11. Pulizia, flessibilità analitica e crisi della replicabilità

La crisi della replicabilità ha mostrato che risultati scientifici fragili non derivano soltanto da errori statistici finali. Possono nascere lungo l'intero percorso che conduce dai dati grezzi al risultato pubblicato.

La pulizia offre molti **gradi di libertà del ricercatore**. Possiamo scegliere quale duplicato conservare, quale soglia definisca un valore anomalo, quanti item mancanti siano accettabili, quali partecipanti escludere e come costruire un punteggio. Molte alternative possono apparire ragionevoli considerate singolarmente.

Il problema emerge quando le decisioni vengono prese dopo avere osservato il loro effetto sul risultato e soltanto il percorso finale viene riportato. Non è necessaria la frode. È sufficiente una successione di scelte flessibili, influenzate dalle aspettative, perché l'analisi finisca per favorire un pattern particolare.

Questo problema è discusso nel manuale e nel Companion nel quadro della crisi della replicabilità e dei *researcher degrees of freedom*. Qui ne ricaviamo una conseguenza operativa: i criteri di pulizia dovrebbero essere definiti prima di osservare gli esiti principali quando ciò è possibile; le decisioni emerse successivamente devono essere registrate; le alternative ragionevoli dovrebbero essere confrontate con analisi di sensibilità.

La riproducibilità del codice è necessaria ma non sufficiente. Un criterio arbitrario può essere applicato in modo perfettamente riproducibile. Occorre rendere riproducibile anche la **giustificazione** della scelta.

14.12. Un registro delle decisioni

Il registro può essere breve, purché colleghi ogni intervento alla sua evidenza.

Problema osservato	Evidenza utilizzata	Decisione	Effetto verificato
999 in stress	Codebook	Ricodificato come NA	Aumenta di uno il conteggio dei mancanti
Due righe per S03	Protocollo e date	Conservata la compilazione più recente	Una riga per identificatore
stress = 11 per S04	Questionario originale	Corretto in 1	Nessun valore fuori intervallo
sonno_ore = 28 per S07	Questionario originale	Corretto in 8	Nessun valore fuori intervallo

Questa tabella non sostituisce il codice. Il codice mostra *come* è avvenuta la trasformazione; il registro spiega *perché*.

14.13. Usare l'AI come assistente alla diagnosi

Una richiesta generica come «pulisci il dataset» delega all'assistente decisioni che non può giustificare. L'AI potrebbe eliminare duplicati, convertire valori fuori intervallo in mancanti o unire categorie basandosi soltanto sulla loro apparenza.

È preferibile separare diagnosi e intervento.

Un prompt per diagnosticare senza modificare

Ho un data frame chiamato `dati_grezzi`, con una riga prevista per studente. Le variabili `stress` e `sonno_ore` dovrebbero variare rispettivamente da 1 a 10 e da 0 a 16. Il codebook indica 999 come mancante per `stress` e -99 come mancante per `sonno_ore`.

Non modificare il dataset. Scrivi codice R semplice che segnali identificatori ripetuti, codici mancanti speciali, valori fuori intervallo e grafie differenti delle categorie. Per ogni controllo mostra le righe coinvolte e il loro numero. Distingui ciò che può essere ricodificato usando il codebook da ciò che richiede una verifica della fonte.

Dopo avere verificato i problemi, una seconda richiesta può chiedere trasformazioni specifiche. Il prompt dovrebbe indicare quale evidenza autorizza ciascuna modifica, chiedere di conservare `dati_grezzi` e creare un nuovo oggetto, e richiedere un confronto prima-dopo.

Quando l'AI propone di escludere osservazioni, la domanda decisiva è:

Come cambia la composizione del campione, e quali gruppi vengono rappresentati meno?

Riflessioni conclusive

I dati grezzi non sono immediatamente utilizzabili perché conservano tracce del processo di raccolta: codici speciali, errori, duplicazioni, mancate risposte e differenze di formato. Ignorare questi aspetti può produrre statistiche fortemente distorte. Eliminarli in modo automatico può produrre un problema diverso: un campione più ordinato ma meno rappresentativo.

La pulizia richiede quindi un equilibrio. Dobbiamo intervenire abbastanza da rendere i dati coerenti con il disegno e la misurazione, ma non così liberamente da trasformarli nella forma che preferiamo.

Ogni anomalia deve essere prima resa visibile. La causa deve essere ricostruita attraverso codebook, protocollo o fonte originale. La trasformazione deve essere espressa nel codice e il suo effetto deve essere quantificato. Quando più scelte sono ragionevoli, l'analisi di sensibilità è più informativa di una decisione nascosta.

Questo modo di lavorare risponde direttamente alle lezioni della crisi della replicabilità. Riduce la flessibilità non dichiarata e permette ad altri di comprendere non soltanto quali dati siano stati analizzati, ma perché il dataset abbia assunto quella forma.

Nel capitolo successivo potremo finalmente descrivere le variabili. Le statistiche e i grafici avranno significato soltanto perché il percorso dai dati grezzi al dataset analitico è stato reso esplicito.

Esercizi

1. Spiega perché 999 può produrre una media sintatticamente corretta ma scientificamente priva di significato.
2. Un identificatore compare tre volte. Descrivi due disegni nei quali la ripetizione avrebbe significati differenti e richiederebbe decisioni diverse.
3. Una scala da 0 a 40 contiene il valore 44. Quali fonti controlleresti prima di trasformarlo in NA?
4. L'esclusione dei casi incompleti riduce il campione da 300 a 210 persone. Quali confronti useresti per valutare se il campione rimanente sia ancora rappresentativo di quello reclutato?
5. L'AI unifica automaticamente "altro", "non indicato" e "preferisco non rispondere". Perché questa trasformazione può essere problematica?
6. Scrivi una voce del registro delle decisioni per una correzione verificata sul questionario originale.
7. Due regole plausibili per costruire un punteggio producono campioni di numerosità diversa. Come useresti un'analisi di sensibilità?
8. Formula un prompt che chieda all'AI di diagnosticare problemi nei dati senza eliminare, correggere o ricodificare automaticamente alcun valore.

Soluzioni

1. R tratta 999 come un normale numero se non riceve informazioni sul suo significato. Il calcolo è coerente con i valori memorizzati, ma il codice speciale non rappresenta il costruito misurato e distorce la statistica.
2. In uno studio trasversale con una sola risposta prevista, le tre righe possono indicare invii duplicati. In uno studio longitudinale possono rappresentare tre momenti programmati. Nel primo caso occorre una regola per risolvere la duplicazione; nel secondo servono identificatore e variabile temporale.
3. Controllerei il codebook, l'intervallo teorico e quello effettivamente usato nella versione del questionario, il file originale e l'eventuale procedura di scoring. Verificherei inoltre che la colonna importata sia quella corretta.
4. Confronterei gruppi, età e altre variabili disponibili tra casi completi e incompleti. Esaminerei dove si concentrano i mancanti e se la probabilità di completezza è associata alle variabili centrali dello studio.
5. Le etichette possono rappresentare scelte differenti. Unificarle perde informazione e può alterare la composizione delle categorie senza una giustificazione nel questionario o nel protocollo.
6. La voce dovrebbe indicare il valore osservato, la fonte consultata, il valore corretto, la riga interessata e il controllo eseguito dopo la trasformazione.
7. Applicherei entrambe le regole in versioni separate del dataset e confronterei numerosità, distribuzioni e risultati. Una conclusione che cambia molto tra regole ragionevoli deve essere presentata come sensibile alla scelta di scoring.

8. Il prompt dovrebbe specificare unità di analisi, intervalli, codici speciali e variabili centrali. Dovrebbe chiedere tabelle con righe coinvolte e numerosità, distinguere problemi risolvibili dal codebook da problemi che richiedono verifica e vietare modifiche al dataset.

i Punti chiave

- I dati grezzi possono produrre risultati tecnicamente validi ma scientificamente distorti.
- Un'anomalia segnala una domanda; non autorizza automaticamente una correzione.
- La causa deve essere ricostruita mediante codebook, protocollo o fonte originale.
- Duplicati e valori estremi devono essere interpretati alla luce del disegno.
- I casi completi possono rappresentare una popolazione diversa dal campione reclutato.
- La pulizia modifica il dataset e deve essere valutata confrontando prima e dopo.
- Le scelte di pulizia costituiscono gradi di libertà del ricercatore.
- Codice riproducibile e giustificazione trasparente sono entrambi necessari.
- Le alternative ragionevoli possono essere confrontate con analisi di sensibilità.
- L'AI dovrebbe diagnosticare e implementare decisioni confermate, non inventarle.

i Ambiente di sviluppo

Il capitolo usa dplyr. Le informazioni sulla sessione possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
```

```
Platform: aarch64-apple-darwin23
```

```
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Zagreb
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
other attached packages:
```

```
[1] dplyr_1.2.1
```

```
loaded via a namespace (and not attached):
```

```
[1] digest_0.6.39    R6_2.6.1          fastmap_1.2.0     tidyselect_1.2.1
[5] xfun_0.60         magrittr_2.0.5    glue_1.8.1        tibble_3.3.1
[9] knitr_1.51        pkgconfig_2.0.3   htmltools_0.5.9   rmarkdown_2.31
[13] generics_0.1.4    lifecycle_1.0.5   cli_3.6.6          vctrs_0.7.3
[17] compiler_4.6.1    tools_4.6.1       pillar_1.11.1     evaluate_1.0.5
[21] yaml_2.3.12       otel_0.2.0        rlang_1.3.0        jsonlite_2.0.0
```

15. Esplorare una variabile alla volta

In sintesi

Da sapere Esplorare una variabile significa ricostruirne la distribuzione empirica: quali valori compaiono, con quale frequenza, quali mancano e come le osservazioni si concentrano o si disperdono. La distribuzione non è una proprietà puramente numerica: riflette il costrutto, lo strumento di misura, il campionamento e le decisioni prese durante la preparazione dei dati.

Da saper fare Collegare il tipo di variabile alle descrizioni appropriate; distinguere frequenze, proporzioni e riassunti numerici; leggere forma, posizione e dispersione; riconoscere limiti della scala e osservazioni insolite; formulare descrizioni che riguardino il campione senza trasformarle prematuramente in affermazioni sulla popolazione.

Introduzione

Dopo avere definito il dataset analitico e documentato le decisioni di pulizia, possiamo iniziare a descrivere i dati. Il primo passo consiste nell'osservare una variabile alla volta.

Questa scelta può sembrare elementare. In realtà, molte analisi diventano difficili da interpretare perché si cercano subito relazioni, differenze tra gruppi o modelli complessi senza avere prima compreso le variabili che vi entrano.

Una correlazione può essere dominata da pochi valori estremi. Una media può nascondere una distribuzione fortemente asimmetrica. Una categoria può contenere pochissime osservazioni. Una scala può concentrare quasi tutte le risposte al valore massimo, lasciando poco spazio per osservare differenze individuali.

L'analisi univariata risponde quindi a una domanda preliminare:

Che cosa rappresentano concretamente i valori osservati in questa variabile?

La risposta richiede più di un comando. Dobbiamo conoscere la definizione della variabile, i valori che potrebbe assumere, il modo in cui è stata misurata e la popolazione da cui proviene il campione.

Prerequisiti

Il capitolo presuppone che il percorso dai dati grezzi al dataset analitico sia stato documentato, come discusso in Capitolo 13 e Capitolo 14. Se l'esplorazione rivela valori impossibili, categorie inattese o duplicazioni, è necessario tornare a quei passaggi prima di proseguire.

Panoramica del capitolo

Il concetto centrale sarà la distribuzione empirica. Vedremo come cambia la sua descrizione quando la variabile è categoriale, ordinale o numerica. Per le variabili numeriche distingueremo forma, posizione e dispersione, evitando di ridurre tutto a una media. Discuteremo poi valori mancanti, limiti della scala, osservazioni estreme e rapporto tra campione e popolazione. La sintassi rimarrà essenziale: il codice servirà a rendere visibili queste caratteristiche, non a introdurre un nuovo catalogo di funzioni.

i Preparazione del notebook

Gli esempi usano dplyr e ggplot2, già introdotti nella Parte su R. Il dataset è simulato e contiene una riga per studente. I valori mancanti sono inseriti intenzionalmente.

```
library(dplyr)
library(ggplot2)

set.seed(2026)

n <- 120

studenti <- data.frame(
  id = seq_len(n),
  anno = factor(
    sample(
      c("primo", "secondo", "terzo"),
      size = n,
      replace = TRUE,
      prob = c(.44, .34, .22)
    ),
    levels = c("primo", "secondo", "terzo"),
    ordered = TRUE
  ),
  stress = round(
    1 + 9 * rbeta(n, 2.8, 2.2)
  ),
  qualita_sonno = factor(
    sample(
      1:5,
      size = n,
      replace = TRUE,
      prob = c(.08, .17, .33, .29, .13)
    ),
    levels = 1:5,
    ordered = TRUE
  )
)

studenti$stress[c(9, 54, 103)] <- NA
studenti$qualita_sonno[c(17, 61)] <- NA
```

15.1. La distribuzione empirica

Una variabile è una regola che associa un valore a ciascuna unità osservata. La **distribuzione empirica** descrive come questi valori si presentano nel campione.

Per la variabile *anno*, la distribuzione indica quanti studenti appartengono al primo, al secondo e al terzo anno. Per *stress*, indica quali punteggi compaiono, dove si concentra la maggior parte degli studenti e quanto i punteggi differiscono tra loro.

La distribuzione è quindi l'oggetto principale dell'analisi univariata. Una media, una proporzione o un boxplot ne mostrano soltanto alcuni aspetti.

Dire che lo stress medio è 6 non significa che la maggior parte degli studenti abbia ottenuto 6. Potremmo avere una distribuzione concentrata intorno a quel valore oppure due gruppi distinti, uno con punteggi bassi e uno con punteggi alti. Lo stesso numero riassuntivo può provenire da configurazioni molto diverse.

L'obiettivo iniziale non è scegliere la statistica "migliore", ma costruire una descrizione abbastanza ricca da non confondere un riassunto con l'intera variabile.

15.2. Prima dei numeri viene il significato

Una colonna memorizzata come numero non è necessariamente una quantità continua. *qualita_sonno*, codificata da 1 a 5, rappresenta livelli ordinati. Le categorie possiedono un ordine, ma non sappiamo automaticamente se la distanza psicologica tra 1 e 2 sia uguale a quella tra 4 e 5.

Analogamente, un codice 1, 2 o 3 può rappresentare l'anno di corso. Calcolarne la media non descrive in modo trasparente la composizione del campione.

Prima dell'esplorazione dobbiamo quindi recuperare dalla documentazione almeno tre informazioni: che cosa rappresenta la variabile, quali valori può assumere e come è stata costruita. Queste informazioni determinano quali operazioni abbiano senso.

Tipo concettuale	Domanda iniziale	Descrizione essenziale
Categoriale	Quali categorie compaiono e con quale frequenza?	Conteggi e proporzioni
Ordinale	Come si distribuiscono le risposte lungo l'ordine previsto?	Frequenze ordinate e proporzioni
Numerica	Dove si concentrano i valori e quanto variano?	Distribuzione grafica, posizione e dispersione

La tabella non pretende di risolvere ogni caso. Un punteggio ottenuto sommando molti item ordinali può essere trattato in modo diverso da un singolo item. La decisione deve essere coerente con la costruzione della misura e con lo scopo descrittivo.

15.3. Variabili categoriali: descrivere la composizione

Per una variabile categoriale, la distribuzione è costituita dalle frequenze delle categorie.

```
studenti |>
  count(anno) |>
  mutate(
    proporzione = n / sum(n)
  )
```

	anno	n	proporzione
1	primo	60	0.5000000
2	secondo	38	0.3166667
3	terzo	22	0.1833333

Il conteggio risponde alla domanda “quante osservazioni?”. La proporzione risponde alla domanda “quale parte del campione?”.

Le due informazioni devono essere lette insieme. Una categoria che rappresenta il 10% del campione può contenere dieci persone in uno studio e mille in un altro. La proporzione descrive la composizione; il conteggio segnala quanta informazione sostiene quella descrizione.

```
ggplot(
  studenti,
  aes(x = anno)
) +
  geom_bar() +
  labs(
    x = "Anno di corso",
    y = "Numero di studenti"
  )
```




Figura 15.1.: Composizione del campione per anno di corso.

Il grafico rende immediatamente visibile lo sbilanciamento tra categorie. Non ci dice però se tale composizione riproduca quella della popolazione universitaria. Per affermarlo servirebbero informazioni sul piano di campionamento e sulla popolazione di riferimento.

Una formulazione appropriata è:

Nel campione osservato, gli studenti del primo anno sono più numerosi di quelli del terzo anno.

Una formulazione non giustificata sarebbe:

Gli studenti universitari appartengono soprattutto al primo anno.

La prima frase descrive i dati. La seconda generalizza oltre ciò che il campionamento permette di sostenere.

15.4. Variabili ordinali: conservare l'ordine

Una variabile ordinale contiene categorie che possono essere ordinate. La qualità soggettiva del sonno, misurata da 1 a 5, ne è un esempio.

```
studenti |>
  count(
    qualita_sonno,
    .drop = FALSE
  ) |>
  mutate(
    proporzione = n / sum(n)
  )
```

	qualita_sonno	n	proporzione
1	1	5	0.04166667
2	2	28	0.23333333
3	3	37	0.30833333
4	4	38	0.31666667
5	5	10	0.08333333
6	<NA>	2	0.01666667

Il grafico deve conservare l'ordine dei livelli:

```
ggplot(
  studenti,
  aes(x = qualita_sonno)
) +
  geom_bar() +
  labs(
    x = "Qualità soggettiva del sonno",
    y = "Numero di studenti"
  )
```




Figura 15.2.: Distribuzione della qualità soggettiva del sonno.

La forma della distribuzione mostra quali risposte siano frequenti e se le osservazioni si concentrino verso un estremo della scala.

Se quasi tutte le risposte fossero pari a 5, potremmo osservare un **effetto soffitto**. La variabile distinguerebbe poco gli studenti con livelli elevati perché la scala non offre valori superiori. Una concentrazione al valore minimo suggerirebbe invece un **effetto pavimento**.

Questi pattern possono riflettere il fenomeno, ma anche la formulazione dell'item, la popolazione selezionata o una scala non adeguata all'intervallo reale delle risposte. L'EDA rende visibile il limite; la sua spiegazione richiede di tornare alla misurazione.

15.5. Variabili numeriche: forma, posizione e dispersione

Per una variabile numerica non basta conoscere il minimo e il massimo. Dobbiamo osservare almeno tre caratteristiche.

La **forma** descrive come i valori sono distribuiti: simmetria, asimmetria, concentrazioni, vuoti e possibili gruppi distinti.

La **posizione** descrive dove si trova il centro della distribuzione. Media e mediana rispondono a definizioni differenti di centro.

La **dispersione** descrive quanto i valori differiscono tra loro. Intervallo, distanza interquartile e deviazione standard ne evidenziano aspetti diversi.

Queste caratteristiche devono essere lette insieme.

```
studenti |>
  summarise(
    n_osservato =
      sum(!is.na(stress)),
    n_mancante =
      sum(is.na(stress)),
    minimo =
      min(stress, na.rm = TRUE),
    q25 =
      quantile(
        stress,
        .25,
        na.rm = TRUE
      ),
    mediana =
      median(stress, na.rm = TRUE),
    media =
      mean(stress, na.rm = TRUE),
    q75 =
      quantile(
        stress,
        .75,
        na.rm = TRUE
      ),
    massimo =
      max(stress, na.rm = TRUE),
    deviazione_standard =
      sd(stress, na.rm = TRUE)
  )
```

	n_osservato	n_mancante	minimo	q25	mediana	media	q75	massimo
1	117	3	2	5	6	5.991453	8	9
	deviazione_standard							
1	1.863884							

La tabella offre punti di riferimento. Il grafico mostra come quei numeri siano prodotti dalla distribuzione.

```
ggplot(
  studenti,
  aes(x = stress)
) +
  geom_histogram(
    binwidth = 1,
    boundary = .5,
    na.rm = TRUE
  ) +
  labs(
    x = "Punteggio di stress",
    y = "Numero di studenti"
  )
)
```




Figura 15.3.: Distribuzione dei punteggi di stress.

Poiché `stress` assume valori interi da 1 a 10, intervalli di ampiezza 1 rispettano la risoluzione della misura. Non stiamo cercando un'impostazione grafica universale: stiamo scegliendo una rappresentazione coerente con i valori possibili.

15.6. Media e mediana rispondono a domande differenti

La media utilizza la distanza numerica di ogni osservazione. È il punto di equilibrio della distribuzione ed è sensibile ai valori estremi.

La mediana divide le osservazioni ordinate in due metà. Dipende dalla posizione dei valori, non dall'ampiezza delle distanze più estreme.

Se la distribuzione è approssimativamente simmetrica, media e mediana possono essere simili. Se è asimmetrica o contiene valori molto lontani, possono differire.

Non occorre adottare la regola meccanica “usa la mediana quando la distribuzione non è normale”. La scelta dipende da ciò che vogliamo descrivere. La media è informativa sul livello complessivo della variabile; la mediana descrive il valore che divide il campione in due parti.

Spesso è preferibile riportarle entrambe durante l'esplorazione e spiegare la forma della distribuzione. La decisione su quale statistica privilegiare nel report finale può essere presa dopo avere osservato i dati e considerato il significato della scala.

! Il centro non descrive la distribuzione

Due campioni possono avere la stessa media e dispersioni, asimmetrie o concentrazioni molto differenti. Una statistica di posizione deve essere accompagnata almeno da una misura di dispersione e da una rappresentazione della forma.

15.7. La dispersione non è rumore da eliminare

In psicologia, la variabilità tra persone o tra osservazioni è spesso parte del fenomeno studiato.

Una deviazione standard elevata non significa automaticamente che la misura sia scadente. Può indicare che il campione contiene esperienze molto differenti. Al contrario, una variabilità ridotta può derivare da una popolazione omogenea, da una selezione restrittiva o da un effetto pavimento o soffitto.

La dispersione deve quindi essere interpretata insieme al disegno e alla misurazione.

Il boxplot offre un riepilogo compatto della posizione e della dispersione:

```
ggplot(
  studenti,
  aes(y = stress)
) +
  geom_boxplot(
    na.rm = TRUE
  ) +
  labs(
    x = NULL,
    y = "Punteggio di stress"
  )
```




Figura 15.4.: Boxplot dei punteggi di stress.

Il boxplot non sostituisce l'istogramma. Riduce la distribuzione a pochi elementi: mediana, quartili e osservazioni oltre una regola convenzionale. È utile per una sintesi rapida, ma può nascondere picchi, vuoti e gruppi distinti.

15.8. I valori estremi appartengono prima di tutto alla distribuzione

Un valore distante dagli altri non è automaticamente un errore.

Può essere una registrazione sbagliata, ma può anche rappresentare una persona reale che si colloca in una regione rara della popolazione. Il boxplot può segnalarlo secondo una convenzione geometrica; non può stabilirne l'origine.

L'analisi univariata deve quindi distinguere due domande:

Il valore è possibile secondo lo strumento e la procedura?

Il valore è raro rispetto alle altre osservazioni del campione?

La prima domanda riguarda validità e pulizia. La seconda riguarda la distribuzione empirica. Un valore può essere possibile e raro; in quel caso eliminarlo renderebbe il campione meno fedele alle osservazioni raccolte.

Quando una statistica cambia molto includendo o escludendo un'osservazione, non abbiamo automaticamente trovato una ragione per eliminarla. Abbiamo scoperto che la descrizione è sensibile a quel caso. Questa sensibilità deve essere riportata e approfondita.

15.9. I valori mancanti fanno parte della descrizione

Una distribuzione viene costruita sui valori osservati. Se alcuni valori mancano, il grafico e le statistiche rappresentano soltanto le persone per cui la misura è disponibile.

```
studenti |>
  summarise(
    n_totale = n(),
    n_osservato =
      sum(!is.na(stress)),
    n_mancante =
      sum(is.na(stress)),
    proporzione_mancante =
      mean(is.na(stress))
  )
```

	n_totale	n_osservato	n_mancante	proporzione_mancante
1	120	117	3	0.025

Il numero dei mancanti dovrebbe essere riportato insieme al numero dei valori osservati. Scrivere soltanto `na.rm = TRUE` rende possibile il calcolo, ma non informa il lettore sulla parte del campione che non contribuisce al risultato.

Nell'analisi univariata possiamo descrivere quanti valori mancano e verificare se l'assenza deriva da codici non ancora riconosciuti. Stabilire se i mancanti siano associati ad altre caratteristiche richiede invece di passare a una domanda multivariata.

 La distribuzione osservata non include chi non ha risposto

Se la mancata risposta è collegata al livello della variabile o ad altre caratteristiche dei partecipanti, la distribuzione dei soli valori osservati può essere diversa da quella che avremmo ottenuto con informazioni complete.

15.10. Limiti, risoluzione e accumuli di valori

Una distribuzione è influenzata dai limiti dello strumento.

Una scala da 1 a 10 non può mostrare valori inferiori a 1 o superiori a 10. Se molte persone avrebbero livelli di stress maggiori di quanto lo strumento riesca a rappresentare, le risposte si accumuleranno vicino a 10. Il grafico mostrerà la distribuzione dei punteggi consentiti, non necessariamente quella completa del costrutto.

Anche la risoluzione è importante. Un item con cinque categorie produce pochi valori possibili; un tempo di reazione misurato in millisecondi ne produce molti. Non ha senso chiedere allo stesso grafico lo stesso livello di dettaglio.

Talvolta osserviamo accumuli su valori tondi, come 5, 10 o 15. Questo fenomeno, spesso chiamato *heaping*, può riflettere approssimazione nella risposta o nel processo di registrazione. Non è necessariamente un errore, ma informa sulla precisione effettiva della misura.

L'esplorazione deve quindi chiedersi non soltanto dove si trovino i valori, ma anche quali valori lo strumento permetta di osservare.

15.11. Campione e popolazione

Le statistiche descrittive riassumono il campione disponibile. Non dimostrano che la popolazione possieda la stessa distribuzione.

Se il campione proviene da un singolo corso universitario, la distribuzione dello stress descrive quelle persone nel contesto e nel periodo della raccolta. La generalizzazione ad altri studenti dipende dal campionamento, dalla partecipazione e dalle differenze tra contesti.

Anche una descrizione perfettamente calcolata può essere poco rappresentativa. Un campione di volontari può sottorappresentare chi ha meno tempo, maggiore disagio o minore familiarità con gli strumenti digitali. I valori mancanti e le esclusioni durante la pulizia possono restringere ulteriormente la popolazione effettivamente descritta.

Per questo motivo, il linguaggio deve rimanere proporzionato:

Nel campione, la maggior parte dei punteggi di stress si concentra tra...

è diverso da:

Nella popolazione degli studenti, lo stress si distribuisce...

La seconda frase richiede un passaggio inferenziale e una giustificazione del campionamento che l'EDA, da sola, non fornisce.

15.12. Una lettura integrata della variabile

Al termine dell'esplorazione non dovremmo avere soltanto una tabella e un grafico, ma una breve descrizione coerente.

Per *stress*, una descrizione potrebbe seguire questo ordine narrativo:

La variabile è un punteggio intero compreso tra 1 e 10. Sono disponibili 117 osservazioni su 120. I valori occupano gran parte dell'intervallo della scala e si concentrano nella regione centrale, con una lieve asimmetria. Media e mediana sono simili, mentre il boxplot non suggerisce valori impossibili. La distribuzione descrive il campione osservato e non dimostra che la stessa forma caratterizzi l'intera popolazione studentesca.

La formulazione collega significato, completezza, forma, posizione, dispersione e limite della generalizzazione. Nessuna singola statistica potrebbe sostituirla.

15.13. L'EDA è un ciclo, non una checklist

L'esplorazione univariata può farci tornare indietro.

Una categoria inattesa richiede di consultare il codebook. Un valore impossibile richiede di verificare la fonte. Un accumulo al limite della scala richiede di riflettere sulla misurazione. Una grande quota di mancanti può costringere a ridefinire ciò che il dataset analitico rappresenta.

Il ciclo è:

descrivere → osservare una discrepanza → verificare → eventualmente trasformare → descrivere di nuovo.

La prima visualizzazione non è quindi un risultato definitivo. È uno strumento diagnostico.

15.14. Chiedere all'AI una lettura, non un verdetto

Una richiesta generica come «descrivi questa variabile» può produrre una lunga lista di statistiche e un'interpretazione troppo sicura.

Una richiesta più utile specifica il significato della variabile e chiede di separare osservazione e inferenza.

Un prompt per l'esplorazione univariata

Ho un data frame chiamato `studenti`, con una riga per studente. `stress` è un punteggio intero da 1 a 10 e può contenere valori mancanti.

Proponi una sequenza semplice per descriverne la distribuzione. Includi numerosità totale, valori osservati e mancanti, intervallo, media, mediana, quartili, deviazione standard, istogramma e boxplot.

Non eliminare valori e non dichiararli outlier senza una verifica del loro significato. Spiega che cosa mostra ogni riassunto, segnala eventuali effetti pavimento o soffitto e mantieni le conclusioni riferite al campione.

Dopo avere ricevuto il codice, dobbiamo controllare che la variabile esista, che i limiti dichiarati siano corretti, che i mancanti siano quantificati e che il grafico rispetti la risoluzione della misura.

Se l'AI conclude che la distribuzione è “normale” basandosi soltanto sull'aspetto dell'istogramma, possiamo chiedere una formulazione più prudente:

Descrivi la forma visibile senza trasformarla in una classificazione definitiva e senza anticipare assunzioni richieste da modelli successivi.

15.15. Che cosa non appartiene ancora a questo capitolo

Confrontare la distribuzione dello stress tra anni di corso, studiare la relazione tra stress e sonno o verificare se i mancanti siano più frequenti in un gruppo significa introdurre una seconda variabile.

Queste sono domande importanti, ma non sono più univariate. Verranno affrontate nei capitoli successivi.

Mantenere questa distinzione aiuta a capire quale informazione venga aggiunta passando da una variabile a due o più variabili.

Riflessioni conclusive

Esplorare una variabile significa ricostruire la sua distribuzione nel campione, non produrre automaticamente una media e un grafico.

Per una variabile categoriale osserviamo categorie, conteggi e proporzioni. Per una variabile ordinale conserviamo l'ordine e cerchiamo concentrazioni verso i limiti. Per una variabile numerica leggiamo insieme forma, posizione e dispersione.

I valori mancanti, gli estremi, la risoluzione e i limiti della scala fanno parte della descrizione. Possono indicare problemi nei dati, ma anche caratteristiche reali della misura o del campione. L'EDA deve renderli visibili prima di interpretarli.

Il risultato finale è una descrizione narrativa e controllabile che rimane riferita al campione osservato. Solo dopo avere compreso le singole variabili sarà sensato chiedersi come cambino insieme.

Esercizi

1. Perché la media non è una descrizione completa della distribuzione? Costruisci due configurazioni semplici con la stessa media ma forma differente.
2. Esplora la variabile `anno`. Riporta conteggi e proporzioni e formula una frase che descriva il campione senza generalizzare alla popolazione studentesca.
3. Esplora `qualita_sonno`. Spiega perché il grafico a barre è più trasparente di un istogramma per un singolo item ordinale con cinque livelli.
4. Per `stress`, confronta media e mediana e osserva l'istogramma. Spiega che cosa aggiunge il grafico rispetto ai due numeri.
5. Il boxplot segnala un valore distante dagli altri. Quali domande devi porre prima di considerarlo un errore?
6. Una variabile presenta il 18% di valori mancanti. Quali affermazioni puoi fare in questa fase e quali richiedono il confronto con altre variabili?
7. Una scala da 1 a 5 presenta il 70% delle risposte pari a 5. Quali spiegazioni considereresti prima di concludere che il costrutto sia molto elevato nel campione?
8. Formula un prompt che chieda all'AI di esplorare una variabile numerica senza eliminare osservazioni, senza classificare automaticamente gli estremi come errori e senza generalizzare oltre il campione.

Soluzioni

1. La media riassume il punto di equilibrio ma non mostra dispersione, asimmetria o presenza di gruppi. I valori 4, 5, 6 e 1, 5, 9 hanno entrambi media 5, ma dispersioni molto differenti.
2. La risposta deve riportare il numero e la proporzione di studenti in ciascun anno. Una formulazione appropriata è: «Nel campione osservato, il primo anno è la categoria più rappresentata».
3. Il grafico a barre mostra separatamente le frequenze dei cinque livelli e ne conserva l'ordine. L'istogramma suggerirebbe una continuità tra valori che il singolo item non garantisce.
4. Media e mediana descrivono la posizione. L'istogramma mostra come i valori producano quei centri, rendendo visibili asimmetrie, accumuli, vuoti o più picchi.
5. Occorre verificare che il valore sia possibile secondo la scala, che non derivi da un errore di registrazione, che sia coerente con la fonte originale e che la sua rarità non sia una caratteristica reale della popolazione.

6. Possiamo descrivere la quantità di dati mancanti e il numero di osservazioni disponibili. Per stabilire se la mancanza sia associata a gruppi o ad altre caratteristiche dobbiamo introdurre almeno una seconda variabile.
7. Potrebbe trattarsi di un livello realmente elevato, di un campione selezionato, di un item troppo facile o poco discriminante, di desiderabilità sociale oppure di un effetto soffitto dovuto alla scala.
8. Il prompt deve specificare significato, intervallo e unità della variabile, chiedere conteggio dei mancanti, riassunti di posizione e dispersione, rappresentazioni della forma e una descrizione limitata al campione.

Punti chiave

- L'oggetto dell'analisi univariata è la distribuzione empirica.
- Il significato della variabile precede la scelta della statistica.
- Conteggi e proporzioni descrivono variabili categoriali e ordinali.
- Le variabili numeriche richiedono una lettura congiunta di forma, posizione e dispersione.
- Media, mediana, istogramma e boxplot mostrano aspetti differenti.
- Un valore estremo non è automaticamente un errore.
- I valori mancanti determinano chi contribuisce alla distribuzione osservata.
- Limiti e risoluzione dello strumento influenzano la forma visibile.
- Le descrizioni riguardano il campione; la generalizzazione richiede ulteriori giustificazioni.
- L'AI può produrre sintassi e riassunti, ma non deve sostituire la valutazione della misura e del campionamento.

Ambiente di sviluppo

Il capitolo usa `dplyr` e `ggplot2`. Le informazioni sulla sessione possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
```

```
Platform: aarch64-apple-darwin23
```

```
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; LAPACK
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Zagreb
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods   base
```

```
other attached packages:
```

```
[1] ggplot2_4.0.3 dplyr_1.2.1
```

```
loaded via a namespace (and not attached):
```

```
[1] vctrs_0.7.3      cli_3.6.6        knitr_1.51       rlang_1.3.0
[5] xfun_0.60        otel_0.2.0       generics_0.1.4   S7_0.2.2
[9] jsonlite_2.0.0   labeling_0.4.3   glue_1.8.1       htmltools_0.5.9
[13] scales_1.4.0     rmarkdown_2.31   grid_4.6.1       evaluate_1.0.5
[17] tibble_3.3.1     fastmap_1.2.0    yaml_2.3.12      lifecycle_1.0.5
[21] compiler_4.6.1   RColorBrewer_1.1-3 pkgconfig_2.0.3  farver_2.1.2
[25] digest_0.6.39    R6_2.6.1         tidyselect_1.2.1 pillar_1.11.1
[29] magrittr_2.0.5   withr_3.0.3      tools_4.6.1      gtable_0.3.6
```

16. Visualizzare senza deformare

In sintesi

Da sapere Un grafico è una rappresentazione selettiva dei dati. Decide quali osservazioni mostrare, quali differenze rendere salienti e quali aspetti lasciare sullo sfondo. Una visualizzazione utile deve essere coerente con la domanda, fedele ai dati e proporzionata alle conclusioni che il disegno consente.

Da saper fare Identificare il confronto richiesto al lettore; scegliere una rappresentazione che mostri distribuzione, numerosità e valori inattesi quando sono rilevanti; riconoscere assi, aggregazioni, colori e trasformazioni potenzialmente fuorvianti; valutare criticamente un grafico prodotto dall'AI.

Introduzione

Nel capitolo su `ggplot2` abbiamo visto come tradurre una domanda visiva in codice. Qui il problema è diverso. Non ci interessa imparare nuove geometrie o opzioni grafiche, ma capire quando una figura aiuta davvero a ragionare con i dati.

Un grafico non è una finestra neutrale sulla realtà. Per costruirlo scegliamo una tabella, alcune variabili, una scala, un segno grafico e spesso una forma di aggregazione. Ogni scelta rende qualcosa più visibile e qualcos'altro meno visibile.

Un grafico che mostra soltanto le medie rende immediato il confronto tra i centri dei gruppi, ma nasconde la dispersione e la sovrapposizione. Un asse ristretto rende più facile osservare piccole differenze, ma può farle apparire molto più grandi. Un colore può distinguere categorie, ma anche suggerire un ordine o un giudizio che i dati non contengono.

La domanda centrale del capitolo è quindi:

Quale confronto vogliamo rendere possibile, e quali informazioni devono rimanere visibili perché quel confronto sia onesto?

Prerequisiti

Il capitolo presuppone i concetti introdotti in Capitolo 10 e Capitolo 15. La sintassi di `ggplot2` non viene spiegata nuovamente. Gli esempi servono a confrontare rappresentazioni differenti dello stesso oggetto.

Panoramica del capitolo

Partiremo dal rapporto tra domanda e compito percettivo. Vedremo perché la posizione su una scala comune è spesso più facile da confrontare di aree, angoli e volumi. Discuteremo poi ciò che viene perso quando i dati vengono aggregati, il ruolo degli assi e delle trasformazioni, l'uso del colore e

la distinzione tra grafici esplorativi e grafici destinati alla comunicazione. Concluderemo con un protocollo per controllare le figure generate dall'AI.

i Preparazione del notebook

Gli esempi usano dplyr e ggplot2. Il dataset è simulato e ha una riga per studente.

```
library(dplyr)
library(ggplot2)

set.seed(2026)

n_gruppo <- 60

studenti <- data.frame(
  id = seq_len(2 * n_gruppo),
  gruppo = rep(
    c("controllo", "intervento"),
    each = n_gruppo
  ),
  stress = c(
    rnorm(
      n_gruppo,
      mean = 61,
      sd = 10
    ),
    rnorm(
      n_gruppo,
      mean = 55,
      sd = 12
    )
  )
)

studenti$stress <- round(
  pmin(
    pmax(studenti$stress, 20),
    95
  ),
  1
)

studenti$stress[c(14, 93)] <- NA
```

16.1. Il grafico deve rispondere a una domanda

La scelta della figura non dovrebbe partire dal nome di un grafico. Dovrebbe partire dall'operazione che chiediamo al lettore di compiere.

Vogliamo riconoscere la forma di una distribuzione? Confrontare quantità? Osservare la sovrapposizione tra gruppi? Seguire un cambiamento nel tempo? Cercare una relazione tra due misure?

Domanda	Compito del lettore	Rappresentazione iniziale
Come si distribuisce una misura?	Individuare concentrazioni, asimmetrie e valori insoliti	Istogramma o punti
Come è composto il campione?	Confrontare frequenze o proporzioni	Barre su scala comune
Quanto si sovrappongono due gruppi?	Confrontare posizione e dispersione	Punti individuali e sintesi
Come cambiano due misure insieme?	Valutare forma e direzione della relazione	Diagramma di dispersione
Come evolve una misura?	Seguire un ordine temporale	Linee, mantenendo visibili le unità rilevanti

Questa associazione è un punto di partenza, non una procedura automatica. La rappresentazione va valutata osservando ciò che produce e chiedendosi se il confronto importante sia realmente possibile.

16.2. La percezione non tratta tutti i segni allo stesso modo

Confrontare due punti collocati sulla stessa scala è relativamente semplice. Confrontare due lunghezze che partono dalla stessa origine è anch'esso abbastanza diretto. È più difficile confrontare angoli, aree o volumi.

Questa differenza spiega perché un grafico a barre sia generalmente più leggibile di una torta quando vogliamo confrontare frequenze. Nella torta il lettore deve valutare angoli e superfici; nelle barre confronta posizioni e lunghezze rispetto a una base comune.

Supponiamo di avere tre categorie:

```
frequenze <- data.frame(
  livello = factor(
    c("basso", "medio", "alto"),
    levels = c("basso", "medio", "alto")
  ),
  n = c(28, 63, 29)
)
```

Una rappresentazione a barre rende il confronto immediato:

```
ggplot(
  frequenze,
  aes(
    x = livello,
    y = n
  )
) +
```



```
geom_col() +
labs(
  x = "Livello",
  y = "Numero di studenti"
)
```




Figura 16.1.: Frequenze rappresentate mediante lunghezze su una scala comune.

Non esiste un divieto assoluto contro i grafici a torta. La domanda è se la forma scelta renda il compito più facile o più difficile senza offrire un'informazione aggiuntiva.

16.3. Un riassunto può essere corretto e insufficiente

Consideriamo la media dello stress nei due gruppi.

```
stress_medio <- studenti |>
  group_by(gruppo) |>
  summarise(
    n = sum(!is.na(stress)),
    media = mean(
      stress,
      na.rm = TRUE
    ),
    .groups = "drop"
  )

stress_medio
```

```
# A tibble: 2 x 3
```

16. Visualizzare senza deformare

	gruppo	n	media
	<chr>	<int>	<dbl>
1	controllo	59	59.9
2	intervento	59	53.9

Possiamo rappresentare le due medie con due barre:

```
ggplot(  
  stress_medio,  
  aes(  
    x = gruppo,  
    y = media  
  )  
) +  
  geom_col(  
    width = .55  
  ) +  
  labs(  
    x = NULL,  
    y = "Stress medio"  
  )  
)
```




Figura 16.2.: Le sole medie rendono visibile il centro ma nascondono le distribuzioni.

La figura non contiene un errore aritmetico. Mostra esattamente le medie calcolate. Tuttavia, non permette di vedere quanto i punteggi varino, quanto i gruppi si sovrappongano, se le distribuzioni siano asimmetriche o se pochi casi influenzino il risultato.

Una rappresentazione che conserva le osservazioni rende visibile una parte maggiore dell'informazione:

```

ggplot(
  studenti,
  aes(
    x = gruppo,
    y = stress
  )
) +
  geom_jitter(
    width = .12,
    alpha = .55,
    na.rm = TRUE
  ) +
  geom_boxplot(
    width = .32,
    outlier.shape = NA,
    alpha = .2,
    na.rm = TRUE
  ) +
  labs(
    x = NULL,
    y = "Punteggio di stress"
  )

```




Figura 16.3.: Punti individuali e boxplot rendono visibili variabilità, sovrapposizione e numerosità.

Il secondo grafico non è automaticamente superiore per ogni scopo. In una figura molto piccola o con migliaia di osservazioni, tutti i punti potrebbero diventare illeggibili. Il principio da conservare è che l'aggregazione deve essere consapevole: quando mostriamo soltanto una sintesi, dobbiamo sapere quale informazione stiamo togliendo.

! La media non è il gruppo

Una barra che rappresenta una media non rappresenta una persona tipica né mostra la distribuzione del gruppo. È un singolo riassunto costruito a partire da molte osservazioni.

16.4. Numerosità e denominatori devono rimanere visibili

Due gruppi possono avere la stessa media ma numerosità molto diverse. Una percentuale può apparire impressionante pur derivando da pochi casi. Una variazione può sembrare stabile perché il grafico non mostra quante osservazioni la sostengano.

Il denominatore fa parte dell'informazione. In un confronto tra gruppi, possiamo mostrare i dati individuali, riportare *n* nella didascalia oppure accompagnare il grafico con una tabella essenziale.

I valori mancanti modificano a loro volta il denominatore. Nel dataset ci sono 120 righe, ma il grafico dello stress non rappresenta gli studenti con stress mancante.

```
studenti |>
  group_by(gruppo) |>
  summarise(
    n_totale = n(),
    n_rappresentato =
      sum(!is.na(stress)),
    n_mancante =
      sum(is.na(stress)),
    .groups = "drop"
  )
```

```
# A tibble: 2 x 4
  gruppo      n_totale n_rappresentato n_mancante
  <chr>      <int>         <int>         <int>
1 controllo      60             59             1
2 intervento     60             59             1
```

Sopprimere l'avviso con `na.rm = TRUE` rende il risultato più pulito, ma non rende irrilevante l'esclusione. La figura dovrebbe essere interpretata come rappresentazione delle osservazioni disponibili, non automaticamente dell'intero campione reclutato.

16.5. Gli assi definiscono il confronto visivo

La scala degli assi influenza la dimensione apparente delle differenze.

Nei grafici a barre, la lunghezza della barra viene interpretata rispetto alla sua origine. Se l'asse verticale parte da un valore molto elevato, una piccola differenza può apparire enorme.

```
confronto <- data.frame(
  gruppo = c("A", "B"),
  media = c(52, 56)
)
```

```
ggplot(
  confronto,
  aes(
    x = gruppo,
    y = media
  )
) +
  geom_col(
    width = .55
  ) +
  coord_cartesian(
    ylim = c(50, 57)
  ) +
  labs(
    x = NULL,
    y = "Punteggio medio"
  )
)
```




Figura 16.4.: Un asse ristretto amplifica visivamente una differenza modesta tra le lunghezze delle barre.

Il problema non è che ogni asse debba sempre partire da zero. Nei diagrammi di dispersione e nelle serie temporali, restringere l'intervallo può essere necessario per osservare variazioni importanti. Nei grafici a barre, però, la lunghezza porta direttamente il significato quantitativo e l'origine assume un ruolo speciale.

La scala deve quindi essere scelta in relazione al segno grafico e dichiarata con chiarezza. Una buona domanda di controllo è:

Se modificassi l'intervallo dell'asse, la conclusione apparirebbe sostanzialmente diversa?

Quando la risposta è sì, la figura deve rendere particolarmente evidente la scelta di scala.

16.6. Le trasformazioni possono rivelare oppure occultare

Una scala logaritmica può rendere leggibile una variabile fortemente asimmetrica e può trasformare relazioni moltiplicative in pattern più semplici. Non è una manipolazione illegittima.

Diventa problematica quando non viene dichiarata oppure quando viene scelta soltanto perché rende il pattern più convincente.

La trasformazione cambia la distanza visiva tra i valori. Passare da 10 a 20 occupa lo stesso spazio del passaggio da 100 a 200 su una scala logaritmica, perché entrambi rappresentano un raddoppio.

Una figura trasformata dovrebbe quindi indicare chiaramente la scala e, quando l'interpretazione non è immediata, spiegare quale confronto venga favorito.

i Trasformare non significa falsificare

La scala originale non è sempre la rappresentazione più informativa. L'onestà consiste nel dichiarare la trasformazione, motivarla e non confondere le distanze trasformate con quelle originali.

16.7. Il doppio asse può costruire somiglianze

Sovrapporre due serie con assi verticali differenti permette di modificarne separatamente scala e origine. Cambiando questi parametri, due linee possono apparire quasi parallele oppure molto diverse.

La somiglianza visiva può quindi essere in parte costruita dal grafico.

Se due variabili possiedono unità differenti, è spesso più trasparente collocarle in pannelli separati con lo stesso asse temporale. Se vengono standardizzate, la trasformazione deve essere dichiarata e il confronto va interpretato come andamento relativo, non come uguaglianza delle quantità.

Il doppio asse non è sempre vietato, ma richiede una ragione forte e una particolare cautela. Nell'EDA introduttiva, raramente è la scelta più chiara.

16.8. Il colore deve codificare informazione

Il colore può distinguere gruppi, rappresentare un ordine o attirare l'attenzione su un elemento importante. Se viene usato senza uno scopo, aggiunge competizione visiva.

Un colore diverso per ogni osservazione non aiuta a comprendere una distribuzione. Una palette arcobaleno applicata a valori ordinati può creare confini percettivi arbitrari. Rosso e verde usati come unica distinzione possono essere difficili da leggere per una parte del pubblico.

La scelta dovrebbe seguire il significato:

- categorie senza ordine richiedono differenze riconoscibili ma non gerarchiche;
- valori ordinati richiedono una progressione percettiva;
- deviazioni rispetto a un riferimento possono richiedere due direzioni chiaramente distinguibili.

Questa breve articolazione è utile perché i tre casi corrispondono a funzioni informative diverse del colore.

Un controllo semplice consiste nell'immaginare la figura in scala di grigi. Se tutta l'informazione scompare, può essere necessario aggiungere posizione, forma, etichette o pannelli.

16.9. Le etichette orientano l'interpretazione

Titoli e didascalie non sono elementi decorativi. Possono descrivere la domanda oppure anticipare una conclusione.

Confrontiamo:

Effetto dell'intervento sullo stress

con:

Distribuzione dei punteggi di stress nei due gruppi

Il primo titolo formula già una relazione causale. È appropriato soltanto se il disegno e l'analisi giustificano quell'interpretazione. Il secondo descrive ciò che la figura mostra direttamente.

Anche parole come *miglioramento*, *crollo*, *successo* o *fallimento* possono orientare emotivamente il lettore. Una figura esplorativa dovrebbe preferire un linguaggio descrittivo.

Le etichette degli assi devono inoltre indicare che cosa è stato misurato e, quando utile, l'unità o l'intervallo della scala. I nomi interni delle colonne raramente sono sufficienti per un lettore esterno.

16.10. Esplorare e comunicare non sono la stessa attività

Durante l'EDA produciamo spesso molte figure. Proviamo scale, osserviamo sottogruppi, controlliamo singole osservazioni e confrontiamo rappresentazioni alternative. Questi grafici possono essere provvisori e ridondanti perché servono al ragionamento.

Una figura destinata al report ha una funzione diversa. Deve selezionare l'evidenza necessaria per una domanda e renderla leggibile senza richiedere una spiegazione orale.

La selezione finale non dovrebbe però cancellare le caratteristiche scomode emerse durante l'esplorazione. Se la distribuzione contiene forte sovrapposizione o valori insoliti, scegliere una figura che mostri soltanto le medie produce un racconto più semplice ma meno fedele.

Possiamo quindi distinguere:

grafico esplorativo = strumento per fare domande

grafico esplicativo = strumento per sostenere un'affermazione

Entrambi devono essere onesti, ma rispondono a esigenze differenti.

16.11. Il grafico non sostituisce il disegno

Una linea discendente in un diagramma di dispersione mostra un'associazione osservata. Non stabilisce quale variabile venga prima, se esista una causa comune o se il pattern dipenda dalla selezione del campione.

Allo stesso modo, una differenza tra gruppi non diventa un effetto dell'intervento soltanto perché viene rappresentata con barre separate.

La figura rende visibile una struttura nei dati. L'interpretazione causale dipende dal disegno, dall'assegnazione, dalla misurazione e dalle assunzioni del modello.

Questa distinzione è particolarmente importante nei titoli generati dall'AI, che tendono talvolta a convertire associazioni in effetti o differenze osservate in miglioramenti.

16.12. Controllare una figura prodotta dall'AI

Un assistente può generare rapidamente una figura elegante. Prima di valutarne l'estetica dobbiamo ricostruire le decisioni incorporate nel codice.

Dobbiamo sapere quale tabella viene usata, se sono stati applicati filtri, se le osservazioni sono state aggregate, quali valori mancanti non entrano nella figura e che cosa rappresentano assi, colori e segni.

Una richiesta iniziale utile è:



Un prompt per una figura controllabile

Ho un data frame chiamato `studenti`, con una riga per studente. Voglio confrontare la distribuzione di `stress` tra i livelli di gruppo.

Proponi una figura `ggplot2` semplice che mostri le osservazioni individuali e una sintesi della distribuzione. Non aggregare prima i dati e non applicare filtri. Conta i valori osservati e mancanti per gruppo.

Usa etichette descrittive e non causali. Spiega che cosa rappresenta ogni elemento e indica quali caratteristiche della distribuzione potrebbero rimanere nascoste.

Dopo avere ricevuto la figura, possiamo chiedere un audit:

Elenca tutte le decisioni grafiche contenute nel codice. Per ciascuna, spiega quale confronto facilita e quale informazione potrebbe rendere meno visibile.

Questo secondo passaggio è spesso più utile della richiesta generica di "migliorare il grafico".

16.13. Un protocollo di revisione

La valutazione finale può essere organizzata come una breve lettura narrativa.

Prima identifichiamo la domanda. Poi ricostruiamo quali dati entrano nella figura e che cosa rappresenta ogni segno. Osserviamo quale confronto venga richiesto al lettore e se scale, aggregazioni e colori lo rendano fedele. Infine formuliamo una frase su ciò che la figura mostra direttamente e una frase su ciò che non permette di concludere.

Il protocollo può essere riassunto così:

domanda → dati rappresentati → compito percettivo → possibile conclusione → limite.

Non serve una checklist molto lunga se questa sequenza viene applicata con attenzione.

Riflessioni conclusive

Una buona visualizzazione non è necessariamente elaborata. È una rappresentazione nella quale il confronto importante risulta facile e le informazioni necessarie per giudicarlo non vengono nascoste.

La posizione e la lunghezza su scale comuni sono generalmente più leggibili di angoli, aree e volumi. Le sole medie possono essere insufficienti quando dispersione, sovrapposizione e numerosità fanno parte della domanda. Assi, trasformazioni e colori devono avere una funzione dichiarata e non devono costruire un'impressione sproporzionata rispetto ai dati.

Nell'EDA il grafico serve anche a scoprire problemi e generare nuove domande. Nel report serve a sostenere un'affermazione. Il passaggio dalla prima funzione alla seconda richiede selezione, ma non deve cancellare la complessità rilevante.

L'AI può produrre codice e alternative visive. Il ricercatore rimane responsabile della domanda, dei dati rappresentati e dell'interpretazione suggerita dalla figura.

Esercizi

1. Scegli una figura da un articolo o da un report. Descrivi la domanda a cui sembra rispondere, il confronto richiesto al lettore e una caratteristica dei dati che potrebbe non essere visibile.
2. Confronta il grafico delle sole medie con quello che mostra punti e boxplot. Scrivi una frase che il primo consente di formulare e due domande a cui soltanto il secondo permette di rispondere.
3. Ricostruisci il grafico delle barre con asse troncato usando un asse che parta da zero. Spiega perché la differenza numerica non cambia mentre cambia la sua impressione visiva.
4. Una percentuale del 50% deriva da 2 casi su 4. Come modifichereesti la figura o la didascalia per rendere visibile il denominatore?
5. Un grafico usa un colore per il gruppo, una forma per il genere e pannelli per l'anno di corso. Quale domanda dovrebbe giustificare ciascuna codifica? Quando la figura diventerebbe troppo frammentata?
6. Un assistente AI propone il titolo «L'intervento riduce lo stress». Quali informazioni sul disegno e sull'analisi servono prima di accettarlo? Proponi un titolo puramente descrittivo.
7. Descrivi una situazione in cui una scala logaritmica migliorerebbe la leggibilità. Indica che cosa dovrebbe essere dichiarato al lettore.
8. Formula un prompt che chieda all'AI due rappresentazioni alternative della stessa domanda e un confronto esplicito tra ciò che ciascuna rende visibile e ciò che nasconde.

Soluzioni

1. La risposta deve distinguere lo scopo dichiarato dalla struttura effettivamente visibile. Una figura di medie, per esempio, può rispondere al confronto dei centri ma non mostrare sovrapposizione e forma delle distribuzioni.
2. Il primo consente di dire quale gruppo possiede la media più elevata. Il secondo permette anche di osservare quanto i gruppi si sovrappongano e se la differenza dipenda da pochi valori o da uno spostamento più generale.
3. I valori rimangono 52 e 56. Con origine zero, la differenza occupa una parte minore della scala e appare proporzionata alla grandezza complessiva delle quantità.
4. Riporterei i conteggi insieme alle percentuali, mostrerei direttamente i quattro casi quando possibile oppure inserirei 2/4 nella didascalia o nell'etichetta.
5. Il colore dovrebbe sostenere un confronto tra gruppi, la forma un confronto tra generi e i pannelli un confronto tra anni. Se alcune combinazioni contengono pochi casi o la domanda non richiede tutte queste distinzioni, la frammentazione ostacola la lettura.
6. Servono almeno un disegno che identifichi l'effetto, una definizione temporale appropriata e un'analisi coerente. Un titolo descrittivo è: «Distribuzione dei punteggi di stress nei gruppi controllo e intervento».
7. È utile, per esempio, per tempi o concentrazioni che variano su più ordini di grandezza. L'asse deve dichiarare la trasformazione e il testo deve spiegare che distanze uguali rappresentano rapporti, non differenze assolute uguali.
8. Il prompt deve specificare domanda, dati e variabili; chiedere due figure semplici; vietare filtri o aggregazioni non dichiarati; richiedere per ciascuna un'analisi del compito percettivo, dell'informazione conservata e di quella perduta.

Punti chiave

- Un grafico è una selezione, non una copia neutrale dei dati.
- La scelta della figura parte dal confronto che il lettore deve compiere.
- Posizioni e lunghezze su una scala comune sono generalmente facili da confrontare.
- Una sintesi corretta può nascondere distribuzione, sovrapposizione e numerosità.
- Assi e trasformazioni modificano l'impressione visiva e devono essere motivati.
- Il colore deve rappresentare informazione, non soltanto decorare.
- Un grafico esplorativo genera domande; un grafico esplicativo sostiene un'affermazione.
- La visualizzazione non sostituisce le condizioni necessarie per un'interpretazione causale.
- L'AI deve rendere esplicite le decisioni incorporate nella figura.
- La revisione deve terminare distinguendo ciò che la figura mostra da ciò che non permette di concludere.

Ambiente di sviluppo

Il capitolo usa `dplyr` e `ggplot2`. Le informazioni sulla sessione possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
```

```

Platform: aarch64-apple-darwin23
Running under: macOS Tahoe 26.5.2

Matrix products: default
BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L

locale:
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8

time zone: Europe/Zagreb
tzcode source: internal

attached base packages:
[1] stats      graphics  grDevices  utils      datasets  methods    base

other attached packages:
[1] ggplot2_4.0.3 dplyr_1.2.1

loaded via a namespace (and not attached):
 [1] vctrs_0.7.3      cli_3.6.6        knitr_1.51        rlang_1.3.0
 [5] xfun_0.60        ote1_0.2.0       generics_0.1.4    S7_0.2.2
 [9] jsonlite_2.0.0   labeling_0.4.3   glue_1.8.1        htmltools_0.5.9
[13] scales_1.4.0     rmarkdown_2.31   grid_4.6.1        evaluate_1.0.5
[17] tibble_3.3.1     fastmap_1.2.0    yaml_2.3.12       lifecycle_1.0.5
[21] compiler_4.6.1   RColorBrewer_1.1-3 pkgconfig_2.0.3   farver_2.1.2
[25] digest_0.6.39    R6_2.6.1         utf8_1.2.6        tidysselect_1.2.1
[29] pillar_1.11.1    magrittr_2.0.5   withr_3.0.3       tools_4.6.1
[33] gtable_0.3.6

```

17. Distribuzione, posizione e variabilità

In sintesi

Da sapere Una distribuzione descrive l'insieme dei valori osservati e il modo in cui le osservazioni si ripartiscono tra quei valori. Media e mediana descrivono dove si colloca il centro; deviazione standard, intervallo interquartile e MAD descrivono quanto i valori siano dispersi. Nessun singolo numero sostituisce la distribuzione.

Da saper fare Leggere una distribuzione come forma, posizione e dispersione; distinguere media e mediana; ricostruire il calcolo della deviazione standard a partire dagli scarti dalla media; interpretare la deviazione standard nell'unità originale della variabile; riconoscere quando media e deviazione standard sono riassunti poco informativi.

Introduzione

Questo è il capitolo centrale della Parte dedicata alla statistica descrittiva. Le idee introdotte qui ritorneranno nei grafici, nella distribuzione normale, nella standardizzazione, nei modelli statistici e nell'inferenza.

La difficoltà principale non consiste nel calcolare una media o una deviazione standard. R esegue questi calcoli immediatamente. La difficoltà consiste nel comprendere **che cosa viene riassunto e che cosa il riassunto lascia fuori**.

Quando diciamo che una variabile ha media 6, non stiamo ancora descrivendo come siano distribuiti i valori. Potrebbero essere tutti vicini a 6, oppure potrebbero dividersi tra valori molto bassi e molto alti. La stessa media può quindi corrispondere a situazioni psicologicamente molto differenti.

Per descrivere una variabile dobbiamo rispondere a tre domande collegate:

Quali valori compaiono e con quale frequenza?

Dove si colloca il centro dei valori?

Quanto i valori sono distanti tra loro e dal centro?

La prima domanda riguarda la **distribuzione**. La seconda riguarda la **posizione** o tendenza centrale. La terza riguarda la **dispersione** o variabilità.

Prerequisiti

Il capitolo sviluppa le idee introdotte in Capitolo 15. Presuppone inoltre che valori impossibili, codici speciali e duplicazioni siano già stati controllati come discusso in Capitolo 14.

Panoramica del capitolo

Cominceremo dal significato di distribuzione, perché media e deviazione standard hanno senso soltanto come descrizioni di una distribuzione. Vedremo poi moda, mediana e media. La deviazione standard verrà costruita passo per passo a partire dagli scarti dalla media. Infine confronteremo range, IQR, deviazione standard e MAD e chiariremo quando ciascun riassunto sia informativo.

i Preparazione del notebook

Gli esempi usano `dplyr` e `ggplot2`. Il dataset è simulato e contiene una riga per studente.

```

library(dplyr)
library(ggplot2)

set.seed(1234)

studenti <- data.frame(
  id = 1:80,
  stress = round(
    pmin(
      pmax(
        rnorm(
          80,
          mean = 6.2,
          sd = 1.5
        ),
        1
      ),
      10
    ),
    1
  ),
  sonno_qualita = round(
    pmin(
      pmax(
        rnorm(
          80,
          mean = 6.5,
          sd = 1.3
        ),
        1
      ),
      10
    ),
    1
  ),
  ore_sonno = round(
    pmin(
      pmax(
        rnorm(
          80,
          mean = 7.1,
          sd = .9
        ),
        4
      ),
      10
    ),
    1
  )
)

studenti$ore_sonno[c(4, 17)] <-
  c(4.1, 9.8)

212 studenti$stress[c(22, 49)] <-
  c(9.7, 9.9)

```

17.1. Che cosa significa distribuzione?

Nel linguaggio quotidiano, *distribuire* significa ripartire qualcosa. In statistica, una distribuzione descrive come le osservazioni sono ripartite tra i valori possibili di una variabile.

Consideriamo sette valori relativi alle ore di sonno:

```
sonno_a <- c(
  6.2, 6.5, 6.8,
  7.0,
  7.2, 7.5, 7.8
)

sonno_a
```

```
[1] 6.2 6.5 6.8 7.0 7.2 7.5 7.8
```

La distribuzione non è soltanto l'elenco dei numeri. Comprende il loro ordine, la frequenza con cui compaiono, la zona in cui si concentrano e le distanze che li separano.

Per una variabile con pochi valori possibili, una tabella di frequenza può descrivere direttamente la distribuzione. Per una variabile numerica con molti valori, un istogramma o un grafico a punti ne rende visibile la struttura.

```
ggplot(
  studenti,
  aes(x = ore_sonno)
) +
  geom_histogram(
    binwidth = .5,
    boundary = 0,
    na.rm = TRUE
  ) +
  labs(
    x = "Ore di sonno",
    y = "Numero di studenti"
  )
```




Figura 17.1.: Distribuzione delle ore di sonno nel campione didattico.

Nel grafico possiamo osservare dove si concentra la maggior parte dei valori, quanto ampia sia la regione occupata e se esistano code, vuoti o osservazioni lontane dalle altre.

La distribuzione empirica riguarda il campione osservato. Non deve essere confusa con una distribuzione teorica, come la distribuzione normale, che è un modello matematico. Nel capitolo successivo useremo un modello per rappresentare alcune distribuzioni; qui impariamo prima a leggere ciò che i dati mostrano.

! La distribuzione è l'oggetto, le statistiche sono riassunti

Media, mediana e deviazione standard non sono caratteristiche isolate. Sono numeri calcolati su una distribuzione. Per interpretarli dobbiamo sapere quale forma di dati stanno riassumendo.

17.2. Stessa posizione, dispersione differente

Consideriamo due gruppi di cinque studenti:

```
gruppo_compatto <- c(
  6.5, 6.8, 7.0, 7.2, 7.5
)

gruppo_disperso <- c(
  4.0, 5.5, 7.0, 8.5, 10.0
)

data.frame(
  gruppo = rep(
    c("compatto", "disperso"),
```



```

    each = 5
  ),
  ore_sonno = c(
    gruppo_compatto,
    gruppo_disperso
  )
)

```

	gruppo	ore_sonno
1	compatto	6.5
2	compatto	6.8
3	compatto	7.0
4	compatto	7.2
5	compatto	7.5
6	disperso	4.0
7	disperso	5.5
8	disperso	7.0
9	disperso	8.5
10	disperso	10.0

Entrambi hanno media pari a 7 ore:

```

data.frame(
  gruppo = c(
    "compatto",
    "disperso"
  ),
  media = c(
    mean(gruppo_compatto),
    mean(gruppo_disperso)
  ),
  deviazione_standard = c(
    sd(gruppo_compatto),
    sd(gruppo_disperso)
  )
)

```

	gruppo	media	deviazione_standard
1	compatto	7	0.3807887
2	disperso	7	2.3717082

Nel primo gruppo, quasi tutti dormono intorno a sette ore. Nel secondo, sette ore rappresenta il punto centrale di valori molto distanti tra loro. La media è identica, ma le distribuzioni non raccontano la stessa situazione.

Questa è la ragione per cui una misura di posizione deve essere accompagnata da una misura di dispersione.

17.3. Posizione: dove si colloca il centro?

Un centro è un modo di rappresentare molti valori con un solo numero. Moda, mediana e media definiscono il centro in modi differenti.

17.3.1. La moda

La **moda** è il valore o la categoria che compare più frequentemente.

Se chiediamo quale strategia venga usata più spesso per gestire lo stress, la moda identifica la risposta più comune:

```
strategie <- c(
  "studio", "sonno", "sport",
  "studio", "amici", "studio",
  "sport", "sonno", "studio",
  "amici", "studio"
)

table(strategie)
```

```
strategie
  amici  sonno  sport studio
      2     2     2     5
```

La moda ha senso anche per variabili puramente categoriali, per le quali non esistono distanze numeriche interpretabili. Può tuttavia essere poco stabile: piccoli cambiamenti nei dati possono modificare la categoria più frequente.

17.3.2. La mediana

Per trovare la **mediana**, ordiniamo i valori e individuiamo la posizione centrale.

Nel vettore:

```
6.2, 6.5, 6.8, 7.0, 7.2, 7.5, 7.8
```

il valore centrale è 7.0. Tre osservazioni sono inferiori e tre sono superiori.

```
median(sonno_a)
```

```
[1] 7
```

Se il numero delle osservazioni è pari, non esiste una singola posizione centrale. R calcola la media dei due valori centrali.

La mediana dipende soprattutto dall'ordine. Se il valore massimo passa da 7.8 a 15, la posizione centrale non cambia. Per questa ragione la mediana è detta **robusta** rispetto a pochi valori estremi.

Dire che la mediana è 7 significa che almeno metà dei valori è minore o uguale a 7 e almeno metà è maggiore o uguale a 7. Non significa che la maggior parte delle persone abbia esattamente valore 7.

17.3.3. La media

La **media aritmetica** si ottiene sommando tutti i valori e dividendo per il numero delle osservazioni:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Nel simbolo $\bar{x}$, la barra indica la media campionaria. Il simbolo n rappresenta il numero di osservazioni; x_i indica il valore della generica osservazione i .

Per `sonno_a`:

```
mean(sonno_a)
```

```
[1] 7
```

La formula può essere letta in linguaggio naturale:

Somma tutte le ore osservate e distribuisce il totale in parti uguali tra le persone.

Questa interpretazione suggerisce un'immagine utile. La media è il valore che avremmo se il totale venisse redistribuito in modo uniforme. È anche il **punto di equilibrio** della distribuzione.

A differenza della mediana, la media usa l'ampiezza di ogni valore. Se una singola osservazione diventa molto grande, aumenta anche il totale da distribuire e la media si sposta.

17.4. Media e mediana reagiscono diversamente agli estremi

Confrontiamo due insiemi quasi identici:

```
sonno_senza_estremo <- c(
  6.2, 6.5, 6.8,
  7.0,
  7.1, 7.3, 7.5
)

sonno_con_estremo <- c(
  6.2, 6.5, 6.8,
  7.0,
  7.1, 7.3, 12.0
)

data.frame(
  scenario = c(
    "senza valore estremo",
    "con valore estremo"
  ),
  media = c(
    mean(sonno_senza_estremo),
```

```

    mean(sonno_con_estremo)
  ),
  mediana = c(
    median(sonno_senza_estremo),
    median(sonno_con_estremo)
  )
)

```

	scenario	media	mediana
1	senza valore estremo	6.914286	7
2	con valore estremo	7.557143	7

La media cambia perché il valore 12 aggiunge una quantità elevata al totale. La mediana cambia poco o non cambia perché il valore estremo rimane comunque all'ultima posizione.

Non dobbiamo concludere che la media sia “sbagliata”. La media rende visibile l'effetto quantitativo del valore estremo; la mediana rende visibile la posizione centrale senza lasciarsi trascinare dalla sua ampiezza.

La scelta dipende quindi da ciò che vogliamo descrivere e dalla forma della distribuzione.

17.5. Dispersione: quanto differiscono i valori?

La dispersione descrive quanto spazio occupa la distribuzione e quanto i valori siano differenti tra loro.

Nel gruppo compatto, la media 7 rappresenta abbastanza bene quasi tutti gli studenti. Nel gruppo disperso, la stessa media nasconde esperienze molto differenti. La dispersione esprime questa differenza.

Esistono più misure perché “quanto sono sparsi i dati?” può essere definito in modi diversi.

17.6. Il range: la larghezza totale

Il **range** è la differenza tra il valore massimo e il valore minimo:

$$\text{range} = \max(x) - \min(x).$$

```
range(studenti$ore_sonno)
```

```
[1] 4.1 9.8
```

```
diff(
  range(studenti$ore_sonno)
)
```

```
[1] 5.7
```

Se il minimo è 4.1 e il massimo è 9.8, il range è 5.7 ore. La distribuzione osservata occupa quindi un intervallo totale di 5.7 ore.

Il range è immediato, ma dipende soltanto da due osservazioni. Se cambia il valore più alto o quello più basso, il range può cambiare molto anche quando tutte le altre osservazioni rimangono identiche.

17.7. Quartili e intervallo interquartile

Dopo avere ordinato i valori, i quartili individuano alcune posizioni della distribuzione. Il primo quartile Q_1 lascia circa il 25% delle osservazioni al di sotto; la mediana lascia il 50%; il terzo quartile Q_3 lascia circa il 75%.

L'**intervallo interquartile**, o IQR, è:

$$IQR = Q_3 - Q_1.$$

```
quantile(
  studenti$ore_sonno,
  probs = c(.25, .50, .75)
)
```

```
25% 50% 75%
6.7 7.3 7.7
```

```
IQR(studenti$ore_sonno)
```

```
[1] 1
```

L'IQR descrive l'ampiezza della metà centrale delle osservazioni. Ignora l'ampiezza esatta del 25% più basso e del 25% più alto; per questo è meno sensibile ai valori estremi rispetto al range.

Se $Q_1 = 6.5$ e $Q_3 = 7.7$, l'IQR è 1.2 ore. Possiamo dire che la metà centrale degli studenti si distribuisce in un intervallo ampio 1.2 ore.

17.8. Dalla distanza alla deviazione standard

La deviazione standard viene spesso presentata come una formula da applicare. È più utile costruirne il significato passo per passo.

Consideriamo tre valori:

```
x <- c(4, 6, 8)

mean(x)
```

```
[1] 6
```

La media è 6. Ora calcoliamo la distanza con segno di ogni valore dalla media:

$$d_i = x_i - \bar{x}.$$

Gli scarti sono:

Valore x_i	Media $\bar{x}$	Scarto $x_i - \bar{x}$
4	6	-2
6	6	0
8	6	2

Uno scarto negativo indica un valore sotto la media; uno scarto positivo indica un valore sopra la media.

Se sommiamo gli scarti, otteniamo sempre zero:

$$\sum_{i=1}^n (x_i - \bar{x}) = 0.$$

Nel nostro esempio, $-2 + 0 + 2 = 0$. Questo accade perché la media è il punto di equilibrio. Gli scarti negativi e positivi si compensano.

La semplice media degli scarti non può quindi misurare la dispersione: sarebbe zero anche per dati molto dispersi.

17.9. Perché eleviamo gli scarti al quadrato?

Per impedire la compensazione tra segni, eleviamo ogni scarto al quadrato:

Valore x_i	Scarto	Scarto al quadrato
4	-2	4
6	0	0
8	2	4

I quadrati sono sempre non negativi. Inoltre, gli scarti grandi ricevono un peso maggiore: uno scarto di 4 contribuisce quattro volte più di uno scarto di 2 elevato al quadrato, perché $4^2 = 16$ e $2^2 = 4$.

Questo comportamento è utile in molti modelli statistici, ma rende la deviazione standard sensibile ai valori estremi.

17.10. La varianza: scarto quadratico medio

La **varianza campionaria** è:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

La formula contiene quattro operazioni:

1. calcolare la media;
2. calcolare lo scarto di ogni valore dalla media;
3. elevare gli scarti al quadrato e sommarli;
4. dividere la somma per $n - 1$.

Nel nostro esempio, la somma degli scarti quadratici è:

$$4 + 0 + 4 = 8.$$

Poiché $n = 3$, dividiamo per $n - 1 = 2$:

$$s^2 = \frac{8}{2} = 4.$$

In R:

```
var(x)
```

```
[1] 4
```

La varianza è espressa in unità al quadrato. Se i dati sono ore, la varianza è in ore quadrate. Questa unità non ha un'interpretazione quotidiana immediata.

17.10.1. Perché $n - 1$?

La funzione `var()` e la funzione `sd()` di R usano $n - 1$. La media $\bar{x}$ è stata calcolata sugli stessi dati e impone che gli scarti sommino a zero. Dopo avere conosciuto $n - 1$ scarti, l'ultimo è già determinato. Si dice quindi che rimangono $n - 1$ **gradi di libertà**.

Dividere per $n - 1$ corregge inoltre la tendenza della varianza calcolata su un campione a sottostimare la variabilità della popolazione da cui il campione proviene.

Per comprendere la deviazione standard non è necessario padroneggiare subito tutta la teoria dei gradi di libertà. È però importante sapere quale convenzione usa R.

17.11. La deviazione standard restituisce l'unità originale

La **deviazione standard campionaria** è la radice quadrata della varianza:

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Nel nostro esempio:

$$s = \sqrt{4} = 2.$$

```
sd(x)
```

```
[1] 2
```

La radice quadrata annulla l'effetto dell'elevamento al quadrato sulle unità. Se la variabile è misurata in ore, la deviazione standard torna a essere espressa in ore.

Possiamo quindi interpretare $s = 2$ dicendo che i valori hanno una distanza tipica di circa 2 unità dalla media.

La parola *tipica* è intuitiva, ma va usata con attenzione. La deviazione standard non è la media delle distanze assolute. È la radice della media corretta degli scarti quadratici. È quindi una distanza di tipo quadratico, particolarmente sensibile agli scarti grandi.

! Che cosa significa davvero una deviazione standard

La deviazione standard quantifica la dispersione intorno alla media nella stessa unità della variabile. Un valore piccolo indica che le osservazioni sono relativamente concentrate intorno alla media; un valore grande indica che occupano una regione più ampia. Il significato di “piccolo” o “grande” dipende dalla scala e dal fenomeno.

17.12. Leggere una media insieme alla deviazione standard

Supponiamo che le ore di sonno abbiano:

$$\bar{x} = 7.0, \quad s = 0.4.$$

La distribuzione è relativamente concentrata: molti valori saranno vicini a 7, anche se non possiamo sapere esattamente quanti senza osservare la forma.

Se invece:

$$\bar{x} = 7.0, \quad s = 2.0,$$

la stessa media riassume valori molto più eterogenei.

La deviazione standard non indica il minimo e il massimo. Non significa che tutti i valori siano compresi tra $\bar{x} - s$ e $\bar{x} + s$. Non autorizza neppure a eliminare automaticamente le osservazioni oltre due deviazioni standard.

Soltanto quando la distribuzione è approssimativamente normale possiamo collegare la deviazione standard a percentuali note di osservazioni entro uno, due o tre scarti dalla media. Questo collegamento verrà sviluppato nel capitolo successivo.

17.13. La stessa deviazione standard può avere significati diversi

Una deviazione standard di 2 punti è piccola su una scala da 0 a 100 e molto grande su una scala da 1 a 5. L'interpretazione richiede quindi l'unità e l'intervallo della variabile.

Anche la forma conta. Una deviazione standard elevata può derivare da una distribuzione ampia e unimodale, da pochi valori estremi oppure dalla presenza di due sottogruppi distinti.

Per questo motivo, media e deviazione standard devono essere accompagnate da un grafico. I due numeri descrivono posizione e dispersione, ma non spiegano **come** la dispersione sia organizzata.

17.14. Il MAD: distanza dalla mediana

Una misura robusta di dispersione è la **deviazione mediana assoluta**, indicata con MAD:

$$MAD = \text{mediana}(|x_i - \text{mediana}(x)|).$$

La procedura è simile a quella della deviazione standard, ma usa la mediana come centro e le distanze assolute invece dei quadrati.

In R, per ottenere esattamente il valore definito dalla formula scriviamo:

```
mad(
  studenti$ore_sonno,
  constant = 1
)
```

```
[1] 0.55
```

Per impostazione predefinita, `mad()` moltiplica il risultato per una costante pari a circa 1.4826:

```
mad(studenti$ore_sonno)
```

```
[1] 0.81543
```

Questa versione scalata è costruita per essere confrontabile con la deviazione standard quando i dati seguono approssimativamente una distribuzione normale. La distinzione deve essere resa esplicita quando riportiamo il valore.

Il MAD è poco influenzato da pochi valori estremi perché né il centro né la misura delle distanze dipendono fortemente dalla loro ampiezza.

17.15. Riassunti sensibili e riassunti robusti

Media e deviazione standard utilizzano intensamente tutti i valori. Sono quindi **sensibili** agli estremi. Questa sensibilità non è necessariamente un difetto: se un valore elevato è reale, contribuisce alla quantità totale e alla dispersione.

Mediana, IQR e MAD sono **robusti**: cambiano meno quando poche osservazioni sono molto lontane dalle altre. Sono particolarmente utili per distribuzioni asimmetriche o con code lunghe.

Le due famiglie non sono in competizione assoluta. Rispondono a domande differenti.

Centro	Dispersione associata	Che cosa privilegia
Media	Deviazione standard	Distanze quantitative da un punto di equilibrio
Mediana	IQR o MAD	Posizioni centrali e distanze robuste

La coppia media–deviazione standard è coerente perché entrambe dipendono dalla media e dagli scarti quantitativi. La coppia mediana–IQR o mediana–MAD è coerente perché entrambe riducono l’influenza delle code e degli estremi.

17.16. Un confronto completo

Calcoliamo i principali riassunti per le ore di sonno:

```
studenti |>
  summarise(
    n = sum(!is.na(ore_sonno)),
    media =
      mean(
        ore_sonno,
        na.rm = TRUE
      ),
    mediana =
      median(
        ore_sonno,
        na.rm = TRUE
      ),
    deviazione_standard =
      sd(
        ore_sonno,
        na.rm = TRUE
      ),
    varianza =
      var(
        ore_sonno,
        na.rm = TRUE
      ),
    range =
```

```

diff(
  range(
    ore_sonno,
    na.rm = TRUE
  )
),
iqr =
  IQR(
    ore_sonno,
    na.rm = TRUE
  ),
mad_non_scalato =
  mad(
    ore_sonno,
    constant = 1,
    na.rm = TRUE
  )
)

```

	n	media	mediana	deviazione_standard	varianza	range	iqr	mad_non_scalato
1	80	7.2325	7.3	1.128769	1.27412	5.7	1	0.55

Il grafico rimane necessario:

```

ggplot(
  studenti,
  aes(x = ore_sonno)
) +
  geom_histogram(
    binwidth = .5,
    boundary = 0,
    na.rm = TRUE
  ) +
  geom_vline(
    xintercept =
      mean(
        studenti$ore_sonno,
        na.rm = TRUE
      ),
    linetype = "solid"
  ) +
  geom_vline(
    xintercept =
      median(
        studenti$ore_sonno,
        na.rm = TRUE
      ),
    linetype = "dashed"
  ) +
  labs(

```

```
x = "Ore di sonno",
y = "Numero di studenti",
subtitle =
  "Linea continua: media; linea tratteggiata: mediana"
)
```




Figura 17.2.: Istogramma e posizione della media e della mediana per le ore di sonno.

Se media e mediana sono vicine e la distribuzione appare unimodale e non fortemente asimmetrica, media e deviazione standard possono offrire un riassunto utile. Se differiscono molto o il grafico mostra code lunghe, gruppi distinti o valori estremi, la coppia mediana-IQR può descrivere meglio la regione centrale.

Non si tratta di applicare una regola automatica. Si tratta di scegliere il riassunto dopo avere compreso la distribuzione.

17.17. Distribuzioni che un singolo centro descrive male

Una distribuzione può contenere due concentrazioni distinte. In quel caso, una media collocata tra i due gruppi può corrispondere a una zona in cui esistono poche osservazioni.

Immaginiamo che metà degli studenti dorma circa cinque ore e metà circa nove. La media sarebbe vicina a sette, ma sette ore non rappresenterebbe bene nessuno dei due gruppi.

La deviazione standard sarebbe elevata, ma non ci direbbe che la variabilità deriva da due concentrazioni. Soltanto il grafico renderebbe visibile questa struttura.

Questo esempio mostra il limite generale dei riassunti: posizione e dispersione non determinano l'intera forma della distribuzione.

17.18. Valori mancanti e denominatore

Le statistiche descrittive devono dichiarare quante osservazioni utilizzano.

```
studenti |>
  summarise(
    n_totale = n(),
    n_osservato =
      sum(!is.na(ore_sonno)),
    n_mancante =
      sum(is.na(ore_sonno)),
    media =
      mean(
        ore_sonno,
        na.rm = TRUE
      ),
    deviazione_standard =
      sd(
        ore_sonno,
        na.rm = TRUE
      )
  )
```

	n_totale	n_osservato	n_mancante	media	deviazione_standard
1	80	80	0	7.2325	1.128769

`na.rm = TRUE` permette il calcolo sui valori disponibili. Non dimostra che le osservazioni mancanti siano irrilevanti. Media e deviazione standard descrivono la distribuzione dei valori osservati, non necessariamente quella di tutte le persone reclutate.

17.19. Come descrivere una distribuzione

Una descrizione completa non deve elencare ogni statistica disponibile. Deve collegare misura, forma e riassunti.

Per esempio:

Le ore di sonno sono disponibili per 80 studenti. La distribuzione è unimodale e approssimativamente simmetrica, con alcuni valori distanti alle due estremità. La media è 7.1 ore e la deviazione standard è 1.0 ora; pertanto, i valori mostrano una distanza quadratica tipica di circa un'ora dalla media. Media e mediana sono simili, mentre l'IQR descrive l'ampiezza della metà centrale. I risultati riguardano il campione osservato.

Questa formulazione evita due errori. Non presenta la deviazione standard come una percentuale o come un intervallo che contiene necessariamente i dati. Non trasforma la media nel valore posseduto da ogni individuo.

17.20. Errori frequenti nell'interpretazione

La deviazione standard non è un errore di misura. Una parte della dispersione può dipendere dall'errore, ma una parte può rappresentare differenze reali tra persone.

La deviazione standard non è l'errore standard della media. La prima descrive la dispersione delle osservazioni; il secondo descrive l'incertezza di una stima della media.

La deviazione standard non è la distanza massima dalla media. Alcune osservazioni possono trovarsi molto oltre una deviazione standard.

Una deviazione standard elevata non è automaticamente un problema. Può essere la caratteristica sostantiva più interessante del campione.

Infine, una deviazione standard piccola non dimostra che una misura sia precisa o valida. Può derivare da un campione omogeneo o da una scala con effetto pavimento o soffitto.

17.21. Usare l'AI per comprendere, non soltanto calcolare

Un assistente AI può produrre rapidamente una tabella con media, mediana, deviazione standard, IQR e MAD. La parte importante è chiedergli di rendere esplicita la relazione tra numeri e distribuzione.

Un prompt per comprendere la deviazione standard

Ho una variabile numerica chiamata `ore_sonno`, misurata in ore. Prima conta valori osservati e mancanti e mostra un istogramma.

Calcola poi media, mediana, deviazione standard, IQR e MAD non scalato. Spiega la deviazione standard ricostruendo scarti dalla media, quadrati, divisione per $n - 1$ e radice quadrata.

Non interpretare la deviazione standard come intervallo che contiene necessariamente i dati. Segnala se la forma della distribuzione rende media e deviazione standard poco rappresentative.

Se l'AI risponde soltanto “la deviazione standard indica quanto i dati si discostano dalla media”, possiamo chiedere:

Mostra con cinque numeri due distribuzioni con la stessa media e deviazioni standard diverse. Spiega quale passaggio del calcolo produce la differenza.

L'obiettivo non è accumulare definizioni, ma costruire un'immagine mentale verificabile.

17.22. Esprimere una distanza in deviazioni standard

Una volta compreso il significato della deviazione standard, possiamo usarla come unità di misura. Lo **z-score** di un valore x è:

$$z = \frac{x - \bar{x}}{s}.$$

La formula confronta la distanza dalla media, $x - \bar{x}$, con la dispersione tipica della variabile, s .

Se $z = 0$, il valore coincide con la media. Se $z = 1$, si trova una deviazione standard sopra la media. Se $z = -2$, si trova due deviazioni standard sotto la media.

Supponiamo che le ore di sonno abbiano media pari a 7.1 e deviazione standard pari a 0.9. Per una persona che dorme 5.3 ore:

$$z = \frac{5.3 - 7.1}{0.9} = -2.$$

Il valore si trova quindi due deviazioni standard sotto la media del campione.

Lo z-score non richiede che la distribuzione sia normale. Esprime soltanto una posizione relativa usando la deviazione standard come unità. Per trasformarlo in una probabilità o in un percentile dobbiamo introdurre un modello della forma distributiva, per esempio la distribuzione normale.

```
media_sonno <-
  mean(
    studenti$ore_sonno,
    na.rm = TRUE
  )

sd_sonno <-
  sd(
    studenti$ore_sonno,
    na.rm = TRUE
  )

studenti |>
  mutate(
    z_ore_sonno =
      (ore_sonno - media_sonno) /
      sd_sonno
  ) |>
  select(
    id,
    ore_sonno,
    z_ore_sonno
  ) |>
  head()
```

	id	ore_sonno	z_ore_sonno
1	1	6.3	-0.8261209
2	2	6.9	-0.2945686
3	3	6.7	-0.4717527
4	4	4.1	-2.7751462
5	5	7.5	0.2369838
6	6	7.7	0.4141679

Standardizzare non rende normale una distribuzione

La trasformazione in z-score modifica il centro e l'unità di misura, ma non modifica la forma. Una distribuzione asimmetrica rimane asimmetrica; una distribuzione con due picchi conserva

i due picchi.

17.23. Collegamento con la distribuzione normale

La distribuzione normale è descritta da due parametri: posizione e dispersione. Nella sua forma più comune, questi parametri sono la media e la deviazione standard.

Questo collegamento non significa che ogni variabile debba essere normale per possedere una media e una deviazione standard. Entrambe possono essere calcolate per molte distribuzioni differenti.

La normalità aggiunge un'informazione ulteriore: specifica la forma. Quando la forma è normale, la media e la deviazione standard permettono di ricostruire l'intera distribuzione teorica e di collegare le distanze dalla media a percentuali precise.

Nel prossimo capitolo vedremo questo passaggio. Qui deve rimanere chiara la distinzione:

media e deviazione standard descrivono posizione e dispersione;

la distribuzione normale aggiunge una particolare forma.

Riflessioni conclusive

Una distribuzione descrive come le osservazioni sono ripartite tra i valori. È l'oggetto che vogliamo comprendere. Media, mediana, deviazione standard, IQR e MAD sono modi differenti di riassumerne alcuni aspetti.

La media è il punto di equilibrio e utilizza l'ampiezza di tutti i valori. La mediana è il centro delle posizioni ordinate ed è meno influenzata dagli estremi.

La deviazione standard nasce dalle distanze dalla media. Gli scarti vengono elevati al quadrato per evitare che segni opposti si annullino; vengono mediati usando $n - 1$ e infine riportati nell'unità originale attraverso la radice quadrata. Il risultato può essere letto come una distanza quadratica tipica dalla media.

La coppia media–deviazione standard è informativa quando la distribuzione possiede un centro interpretabile e non è dominata da asimmetrie, gruppi distinti o estremi. Negli altri casi, mediana, IQR e MAD possono offrire una descrizione più robusta.

Nessuna coppia di numeri sostituisce il grafico. Comprendere una distribuzione significa tenere insieme forma, posizione, dispersione, valori mancanti e significato della misura.

Esercizi

1. Spiega con parole tue che cosa significa *distribuzione*. Perché una media non è una distribuzione?
2. I valori 5, 6, 7, 8, 9 e 1, 4, 7, 10, 13 hanno la stessa media. Calcola o prevedi quale insieme abbia deviazione standard maggiore e spiega perché senza usare soltanto la formula.
3. Per i valori 4, 6, 8, ricostruisci media, scarti, scarti quadratici, varianza campionaria e deviazione standard.

4. Perché la somma degli scarti dalla media è zero? Perché questa proprietà impedisce di usare la media degli scarti come misura di dispersione?
5. Una variabile ha media 50 e deviazione standard 8. Quali delle seguenti affermazioni sono giustificate?
 - a. Tutti i valori sono compresi tra 42 e 58.
 - b. La dispersione è espressa nella stessa unità della variabile.
 - c. La distanza quadratica tipica dalla media è circa 8.
 - d. I valori oltre 66 sono necessariamente errori.
6. Una distribuzione è fortemente asimmetrica e contiene alcuni valori molto elevati. Confronta ciò che descrivono media–deviazione standard e mediana–IQR.
7. Spiega la differenza tra deviazione standard e MAD. Perché il valore restituito da `mad()` in R non coincide, per impostazione predefinita, con la formula non scalata?
8. L'AI produce una tabella con media e deviazione standard ma non mostra il grafico né il numero dei mancanti. Scrivi una richiesta di revisione che renda il risultato interpretabile.

Soluzioni

1. Una distribuzione descrive quali valori compaiono e come le osservazioni si ripartiscono tra essi. La media rappresenta soltanto un punto di equilibrio e non mostra forma o dispersione.
2. Il secondo insieme ha deviazione standard maggiore. I valori sono più lontani dalla media 7, anche se il loro punto di equilibrio è lo stesso.
3. La media è 6. Gli scarti sono -2, 0, 2; i quadrati sono 4, 0, 4; la loro somma è 8. La varianza campionaria è $8 / (3 - 1) = 4$; la deviazione standard è $\sqrt{4} = 2$.
4. La media è il punto di equilibrio, quindi gli scarti negativi compensano quelli positivi. La loro media sarebbe sempre zero e non distinguerebbe una distribuzione compatta da una dispersa.
5. Sono giustificate b e c. La deviazione standard non definisce un intervallo obbligatorio e non trasforma automaticamente i valori distanti in errori.
6. Media e deviazione standard incorporano fortemente l'ampiezza dei valori elevati. Mediana e IQR descrivono posizione e metà centrale con minore influenza degli estremi. È utile riportare il grafico e, durante l'EDA, confrontare entrambe le coppie.
7. La deviazione standard usa scarti quadratici dalla media; il MAD usa distanze assolute dalla mediana. `mad()` moltiplica per impostazione predefinita il MAD grezzo per circa 1.4826, così da renderlo confrontabile con la deviazione standard sotto normalità. Per la formula non scalata si usa `constant = 1`.
8. La richiesta deve chiedere numerosità totale, valori osservati e mancanti, istogramma o altro grafico della distribuzione, confronto tra media e mediana e spiegazione dell'adeguatezza della deviazione standard alla forma osservata.

i Punti chiave

- La distribuzione descrive valori, frequenze, forma, posizione e dispersione.
- Media e mediana definiscono il centro in modi differenti.
- La media è il punto di equilibrio ed è sensibile all'ampiezza degli estremi.
- La mediana dipende dall'ordine ed è più robusta.
- Il range usa soltanto minimo e massimo.
- L'IQR descrive l'ampiezza della metà centrale.
- La deviazione standard è la radice della varianza ed è espressa nell'unità originale.
- La deviazione standard può essere letta come distanza quadratica tipica dalla media.
- Il MAD è una misura robusta basata sulla mediana.
- Nessun riassunto numerico sostituisce la forma della distribuzione.

i Ambiente di sviluppo

Il capitolo usa `dplyr` e `ggplot2`. Le informazioni sulla sessione possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
```

```
Platform: aarch64-apple-darwin23
```

```
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; LAPACK
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Zagreb
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
other attached packages:
```

```
[1] ggplot2_4.0.3 dplyr_1.2.1
```

```
loaded via a namespace (and not attached):
```

```
[1] vctrs_0.7.3      cli_3.6.6        knitr_1.51       rlang_1.3.0
[5] xfun_0.60        ote1_0.2.0       generics_0.1.4   S7_0.2.2
[9] jsonlite_2.0.0   labeling_0.4.3   glue_1.8.1       htmltools_0.5.9
[13] scales_1.4.0     rmarkdown_2.31  grid_4.6.1       evaluate_1.0.5
[17] tibble_3.3.1     fastmap_1.2.0   yaml_2.3.12      lifecycle_1.0.5
[21] compiler_4.6.1   RColorBrewer_1.1-3 pkgconfig_2.0.3  farver_2.1.2
[25] digest_0.6.39    R6_2.6.1         tidyselect_1.2.1 pillar_1.11.1
[29] magrittr_2.0.5   withr_3.0.3     tools_4.6.1      gtable_0.3.6
```

18. La normale come modello di riferimento

In sintesi

Da sapere Media e deviazione standard descrivono posizione e dispersione, ma non determinano la forma di una distribuzione. La distribuzione normale aggiunge una forma particolare: simmetrica, unimodale e con code che diminuiscono gradualmente. In EDA viene usata come riferimento da confrontare con i dati, non come forma che i dati devono obbligatoriamente rispettare.

Da saper fare Distinguere distribuzione osservata e modello normale; interpretare la regola 68–95–99,7 come proprietà condizionale alla normalità; confrontare un istogramma e un QQ-plot con il riferimento normale; descrivere in quale modo i dati si discostano dal modello senza ridurre la valutazione a un verdetto binario.

Introduzione

Nel capitolo precedente abbiamo visto che una distribuzione non è determinata soltanto dal suo centro e dalla sua dispersione. Due insiemi di valori possono avere la stessa media e la stessa deviazione standard e possedere forme differenti.

La distribuzione normale aggiunge precisamente ciò che mancava:

$$\text{distribuzione} = \text{posizione} + \text{dispersione} + \text{forma}.$$

Nella normale, la posizione è descritta dalla media μ , la dispersione dalla deviazione standard σ e la forma è simmetrica e unimodale.

Questa famiglia è già trattata nel modulo *Probabilità*, dove viene studiata come distribuzione di probabilità. Qui non ripeteremo densità, probabilità cumulative, normale standard o calcolo dei percentili. Ci interessa una funzione più circoscritta:

usare la normale come modello di riferimento per interpretare la deviazione standard e osservare come una distribuzione empirica se ne discosti.

Prerequisiti

Il capitolo presuppone Capitolo 17. Per una trattazione probabilistica completa della normale, si rimanda al modulo *utet-prob*.

Panoramica del capitolo

Vedremo anzitutto che media e deviazione standard determinano interamente una distribuzione normale. Useremo poi la regola 68–95–99,7 per rendere concreta l'interpretazione della deviazione standard. Infine confronteremo una distribuzione empirica con il modello attraverso un istogramma e un QQ-plot. Il test di normalità verrà discusso soltanto per chiarire perché non dovrebbe essere usato come interruttore automatico.

Preparazione del notebook

Gli esempi usano `ggplot2` e `dplyr`. Il dataset simulato comprende una variabile approssimativamente simmetrica e una variabile con asimmetria positiva, così da confrontare due forme differenti.

```
library(dplyr)
library(ggplot2)

set.seed(2026)

n <- 240

dati_normale <- data.frame(
  punteggio_simmetrico =
    rnorm(
      n,
      mean = 55,
      sd = 10
    ),
  tempo_asimmetrico =
    rlnorm(
      n,
      meanlog = 4.4,
      sdlog = .35
    )
)
```

18.1. Un modello definito da posizione e dispersione

Una distribuzione normale è simmetrica rispetto alla media e presenta un unico picco. La densità diminuisce gradualmente allontanandosi dal centro, senza raggiungere un limite netto.

La notazione:

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

si legge:

La variabile X è descritta da una distribuzione normale con media μ e varianza σ^2 .

La deviazione standard è σ . Conoscere μ e σ è sufficiente per determinare l'intera curva.

La media stabilisce dove si trova il centro. Modificando μ , la forma si sposta senza cambiare. La deviazione standard stabilisce l'ampiezza della distribuzione. Aumentando σ , i valori plausibili occupano una regione più larga e la curva diventa più bassa; diminuendola, la distribuzione si concentra maggiormente intorno alla media.

```
curve_normali <- data.frame(
  x = rep(
    seq(-5, 9, length.out = 600),
    times = 3
  ),
  modello = rep(
    c(
      "media 0, sd 1",
      "media 3, sd 1",
      "media 3, sd 2"
    ),
    each = 600
  )
) |>
mutate(
  densita = case_when(
    modello == "media 0, sd 1" ~
      dnorm(x, mean = 0, sd = 1),
    modello == "media 3, sd 1" ~
      dnorm(x, mean = 3, sd = 1),
    TRUE ~
      dnorm(x, mean = 3, sd = 2)
  )
)

ggplot(
  curve_normali,
  aes(
    x = x,
    y = densita,
    linetype = modello
  )
) +
  geom_line() +
  labs(
    x = "Valore",
    y = "Densità",
    linetype = NULL
  )
```




Figura 18.1.: Distribuzioni normali con posizione e dispersione differenti.

L'asse verticale rappresenta una densità, non un conteggio. Nel contesto EDA non serve approfondirne il calcolo: è sufficiente comprendere che la curva descrive come la probabilità viene distribuita lungo l'asse orizzontale.

18.2. La deviazione standard sotto normalità

Nel capitolo precedente abbiamo interpretato la deviazione standard come una distanza quadratica tipica dalla media. Questa interpretazione è generale e non richiede una distribuzione normale.

La normale permette però di aggiungere percentuali precise:

$$P(\mu - \sigma < X < \mu + \sigma) \approx 0.68,$$

$$P(\mu - 2\sigma < X < \mu + 2\sigma) \approx 0.95,$$

$$P(\mu - 3\sigma < X < \mu + 3\sigma) \approx 0.997.$$

In una distribuzione normale, circa il 68% dei valori si trova entro una deviazione standard dalla media, circa il 95% entro due e circa il 99,7% entro tre.

! Una proprietà della normale, non della deviazione standard

Le percentuali 68–95–99,7 non valgono per ogni distribuzione. Una variabile può avere media e deviazione standard perfettamente calcolabili ed essere molto asimmetrica, limitata, discreta o formata da più gruppi. In quei casi, gli intervalli $\bar{x} \pm s$, $\bar{x} \pm 2s$ e $\bar{x} \pm 3s$ non devono essere interpretati attraverso queste percentuali.

Supponiamo che un punteggio sia approssimativamente normale con:

$$\mu = 50, \quad \sigma = 10.$$

Ci aspettiamo allora circa il 68% dei valori tra 40 e 60, circa il 95% tra 30 e 70 e circa il 99,7% tra 20 e 80.

Questi intervalli non sono soglie cliniche né criteri automatici per individuare errori. Descrivono soltanto ciò che il modello normale prevede.

18.3. Il modello non coincide con i dati

Una curva normale è continua, regolare e perfettamente simmetrica. Una distribuzione empirica è formata da un numero finito di osservazioni e presenterà sempre irregolarità.

La domanda non può quindi essere:

I dati coincidono perfettamente con una normale?

Nessun campione reale coincide esattamente con una curva teorica. La domanda utile è:

Quali caratteristiche importanti dei dati vengono rappresentate bene dal modello normale e quali no?

Per iniziare possiamo sovrapporre all'istogramma la curva normale con la stessa media e la stessa deviazione standard dei dati.

```
media_osservata <-
  mean(
    dati_normale$punteggio_simmetrico
  )

sd_osservata <-
  sd(
    dati_normale$punteggio_simmetrico
  )

ggplot(
  dati_normale,
  aes(x = punteggio_simmetrico)
) +
  geom_histogram(
    aes(y = after_stat(density)),
    bins = 18
  ) +
  stat_function(
    fun = dnorm,
    args = list(
      mean = media_osservata,
      sd = sd_osservata
    )
  ) +
```

```
labs(
  x = "Punteggio",
  y = "Densità"
)
```




Figura 18.2.: Distribuzione empirica e curva normale con la stessa media e deviazione standard.

La sovrapposizione permette di osservare se il centro, la dispersione e la forma generale sono simili. Non costituisce una prova e dipende anche dalla scelta degli intervalli dell'istogramma.

Per questo il confronto deve essere accompagnato dalla lettura della distribuzione già sviluppata nei capitoli precedenti: simmetria, code, valori insoliti, limiti della scala e possibili sottogruppi.

18.4. Il QQ-plot come confronto tra posizioni

Il QQ-plot confronta i quantili osservati con quelli che avremmo sotto una distribuzione normale.

L'idea può essere espressa senza entrare nei dettagli del calcolo:

Ordina i valori osservati e confronta ciascuna posizione con la posizione corrispondente prevista dal modello normale.

Se il modello rappresenta bene la forma, i punti seguono approssimativamente una linea retta.

```
ggplot(
  dati_normale,
  aes(sample = punteggio_simmetrico)
) +
  geom_qq() +
  geom_qq_line() +
  labs(
```



```
x = "Quantili teorici della normale",
y = "Quantili osservati"
)
```




Figura 18.3.: QQ-plot di una variabile simulata con forma approssimativamente normale.

Il QQ-plot non deve essere letto cercando una coincidenza perfetta. Piccole oscillazioni sono previste in ogni campione. Ci interessano deviazioni sistematiche.

Una curvatura generale può indicare asimmetria. Un allontanamento marcato alle due estremità può indicare code più pesanti o più leggere rispetto alla normale. Pochi punti molto lontani possono segnalare osservazioni da controllare, senza dimostrare che siano errori.

Confrontiamo una distribuzione asimmetrica:

```
ggplot(
  dati_normale,
  aes(x = tempo_asimmetrico)
) +
  geom_histogram(
    bins = 20
  ) +
  labs(
    x = "Tempo",
    y = "Numero di osservazioni"
  )

ggplot(
  dati_normale,
  aes(sample = tempo_asimmetrico)
) +
  geom_qq() +
```

```
geom_qq_line() +
labs(
  x = "Quantili teorici della normale",
  y = "Quantili osservati"
)
```




Figura 18.4.: Istogramma e QQ-plot di una distribuzione con asimmetria positiva.




Figura 18.5.: Istogramma e QQ-plot di una distribuzione con asimmetria positiva.

L'istogramma mostra direttamente la coda destra. Nel QQ-plot, lo scostamento sistematico dalla linea rende visibile che la differenza non è soltanto una piccola irregolarità campionaria.

18.5. Descrivere la differenza, non emettere un verdetto

La normale è spesso trasformata in una classificazione:

normale / non normale.

Questa dicotomia perde l'informazione più utile. Due distribuzioni definite “non normali” possono differire per ragioni completamente diverse: una può essere moderatamente asimmetrica, un'altra possedere due picchi, un'altra ancora essere limitata da una scala con effetto soffitto.

Nell'EDA è più informativo descrivere **come** i dati differiscono dal riferimento:

La distribuzione è approssimativamente simmetrica nella regione centrale, ma presenta una coda destra più lunga di quella prevista dal modello normale.

oppure:

I punti del QQ-plot seguono la linea nella parte centrale e si allontanano alle estremità, suggerendo code più pesanti.

Queste descrizioni orientano le decisioni successive. Un'asimmetria può suggerire una diversa rappresentazione o un diverso modello; due picchi possono indicare sottogruppi; un limite superiore può riflettere la scala di misura.

18.6. I test di normalità non sono interruttori

Il test di Shapiro–Wilk confronta i dati con l'ipotesi di una distribuzione normale. Può essere utile in contesti specifici, ma non sostituisce l'ispezione della forma.

Con campioni piccoli, deviazioni importanti possono non essere rilevate. Con campioni grandi, differenze minime e irrilevanti possono produrre un valore- p molto piccolo.

Soprattutto, il test non spiega quale caratteristica generi la discrepanza.

Due interpretazioni da evitare

$p < .05$ non significa che i dati non possano essere analizzati.

$p > .05$ non dimostra che la distribuzione sia normale.

Il risultato riguarda la compatibilità con un'ipotesi formalizzata e dipende anche dalla numerosità campionaria. Nell'EDA dobbiamo osservare forma e conseguenze delle deviazioni.

Inoltre, molte tecniche statistiche non richiedono che la variabile osservata sia normale. Le assunzioni possono riguardare errori, residui o distribuzioni condizionate. La domanda sull'adeguatezza deve quindi essere posta nel contesto del modello effettivamente usato, non come rituale preliminare applicato a ogni colonna.

18.7. Quando il riferimento normale è utile

La normale è un riferimento utile quando la distribuzione è sostanzialmente unimodale, abbastanza simmetrica e priva di code o limiti che rendano il modello chiaramente inadeguato.

In questa situazione, media e deviazione standard acquistano un'interpretazione particolarmente ricca: non descrivono soltanto centro e dispersione, ma permettono di ricostruire approssimativamente la posizione della maggior parte dei valori.

Quando la forma è molto diversa, non dobbiamo “correggere” automaticamente i dati per renderli normali. Possiamo descrivere la distribuzione con mediana e IQR, usare una trasformazione motivata oppure scegliere un modello più adatto alla natura della variabile.

La decisione dipende dallo scopo. Una distribuzione moderatamente asimmetrica può essere descritta adeguatamente senza alcuna trasformazione; la stessa asimmetria può diventare rilevante in un modello che attribuisce molta importanza alle code.

18.8. Usare l'AI per confrontare dati e modello

Una richiesta generica come «verifica se i dati sono normali» invita l'assistente a produrre un test e un verdetto.

È più utile chiedere un confronto descrittivo.

Un prompt per il confronto con la normale

Ho una variabile numerica chiamata punteggio, con una riga per partecipante. Prima conta valori osservati e mancanti e descrivi intervallo, media, mediana e deviazione standard.

Produci poi un istogramma con una curva normale avente la stessa media e deviazione standard e un QQ-plot. Descrivi separatamente centro, simmetria, code e osservazioni insolite.

Non classificare la distribuzione soltanto come normale o non normale. Non usare il test di Shapiro–Wilk come unico criterio e non proporre trasformazioni prima di avere spiegato quale discrepanza dovrebbero affrontare.

L'AI può costruire i grafici e proporre una prima descrizione. Il ricercatore deve controllare che la variabile, il campione e i valori mancanti siano quelli corretti e che le conclusioni non vadano oltre ciò che le figure mostrano.

18.9. Il collegamento con i modelli

Nel seguito del percorso, la normale potrà rappresentare una distribuzione di osservazioni, una componente di errore o una distribuzione su quantità incerte.

Qui è sufficiente trattenere un principio:

scegliere una distribuzione significa proporre una forma per la variabilità.

La scelta non viene convalidata dal nome del modello. Deve essere confrontata con i dati e con il processo che li ha generati.

Questa prospettiva prepara il passaggio ai controlli predittivi sviluppati nel manuale e nel Companion, senza anticiparne la trattazione tecnica.

Riflessioni conclusive

La distribuzione normale non viene ripetuta qui come capitolo di probabilità. Viene usata come modello di riferimento per completare il significato della deviazione standard e per imparare a confrontare dati osservati e forme teoriche.

Media e deviazione standard determinano interamente una normale. Soltanto sotto questa forma possiamo interpretare gli intervalli di una, due e tre deviazioni standard attraverso la regola 68–95–99,7.

Istogramma e QQ-plot permettono di osservare in quale modo una distribuzione empirica sia simile o diversa dal riferimento. La domanda utile non è se i dati siano perfettamente normali, ma quali discrepanze esistano e se siano rilevanti per lo scopo dell'analisi.

I test di normalità non sostituiscono questo giudizio. La normale rimane un modello: può essere utile, approssimativo oppure inadeguato. L'EDA deve rendere visibile quale di queste situazioni sia più plausibile.

Esercizi

1. Spiega perché media e deviazione standard non determinano la forma di una distribuzione in generale, ma determinano completamente una distribuzione normale.
2. Una variabile ha media 40 e deviazione standard 5. Assumendo un modello normale, calcola gli intervalli che dovrebbero contenere circa il 68%, il 95% e il 99,7% dei valori.
3. Perché la regola 68–95–99,7 non può essere applicata automaticamente a una distribuzione fortemente asimmetrica?
4. Un istogramma appare abbastanza simmetrico, ma il QQ-plot mostra scostamenti alle estremità. Formula una descrizione che eviti il verdetto “normale/non normale”.
5. Il test di Shapiro–Wilk produce $p < .001$ in un campione di 20.000 persone. Perché questo risultato non basta a stabilire che il modello normale sia inutilizzabile?
6. Una scala psicologica da 1 a 5 presenta un forte effetto soffitto. Quale caratteristica del modello normale è incompatibile con questa distribuzione?
7. Confronta z-score e percentile normale. Quale dei due richiede un'ipotesi sulla forma della distribuzione?
8. Formula un prompt che chieda all'AI di confrontare una variabile con il modello normale senza emettere un verdetto binario e senza proporre trasformazioni automatiche.

Soluzioni

1. Media e deviazione standard descrivono soltanto posizione e dispersione. Distribuzioni con forme differenti possono condividere questi due valori. Nella famiglia normale,

invece, la forma è fissata e i due parametri determinano posizione e ampiezza della curva.

2. Gli intervalli sono 35–45, 30–50 e 25–55.
3. Le percentuali derivano dalla forma normale. In una distribuzione asimmetrica, la quantità di valori sotto e sopra la media può essere molto diversa e le code possono occupare regioni non previste dalla regola.
4. Una formulazione appropriata è: «La regione centrale è abbastanza coerente con il riferimento normale, mentre le code mostrano deviazioni sistematiche, suggerendo una frequenza di valori estremi diversa da quella prevista dal modello».
5. Con campioni molto grandi il test rileva anche discrepanze minime. Occorre osservare la forma della deviazione e valutare se abbia conseguenze sostanziali per lo scopo e per il modello utilizzato.
6. La normale è continua, simmetrica e non possiede limiti rigidi. Una scala con molte osservazioni al massimo è discreta, limitata e asimmetrica.
7. Lo z-score esprime una distanza in unità di deviazione standard e non richiede normalità. Il percentile normale richiede l'adozione della distribuzione normale come modello.
8. Il prompt deve chiedere numerosità e mancanti, descrizione della distribuzione, istogramma con riferimento normale, QQ-plot e una lettura separata di centro, simmetria e code. Deve vietare l'uso del solo test di normalità come criterio.

i Punti chiave

- La normale è un modello di forma, non una legge che i dati devono rispettare.
- Media e deviazione standard determinano completamente una distribuzione normale.
- La regola 68–95–99,7 è condizionale alla forma normale.
- Lo z-score non richiede normalità; il percentile normale sì.
- L'istogramma confronta la forma generale con il riferimento.
- Il QQ-plot confronta posizioni osservate e posizioni previste.
- Le deviazioni devono essere descritte, non ridotte a un verdetto binario.
- Il test di normalità dipende dalla numerosità e non identifica la natura della discrepanza.
- Non ogni analisi richiede che la variabile osservata sia normale.
- L'AI può produrre confronti, ma non deve trasformare la normalità in un rituale automatico.

i Ambiente di sviluppo

Il capitolo usa dplyr e ggplot2. Le informazioni sulla sessione possono essere ottenute con:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
```

```
Platform: aarch64-apple-darwin23
```

```
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; LAPACK
```

```

locale:
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8

time zone: Europe/Zagreb
tzcode source: internal

attached base packages:
[1] stats      graphics  grDevices  utils      datasets  methods    base

other attached packages:
[1] ggplot2_4.0.3 dplyr_1.2.1

loaded via a namespace (and not attached):
 [1] vctrs_0.7.3      cli_3.6.6        knitr_1.51       rlang_1.3.0
 [5] xfun_0.60        otel_0.2.0       generics_0.1.4   S7_0.2.2
 [9] jsonlite_2.0.0   labeling_0.4.3   glue_1.8.1       htmltools_0.5.9
[13] scales_1.4.0     rmarkdown_2.31   grid_4.6.1       evaluate_1.0.5
[17] tibble_3.3.1     fastmap_1.2.0    yaml_2.3.12      lifecycle_1.0.5
[21] compiler_4.6.1   RColorBrewer_1.1-3 pkgconfig_2.0.3  farver_2.1.2
[25] digest_0.6.39    R6_2.6.1         tidyselect_1.2.1 pillar_1.11.1
[29] magrittr_2.0.5   withr_3.0.3      tools_4.6.1      gtable_0.3.6

```

19. Esplorare relazioni tra due variabili

In sintesi

Da sapere Una relazione tra due variabili riguarda il modo in cui le loro osservazioni sono accoppiate. Lo scatterplot rende visibile questa distribuzione congiunta. La correlazione di Pearson ne riassume soltanto la componente lineare; non descrive ogni possibile relazione e non possiede, da sola, un significato causale.

Da saper fare Controllare quali coppie di valori entrano nell'analisi; leggere direzione, forma, dispersione e osservazioni influenti nello scatterplot; interpretare la correlazione come concordanza tra valori standardizzati; riconoscere relazioni non lineari, sottogruppi e restrizioni dell'intervallo; formulare conclusioni riferite all'associazione osservata.

Introduzione

L'analisi univariata descrive una variabile alla volta. Quando passiamo a due variabili, la domanda cambia. Non ci interessa più soltanto quali valori compaiano, ma **come i valori delle due misure siano accoppiati nelle stesse unità di analisi**.

Se ogni riga rappresenta uno studente, la coppia formata da stress e ore di sonno appartiene alla stessa persona. Scambiare tra loro i valori di sonno lascerebbe inalterate le due distribuzioni univariate, ma cambierebbe completamente la relazione.

L'oggetto dell'analisi bivariata è quindi la **distribuzione congiunta osservata**.

La teoria probabilistica di covarianza e correlazione è già sviluppata nel capitolo [Covarianza e correlazione](#) del modulo *utet-prob*. Qui useremo quei concetti in una funzione diversa: leggere criticamente una relazione nei dati.

Anche la causalità rimane fuori dallo scopo del capitolo. Il Companion distingue sistematicamente associazione, previsione ed effetto causale. In questa sede la domanda è soltanto:

Come variano insieme due misure nel campione osservato?

Prerequisiti

È necessario avere compreso distribuzione e deviazione standard in Capitolo 17 e i principi della visualizzazione in Capitolo 16. Il capitolo successivo chiarirà il confine tra descrizione associativa e domanda causale.

Panoramica del capitolo

Cominceremo dalle coppie osservate e dallo scatterplot. La correlazione di Pearson verrà poi collegata agli scarti standardizzati, senza ripetere la teoria probabilistica. Vedremo infine perché un solo coefficiente può nascondere curvature, punti influenti, sottogruppi, intervalli ristretti e dati mancanti. La correlazione di Spearman verrà introdotta come descrizione di un andamento monotono basata sui ranghi, non come rimedio generico alla non normalità.

i Preparazione del notebook

Il dataset simulato contiene una riga per studente. Stress e sonno sono costruiti in modo da mostrare un'associazione negativa imperfetta; alcuni valori mancanti ricordano che la relazione può essere calcolata soltanto sulle coppie complete.

```

library(dplyr)
library(ggplot2)

set.seed(2026)

n <- 140

studenti <- data.frame(
  id = seq_len(n),
  stress = round(
    pmin(
      pmax(
        rnorm(n, mean = 6, sd = 1.7),
        1
      ),
      10
    ),
    1
  )
)

studenti$sonno_ore <- round(
  9.2 -
    0.38 * studenti$stress +
    rnorm(n, mean = 0, sd = .85),
  1
)

studenti$anno <- factor(
  sample(
    c("primo", "secondo", "terzo"),
    n,
    replace = TRUE
  )
)

studenti$stress[c(12, 87)] <- NA
studenti$sonno_ore[c(31, 109, 133)] <- NA

```

19.1. La relazione dipende dall'accoppiamento

Consideriamo due brevi sequenze:

```

x <- c(1, 2, 3, 4, 5)
y_crescente <- c(2, 4, 5, 7, 9)
y_decrescente <- rev(y_crescente)

data.frame(
  x = x,

```

```

y_crescente = y_crescente,
y_decrecente = y_decrecente
)

```

	x	y_crescente	y_decrecente
1	1	2	9
2	2	4	7
3	3	5	5
4	4	7	4
5	5	9	2

`y_crescente` e `y_decrecente` contengono esattamente gli stessi valori. Hanno quindi la stessa media, la stessa deviazione standard e lo stesso istogramma. Cambia soltanto il modo in cui vengono accoppiati con `x`.

```

c(
  crescente =
    cor(x, y_crescente),
  decrecente =
    cor(x, y_decrecente)
)

```

```

crescente decrecente
0.9948498  -0.9948498

```

La relazione non appartiene alle due colonne considerate separatamente. Appartiene alle coppie:

$$(x_1, y_1), \dots, (x_n, y_n).$$

Questo è il motivo per cui l'unità di analisi e l'allineamento delle righe sono fondamentali. Un errore di ordinamento o di unione tra tabelle può produrre una correlazione priva di significato anche quando le distribuzioni marginali sembrano corrette.

19.2. Prima del coefficiente: quali coppie entrano?

Per descrivere stress e sonno dobbiamo sapere quante osservazioni possiedono entrambe le misure.

```

studenti |>
  summarise(
    n_totale = n(),
    stress_osservato =
      sum(!is.na(stress)),
    sonno_osservato =
      sum(!is.na(sonno_ore)),
    coppie_complete =
      sum(
        complete.cases(

```

```
        stress,  
        sonno_ore  
      )  
    )  
  )
```

```
  n_totale stress_osservato sonno_osservato coppie_complete  
1      140             138             137             135
```

La media dello stress può usare un insieme di studenti, la media del sonno un altro e la correlazione soltanto la loro intersezione. Il coefficiente non descrive automaticamente l'intero campione reclutato.

La prima frase di un report bivariato dovrebbe quindi dichiarare il numero di coppie complete. Se la perdita è consistente, occorre chiedersi chi rimanga escluso prima di interpretare la relazione.

19.3. Lo scatterplot rappresenta la distribuzione congiunta

Ogni punto dello scatterplot rappresenta una coppia di valori appartenente alla stessa unità.

```
ggplot(  
  studenti,  
  aes(  
    x = stress,  
    y = sonno_ore  
  )  
) +  
  geom_point(  
    alpha = .65,  
    na.rm = TRUE  
  ) +  
  geom_smooth(  
    method = "lm",  
    se = FALSE,  
    na.rm = TRUE  
  ) +  
  labs(  
    x = "Punteggio di stress",  
    y = "Ore di sonno"  
  )  
)
```




Figura 19.1.: Relazione osservata tra stress e ore di sonno. Ogni punto rappresenta uno studente con entrambe le misure disponibili.

Il grafico permette di leggere quattro aspetti collegati.

La **direzione** indica se valori più alti di una variabile tendano ad accompagnarsi a valori più alti o più bassi dell'altra.

La **forma** indica se l'andamento possa essere riassunto approssimativamente da una linea retta oppure presenti curvature, soglie o cambiamenti di direzione.

La **dispersione** indica quanto le osservazioni siano vicine a una tendenza comune. Anche in presenza di un andamento visibile, persone con lo stesso livello di stress possono dormire quantità molto differenti.

Le **discrepanze locali** comprendono punti isolati, vuoti, accumuli e possibili sottogruppi. Queste caratteristiche possono avere un significato sostantivo o segnalare problemi di misura e preparazione.

La linea non costituisce una spiegazione. È soltanto un riassunto lineare della nuvola di punti.

19.4. La covarianza come concordanza degli scarti

La covarianza campionaria è:

$$s_{XY} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

La formula confronta gli scarti delle due variabili dalle rispettive medie.

Se una persona è sopra la media in entrambe le variabili, il prodotto degli scarti è positivo. È positivo anche quando entrambi gli scarti sono negativi. Se una variabile è sopra la media e l'altra sotto, il prodotto è negativo.

La covarianza è quindi positiva quando le osservazioni tendono a collocarsi dallo stesso lato delle due medie e negativa quando tendono a collocarsi su lati opposti.

```
studenti |>
  summarise(
    covarianza =
      cov(
        stress,
        sonno_ore,
        use = "complete.obs"
      )
  )
```

```
covarianza
1 -1.071987
```

Il valore numerico dipende dalle unità. Cambiare le ore in minuti moltiplicherebbe la covarianza, pur lasciando invariata la struttura della relazione.

19.5. La correlazione standardizza la covarianza

La correlazione di Pearson è:

$$r = \frac{s_{XY}}{s_X s_Y}.$$

Dividere per le due deviazioni standard rimuove le unità di misura. Il coefficiente è compreso tra -1 e 1 .

Possiamo leggerlo anche attraverso gli z-score:

$$r = \frac{1}{n-1} \sum_{i=1}^n z_{Xi} z_{Yi}.$$

La correlazione è quindi la media corretta dei prodotti tra le posizioni standardizzate delle due variabili. Un valore positivo nasce quando punteggi relativamente alti si accompagnano ad altri punteggi relativamente alti, e punteggi relativamente bassi ad altri punteggi relativamente bassi. Un valore negativo nasce da posizioni opposte.

```
studenti |>
  summarise(
    n =
      sum(
        complete.cases(
          stress,
          sonno_ore
        )
      ),
    r =
```

```
cor(
  stress,
  sonno_ore,
  use = "complete.obs"
)
```

```
      n      r
1 135 -0.629458
```

Il segno descrive la direzione lineare. Il valore assoluto descrive quanto strettamente i punti seguano una linea, non quanto sia importante il fenomeno e non quanto sia grande un effetto causale.

! La correlazione è una sintesi della relazione lineare osservata

$r = 0$ significa assenza di una componente lineare netta nel campione. Non significa indipendenza, assenza di ogni relazione o assenza di rilevanza psicologica.

19.6. Non esistono soglie universali

Etichette come “piccola”, “media” e “grande” possono essere utili in contesti specifici, ma non possiedono un significato universale.

Una correlazione modesta può essere importante quando la misura è rumorosa, il fenomeno è influenzato da molte cause o l’esito ha conseguenze rilevanti. Una correlazione elevata può derivare da costrutti quasi sovrapposti, da un ristretto processo di selezione o da una componente comune del metodo di misura.

L’interpretazione richiede quindi teoria, qualità della misura, intervallo dei valori e popolazione campionata. Il coefficiente deve essere riportato insieme al grafico e alla numerosità.

19.7. Pearson può nascondere la forma

Consideriamo una relazione a U:

```
set.seed(47)

relazione_u <- data.frame(
  attivazione =
    seq(-3, 3, length.out = 130)
)

relazione_u$prestazione <-
  9 -
  relazione_u$attivazione^2 +
  rnorm(130, mean = 0, sd = .65)

cor(
```

19. Esplorare relazioni tra due variabili

```
relazione_u$attivazione,  
relazione_u$prestazione  
)
```

```
[1] 0.02643262
```

```
ggplot(  
  relazione_u,  
  aes(  
    x = attivazione,  
    y = prestazione  
  )  
) +  
  geom_point(  
    alpha = .65  
  ) +  
  geom_smooth(  
    se = FALSE  
  ) +  
  labs(  
    x = "Attivazione",  
    y = "Prestazione"  
  )  
)
```




Figura 19.2.: Una relazione evidente può avere correlazione lineare vicina a zero.

Il coefficiente è vicino a zero perché la tendenza crescente in una parte dell'intervallo compensa quella decrescente nell'altra. Il grafico mostra invece una struttura regolare.

Non dobbiamo cercare un coefficiente alternativo finché non abbiamo descritto la forma. Una relazione a U non è monotona e non viene riassunta adeguatamente neppure dalla correlazione di Spearman.

19.8. La correlazione di Spearman descrive l'ordine monotono

La correlazione di Spearman applica il coefficiente di Pearson ai ranghi dei valori.

```
studenti |>
  summarise(
    rho =
      cor(
        stress,
        sonno_ore,
        method = "spearman",
        use = "complete.obs"
      )
  )
```

```
      rho
1 -0.6186075
```

È utile quando le variabili hanno un significato prevalentemente ordinale o quando la relazione è monotona ma non ben rappresentata da una linea retta. Una relazione è monotona se, al crescere di una variabile, l'altra tende sempre nella stessa direzione, anche con velocità diversa.

Spearman non deve essere scelto semplicemente perché una variabile “non è normale”. La normalità delle distribuzioni marginali non è ciò che distingue concettualmente Pearson da Spearman in un'analisi descrittiva.

19.9. Un punto può cambiare il riassunto

In campioni piccoli, una singola osservazione lontana dalle altre può creare, rafforzare, indebolire o invertire una correlazione.

La prima domanda non è se il punto debba essere eliminato, ma se sia valido e da quale processo provenga. Se è un errore confermato, si torna alla pulizia. Se è un caso reale, fa parte della distribuzione e la sensibilità del coefficiente deve essere resa visibile.

Un confronto trasparente può riportare il coefficiente con tutti i casi e, come analisi di sensibilità, il valore ottenuto senza l'osservazione influente. La seconda analisi non autorizza automaticamente l'esclusione; mostra quanto il riassunto dipenda dal caso.

19.10. I sottogruppi possono modificare la relazione

Un'associazione complessiva può combinare gruppi con livelli medi e relazioni interne differenti. Per esempio, una nuvola di punti può riflettere anni di corso, contesti clinici o strumenti di misura diversi.

Colorare o separare il grafico secondo una variabile prevista dal disegno può rendere visibile questa struttura:

19. Esplorare relazioni tra due variabili

```
ggplot(
  studenti,
  aes(
    x = stress,
    y = sonno_ore
  )
) +
  geom_point(
    alpha = .6,
    na.rm = TRUE
  ) +
  facet_wrap(
    ~ anno
  ) +
  labs(
    x = "Punteggio di stress",
    y = "Ore di sonno"
  )
)
```




Figura 19.3.: La stessa relazione osservata separata per anno di corso.

Non dobbiamo però cercare sottogruppi arbitrari fino a trovare una storia interessante. La variabile di stratificazione deve provenire dal disegno, dalla teoria o da una discrepanza concreta osservata nei dati.

Il significato causale dell'aggregazione e del condizionamento verrà affrontato nel Companion. Qui il punto è descrittivo: un solo coefficiente può riassumere male dati eterogenei.

19.11. L'intervallo osservato influenza la correlazione

Una correlazione descrive la relazione nel campione disponibile. Se selezioniamo soltanto una regione ristretta della variabile, il coefficiente può diminuire perché rimane poca variazione da associare.

La correlazione tra abilità e prestazione osservata in tutta la popolazione può essere più elevata di quella osservata soltanto tra studenti già selezionati per alta abilità. Questo fenomeno è chiamato **restrizione dell'intervallo**.

Di conseguenza, non è corretto trattare la correlazione come una proprietà immutabile di due costrutti. Dipende dalla popolazione, dal campionamento, dalle misure e dall'intervallo effettivamente osservato.

19.12. La misura limita la relazione osservata

L'errore di misurazione e gli effetti pavimento o soffitto possono ridurre o deformare la correlazione.

Se una scala assegna quasi a tutti lo stesso punteggio, non rimane variabilità sufficiente per osservare come la misura cambi insieme a un'altra variabile. Se due questionari condividono formulazione, metodo di risposta o desiderabilità sociale, una parte della correlazione può riflettere il metodo comune più che i costrutti.

L'interpretazione deve quindi tornare alla validità delle misure discussa in Capitolo 4. La precisione del coefficiente numerico non compensa una definizione debole delle variabili.

19.13. Una procedura EDA bivariata

Il percorso può essere riassunto senza trasformarlo in una checklist meccanica.

Prima definiamo l'unità e le due variabili. Poi contiamo le coppie complete e osserviamo separatamente le distribuzioni marginali. Costruiamo lo scatterplot e descriviamo direzione, forma, dispersione e discrepanze. Soltanto a questo punto calcoliamo un coefficiente coerente con la struttura osservata. Infine controlliamo sensibilità a casi influenti, sottogruppi previsti e restrizione dell'intervallo.

coppie valide → grafico → forma → coefficiente → controlli.

Il coefficiente conclude una lettura, non la sostituisce.

19.14. Scrivere il risultato

Una formulazione appropriata potrebbe essere:

Nel campione, 135 studenti possiedono entrambe le misure. Lo scatterplot mostra un andamento approssimativamente lineare negativo, con considerevole sovrapposizione e senza una curvatura evidente. La correlazione di Pearson è negativa. Gli studenti con punteggi di stress più elevati tendono quindi a riportare meno ore di sonno, ma la relazione presenta ampia variabilità individuale.

Questa frase descrive la distribuzione osservata. Non afferma che lo stress riduca il sonno, che il sonno riduca lo stress o che una terza variabile non contribuisca alla relazione.

19.15. Usare l'AI senza ridurre la relazione a un numero

Un prompt per l'EDA bivariata

Ho un data frame `studenti`, con una riga per studente. Voglio descrivere la relazione osservata tra `stress` e `sonno_ore`.

Conta prima le coppie complete e mostra le distribuzioni marginali. Produci poi uno scatterplot con una linea lineare usata soltanto come riassunto descrittivo.

Descrivi direzione, forma, dispersione, punti influenti e possibili sottogruppi prima di calcolare Pearson. Calcola Spearman soltanto come confronto dell'ordine monotono e non perché le variabili non sono normali.

Mantieni il linguaggio associativo e segnala quali conclusioni causali non sono giustificate.

Dopo avere ricevuto il codice, dobbiamo verificare che le righe siano correttamente accoppiate, che il trattamento dei mancanti sia visibile e che nessun filtro abbia ristretto silenziosamente l'intervallo.

Riflessioni conclusive

Una relazione bivariata appartiene alle coppie di valori osservate. Lo scatterplot è la rappresentazione primaria della distribuzione congiunta e deve precedere il coefficiente.

La covarianza descrive la concordanza degli scarti dalle medie. La correlazione di Pearson standardizza questa quantità e riassume la componente lineare su una scala da -1 a 1 . Spearman descrive invece la concordanza dei ranghi in un andamento monotono.

Nessuno dei due coefficienti rappresenta curvature, sottogruppi, valori influenti o processi di selezione. Il loro valore dipende inoltre dall'intervallo osservato e dalla qualità delle misure.

L'EDA bivariata termina con una descrizione dell'associazione nel campione. Il passaggio verso previsione, effetto causale o spiegazione richiede domande e condizioni ulteriori, sviluppate nel Companion.

Esercizi

1. Spiega perché due variabili possono conservare le stesse distribuzioni univariate ma cambiare correlazione quando i valori vengono riaccoppiati.
2. Costruisci lo scatterplot di `stress` e `sonno_ore`. Descrivi direzione, forma e dispersione prima di calcolare il coefficiente.
3. Spiega la formula di Pearson usando i prodotti tra z-score. Che cosa rende positivo o negativo un singolo contributo?
4. Costruisci una relazione a U e mostra perché Pearson e Spearman possono entrambi essere vicini a zero nonostante un pattern evidente.
5. Un coefficiente cambia da $-.55$ a $-.12$ dopo avere rimosso un punto. Quali verifiche sono necessarie prima di decidere se escluderlo?

6. Perché Spearman non è una soluzione automatica quando una distribuzione marginale è asimmetrica?
7. Descrivi due modi in cui la restrizione dell'intervallo o l'errore di misura possono modificare una correlazione.
8. Formula un prompt che chieda all'AI di controllare una relazione bivariata senza interpretarla causalmente.

Soluzioni

1. Media, deviazione standard e istogrammi dipendono dai valori presenti in ciascuna colonna. La correlazione dipende invece da quali valori compaiono nella stessa riga.
2. La risposta deve partire dal grafico e indicare se l'andamento sia crescente o decrescente, lineare o curvo e quanto i punti siano dispersi.
3. Prodotti positivi derivano da due z-score con lo stesso segno; prodotti negativi da segni opposti. La media corretta di questi prodotti determina direzione e forza lineare.
4. In una relazione a U, la parte crescente e quella decrescente si compensano. Poiché l'andamento non è monotono, anche l'ordinamento non procede sempre nella stessa direzione.
5. Occorre verificare la fonte, la plausibilità e la correttezza della riga; esaminare se il caso appartenga alla popolazione di interesse; riportare la sensibilità senza trasformarla automaticamente in criterio di esclusione.
6. Spearman risponde a una domanda sui ranghi e sugli andamenti monotoni. L'asimmetria di una singola variabile non implica che Pearson sia concettualmente inappropriato.
7. Un intervallo ristretto riduce la variabilità disponibile; l'errore di misura aggiunge variazione non condivisa o metodo comune. Entrambi possono modificare il coefficiente osservato.
8. Il prompt deve specificare unità, variabili e coppie complete; chiedere grafico e descrizione della forma; rendere visibili filtri e mancanti; vietare linguaggio causale.

Punti chiave

- La relazione appartiene alle coppie, non alle colonne considerate separatamente.
- Lo scatterplot rappresenta la distribuzione congiunta osservata.
- Pearson riassume la componente lineare.
- La correlazione può essere letta come concordanza tra z-score.
- Un valore vicino a zero non esclude relazioni non lineari.
- Spearman riguarda ranghi e monotonia, non la normalità marginale.
- Punti influenti e sottogruppi devono essere resi visibili.
- Restrizione dell'intervallo e qualità della misura modificano il coefficiente.
- La correlazione descrive il campione e non possiede da sola significato causale.
- Il coefficiente conclude l'EDA bivariata; non sostituisce il grafico.

i Ambiente di sviluppo

Il capitolo usa dplyr e ggplot2.

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
```

```
Platform: aarch64-apple-darwin23
```

```
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; LAPACK
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Zagreb
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
other attached packages:
```

```
[1] ggplot2_4.0.3 dplyr_1.2.1
```

```
loaded via a namespace (and not attached):
```

```
[1] vctrs_0.7.3      nlme_3.1-170      cli_3.6.6          knitr_1.51
[5] rlang_1.3.0      xfun_0.60         otel_0.2.0         generics_0.1.4
[9] S7_0.2.2         jsonlite_2.0.0    labeling_0.4.3     glue_1.8.1
[13] htmltools_0.5.9  scales_1.4.0      rmarkdown_2.31     grid_4.6.1
[17] evaluate_1.0.5   tibble_3.3.1      fastmap_1.2.0      yaml_2.3.12
[21] lifecycle_1.0.5  compiler_4.6.1    RColorBrewer_1.1-3
[25] pkgconfig_2.0.3  mgcv_1.9-4        lattice_0.22-9     farver_2.1.2       digest_0.6.39
[29] R6_2.6.1         tidyselect_1.2.1  splines_4.6.1      pillar_1.11.1
[33] magrittr_2.0.5   Matrix_1.7-6      withr_3.0.3        tools_4.6.1
[37] gtable_0.3.6
```

20. Dall'associazione alla domanda causale

In sintesi

Da sapere L'EDA descrive distribuzioni e associazioni osservate. Una domanda causale chiede invece che cosa cambierebbe sotto un intervento alternativo. Il passaggio non dipende dall'aggiunta di un coefficiente o di una covariata, ma dal disegno e dalle assunzioni che permettono di identificare il confronto causale.

Da saper fare Distinguere descrizione, previsione ed effetto causale; riconoscere quando il linguaggio eccede i dati; trasformare una vaga affermazione causale in una domanda che specifichi intervento, alternativa, esito, tempo e popolazione; spiegare che cosa l'EDA può controllare e che cosa richiede il percorso causale del Companion.

Introduzione

Nel capitolo precedente abbiamo descritto come due variabili varino insieme. Una relazione osservata può essere scientificamente importante, ma non risponde automaticamente alla domanda su ciò che accadrebbe modificando una delle variabili.

Se gli studenti con maggiore stress dormono meno, i dati sono compatibili con molte storie. Lo stress può ridurre il sonno; il sonno insufficiente può aumentare lo stress; il periodo degli esami può influenzare entrambi; la partecipazione allo studio può selezionare combinazioni particolari di studenti.

L'EDA permette di vedere la relazione. Non sceglie da sola quale storia sia corretta.

Il Companion dedica un intero percorso a questa distinzione. Il capitolo *Associazione, previsione ed effetto causale* separa i tre obiettivi; *Definire un effetto causale* formalizza interventi, esiti potenziali ed estimand; *Identificare effetti causali nei dati osservazionali* sviluppa DAG e strategie di identificazione.

Questo capitolo non ripete quei contenuti. Ha una funzione di confine:

insegnare dove termina una descrizione EDA e quale domanda deve essere formulata prima di entrare nell'inferenza causale.

Prerequisiti

È necessario avere letto Capitolo 3 e Capitolo 19. Il contenuto qui presentato è soltanto una preparazione al percorso causale del Companion.

Panoramica del capitolo

Distingueremo anzitutto descrizione, previsione e causalità. Vedremo poi come rendere precisa una domanda di intervento e perché associazione osservata ed effetto causale sono quantità differenti. La parte centrale chiarirà il ruolo limitato ma importante dell'EDA: controllare dati, sequenza temporale, composizione dei gruppi e incoerenze con il disegno, senza pretendere di identificare automaticamente l'effetto. Concluderemo con un protocollo linguistico e con richieste appropriate all'AI.

20.1. La stessa formula può rispondere a domande diverse

Una regressione o una correlazione possono comparire in analisi con finalità differenti. Il significato non è stabilito dal software.

Obiettivo	Domanda	Criterio principale
Descrizione associativa	Come differisce Y tra unità con valori diversi di X ?	Adeguatezza alla distribuzione osservata
Previsione	Quale valore di Y è plausibile per una nuova unità?	Prestazione su dati nuovi pertinenti
Effetto causale	Come cambierebbe Y se intervenissimo su X ?	Disegno e identificazione
Spiegazione del processo	Quale meccanismo produce il cambiamento?	Teoria processuale e controlli discriminanti

Questi obiettivi non formano una scala nella quale uno sia sempre superiore. Un'analisi può descrivere bene un'associazione senza prevedere accuratamente nuovi casi. Può prevedere bene usando segnali che non sono cause manipolabili. Un esperimento può identificare un effetto senza spiegare il meccanismo che lo produce.

La prima decisione deve quindi riguardare la domanda, non il metodo.

20.2. La domanda associativa riguarda persone osservate

Una quantità associativa confronta ciò che vediamo nei dati.

Per un'esposizione binaria A , una differenza descrittiva elementare è:

$$\Delta_{\text{ass}} = E(Y \mid A = 1) - E(Y \mid A = 0).$$

La formula confronta l'esito medio delle persone osservate nei due gruppi. Se chi riceve il trattamento presenta una gravità iniziale maggiore, una diversa motivazione o un diverso accesso alle cure, tali differenze fanno parte del confronto.

L'associazione può essere importante. Può descrivere disuguaglianze, individuare gruppi con bisogni differenti, generare ipotesi e contribuire alla previsione.

Il problema nasce soltanto quando la descrizione viene trasformata in un'affermazione su ciò che il trattamento **produce**.

20.3. La domanda causale richiede un intervento

Una formulazione come:

Qual è l'effetto del sonno sull'ansia?

è troppo vaga per definire un effetto.

Dobbiamo precisare che cosa significhi intervenire sul sonno, quale alternativa venga confrontata, quale esito venga misurato, quando venga misurato e in quale popolazione.

Una domanda più precisa è:

Negli studenti universitari che dormono abitualmente meno di sei ore, quale sarebbe la differenza media nell'ansia di stato dopo quattro settimane tra un intervento che aumenta il sonno a sette ore per notte e il mantenimento delle abitudini correnti?

La precisione non è un dettaglio stilistico. Definisce i due scenari da confrontare.

Nel linguaggio dei potenziali esiti, l'effetto medio può essere scritto:

$$\tau_{ATE} = E[Y(1) - Y(0)].$$

$Y(1)$ rappresenta l'esito sotto un intervento e $Y(0)$ l'esito sotto l'alternativa. La formula confronta due scenari riferiti alla stessa popolazione, non semplicemente due gruppi diversi già presenti nel dataset.

La formalizzazione completa è sviluppata nel Companion. Qui è sufficiente comprendere che:

$$E(Y | A = 1) - E(Y | A = 0) \neq E[Y(1) - Y(0)]$$

in generale.

20.4. Perché l'associazione e l'effetto possono differire

Supponiamo che gli studenti più ansiosi scelgano più spesso un corso di rilassamento. Dopo il corso, il gruppo partecipante può mostrare ancora più ansia del gruppo non partecipante, anche se il corso ha prodotto un beneficio.

Il confronto osservato mescola l'eventuale effetto del corso con le differenze preesistenti.

Una causa comune può essere rappresentata schematicamente come:

$$A \leftarrow C \rightarrow Y,$$

dove C influenza sia l'esposizione A sia l'esito Y .

Questa struttura viene chiamata confondimento. Il punto essenziale, in questo modulo, non è imparare una procedura di aggiustamento. È riconoscere che il confondente viene definito da un'ipotesi sul processo generativo, non soltanto da una correlazione trovata nel dataset.

Aggiungere automaticamente tutte le variabili a una regressione non risolve il problema. Alcune variabili possono essere conseguenze del trattamento, mediatori o effetti comuni. Condizionare su

di esse può cambiare la domanda o creare una nuova associazione. La logica completa è trattata attraverso i DAG nel Companion.

! L'identificazione precede la stima

Correlazione, regressione, matching e pesatura sono strumenti di stima. Non creano da soli il confronto causale. Prima occorre spiegare perché i dati osservati possano rappresentare gli scenari definiti dalla domanda.

20.5. Che cosa aggiunge la randomizzazione

In un esperimento randomizzato, l'assegnazione del trattamento non dipende sistematicamente dalle caratteristiche iniziali delle persone. I gruppi possono differire per caso, ma risultano comparabili in aspettativa rispetto ai potenziali esiti.

È il disegno randomizzato a giustificare il confronto causale, non il fatto che il valore- p sia piccolo, che il modello sia complesso o che le distribuzioni dei gruppi appaiano simili.

L'EDA rimane utile anche in un esperimento. Può controllare l'implementazione dell'assegnazione, le perdite successive, l'aderenza all'intervento, le distribuzioni degli esiti e la presenza di errori. Non deve però usare gli sbilanciamenti casuali osservati come prova che la randomizzazione abbia "fallito".

20.6. Che cosa può fare l'EDA

L'EDA possiede un ruolo preparatorio concreto.

Può verificare se il dataset rispetti l'unità e la sequenza temporale previste. Può mostrare la composizione dei gruppi e rendere visibili differenze iniziali. Può identificare valori mancanti, perdite al follow-up, errori di codifica e restrizioni della popolazione effettivamente analizzata. Può inoltre mostrare se l'associazione cambi tra sottogruppi previsti dal disegno.

Queste osservazioni possono mettere in discussione una storia causale o indicare che il dataset non rappresenta il disegno dichiarato.

Non possono però dimostrare l'assenza di confondimento non misurato, scegliere automaticamente l'insieme corretto di covariate, stabilire la direzione causale o trasformare una relazione osservata in un effetto.

Il rapporto può essere espresso così:

EDA $\rightarrow$ controllo dei dati e del disegno,

ma non:

EDA $\rightarrow$ identificazione automatica dell'effetto.

20.7. Il tempo fa parte della domanda

Una possibile causa deve precedere il proprio effetto alla scala temporale rilevante. Questa condizione è necessaria, ma non sufficiente.

In uno studio trasversale, stress e sonno vengono spesso misurati nello stesso momento. Anche se la correlazione è forte, il dataset non permette di stabilire quale processo venga prima.

Una misura longitudinale può chiarire la sequenza, ma non elimina automaticamente confondimento, selezione o feedback. Le relazioni psicologiche possono inoltre essere bidirezionali e svilupparsi su più scale temporali.

L'EDA deve quindi controllare che le variabili temporali siano correttamente ordinate e che le osservazioni ripetute non vengano trattate come persone indipendenti. La direzione causale richiede comunque un modello sostantivo.

20.8. Stratificare non equivale ad aggiustare correttamente

Separare un grafico per un terzo fattore può rivelare che la relazione aggregata combina gruppi differenti. È un'importante operazione descrittiva.

Non segue, però, che ogni variabile che modifica il grafico debba essere controllata nel modello causale.

Un confondente, un mediatore e un collider possono produrre pattern statistici interessanti, ma reagiscono in modo diverso al condizionamento. La loro classificazione dipende dalle frecce causali ipotizzate.

Per questo motivo, il paradosso di Simpson non viene sviluppato nuovamente qui. Il suo significato causale è trattato nel capitolo del Companion dedicato all'identificazione. In EDA è sufficiente riconoscere che aggregazione e stratificazione possono produrre descrizioni differenti e che la scelta tra esse richiede una domanda esplicita.

20.9. Il linguaggio deve seguire il disegno

Con dati osservazionali trasversali, una frase prudente è:

Nel campione, maggiore stress è associato a meno ore di sonno.

Sono più impegnative:

Lo stress predice il sonno.

Lo stress riduce il sonno.

La prima può essere appropriata soltanto se la capacità predittiva è stata valutata su osservazioni nuove o con una procedura pertinente. La seconda richiede un effetto causale identificato.

Verbi come *determina*, *produce*, *porta a*, *protegge* e *riduce* devono essere sostenuti da una domanda causale definita e da un disegno o da assunzioni di identificazione.

Linguaggio prudente non significa vago. Possiamo descrivere con precisione direzione, popolazione, tempo e grandezza dell'associazione senza attribuirle una causa.

20.10. Quando fermarsi e passare al Companion

Il passaggio al percorso causale è necessario quando la domanda contiene, esplicitamente o implicitamente, un intervento:

Che cosa accadrebbe se modificassimo X ?

A quel punto occorre definire l'estimand, rappresentare la struttura causale, stabilire quali assunzioni rendano identificabile l'effetto e soltanto dopo scegliere un metodo di stima.

Il percorso consigliato è:

1. Associazione, previsione ed effetto causale;
2. Definire un effetto causale: interventi, controfattuali ed estimand;
3. Identificare effetti causali nei dati osservazionali.

Questo modulo EDA fornisce il dataset controllato e la descrizione della relazione. Il Companion sviluppa il passaggio teorico e modellistico successivo.

20.11. Usare l'AI senza farle inventare una causa

Una richiesta come:

Qual è la causa di questa correlazione?

non può essere risolta dal dataset soltanto. L'assistente tenderà a proporre storie plausibili, ma la plausibilità narrativa non costituisce identificazione.

Un prompt per disciplinare l'interpretazione

Ho osservato un'associazione tra `stress` e `sonno_ore` in dati trasversali.

Separa quattro possibili obiettivi: descrizione associativa, previsione, effetto causale e spiegazione del processo. Per ciascuno indica quale domanda potrei formulare e quale informazione aggiuntiva sarebbe necessaria.

Non trasformare l'associazione in un effetto. Per la domanda causale, chiedimi di specificare intervento, alternativa, esito, tempo e popolazione. Elenca possibili spiegazioni alternative soltanto come ipotesi da sottoporre a disegno e teoria, non come conclusioni ricavate dai dati.

L'AI può inoltre aiutare a revisionare il linguaggio:

Evidenzia tutte le espressioni causali in questo paragrafo. Per ciascuna, indica quale disegno o assunzione sarebbe necessario e proponi una versione associativa coerente con i dati disponibili.

Riflessioni conclusive

L'EDA descrive ciò che è osservato. La causalità riguarda il confronto tra ciò che accadrebbe sotto interventi alternativi.

Una differenza tra gruppi o una correlazione appartiene alla distribuzione osservata. Un effetto causale appartiene a una domanda definita da intervento, alternativa, esito, tempo e popolazione.

Il passaggio non viene compiuto aggiungendo variabili a una regressione. Richiede identificazione: una giustificazione basata sul disegno e su ipotesi causali esplicite. La randomizzazione può fornire tale giustificazione; con dati osservazionali servono assunzioni e strutture sviluppate nel Companion.

L'EDA rimane essenziale. Può mostrare incoerenze tra dati e disegno, perdite, squilibri, sottogruppi e sequenze temporali. Può indebolire una storia causale, ma non convalidarla da sola.

Il risultato di questo capitolo non è una tecnica. È una disciplina interpretativa: sapere quando una frase descrive i dati e quando sta facendo una promessa causale che richiede un altro percorso.

Esercizi

1. Trasforma «lo smartphone aumenta l'ansia» in una domanda causale che specifichi intervento, alternativa, esito, tempo e popolazione.
2. Spiega perché la differenza osservata tra trattati e non trattati non coincide necessariamente con l'effetto medio del trattamento.
3. Per la relazione tra stress e sonno, formula una domanda associativa, una predittiva, una causale e una meccanicistica.
4. Un'analisi aggiunge alla regressione tutte le variabili disponibili. Perché questa strategia non garantisce una stima causale migliore?
5. Elenca tre controlli EDA utili in un esperimento randomizzato e spiega perché nessuno di essi sostituisce la randomizzazione.
6. Una relazione aggregata scompare separando i dati per anno di corso. Quale conclusione descrittiva puoi formulare? Quale conclusione causale non è ancora giustificata?
7. Riscrivi in linguaggio associativo: «Il supporto sociale protegge dalla depressione».
8. Formula un prompt che chieda all'AI di distinguere ciò che i dati mostrano dalle ipotesi causali necessarie per un'interpretazione più forte.

Soluzioni

1. La domanda deve definire, per esempio, una riduzione operativa dell'uso, una condizione di confronto, una misura di ansia, un intervallo temporale e una popolazione precisa.
2. I gruppi osservati possono differire per caratteristiche anteriori al trattamento che influenzano anche l'esito. La differenza combina queste differenze con l'eventuale effetto.
3. Associativa: come varia il sonno tra studenti con stress diverso? Predittiva: quanto bene lo stress anticipa il sonno di nuovi studenti? Causale: come cambierebbe il sonno sotto un intervento sullo stress? Meccanicistica: attraverso quali processi psicologici o fisiologici avviene il cambiamento?

4. Alcune variabili possono essere mediatori, collider o conseguenze del trattamento. La scelta dipende dalla struttura causale e dall'estimand, non dalla sola disponibilità o capacità predittiva.
5. Si possono controllare assegnazione, perdite, aderenza, errori e distribuzioni degli esiti. Questi controlli verificano l'implementazione e la qualità dei dati; l'identificazione deriva dal disegno.
6. Possiamo dire che l'associazione complessiva combina distribuzioni differenti per anno. Non possiamo stabilire che l'anno sia il confondente corretto o che il condizionamento identifichi un effetto.
7. «Nel campione, livelli più elevati di supporto sociale sono associati a minori punteggi di depressione».
8. Il prompt deve chiedere una descrizione associativa, possibili spiegazioni alternative etichettate come ipotesi, requisiti di una domanda causale e limiti del disegno disponibile.

i Punti chiave

- Associazione, previsione, causalità e meccanismo rispondono a domande differenti.
- Una formula statistica non stabilisce l'obiettivo dell'analisi.
- L'effetto causale confronta interventi alternativi sulla stessa popolazione.
- La differenza osservata tra gruppi non coincide in generale con l'effetto medio.
- L'identificazione precede la scelta del metodo di stima.
- Aggiustare per tutte le variabili non è una strategia causale.
- L'EDA controlla dati e disegno, ma non elimina il confondimento non misurato.
- La sequenza temporale è necessaria ma non sufficiente.
- Il linguaggio deve rimanere proporzionato al disegno.
- La trattazione completa della causalità appartiene al Companion.

21. Osservazioni inattese e outlier

In sintesi

Da sapere Un outlier non è automaticamente un errore e non è una proprietà assoluta dell'osservazione. Un valore può essere impossibile per la scala, raro ma plausibile, influente su un riassunto oppure inatteso rispetto alla relazione tra più variabili. I criteri statistici segnalano casi da esaminare; non decidono quali osservazioni eliminare.

Da saper fare Distinguere errore, rarità e influenza; usare grafici, IQR e MAD come strumenti diagnostici; verificare la fonte prima di modificare un valore; confrontare i risultati sotto decisioni alternative; documentare ciò che viene corretto, mantenuto o escluso; controllare le proposte dell'AI.

Introduzione

L'analisi esplorativa termina spesso con alcune osservazioni che non assomigliano alle altre. Possono trovarsi lontano dal centro di una distribuzione, non seguire la relazione visibile tra due variabili oppure modificare sensibilmente una media, una deviazione standard o una correlazione.

È naturale chiamarle *outlier*. Il termine, però, può indurre a pensare che siano elementi estranei da rimuovere. In realtà, un'osservazione inattesa può avere origini molto diverse.

Un punteggio di stress pari a 99 su una scala da 1 a 10 è incompatibile con la misura. Una notte con 1.2 ore di sonno è estrema ma possibile. Una persona con molto stress e molte ore di sonno può non essere estrema in nessuna delle due variabili, ma risultare insolita rispetto alla relazione osservata.

Questi casi richiedono decisioni differenti. La domanda guida non è:

Quale regola posso usare per eliminare gli outlier?

È invece:

Perché questa osservazione appare inattesa, quale evidenza ne chiarisce l'origine e come cambia l'analisi se la trattiamo in modi differenti?

Il capitolo riprende necessariamente alcuni principi della pulizia dei dati. Non li ripeterà come una procedura generale: li applicherà al problema specifico delle osservazioni rare e influenti.

Prerequisiti

Il capitolo presuppone Capitolo 14, Capitolo 17 e Capitolo 19. La distinzione tra dato grezzo, anomalia osservata ed errore confermato rimane valida anche qui.

Panoramica del capitolo

Distingueremo anzitutto valori impossibili, estremi, influenti e inattesi rispetto a una relazione. Useremo poi grafici e criteri robusti come IQR e MAD per individuare osservazioni da controllare. Il punto centrale sarà il passaggio dalla segnalazione alla decisione: verifica della fonte, mantenimento del caso, correzione documentata o analisi di sensibilità. I dati mancanti verranno richiamati soltanto nel punto in cui una correzione può produrre un valore NA; la loro trattazione generale richiederebbe un capitolo autonomo.

i Preparazione del notebook

Il dataset simulato contiene una riga per studente. Sono state introdotte quattro situazioni differenti: un valore impossibile, due valori estremi ma plausibili e una coppia insolita rispetto alla relazione tra stress e sonno.


```

library(dplyr)
library(ggplot2)

set.seed(123)

n <- 120

dati_outlier <- data.frame(
  id = sprintf("S%03d", seq_len(n)),
  stress = round(
    pmin(
      pmax(
        rnorm(n, mean = 6, sd = 1.4),
        1
      ),
      10
    ),
    1
  )
)

dati_outlier$sonno_ore <- round(
  pmin(
    pmax(
      8.2 -
        .28 * dati_outlier$stress +
        rnorm(n, mean = 0, sd = .7),
      3
    ),
    10
  ),
  1
)

dati_outlier$benessere <- round(
  pmin(
    pmax(
      72 -
        3.5 * dati_outlier$stress +
        rnorm(n, mean = 0, sd = 8),
      20
    ),
    95
  ),
  0
)

dati_outlier <- dati_outlier |>
  mutate(
    stress = if_else(
      id == "S102",
      99,
      stress
    ),
    sonno_ore = case_when(
      id == "S017" ~ 1.2,

```

21.1. Un outlier è relativo a un'aspettativa

Un valore viene definito inatteso rispetto a qualcosa.

Può essere incompatibile con i valori ammessi dallo strumento. Può trovarsi lontano dalla maggior parte delle osservazioni. Può avere un forte effetto su un riassunto. Può infine risultare inatteso rispetto a una relazione, pur essendo ordinario se considerato separatamente.

Queste situazioni non devono essere confuse.

Situazione	Domanda appropriata
Valore impossibile	È compatibile con scala, unità e codebook?
Valore estremo	È raro ma plausibile nella popolazione studiata?
Valore influente	Quanto cambia il risultato quando il caso è incluso?
Valore bivariato inatteso	È incompatibile con una relazione o segnala eterogeneità?

La tabella non assegna una decisione. Organizza la diagnosi.

Un caso può appartenere a più categorie. Un valore impossibile può essere anche influente; un caso estremo può non modificare quasi per nulla la mediana; un'osservazione bivariata inattesa può rivelare un sottogruppo reale.

21.2. Prima viene la compatibilità con la misura

Il primo controllo non è statistico. Riguarda ciò che la variabile può rappresentare.

Nel dataset, `stress` è definito su una scala da 1 a 10. Il valore 99 non è semplicemente lontano dalla media: è incompatibile con il sistema di misurazione.

```
dati_outlier |>
  filter(
    stress < 1 |
    stress > 10 |
    sonno_ore < 0 |
    sonno_ore > 24
  )
```

```
      id stress sonno_ore benessere
1 S102    99      6.8      57
```

Il codice segnala la discrepanza. Non ne stabilisce la causa.

Se il codebook indica che 99 significa “mancante”, possiamo ricodificarlo:

```
dati_controllati <- dati_outlier |>
  mutate(
    stress = if_else(
      stress < 1 |
      stress > 10,
      NA_real_,
      stress
    )
  )
```

Se la fonte originale mostra invece che il valore corretto era 9, la decisione appropriata è una correzione documentata. Se non possiamo ricostruire il valore, NA esprime che l'informazione non è disponibile.

! Ricodificare come mancante non conclude il problema

Trasformare un valore impossibile in NA impedisce che entri nei calcoli come numero reale. Non dimostra che la sua assenza sia irrilevante. In questo modulo ci limitiamo a contarla e a rendere visibile quali analisi escludano quella riga. La teoria e il trattamento generale dei dati mancanti richiedono una trattazione separata.

21.3. Guardare la distribuzione prima delle soglie

Dopo avere risolto i valori incompatibili con la misura, possiamo osservare la distribuzione delle ore di sonno.

```
ggplot(
  dati_controllati,
  aes(x = sonno_ore)
) +
  geom_histogram(
    binwidth = .5,
    boundary = 0
  ) +
  labs(
    x = "Ore di sonno",
    y = "Numero di studenti"
  )
```




Figura 21.1.: Distribuzione delle ore di sonno dopo il controllo dei valori impossibili.

L'istogramma mostra due valori lontani dalla concentrazione centrale. Non ci dice se siano errori.

```
ggplot(  
  dati_controllati,  
  aes(y = sonno_ore)  
) +  
  geom_boxplot() +  
  labs(  
    x = NULL,  
    y = "Ore di sonno"  
  )
```




Figura 21.2.: Il boxplot segnala osservazioni lontane dalla metà centrale della distribuzione.

Il boxplot applica una convenzione geometrica. I punti oltre i baffi sono osservazioni da controllare, non “dati cattivi”.

La rarità è una proprietà della distribuzione osservata. L’errore è una conclusione sulla provenienza del dato. Non sono la stessa cosa.

21.4. Il criterio IQR segnala valori lontani dalla metà centrale

L’intervallo interquartile è:

$$IQR = Q_3 - Q_1.$$

Una regola convenzionale segnala i valori inferiori a:

$$Q_1 - 1.5 IQR$$

o superiori a:

$$Q_3 + 1.5 IQR.$$

```
q1 <-
  quantile(
    dati_controllati$sonno_ore,
    .25,
    na.rm = TRUE
  )
```

```

q3 <-
  quantile(
    dati_controllati$sonno_ore,
    .75,
    na.rm = TRUE
  )

iqr_sonno <-
  IQR(
    dati_controllati$sonno_ore,
    na.rm = TRUE
  )

limite_basso_iqr <-
  q1 - 1.5 * iqr_sonno

limite_alto_iqr <-
  q3 + 1.5 * iqr_sonno

data.frame(
  q1 = q1,
  q3 = q3,
  iqr = iqr_sonno,
  limite_basso = limite_basso_iqr,
  limite_alto = limite_alto_iqr
)

```

	q1	q3	iqr	limite_basso	limite_alto
25%	6	7.1	1.1	4.35	8.75

```

casi_iqr <- dati_controllati |>
  filter(
    sonno_ore < limite_basso_iqr |
    sonno_ore > limite_alto_iqr
  )

casi_iqr

```

	id	stress	sonno_ore	benessere
1	S017	6.7	1.2	57
2	S055	9.3	9.2	68
3	S083	5.5	13.5	42

La regola misura la distanza dalla regione centrale in unità di IQR. Non conosce il significato delle ore di sonno e non distingue una notte reale da un errore di trascrizione.

In distribuzioni asimmetriche o con code lunghe può segnalare molte osservazioni perfettamente coerenti con il fenomeno. Per questo il criterio deve essere letto insieme al grafico e alla conoscenza della misura.

21.5. Il MAD offre un secondo criterio robusto

Nel capitolo su posizione e dispersione abbiamo definito:

$$MAD = \text{mediana}(|x_i - \text{mediana}(x)|).$$

Usando il MAD non scalato, possiamo costruire un punteggio robusto:

$$z_i^{\text{rob}} = 0.6745 \frac{x_i - \text{mediana}(x)}{MAD}.$$

```

mediana_sonno <-
  median(
    dati_controllati$sonno_ore,
    na.rm = TRUE
  )

mad_sonno <-
  mad(
    dati_controllati$sonno_ore,
    constant = 1,
    na.rm = TRUE
  )

dati_mad <- dati_controllati |>
  mutate(
    z_robusto =
      .6745 *
      (sonno_ore - mediana_sonno) /
      mad_sonno
  )

dati_mad |>
  filter(
    abs(z_robusto) > 3.5
  ) |>
  select(
    id,
    sonno_ore,
    z_robusto
  )

```

	id	sonno_ore	z_robusto
1	S017	1.2	-7.0148
2	S055	9.2	3.7772
3	S083	13.5	9.5779

La soglia 3.5 è una convenzione operativa. Il vantaggio del metodo è la minore dipendenza da media e deviazione standard, che possono essere esse stesse spostate dai valori estremi.

IQR e MAD possono segnalare insieme leggermente differenti. La discrepanza non deve essere risolta scegliendo il criterio che elimina più casi o produce il risultato preferito. Mostra semplicemente che “essere outlier” dipende anche dalla definizione adottata.

21.6. Un valore estremo può essere una parte reale della popolazione

Dormire 1.2 ore è raro, ma possibile. Dormire 13.5 ore è insolito, ma può verificarsi in condizioni particolari.

Prima di modificare questi valori dovremmo controllare la fonte, l’unità temporale e il contesto. La risposta si riferisce a una notte specifica, a una media settimanale o al sonno nelle ultime ventiquattro ore? È stata digitata direttamente dal partecipante o calcolata da un dispositivo?

Se i valori sono confermati e la popolazione di interesse comprende quelle situazioni, eliminarli rende il dataset meno rappresentativo.

La presenza di osservazioni rare può indicare che il fenomeno è eterogeneo. Può suggerire sottogruppi, code più pesanti di quelle previste dal modello o una misura che funziona diversamente in alcune condizioni.

21.7. Estremo e influente non significano la stessa cosa

Un valore è **estremo** quando si trova lontano dalla maggior parte delle osservazioni. È **influyente** quando modifica in modo rilevante un risultato.

L’influenza dipende dalla statistica e dalla domanda. Un valore molto elevato può modificare fortemente la media e la deviazione standard, ma avere un effetto limitato sulla mediana e sull’IQR.

Possiamo confrontare i riassunti mantenendo tutti i valori plausibili e rimuovendo temporaneamente i casi segnalati dall’IQR:

```
dati_senza_casi_iqr <- dati_controllati |>
  anti_join(
    casi_iqr |>
      select(id),
    by = "id"
  )

bind_rows(
  "tutti i valori plausibili" =
    dati_controllati,
  "senza casi IQR" =
    dati_senza_casi_iqr,
  .id = "scenario"
) |>
  group_by(scenario) |>
  summarise(
    n = sum(!is.na(sonno_ore)),
    media =
      mean(
        sonno_ore,
```



```

      na.rm = TRUE
    ),
    mediana =
      median(
        sonno_ore,
        na.rm = TRUE
      ),
    deviazione_standard =
      sd(
        sonno_ore,
        na.rm = TRUE
      ),
    iqr =
      IQR(
        sonno_ore,
        na.rm = TRUE
      ),
    .groups = "drop"
  )

```

A tibble: 2 x 6

scenario	n	media	mediana	deviazione_standard	iqr
<chr>	<int>	<dbl>	<dbl>	<dbl>	<dbl>
1 senza casi IQR	117	6.51	6.4	0.734	1.1
2 tutti i valori plausibili	120	6.54	6.4	1.11	1.1

Questa è un'analisi di sensibilità, non una procedura di pulizia. Mostra quanto i riassunti dipendano dalla decisione.

Se la media cambia molto e la mediana poco, abbiamo appreso qualcosa sulla distribuzione. Non abbiamo ancora dimostrato che la versione senza i casi sia quella corretta.

21.8. Un'osservazione può essere inattesa solo nella relazione

La coppia S055 possiede valori plausibili di stress e sonno, ma combina stress elevato e molte ore di sonno. Rispetto alla tendenza generale, può apparire inattesa.

```

ggplot(
  dati_controllati,
  aes(
    x = stress,
    y = sonno_ore
  )
) +
  geom_point(
    alpha = .65,
    na.rm = TRUE
  ) +
  geom_smooth(

```

```

method = "lm",
se = FALSE,
na.rm = TRUE
) +
geom_point(
  data = dati_controllati |>
    filter(id == "S055"),
  size = 3
) +
labs(
  x = "Punteggio di stress",
  y = "Ore di sonno"
)

```




Figura 21.3.: Un'osservazione può essere ordinaria nelle singole variabili ma inattesa rispetto alla relazione.

Il caso può essere un errore, una persona appartenente a un sottogruppo oppure un'indicazione che la relazione lineare è troppo semplice.

Questa situazione non viene rilevata da una soglia applicata separatamente alle due variabili. Mostra perché gli outlier dipendano anche dal modello o dalla relazione rispetto a cui vengono valutati.

Un punto lontano dalla linea non è automaticamente da eliminare. Può rivelare che la linea descrive male una parte dei dati.

21.9. Dalla segnalazione alla decisione

Dopo avere individuato un caso, la decisione dovrebbe seguire un ordine riconoscibile.

Prima ricostruiamo la provenienza del valore. Poi verifichiamo la compatibilità con misura e disegno. Se esiste un errore documentabile, correggiamo il dato o lo rappresentiamo come mancante. Se il valore è plausibile, lo manteniamo e ne valutiamo l'influenza. Quando più decisioni sono ragionevoli, mostriamo un'analisi di sensibilità.

segnalazione → verifica della fonte → decisione motivata → confronto dei risultati.

La rimozione è quindi una possibilità, non il punto di partenza.

 Una distribuzione più ordinata non è necessariamente più vera

Eliminare valori perché aumentano la deviazione standard, indeboliscono una correlazione o rendono il grafico meno regolare equivale a modificare i dati in funzione del risultato. Una decisione è difendibile quando deriva dalla qualità del dato, dalla definizione della popolazione o da un criterio metodologico dichiarato.

21.10. Outlier e gradi di libertà del ricercatore

Le decisioni sugli outlier possono diventare una fonte importante di flessibilità analitica.

Possiamo scegliere il criterio IQR, il MAD, una soglia in deviazioni standard, un controllo visivo oppure una misura di influenza legata a un modello. Possiamo applicare la regola a una variabile, a tutte le variabili o soltanto al risultato principale. Possiamo eliminare il caso, trasformare la variabile o cambiare modello.

Molte scelte possono essere ragionevoli. Il problema emerge quando il criterio viene selezionato dopo avere osservato quale versione produce il risultato desiderato.

Per ridurre questa flessibilità, è utile definire in anticipo i controlli possibili, conservare sempre i dati originali, registrare ogni modifica e mostrare quanto le conclusioni dipendano dalle alternative plausibili.

Questa disciplina collega il capitolo alle questioni di trasparenza e replicabilità già discusse in Capitolo 14.

21.11. Documentare il percorso

Una tabella delle decisioni può collegare problema, evidenza, intervento ed effetto.

```
decisioni_outlier <- data.frame(
  id = c(
    "S102",
    "S017",
    "S083",
    "S055"
  ),
  problema = c(
    "valore impossibile nella scala di stress",
    "ore di sonno molto basse",
    "ore di sonno molto alte",
```

```

    "coppia inattesa rispetto alla relazione"
  ),
  evidenza = c(
    "scala definita da 1 a 10",
    "da verificare sulla fonte",
    "da verificare sulla fonte",
    "valori plausibili nelle due variabili"
  ),
  decisione = c(
    "ricodificato come mancante",
    "mantenuto in attesa di verifica",
    "mantenuto in attesa di verifica",
    "mantenuto e incluso nell'analisi di sensibilità"
  )
)

decisioni_outlier

```

id	problema	evidenza	decisione
1 S102	valore impossibile nella scala di stress		
2 S017	ore di sonno molto basse		
3 S083	ore di sonno molto alte		
4 S055	coppia inattesa rispetto alla relazione		
		scala definita da 1 a 10	
		da verificare sulla fonte	
		da verificare sulla fonte	
		valori plausibili nelle due variabili	
			ricodificato come mancante
			mantenuto in attesa di verifica
			mantenuto in attesa di verifica
			mantenuto e incluso nell'analisi di sensibilità

Nel progetto reale dovremmo aggiungere la fonte consultata, la data della verifica e l'effetto quantitativo della decisione.

Il codice mostra *come* abbiamo modificato il dataset. Il registro spiega *perché*.

21.12. Un richiamo essenziale ai dati mancanti

Un capitolo introduttivo sugli outlier non può sviluppare adeguatamente i dati mancanti. Sarebbe necessario distinguere processi diversi di mancata osservazione, discutere le conseguenze sulle stime e introdurre metodi specifici.

Qui manteniamo soltanto tre principi.

Un valore impossibile può essere rappresentato come NA quando l'informazione corretta non è recuperabile. Il numero di osservazioni mancanti e il denominatore di ogni analisi devono rimanere visibili. Infine, trasformare un valore in NA non autorizza automaticamente a eliminare l'intera riga da tutte le analisi.

Quando la quota di mancanti è consistente o sembra concentrarsi in particolari gruppi, il problema supera lo scopo del capitolo e richiede un'analisi dedicata.

21.13. Usare l'AI per segnalare, non per decidere

Una richiesta come:

Pulisci gli outlier.

invita l'assistente a trasformare convenzioni statistiche in decisioni metodologiche.

Una richiesta più controllabile separa individuazione e intervento.

Un prompt per diagnosticare gli outlier

Ho un data frame `dati_outlier`, con una riga per studente. `stress` deve variare da 1 a 10; `sonno_ore` rappresenta le ore dormite nelle ultime ventiquattro ore.

Non eliminare e non modificare alcuna osservazione. Segnala separatamente:

1. valori incompatibili con i limiti dichiarati;
2. casi individuati dal criterio IQR;
3. casi individuati da un punteggio robusto basato sul MAD;
4. osservazioni inattese nello scatterplot tra stress e sonno.

Per ogni caso mostra l'identificatore e i valori originali. Spiega quali decisioni richiedono il codebook o la verifica della fonte. Proponi infine un confronto dei risultati con e senza i casi segnalati, presentandolo come analisi di sensibilità e non come giustificazione automatica dell'esclusione.

Dopo la diagnosi, una seconda richiesta può implementare soltanto le decisioni che il ricercatore ha già giustificato.

Riflessioni conclusive

Un outlier non è un'etichetta che autorizza la cancellazione di una riga. È una relazione tra un'osservazione e un'aspettativa: i limiti della misura, la distribuzione del campione, un riassunto statistico o un modello della relazione.

I valori impossibili appartengono alla qualità del dato e richiedono una verifica della fonte. I valori estremi ma plausibili possono rappresentare regioni rare ma reali della popolazione. I casi influenti segnalano che una conclusione dipende fortemente da poche osservazioni. Gli outlier bivariati o multivariati possono indicare eterogeneità oppure un modello troppo semplice.

IQR e MAD sono strumenti utili perché rendono sistematica la segnalazione, ma non sostituiscono il giudizio metodologico. La decisione deve essere documentata e, quando non è univoca, accompagnata da un'analisi di sensibilità.

I dati mancanti vengono soltanto sfiorati: ricodificare un valore impossibile come NA è talvolta necessario, ma la gestione generale della mancata osservazione è un problema più ampio di questo modulo introduttivo.

L'EDA si conclude quindi non con un dataset privo di anomalie, ma con una comprensione più trasparente di quali osservazioni sostengano i risultati e di quanto le conclusioni dipendano dalle decisioni prese.

Esercizi

1. Spiega la differenza tra valore impossibile, valore estremo e valore influente usando tre esempi differenti.
2. Applica il criterio IQR alla variabile `benessere`. Quali casi vengono segnalati? La segnalazione dimostra che siano errori?
3. Calcola media, mediana, deviazione standard e IQR di `sonno_ore` con tutti i valori plausibili e senza i casi IQR. Quali riassunti cambiano maggiormente?
4. Verifica sulla base del grafico perché S055 sia inatteso rispetto alla relazione, pur non essendo necessariamente estremo nelle singole variabili.
5. La correlazione tra stress e sonno cambia molto dopo la rimozione di un caso. Quali domande devi risolvere prima di decidere se escluderlo?
6. Un valore impossibile viene ricodificato come NA. Quali informazioni devono comparire nel report anche se il valore non entra più nel calcolo?
7. Scrivi una voce del registro delle decisioni per un valore estremo confermato dalla fonte e mantenuto nel dataset.
8. Formula un prompt che chieda all'AI di individuare casi inattesi senza modificarli e di produrre un'analisi di sensibilità.

Soluzioni

1. Un punteggio 99 su una scala 1–10 è impossibile. Una notte con 1.2 ore di sonno è estrema ma possibile. Un punto che modifica fortemente una correlazione è influente rispetto a quel riassunto.
2. Il criterio identifica osservazioni lontane dalla metà centrale. Non ricostruisce la loro origine e non dimostra che siano errori.
3. Media e deviazione standard tendono a cambiare maggiormente perché dipendono dall'ampiezza degli estremi. Mediana e IQR sono generalmente più stabili.
4. Il caso combina stress elevato e molte ore di sonno, mentre la tendenza complessiva è negativa. La sua particolarità appartiene alla coppia di valori.
5. Occorre verificare validità, provenienza, appartenenza alla popolazione e coerenza con il disegno. Il cambiamento del coefficiente dimostra sensibilità, non errore.
6. Devono comparire il motivo della ricodifica, la fonte della decisione, il numero dei mancanti e la numerosità effettivamente usata nelle analisi.
7. La voce deve indicare identificatore, variabile, valore, fonte consultata, motivo del mantenimento ed eventuale effetto sui risultati.
8. Il prompt deve specificare limiti e significato delle variabili, vietare modifiche automatiche, chiedere identificatori e valori originali e separare diagnosi, verifica e confronto dei risultati.

i Punti chiave

- Un outlier è relativo a una misura, una distribuzione, un riassunto o una relazione.
- Un valore impossibile non è semplicemente un valore estremo.
- Rarità e errore sono concetti differenti.
- IQR e MAD segnalano casi; non decidono esclusioni.
- Estremo e influente non significano la stessa cosa.
- Un'osservazione può essere inattesa soltanto rispetto a una relazione.
- I casi plausibili possono rivelare eterogeneità o limiti del modello.
- Le decisioni ambigue richiedono analisi di sensibilità.
- Ricodificare come NA non risolve il problema generale dei dati mancanti.
- L'AI deve assistere diagnosi e codice, non assumere la decisione scientifica.

i Ambiente di sviluppo

Il capitolo usa dplyr e ggplot2.

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
```

```
Platform: aarch64-apple-darwin23
```

```
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Zagreb
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
other attached packages:
```

```
[1] ggplot2_4.0.3 dplyr_1.2.1
```

```
loaded via a namespace (and not attached):
```

```
[1] vctrs_0.7.3      nlme_3.1-170      cli_3.6.6         knitr_1.51
[5] rlang_1.3.0      xfun_0.60         otel_0.2.0        generics_0.1.4
[9] S7_0.2.2         jsonlite_2.0.0    labeling_0.4.3    glue_1.8.1
[13] htmltools_0.5.9  scales_1.4.0      rmarkdown_2.31    grid_4.6.1
[17] evaluate_1.0.5   tibble_3.3.1      fastmap_1.2.0     yaml_2.3.12
[21] lifecycle_1.0.5  compiler_4.6.1    RColorBrewer_1.1-
3 pkgconfig_2.0.3
[25] mgcv_1.9-4       lattice_0.22-9    farver_2.1.2      digest_0.6.39
[29] R6_2.6.1         utf8_1.2.6        tidyselect_1.2.1  splines_4.6.1
[33] pillar_1.11.1    magrittr_2.0.5    Matrix_1.7-
6      withr_3.0.3
```

[37] tools_4.6.1 gtable_0.3.6

Parte IV.

Epilogo

Considerazioni conclusive

Questo modulo è partito da una domanda semplice soltanto in apparenza:

Che cosa deve accadere prima che un insieme di osservazioni possa diventare evidenza scientifica?

La risposta non coincide con l'apprendimento di alcuni comandi R o di una raccolta di statistiche descrittive. Prima dell'inferenza vengono il disegno, la misurazione, la costruzione del dataset analitico, il controllo della qualità dei dati e la comprensione delle distribuzioni osservate.

Il percorso può essere riassunto così:

fenomeno → domanda → disegno → misurazione → dati → esplorazione → modello.

Ogni passaggio limita ciò che potremo concludere nei passaggi successivi. Un modello sofisticato non può correggere automaticamente una domanda vaga, una misura poco valida o un campione costruito attraverso esclusioni non documentate.

Un modo di lavorare

La competenza principale sviluppata nel modulo non è una procedura particolare. È un modo di organizzare il ragionamento.

Prima di eseguire un'operazione abbiamo imparato a specificarne l'input, lo scopo e il risultato atteso. Dopo l'esecuzione abbiamo controllato che la trasformazione avesse prodotto ciò che intendevamo ottenere.

Questo schema ha attraversato l'intero percorso:

domanda → operazione → risultato → controllo → interpretazione.

R rende questa sequenza esplicita e riproducibile. Quarto collega il codice alla spiegazione. L'EDA rende visibile la struttura delle osservazioni prima che venga riassunta da un modello.

La tecnologia non sostituisce però il giudizio. Il codice può terminare senza errori e usare la variabile sbagliata. Un grafico può essere elegante e nascondere metà del campione. Una media può essere calcolata correttamente su valori che non rappresentano il costrutto dichiarato.

La distribuzione come fondamento

L'idea statistica più importante del modulo è quella di distribuzione.

Una distribuzione descrive quali valori compaiono, con quale frequenza, dove si concentrano e quanto siano dispersi. Media, mediana, deviazione standard, intervallo interquartile e correlazione sono riassunti di questa struttura; non la sostituiscono.

Comprendere la deviazione standard ha significato comprendere una particolare misura della distanza dei valori dalla media. Confrontare i dati con la distribuzione normale ha poi mostrato che la regola 68–95–99,7 non appartiene alla deviazione standard in generale, ma a uno specifico modello della forma distributiva.

Lo stesso principio vale per la correlazione. Un coefficiente riassume una componente della distribuzione congiunta, ma non mostra curvature, sottogruppi, valori influenti o problemi di misurazione. Per questo il grafico deve precedere il numero.

I dati non arrivano già pronti

Un altro risultato fondamentale riguarda la preparazione dei dati.

I dati grezzi conservano le tracce del processo con cui sono stati raccolti: codici speciali, duplicazioni, errori di registrazione, mancate risposte e differenze di formato. Usarli senza controlli può produrre risultati fortemente distorti.

Non esiste tuttavia una procedura universale e automatica di pulizia. Ogni intervento modifica il dataset e può cambiare la popolazione effettivamente rappresentata.

Abbiamo quindi adottato una regola generale:

discrepanza → verifica → decisione motivata → controllo dell'effetto.

Lo stesso vale per gli outlier. Un valore raro non è automaticamente un errore; un valore estremo non è necessariamente influente; un caso inatteso può segnalare un sottogruppo reale o un modello troppo semplice.

Quando più decisioni sono plausibili, l'analisi di sensibilità è più informativa di un'esclusione nascosta.

Descrivere senza oltrepassare i dati

L'EDA insegna anche a controllare il linguaggio.

Una relazione osservata può essere descritta con precisione senza trasformarla in un effetto causale. Una differenza tra gruppi non stabilisce automaticamente che il gruppo o il trattamento abbia prodotto la differenza. Una capacità predittiva non identifica necessariamente un meccanismo.

Il modulo ha quindi mantenuto distinto ciò che i dati mostrano direttamente da ciò che richiede un disegno, un modello o un'ipotesi ulteriore.

Questa disciplina interpretativa non indebolisce la ricerca. La rende più chiara. Dire esattamente che cosa sappiamo permette anche di riconoscere che cosa dobbiamo ancora studiare.

Il ruolo dell'intelligenza artificiale

Gli assistenti AI possono generare codice, spiegare errori, proporre grafici e aiutare a organizzare un documento. Per questo non è necessario trasformare ogni studente o ricercatore in un programmatore professionista.

È però necessario mantenere il controllo del procedimento.

Una richiesta utile all'AI specifica il dataset, l'unità di analisi, il significato delle variabili, l'operazione desiderata, il trattamento dei mancanti e i controlli da produrre. Una richiesta vaga costringe invece l'assistente a inventare filtri, soglie, ricodifiche e criteri di esclusione.

Il principio da conservare è:

L'AI può tradurre una procedura dichiarata in codice; non deve sostituire il ricercatore nella definizione della procedura.

Chi presenta l'analisi rimane responsabile della qualità dei dati, della correttezza delle trasformazioni e della proporzione tra risultati e conclusioni.

Che cosa non è stato sviluppato qui

Questo modulo non è un corso completo di probabilità, inferenza o modellizzazione statistica.

La teoria delle variabili casuali, delle distribuzioni di probabilità, della covarianza e della correlazione è sviluppata nel modulo [utet-prob](#).

Il confronto con l'inferenza frequentista è sviluppato nel modulo [utet-frequentista](#).

Il manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza* costituisce il nucleo teorico del percorso. Introduce la probabilità bayesiana, l'aggiornamento delle credenze, la modellizzazione, il workflow e le applicazioni psicologiche.

Il [Companion](#) è il laboratorio operativo associato al manuale. Sviluppa modelli in R, brms e Stan e approfondisce, tra gli altri temi, regressione, modelli gerarchici, controlli predittivi e causalità.

La divisione dei ruoli è intenzionale. Questo sito prepara le domande e i dati; gli altri moduli sviluppano il linguaggio probabilistico e i modelli necessari per affrontare l'incertezza inferenziale.

Dall'esplorazione alla modellizzazione

Il passaggio successivo non consiste nell'abbandonare l'EDA per iniziare la "vera statistica".

Un modello è una rappresentazione selettiva del processo che potrebbe avere generato i dati. Per valutarlo dobbiamo continuare a confrontare ciò che il modello produce con ciò che abbiamo osservato.

Nel workflow bayesiano, questa continuità diventa particolarmente evidente nei controlli predittivi. Il modello genera distribuzioni di dati plausibili e il ricercatore le confronta con distribuzioni, grafici e caratteristiche del dataset reale.

L'EDA non si trasforma automaticamente in *posterior predictive checking*, ma prepara lo stesso atteggiamento:

rendere esplicita un'aspettativa e confrontarla con ciò che i dati mostrano.

Le competenze sviluppate qui rimangono quindi necessarie anche quando i modelli diventano più complessi. Una regressione, un modello multilivello o un modello cognitivo non eliminano la necessità di comprendere unità di analisi, distribuzioni, valori mancanti, osservazioni influenti e limiti della misura.

Un workflow che rimane aperto

L'analisi dei dati non è una sequenza lineare che procede una volta per tutte dalla pulizia al risultato finale.

Un grafico può rivelare un problema di codifica. Un modello può mostrare che una variabile è stata misurata con una risoluzione insufficiente. Un controllo predittivo può suggerire che la distribuzione scelta non rappresenta le code o la variabilità tra persone. Una nuova domanda può richiedere un diverso dataset analitico.

Il percorso è quindi iterativo:

domanda ↔ dati ↔ esplorazione ↔ modello ↔ controllo.

Tornare indietro non rappresenta un fallimento. È una parte normale del ragionamento scientifico.

Un'ultima raccomandazione

La statistica non si impara accumulando procedure da applicare meccanicamente. Si impara formulando domande, osservando le conseguenze delle proprie decisioni e cercando spiegazioni quando i risultati non corrispondono alle aspettative.

Di fronte a un nuovo dataset, le domande più utili rimarranno semplici:

Che cosa rappresenta una riga?

Da dove proviene questa variabile?

Quali osservazioni entrano nel risultato?

Che cosa rende visibile questo grafico?

Quanto dipende la conclusione da una scelta analitica?

Sto descrivendo un'associazione oppure affermando qualcosa di più?

Queste domande non impediscono di usare strumenti complessi. Permettono di usarli con responsabilità.

Il risultato più importante del modulo non è quindi un insieme di comandi o formule. È l'abitudine a rendere esplicito il percorso che collega una domanda ai dati e i dati a una conclusione.



Risorse per continuare

- **Manuale principale:** *Inferenza bayesiana in psicologia: Ragionare con l'incertezza*
- **Companion operativo:** ccaudek.github.io/utet-companion
- **Modulo di probabilità:** ccaudek.github.io/utet-prob

- **Modulo frequentista:** ccaudek.github.io/utet-frequentista
- **Repository:** github.com/ccaudek

- Bechtel, W. (2009). Looking down, around, and up: Mechanistic explanation in psychology. *Philosophical Psychology*, 22(5), 543–564.
- Dogucu, M. (2024). Reproducibility in the Classroom. *Annual Review of Statistics and Its Application*, 12.
- Henrich, J., Heine, S. J., & Norenzayan, A. (2010). The weirdest people in the world? *Behavioral and Brain Sciences*, 33(2-3), 61–83.
- Huntington-Klein, N. (2021). *The effect: An introduction to research design and causality*. Chapman; Hall/CRC.
- Johnson, A. A., Ott, M., & Dogucu, M. (2022). *Bayes Rules! An Introduction to Bayesian Modeling with R*. CRC Press.
- Lilienfeld, S. O., & Strother, A. N. (2020). Psychological measurement and the replication crisis: Four sacred cows. *Canadian Psychology/Psychologie Canadienne*, 61(4), 281–288.
- Marr, D. (2010). *Vision: A computational investigation into the human representation and processing of visual information*. MIT press.
- Maul, A., Irribarra, D. T., & Wilson, M. (2016). On the philosophical foundations of psychological measurement. *Measurement*, 79, 311–320.
- McElreath, R. (2020). *Statistical rethinking: A Bayesian course with examples in R and Stan* (2nd Edition). CRC Press.
- Peterson, R. A., & Merunka, D. R. (2014). Convenience samples of college students and research reproducibility. *Journal of Business Research*, 67(5), 1035–1041.
- Povich, M. (2025). Mechanistic Explanation in Psychology. In H. Stam & H. Looren de Jong (A c. Di), *The SAGE Handbook of Theoretical Psychology*. SAGE Publications.
- Soto, F. A., Vogel, E. H., Uribe-Bahamonde, Y. E., & Perez, O. D. (2023). Why is the Rescorla-Wagner model so influential? *Neurobiology of Learning and Memory*, 204, 107794.
- Stevens, S. S. (1946). On the theory of scales of measurement. *Science*, 103(2684), 677–680.
- Youyou, W., Yang, Y., & Uzzi, B. (2023). A discipline-wide investigation of the replicability of Psychology papers over the past two decades. *Proceedings of the National Academy of Sciences*, 120(6), e2208863120.