

Analisi esplorativa dei dati in psicologia

Modulo introduttivo

Corrado Caudek

15 luglio 2026

1. Analisi esplorativa dei dati in psicologia

Modulo introduttivo a fondamenti, R ed EDA

Questo sito accompagna il manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza*. Il suo scopo è semplice: aiutarti a capire **che cosa sono i dati psicologici**, come prepararli con **R** e come esplorarli prima di costruire modelli statistici.

Non serve esperienza precedente di programmazione o di statistica avanzata. Il percorso è pensato per studenti di psicologia che iniziano da zero.

Che cosa imparerai

Alla fine del modulo dovresti essere in grado di:

- riconoscere come nascono i dati in una ricerca psicologica;
- capire che cosa misurano le variabili e quali limiti hanno;
- usare R per organizzare, pulire e trasformare dati;
- produrre grafici e sintesi descrittive;
- esplorare pattern, anomalie e relazioni tra variabili;
- prepararti allo studio dell'inferenza statistica e bayesiana.

Come è organizzato il modulo

Il sito è diviso in tre parti.

Parte	A cosa serve
Fondamenti	Capire da dove vengono i dati, che cosa rappresentano e quali conclusioni permettono.
R	Imparare gli strumenti essenziali per lavorare con i dati in modo riproducibile.
EDA	Esplorare, visualizzare e descrivere i dati prima dell'inferenza formale.

Se parti da zero, segui l'ordine dei capitoli: **Fondamenti** → **R** → **EDA**.

Se conosci già R o alcuni concetti statistici, puoi usare il sito anche come materiale di consultazione.

Prerequisiti

Non sono richiesti prerequisiti formali.

Per iniziare servono soltanto:

- interesse per la ricerca psicologica;
- disponibilità a lavorare in modo attivo;
- un computer su cui installare R e gli strumenti indicati nei capitoli dedicati.

La prima parte, **Fondamenti**, è concettuale e può essere letta anche senza installare software.

Le parti **R** ed **EDA** richiedono invece un ambiente di lavoro configurato.

Collegamento con gli altri materiali

Questo modulo non sostituisce il manuale principale. Lo prepara.

Qui impariamo a porre domande preliminari:

- da dove vengono i dati?
- che cosa misurano?
- quali errori o distorsioni possono contenere?
- quali pattern osserviamo prima di stimare un modello?

Il manuale principale approfondisce poi il significato dell'inferenza bayesiana. Gli altri companion forniscono richiami di probabilità, confronto con l'approccio frequentista e strumenti operativi per modelli bayesiani con R, brms e Stan.

Come usare questo sito

Leggi i capitoli nell'ordine proposto e prova sempre a eseguire il codice sul tuo computer.

Quando incontri un esempio in R:

1. copialo o eseguillo;
2. osserva il risultato;
3. modifica qualcosa;
4. chiediti che cosa cambia e perché.

La competenza non nasce guardando il codice, ma usandolo.

Da dove iniziare

Inizia dalla [Prefazione](#), oppure passa direttamente alla sezione [Fondamenti](#).

Feedback

Se trovi errori, passaggi poco chiari o codice che non funziona, puoi segnalarli tramite il repository GitHub del progetto o con il pulsante *Segnala un problema* presente nelle pagine del sito.

Licenza

Materiali distribuiti con licenza [CC BY-NC-ND 4.0](#).

Prefazione

Questo sito raccoglie i materiali propedeutici al manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza*. Prima di affrontare la modellazione statistica vera e propria, è necessario consolidare le fondamenta metodologiche. Questa preparazione si articola attorno a tre pilastri essenziali.

Tre pilastri

Pensare. La sezione *Fondamenti* affronta le questioni preliminari a qualsiasi analisi: cosa significa quantificare un costrutto psicologico? Come si progetta uno studio che generi evidenze interpretabili? Quali sono i limiti epistemologici intrinseci alla nostra capacità di apprendere dai dati? Senza una riflessione su questi aspetti, anche l'analisi più raffinata rischia di produrre risultati formalmente corretti ma sostanzialmente vuoti.

Fare. La sezione *R* fornisce gli strumenti operativi per manipolare i dati e implementare le analisi. *R* è il linguaggio che accompagnerà l'intero percorso, dalla gestione dei dati grezzi alla stima di modelli bayesiani. L'obiettivo non è l'apprendimento mnemonico dei comandi, ma lo sviluppo di una **competenza algoritmica**, ovvero la capacità di tradurre un disegno di ricerca in un flusso di codice funzionante e replicabile.

Guardare. La sezione *EDA* (Exploratory Data Analysis) è dedicata all'esplorazione critica dei dati prima di ogni inferenza formale. Visualizzare le distribuzioni, identificare le anomalie dei dati e verificare le assunzioni non sono passaggi meccanici, ma il lavoro che distingue un'analisi robusta da una basata su premesse fragili. Come ricordava John Tukey, è meglio rispondere in modo approssimativo alla domanda giusta piuttosto che rispondere in maniera esatta a quella sbagliata. L'EDA è l'esercizio che ci aiuta a porre e a porci le domande giuste.

Perché questi materiali insieme?

Il lettore potrebbe chiedersi perché un sito di supporto a un manuale di statistica bayesiana includa argomenti così diversi: programmazione, misurazione psicologica e statistica descrittiva. La risposta è che nella pratica della ricerca questi argomenti non sono affatto separati.

Ogni analisi dei dati inizia con una domanda (*pensare*), richiede strumenti per essere implementata (*fare*), e passa attraverso un'esplorazione preliminare (*guardare*). Solo dopo questi passaggi ha senso stimare i modelli e trarre le conclusioni. I capitoli seguenti costruiscono questa sequenza, preparando il terreno per l'inferenza bayesiana trattata nel manuale principale.

Il progetto complessivo

Questo sito fa parte di un ecosistema di risorse didattiche:

Risorsa	Contenuto	Link
Manuale principale	Inferenza bayesiana, modelli, workflow	utet-companion
Questo sito	EDA, R, concetti fondamentali	utet-eda
Teoria della probabilità	Fondamenti probabilistici	utet-prob

Il manuale cartaceo *Inferenza bayesiana in psicologia: Ragionare con l'incertezza* è pensato per essere letto in modo autonomo, ma i materiali online permettono di approfondire gli aspetti computazionali e di vedere il codice in azione.

A chi è destinato

Questo materiale è rivolto agli studenti di psicologia che si avvicinano per la prima volta all'analisi dei dati, ma anche a chi desidera consolidare le proprie competenze. Non sono richieste conoscenze pregresse di programmazione o statistica avanzata.

Come procedere

Il percorso suggerito è sequenziale: prima i fondamenti concettuali, poi gli strumenti, infine l'esplorazione. Tuttavia, i capitoli sono progettati anche per essere consultati come riferimento durante il lavoro pratico. Il codice è riproducibile e i dataset sono disponibili nel repository.

Parte I.

Fondamenti

Pensare prima di calcolare.

Questa sezione introduce le domande che precedono qualsiasi analisi dei dati. Prima di aprire R, costruire un grafico o stimare un modello, dobbiamo chiederci cosa stiamo osservando, da dove provengono i dati e quali conclusioni possiamo trarre.

Nel linguaggio comune, i dati sono spesso considerati semplicemente come numeri disponibili in una tabella. Nella ricerca psicologica, però, i dati non sono numeri neutri. Sono il risultato di una serie di scelte: una domanda di ricerca, un disegno di studio, uno strumento di misurazione, una procedura di raccolta, criteri di inclusione ed esclusione, decisioni di codifica e, infine, procedure di analisi. Ogni passaggio apre possibilità, ma introduce anche dei limiti.

Per esempio, se vogliamo studiare la relazione tra lo stress accademico e la qualità del sonno negli studenti universitari, non basta raccogliere due punteggi e calcolare una correlazione. Dobbiamo prima chiarire cosa intendiamo per “stress”, come lo misuriamo, a quale popolazione vogliamo generalizzare, come sono stati scelti gli studenti, se il disegno permette solo di descrivere un’associazione o anche di sostenere un’interpretazione causale e quali fonti di incertezza restano presenti nei dati.

Questa parte del modulo ha quindi una funzione preparatoria: insegna a leggere i dati prima di analizzarli. L’obiettivo non è anticipare le tecniche statistiche, ma costruire il vocabolario concettuale necessario per poterle utilizzare in modo sensato.

Perché questi fondamenti vengono prima di R e dell'EDA

La sezione successiva del modulo introdurrà il linguaggio R, mentre la parte dedicata all'EDA mostrerà come esplorare distribuzioni, relazioni, anomalie e modelli nei dati. Tuttavia, nessuna procedura operativa può sostituire una comprensione preliminare del significato dei dati.

Un grafico può essere ben costruito, ma rappresentare una misura poco valida. Una media può essere calcolata correttamente, ma riferirsi a una variabile per cui la media è poco informativa. Una correlazione può essere numericamente precisa, ma interpretata in modo improprio come prova causale. Un modello statistico può essere stimato senza errori di calcolo, ma rispondere a una domanda formulata in modo errato.

Per questo motivo, la prima parte del percorso è dedicata al passaggio dai fenomeni psicologici ai dati analizzabili. Il filo conduttore è il seguente:

**Fenomeno psicologico → domanda di ricerca → disegno → misurazione → dati
→ esplorazione → modello → inferenza.**

L’inferenza bayesiana, trattata nel manuale principale, fornisce un metodo coerente per ragionare sull’incertezza, aggiornare le credenze alla luce dei dati e valutare i modelli alternativi. Tuttavia, anche l’inferenza più raffinata dipende dalla qualità delle domande, delle misure e dei disegni che hanno generato i dati. Questa sezione serve a rendere esplicite tali condizioni.

Tre domande guida

I capitoli di questa parte ruotano attorno a tre domande fondamentali.

Che cosa stiamo cercando di capire?

Ogni analisi nasce da una domanda. In psicologia, queste domande riguardano spesso processi non direttamente osservabili, come l'attenzione, la memoria, l'ansia, la motivazione, l'impulsività, la regolazione emotiva, l'apprendimento e il benessere. Questi fenomeni devono essere tradotti in ipotesi, variabili e procedure osservabili.

La prima difficoltà è dunque di natura teorica: dobbiamo distinguere il fenomeno psicologico che vogliamo comprendere dagli indicatori empirici che possiamo effettivamente raccogliere. Questa distinzione sarà essenziale per tutto il percorso, perché i dati non parlano da sé, ma acquistano significato all'interno di un quadro teorico.

Che cosa osserviamo davvero?

Molti costrutti psicologici non sono osservabili direttamente. Non misuriamo l'ansia in sé, ma le risposte a un questionario, i comportamenti, i tempi di reazione, le valutazioni cliniche, gli indicatori fisiologici o altre manifestazioni parziali del costrutto. Ogni indicatore contiene informazioni, ma anche errori.

Per interpretare un dato, quindi, dobbiamo sapere che cosa rappresenta, come è stato prodotto e quali sono i suoi limiti. La misurazione non è un dettaglio tecnico, ma il punto in cui una teoria psicologica entra in contatto con l'osservazione empirica.

Che cosa possiamo concludere?

Non tutti i dati permettono di trarre le stesse conclusioni. Alcuni dati sono utili per descrivere un gruppo specifico, altri permettono una generalizzazione più ampia e altri ancora, se raccolti con un disegno adeguato, possono sostenere ipotesi causali.

Il tipo di studio, la strategia di campionamento, la qualità delle misure e la presenza di possibili fattori confondenti determinano i limiti dell'inferenza. Una parte importante della competenza statistica consiste nel riconoscere tali limiti prima di trarre conclusioni troppo affrettate.

Mappa della sezione

I capitoli che seguono costruiscono progressivamente questa competenza.

Capitolo	Domanda guida	Funzione nel percorso
Concetti chiave	Che cos'è un dato?	Introdurre il lessico minimo: popolazione, campione, unità statistica, variabile, parametro, statistica, variabilità e incertezza.
Disegno della ricerca	Come sono stati generati i dati?	Comprendere campionamento, studi osservazionali, esperimenti, generalizzabilità, bias e limiti dell'interpretazione causale.

Capitolo	Domanda guida	Funzione nel percorso
Misurazione	Che cosa significa il valore osservato?	Collegare costrutti teorici, indicatori empirici, errore di misura, validità, affidabilità e livelli di scala.
Modelli psicologici	Descrivere basta?	Preparare il passaggio dalla descrizione dei pattern alla spiegazione dei processi che potrebbero averli generati.

Questa mappa non va letta come una sequenza di definizioni da memorizzare, ma come un insieme di strumenti per orientarsi. Quando ci troveremo di fronte a un dataset, torneremo implicitamente a queste domande: chi o cosa è stato osservato? Con quale misura? In quale contesto? Con quale disegno? Quale forma di incertezza rimane?

Un esempio ricorrente

Per rendere i concetti più concreti, useremo spesso esempi tratti dalla ricerca psicologica. Un caso semplice può accompagnare l'intera sezione: lo studio della relazione tra lo stress accademico e la qualità del sonno.

Questo esempio ci permette di vedere come una stessa domanda possa assumere significati diversi a seconda del livello di analisi:

- come **domanda descrittiva**, potremmo chiederci quanto siano frequenti i livelli elevati di stress in un determinato gruppo di studenti;
- come **domanda associativa**, potremmo chiederci se gli studenti più stressati riportano una qualità del sonno peggiore;
- come **domanda causale**, potremmo chiederci se una riduzione dello stress produce un miglioramento della qualità del sonno;
- come **domanda esplicativa**, potremmo chiederci attraverso quali meccanismi psicologici lo stress interferisce con il sonno.

Le analisi statistiche richieste da queste domande possono essere diverse, ma soprattutto cambiano le condizioni necessarie per interpretare correttamente i risultati. Una correlazione può essere sufficiente per descrivere un'associazione, ma non per dimostrare da sola un effetto causale. Un questionario può essere utile, ma solo se misura in modo valido e affidabile il costrutto di interesse. Un campione di convenienza può essere informativo, ma non autorizza generalizzazioni automatiche a tutti gli studenti universitari.

Collegamenti con il resto del modulo

La sezione **R** tradurrà molte di queste idee in procedure operative. Impareremo a organizzare i dati, manipolare le tabelle, scrivere le funzioni, produrre i grafici e documentare le analisi riproducibili. Tuttavia, il codice sarà sempre al servizio di una domanda: non lo scriveremo per accumulare comandi, ma per rendere esplicito e controllabile il percorso che va dai dati grezzi all'interpretazione.

La sezione **EDA** mostrerà come osservare i dati prima di formalizzare un modello. Esploreremo distribuzioni, valori anomali, relazioni tra variabili, indici di posizione e dispersione, nonché visualizzazioni e primi ragionamenti su correlazione e causalità. L'esplorazione sarà utile solo se sapremo cosa stiamo esplorando e quali limiti derivano dalla misurazione e dal disegno.

Il manuale principale sull'inferenza bayesiana riprenderà molti di questi temi a un livello più generale. In quel contesto, l'attenzione sarà rivolta al significato epistemologico delle procedure: cosa significa aggiornare una credenza, stimare un parametro, confrontare modelli e quantificare l'incertezza. Questa sezione prepara il terreno per questo percorso, mostrando che l'incertezza non deriva solo dal calcolo statistico, ma anche dalla teoria, dal campionamento, dalla misurazione e dal disegno della ricerca.

Cosa portare con sé

Al termine di questa prima parte, lo studente dovrebbe essere in grado di affrontare un dataset ponendosi alcune domande essenziali:

1. Qual è il fenomeno psicologico di interesse?
2. Quale domanda di ricerca ha motivato la raccolta dei dati?
3. Qual è la popolazione di riferimento e quale campione è stato osservato?
4. Quali variabili sono state misurate e che cosa rappresentano?
5. Le misure sono plausibilmente valide e affidabili?
6. Il disegno consente descrizione, previsione, generalizzazione o inferenza causale?
7. Quali fonti di incertezza, errore o bias devono essere considerate?
8. Quali conclusioni sarebbero giustificate e quali sarebbero eccessive?

Queste domande accompagneranno tutto il percorso. Imparare a formularle è il primo passo per evitare il rischio più comune nell'analisi dei dati: produrre risultati tecnicamente corretti ma scientificamente poco rilevanti.

2. Concetti chiave

Prima di utilizzare R, costruire grafici o stimare modelli, è necessario chiarire la natura dei dati che analizziamo. In psicologia, i dati non sono numeri neutri, ma osservazioni prodotte da una domanda di ricerca, da un disegno di studio, da strumenti di misura e da decisioni operative. Questo capitolo introduce il lessico minimo per passare da un fenomeno psicologico a una matrice di dati interpretabile.

L'obiettivo del capitolo non è ancora quello di insegnare tecniche di analisi. Prima di calcolare una media, disegnare un istogramma o stimare un modello, è necessario porsi le seguenti domande:

- quale fenomeno vogliamo comprendere;
- quali persone, situazioni o risposte abbiamo osservato;
- quali variabili rappresentano il fenomeno;
- a quale popolazione vorremmo generalizzare.
- quali fonti di variabilità, errore e bias sono presenti nei dati.
- cosa possiamo descrivere, stimare o inferire in modo giustificato.

Il filo conduttore del capitolo è semplice: i dati acquistano significato solo quando sappiamo da dove provengono e cosa rappresentano. Questo concetto sarà presente anche nei capitoli successivi, dedicati al disegno di ricerca, alla misurazione, all'esplorazione dei dati e alla modellazione.

Statistica

Il termine *statistica* può indicare due cose diverse.

1. La statistica è la disciplina che studia i metodi per raccogliere, organizzare, analizzare, interpretare e comunicare i dati.
2. Con il termine "statistica" si indica anche un valore numerico calcolato su un campione, come la media campionaria, la deviazione standard campionaria o la correlazione campionaria.

Nel primo senso, la statistica è un metodo di ragionamento sui dati. Nel secondo senso, una statistica è un riassunto numerico dei dati osservati.

Panoramica del capitolo

In questo capitolo imparerai a:

- distinguere fenomeni, domande di ricerca, dati e variabili;
- riconoscere unità statistiche, osservazioni e matrici di dati;
- distinguere popolazione, campione, parametro e statistica;
- comprendere perché il campione introduce incertezza;
- riconoscere alcune fonti di bias nella raccolta dei dati;
- distinguere descrizione, stima e inferenza;
- capire perché un'associazione osservata non è automaticamente una relazione causale.

Prerequisiti

Per seguire questo capitolo non sono richieste conoscenze tecniche di statistica o di R. È sufficiente avere familiarità con il modo in cui in psicologia si formulano domande empiriche, per esempio: *lo stress accademico è associato alla qualità del sonno?* oppure *un intervento riduce i sintomi d'ansia?*

Lecture facoltative per chi desidera approfondire:

- **Horoscopes**, discusso nell'ultimo capitolo di McElreath (2020);
- *The Effect: An Introduction to Research Design and Causality*, in particolare il capitolo sui treatment effects.

2.1. Perché partire dai concetti chiave

Quando ci troviamo di fronte a un dataset, è facile pensare che l'analisi inizi dal file: lo apriamo, controlliamo le colonne, calcoliamo qualche statistica descrittiva e produciamo un grafico. Dal punto di vista scientifico, però, l'analisi inizia prima.

Un dataset è il risultato di una serie di passaggi:

1. un fenomeno viene considerato rilevante;
2. il fenomeno viene trasformato in una domanda di ricerca;
3. la domanda suggerisce quali persone, situazioni o comportamenti osservare;
4. le osservazioni vengono registrate come variabili;
5. le variabili vengono organizzate in una matrice di dati;
6. la matrice viene descritta, esplorata e, eventualmente, utilizzata per costruire inferenze.

Ogni passaggio introduce delle scelte. Alcune riguardano il disegno dello studio, altre la misurazione e altre ancora il modo in cui i dati vengono codificati e analizzati. Per questo motivo, i dati non sono mai completamente indipendenti dal contesto in cui sono stati prodotti (Johnson et al., 2022).

Idea guida

Una buona analisi dei dati non inizia con una tecnica, ma con una domanda: “Che cosa rappresentano questi dati e quale conclusione possono sostenere?”.

2.2. Un esempio guida: stress accademico e sonno

Useremo come esempio ricorrente una domanda semplice:

Gli studenti universitari che riportano livelli più alti di stress accademico dormono peggio?

Questa domanda può sembrare immediata, ma in realtà nasconde molte decisioni implicite.

- A quali studenti ci riferiamo? Gli studenti di un corso specifico, di una facoltà, di un ateneo o gli studenti universitari in generale?
- Che cosa intendiamo per “stress accademico”? Numero di esami, pressione percepita, ansia da prestazione o carico di studio?

- Che cosa intendiamo per “dormire peggio”? Meno ore di sonno, peggiore qualità del sonno, più risvegli notturni?
- Come raccogliamo i dati? Con un questionario, un diario del sonno o un dispositivo indossabile?
- Vogliamo solo descrivere un’associazione o vogliamo sostenere che lo stress provoca un peggioramento del sonno?

Il passaggio da una domanda apparentemente semplice a un dataset richiede dunque molte specificazioni. Questo è particolarmente importante in psicologia, dove spesso studiamo costrutti non osservabili direttamente, come lo stress, l’ansia, l’autostima, il benessere e la motivazione.

2.3. Fenomeni, domande e dati

Un *fenomeno* è qualcosa che vogliamo comprendere: un comportamento, un processo mentale, una differenza tra gruppi, un cambiamento nel tempo o una relazione tra variabili. Una *domanda di ricerca* traduce il fenomeno in una forma osservabile e discutibile empiricamente.

Nel nostro esempio, il fenomeno generale è il rapporto tra vita accademica e benessere. Una possibile domanda empirica potrebbe essere: “Esiste un’associazione tra lo stress accademico percepito e la qualità del sonno?”

I *dati* sono le osservazioni raccolte per rispondere a questa domanda. Questi dati possono essere numeri, categorie, risposte testuali, tempi di reazione, punteggi di questionari, scelte comportamentali o misure fisiologiche. Ciò che rende i dati scientificamente utili non è il fatto che siano numerici, ma il fatto che siano collegati a una domanda e raccolti con procedure esplicite.

Errore comune

Un errore frequente è pensare che un numero sia automaticamente più scientifico di una descrizione verbale. In realtà, un numero è utile solo se sappiamo cosa rappresenta, come è stato ottenuto e quali limiti interpretativi comporta.

2.4. Unità statistiche, osservazioni e variabili

Per organizzare i dati, dobbiamo distinguere tre elementi:

- l’unità statistica, ovvero l’entità su cui raccogliamo le informazioni; In molti studi psicologici, l’unità è una persona, ma può anche essere una coppia, una classe, una seduta terapeutica, una risposta a un item, una prova sperimentale o un gruppo.
- Un’osservazione è un’informazione registrata su un’unità statistica.
- Una variabile è una caratteristica che può assumere valori diversi da un’unità all’altra o da un’occasione di misura all’altra.

Nel nostro esempio, le unità statistiche potrebbero essere gli studenti. Per ciascuno di essi, potremmo osservare il punteggio di stress, le ore di sonno, la qualità soggettiva del sonno, l’età, il genere, il corso di laurea e il numero di esami imminenti.

Esempio

Se osserviamo 120 studenti e registriamo per ciascuno di essi il livello di stress percepito, le ore di sonno e la qualità del sonno, abbiamo 120 unità statistiche. Le colonne del dataset

rappresentano le variabili. Ogni riga rappresenta, di norma, uno studente.

2.5. La matrice dei dati

Nella maggior parte delle analisi introduttive, i dati vengono organizzati in una *matrice dei dati*, ovvero una tabella in cui le righe rappresentano le unità statistiche e le colonne rappresentano le variabili.

id_studente	stress	ore_sonno	qualita_sonno	genere	esami_immi- nenti
1	18	6.5	3	F	2
2	27	5.0	2	M	4
3	11	7.5	4	F	1

Questa forma tabellare è alla base di molte operazioni in R: la selezione delle colonne, il filtraggio delle righe, il calcolo delle statistiche descrittive, la produzione di grafici e la costruzione di modelli. Tuttavia, una matrice ordinata non garantisce che i dati siano adeguati alla domanda. Prima di procedere con l'analisi, è necessario verificare che le variabili siano state definite in modo chiaro, che le osservazioni siano affidabili e che il campione sia rappresentativo della popolazione di riferimento.

Collegamento con R

Nei capitoli su R e su `dplyr`, una matrice di dati verrà trattata come un oggetto su cui eseguire diverse operazioni: selezione, filtrazione, trasformazione, raggruppamento e riassunzione. In questo caso, ci interessa soprattutto il significato scientifico di righe e colonne.

2.6. Popolazione e campione

La *popolazione* è l'insieme delle unità a cui vorremmo riferire le nostre conclusioni. Il *campione* è l'insieme delle unità che abbiamo effettivamente osservato.

Nel nostro esempio, la popolazione potrebbe essere costituita da:

- tutti gli studenti del corso;
- tutti gli studenti di un ateneo.
- tutti gli studenti universitari italiani.
- tutti gli studenti universitari in generale.

Queste alternative non sono equivalenti. Se si raccolgono dati solo tra gli studenti di un singolo corso, sarà difficile sostenere che i risultati siano automaticamente validi per tutti gli studenti universitari. La qualità del passaggio dal campione alla popolazione dipende dal modo in cui il campione è stato formato.

Generalizzazione

Generalizzare significa usare ciò che abbiamo osservato in un campione per trarre conclusioni su una popolazione più ampia. Questa operazione è sempre delicata: un campione di grandi dimensioni non è necessariamente rappresentativo e un campione non rappresentativo può

produrre conclusioni fuorvianti.

2.6.1. Campioni e rappresentatività

Un *campione* è rappresentativo quando riflette, rispetto agli aspetti rilevanti per la domanda di ricerca, la popolazione di interesse. In pratica, molti studi psicologici utilizzano campioni di convenienza, come gli studenti reclutati durante le lezioni, i volontari online o i partecipanti disponibili in un determinato contesto. Questi campioni possono rivelarsi utili, soprattutto nelle fasi esplorative, ma limitano la validità delle generalizzazioni.

Il punto non è evitare sempre i campioni di convenienza. Il punto è dichiarare con precisione quali conclusioni è possibile trarre e quali no.

2.7. Parametri e statistiche

Un *parametro* è una caratteristica numerica della popolazione. Una *statistica* è una caratteristica numerica calcolata sul campione.

Per esempio, immaginiamo di voler conoscere la media delle ore di sonno degli studenti universitari italiani durante la sessione d'esame. Questa media nella popolazione è un parametro. Se raccogliamo i dati di 120 studenti e calcoliamo la media delle ore di sonno nel campione, otterremo una statistica.

i Parametro e statistica

Il parametro è ciò che vorremmo conoscere nella popolazione. La statistica è ciò che possiamo calcolare a partire dai dati osservati. L'inferenza statistica nasce dallo scarto tra queste due cose.

La statistica campionaria raramente coincide esattamente con il parametro della popolazione. Se ripetessimo lo studio con un altro campione, otterremmo probabilmente una media diversa. Questa variabilità tra i campioni è una delle principali fonti di incertezza statistica.

2.8. Variabilità e incertezza

La variabilità è una caratteristica fondamentale dei dati psicologici. Le persone sono diverse tra loro, cambiano nel tempo e reagiscono in modo diverso a contesti simili. Anche quando studiamo lo stesso fenomeno, non osserviamo sempre gli stessi valori.

L'incertezza può derivare da diverse fonti:

- osserviamo un campione e non l'intera popolazione;
- misuriamo i costrutti psicologici in modo imperfetto;
- i dati possono contenere errori, valori mancanti o risposte inattendibili;
- il disegno dello studio può introdurre bias;
- il modello statistico usato per l'analisi dei dati è sempre una semplificazione.

L'analisi statistica serve anche a rendere esplicita questa incertezza. Nell'approccio bayesiano, che verrà trattato nel manuale principale, l'incertezza viene rappresentata direttamente tramite distribuzioni di probabilità. In questo capitolo, ci basta riconoscere che l'incertezza non è un difetto occasionale, ma una condizione normale dell'inferenza sui dati.

2.9. Bias: quando i dati si spostano in una direzione

La variabilità non è l'unico problema. Un campione o una misura possono anche essere *distorti*. Un bias è un errore sistematico che tende a spostare i risultati in una direzione.

Nel nostro esempio, potremmo avere un bias se:

- al questionario rispondono soprattutto studenti molto stressati;
- partecipano solo gli studenti presenti a lezione, escludendo chi ha difficoltà di frequenza;
- la domanda sulla qualità del sonno è formulata in modo ambiguo.
- gli studenti rispondono in modo socialmente desiderabile;
- raccogliamo i dati solo durante la settimana d'esame e li trattiamo come se rappresentassero l'intero semestre.

Comprendere chi ha raccolto i dati, come, quando e con quali strumenti è essenziale per interpretarli correttamente (Johnson et al., 2022). Nei capitoli successivi vedremo che il bias può dipendere dal disegno dello studio, dalla misurazione o dalle decisioni prese durante la pulizia dei dati.

Errore comune

Aumentare la dimensione del campione può ridurre la variabilità campionaria, ma non elimina automaticamente il bias. Un campione molto grande ma distorto può produrre una stima molto precisa di una quantità errata.

2.10. Variabili: significato e ruolo nella domanda

Una variabile può essere numerica o categoriale, osservata direttamente o costruita a partire da più risposte. In questa fase è utile distinguere due aspetti.

Il primo è il *tipo di informazione* contenuta nella variabile. Per esempio, le ore di sonno sono una misura quantitativa; il genere, se registrato in categorie, è una variabile categoriale; la qualità soggettiva del sonno potrebbe essere registrata su una scala ordinale.

Il secondo aspetto è il *ruolo della variabile nella domanda di ricerca*. In una domanda come “Lo stress accademico è associato alla qualità del sonno?”, lo stress è la variabile esplicativa o predittiva, mentre la qualità del sonno è la variabile esito. Questa distinzione è utile per formulare ipotesi, ma non è sufficiente a stabilire la causalità.

Variabile indipendente e variabile dipendente

Nei disegni sperimentali si parla spesso di *variabile indipendente* e *variabile dipendente*. La variabile indipendente è quella manipolata dal ricercatore, mentre la variabile dipendente è l'esito osservato. Negli studi osservazionali, invece, è più prudente parlare di variabile esplicativa o predittiva e di variabile esito.

2.11. Descrivere, stimare, inferire

Una stessa matrice di dati può essere utilizzata per diversi scopi.

- *Descrivere* significa riassumere ciò che osserviamo nel campione: medie, frequenze, distribuzioni, grafici, valori anomali, relazioni visive tra variabili.
- *Stimare* significa usare i dati del campione per ottenere un valore plausibile di una quantità nella popolazione, per esempio una media o una differenza tra medie.
- *Inferire* significa trarre conclusioni più generali tenendo conto dell'incertezza, delle assunzioni e dei limiti del disegno.

L'EDA, ovvero l'analisi esplorativa dei dati, parte soprattutto dalla descrizione: l'osservazione di distribuzioni, pattern, anomalie e possibili relazioni. Tuttavia, anche la descrizione richiede un'attenta analisi concettuale. Un grafico può mostrare un'associazione, ma la sua interpretazione dipende dal campione, dalla misura e dal disegno dello studio.

2.12. Effetti e causalità: una cautela iniziale

Nel linguaggio statistico e psicologico si parla spesso di *effetto*. Tuttavia, il termine può generare ambiguità. A volte indica una differenza o un'associazione osservata nei dati, altre volte suggerisce una relazione causale.

Se, per esempio, osserviamo che gli studenti con un livello di stress più alto riportano una qualità del sonno più bassa, abbiamo osservato un'associazione. Possiamo definirla, in senso descrittivo, un effetto dello stress sul sonno, ma con molta cautela. Per poter sostenere una conclusione causale, è necessario sapere come sono stati raccolti i dati e se il disegno consente di escludere spiegazioni alternative, quali il carico di lavoro, la salute mentale pregressa, le abitudini di studio o le condizioni economiche (Huntington-Klein, 2021).

Questo tema verrà ripreso nel capitolo dedicato al disegno di ricerca e in quello introduttivo alla causalità. Qui è sufficiente ricordare che i modelli statistici possono quantificare le associazioni, ma non creano da soli le condizioni per una conclusione causale.

2.13. Collegamento con il resto del percorso

Questo capitolo introduce il vocabolario minimo per i capitoli successivi.

Capitolo successivo	Domanda che riprende questo capitolo
Disegno di ricerca	Come sono stati generati i dati e quale inferenza autorizzano?
Misurazione	Che cosa rappresentano davvero i valori osservati?
R e dplyr	Come organizziamo, trasformiamo e controlliamo la matrice dei dati?
EDA	Che cosa possiamo vedere nei dati prima di stimare un modello?
Correlazione e causalità	Quando un'associazione è solo descrittiva e quando può sostenere ipotesi causali?
Inferenza bayesiana	Come rappresentiamo l'incertezza sui parametri e sui modelli?

Collegamento con il manuale bayesiano

L'inferenza bayesiana non elimina i problemi relativi al disegno, al campionamento o alla misurazione. Li rende espliciti all'interno di un ragionamento probabilistico. Per questo motivo, è importante imparare fin da subito a porsi le seguenti domande: cosa è stato osservato, cosa è incerto e quali assunzioni collegano i dati alla conclusione.

Riflessioni conclusive

I dati psicologici sono il risultato di un percorso che va dal fenomeno alla domanda, dalla domanda alla misura, dalla misura alla matrice dei dati e dalla matrice all'interpretazione. In ogni passaggio, le decisioni che prendiamo influenzano ciò che potremo concludere.

Il messaggio centrale di questo capitolo è che l'analisi dei dati non consiste solo nell'applicare procedure corrette. Consiste anche nel capire se le procedure applicate sono appropriate alla domanda, ai dati e al modo in cui questi sono stati prodotti. Prima di calcolare, dobbiamo interpretare e, prima di interpretare, dobbiamo sapere cosa stiamo osservando.

Cosa portare al capitolo successivo

Quando leggi o costruisci un dataset, prova sempre a rispondere a quattro domande:

1. Qual è la popolazione a cui vorrei riferirmi?
2. Quale campione ho effettivamente osservato?
3. Quali variabili rappresentano il fenomeno di interesse?
4. Quali fonti di incertezza o bias possono limitare le conclusioni?

Problemi

1. Nel caso dello studio su stress accademico e sonno, identifica il fenomeno generale, una possibile domanda di ricerca e almeno tre variabili osservabili.
2. Spiega la differenza tra popolazione e campione usando un esempio diverso da quello discusso nel capitolo.
3. Che differenza c'è tra un parametro e una statistica? Perché questa distinzione è importante per l'inferenza?
4. Immagina che uno studio sul benessere degli studenti recluti solo partecipanti volontari tramite un annuncio online. Quali bias potrebbero emergere?
5. Perché un campione molto grande non garantisce necessariamente conclusioni valide?
6. In che senso una variabile può essere definita dal suo tipo di informazione e dal suo ruolo nella domanda di ricerca?
7. Spiega la differenza tra descrivere, stimare e inferire.
8. Perché osservare un'associazione tra due variabili non basta per concludere che una causa l'altra?

 Soluzioni

1. Nel caso dello studio su stress accademico e sonno, identifica il fenomeno generale, una possibile domanda di ricerca e almeno tre variabili osservabili.

Il fenomeno generale è il rapporto tra vita accademica e benessere. Una possibile domanda di ricerca è: *gli studenti con livelli più alti di stress accademico riportano una qualità del sonno peggiore?* Variabili osservabili potrebbero essere il punteggio di stress percepito, le ore di sonno, la qualità soggettiva del sonno, il numero di esami imminenti e l'anno di corso.

2. Spiega la differenza tra popolazione e campione usando un esempio diverso da quello discusso nel capitolo.

La popolazione è l'insieme a cui vorremmo generalizzare. Il campione è l'insieme che osserviamo davvero. Per esempio, se vogliamo studiare l'uso dei social media negli adolescenti italiani, la popolazione potrebbe essere l'insieme degli adolescenti italiani, mentre il campione potrebbe essere formato da 300 studenti reclutati in alcune scuole.

3. Che differenza c'è tra un parametro e una statistica? Perché questa distinzione è importante per l'inferenza?

Un parametro è una caratteristica della popolazione, come la media reale del tempo di sonno di tutti gli studenti di un ateneo. Una statistica è la corrispondente quantità calcolata nel campione. L'inferenza statistica usa le statistiche campionarie per ragionare sui parametri non osservati, tenendo conto dell'incertezza.

4. Immagina che uno studio sul benessere degli studenti recluti solo partecipanti volontari tramite un annuncio online. Quali bias potrebbero emergere?

Potrebbe emergere un bias di autoselezione: partecipano soprattutto gli studenti più interessati al tema, più motivati o con esperienze particolarmente positive o negative. Potrebbero inoltre essere esclusi studenti con minore accesso alle comunicazioni online o con meno tempo disponibile. Il campione potrebbe quindi non rappresentare bene la popolazione di interesse.

5. Perché un campione molto grande non garantisce necessariamente conclusioni valide?

Un campione grande riduce spesso la variabilità casuale delle stime, ma non elimina il bias. Se il campione è selezionato in modo distorto, anche molte osservazioni possono produrre una stima precisa ma sbagliata rispetto alla popolazione di interesse.

6. In che senso una variabile può essere definita dal suo tipo di informazione e dal suo ruolo nella domanda di ricerca?

Il tipo di informazione riguarda il formato della variabile: numerica, categoriale, ordinale, testuale e così via. Il ruolo nella domanda riguarda invece la funzione della variabile nell'analisi: per esempio variabile predittiva, esito, variabile di controllo o possibile confondente.

7. Spiega la differenza tra descrivere, stimare e inferire.

Descrivere significa riassumere ciò che osserviamo nel campione. Stimare significa usare il campione per ottenere un valore plausibile di una quantità nella popolazione. Inferire significa trarre conclusioni più generali tenendo conto dell'incertezza, delle assunzioni e dei limiti del disegno.

8. Perché osservare un'associazione tra due variabili non basta per concludere che una causa l'altra?

Perché l'associazione potrebbe dipendere da altre variabili non considerate, da bias di selezione, da errori di misura o dalla direzione inversa della relazione. Per sostenere una conclusione causale servono informazioni sul disegno dello studio e sulle possibili spiegazioni alternative.

Bibliografia

3. Disegno di ricerca: quali conclusioni sono giustificate dai dati?

Nel capitolo precedente abbiamo introdotto il passaggio dai fenomeni psicologici ai dati. Abbiamo visto che un dato non è un numero isolato, ma il risultato di una domanda di ricerca, di una procedura di osservazione e di una scelta di misurazione.

In questo capitolo facciamo un passo indietro: prima di descrivere o analizzare i dati, dobbiamo chiederci come sono stati generati. La stessa variabile, misurata con lo stesso strumento, può assumere significati diversi a seconda del disegno dello studio. Un questionario sullo stress somministrato a studenti volontari durante la sessione d'esame non fornisce le stesse conclusioni di un'indagine probabilistica su tutti gli studenti di un ateneo o di un esperimento in cui lo stress viene manipolato in condizioni controllate.

La domanda guida del capitolo è quindi semplice:

Quali conclusioni sono giustificate dal modo in cui questi dati sono stati raccolti?

Questa domanda accompagnerà tutto il percorso successivo. L'EDA aiuta a individuare i pattern nei dati, R permette di organizzarli, descriverli e visualizzarli, mentre l'inferenza bayesiana consente di ragionare in modo esplicito sull'incertezza. Tuttavia, nessuna procedura statistica può eliminare automaticamente i limiti introdotti da un campione distorto, da un disegno inadeguato o da una domanda formulata in modo ambiguo.

Prerequisiti

Per seguire questo capitolo è sufficiente aver compreso i concetti introdotti nel capitolo precedente: popolazione, campione, unità statistica, variabile, osservazione, statistica campionaria, parametro e incertezza.

La letteratura sulla replicabilità in psicologia e sui campioni WEIRD fornisce un importante contesto per approfondire l'argomento (Henrich et al., 2010; Youyou et al., 2023), ma non è necessaria per una prima lettura.

3.1. Perché il disegno di ricerca conta

Quando osserviamo un risultato, per esempio una correlazione tra stress accademico e qualità del sonno, siamo tentati di interpretarlo immediatamente come una proprietà del fenomeno psicologico: “Gli studenti più stressati dormono peggio”. Prima di arrivare a questa conclusione, però, dobbiamo porci alcune domande.

- Chi sono gli studenti osservati?
- Come sono stati reclutati?
- In quale periodo dell'anno sono stati raccolti i dati?

- Lo stress e il sonno sono stati misurati con strumenti validi?
- La raccolta dei dati è avvenuta una sola volta o più volte nel tempo?
- Ci sono variabili alternative che potrebbero spiegare l'associazione osservata?
- Qual è l'obiettivo della nostra analisi: descrivere questi dati, generalizzare a una popolazione più ampia, fare una previsione o sostenere una conclusione causale?

Queste domande non riguardano dettagli tecnici. Definiscono il significato stesso dell'analisi. Il disegno di ricerca stabilisce il rapporto tra tre elementi:

1. **la domanda di ricerca**, cioè ciò che vogliamo capire;
2. **il processo di raccolta dei dati**, cioè come otteniamo le osservazioni;
3. **le conclusioni giustificate**, cioè che cosa possiamo affermare con prudenza.

! Idea chiave

Il disegno di ricerca non serve soltanto a "raccolgere dati". Serve a stabilire quali interpretazioni dei dati sono plausibili e quali, invece, sarebbero troppo forti rispetto all'evidenza disponibile.

3.2. Un esempio ricorrente: stress accademico e sonno

Useremo un esempio semplice per collegare le varie parti del capitolo.

Immaginiamo di voler studiare la relazione tra **stress accademico** e **qualità del sonno** negli studenti universitari. Una possibile domanda di ricerca potrebbe essere:

Gli studenti con livelli più elevati di stress accademico riportano una qualità del sonno peggiore?

Questa domanda può essere affrontata in modi diversi.

Scelta di disegno	Esempio	Conclusione più prudente
Studio descrittivo	Descriviamo il livello medio di stress e sonno in un gruppo di studenti	"In questo campione, lo stress medio è..."
Studio osservazionale trasversale	Misuriamo stress e sonno una sola volta	"Stress e sonno sono associati in questo campione"
Studio longitudinale	Misuriamo stress e sonno più volte durante il semestre	"I cambiamenti nello stress precedono o accompagnano cambiamenti nel sonno"
Studio sperimentale	Manipoliamo una fonte di stress in condizioni controllate	"In queste condizioni, la manipolazione dello stress produce un cambiamento nel sonno o in un indicatore collegato"

La variabile può essere simile, ma il tipo di conclusione cambia. Questa è la ragione per cui il disegno viene prima dell'analisi.

3.3. Popolazione, popolazione target e campione

Nel capitolo precedente abbiamo distinto **popolazione** e **campione**. Qui rendiamo la distinzione più operativa.

La **popolazione target** è l'insieme di persone, casi o unità a cui vorremmo riferire le nostre conclusioni. Nel nostro esempio potrebbe essere:

- tutti gli studenti universitari italiani;
- gli studenti iscritti a un particolare ateneo;
- gli studenti di psicologia del primo anno;
- gli studenti che stanno preparando esami in un certo periodo dell'anno.

La **popolazione accessibile** è l'insieme delle unità che possiamo raggiungere in modo realistico. Spesso è più ristretta della popolazione target. Per esempio, potremmo avere accesso solo agli studenti che frequentano un determinato corso, agli iscritti a una mailing list o ai volontari che rispondono a un annuncio online.

Il **campione** è il sottoinsieme effettivamente osservato.

La distanza tra la popolazione target, la popolazione accessibile e il campione è una delle principali fonti di cautela nell'interpretazione dei risultati.

Esempio

Se vogliamo parlare degli studenti universitari italiani, ma raccogliamo i dati solo dagli studenti di psicologia di un singolo ateneo, durante la settimana precedente agli esami, il campione può essere utile per esplorare il fenomeno. Tuttavia, ciò non autorizza automaticamente una generalizzazione a tutti gli studenti universitari.

3.4. Campionamento e rappresentatività

Il **campionamento** è il processo con cui si selezionano le unità da osservare. Il problema centrale è la rappresentatività: il campione riflette in modo adeguato le caratteristiche della popolazione di riferimento?

Un campione è rappresentativo non perché è “grande” in senso generico, ma perché è stato costruito in modo da ridurre le distorsioni sistematiche rispetto alla popolazione di interesse. Un campione enorme, ma molto selezionato, può essere meno utile di un campione più piccolo, ma costruito con maggiore attenzione.

3.4.1. Campionamento probabilistico

Nel **campionamento probabilistico**, ogni unità della popolazione ha una probabilità nota e diversa da zero di essere inclusa nel campione. Ciò non garantisce che ogni campione sia perfetto, ma consente di ragionare in modo più controllato sull'errore di campionamento e sulla generalizzazione.

I principali tipi sono:

- **Campionamento casuale semplice**: ogni unità ha la stessa probabilità di essere selezionata; Richiede una lista completa della popolazione, chiamata “frame di campionamento”.

- **Campionamento stratificato:** la popolazione viene suddivisa in sottogruppi rilevanti, per esempio in base al genere, all'età o all'area geografica, e si effettua il campionamento da ciascuno strato.
- **Campionamento a grappolo:** si selezionano gruppi naturali, per esempio scuole, classi, reparti o quartieri, e poi si osservano le unità all'interno dei gruppi selezionati.
- **Campionamento multistadio:** si combinano più fasi, per esempio prima si selezionano le scuole, poi le classi e infine gli studenti.

Questi metodi sono particolarmente importanti quando l'obiettivo è stimare quantità riferite a una popolazione ampia, come le prevalenze, le medie, le distribuzioni e le differenze tra sottogruppi.

3.4.2. Campionamento non probabilistico

Nel **campionamento non probabilistico**, la probabilità di inclusione delle unità non è nota. In psicologia ciò si verifica spesso, perché non disponiamo di un elenco completo della popolazione o perché vincoli pratici, economici ed etici rendono difficile un campionamento probabilistico.

Il caso più comune è il **campionamento di convenienza**: i partecipanti vengono reclutati tra persone facilmente accessibili, come gli studenti universitari, i volontari online o le persone disponibili attraverso reti personali e istituzionali.

Il campionamento di convenienza è rapido, economico e spesso necessario. Tuttavia, questo tipo di campionamento limita la possibilità di generalizzare i risultati. Il punto non è vietarlo, ma interpretarlo correttamente.

Errore comune

Affermare che un campione è “di convenienza” non significa che lo studio sia inutile. Significa che dobbiamo essere precisi su ciò che lo studio permette e non permette di concludere.

3.5. Campioni di convenienza nella ricerca psicologica

Molti studi psicologici utilizzano campioni di convenienza, spesso composti da studenti universitari o partecipanti reclutati online. Questa pratica è comprensibile: reclutare un campione probabilistico ampio richiede tempo, risorse, infrastrutture e accesso a popolazioni che spesso non sono disponibili (Peterson & Merunka, 2014).

Tuttavia, i campioni di convenienza possono produrre distorsioni sistematiche. Un campione composto esclusivamente da studenti universitari occidentali, istruiti e giovani potrebbe non rappresentare l'intera variabilità della popolazione umana. Il problema è particolarmente rilevante quando i processi studiati sono influenzati da fattori quali cultura, età, istruzione, status socioeconomico o contesto istituzionale. Questo problema è stato discusso in letteratura attraverso la nozione di campioni WEIRD: *Western, Educated, Industrialized, Rich, Democratic* (WEIRD) (Henrich et al., 2010).

3.5.1. Quando può essere utile

Un campione di convenienza può essere utile quando:

- lo studio è esplorativo;
- si vuole testare una procedura o uno strumento;
- si studia un meccanismo psicologico di base e si è cauti sulla generalizzazione;

3. Disegno di ricerca: quali conclusioni sono giustificate dai dati?

- lo scopo è confrontare pattern, non stimare una prevalenza nella popolazione;
- lo studio verrà replicato in campioni diversi.

3.5.2. Quando è problematico

Diventa invece particolarmente problematico quando:

- si vuole stimare una caratteristica della popolazione generale;
- si vogliono confrontare gruppi sociali o culturali non adeguatamente rappresentati;
- il fenomeno è plausibilmente influenzato da età, cultura, istruzione o contesto;
- le conclusioni vengono presentate come universali senza giustificazione;
- non vengono descritte le caratteristiche del campione.

3.5.3. Come mitigare i limiti

Quando si utilizza un campione di convenienza, alcune pratiche possono aiutare a rendere le conclusioni più trasparenti.

1. **Descrivere il campione in modo accurato:** età, genere, percorso di studi, provenienza, criteri di inclusione ed esclusione.
2. **Limitare le conclusioni:** evitare formule come “le persone” o “gli studenti” se il campione riguarda solo un gruppo specifico.
3. **Diversificare il reclutamento:** includere partecipanti provenienti da diversi corsi, atenei, canali o contesti.
4. **Replicare:** verificare se il pattern si osserva anche in campioni diversi.
5. **Distinguere esplorazione e conferma:** essere chiari se lo studio genera ipotesi o ne testa una già formulata.

Messaggio da ricordare

Il campionamento di convenienza può essere una scelta realistica e informativa, ma richiede una scrittura delle conclusioni prudente. Non dobbiamo chiederci solo “quanti partecipanti abbiamo?”, ma anche “chi manca dal nostro campione?”.

3.6. Bias: quando il processo di raccolta distorce il risultato

Un **bias** è una distorsione sistematica. A differenza della variabilità casuale, che può produrre fluttuazioni in entrambe le direzioni, il bias spinge il risultato verso una direzione particolare.

Alcuni bias comuni nella ricerca psicologica sono:

Tipo di bias	Descrizione	Esempio
Bias di selezione	Alcune persone hanno più probabilità di entrare nel campione	Rispondono al questionario soprattutto studenti molto motivati
Bias di autoselezione	La partecipazione dipende da caratteristiche dei partecipanti	Partecipa chi ha un interesse speciale per il tema dello stress

Tipo di bias	Descrizione	Esempio
Bias di non risposta	Chi non risponde differisce da chi risponde	Gli studenti più stressati ignorano l'invito per mancanza di tempo
Bias di contesto	Il momento o il luogo della raccolta influenza le risposte	Dati raccolti solo durante la sessione d'esame
Bias dell'osservatore	Aspettative del ricercatore influenzano la raccolta o codifica dei dati	Il valutatore interpreta risposte ambigue in linea con l'ipotesi

Il bias non si elimina semplicemente aumentando la dimensione del campione. Se la procedura di selezione dei partecipanti è sistematica e tende a includere sempre lo stesso tipo di partecipanti, aggiungere altri partecipanti dello stesso tipo può rendere la stima più precisa, ma non più corretta.

3.7. Disegni di ricerca: descrivere, associare, spiegare

Una distinzione fondamentale riguarda il tipo di domanda che lo studio permette di affrontare.

Tipo di studio	Domanda tipica	Cosa sostiene bene	Cosa non sostiene da solo
Descrittivo	Com'è distribuita una variabile?	Descrizione di un campione o di una popolazione ben definita	Causalità e meccanismi
Osservazionale trasversale	Due variabili sono associate?	Relazioni tra variabili misurate nello stesso momento	Direzione causale
Osservazionale longitudinale	Come cambiano le variabili nel tempo?	Sequenze temporali e traiettorie	Causalità senza controllo dei confondenti
Sperimentale	Una manipolazione produce un effetto?	Inferenza causale in condizioni controllate	Generalizzazione automatica a ogni contesto

Questa tabella introduce un principio semplice: non tutti i dati rispondono allo stesso tipo di domanda. Un disegno può essere eccellente per descrivere, ma insufficiente per spiegare causalmente; oppure può essere molto controllato, ma poco rappresentativo del mondo reale.

3.8. Studi descrittivi

Uno studio descrittivo mira a rappresentare come si presenta un fenomeno in un campione o in una popolazione. Nel nostro esempio, potremmo voler sapere:

- qual è il livello medio di stress accademico nel campione;
- quanto varia la qualità del sonno tra gli studenti;
- quanti studenti riportano livelli di stress molto elevati;

3. Disegno di ricerca: quali conclusioni sono giustificate dai dati?

- se la distribuzione delle risposte è simmetrica o asimmetrica.

Gli studi descrittivi sono spesso il primo passo di un'indagine. Non vanno considerati inferiori agli studi inferenziali: senza una descrizione accurata, rischiamo di modellare dati che non abbiamo ancora compreso.

Il collegamento con l'EDA è diretto. Tabelle, grafici, indici di posizione, dispersione e forma della distribuzione servono proprio a costruire una descrizione informativa dei dati.

3.9. Studi osservazionali

Negli **studi osservazionali**, il ricercatore misura variabili senza manipolarle direttamente. Per esempio, si può misurare lo stress accademico e la qualità del sonno in un gruppo di studenti e verificare se sono correlati.

Il vantaggio degli studi osservazionali è che permettono di studiare fenomeni in contesti naturali e situazioni in cui la manipolazione sarebbe impossibile o non etica. Il limite principale è che le associazioni osservate possono essere spiegate da variabili alternative.

3.9.1. Studi trasversali

In uno **studio trasversale**, i dati vengono raccolti in un unico momento. Questo disegno è utile per descrivere una situazione o esaminare le associazioni tra le variabili. Tuttavia, se stress e sonno vengono misurati nello stesso momento, è difficile stabilire se lo stress preceda il sonno scarso, se il sonno scarso aumenti lo stress o se entrambi dipendano da una terza variabile.

3.9.2. Studi longitudinali

In uno **studio longitudinale**, le stesse unità vengono osservate più volte nel tempo. Questo tipo di studio è più informativo quando si vogliono studiare il cambiamento, la stabilità e la sequenza temporale. Se lo stress misurato a ottobre predice la qualità del sonno a novembre, abbiamo un'informazione temporale in più rispetto a uno studio trasversale.

Tuttavia, la sequenza temporale da sola non basta a dimostrare la causalità. Potrebbero infatti esistere variabili confondenti, come il carico di lavoro, le condizioni economiche, la salute fisica o i tratti della personalità.

3.9.3. Studi caso-controllo e studi di coorte

In alcuni contesti si utilizzano disegni osservazionali più specifici.

- Negli **studi di coorte**, un gruppo di individui viene seguito nel tempo per osservare l'insorgenza di un determinato esito. Per esempio, si potrebbero seguire studenti con diversi livelli iniziali di stress e osservare chi sviluppa problemi di sonno persistenti.
- Negli **studi caso-controllo**, si confrontano persone che presentano un certo esito con persone che non lo presentano, cercando differenze pregresse o concomitanti. Per esempio, si potrebbero confrontare gli studenti con insonnia clinicamente rilevante e quelli senza insonnia in relazione alla loro recente storia di stress accademico.

Questi disegni sono utili in molte aree della psicologia applicata e della ricerca clinica, ma richiedono un'attenzione particolare ai bias di selezione e di ricordo.

3.10. Studi sperimentali

Negli **studi sperimentali**, il ricercatore manipola una variabile indipendente e ne osserva l'effetto su una variabile dipendente. L'obiettivo è rendere più credibile una conclusione causale.

Nel nostro esempio, potremmo manipolare il livello di stress indotto da un compito: un gruppo di soggetti svolgerà un compito valutativo sotto pressione, mentre un altro gruppo svolgerà un compito simile senza pressione. Successivamente, si confronta un indicatore di sonno o un indicatore più immediato collegato allo stress, come l'attivazione fisiologica, le prestazioni o i tempi di reazione.

Un esperimento ben progettato si basa su tre ingredienti principali.

3.10.1. Manipolazione

La **manipolazione** è l'intervento del ricercatore sulla variabile indipendente. In assenza di manipolazione, è possibile osservare differenze tra le persone, ma è più difficile attribuirle a una causa specifica.

3.10.2. Controllo

Il **controllo** consiste nel mantenere costanti o comunque gestire i fattori che potrebbero influenzare l'esito. Un gruppo di controllo fornisce un punto di riferimento: cosa accade quando la manipolazione non viene applicata o viene applicata in modo neutro?

3.10.3. Randomizzazione

La **randomizzazione** assegna i partecipanti alle condizioni sperimentali in modo casuale. Questo metodo aiuta a distribuire variabili note e non note tra i gruppi, riducendo la probabilità che una differenza osservata dipenda da caratteristiche preesistenti dei partecipanti.

! Causalità

La randomizzazione non rende automaticamente perfetto uno studio, ma è uno degli strumenti più potenti per sostenere un'inferenza causale. In assenza di randomizzazione, le differenze tra i gruppi possono riflettere differenze già presenti prima dell'intervento.

3.10.4. Cecità e aspettative

In psicologia, le aspettative dei partecipanti e dei ricercatori possono influenzare il comportamento, le risposte e persino la codifica dei dati. Per questo motivo si utilizzano le procedure di **cecità** (*blinding*):

- nella **cecità singola**, il partecipante non conosce la condizione assegnata;
- nella **cecità doppia**, né il partecipante né chi interagisce con lui conoscono l'assegnazione;
- in alcune situazioni, anche l'analisi può essere condotta senza conoscere le etichette delle condizioni.

Tuttavia, non sempre è possibile ricorrere alla cecità. L'importante è chiedersi se le aspettative e le conoscenze del ricercatore o del partecipante possano influenzare i dati.

3.10.5. Disegni **between-subjects** e **within-subjects**

Nei disegni **between-subjects**, i partecipanti sono assegnati a condizioni diverse. Ogni persona vive una sola condizione. Questo metodo evita gli effetti di apprendimento o di contaminazione tra le condizioni, ma richiede un numero maggiore di partecipanti per distinguere l'effetto della manipolazione dalla variabilità individuale.

Nei disegni **within-subjects**, invece, gli stessi partecipanti vivono più condizioni. Questo riduce la variabilità tra le persone, perché ogni partecipante funge in parte da proprio controllo. Tuttavia, introduce possibili effetti di ordine, pratica, affaticamento o memoria. Per questo motivo, spesso si bilancia l'ordine delle condizioni.

3.11. Validità interna, esterna e di costrutto

Quando valutiamo un disegno, possiamo porci tre domande.

3.11.1. Validità interna

La **validità interna** riguarda la credibilità della conclusione causale. Se osserviamo una differenza tra due condizioni, possiamo attribuirla alla manipolazione oppure esistono spiegazioni alternative?

La validità interna aumenta quando il disegno sperimentale controlla i fattori di confusione, utilizza la randomizzazione, standardizza le procedure e riduce il bias di aspettativa.

3.11.2. Validità esterna

La **validità esterna** riguarda la generalizzabilità. I risultati sono validi solo per il campione osservato o possono essere trasferiti ad altre persone, contesti, tempi e culture?

Un esperimento molto controllato può avere una buona validità interna, ma una validità esterna limitata. Al contrario, uno studio condotto in un contesto naturale può essere più realistico, ma meno controllato.

3.11.3. Validità di costrutto

La **validità di costrutto** riguarda il rapporto tra la variabile osservata e il costrutto teorico. Il questionario utilizzato misura davvero lo stress accademico? L'indicatore del sonno rappresenta davvero la qualità del sonno?

A questa domanda si tornerà nel capitolo successivo, dedicato alla misurazione. Qui è sufficiente notare che un disegno ben costruito può comunque produrre conclusioni fragili se le variabili non rappresentano adeguatamente i costrutti teorici.

3.12. Replicazione e accumulo dell'evidenza

Uno studio singolo difficilmente chiude una questione scientifica. Ciò è particolarmente vero in psicologia, dove gli effetti possono dipendere dal contesto, dalla popolazione, dalla procedura, dagli strumenti e dalle modalità di analisi. La replicazione è quindi una pratica essenziale per valutare la robustezza dei risultati (Youyou et al., 2023).

Possiamo distinguere due tipi di replicazione:

- **replicazione diretta**, quando si ripete uno studio cercando di mantenere il più possibile le stesse condizioni;
- **replicazione concettuale**, quando si testa la stessa idea con procedure, campioni o misure parzialmente diverse.

La replicazione non è un atto meccanico. Permette di capire se un risultato dipende da una specifica combinazione di scelte operative o se riflette un modello più stabile.

3.13. Collegamento con EDA e R

Quando arriveremo all'analisi esplorativa dei dati, useremo R per organizzare i dataset, calcolare le statistiche descrittive, costruire i grafici e individuare i pattern. Tuttavia, ogni operazione avrà senso solo se collegata al disegno.

Prima di analizzare un dataset, dovremmo sempre chiederci:

1. Qual è la popolazione target?
2. Qual è la popolazione accessibile?
3. Come è stato selezionato il campione?
4. Quali variabili sono state misurate e in quale momento?
5. Il disegno è descrittivo, osservazionale o sperimentale?
6. Quali bias sono plausibili?
7. Quali conclusioni sono giustificate?

Queste domande saranno parte integrante del lavoro pratico: prima di calcolare una media o di disegnare un grafico, dobbiamo comprendere il significato delle righe e delle colonne del dataset.

3.14. Collegamento con l'inferenza bayesiana

Il legame con l'inferenza bayesiana è profondo, anche se in questo capitolo non introdurremo ancora modelli formali. Un'analisi bayesiana consente di rendere esplicita l'incertezza e di aggiornare le credenze alla luce dei dati. Tuttavia, l'incertezza rappresentata dal modello non esaurisce tutte le fonti di incertezza.

Alcune incertezze derivano dal processo di generazione dei dati:

- il campione rappresenta davvero la popolazione di riferimento?
- la procedura ha introdotto dei bias?
- le variabili misurate catturano i costrutti rilevanti?
- il disegno consente di trarre conclusioni causali o solo associative?
- Il risultato è robusto a campioni e contesti diversi?

3. Disegno di ricerca: quali conclusioni sono giustificate dai dati?

Queste domande rimarranno valide anche quando useremo modelli più sofisticati. Un modello bayesiano ben stimato non compensa automaticamente un disegno debole. Piuttosto, ci aiuta a discutere in modo più trasparente ciò che i dati, dati i loro limiti, suggeriscono.

3.15. Cosa portare al capitolo successivo

Il messaggio centrale del capitolo è che i dati hanno una storia. Prima di analizzarli dobbiamo sapere come sono stati prodotti.

Da questo capitolo dovremmo portare con noi cinque idee:

1. La popolazione target non coincide necessariamente con il campione osservato.
2. Il campionamento influenza la possibilità di generalizzare.
3. Il campionamento di convenienza può essere utile, ma richiede cautela nell'interpretazione dei risultati.
4. Disegni descrittivi, osservazionali e sperimentali sostengono conclusioni diverse.
5. La causalità richiede condizioni più stringenti rispetto alla semplice associazione.

Nel prossimo capitolo ci concentreremo su un altro passaggio essenziale: **che cosa significa misurare una variabile psicologica**. Anche quando il disegno è appropriato, infatti, resta da chiarire se i numeri osservati rappresentano davvero i costrutti che vogliamo studiare.

Esercizi

! Problemi

1. Uno studio vuole stimare il livello medio di stress degli studenti universitari italiani, ma recluta partecipanti solo tramite un annuncio pubblicato nel corso di psicometria di un singolo ateneo. Qual è la popolazione target? Qual è la popolazione accessibile? Quali limiti di generalizzazione emergono?
2. Nel dataset di uno studio su stress e sonno, osserviamo che gli studenti più stressati riportano una peggiore qualità del sonno. Quali conclusioni sono giustificate se lo studio è trasversale? Quali conclusioni non sono giustificate?
3. Perché aumentare la dimensione di un campione di convenienza non elimina necessariamente il bias di selezione?
4. Confronta un disegno between-subjects e un disegno within-subjects per uno studio sperimentale sull'effetto di una procedura di rilassamento sull'ansia pre-esame. Quali vantaggi e limiti avrebbe ciascun disegno?
5. Scegli uno studio psicologico che conosci, anche ipotetico, e valuta separatamente validità interna, validità esterna e validità di costrutto.

💡 Soluzioni

1. Popolazione target, popolazione accessibile e limiti di generalizzazione

La popolazione target dichiarata è l'insieme degli studenti universitari italiani. La popolazione accessibile, però, è molto più ristretta: gli studenti raggiunti attraverso il corso di psicometria

di un singolo ateneo. Il campione effettivo sarà ancora più ristretto, perché includerà solo chi decide di rispondere.

Il limite principale è che il campione potrebbe differire dalla popolazione target per percorso di studi, età, genere, motivazione, periodo dell'anno, familiarità con la psicologia e molti altri fattori. Lo studio può essere utile come esplorazione, ma non autorizza una stima forte del livello medio di stress di tutti gli studenti universitari italiani.

2. Associazione tra stress e sonno in uno studio trasversale

Se lo studio è trasversale, possiamo dire che nel campione osservato stress e qualità del sonno risultano associati. Possiamo anche descrivere la direzione dell'associazione, per esempio che livelli più alti di stress tendono ad accompagnarsi a qualità del sonno più bassa.

Non possiamo però concludere che lo stress causa il peggioramento del sonno. Potrebbe essere il sonno scarso ad aumentare lo stress, oppure entrambe le variabili potrebbero dipendere da altri fattori, come carico di studio, lavoro, salute fisica o difficoltà economiche.

3. Dimensione del campione e bias di selezione

Un campione più grande riduce la variabilità casuale delle stime, ma non elimina una distorsione sistematica. Se il reclutamento raggiunge soprattutto un certo tipo di partecipanti, aggiungere altri partecipanti reclutati nello stesso modo può rendere il risultato più stabile ma ancora distorto.

Per esempio, diecimila risposte raccolte solo da studenti di psicologia non rappresentano automaticamente tutti gli studenti universitari. La quantità di dati non sostituisce la qualità del processo di campionamento.

4. Disegno between-subjects e within-subjects

In un disegno between-subjects, un gruppo riceve la procedura di rilassamento e un altro gruppo no, o riceve una procedura di controllo. Il vantaggio è che ogni partecipante sperimenta una sola condizione, riducendo effetti di contaminazione. Il limite è che differenze individuali preesistenti possono aumentare la variabilità, anche se la randomizzazione aiuta a bilanciarle. In un disegno within-subjects, gli stessi partecipanti vengono osservati in entrambe le condizioni, per esempio con e senza rilassamento. Il vantaggio è che ogni partecipante funge da proprio controllo, aumentando la precisione. Il limite è che possono comparire effetti di ordine, pratica, aspettativa o affaticamento. Servirebbe quindi bilanciare l'ordine delle condizioni.

5. Validità interna, esterna e di costrutto

La validità interna riguarda quanto è credibile l'interpretazione causale: il disegno controlla spiegazioni alternative? La validità esterna riguarda la possibilità di generalizzare: il campione e il contesto rappresentano la popolazione o le situazioni a cui vogliamo riferirci? La validità di costrutto riguarda la qualità della misurazione: le variabili osservate rappresentano davvero i costrutti teorici?

Uno studio può essere forte su una dimensione e debole su un'altra. Per esempio, un esperimento di laboratorio può avere buona validità interna ma validità esterna limitata; uno studio sul campo può avere maggiore realismo ma minore controllo.

Bibliografia

4. La misurazione in psicologia

Prima di calcolare una media, costruire un grafico o stimare un modello, è necessario chiedersi cosa rappresentano i numeri che abbiamo di fronte. In psicologia questa domanda è particolarmente importante, perché molti fenomeni di interesse, come ansia, stress, motivazione, benessere, autostima e attenzione, non sono osservabili direttamente. Li conosciamo attraverso risposte, comportamenti, tempi, scelte, punteggi o indicatori fisiologici. Ogni misura è quindi una traduzione imperfetta di un costrutto teorico in un dato osservabile.

Questo capitolo introduce gli strumenti concettuali minimi per ragionare su questa traduzione. L'obiettivo non è memorizzare una tassonomia di scale di misura, ma imparare a porsi tre domande:

1. **Che cosa vogliamo misurare?**
Qual è il costrutto psicologico di interesse?
2. **Che cosa osserviamo davvero?**
Quale indicatore, risposta o comportamento viene registrato nei dati?
3. **Che cosa possiamo fare con quei valori?**
Quali descrizioni, grafici, statistiche e modelli sono coerenti con la natura della misura?

Queste domande collegano il capitolo precedente, dedicato al disegno della ricerca, ai capitoli successivi sull'analisi esplorativa dei dati. Anche il disegno migliore può produrre conclusioni fragili se le variabili osservate non rappresentano adeguatamente i costrutti che intendiamo studiare.

Panoramica del capitolo

In questo capitolo imparerai a:

- distinguere costrutti psicologici, indicatori osservabili e valori registrati;
- comprendere il ruolo dell'errore di misura;
- distinguere affidabilità e validità;
- usare i livelli di scala come strumenti diagnostici;
- riconoscere quali operazioni statistiche sono coerenti con una misura;
- discutere il caso delle scale Likert in modo non dogmatico;
- collegare la misurazione alla scelta di grafici, statistiche descrittive e modelli;
- comprendere perché la misurazione è un problema epistemologico, non solo tecnico.

Prerequisiti

Per seguire questo capitolo è utile avere chiari i concetti introdotti nei capitoli precedenti: fenomeno psicologico, domanda di ricerca, variabile, unità statistica, campione, popolazione, bias e incertezza.

Lecture facoltative per chi desidera approfondire:

- Maul et al. (2016), sui fondamenti filosofici della misurazione psicologica;

- Lilienfeld & Strother (2020), sul rapporto tra misurazione psicologica e crisi della replicabilità;
- Stevens (1946), per la tassonomia classica dei livelli di misura.

Queste letture non sono prerequisiti obbligatori. Il capitolo fornisce tutto il necessario per seguire il percorso introduttivo.

4.1. Perché la misurazione viene prima dell'analisi

Quando apriamo un dataset, vediamo righe, colonne e valori. È naturale pensare che il lavoro statistico inizi da lì. Ma quei valori sono il risultato finale di una serie di decisioni:

1. abbiamo scelto un fenomeno psicologico da studiare;
2. abbiamo formulato una domanda empirica;
3. abbiamo definito uno o più costrutti;
4. abbiamo scelto indicatori osservabili;
5. abbiamo raccolto risposte, comportamenti o misure;
6. abbiamo codificato queste osservazioni in variabili;
7. abbiamo organizzato le variabili in una matrice di dati.

Ogni passaggio può introdurre errore, ambiguità o bias. Per questo motivo, una variabile non è solo una colonna in un file, ma il risultato di una serie di scelte teoriche e operative.

! Idea guida

In psicologia non misuriamo direttamente i costrutti. Osserviamo indicatori che li rappresentano in modo parziale, fallibile e dipendente dal contesto.

Consideriamo l'esempio guida già introdotto nei capitoli precedenti:

Gli studenti universitari che riportano livelli più alti di stress accademico dormono peggio?

Questa domanda contiene almeno due costrutti: *stress accademico* e *qualità del sonno*. Nessuno dei due è osservabile direttamente, come lo è la lunghezza di un tavolo. Dobbiamo quindi decidere come rappresentarli.

Per lo stress accademico potremmo usare:

- una scala self-report sulla pressione percepita;
- il numero di esami imminenti;
- il numero di ore di studio settimanali;
- una misura fisiologica, come la variabilità della frequenza cardiaca;
- una combinazione di più indicatori.

Per il sonno potremmo usare:

- ore di sonno dichiarate dallo studente;
- qualità soggettiva del sonno su scala Likert;
- diario del sonno;
- dati raccolti da un dispositivo indossabile;
- numero di risvegli notturni.

Queste scelte non sono equivalenti. Ciascuna misura coglie un aspetto diverso del fenomeno e presenta limiti specifici. Misurare significa stabilire quale relazione intendiamo instaurare tra il costrutto teorico e l'indicatore osservato.

4.2. Costrutti, indicatori e dati

Un *costrutto* è un concetto teorico utilizzato per spiegare o descrivere un fenomeno psicologico. Esempi di costrutti sono ansia, depressione, intelligenza, stress, motivazione, impulsività e benessere. Sono utili perché aiutano a organizzare il pensiero teorico, ma non sono direttamente visibili.

Un *indicatore* è ciò che osserviamo per avvicinarci al costrutto. Può trattarsi di una risposta a un questionario, di un comportamento, di un tempo di reazione, di un numero di errori, di una scelta, di una valutazione da parte di un osservatore o di una misura fisiologica.

Un *dato* è il valore registrato per quell'indicatore in una specifica unità statistica.

Livello	Esempio nello studio su stress e sonno
Costrutto	Stress accademico
Indicatore	Punteggio a una scala di stress percepito
Dato osservato	Uno studente ottiene 27 su 40

Questa distinzione è fondamentale. Il punteggio 27 non è *lo stress* dello studente. Si tratta di un valore osservato che, secondo una determinata teoria e una determinata procedura di misurazione, dovrebbe fornire informazioni sul suo stress accademico.

Errore comune

Un errore frequente è quello di identificare il costrutto con il punteggio. Dire “lo stress è 27” è scorretto. È più prudente dire: “Lo studente ha ottenuto 27 con questo strumento che, si suppone, misuri lo stress accademico”.

4.3. L'equazione fondamentale della misurazione

Una misura osservata può essere rappresentata in modo molto semplice:

$$y = z + \varepsilon_y,$$

dove:

- y è il valore osservato;
- z è il valore teorico del costrutto che vorremmo conoscere;
- ε_y è l'errore di misura.

Questa equazione non va letta come una formula tecnica da applicare immediatamente, ma come una mappa concettuale. Ci ricorda che il dato osservato non corrisponde mai perfettamente al costrutto. Ogni misura contiene una componente informativa e una componente di errore.

Nel caso dello stress accademico, l'errore può nascere da molteplici fonti:

- lo studente interpreta male un item;

- risponde in modo socialmente desiderabile;
- compila il questionario in una giornata particolarmente difficile;
- la scala non copre bene tutte le dimensioni dello stress;
- alcuni item misurano l'ansia generale più che lo stress accademico;
- la modalità di somministrazione influenza le risposte.

L'equazione $y = z + \varepsilon_y$ aiuta a organizzare tre domande centrali.

Domanda	Concetto collegato	Significato
Quanto rumore contiene la misura?	Affidabilità	La misura è stabile e coerente?
La misura cattura il costrutto giusto?	Validità	Stiamo misurando ciò che diciamo di misurare?
Quali operazioni sono legittime sui valori osservati?	Livello di scala	Media, differenze, rapporti e modelli hanno senso?

4.4. Affidabilità: quanto rumore contiene la misura

Una misura è *affidabile* quando produce risultati coerenti, stabili e poco rumorosi, a parità di ciò che si intende misurare. Se uno strumento è molto instabile, il valore osservato dipenderà eccessivamente da fattori accidentali.

L'affidabilità può assumere forme diverse:

- *stabilità nel tempo*: la misura produce risultati simili se ripetuta in condizioni comparabili;
- *coerenza interna*: gli item di una scala che dovrebbero misurare lo stesso costrutto tendono a muoversi insieme;
- *accordo tra valutatori*: osservatori diversi assegnano valutazioni simili agli stessi comportamenti;
- *precisione della procedura*: lo strumento registra valori con poca variabilità accidentale.

Una misura poco affidabile rende difficile individuare dei pattern nei dati. Se lo stress viene misurato con un elevato livello di rumore, l'associazione tra stress e sonno può apparire più debole, instabile o addirittura scomparire.

i Precisione e bias

La precisione riguarda la variabilità accidentale delle misure. Il bias, invece, riguarda una distorsione sistematica. Uno strumento può essere preciso, ma distorto: può, per esempio, fornire valori molto coerenti, ma costantemente spostati nella stessa direzione.

4.5. Validità: stiamo misurando il costrutto giusto?

Una misura è *valida* nella misura in cui sostiene l'interpretazione che vogliamo attribuirle. La validità non è una proprietà magica dello strumento in sé, ma dipende dall'uso che se ne fa, dalla popolazione presa in esame, dal contesto e dalle conclusioni che si vogliono trarre.

Per esempio, una scala può essere valida per misurare lo stress accademico degli studenti universitari durante la sessione d'esame, ma non necessariamente per i lavoratori adulti, gli adolescenti o i

pazienti clinici. Una misura può funzionare bene per descrivere le differenze tra i gruppi, ma può non essere adatta per prendere decisioni individuali.

Alcune domande utili sono:

- gli item coprono davvero il costrutto di interesse?
- la misura distingue il costrutto da fenomeni simili, ma diversi?
- i punteggi sono associati ad altri indicatori in modo coerente con la teoria?
- la misura funziona allo stesso modo in gruppi diversi?
- l'interpretazione dei punteggi è giustificata nel contesto specifico dello studio?

! Affidabilità non basta

Una misura può essere affidabile, ma non valida. Un questionario può produrre punteggi molto stabili e coerenti, ma misurare l'ansia generale invece dello stress accademico.

4.6. Il livello di scala: quali operazioni sono legittime?

Dopo aver chiarito il rapporto tra costrutto e indicatore, dobbiamo chiederci che tipo di informazione è contenuta nei valori osservati. La tassonomia classica di Stevens (1946) distingue quattro livelli di scala: nominale, ordinale, a intervalli e di rapporti.

Questa classificazione non deve essere imparata a memoria. Si tratta di uno strumento diagnostico che aiuta a stabilire quali operazioni statistiche e quali interpretazioni sono coerenti con la misura.

Scale di modalità	Operazioni aritmetiche
nominali	enumerare le classi di equivalenza e/o le frequenze per ciascuna classe di equivalenza
ordinali	enumerare le classi di equivalenza e/o le frequenze per ciascuna classe di equivalenza
intervallari	differenze (rapporti tra differenze)
di rapporti	rapporti diretti tra le misure

Figura 4.1.: Scale di misurazione.

4.6.1. Scala nominale

Una scala nominale classifica le osservazioni in categorie senza ordine intrinseco.

Esempi in psicologia:

- condizione sperimentale: controllo, trattamento, placebo;
- tipo di diagnosi;
- modalità di risposta scelta;
- gruppo di appartenenza.

Con una variabile nominale è possibile contare le frequenze, calcolare le proporzioni e identificare la categoria più frequente. Non ha senso calcolare la media delle etichette numeriche eventualmente usate per codificare le categorie.

 Esempio

Se codifichiamo controllo = 0 e trattamento = 1, i numeri sono etichette. La media della variabile può essere utile come proporzione di partecipanti nel gruppo di trattamento, ma questo non significa che esista una quantità psicologica intermedia tra il gruppo di controllo e quello di trattamento.

4.6.2. Scala ordinale

Una scala ordinale introduce un ordine tra le categorie, ma non garantisce che le distanze tra categorie siano uguali.

Esempi:

- gravità dei sintomi: lieve, moderata, severa;
- giudizio di accordo: per nulla, poco, abbastanza, molto;
- posizione in una graduatoria;
- qualità del sonno valutata da 1 a 5.

Con i dati ordinali è possibile ordinare i valori, calcolare le mediane, i percentili e le frequenze cumulative. Dobbiamo invece essere cauti con le medie e le differenze, perché presuppongono che le distanze tra le categorie siano interpretabili.

4.6.3. Scala a intervalli

Una scala a intervalli permette di interpretare le differenze tra valori. La distanza tra 10 e 20 ha lo stesso significato della distanza tra 40 e 50. Tuttavia, lo zero è un valore arbitrario e non indica l'assenza della proprietà misurata.

Esempi classici sono la temperatura in gradi Celsius o Fahrenheit e molti punteggi standardizzati, come alcuni punteggi psicometrici. Se un test ha una media di 100 e una deviazione standard di 15, una differenza di 15 punti può essere interpretata in relazione alla scala, ma non ha senso affermare che un punteggio di 120 rappresenta il doppio di un punteggio di 60.

Con le scale a intervalli hanno senso medie, differenze e deviazioni standard. Non hanno senso, invece, le interpretazioni basate su rapporti diretti tra valori.

4.6.4. Scala di rapporti

Una scala di rapporti possiede tutte le proprietà di una scala a intervalli, ma ha anche uno zero non arbitrario che rappresenta l'assenza della quantità misurata. Ciò rende interpretabili i rapporti tra i valori.

Esempi:

- tempo di reazione;
- numero di errori;
- numero di parole ricordate;

4. La misurazione in psicologia

- frequenza di un comportamento in un intervallo di tempo;
- durata di un'attività.

Se una persona impiega 800 millisecondi e un'altra 400, ha senso dire che il primo tempo è il doppio del secondo. Questa interpretazione è possibile perché lo zero della scala temporale non è una convenzione arbitraria.

4.6.5. Una sintesi operativa

Livello	Che cosa preserva	Operazioni tipiche	Esempio
Nominale	Identità/diversità	Frequenze, proporzioni, moda	Tipo di terapia
Ordinale	Ordine	Mediana, percentili, ranghi	Gravità dei sintomi
Intervalli	Differenze	Media, deviazione standard, differenze	Punteggio standardizzato
Rapporti	Rapporti	Tutte le operazioni precedenti più rapporti	Tempo di reazione

Errore comune

Assegnare dei numeri a una variabile non la rende automaticamente quantitativa. I numeri possono essere etichette, ranghi, punteggi approssimativi o vere e proprie misure quantitative. Il loro significato dipende dalla procedura di misurazione utilizzata.

4.7. Il test della trasformazione

Un modo pratico per capire se un'interpretazione è legittima consiste nel chiedersi quali trasformazioni dei valori non alterano il significato della misura.

- Per una scala nominale, è possibile cambiare le etichette senza alterare l'informazione.
- Per una scala ordinale, possiamo applicare trasformazioni monotone che preservano l'ordine.
- Per una scala a intervalli, possiamo cambiare l'origine e le unità di misura con trasformazioni lineari.
- Per una scala di rapporti, possiamo cambiare le unità di misura moltiplicando per una costante positiva, ma non possiamo spostare arbitrariamente lo zero.

Test della trasformazione

Se una conclusione cambia in modo sostanziale dopo una trasformazione che dovrebbe essere ammissibile per quel livello di scala, allora probabilmente stiamo attribuendo alla variabile proprietà metriche che non possiede.

4.7.1. Esempio pratico in R

Consideriamo risposte su una scala Likert da 1 a 5. Se trattiamo la scala come puramente ordinale, ciò che deve essere preservato è l'ordine. Se invece calcoliamo le medie e le differenze, stiamo facendo un'assunzione ulteriore: che le distanze tra le categorie siano interpretabili.

```
# Risposte su scala Likert 1-5
likert <- c(2, 3, 4, 3, 5, 2, 4, 3, 4, 5)

# Trasformazione monotona: preserva l'ordine ma cambia le distanze
likert_monotona <- c(1, 2, 4, 2, 10, 1, 4, 2, 4, 10)

# La mediana è meno sensibile alla trasformazione monotona
median(likert)
```

```
[1] 3.5
```

```
median(likert_monotona)
```

```
[1] 3
```

```
# La media dipende invece dalle distanze numeriche assegnate
mean(likert)
```

```
[1] 3.5
```

```
mean(likert_monotona)
```

```
[1] 4
```

Questo esempio non dimostra che le medie su scala Likert siano sempre errate. Mostra, però, che la media incorpora un'assunzione: i valori numerici devono rappresentare distanze interpretabili. Se tale assunzione è fragile, le conclusioni basate sulle medie devono essere presentate con cautela.

4.8. Il caso delle scale Likert

Le scale Likert sono molto diffuse in psicologia. Chiedono ai partecipanti di esprimere il loro grado di accordo, frequenza, intensità o valutazione soggettiva utilizzando categorie ordinate, solitamente da 1 a 5 o da 1 a 7.

Dal punto di vista strettamente statistico, ogni item Likert è ordinale: sappiamo che “molto d'accordo” indica un livello di accordo maggiore rispetto a “abbastanza d'accordo”, ma non sappiamo se la distanza psicologica tra le categorie adiacenti sia costante.

Nella pratica, tuttavia, molte analisi trattano i punteggi Likert aggregati come approssimazioni di scale a intervalli. Questa scelta può essere ragionevole quando:

- il punteggio deriva dalla somma o dalla media di più item coerenti;

4. La misurazione in psicologia

- la scala ha un numero sufficiente di categorie;
- la distribuzione non è estremamente asimmetrica o concentrata agli estremi.
- le conclusioni sono robuste rispetto ad analisi alternative;
- l'assunzione metrica viene dichiarata esplicitamente.

La soluzione non è vietare sempre le medie né usarle sempre senza riflettere. La soluzione è rendere esplicita l'assunzione.

Una posizione pragmatica

Trattare una scala Likert come approssimazione intervallare è una scelta modellistica, non una verità garantita dai dati. Può essere utile, ma va giustificata e controllata.

4.8.1. Raccomandazioni pratiche

Quando si lavora con scale Likert o punteggi psicologici simili:

1. specifica se stai analizzando singoli item o punteggi aggregati;
2. dichiara se tratti il punteggio come ordinale o approssimativamente intervallato;
3. Evita interpretazioni di rapporto, come “il doppio dell'accordo”;
4. controlla le distribuzioni, i valori estremi e i pattern di risposta;
5. quando l'esito è centrale per la ricerca, valuta l'analisi di sensibilità o i modelli ordinali;
6. Collegare sempre l'interpretazione dei punteggi al costrutto teorico.

4.9. Misure self-report, comportamentali e fisiologiche

Molte misure psicologiche sono *self-report*: chiedono alla persona di descrivere stati, atteggiamenti, emozioni o comportamenti. Questi strumenti sono preziosi perché molti fenomeni psicologici hanno una componente soggettiva accessibile solo attraverso il resoconto della persona.

Tuttavia, i self-report possono essere influenzati da:

- desiderabilità sociale;
- memoria imperfetta;
- interpretazione diversa degli item;
- stanchezza o scarsa attenzione;
- stile di risposta, per esempio tendenza ad accordarsi con le affermazioni;
- contesto di somministrazione.

Le misure comportamentali e fisiologiche sembrano talvolta più oggettive, ma non sono automaticamente più valide. Anche un tempo di reazione, il numero di errori o un indicatore fisiologico richiedono una teoria che spieghi perché quell'indicatore dovrebbe rappresentare il costrutto.

Esempio

Un tempo di reazione più lento in un compito cognitivo può riflettere minore attenzione, maggiore cautela, difficoltà del compito, affaticamento, scarsa motivazione o una strategia di risposta diversa. Il dato è osservabile, ma la sua interpretazione richiede un modello teorico.

4.10. Variabili discrete e continue

Il livello di scala non esaurisce le proprietà di una variabile. Un'altra distinzione importante riguarda la granularità: alcune variabili sono discrete, altre continue.

Una *variabile discreta* assume valori separati, spesso interi. Esempi:

- numero di errori;
- numero di parole ricordate;
- numero di accessi a una piattaforma;
- numero di episodi in un periodo.

Una *variabile continua* può assumere, almeno idealmente, infiniti valori all'interno di un intervallo. Esempi:

- tempo di reazione;
- durata del sonno;
- altezza;
- intensità fisiologica misurata da uno strumento.




Figura 4.2.: Esempi di distribuzioni per variabili discrete e continue.

Questa distinzione è importante perché influenza la scelta dei grafici, delle statistiche descrittive e dei modelli. Per esempio, il conteggio degli errori non ha le stesse proprietà di una misura continua del tempo. Allo stesso modo, un punteggio su una scala con pochi valori possibili può richiedere cautele diverse rispetto a una misura realmente continua.

i Collegamento con i modelli

Nei capitoli successivi, e soprattutto nel companion operativo su *brms* e *cmdstan*, il tipo di variabile aiuterà a scegliere la famiglia di distribuzioni: normale per molte misure continue, Bernoulli per esiti binari, binomiale per proporzioni, Poisson o negative binomial per conteggi, modelli ordinali per risposte ordinate.

4.11. Misurazione ed EDA

L'analisi esplorativa dei dati non è separata dalla misurazione. La scelta di un grafico o di una statistica descrittiva dipende dal tipo di variabile e dal significato dei valori.

Alcuni esempi:

- per le variabili nominali, sono utili le tabelle di frequenza e i grafici a barre;
- per le variabili ordinali, sono utili le frequenze ordinate, i percentili, le mediane e i grafici che preservano l'ordine;

- per le variabili quantitative, è possibile esplorare distribuzioni, medie, deviazioni standard, densità e boxplot.
- per i tempi di reazione o i conteggi, è necessario controllare le asimmetrie, i valori estremi e i vincoli naturali della scala.
- per le scale Likert, è spesso utile mostrare la distribuzione delle risposte prima di riassumerle in una media.

Collegamento con R

In R, una variabile può essere codificata come numero anche se, concettualmente, è ordinale o nominale. Per esempio, una risposta da 1 a 5 può essere letta come numerica, ma questo non implica che ogni operazione aritmetica sia automaticamente significativa. La codifica informatica non sostituisce il ragionamento sulla misura.

4.12. Misurazione e inferenza bayesiana

Nel manuale principale, l'inferenza bayesiana verrà presentata come un metodo per aggiornare le credenze alla luce dei dati e rappresentare l'incertezza mediante distribuzioni di probabilità. La misurazione entra in questo processo in modo fondamentale.

Se il dato osservato è una misura imperfetta del costrutto, l'incertezza non riguarda solo il parametro del modello, ma anche il legame tra il costrutto e l'indicatore. In modelli più avanzati, questo legame può essere rappresentato esplicitamente attraverso modelli con errore di misura, modelli latenti o modelli gerarchici.

Per ora, non dobbiamo stimare questi modelli. È sufficiente tenere a mente una cautela:

un modello statistico può essere molto sofisticato, ma le sue conclusioni dipendono sempre dalla qualità e dal significato delle misure osservate.

Idea per il manuale bayesiano

L'approccio bayesiano rende naturale distinguere ciò che osserviamo da ciò che vogliamo inferire. Questa distinzione è già presente nella misurazione: osserviamo y , ma siamo interessati a z .

4.13. Teoria e misurazione: un circolo virtuoso

La teoria e la misurazione si sostengono a vicenda.

Una teoria aiuta a decidere cosa misurare, quali indicatori utilizzare e quali modelli attendersi. Senza una teoria, rischiamo di accumulare numeri senza sapere cosa significano.

La misurazione, a sua volta, mette alla prova la teoria. Se un costrutto non può essere collegato a indicatori osservabili in modo chiaro, la teoria resta troppo vaga. Se gli indicatori non si comportano come previsto, può essere necessario rivedere la misura, la teoria o entrambe.

Nel percorso di questo modulo, questo circolo virtuoso ha una funzione pratica:

1. la teoria definisce il costrutto;
2. il disegno stabilisce come raccogliere dati utili;

3. la misurazione traduce il costrutto in variabili;
4. l'EDA controlla il comportamento di queste variabili nei dati;
5. il modello statistico formalizza una spiegazione o una previsione;
6. l'inferenza valuta quanto i dati sostengono il modello.

Riflessioni conclusive

La misurazione non è una fase preliminare da superare rapidamente prima della statistica. È il punto in cui la teoria entra nei dati.

Da questo capitolo dovremmo portare con noi cinque idee:

1. I costrutti psicologici non sono osservati direttamente.
2. Ogni dato è un indicatore imperfetto di qualcosa che vogliamo conoscere.
3. L'errore di misura può essere casuale o sistematico.
4. Affidabilità, validità e livello di scala rispondono a domande diverse.
5. Le analisi statistiche sono legittime solo se rispettano il significato della misura.

Nel prossimo blocco dedicato all'EDA, useremo queste idee per analizzare le variabili: controlleremo le distribuzioni, i valori mancanti, le codifiche, le anomalie e i pattern visivi, ricordando che un grafico o una statistica descrittiva hanno senso solo se conosciamo il significato dei dati.

Esercizi

! Problemi

1. Nello studio su stress accademico e sonno, identifica il costrutto, l'indicatore e il dato osservato per ciascuna delle seguenti variabili: punteggio a una scala di stress, ore di sonno dichiarate, qualità del sonno da 1 a 5.
2. Spiega, in massimo 8 righe, la differenza tra affidabilità e validità. Fai un esempio di misura affidabile ma non valida.
3. Per ciascuna variabile, indica il livello di scala più plausibile e giustifica la risposta: tipo di terapia, gravità dei sintomi in tre categorie ordinate, punteggio QI, tempo di reazione, numero di parole ricordate.
4. Una scala Likert da 1 a 5 misura l'accordo con l'affermazione "mi sento sotto pressione per gli esami". Quali assunzioni fai se calcoli la media delle risposte? Quali interpretazioni dovresti evitare?
5. Un ricercatore osserva che gli studenti con punteggio medio di stress pari a 30 dormono meno degli studenti con punteggio medio pari a 15 e conclude che "hanno il doppio dello stress". Perché questa interpretazione è problematica?
6. Scegli un costrutto psicologico, per esempio motivazione, ansia, impulsività o benessere. Proponi due indicatori possibili e discuti per ciascuno una fonte di errore di misura.
7. Spiega perché un tempo di reazione può essere una scala di rapporti, ma la sua interpretazione psicologica non è automaticamente semplice.

Soluzioni

1. Costrutto, indicatore e dato osservato

Il costrutto è ciò che vogliamo studiare teoricamente. L'indicatore è il modo in cui proviamo a osservarlo. Il dato è il valore registrato.

- Punteggio a una scala di stress: il costrutto è lo stress accademico; l'indicatore è la scala self-report; il dato è il punteggio ottenuto da uno studente.
- Ore di sonno dichiarate: il costrutto può essere quantità di sonno; l'indicatore è il resoconto dello studente; il dato è il numero di ore riportato.
- Qualità del sonno da 1 a 5: il costrutto è la qualità soggettiva del sonno; l'indicatore è la valutazione ordinata; il dato è il valore scelto.

2. Affidabilità e validità

L'affidabilità riguarda la coerenza e stabilità della misura. La validità riguarda la correttezza dell'interpretazione: la misura rappresenta davvero il costrutto di interesse? Una misura può essere affidabile ma non valida. Per esempio, una scala può produrre punteggi molto stabili, ma misurare ansia generale quando lo studio vuole misurare stress accademico.

3. Livelli di scala

- Tipo di terapia: nominale, perché le categorie non hanno un ordine naturale.
- Gravità dei sintomi in tre categorie: ordinale, perché le categorie sono ordinate ma le distanze non sono note.
- Punteggio QI: di solito trattato come scala a intervalli, perché le differenze sono interpretabili ma lo zero non indica assenza di intelligenza.
- Tempo di reazione: scala di rapporti, perché ha uno zero non arbitrario e i rapporti sono interpretabili.
- Numero di parole ricordate: scala di rapporti, perché è un conteggio con zero significativo.

4. Media di una scala Likert

Calcolare la media implica trattare i valori numerici come se le distanze tra categorie fossero abbastanza regolari. Questa può essere una scelta pragmatica, soprattutto con punteggi aggregati, ma va dichiarata. Bisogna evitare interpretazioni di rapporto, per esempio dire che un punteggio 4 indica il doppio dell'accordo rispetto a un punteggio 2.

5. Interpretazione "doppio dello stress"

L'interpretazione è problematica perché un punteggio di stress non possiede necessariamente uno zero assoluto né rapporti interpretabili. Anche se 30 è il doppio di 15 come numero, non segue che il costrutto psicologico misurato sia doppio. Il rapporto tra punteggio osservato e costrutto dipende dalla scala e dalla validità della misura.

6. Due indicatori di un costrutto

Per la motivazione allo studio, due indicatori possibili sono: un questionario self-report e il tempo effettivo dedicato allo studio in una settimana. Il questionario può essere influenzato da desiderabilità sociale o interpretazione degli item. Il tempo di studio può essere registrato in modo impreciso e non distingue studio concentrato da tempo passato sui libri senza attenzione.

7. Tempo di reazione

Il tempo di reazione è una scala di rapporti perché zero ha un significato non arbitrario e un tempo di 800 ms è il doppio di 400 ms. Tuttavia, l'interpretazione psicologica richiede cautela: un tempo più lento può indicare minore velocità di elaborazione, maggiore cautela, affaticamento, difficoltà del compito o una strategia diversa.

Bibliografia

5. Dalla descrizione alla spiegazione

Nei capitoli precedenti abbiamo chiarito tre passaggi preliminari: i dati derivano da una domanda di ricerca, da un disegno di studio e da una procedura di misurazione. Ora introduciamo un quarto passaggio: perché i dati mostrano determinati pattern?

L'analisi esplorativa dei dati aiuta a capire cosa accade: distribuzioni, differenze, associazioni, valori anomali e tendenze. La psicologia, però, non si limita a descrivere i pattern. Vuole anche proporre delle spiegazioni: quali processi cognitivi, affettivi, comportamentali o sociali potrebbero aver generato quei dati?

Questo capitolo introduce l'idea di modello come ponte tra descrizione e spiegazione. Non si tratta di un capitolo di modellazione computazionale avanzata. Piuttosto, serve a preparare il terreno: prima di stimare un modello con R, brms o cmdstan, dobbiamo capire che cosa significa usare un modello per rappresentare un processo psicologico.

Il messaggio centrale è semplice:

L'EDA mostra i pattern nei dati; i modelli propongono un meccanismo che potrebbe averli generati; l'inferenza bayesiana aiuta a valutare quanto quel meccanismo sia plausibile alla luce dei dati.

Questa idea collega la prima parte del modulo, dedicata ai fondamenti, ai capitoli successivi su R, l'EDA e la modellazione bayesiana. In questa fase non useremo ancora tecniche di stima, ma costruiremo il lessico necessario per comprendere il passaggio da una descrizione empirica a una spiegazione teorica.

Panoramica del capitolo

In questo capitolo imparerai a:

- distinguere descrizione, predizione e spiegazione;
- capire che cosa intendiamo per modello in psicologia;
- riconoscere la differenza tra modelli descrittivi, predittivi ed esplicativi;
- comprendere perché molti processi psicologici richiedono variabili latenti;
- vedere in che senso alcuni modelli cognitivi possono essere meccanicistici;
- collegare EDA, modelli e inferenza bayesiana;
- interpretare esempi come Rescorla-Wagner e Drift Diffusion Model senza doverli ancora stimare.

Prerequisiti

Per seguire questo capitolo è utile avere chiari i concetti introdotti nei capitoli precedenti:

- fenomeno psicologico e domanda di ricerca;
- unità statistiche, variabili e dati osservati;
- campione, popolazione e generalizzazione;

- costrutti, indicatori, validità ed errore di misura.

Lecture facoltative per chi desidera approfondire:

- Soto et al. (2023), sul ruolo del modello di Rescorla-Wagner nella psicologia dell'apprendimento;
- Marr (2010), sui livelli di analisi nei sistemi cognitivi;
- Bechtel (2009) e Povich (2025), sulla spiegazione meccanicistica.

Queste letture non sono necessarie per comprendere il capitolo. Sono indicate solo per chi vuole collocare la discussione in un quadro teorico più ampio.

5.1. Perché parlare di modelli in un companion su EDA e R?

A prima vista, un capitolo sui modelli cognitivi può sembrare fuori luogo. Stiamo ancora imparando a organizzare i dati, a descrivere le variabili e a costruire i grafici. Perché introdurre già il tema della modellazione?

La ragione è didattica. Senza modelli, l'analisi dei dati rischia di ridursi a una serie di operazioni tecniche: calcolare una media, confrontare gruppi, stimare una correlazione, produrre un grafico. Queste operazioni sono utili, ma non bastano per fare inferenza psicologica.

Consideriamo una domanda già usata nei capitoli precedenti:

Gli studenti universitari che riportano livelli più alti di stress accademico dormono peggio?

L'EDA può aiutarci a descrivere i dati:

- la distribuzione dei punteggi di stress;
- la distribuzione delle ore di sonno;
- la relazione tra stress e qualità del sonno;
- eventuali sottogruppi o valori anomali.

Se, per esempio, scopriamo che gli studenti più stressati dormono meno, abbiamo identificato un pattern. Tuttavia, il pattern non è ancora una spiegazione. Possiamo chiederci:

- lo stress riduce il sonno?
- il cattivo sonno aumenta la percezione dello stress?
- entrambi dipendono da una terza variabile, come il carico di lavoro, l'ansia o le abitudini digitali?
- lo stesso pattern emerge per tutti gli studenti o solo per alcuni sottogruppi?

Queste domande richiedono qualcosa in più di una semplice descrizione. Richiedono un'ipotesi sul processo che genera i dati. In altre parole, richiedono un modello.

! Idea guida

Un modello non è solo una formula. È una rappresentazione esplicita di come pensiamo che un fenomeno psicologico sia organizzato e di quali processi possano produrre i dati osservati.

5.2. Descrivere, predire, spiegare

Nella pratica della ricerca psicologica, descrizione, predizione e spiegazione sono spesso intrecciate. Tuttavia, è utile distinguerle.

5.2.1. Descrivere

Descrivere significa riassumere ciò che osserviamo nei dati.

Esempi:

- la media delle ore di sonno è 6,4;
- la distribuzione dei punteggi di stress è asimmetrica;
- stress e qualità del sonno sono negativamente associati;
- alcuni studenti presentano valori molto estremi.

La descrizione è il compito principale dell'EDA. Una buona descrizione non è banale: permette di controllare la qualità dei dati, individuare pattern inattesi e formulare domande più precise.

5.2.2. Predire

Predire significa usare alcune informazioni per anticiparne altre.

Esempi:

- usare il punteggio di stress per prevedere la qualità del sonno;
- usare età, genere e carico di studio per prevedere il numero di ore dormite;
- usare i tempi di reazione e l'accuratezza per classificare i partecipanti o le condizioni sperimentali.

Un modello predittivo può essere molto utile anche se non spiega davvero il processo sottostante. Per esempio, un algoritmo può prevedere bene quali studenti dormiranno meno, ma non può spiegarci il perché.

5.2.3. Spiegare

Spiegare significa proporre un processo generativo, ovvero un insieme di componenti, relazioni e assunzioni che rende comprensibile il modello osservato.

Esempi:

- lo stress potrebbe aumentare la ruminazione serale, che a sua volta riduce la qualità del sonno;
- la privazione di sonno potrebbe ridurre il controllo attentivo, aumentando gli errori e i tempi di reazione.
- Un compito difficile potrebbe rallentare l'accumulo di prove prima di una decisione.

La spiegazione richiede di andare oltre la superficie dei dati. Chiede quali processi non direttamente osservabili potrebbero aver prodotto le osservazioni disponibili.

Domanda	Tipo di lavoro	Esempio
Che cosa osserviamo?	Descrizione	Gli studenti più stressati dormono meno.
Possiamo anticipare un esito?	Predizione	Dato lo stress, prevediamo la qualità del sonno.
Quale processo ha generato il pattern?	Spiegazione	La ruminazione media l'effetto dello stress sul sonno.

Errore comune

Una predizione accurata non è automaticamente una spiegazione. Un modello può prevedere bene senza rappresentare il meccanismo psicologico che genera il comportamento.

5.3. Che cos'è un modello?

Nel linguaggio comune, il termine *modello* può indicare molte cose: un esempio da imitare, una miniatura, uno schema, una formula, una simulazione. In psicologia, un modello è una rappresentazione semplificata di un fenomeno.

Un buon modello non copia la realtà in tutti i suoi dettagli. Se lo facesse, sarebbe inutile quanto la realtà stessa. Un modello seleziona alcuni aspetti considerati rilevanti e li organizza in modo esplicito.

Per esempio, un modello del rapporto tra stress e sonno potrebbe includere:

- una variabile osservata: punteggio di stress;
- una variabile osservata: qualità del sonno;
- una variabile latente: ruminazione;
- un'assunzione: lo stress aumenta la ruminazione;
- un'altra assunzione: la ruminazione riduce la qualità del sonno;
- una componente di errore: non tutto il sonno è spiegato dallo stress e dalla ruminazione.

Anche un modello molto semplice comporta delle assunzioni. Esplicitare queste assunzioni è uno dei principali vantaggi della modellazione.

Modelli e semplificazione

Un modello è sempre una semplificazione. La domanda non è: "Il modello è vero in senso assoluto?". La domanda più utile è: "Il modello rende esplicite assunzioni plausibili e ci aiuta a comprendere i dati meglio delle alternative disponibili?".

5.4. Modelli descrittivi, predittivi ed esplicativi

Possiamo distinguere tre famiglie di modelli. La distinzione non è rigida, ma aiuta a capire quali domande stiamo ponendo.

5.4.1. Modelli descrittivi

Un modello descrittivo riassume la struttura osservata nei dati. Per esempio, una retta di regressione può descrivere la relazione tra stress e ore di sonno. Se la retta ha pendenza negativa, possiamo affermare che, nel campione osservato, valori più alti di stress tendono a essere associati a un minor numero di ore di sonno.

Questo tipo di modello è utile, ma di per sé non spiega il perché della relazione. Potrebbe descrivere una relazione causale, una relazione indiretta, un effetto di confondimento o una coincidenza dovuta al campione.

5.4.2. Modelli predittivi

Un modello predittivo è costruito per anticipare valori non ancora osservati. In psicologia applicata, può essere utile per individuare gli studenti a rischio, prevedere le ricadute cliniche, stimare le prestazioni future o classificare i profili comportamentali.

La qualità di un modello predittivo si valuta soprattutto chiedendosi se funziona su dati nuovi. Tuttavia, anche un buon modello predittivo può restare opaco dal punto di vista teorico.

5.4.3. Modelli esplicativi

Un modello esplicativo cerca di rappresentare un processo. Non si limita a dire che due variabili sono associate, ma propone un'organizzazione causale o funzionale che possa generare il comportamento osservato.

In psicologia cognitiva, molti modelli esplicativi introducono processi non osservabili direttamente, come l'attenzione, la memoria di lavoro, le aspettative, le credenze, l'evidenza accumulata, le soglie decisionali e il valore atteso. Questi elementi non sono dati grezzi. Si tratta di componenti teoriche che aiutano a spiegare perché certe risposte sono state osservate.

Tipo di modello	Domanda principale	Criterio di utilità
Descrittivo	Che pattern osserviamo?	Riassume bene i dati disponibili.
Predittivo	Che cosa accadrà in dati nuovi?	Prevede bene casi non ancora osservati.
Esplicativo	Quale processo genera il pattern?	Rende plausibile un meccanismo.

5.5. Variabili osservate e variabili latenti

Un punto cruciale per la psicologia è che molti fenomeni di interesse non sono direttamente osservabili. Non osserviamo direttamente lo stress, l'ansia, l'attenzione, la motivazione, le aspettative o il controllo cognitivo. Osserviamo invece risposte, tempi, scelte, punteggi, errori, valutazioni o misure fisiologiche.

Per questo motivo, i modelli psicologici spesso distinguono tra:

- variabili osservate, ovvero valori registrati nei dati;
- variabili latenti, ovvero componenti teoriche non osservate direttamente, ma inferite dai dati.

Nel capitolo sulla misurazione abbiamo rappresentato questa idea con:

$$y = z + \varepsilon_y,$$

dove y è il dato osservato, z è il costrutto teorico e ε_y è l'errore di misura.

Un modello estende questa logica. Non si limita a dire che un indicatore misura un costrutto, ma specifica anche come il costrutto, insieme ad altri processi, possa generare le osservazioni.

! Collegamento con la misurazione

La modellazione non elimina il problema della misurazione. Al contrario, lo rende più esplicito: dobbiamo chiarire quali parti del modello sono osservabili, quali sono latenti e quali assunzioni collegano le une alle altre.

5.6. Modelli meccanicistici: spiegare come funziona un processo

Un modello è detto meccanicistico quando cerca di rappresentare le componenti e le relazioni che producono un fenomeno. In una formulazione classica, un meccanismo è una collezione organizzata di entità e attività che produce o mantiene un fenomeno (Bechtel, 2009).

In psicologia, questa idea va interpretata con cautela. Un modello meccanicistico non deve necessariamente descrivere neuroni, circuiti cerebrali o parti fisiche osservabili. Può anche rappresentare componenti funzionali, come:

- valori attesi;
- aspettative;
- segnali di errore;
- evidenza accumulata;
- soglie decisionali;
- processi di memoria o attenzione.

Ciò che importa è che il modello spieghi come queste componenti interagiscono tra loro per produrre il comportamento.

Ciò che conta è che il modello spieghi come queste componenti interagiscono tra loro per produrre il comportamento.

Per esempio, consideriamo un compito decisionale in cui una persona deve scegliere rapidamente tra due alternative. Una descrizione dei dati potrebbe indicare che una determinata condizione produce tempi di reazione più lunghi. Un modello meccanicistico potrebbe invece proporre che la condizione rallenta l'accumulo di evidenza o induce una strategia più cauta. Le due spiegazioni hanno implicazioni diverse, anche se entrambe possono produrre tempi più lunghi.

💡 Domanda diagnostica

Per capire se un modello ha ambizioni esplicative, chiediti se il modello si limita a dire che una variabile predice un'altra o se propone come il comportamento emerge dall'interazione di componenti definite.

5.7. I livelli di analisi di Marr

Un modo utile per collocare i modelli cognitivi è la distinzione proposta da Marr (2010) tra tre livelli di analisi.

1. **Livello computazionale:** quale problema deve risolvere il sistema e perché?
2. **Livello algoritmico:** quali rappresentazioni e procedure usa il sistema per risolverlo?
3. **Livello implementativo:** con quali mezzi fisici il processo viene realizzato?

Questa distinzione è importante perché evita un equivoco. Un modello cognitivo può essere esplicativo anche se non descrive direttamente il cervello. Per esempio, un modello può spiegare una decisione a livello algoritmico rappresentando come una persona accumula le prove nel tempo, senza specificare tutti i dettagli neurali del processo.

Livello	Domanda	Esempio
Computazionale	Qual è il problema?	Decidere quale alternativa è più probabile.
Algoritmico	Come viene risolto?	Accumulare evidenza fino a una soglia.
Implementativo	Dove e come è realizzato?	Circuiti neurali coinvolti nella decisione.

Perché è utile per questo corso

Nei companion operativi, invece, lavoreremo soprattutto con rappresentazioni formali e statistiche. Non sempre ci occuperemo di implementazione neurale. Ciò non rende i modelli meno importanti: spesso, infatti, la domanda psicologica principale riguarda il livello computazionale o algoritmico.

5.8. Due esempi: apprendimento e decisione

Non è necessario padroneggiare ora i modelli computazionali. Tuttavia, due esempi possono aiutare a comprendere la differenza tra una descrizione e una spiegazione formale.

5.8.1. Il modello di Rescorla-Wagner

Il modello di Rescorla-Wagner è un modello di apprendimento associativo. L'idea centrale è che l'apprendimento dipenda dall'errore di previsione: impariamo di più quando ciò che accade è diverso da ciò che ci aspettavamo.

In termini intuitivi:

- se un evento è sorprendente, aggiorniamo molto le nostre aspettative.
- se un evento è già previsto, aggiorniamo poco;
- la rapidità con cui avviene l'aggiornamento dipende da un parametro di apprendimento.

Il punto didattico non è imparare l'equazione. Il punto è vedere che il modello non si limita a dire che esperienza e comportamento sono associati. Propone un meccanismo: l'aspettativa cambia nel tempo in funzione dell'errore di previsione.

5.8.2. Il Drift Diffusion Model

Il Drift Diffusion Model (DDM) è un modello dei processi decisionali in compiti a due alternative. L'idea centrale è che, prima di rispondere, una persona accumuli prove a favore di una delle due risposte fino al raggiungimento di una soglia.

Il modello distingue diverse componenti del comportamento:

- la qualità dell'informazione disponibile;
- la velocità con cui l'evidenza viene accumulata;
- la cautela della persona nel prendere una decisione.
- il tempo necessario per percepire lo stimolo e produrre la risposta;
- eventuali bias iniziali verso una risposta.

Questa distinzione è utile perché lo stesso dato osservato può avere spiegazioni diverse. Tempi di reazione più lunghi possono indicare un'elaborazione più lenta, una strategia più cauta, un segnale più ambiguo o una combinazione di questi fattori.

Esempio concettuale

Supponiamo che, in un compito attentivo, gli studenti sotto stress rispondano più lentamente. Una descrizione potrebbe essere: "Il gruppo stressato ha tempi di reazione più lunghi". Un modello cognitivo potrebbe invece chiedersi: perché rispondono più lentamente? Accumulano evidenza più lentamente? Adottano soglie decisionali più alte? Impiegano più tempo nelle fasi percettive e motorie?

5.9. Perché i modelli aiutano la riproducibilità

La crisi della riproducibilità in psicologia ha mostrato che non basta osservare un effetto statisticamente significativo. Dobbiamo anche capire quando, perché e in quali condizioni un effetto dovrebbe ripresentarsi.

I modelli esplicativi possono essere d'aiuto perché:

- rendono esplicite le assunzioni teoriche;
- chiariscono quali processi dovrebbero generare il comportamento;
- permettono di formulare previsioni più precise.
- aiutano a distinguere spiegazioni alternative;
- rendono più trasparente il rapporto tra teoria, dati e inferenza.

Ciò non significa che ogni modello esplicativo sia corretto. Un modello può essere sbagliato, troppo semplice o mal specificato. Tuttavia, un modello esplicito è criticabile: possiamo discutere le sue assunzioni, confrontarlo con alternative, verificare le sue previsioni e comprendere i suoi limiti.

Errore comune

Formalizzare un'idea non la rende automaticamente vera. Un modello matematico può essere elegante, ma comunque inadeguato. La formalizzazione è utile perché rende le assunzioni visibili, non perché garantisca la verità del modello.

5.10. Il collegamento con l'inferenza bayesiana

In questo contesto, l'inferenza bayesiana si inserisce naturalmente. Un modello psicologico contiene delle assunzioni sui processi che generano i dati. L'inferenza bayesiana consente di aggiornare la plausibilità dei valori dei parametri e, talvolta, dei modelli alternativi, alla luce delle osservazioni.

In forma molto generale, il ragionamento è questo:

1. formulare un modello, ovvero una rappresentazione del processo che potrebbe generare i dati;
- 2) specifichiamo quali parti sono osservate e quali sono latenti;
- 3) esprimere l'incertezza sui parametri del modello;
- 4) osserviamo i dati;
- 5) aggiorniamo la nostra incertezza alla luce dei dati;
6. Verifichiamo se il modello riproduce gli aspetti più importanti dei dati osservati.

In questo capitolo non ci soffermiamo sui dettagli tecnici di questi passaggi. Li anticipiamo solo dal punto di vista concettuale. Nei moduli successivi, soprattutto nel modulo operativo con `brms` e `cmdstan`, questi passaggi diventeranno procedure concrete.

! Ponte con il manuale bayesiano

Nel manuale principale, l'inferenza bayesiana viene presentata come un metodo per gestire l'incertezza. Qui aggiungiamo un tassello: l'incertezza riguarda anche i processi che hanno generato i dati e non solo i valori numerici dei parametri.

5.11. Il ruolo dell'EDA prima della modellazione

Se i modelli sono così importanti, perché dedicare tanto spazio all'EDA?

Perché una buona modellazione richiede una buona comprensione preliminare dei dati. L'EDA aiuta a:

- verificare che i dati siano coerenti con la domanda di ricerca;
- individuare valori mancanti, errori o anomalie;
- osservare la forma delle distribuzioni;
- individuare differenze tra sottogruppi;
- riconoscere associazioni inattese;
- formulare ipotesi sui processi sottostanti;
- verificare se un modello plausibile dovrebbe includere determinate variabili o determinate strutture.

L'EDA non è un passaggio inferiore rispetto alla modellazione. È un lavoro preliminare che permette di costruire modelli più sensati.

💡 Collegamento con i capitoli successivi

Quando nei capitoli EDA esploreremo distribuzioni, medie, variabilità, correlazioni e outlier, non lo faremo solo per produrre riassunti. Lo faremo per imparare a riconoscere quali pattern necessitano di una spiegazione e quali assunzioni un modello deve rispettare.

5.12. Una sequenza di lavoro

Possiamo ora riassumere il percorso che collega i capitoli di questa prima parte.

1. **Fenomeno:** scegliamo un fenomeno psicologico da comprendere.
2. **Domanda:** trasformiamo il fenomeno in una domanda empirica.
3. **Disegno:** decidiamo come raccogliere dati coerenti con la domanda.
4. **Misurazione:** traduciamo costrutti teorici in indicatori osservabili.
5. **EDA:** descriviamo i dati e individuiamo pattern.
6. **Modello:** proponiamo un processo che potrebbe generare quei pattern.
7. **Inferenza:** valutiamo il modello alla luce dei dati e dell'incertezza.

Questa sequenza non è sempre lineare. Spesso l'analisi esplorativa dei dati (EDA) fa emergere problemi di misurazione, un modello suggerisce una nuova raccolta dati o un risultato inatteso richiede di riformulare la domanda iniziale. Tuttavia, come mappa didattica, questa sequenza aiuta a collocare ogni parte del progetto.

5.13. Cosa portare al capitolo successivo

Da questo capitolo dovresti ricavare quattro idee.

1. **Descrivere non significa spiegare.**
Un pattern nei dati è un punto di partenza, non una conclusione finale.
2. **Un modello rende esplicite le assunzioni.**
Ogni modello seleziona alcune componenti del fenomeno e propone delle relazioni tra di esse.
3. **In psicologia molte variabili importanti sono latenti.**
I dati osservati sono indicatori parziali di processi non direttamente osservabili.
4. **L'inferenza bayesiana valuta modelli in condizioni di incertezza.**
Non elimina le assunzioni, ma permette di ragionare in modo esplicito su di esse.

Nei capitoli successivi passeremo alla parte operativa del companion. Impareremo a usare R non come fine a sé stesso, ma come strumento per organizzare, esplorare e interrogare i dati psicologici.

! Problemi

1. In che cosa differiscono descrizione, predizione e spiegazione?
2. Perché una correlazione tra stress e sonno non è automaticamente una spiegazione?
3. Che cosa significa dire che una variabile psicologica è latente?
4. Perché un modello predittivo accurato potrebbe non essere esplicativo?
5. Qual è l'idea centrale del modello di Rescorla-Wagner?
6. Qual è l'idea centrale del Drift Diffusion Model?
7. In che modo l'EDA prepara la costruzione di un modello?
8. Perché l'inferenza bayesiana si collega naturalmente alla modellazione?

💡 Soluzioni

1. La descrizione riassume ciò che osserviamo nei dati; la predizione usa alcune informazioni per anticiparne altre; la spiegazione propone un processo che potrebbe aver generato il pattern osservato.

2. Una correlazione indica che due variabili variano insieme, ma non chiarisce il processo che produce la relazione. Lo stress potrebbe influenzare il sonno, il sonno potrebbe influenzare lo stress, oppure entrambi potrebbero dipendere da altre variabili.
3. Una variabile latente è una componente teorica non osservata direttamente, come ansia, attenzione, motivazione o ruminazione. La inferiamo attraverso indicatori osservabili, come risposte, punteggi, tempi di reazione o scelte.
4. Un modello può prevedere bene perché sfrutta regolarità statistiche nei dati, senza rappresentare il meccanismo psicologico che produce quelle regolarità. Accuratezza predittiva e potere esplicativo non coincidono necessariamente.
5. Il modello di Rescorla-Wagner descrive l'apprendimento come aggiornamento delle aspettative sulla base dell'errore di previsione. Quando ciò che accade è diverso da ciò che ci aspettavamo, l'apprendimento è maggiore.
6. Il Drift Diffusion Model descrive alcune decisioni come un processo di accumulo graduale di evidenza fino al raggiungimento di una soglia decisionale. Permette di distinguere componenti come velocità di accumulo, cautela decisionale e tempo di non-decisione.
7. L'EDA permette di capire come sono fatti i dati, individuare anomalie, osservare distribuzioni e associazioni, e formulare ipotesi sui processi che potrebbero aver prodotto i pattern osservati.
8. L'inferenza bayesiana consente di aggiornare l'incertezza sui parametri, e talvolta sui modelli, alla luce dei dati. Questo la rende adatta a una prospettiva in cui i modelli sono ipotesi esplicite sui processi generatori dei dati.

Bibliografia

Parte II.

R

Capire, controllare e documentare analisi nell'epoca dell'AI.

Questa sezione introduce R come strumento per lavorare con i dati in modo trasparente e riproducibile. Non ha l'obiettivo di trasformare gli studenti in programmatori. Il suo obiettivo è più limitato, ma molto importante: fornire le competenze minime necessarie per leggere, eseguire, modificare, controllare e documentare l'analisi dei dati psicologici.

Oggi, questo obiettivo va formulato in modo diverso rispetto al passato. Gli strumenti di intelligenza artificiale possono generare codice, correggere errori, suggerire grafici, spiegare funzioni e proporre soluzioni alternative. Questo è utile e in questo manuale non viene trattato come qualcosa da evitare. Nella ricerca contemporanea, l'uso di strumenti di supporto alla scrittura del codice è ormai una pratica comune.

Tuttavia, l'uso dell'AI non esime dalla responsabilità dell'analisi. Chi presenta un risultato deve essere in grado di spiegare cosa fa il codice, perché è stato usato, quali dati ha trasformato, quali osservazioni ha incluso o escluso, quali assunzioni incorpora e quali limiti ci sono nell'interpretazione.

L'obiettivo non è imparare R per scrivere ogni comando a mano. L'obiettivo è imparare a sufficienza R per capire, controllare e modificare il codice che si utilizza, anche quando è stato prodotto con l'aiuto dell'intelligenza artificiale.

Perché usare ancora R

R è un linguaggio nato per l'analisi statistica. In psicologia e nelle scienze sociali è molto utilizzato perché consente di organizzare, trasformare, visualizzare i dati, stimare i modelli, produrre report riproducibili e condividere in modo esplicito le procedure di analisi.

Per il percorso di questo Companion, R serve soprattutto a tre scopi.

In primo luogo, rende visibili le operazioni eseguite sui dati. Se calcoliamo una media, filtriamo alcune osservazioni, ricodifichiamo una variabile o produciamo un grafico, il codice lascia una traccia controllabile di tutte le operazioni eseguite. Questo è essenziale per evitare che l'analisi diventi una sequenza di passaggi impliciti e difficili da verificare.

In secondo luogo, permette di riprodurre i risultati. Un'analisi non dovrebbe dipendere dalla memoria di chi l'ha eseguita o da passaggi manuali difficili da ricostruire. Se i dati, il codice e il testo sono organizzati correttamente, un'altra persona può comprendere il percorso seguito e, almeno in linea di principio, riprodurlo.

In terzo luogo, R collega l'analisi operativa alle domande metodologiche discusse nella prima parte del manuale. Le variabili, i campioni, le scale di misura, i valori mancanti, i disegni di ricerca e i limiti dell'inferenza non sono concetti astratti, ma diventano colonne di una tabella, righe di un dataset, condizioni di filtro, grafici, statistiche descrittive e modelli.

Che cosa significa imparare R oggi

Imparare R non significa memorizzare molte funzioni. Significa riconoscere alcuni schemi ricorrenti. La maggior parte del codice che useremo nel companion può essere compresa se si conoscono pochi elementi fondamentali:

Elemento	Perché serve
<code>oggetto <- valore</code>	Capire che un risultato viene salvato con un nome.
<code>funzione(argomento = valore)</code> <code>dati > funzione()</code>	Leggere la struttura di quasi tutti i comandi R. Capire una sequenza di operazioni applicate a una tabella.
<code>select()</code> , <code>filter()</code> , <code>mutate()</code>	Capire come si scelgono, filtrano e trasformano variabili e osservazioni.
<code>group_by()</code> e <code>summarise()</code> <code>NA, is.na(), na.rm = TRUE</code>	Capire come si calcolano statistiche per gruppi. Riconoscere e gestire i dati mancanti.
<code>ggplot(..., aes(...)) + geom_*()</code> blocchi di codice R in Quarto	Leggere la grammatica di base dei grafici. Capire dove il codice viene eseguito in un documento Quarto.
<code>pacchetto::funzione()</code>	Sapere da quale pacchetto proviene una funzione.

Questa è la grammatica minima. Non permette di fare tutto, ma di certo non si è più ciechi davanti al codice. Consente di chiedere aiuto in modo più preciso, di riconoscere gli errori più comuni, di modificare gli esempi esistenti e di verificare se una soluzione proposta dall'AI è plausibile.

Quattro competenze da sviluppare

In questa sezione lavoreremo soprattutto su quattro competenze.

Leggere il codice

Leggere il codice significa saper spiegare, in linguaggio comune, cosa fa una sequenza di comandi. Per esempio: “questo codice prende il dataset, seleziona alcune variabili, elimina i casi con valori mancanti, calcola una media per gruppo e produce un grafico”.

Questa competenza è più importante della semplice memorizzazione. Anche se un comando è stato scritto dall'AI, lo studente deve essere in grado di spiegare l'operazione eseguita.

Eeguire il codice

Eeguire il codice significa saper aprire un progetto, caricare i pacchetti necessari, importare i dati, lanciare i comandi e osservare l'output. Si tratta di una competenza pratica, ma non banale: molti errori derivano da file posizionati in modo errato, pacchetti non caricati, nomi di variabili scritti in modo diverso o dati letti con un formato inaspettato.

Modificare il codice

Modificare il codice significa prendere un esempio funzionante e adattarlo a un nuovo problema. Questa è una competenza fondamentale per chi muove i primi passi nel settore. Spesso non partiremo da una pagina vuota, ma da un esempio, da una soluzione generata dall'AI o da un frammento di codice già presente nel Companion. Il compito sarà capire quali parti cambiare e quali lasciare invariate.

Verificare il codice

Verificare il codice significa controllare che l'analisi faccia davvero ciò che pensiamo. Per esempio, dopo un filtro, dobbiamo chiederci quante osservazioni sono rimaste; dopo una ricodifica, dobbiamo controllare i valori della nuova variabile e, dopo un grafico, dobbiamo chiederci se il tipo di visualizzazione è coerente con il tipo di dati.

Questa è la competenza più importante nell'epoca dell'intelligenza artificiale. L'AI può generare codice formalmente corretto, ma che potrebbe non essere adatto alla domanda, al dataset o al disegno della ricerca. Il controllo resta comunque responsabilità di chi conduce l'analisi.

Usare l'AI con criterio

L'AI può essere un buon assistente per lavorare con R. Può aiutare a:

- scrivere una prima versione del codice;
- spiegare un messaggio di errore;
- proporre una pipeline `dplyr`;
- suggerire un grafico con `ggplot2`;
- trasformare un codice disordinato in un codice più leggibile;
- commentare un blocco di codice;
- proporre controlli diagnostici.

Tuttavia, l'AI non conosce automaticamente il contesto della ricerca. Non conosce la domanda teorica originaria, né come è stato costruito il campione, né cosa rappresentano le variabili, quali sono le codifiche speciali, quali osservazioni devono essere escluse o quale interpretazione è giustificata dal disegno.

Per questo motivo, ogni utilizzo dell'AI dovrebbe essere accompagnato da alcune domande di controllo:

1. Il codice usa il dataset corretto?
2. I nomi delle variabili corrispondono a quelli reali?
3. Le variabili sono trattate nel modo giusto, per esempio come variabili numeriche, categoriali o ordinali?
4. I valori mancanti sono gestiti in modo esplicito?
5. La pipeline elimina alcune osservazioni? Se sì, quante e perché?
6. Il grafico o la statistica sono coerenti con la domanda?
7. Il risultato viene interpretato come descrizione, associazione, previsione o causalità?
8. Il codice è inserito in un documento riproducibile?

Una regola pratica: non usare mai del codice che non sapresti spiegare almeno a grandi linee. Non è necessario ricordare ogni dettaglio sintattico, ma è importante sapere quali sono gli input, gli output e le trasformazioni che avvengono nel mezzo.

Che cosa non faremo

Questa sezione non è un manuale completo di R. In rete si trovano molte risorse, spesso eccellenti, che spiegano in dettaglio la sintassi del linguaggio, la programmazione avanzata, la costruzione di pacchetti, le tecniche di ottimizzazione e molti altri aspetti.

Qui faremo una scelta diversa. Tratteremo solo gli argomenti necessari per iniziare a lavorare con i dati psicologici nel contesto di questo progetto. Alcuni dettagli verranno semplificati. Alcuni argomenti verranno solo menzionati. Altri saranno rimandati a materiali esterni o a approfondimenti facoltativi.

Questa scelta non impoverisce il percorso. Al contrario, lo rende più adatto allo scopo. Per gli studenti che si avvicinano per la prima volta alla statistica, il problema principale non è conoscere tutte le possibilità offerte da R, ma costruire un rapporto non intimidatorio e responsabile con il codice.

Mappa della sezione

I capitoli successivi sono organizzati per accompagnare gradualmente il passaggio dalla comprensione del codice all'analisi riproducibile.

Capitolo	Funzione principale	Domanda guida
Sintassi di base	Introdurre la grammatica minima per leggere codice R.	Che cosa sta facendo questo comando?
Ambiente di lavoro	Organizzare file, progetti e percorsi.	Dove sono i dati e come rendo l'analisi riproducibile?
Funzioni utili	Importare dati, controllare tabelle e svolgere operazioni comuni.	Il dataset è stato letto e controllato correttamente?
Programmazione	Presentare alcuni strumenti per capire codice più articolato.	Quando serve automatizzare o generalizzare un'operazione?
dplyr	Trasformare dati in modo leggibile.	Quali righe e colonne sto usando, creando o modificando?
ggplot2	Visualizzare distribuzioni, confronti e relazioni.	Quale grafico rende visibile il pattern rilevante?
Quarto	Integrare testo, codice e output in un documento riproducibile.	Come comunico un'analisi in modo trasparente?
Pacchetti	Capire come R viene esteso da librerie specializzate.	Da dove vengono le funzioni che sto usando?

Questa mappa non va letta come un programma di programmazione generale. Ogni capitolo è concepito per preparare il lavoro successivo nella sezione EDA, in cui useremo R per esplorare dati reali o simulati, costruire grafici, calcolare statistiche descrittive e analizzare modelli, anomalie e relazioni tra variabili.

Collegamento con il resto del progetto

La prima parte del modulo ha trattato il tema della genesi dei dati: domande di ricerca, campioni, disegni, misure, costrutti e modelli. La sezione dedicata a R mostra come rendere operative queste idee.

Per esempio, se vogliamo studiare la relazione tra lo stress accademico e la qualità del sonno, R ci permette di:

- importare il file con le risposte degli studenti;
- verificare quante osservazioni e variabili contiene;
- verificare la presenza di dati mancanti;
- distinguere le variabili numeriche, ordinali e categoriali;
- calcolare le statistiche descrittive;
- produrre grafici;
- documentare ogni passaggio in un report.

La sezione EDA utilizzerà questi strumenti per esplorare i dati prima di passare a modelli più formali. Il manuale principale sull'inferenza bayesiana riprenderà poi i temi dell'incertezza, della stima e del confronto tra modelli. In questo percorso, R non è il fine, ma il mezzo che rende possibile il passaggio controllato dalla domanda ai dati, dai dati all'analisi e dall'analisi all'interpretazione.

Come studiare questa sezione

Per trarre beneficio da questa parte, non è necessario memorizzare tutto. È più utile adottare alcune abitudini.

In primo luogo, esegui il codice e osserva l'output. Chiediti sempre che cosa è cambiato dopo ogni comando.

In secondo luogo, modifica piccoli dettagli. Cambia una variabile, un filtro, il titolo di un grafico o un'opzione della funzione. Spesso, vedere che cosa succede è il modo più efficace per capire.

In terzo luogo, considera l'AI come un interlocutore, non come un sostituto. Puoi chiedere spiegazioni, alternative e correzioni, ma ricorda sempre di verificare il risultato sul dataset reale.

In quarto luogo, scrivi brevi commenti. Anche una frase semplice può chiarire il rapporto tra il codice e la domanda di ricerca.

Infine, conserva il codice in un progetto ben organizzato e, quando possibile, in un documento Quarto. L'analisi diventa più solida dal punto di vista scientifico quando può essere ricostruita.

Cosa portare con sé

Al termine di questa sezione, non sarà necessario conoscere ogni aspetto di R, ma sarà importante saper fare alcune cose essenziali:

1. aprire un progetto e orientarsi tra file, dati e script;
2. leggere un blocco di codice R e spiegarne il senso generale;
3. eseguire il codice e riconoscere gli output principali;
4. importare un dataset e controllarne la struttura;
5. gestire in modo consapevole valori mancanti e tipi di variabili;
6. usare o modificare semplici pipeline `dplyr`;
7. leggere e adattare grafici `ggplot2`;
8. integrare testo, codice e risultati in Quarto;
9. usare l'AI per ottenere supporto senza perdere controllo sull'analisi;
10. distinguere un errore di sintassi da un errore concettuale.

Queste competenze sono sufficienti per iniziare la parte di analisi esplorativa dei dati (EDA). In particolare, sono sufficienti per adottare un approccio attivo nei confronti del codice: non subirlo passivamente o copiarlo meccanicamente, ma utilizzarlo come strumento per rendere il ragionamento sui dati più chiaro, controllabile e comunicabile.

6. Sintassi minima per leggere codice R

Perché questo capitolo esiste

Per analizzare i dati psicologici con R non è necessario diventare programmatori. È necessario, però, imparare a leggere il codice, capire quali operazioni compie, verificare che siano coerenti con la domanda di ricerca e correggere gli errori più comuni.

Oggi, molti passaggi di codice possono essere scritti con l'aiuto dell'intelligenza artificiale. Questo non rende la sintassi di R inutile, ma la rende diversa: non è necessario memorizzare ogni dettaglio del linguaggio, ma è importante conoscere a sufficienza R da non utilizzare codice che non si comprende.

In questo capitolo useremo quindi R come una lingua di lavoro minima. L'obiettivo è arrivare a leggere un blocco di codice e saper rispondere a tre domande:

1. cosa entra nell'analisi?
2. quali trasformazioni vengono applicate ai dati?
3. che cosa produce il codice come risultato?

Idea guida

L'AI può aiutare a scrivere codice. Tuttavia, non può sostituire la responsabilità di capire che cosa fa il codice e se quel codice è adatto ai dati e alla domanda di ricerca.

6.1. Che cosa devi saper fare alla fine del capitolo

Al termine di questo capitolo, non è necessario che tu sappia scrivere codice complesso da zero. Dovresti però sapere:

- riconoscere un oggetto creato in R;
- leggere una funzione e i suoi argomenti;
- capire il significato della pipe `|>`;
- distinguere vettori, variabili e data frame;
- riconoscere valori mancanti (NA);
- leggere condizioni logiche semplici;
- capire quando un codice seleziona righe o colonne;
- spiegare a parole il funzionamento di un breve blocco di codice;
- usare l'AI per ottenere aiuto senza perdere il controllo dell'analisi.

In questa sede non tratteremo tutti i dettagli della programmazione in R. Le funzioni più avanzate, i cicli, la scrittura di funzioni personalizzate e le tecniche di programmazione verranno illustrate solo quando necessario.

6.2. Il codice come traccia dell'analisi

Un'analisi statistica non è soltanto il risultato finale. È una sequenza di decisioni:

- quali dati sono stati caricati;
- quali casi sono stati esclusi;
- quali variabili sono state trasformate;
- quali statistiche sono state calcolate;
- quali grafici sono stati prodotti.

In R queste decisioni vengono scritte in forma esplicita. Per esempio:

```
sleep_data <- read.csv("data/sleep_stress.csv")
mean(sleep_data$sleep_quality, na.rm = TRUE)
```

Questo codice dice due cose:

1. viene letto un file di dati e il risultato viene salvato nell'oggetto `sleep_data`;
2. viene calcolata la media della variabile `sleep_quality`, ignorando i valori mancanti.

La sintassi serve a questo: rendere visibile ciò che è stato fatto. Anche se il codice è stato suggerito dall'AI, deve poter essere letto, discusso e controllato.

6.3. La grammatica minima di R

6.3.1. Oggetti: salvare un risultato con un nome

In R si lavora creando oggetti. Un oggetto è un nome che contiene un valore, un dataset, un risultato o un grafico.

```
stress <- 18
```

Il simbolo `<-` significa "assegna a". La riga si legge così:

salva il valore 18 in un oggetto chiamato `stress`.

Da quel momento, il nome `stress` può essere riutilizzato:

```
stress + 2
```

I nomi degli oggetti dovrebbero essere chiari. Un nome come `x` è rapido, ma poco informativo. Un nome come `stress_score` è molto più esplicativo.

```
# Poco chiaro
x <- 18

# Più chiaro
stress_score <- 18
```

 Errore comune

Se R risponde con un messaggio come `object 'stress_score' not found`, significa che stai usando un oggetto che non esiste nella sessione corrente oppure che il nome è stato scritto in modo diverso.

6.3.2. Funzioni: chiedere a R di fare qualcosa

Una funzione è un comando che riceve uno o più input e restituisce un risultato.

```
mean(c(18, 22, 19, 25))
```

Questa riga usa la funzione `mean()` per calcolare la media di un insieme di valori. La struttura generale è:

```
funzione(argomento1, argomento2, ...)
```

Molto del codice R può essere compreso riconoscendo questa struttura. Per esempio:

```
sd(stress_score)
hist(stress_score)
summary(sleep_data)
```

In tutti e tre i casi R applica una funzione a un oggetto.

6.3.3. Argomenti: specificare come deve lavorare una funzione

Le funzioni spesso hanno degli argomenti, ovvero delle opzioni che ne modificano il comportamento.

```
mean(sleep_data$sleep_quality, na.rm = TRUE)
```

In questo caso, l'opzione `na.rm = TRUE` chiede a R di rimuovere i valori mancanti prima di calcolare la media.

Questa piccola opzione è molto importante. Se ci sono dati mancanti e non specifichiamo come gestirli, il risultato potrebbe essere NA:

```
mean(c(7, 6, NA, 8))
mean(c(7, 6, NA, 8), na.rm = TRUE)
```

 Cosa devi controllare tu

Quando l'AI produce codice con `na.rm = TRUE`, non limitarti ad accettarlo. Chiediti: quanti valori mancanti ci sono? Perché mancano? È corretto ignorarli in questa analisi?

6.3.4. Vettori: più valori dello stesso tipo

Un vettore è una sequenza di valori. Spesso viene creato con la funzione `c()`:

```
swls_scores <- c(20, 16, 23, 25, 11)
```

Questo oggetto contiene cinque punteggi. Possiamo calcolare alcune statistiche:

```
mean(swls_scores)
sd(swls_scores)
length(swls_scores)
```

Per questo corso è sufficiente sapere che molte variabili in un dataset possono essere considerate come vettori: una colonna di punteggi, una colonna di età, una colonna con il gruppo sperimentale, ecc.

6.3.5. Data frame: una tabella di dati

La struttura più importante per l'analisi dei dati è il data frame. Un data frame è una tabella in cui:

- ogni riga rappresenta un caso o un partecipante;
- ogni colonna rappresenta una variabile.

Per esempio:

```
sleep_data <- data.frame(
  id = 1:5,
  stress = c(18, 22, 19, 25, 21),
  sleep_quality = c(7, 6, 8, 5, NA)
)
```

Questo dataset contiene cinque partecipanti e tre variabili: `id`, `stress` e `sleep_quality`.

Per ispezionare una tabella possiamo usare:

```
head(sleep_data)
str(sleep_data)
summary(sleep_data)
```

Questi comandi non sono analisi finali. Si tratta di controlli preliminari. Prima di calcolare qualunque risultato, è necessario sapere cosa contiene il dataset.

6.4. Variabili e tipi di dati

R distingue diversi tipi di valori. Per l'EDA è sufficiente riconoscere i seguenti casi principali:

Un errore frequente è trattare una variabile come se fosse numerica quando R l'ha letta come testo, oppure trattare i numeri come se rappresentassero delle quantità, quando in realtà sono dei codici di categoria.

Tipo.di.dato	Esempio	Domanda.da.porsi
Numerico	'21', '3.5', '18.9'	Ha senso calcolare media
Testo	"femmina", "controllo"	Deve essere trattato come
Logico	'TRUE', 'FALSE'	Esprime una condizione v
Fattore/categoria	'gruppo', 'genere'	Quali livelli possibili ha?
Mancante	'NA'	Perché manca questo valo

```
str(sleep_data)
```

Questa riga è spesso più importante di un calcolo statistico: permette di verificare come R ha interpretato le variabili.

6.5. Operatori logici: selezionare casi

Molte analisi richiedono la selezione di alcuni casi. Per farlo, si utilizzano condizioni logiche.

Operatore	Significato	Esempio
>	maggiore di	<code>stress > 20</code>
<	minore di	<code>sleep_quality < 6</code>
==	uguale a	<code>group == "controllo"</code>
!=	diverso da	<code>group != "controllo"</code>
&	e	<code>stress > 20 & sleep_quality < 6</code>
	oppure	<code>group == "A" group == "B"</code>

Attenzione: per verificare l'uguaglianza si usa `==`, non `=`. Scrivere `group = "controllo"` all'interno di una condizione è un errore comune.

6.6. La pipe: leggere il codice come una sequenza di passi

Nei capitoli successivi useremo spesso la pipe `|>`. La pipe si legge come “poi” oppure “passa il risultato a”.

```
sleep_data |>
  summary()
```

Questa istruzione si legge così:

prendi `sleep_data`, poi applica `summary()`.

La pipe diventa utile quando le operazioni sono più di una:

```
sleep_data |>
  subset(stress > 20) |>
  summary()
```

Questa sequenza si legge così:

1. prendi `sleep_data`;
2. conserva solo i casi con `stress > 20`;
3. produci un riepilogo del risultato.

Nei capitoli su `dplyr` useremo la stessa logica con funzioni più leggibili come `filter()`, `select()`, `mutate()` e `summarise()`.

6.7. Leggere un blocco di codice riga per riga

Consideriamo un esempio vicino ai temi del modulo:

```
sleep_data <- read.csv("data/sleep_stress.csv")

sleep_data |>
  subset(stress > 20) |>
  summary()
```

Per leggerlo, non è necessario conoscere tutto R, basta procedere con ordine:

1. `read.csv("data/sleep_stress.csv")` legge un file CSV;
2. il risultato viene salvato in `sleep_data`;
3. `sleep_data |> ...` prende quel dataset come punto di partenza;
4. `subset(stress > 20)` conserva solo alcuni casi;
5. `summary()` produce un riepilogo.

La domanda metodologica è: cosa abbiamo escluso? In questo caso, l'analisi riguarda solo gli studenti con un punteggio di stress superiore a 20. Se non ce ne accorgiamo, potremmo interpretare il risultato come se riguardasse l'intero campione.

Metodo di lettura

Quando incontri codice generato dall'AI, non leggerlo tutto insieme. Leggilo riga per riga e trasforma ogni riga in una frase in linguaggio naturale.

6.8. Usare l'AI con criterio

In questa parte del corso, l'uso dell'AI è ammesso e incoraggiato, a condizione che serva a imparare e a lavorare meglio. Tuttavia, ogni uso dell'AI deve lasciare lo studente in grado di spiegare il codice utilizzato.

6.8.1. Cosa puoi chiedere all'AI

Puoi chiedere, per esempio:

Ho un dataset R chiamato `sleep_data` con le variabili `stress` e `sleep_quality`. Scrivi un codice R semplice per calcolare la media di `sleep_quality` e spiega ogni riga.

Oppure:

6. Sintassi minima per leggere codice R

Questo codice R genera un errore. Spiegami il messaggio di errore e proponi una correzione senza usare funzioni avanzate.

6.8.2. Cosa devi controllare tu

Dopo aver ricevuto codice dall'AI, controlla sempre:

- i nomi delle variabili sono presenti nel dataset?
- il codice elimina righe o valori mancanti?
- il risultato è coerente con il tipo di variabile?
- il grafico o la statistica sono adeguati alla domanda?
- sei in grado di spiegare ogni riga?

6.8.3. Prompt utile

Un buon prompt per imparare R non è:

Scrivi il codice per fare l'analisi.

È meglio chiedere:

Scrivi un codice R semplice e commentato riga per riga. Usa solo funzioni di base o funzioni già introdotte nel corso. Alla fine, indicami quali controlli devo effettuare per verificare che il risultato sia corretto.

6.9. Messaggi di errore: non sono fallimenti

Gli errori fanno parte del lavoro con R. Alcuni messaggi ricorrenti sono:

Messaggio	Possibile significato
<code>object not found</code>	Il nome dell'oggetto è sbagliato o l'oggetto non è stato creato.
<code>could not find function</code>	La funzione è scritta male o il pacchetto non è stato caricato.
<code>non-numeric argument</code>	Stai usando un'operazione numerica su un valore non numerico.
<code>NAs introduced by coercion</code>	R ha provato a convertire qualcosa in numero ma alcuni valori non erano numeri.

Quando compare un errore, il primo passo non è cambiare codice a caso. Il primo passo è capire che cosa R sta dicendo.

Una buona richiesta all'AI è:

Spiegami questo errore R in modo semplice. Prima spiegami che cosa significa, poi mostrami come controllare il problema nel dataset.

6.10. Mini-esempio: dalla tabella al controllo

Immaginiamo di avere questi dati:

```
sleep_data <- data.frame(
  id = 1:6,
  stress = c(18, 22, 19, 25, 21, NA),
  sleep_quality = c(7, 6, 8, 5, NA, 6)
)
```

Prima di calcolare la relazione tra stress e sonno, possiamo effettuare dei controlli minimi:

```
str(sleep_data)
summary(sleep_data)
mean(sleep_data$stress, na.rm = TRUE)
mean(sleep_data$sleep_quality, na.rm = TRUE)
```

Queste righe non rispondono ancora alla domanda di ricerca. Queste righe servono a capire se i dati sono leggibili, se ci sono valori mancanti e quali valori appaiono plausibili.

6.11. Cosa rimandiamo ai capitoli successivi

Questo capitolo introduce solo la sintassi minima. I dettagli verranno ripresi quando necessario:

- l'organizzazione dei file e dei progetti sarà trattata nel capitolo sull'ambiente di lavoro;
- l'importazione e il controllo dei dati saranno trattati nel capitolo sulle funzioni di utilità;
- la trasformazione ordinata dei dati sarà trattata con `dplyr`;
- la visualizzazione sarà trattata con `ggplot2`;
- la scrittura di report riproducibili sarà trattata nel capitolo su Quarto;
- la programmazione vera e propria resterà un approfondimento, non un prerequisito per iniziare.

6.12. Esercizi

! Esercizio 1: leggere codice

Leggi il codice seguente e scrivi, in linguaggio naturale, che cosa fa ogni riga.

```
swls_scores <- c(20, 16, 23, 25, 11, NA)
mean(swls_scores, na.rm = TRUE)
sd(swls_scores, na.rm = TRUE)
```

Poi rispondi:

1. perché compare `na.rm = TRUE`?
2. che cosa succederebbe togliendolo?
3. che tipo di variabile rappresenta `swls_scores`?

! Esercizio 2: diagnosticare un errore

Il codice seguente produce un errore:

```
stress_score <- 18
stress_score + sleep_score
```

Rispondi:

1. quale oggetto non è stato creato?
2. quale messaggio di errore ti aspetti?
3. come potresti chiedere all'AI di spiegarti il problema senza farti scrivere direttamente tutta la soluzione?

! Esercizio 3: controllare codice prodotto dall'AI

L'AI propone questo codice:

```
sleep_data |>
  subset(stress > 20) |>
  summary()
```

Rispondi:

1. quali casi vengono esclusi?
2. il riepilogo finale riguarda tutto il dataset o solo un sottoinsieme?
3. quale frase aggiungeresti in un report Quarto per spiegare questa scelta?

! Esercizio 4: scrivere un prompt migliore

Trasforma questo prompt generico:

Fammi l'analisi in R.

in un prompt più utile per imparare. Il nuovo prompt deve chiedere all'AI di:

- usare codice semplice;
- spiegare ogni riga;
- indicare quali controlli fare;
- non interpretare i risultati oltre ciò che il codice permette.

Cosa portare al capitolo successivo

La sintassi di R non va imparata come una serie di regole astratte. Va utilizzata come strumento per rendere esplicite le operazioni sui dati.

Per proseguire, ti serviranno soprattutto queste idee:

- un oggetto salva qualcosa con un nome;
- una funzione applica un'operazione;

- gli argomenti modificano il comportamento della funzione;
- i data frame sono tabelle di casi e variabili;
- i valori mancanti devono essere riconosciuti e gestiti;
- la pipe permette di leggere il codice come una sequenza di passaggi;
- il codice prodotto dall'AI deve sempre essere controllato.

Questi elementi saranno collocati in un ambiente di lavoro ordinato nel prossimo capitolo: file, cartelle, progetti e documenti riproducibili.

Bibliografia

7. Ambiente di lavoro e progetti R

7.1. Perché questo capitolo viene prima dell'analisi

Spesso, quando un'analisi non funziona, il problema non è una formula statistica. Spesso il problema è molto più semplice: il file dei dati non si trova nella cartella giusta, il percorso è scritto in modo diverso sul computer di un'altra persona, un pacchetto non è stato caricato o il codice dipende da oggetti rimasti in memoria da una sessione precedente.

Per questo motivo, prima di imparare a trasformare o visualizzare i dati, è necessario imparare a organizzare l'ambiente di lavoro.

In questo capitolo useremo il termine “ambiente” in senso pratico: il progetto, le cartelle, i file, la sessione di R, i pacchetti caricati e le condizioni che permettono di eseguire di nuovo un'analisi.

L'idea centrale è semplice:

Un'analisi è davvero utile solo se può essere capita, controllata e riprodotta.

Questo vale anche quando il codice è stato scritto con l'aiuto dell'AI. L'AI può suggerire comandi, correggere errori e proporre strutture di progetto, ma non può sapere da sola dove si trovano i vostri file, quale versione dei dati state utilizzando, quali passaggi avete già eseguito e quali scelte devono essere documentate.

7.2. Obiettivi del capitolo

Alla fine del capitolo dovrete sapere:

- riconoscere la differenza tra file, cartelle e progetto;
- creare o aprire un progetto R in RStudio/Posit;
- usare nomi di file leggibili e robusti;
- distinguere percorsi assoluti e percorsi relativi;
- capire perché `setwd()` va evitato nei documenti condivisi;
- usare una struttura semplice per organizzare dati, codice e risultati;
- controllare se un'analisi può essere rieseguita da zero.

Non è necessario memorizzare ogni dettaglio tecnico. È invece importante sviluppare una buona abitudine: **analisi deve essere inserita in una cartella di progetto ben organizzata.**

7.3. Il progetto come unità di lavoro

Un progetto di analisi non è un singolo file. Si tratta di una piccola unità di ricerca che contiene almeno:

- i dati;
- il codice;
- il testo che spiega le scelte fatte;
- gli output prodotti dall'analisi.

In RStudio/Posit, un progetto R è una cartella che contiene un file con estensione `.Rproj`. Aprire quel file significa dire a R: “questa è la cartella principale del mio lavoro”.

Una struttura minima può essere questa:

```
progetto_stress_sonno/
  progetto_stress_sonno.Rproj
  data/
    raw/
      stress_sonno_originale.csv
    processed/
      stress_sonno_pulito.csv
  code/
    01_pulizia_dati.R
  output/
    grafico_sonno.png
  report.qmd
```

Non tutti i progetti devono avere esattamente questa struttura. L'importante è che la struttura sia chiara e stabile. Chi apre il progetto deve poter capire rapidamente dove si trovano i dati originali, il codice e i risultati.

Regola pratica

Create una cartella separata per ogni progetto. Non lavorate in una cartella generica chiamata Desktop, Download o R.

7.4. Nomi di file semplici

I nomi dei file devono essere facili da leggere per gli esseri umani e facili da gestire per il computer.

Usate:

- lettere minuscole;
- numeri;
- trattini bassi `_` o trattini `-`;
- date nel formato `YYYY-MM-DD`, quando servono.

Evitate:

- spazi;

7. Ambiente di lavoro e progetti R

- accenti;
- caratteri speciali;
- nomi vaghi come `file1.csv`, `nuovo.csv`, `analisi_finale_vera.R`.

Esempi:

```
# Meglio
2026-03-15_stress_sonno_raw.csv
01_pulizia_dati.R
02_grafici_eda.qmd

# Peggio
Dati Stress Sonno.csv
analisi finale.R
nuovo file corretto 2.csv
```

Questa regola può sembrare banale, ma permette di evitare molti errori. Inoltre, rende più semplice chiedere aiuto all'AI: un nome chiaro permette di descrivere meglio il problema e di controllare più facilmente il codice suggerito.

7.5. Percorsi assoluti e relativi

Un percorso indica la posizione di un file.

Un **percorso assoluto** descrive la posizione completa del file nel computer:

```
/Users/maria/Desktop/progetto_stress_sonno/data/raw/stress_sonno_originale.csv
```

oppure, su Windows:

```
C:/Users/Maria/Desktop/progetto_stress_sonno/data/raw/stress_sonno_originale.csv
```

Il problema è che un percorso assoluto funziona solo su quel computer. Se il progetto viene spostato, condiviso o aperto da un'altra persona, il codice probabilmente non funzionerà più.

Un **percorso relativo** descrive invece la posizione del file rispetto alla cartella principale del progetto:

```
data/raw/stress_sonno_originale.csv
```

Questo percorso è più robusto. Funziona finché la struttura interna del progetto rimane la stessa.

! Da ricordare

Nei progetti condivisi, nei report Quarto e negli esercizi, utilizzate percorsi relativi. Evitate i percorsi che contengono il nome del vostro computer, il nome del vostro utente o il nome del vostro desktop.

7.6. Evitare `setwd()` nei file condivisi

In molti tutorial si trova un comando come questo:

```
setwd("/Users/maria/Desktop/progetto_stress_sonno")
```

Questo comando cambia manualmente la cartella di lavoro. Può sembrare comodo, ma rende il codice fragile: funzionerà sul computer di Maria, ma non su quello di Luca o Giulia.

In un progetto R ben organizzato, di solito non è necessario usare la funzione `setwd()`. Aprendo il file `.Rproj`, RStudio/Posit riconosce la cartella principale del progetto.

Quando dobbiamo indicare un file all'interno del progetto, possiamo usare un percorso relativo:

```
readr::read_csv("data/raw/stress_sonno_originale.csv")
```

In alternativa, si può usare il pacchetto `here`, che costruisce percorsi a partire dalla radice del progetto:

```
readr::read_csv(here::here("data", "raw", "stress_sonno_originale.csv"))
```

La seconda forma è spesso più sicura quando il progetto contiene molti file e cartelle.

7.7. Dati originali e dati modificati

Una buona abitudine è non modificare mai direttamente i dati originali.

Distinguate tra:

- `data/raw/`: dati originali, così come sono stati ricevuti o scaricati;
- `data/processed/`: dati puliti o trasformati;
- `code/`: script che spiegano come si passa dai dati originali ai dati modificati.

Per esempio:

```
data/raw/stress_sonno_originale.csv
```

può essere importato, controllato, corretto e salvato come:

```
data/processed/stress_sonno_pulito.csv
```

L'obiettivo non è creare molte cartelle. Il punto è poter rispondere a questa domanda:

Da dove provengono questi dati e quali trasformazioni sono state effettuate?

Questa domanda è più importante della sintassi. È una domanda metodologica.

7.8. La sessione di R

Quando lavorate in R, create oggetti nella memoria della sessione: dataset, vettori, risultati, grafici, modelli. Questi oggetti vivono temporaneamente nello spazio di lavoro.

Un errore frequente è scrivere codice che funziona solo perché alcuni oggetti sono già presenti in memoria. In quel caso, il codice sembra corretto, ma non è davvero riproducibile.

Per controllare il vostro lavoro, fate spesso questa prova:

1. riavviate R;
2. eseguite il documento o lo script dall'inizio;
3. verificate che non ci siano errori.

In RStudio/Posit, potete riavviare R da:

```
Session > Restart R
```

Poi rieseguite il codice. Se qualcosa si rompe, significa che il documento dipendeva da passaggi non espliciti.

Controllo minimo di riproducibilità

Prima di consegnare un esercizio o un report, riavviate R ed eseguite tutto da capo. Se il documento non funziona dopo il riavvio, non è ancora riproducibile.

7.9. Pacchetti: installare e caricare

I pacchetti estendono R con nuove funzioni. Per utilizzarli, è necessario distinguere due operazioni.

Installare un pacchetto significa scaricarlo sul computer:

```
install.packages("tidyverse")
```

Caricare un pacchetto significa renderlo disponibile nella sessione corrente:

```
library(tidyverse)
```

L'installazione di solito si effettua una sola volta. Il caricamento, invece, va effettuato ogni volta che si apre una nuova sessione o si esegue un nuovo documento.

Per rendere più chiaro da quale pacchetto proviene una funzione, si può usare la forma:

```
readr::read_csv("data/raw/stress_sonno_originale.csv")
```

In questo caso, `read_csv()` è la funzione e `readr` è il pacchetto.

7.10. Controlli iniziali su un progetto

Quando aprite un progetto, prima di analizzare i dati, effettuate alcuni controlli semplici.

```
# Dove si trova la cartella di lavoro?
getwd()

# Quali file ci sono nella cartella principale?
list.files()

# Il file dei dati esiste?
file.exists("data/raw/stress_sonno_originale.csv")
```

Se usate here:

```
here::here()
file.exists(here::here("data", "raw", "stress_sonno_originale.csv"))
```

Questi comandi non sono analisi statistiche. Sono controlli di orientamento. Servono a evitare errori prima che diventino difficili da individuare.

7.11. Usare l'AI con criterio

L'AI è molto utile per risolvere problemi legati all'ambiente di lavoro. Potete chiederle, per esempio:

Sto lavorando in un progetto R con cartelle `data/raw`, `data/processed` e `code`. Scrivi un esempio di codice per importare un file CSV da `data/raw` usando un percorso relativo.

Oppure:

Questo codice funziona sul mio computer, ma non su quello di un collega". Controlla se ci sono percorsi assoluti o dipendenze dall'ambiente locale.

Ci sono però cose che dovete controllare voi:

- il nome del file è corretto?
- il file si trova davvero nella cartella indicata?
- il codice usa percorsi relativi o assoluti?
- il pacchetto richiesto è installato e caricato?
- il progetto funziona dopo aver riavviato R?

Errore frequente

L'AI può generare nomi di file, cartelle o variabili plausibili ma inesistenti. Non copiate il codice senza prima aver verificato che corrisponda alla struttura reale del vostro progetto.

7.12. Cosa portare ai capitoli successivi

Nei capitoli successivi useremo R per importare, trasformare, riassumere e visualizzare i dati. Prima di procedere, è essenziale che ogni analisi abbia una casa: una cartella di progetto con nomi chiari, percorsi relativi e un documento che possa essere rieseguito.

La sintassi di R è importante, ma non sufficiente. Un'analisi ordinata richiede anche una struttura ben organizzata.

Prima di procedere, verificate di saper eseguire le seguenti operazioni:

- aprire un progetto R;
- trovare la cartella principale del progetto;
- indicare un file con un percorso relativo;
- distinguere i dati originali da quelli modificati;
- riavviare R ed eseguire tutto da capo.
- Spiegare a parole dove si trovano i dati e come vengono usati.

Se siete in grado di fare tutto questo, allora siete pronti a usare R non solo come calcolatrice, ma anche come ambiente per un'analisi trasparente e riproducibile.

8. Dal file alla tabella controllata

Perché questo capitolo esiste

Prima di calcolare statistiche, costruire grafici o stimare modelli, è necessario assicurarsi che i dati siano stati caricati correttamente.

Spesso, gli errori nelle analisi derivano da problemi semplici: il file letto non è quello giusto, una variabile numerica è stata importata come testo, i valori mancanti non sono stati riconosciuti o il codice funziona solo sul computer di chi lo ha scritto.

In questo capitolo non costruiremo un catalogo di funzioni R. Impareremo una routine minima:

importare un file, ispezionare la tabella, controllare che i dati abbiano senso, salvare una versione elaborata quando necessario.

L'AI può suggerire il codice per molti di questi passaggi. Tuttavia, non può sapere da sola se il file importato è quello corretto, se le colonne hanno il significato atteso o se i valori osservati sono plausibili per la domanda di ricerca.

Idea guida

Un dataset importato non è ancora pronto per l'analisi. Prima di utilizzarlo, dobbiamo controllarlo.

8.1. Obiettivi del capitolo

Al termine del capitolo dovresti sapere:

- importare un file utilizzando percorsi relativi al progetto;
- distinguere i dati originali da quelli elaborati;
- controllare le dimensioni, i nomi delle colonne e le prime righe di una tabella;
- riconoscere il tipo delle variabili principali;
- individuare i valori mancanti;
- controllare le categorie e i valori inattesi;
- esportare un dataset elaborato senza sovrascrivere i dati originali;
- verificare il codice prodotto con l'intelligenza artificiale.

8.2. Il flusso minimo

Quando riceviamo un file di dati, possiamo sempre seguire la stessa sequenza:

1. **trovare il file** dentro il progetto;
2. **importarlo** in R;

8. Dal file alla tabella controllata

3. **guardare la struttura** del dataset;
4. **controllare le variabili** più importanti;
5. **identificare problemi evidenti**;
6. **salvare una versione elaborata**, se abbiamo fatto modifiche.

In forma schematica:

```
# Importare
stress_sonno <- rio::import(
  here::here("data", "raw", "stress_sonno.csv")
)

# Controlli iniziali
head(stress_sonno)
dim(stress_sonno)
names(stress_sonno)
str(stress_sonno)

# Valori mancanti e categorie
colSums(is.na(stress_sonno))
table(stress_sonno$genere, useNA = "ifany")
summary(stress_sonno)
```

Questo codice non rappresenta ancora un'analisi statistica. Si tratta di una verifica preliminare che ci permette di capire se la tabella che useremo per l'EDA è coerente con quanto pensiamo di avere.

8.3. Dove devono stare i dati

Un progetto dovrebbe distinguere almeno tra dati originali, dati elaborati, codice e risultati:

```
progetto_stress_sonno/
  progetto_stress_sonno.Rproj
  data/
    raw/
      stress_sonno_originale.csv
    processed/
      stress_sonno_controllato.csv
  code/
    01_controllo_dati.R
  report.qmd
```

La distinzione più importante è questa:

- data/raw/: dati originali, da non modificare;
- data/processed/: dati elaborati o puliti;
- code/ o file .qmd: codice che documenta le operazioni eseguite.

! Regola pratica

Non modificate mai direttamente i dati originali. Conservate una copia intatta in `data/raw/` e salvate eventuali versioni elaborate in `data/processed/`.

8.4. Importare dati con `rio::import()`

Nella ricerca psicologica i dati possono arrivare in formati diversi: `.csv`, `.xlsx`, `.sav`, `.txt`. Il pacchetto `rio` permette di importarli con un comando uniforme.

```
stress_sonno <- rio::import(
  here::here("data", "raw", "stress_sonno.csv")
)
```

La funzione `here::here()` costruisce il percorso a partire dalla cartella principale del progetto. In questo modo il codice non dipende dal Desktop, dal nome dell'utente o dalla posizione del progetto su un singolo computer.

Lo stesso schema può essere usato con file Excel o SPSS:

```
questionario <- rio::import(
  here::here("data", "raw", "questionario.xlsx")
)

archivio_spss <- rio::import(
  here::here("data", "raw", "archivio_studio.sav")
)
```

! Errore comune

Un errore come `file not found` significa quasi sempre che il percorso è sbagliato, il nome del file non corrisponde esattamente oppure il progetto R non è stato aperto dalla cartella corretta.

8.5. Controllo 1: il file importato è quello giusto?

Dopo l'importazione, la prima domanda è:

Questo oggetto contiene davvero i dati che mi aspettavo?

Per rispondere, guardiamo le prime righe:

```
head(stress_sonno)
```

Possiamo anche aprire la tabella nel visualizzatore di RStudio/Posit:

```
View(stress_sonno)
```

`View()` è utile per dare un'occhiata veloce, ma non sostituisce i controlli scritti nel codice. Un controllo scritto è riproducibile, un'occhiata manuale no.

8.6. Controllo 2: quante righe e quante colonne ci sono?

```
dim(stress_sonno)
nrow(stress_sonno)
ncol(stress_sonno)
```

`dim()` restituisce prima il numero di righe e poi il numero di colonne. Se uno studio dovrebbe avere 120 partecipanti e 8 variabili, ci aspettiamo un risultato simile a:

```
[1] 120    8
```

Se troviamo una sola colonna, molte più righe del previsto o un numero inatteso di partecipanti, dobbiamo fermarci e capire che cosa è successo.

8.7. Controllo 3: come si chiamano le variabili?

```
names(stress_sonno)
```

Nomi chiari rendono il codice più leggibile. Nomi come Q1, Q2, VAR0003 o X. . . 4 richiedono attenzione: spesso provengono da esportazioni automatiche e devono essere documentati o rinominati.

Per ora, l'obiettivo non è pulire tutti i nomi, ma controllarli prima di utilizzarli.

8.8. Controllo 4: che tipo di variabili abbiamo?

Una variabile può essere letta da R come numero, testo, fattore, data o valore logico. Se il tipo è sbagliato, anche l'analisi successiva può essere sbagliata.

```
str(stress_sonno)
dplyr::glimpse(stress_sonno)
```

Possiamo anche controllare una singola variabile:

```
class(stress_sonno$stress)
class(stress_sonno$genere)
```

Esempi di problemi frequenti:

- `eta` dovrebbe essere numerica, ma è stata importata come testo;
- `genere` contiene scritture diverse della stessa categoria;
- `data_compilazione` dovrebbe essere una data, ma è stata importata come testo;
- una scala Likert è numerica nel file, ma va interpretata come risposta ordinale.

i Collegamento con la misurazione

Il tipo di variabile in R non corrisponde automaticamente al significato psicologico della misura. Una scala Likert può essere codificata con numeri, ma questi numeri rappresentano risposte ordinate. Il controllo tecnico deve sempre essere collegato a quello concettuale.

8.9. Controllo 5: ci sono valori mancanti?

In R i valori mancanti sono rappresentati da NA.

```
colSums(is.na(stress_sonno))
```

Per una singola variabile:

```
sum(is.na(stress_sonno$qualita_sonno))
mean(is.na(stress_sonno$qualita_sonno))
```

La prima riga conta i valori mancanti. La seconda calcola la proporzione di valori mancanti.

I valori mancanti non sono solo un problema tecnico. Possono indicare domande saltate, prove non registrate, risposte sensibili o codifiche speciali come 999 o -99.

! Prima di usare `na.rm = TRUE`

Quando un codice ignora i valori mancanti, bisogna sapere quanti sono, dove si trovano e perché mancano.

8.10. Controllo 6: i valori sono plausibili?

Per variabili numeriche:

```
summary(stress_sonno$stress)
summary(stress_sonno$ore_sonno)
```

Per variabili categoriali:

```
table(stress_sonno$genere, useNA = "ifany")
table(stress_sonno$condizione, useNA = "ifany")
```

Esempi di segnali d'allarme:

- una variabile `eta` contiene il valore 222;
- una variabile `ore_sonno` contiene valori negativi;
- una scala da 1 a 7 contiene il valore 9;
- la categoria `femmina` compare anche come `F`, `Femmina`, `female`;
- una condizione sperimentale attesa non compare.

 Errore comune

Il fatto che il codice funzioni non significa che i dati siano corretti. R può calcolare una media anche su valori impossibili.

8.11. Esportare dati con `rio::export()`

Dopo aver controllato o modificato un dataset, possiamo salvarlo.

```
rio::export(  
  stress_sonno,  
  here::here("data", "processed", "stress_sonno_controllato.csv")  
)
```

La regola è salvare il risultato in una cartella diversa da quella dei dati originali:

```
data/raw/stress_sonno_originale.csv  
data/processed/stress_sonno_controllato.csv
```

In questo modo il file originale resta intatto.

8.12. Checklist dopo l'importazione

Ogni volta che importate un dataset, potete usare questa checklist:

```
# Dimensioni  
nrow(dati)  
ncol(dati)  
  
# Prime righe e nomi  
head(dati)  
names(dati)  
  
# Struttura  
str(dati)  
# oppure  
# dplyr::glimpse(dati)  
  
# Valori mancanti  
colSums(is.na(dati))  
  
# Variabili numeriche principali  
summary(dati$variabile_numerica)  
  
# Variabili categoriali principali  
table(dati$variabile_categoriale, useNA = "ifany")
```

Sostituite `dati`, `variabile_numerica` e `variabile_categoriale` con i nomi reali del vostro dataset.

8.13. Usare l'AI con criterio

L'AI può generare codice utile. Per esempio, possiamo chiedere:

Ho un file `stress_sonno.csv` nella cartella `data/raw/` di un progetto R. Scrivi codice R per importarlo con `rio`, controllare dimensioni, nomi delle colonne, tipi delle variabili e valori mancanti.

Una risposta utile potrebbe essere:

```
stress_sonno <- rio::import(
  here::here("data", "raw", "stress_sonno.csv")
)

dim(stress_sonno)
names(stress_sonno)
dplyr::glimpse(stress_sonno)
colSums(is.na(stress_sonno))
```

Dopo aver ricevuto codice dall'AI, dovete verificare:

1. il percorso del file è corretto?
2. il nome dell'oggetto creato è chiaro?
3. le funzioni usate richiedono pacchetti?
4. il codice mostra davvero le informazioni necessarie?
5. i risultati ottenuti sono plausibili rispetto allo studio?

! Responsabilità dello studente

L'uso dell'AI per generare il codice di importazione e controllo è accettabile. Consegnare i risultati senza sapere quali file sono stati importati, quali variabili sono state lette e quali problemi sono emersi, no.

8.14. Esempio guidato: stress accademico e sonno

Immaginiamo di voler analizzare uno studio su stress accademico e qualità del sonno. Il file originale si chiama `stress_sonno_originale.csv` e si trova in `data/raw/`.

```
stress_sonno <- rio::import(
  here::here("data", "raw", "stress_sonno_originale.csv")
)

dim(stress_sonno)
names(stress_sonno)
dplyr::glimpse(stress_sonno)
colSums(is.na(stress_sonno))
summary(stress_sonno$stress)
summary(stress_sonno$qualita_sonno)
table(stress_sonno$genere, useNA = "ifany")
```

Dopo questi controlli, dovremmo essere in grado di rispondere a domande semplici:

- il numero di righe corrisponde al numero atteso di partecipanti?
- le variabili principali sono presenti?
- i tipi delle variabili sono coerenti?
- ci sono valori mancanti?
- i valori minimi e massimi sono plausibili?
- le categorie sono scritte in modo coerente?

Solo a questo punto ha senso passare a trasformazioni, grafici e statistiche descrittive.

8.15. Errori frequenti

8.15.1. Il file non viene trovato

Verificate che il progetto `.Rproj` sia aperto, che il file sia nella cartella indicata, che il nome sia scritto nello stesso modo e che l'estensione sia corretta.

8.15.2. Il dataset ha una sola colonna

Può succedere che i file CSV utilizzino un separatore diverso da quello atteso. Se dopo l'importazione il dataset ha una sola colonna, non procedere con l'analisi.

8.15.3. Una variabile numerica è stata letta come testo

Possibili cause sono i separatori decimali, i caratteri non numerici o le codifiche dei valori mancanti, come `missing`, `non risponde`, `999` o `-99`.

8.15.4. I valori mancanti non sono riconosciuti

Solo `NA` è riconosciuto da R come valore mancante. Altre codifiche devono essere trasformate esplicitamente, dopo aver verificato il codebook o la documentazione dello studio.

8.16. Esercizi

Esercizio 1: leggere un codice

L'AI ha prodotto questo codice:

```
dati <- rio::import(here::here("data", "raw", "questionario.csv"))
dim(dati)
names(dati)
dplyr::glimpse(dati)
colSums(is.na(dati))
summary(dati)
```

Rispondete: quale file viene importato? Dove deve trovarsi? Quale oggetto viene creato? Quali controlli vengono eseguiti? Quale controllo aggiungereste per una variabile categoriale?

💡 Esercizio 2: diagnosticare un problema

Uno studente importa un file e ottiene un dataset con 1 colonna e 250 righe. Il questionario, però, dovrebbe avere 30 variabili. Perché questo risultato è sospetto? Quale controllo ha permesso di accorgersene? Quali possibili cause potreste verificare?

💡 Esercizio 3: usare l'AI con controllo

Chiedete a un sistema di AI di scrivere codice R per importare un file chiamato `swls.csv`, contenuto in `data/raw/`, e per controllare nomi, dimensioni, tipi di variabili e valori mancanti. Poi valutate la risposta: il codice usa percorsi relativi? Importa il file dalla cartella giusta? Include controlli sufficienti? Sapete spiegare ogni riga?

8.17. Cosa portare al capitolo successivo

Prima di trasformare i dati con `dplyr`, dobbiamo assicurarci che la tabella importata sia affidabile. In particolare, dobbiamo aver controllato:

- il file letto;
- quante righe e colonne contiene;
- come si chiamano le variabili;
- che tipo di variabili sono state importate;
- quanti valori mancanti ci sono;
- se i valori osservati sono plausibili;
- dove viene salvata una eventuale versione elaborata.

Il capitolo successivo utilizzerà questi dati per selezionare le variabili, filtrare le righe, creare nuove colonne e riassumere le informazioni. Tutte queste operazioni hanno senso solo se la tabella di partenza è stata controllata.

Bibliografia

9. Trasformare i dati con dplyr

Perché questo capitolo

Prima di descrivere, visualizzare o modellare i dati, è necessario trasformarli. Raramente un file appena importato è pronto per l'analisi: può contenere variabili inutili, nomi poco chiari, valori mancanti, codifiche diverse da quelle attese o informazioni che devono essere riorganizzate.

Il pacchetto `dplyr` rende queste operazioni esplicite e leggibili. In questo capitolo non cercheremo di imparare tutto il pacchetto `dplyr`. L'obiettivo è più limitato, ma anche più importante: imparare a leggere, modificare e controllare le trasformazioni più comuni dei dati.

Al termine del capitolo, dovresti essere in grado di:

- riconoscere i principali verbi di `dplyr`;
- leggere una pipeline riga per riga;
- selezionare variabili, filtrare le osservazioni e creare nuove colonne;
- calcolare sintesi descrittive per l'intero campione o per gruppi;
- verificare che una trasformazione abbia effettivamente prodotto il risultato desiderato;
- valutare il codice `dplyr` prodotto con l'aiuto dell'AI.

! Idea chiave

`dplyr` non serve solo a “manipolare” dati. Consente di rendere visibile il percorso che porta dal file iniziale alla tabella utilizzata per l'analisi. Ogni riga di codice dovrebbe poter essere spiegata.

9.1. Dati ordinati: una convenzione utile

Molti strumenti del *tidyverse*, incluso `dplyr`, funzionano meglio quando i dati sono organizzati in forma *tidy*. In un dataset *tidy*:

1. ogni variabile è una colonna;
2. ogni osservazione è una riga;
3. ogni valore è una cella.

Questa regola non è una legge naturale. Si tratta di una convenzione pratica. La sua utilità sta nel fatto che rende più semplice descrivere, trasformare e visualizzare i dati.

Per esempio, se si studia la relazione tra stress accademico e qualità del sonno, si potrebbe avere una tabella in cui ogni riga rappresenta uno studente e ogni colonna rappresenta una variabile:

```
library(dplyr)
library(tibble)

studenti <- tibble(
  id = 1:10,
  genere = c("F", "F", "M", "F", "M", "F", "M", "F", "M", "F"),
  corso = c("psicologia", "psicologia", "scienze", "psicologia", "scienze",
            "psicologia", "psicologia", "scienze", "psicologia", "scienze"),
  stress = c(18, 25, 21, 30, 16, 28, 24, NA, 19, 27),
  sonno_ore = c(7.2, 6.1, 6.8, 5.4, 7.5, 5.9, 6.2, 6.7, NA, 5.8),
  caffeina = c(1, 3, 2, 4, 1, 3, 2, 2, 1, 4)
)

studenti
```

```
# A tibble: 10 x 6
      id genere corso      stress sonno_ore caffeina
  <int> <chr> <chr>      <dbl>      <dbl>      <dbl>
1     1 F    psicologia    18        7.2        1
2     2 F    psicologia    25        6.1        3
3     3 M    scienze      21        6.8        2
4     4 F    psicologia    30        5.4        4
5     5 M    scienze      16        7.5        1
6     6 F    psicologia    28        5.9        3
7     7 M    psicologia    24        6.2        2
8     8 F    scienze      NA        6.7        2
9     9 M    psicologia    19        NA         1
10    10 F    scienze      27        5.8        4
```

In questa tabella:

- id identifica lo studente;
- genere e corso sono variabili categoriali;
- stress, sonno_ore e caffeina sono variabili numeriche;
- NA indica un valore mancante.

Prima di procedere, è sempre utile guardare la struttura dei dati:

```
glimpse(studenti)
```

```
Rows: 10
Columns: 6
$ id      <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10
$ genere  <chr>  "F", "F", "M", "F", "M", "F", "M", "F", "M", "F"
$ corso   <chr>  "psicologia", "psicologia", "scienze", "psicologia", "scienz~
$ stress  <dbl> 18, 25, 21, 30, 16, 28, 24, NA, 19, 27
$ sonno_ore <dbl> 7.2, 6.1, 6.8, 5.4, 7.5, 5.9, 6.2, 6.7, NA, 5.8
$ caffeina <dbl> 1, 3, 2, 4, 1, 3, 2, 2, 1, 4
```

9.2. La pipe: leggere il codice come una sequenza di operazioni

In R moderno si usa spesso la pipe `|>`. La pipe prende il risultato di una riga e lo passa alla riga successiva.

Questo permette di leggere il codice dall'alto verso il basso:

```
studenti |>
  filter(stress >= 20) |>
  select(id, stress, sonno_ore)
```

```
# A tibble: 6 x 3
   id stress sonno_ore
<int> <dbl>   <dbl>
1     2    25     6.1
2     3    21     6.8
3     4    30     5.4
4     6    28     5.9
5     7    24     6.2
6    10    27     5.8
```

Il codice può essere letto così:

1. parti dalla tabella `studenti`;
2. tieni solo gli studenti con `stress >= 20`;
3. mostra solo le colonne `id`, `stress` e `sonno_ore`.

La pipe non è indispensabile, ma rende il flusso dell'analisi più chiaro. Questo è particolarmente importante quando il codice viene prodotto o modificato con l'aiuto dell'intelligenza artificiale: una pipeline leggibile è più facile da controllare.



Come leggere una pipeline

Quando leggi codice dplyr, chiediti sempre:

1. quale tabella entra nella pipeline?
2. quali righe vengono incluse o escluse?
3. quali colonne vengono tenute, eliminate o create?
4. quale tabella esce alla fine?

9.3. I verbi essenziali

I verbi principali di dplyr corrispondono a operazioni molto semplici.

Verbo	Domanda a cui risponde
<code>select()</code>	Quali colonne mi servono?
<code>filter()</code>	Quali righe voglio includere?
<code>mutate()</code>	Quali nuove variabili voglio creare?
<code>arrange()</code>	In quale ordine voglio vedere le righe?

Verbo	Domanda a cui risponde
<code>group_by()</code>	Rispetto a quali gruppi voglio calcolare i risultati?
<code>summarise()</code>	Quale sintesi voglio ottenere?

Questi verbi sono sufficienti per la maggior parte delle trasformazioni necessarie in una prima analisi esplorativa.

9.4. Selezionare colonne con `select()`

`select()` serve a scegliere le variabili che vogliamo mantenere.

```
studenti |>
  select(id, stress, sonno_ore)
```

```
# A tibble: 10 x 3
      id stress sonno_ore
  <int> <dbl>   <dbl>
1     1    18     7.2
2     2    25     6.1
3     3    21     6.8
4     4    30     5.4
5     5    16     7.5
6     6    28     5.9
7     7    24     6.2
8     8    NA     6.7
9     9    19     NA
10    10    27     5.8
```

Questa operazione non modifica i valori. Cambia solo le colonne visibili nella tabella risultante.

Possiamo anche rimuovere una colonna utilizzando il segno meno:

```
studenti |>
  select(-caffeina)
```

```
# A tibble: 10 x 5
      id genere corso      stress sonno_ore
  <int> <chr>   <chr>   <dbl>   <dbl>
1     1 F     psicologia 18     7.2
2     2 F     psicologia 25     6.1
3     3 M     scienze   21     6.8
4     4 F     psicologia 30     5.4
5     5 M     scienze   16     7.5
6     6 F     psicologia 28     5.9
7     7 M     psicologia 24     6.2
8     8 F     scienze   NA     6.7
9     9 M     psicologia 19     NA
10    10 F     scienze   27     5.8
```

⚠ Controllo

Dopo la funzione `select()`, controlla sempre se hai mantenuto tutte le variabili necessarie per l'analisi. Eliminare una colonna troppo presto può rendere difficile capire che cosa è successo nelle fasi successive.

9.5. Filtrare righe con `filter()`

La funzione `filter()` serve a includere solo le osservazioni che soddisfano una determinata condizione.

```
studenti |>
  filter(stress >= 20)
```

```
# A tibble: 6 x 6
      id genere corso      stress sonno_ore caffeina
  <int> <chr> <chr>      <dbl>    <dbl>    <dbl>
1     2 F    psicologia    25      6.1      3
2     3 M    scienze      21      6.8      2
3     4 F    psicologia    30      5.4      4
4     6 F    psicologia    28      5.9      3
5     7 M    psicologia    24      6.2      2
6    10 F    scienze      27      5.8      4
```

Possiamo combinare più condizioni:

```
studenti |>
  filter(stress >= 20, sonno_ore < 6.5)
```

```
# A tibble: 5 x 6
      id genere corso      stress sonno_ore caffeina
  <int> <chr> <chr>      <dbl>    <dbl>    <dbl>
1     2 F    psicologia    25      6.1      3
2     4 F    psicologia    30      5.4      4
3     6 F    psicologia    28      5.9      3
4     7 M    psicologia    24      6.2      2
5    10 F    scienze      27      5.8      4
```

Questa pipeline include solo gli studenti con punteggio di stress almeno pari a 20 e meno di 6.5 ore di sonno.

Si possono usare anche operatori logici:

Operatore	Significato
<code>==</code>	uguale a
<code>!=</code>	diverso da
<code>></code>	maggiore di

Operatore	Significato
<	minore di
>=	maggiore o uguale a
<=	minore o uguale a
&	entrambe le condizioni sono vere
	almeno una delle condizioni è vera
%in%	appartiene a un insieme di valori

Esempio:

```
studenti |>
  filter(corso %in% c("psicologia", "scienze"), caffeina >= 3)
```

```
# A tibble: 4 x 6
   id genere corso      stress sonno_ore caffeina
  <int> <chr> <chr>      <dbl>      <dbl>      <dbl>
1     2 F    psicologia    25         6.1         3
2     4 F    psicologia    30         5.4         4
3     6 F    psicologia    28         5.9         3
4    10 F    scienze     27         5.8         4
```

! Attenzione ai valori mancanti

Quando una variabile contiene NA, una condizione logica può produrre risultati inattesi. Le righe con valori mancanti nella variabile utilizzata per il filtraggio vengono solitamente escluse dal risultato.

Per controllare esplicitamente i valori mancanti possiamo usare `is.na()`:

```
studenti |>
  filter(is.na(stress) | is.na(sonno_ore))
```

```
# A tibble: 2 x 6
   id genere corso      stress sonno_ore caffeina
  <int> <chr> <chr>      <dbl>      <dbl>      <dbl>
1     8 F    scienze     NA         6.7         2
2     9 M    psicologia    19         NA         1
```

Questa pipeline mostra gli studenti per cui manca il punteggio di stress oppure il numero di ore di sonno.

9.6. Creare variabili con `mutate()`

La funzione `mutate()` serve a creare nuove colonne o modificare colonne esistenti.

Per esempio, possiamo creare una variabile che indica se lo studente dorme meno di 6 ore:

9. Trasformare i dati con dplyr

```
studenti |>
  mutate(sonno_basso = sonno_ore < 6)
```

```
# A tibble: 10 x 7
      id genere corso      stress sonno_ore caffeina sonno_basso
  <int> <chr>  <chr>    <dbl>    <dbl>    <dbl> <lgl>
1     1  F     psicologia  18      7.2      1 FALSE
2     2  F     psicologia  25      6.1      3 FALSE
3     3  M     scienze    21      6.8      2 FALSE
4     4  F     psicologia  30      5.4      4 TRUE
5     5  M     scienze    16      7.5      1 FALSE
6     6  F     psicologia  28      5.9      3 TRUE
7     7  M     psicologia  24      6.2      2 FALSE
8     8  F     scienze    NA      6.7      2 FALSE
9     9  M     psicologia  19      NA      1 NA
10    10  F     scienze    27      5.8      4 TRUE
```

Possiamo anche creare una variabile categoriale a partire da una variabile numerica:

```
studenti |>
  mutate(
    livello_stress = case_when(
      stress < 20 ~ "basso",
      stress >= 20 & stress < 27 ~ "medio",
      stress >= 27 ~ "alto",
      TRUE ~ NA_character_
    )
  ) |>
  select(id, stress, livello_stress)
```

```
# A tibble: 10 x 3
      id stress livello_stress
  <int> <dbl> <chr>
1     1    18 basso
2     2    25 medio
3     3    21 medio
4     4    30 alto
5     5    16 basso
6     6    28 alto
7     7    24 medio
8     8     NA <NA>
9     9    19 basso
10    10    27 alto
```

In questo esempio, `case_when()` assegna un'etichetta a seconda del valore di `stress`. L'ultima riga, `TRUE ~ NA_character_`, specifica che i casi non classificabili ricevono un valore mancante.

⚠ Controllo

Dopo mutate(), controlla sempre la nuova variabile. Un errore nella definizione di una categoria può alterare l'interpretazione dell'intera analisi.

```
studenti |>
  mutate(
    livello_stress = case_when(
      stress < 20 ~ "basso",
      stress >= 20 & stress < 27 ~ "medio",
      stress >= 27 ~ "alto",
      TRUE ~ NA_character_
    )
  ) |>
  count(livello_stress)
```

```
# A tibble: 4 x 2
  livello_stress      n
  <chr>          <int>
1 alto              3
2 basso             3
3 medio             3
4 <NA>              1
```

9.7. Ordinare righe con arrange()

La funzione arrange() cambia l'ordine delle righe.

```
studenti |>
  arrange(stress)
```

```
# A tibble: 10 x 6
   id genere corso      stress sonno_ore caffeina
  <int> <chr> <chr>    <dbl>    <dbl>    <dbl>
1     5 M     scienze    16     7.5      1
2     1 F     psicologia  18     7.2      1
3     9 M     psicologia  19     NA       1
4     3 M     scienze    21     6.8      2
5     7 M     psicologia  24     6.2      2
6     2 F     psicologia  25     6.1      3
7    10 F     scienze    27     5.8      4
8     6 F     psicologia  28     5.9      3
9     4 F     psicologia  30     5.4      4
10    8 F     scienze    NA     6.7      2
```

Per ordinare in modo decrescente si usa desc():

9. Trasformare i dati con dplyr

```
studenti |>
  arrange(desc(stress))
```

```
# A tibble: 10 x 6
      id genere corso      stress sonno_ore caffeina
  <int> <chr>  <chr>    <dbl>    <dbl>    <dbl>
1     4 F      psicologia 30      5.4      4
2     6 F      psicologia 28      5.9      3
3    10 F      scienze 27      5.8      4
4     2 F      psicologia 25      6.1      3
5     7 M      psicologia 24      6.2      2
6     3 M      scienze 21      6.8      2
7     9 M      psicologia 19      NA       1
8     1 F      psicologia 18      7.2      1
9     5 M      scienze 16      7.5      1
10    8 F      scienze  NA      6.7      2
```

Questa operazione è utile per ispezionare i valori estremi, gli errori di inserimento e i casi che meritano attenzione.

9.8. Riassumere dati con summarise()

La funzione summarise() riduce una tabella a una o più statistiche descrittive.

```
studenti |>
  summarise(
    n = n(),
    stress_medio = mean(stress, na.rm = TRUE),
    sonno_medio = mean(sonno_ore, na.rm = TRUE)
  )
```

```
# A tibble: 1 x 3
      n stress_medio sonno_medio
  <int>    <dbl>    <dbl>
1    10      23.1      6.4
```

L'argomento `na.rm = TRUE` dice a R di ignorare i valori mancanti nel calcolo della media. Ciò non significa che i valori mancanti siano irrilevanti, ma solo che non bloccano il calcolo.

! Non nascondere i mancanti

Quando si utilizza `na.rm = TRUE` è necessario anche verificare quanti valori mancanti sono presenti. Una media calcolata su pochi casi può non essere molto significativa.

```
studenti |>
  summarise(
    n_totale = n(),
    n_stress_mancante = sum(is.na(stress)),
    n_sonno_mancante = sum(is.na(sonno_ore))
  )
```

```
# A tibble: 1 x 3
  n_totale n_stress_mancante n_sonno_mancante
  <int>         <int>         <int>
1      10             1             1
```

9.9. Calcolare sintesi per gruppi con `group_by()`

La funzione `group_by()` da sola non produce una tabella finale interessante. Serve a indicare a R che le operazioni successive devono essere eseguite separatamente per ciascun gruppo.

```
studenti |>
  group_by(genere) |>
  summarise(
    n = n(),
    stress_medio = mean(stress, na.rm = TRUE),
    sonno_medio = mean(sonno_ore, na.rm = TRUE),
    .groups = "drop"
  )
```

```
# A tibble: 2 x 4
  genere      n stress_medio sonno_medio
  <chr> <int>         <dbl>         <dbl>
1 F         6      25.6         6.18
2 M         4      20         6.83
```

Questa pipeline può essere letta nel modo seguente:

- 1) parti dalla tabella `studenti`;
- 2) separa le righe in base al genere;
- 3) per ciascun gruppo, calcola il numero di casi, lo stress medio e il sonno medio;
- 4) restituisci una tabella non più raggruppata.

La riga `.groups = "drop"` evita che il risultato mantenga informazioni di raggruppamento non necessarie. Per analisi semplici non è sempre indispensabile, ma rende il risultato più esplicito.

9.10. Contare casi con `count()`

Una delle operazioni più utili in EDA è contare quanti casi appartengono a ciascuna categoria.

9. Trasformare i dati con dplyr

```
studenti |>
  count(corso)
```

```
# A tibble: 2 x 2
  corso      n
  <chr>    <int>
1 psicologia 6
2 scienze   4
```

Possiamo contare anche combinazioni di variabili:

```
studenti |>
  count(corso, genere)
```

```
# A tibble: 4 x 3
  corso      genere      n
  <chr>    <chr>  <int>
1 psicologia F         4
2 psicologia M         2
3 scienze  F         2
4 scienze  M         2
```

Questi controlli sono semplici, ma spesso rivelano problemi importanti: categorie scritte in modo incoerente, gruppi troppo piccoli o valori inattesi.

9.11. Una pipeline completa

Consideriamo una domanda semplice:

Tra gli studenti con dati completi su stress e sonno, qual è la media delle ore di sonno in base al livello di stress?

Possiamo costruire una pipeline in più passaggi:

```
sonno_per_stress <- studenti |>
  filter(!is.na(stress), !is.na(sonno_ore)) |>
  mutate(
    livello_stress = case_when(
      stress < 20 ~ "basso",
      stress >= 20 & stress < 27 ~ "medio",
      stress >= 27 ~ "alto"
    )
  ) |>
  group_by(livello_stress) |>
  summarise(
    n = n(),
    sonno_medio = mean(sonno_ore),
    sonno_sd = sd(sonno_ore),
```

```

    .groups = "drop"
  ) |>
  arrange(desc(sonno_medio))

sonno_per_stress

```

```

# A tibble: 3 x 4
  livello_stress      n sonno_medio sonno_sd
  <chr>          <int>      <dbl>    <dbl>
1 basso           2        7.35     0.212
2 medio           3        6.37     0.379
3 alto            3        5.7      0.265

```

Questa pipeline non è solo codice. Si tratta di una sequenza di decisioni:

- escludiamo i casi con dati mancanti relativi a stress o sonno;
- trasformiamo lo stress in tre categorie;
- calcolare la media e la deviazione standard del sonno per ciascuna categoria;
- ordiniamo i risultati.

Ogni decisione dovrebbe poter essere giustificata.

Checklist dopo una pipeline

Dopo una trasformazione importante, controlla sempre:

1. quante righe sono rimaste;
2. quali colonne sono presenti;
3. se sono comparsi nuovi valori mancanti;
4. se le categorie hanno una numerosità plausibile;
5. se il risultato risponde davvero alla domanda iniziale.

```

studenti |>
  filter(!is.na(stress), !is.na(sonno_ore)) |>
  summarise(n_righe = n())

```

```

# A tibble: 1 x 1
  n_righe
  <int>
1       8

```

9.12. Usare l'AI con criterio

L'AI può essere molto utile per scrivere codice dplyr. Per esempio, puoi chiedere:

Scrivi una pipeline dplyr che elimini i casi con valori mancanti per stress e sonno, crei tre livelli di stress e calcoli la media del sonno per ciascun livello.

Questo è un uso legittimo dell'AI. Ma il controllo resta tuo.

9.12.1. Cosa puoi chiedere all'AI

- Generare una prima bozza della pipeline;
- spiegare una riga di codice;
- correggere un errore sintattico;
- suggerire una funzione adatta;
- trasformare un codice lungo in uno più leggibile.

9.12.2. Cosa devi controllare tu

- Che le variabili esistano davvero nel dataset;
- che i nomi delle colonne siano corretti;
- che i filtri non eliminino casi in modo non intenzionale;
- che i valori mancanti siano trattati esplicitamente;
- che le nuove variabili abbiano il significato psicologico desiderato;
- che le statistiche calcolate siano appropriate per la domanda.

Errore frequente

Un codice può essere sintatticamente corretto, ma concettualmente errato. Per esempio, una pipeline può calcolare la media di una variabile ordinale trattandola come se fosse a intervalli o può escludere tutti i casi con dati mancanti senza dichiararlo.

9.13. Leggere codice generato dall'AI

Supponiamo che l'AI produca questo codice:

```
studenti |>
  filter(stress > 20 & sonno_ore > 6) |>
  group_by(corso) |>
  summarise(media_stress = mean(stress))
```

```
# A tibble: 2 x 2
  corso      media_stress
  <chr>      <dbl>
1 psicologia 24.5
2 scienze   21
```

Il codice funziona, ma prima di usarlo dobbiamo capirlo.

Domande da porsi:

- Perché vengono mantenuti solo studenti con `stress > 20` e `sonno_ore > 6`?
- Questa selezione risponde alla domanda di ricerca?
- Che cosa succede ai valori mancanti?
- La media dello stress per corso è la sintesi che volevamo?
- È necessario aggiungere `na.rm = TRUE`?

Una versione più esplicita potrebbe essere:

```
studenti |>
  filter(!is.na(stress), !is.na(sonno_ore)) |>
  group_by(corso) |>
  summarise(
    n = n(),
    media_stress = mean(stress),
    media_sonno = mean(sonno_ore),
    .groups = "drop"
  )
```

```
# A tibble: 2 x 4
  corso          n media_stress media_sonno
  <chr>      <int>      <dbl>      <dbl>
1 psicologia     5         25         6.16
2 scienze       3        21.3         6.7
```

Questa seconda versione chiarisce quali casi sono inclusi e quali statistiche vengono calcolate.

9.14. Funzioni utili da conoscere

Oltre ai verbi principali, alcune funzioni tornano spesso:

Funzione	Uso tipico
<code>n()</code>	conta le righe in un gruppo
<code>is.na()</code>	identifica valori mancanti
<code>sum(is.na(x))</code>	conta i valori mancanti di x
<code>mean(x, na.rm = TRUE)</code>	calcola la media ignorando i mancanti
<code>sd(x, na.rm = TRUE)</code>	calcola la deviazione standard ignorando i mancanti
<code>case_when()</code>	crea categorie a partire da condizioni
<code>if_else()</code>	crea una variabile con due condizioni
<code>desc()</code>	ordina in senso decrescente
<code>count()</code>	conta casi per categoria

Non è necessario memorizzarle tutte subito. È però importante riconoscerle quando compaiono nel codice.

9.15. Cosa portare al capitolo successivo

Da questo capitolo dovresti ricavare soprattutto tre idee:

1. trasformare i dati significa prendere decisioni;
2. dplyr rende queste decisioni visibili in forma di pipeline;
3. l'AI può aiutare a scrivere codice, ma non può sostituire il controllo sostanziale sull'analisi.

Nel capitolo su ggplot2 useremo la stessa logica: non impareremo tutti i modi possibili per creare grafici, ma la grammatica minima per costruire e valutare visualizzazioni coerenti con le domande dell'EDA.

Esercizi

💡 Esercizio 1: leggere una pipeline

Considera il codice seguente:

```
studenti |>
  filter(!is.na(stress), stress >= 20) |>
  mutate(sonno_basso = sonno_ore < 6) |>
  group_by(sonno_basso) |>
  summarise(
    n = n(),
    stress_medio = mean(stress),
    .groups = "drop"
  )
```

Rispondi:

1. Quali righe vengono escluse?
2. Quale nuova variabile viene creata?
3. Che cosa rappresenta n?
4. Quale domanda empirica potrebbe essere esplorata con questa pipeline?

💡 Esercizio 2: trovare il problema

L'AI ha prodotto questo codice:

```
studenti |>
  filter(stress > 25) |>
  summarise(media_sonno = mean(sonno_ore))
```

Il codice è sintatticamente corretto. Quali controlli dovresti fare prima di fidarti del risultato? Prova a riscrivere la pipeline rendendo esplicito il trattamento dei valori mancanti e il numero di casi usati nel calcolo.

💡 Esercizio 3: modificare una pipeline

Parti da questa pipeline:

```
studenti |>
  group_by(corso) |>
  summarise(media_stress = mean(stress, na.rm = TRUE))
```

Modificala in modo che restituisca, per ciascun corso:

- il numero totale di studenti;

- il numero di valori mancanti in `stress`;
- la media di `stress`;
- la media di `sonno_ore`.

💡 Esercizio 4: prompt e controllo

Scrivi un prompt per chiedere all'AI una pipeline dplyr che:

1. usi la tabella `studenti`;
2. escluda i casi con valori mancanti su `stress` o `sonno_ore`;
3. crei una variabile `stress_alto`, uguale a `TRUE` se `stress >= 27`;
4. calcoli media e deviazione standard di `sonno_ore` separatamente per `stress_alto`.

Poi indica almeno tre controlli che dovresti eseguire sul codice prodotto.

i Informazioni sull'ambiente di sviluppo

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
Platform: aarch64-apple-darwin23
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Rome
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
other attached packages:
```

```
[1] tibble_3.3.1 dplyr_1.2.1
```

```
loaded via a namespace (and not attached):
```

```
[1] digest_0.6.39    utf8_1.2.6      R6_2.6.1        fastmap_1.2.0
[5] tidyselect_1.2.1 xfun_0.60       magrittr_2.0.5   glue_1.8.1
[9] knitr_1.51       pkgconfig_2.0.3 htmltools_0.5.9  rmarkdown_2.31
[13] generics_0.1.4   lifecycle_1.0.5 cli_3.6.6        vctrs_0.7.3
[17] withr_3.0.3      compiler_4.6.1  tools_4.6.1     pillar_1.11.1
[21] evaluate_1.0.5   yaml_2.3.12     otel_0.2.0      rlang_1.3.0
[25] jsonlite_2.0.0
```

Bibliografia

10. Visualizzare i dati con ggplot2

Perché questo capitolo

L'analisi esplorativa dei dati inizia quasi sempre con la creazione di un grafico. Prima di calcolare un modello, stimare un parametro o discutere un effetto, dobbiamo chiederci cosa mostrano i dati osservati.

Un grafico non serve solo a rendere un risultato più gradevole. Permette di osservare la forma delle distribuzioni, confrontare i gruppi, individuare valori anomali, riconoscere le relazioni tra le variabili e verificare che il codice abbia prodotto i risultati attesi.

In questo capitolo useremo ggplot2 in modo essenziale. Non impareremo tutte le opzioni disponibili. L'obiettivo è più semplice: imparare a leggere, modificare e controllare i grafici più comuni nell'analisi esplorativa dei dati (EDA).

Al termine del capitolo dovresti essere in grado di:

- riconoscere la struttura di base di un grafico ggplot2;
- scegliere il grafico più adatto in base al tipo di variabili e alla domanda esplorativa;
- leggere un codice ggplot2 riga per riga;
- verificare che un grafico rappresenti correttamente i dati;
- usare l'AI per generare il codice grafico senza delegare la scelta e l'interpretazione del grafico.
- salvare un grafico in modo riproducibile.

! Idea chiave

L'AI può scrivere il codice ggplot2, ma non può decidere al posto nostro se il grafico è adatto alla domanda, se le variabili sono rappresentate correttamente e se l'interpretazione rispetta i limiti dei dati.

10.1. I dati di esempio

Useremo un piccolo dataset simulato su stress accademico e sonno. L'esempio è lo stesso filo conduttore già usato nei capitoli precedenti: vogliamo capire se, nel nostro campione, livelli più alti di stress sono associati a una peggiore qualità del sonno.

```
library(tidyverse)

studenti <- tibble(
  id = 1:80,
  genere = sample(c("F", "M"), size = 80, replace = TRUE),
  anno = sample(c("primo", "secondo", "terzo"), size = 80, replace = TRUE),
  stress = round(rnorm(80, mean = 24, sd = 6)),
  sonno_ore = round(rnorm(80, mean = 6.5, sd = 1.1), 1),
```

10. Visualizzare i dati con ggplot2

```
qualita_sonno = round(9 - 0.12 * stress + rnorm(80, mean = 0, sd = 1.1), 1)
) |>
mutate(
  stress = pmin(pmax(stress, 8), 40),
  sonno_ore = pmin(pmax(sonno_ore, 3.5), 9.5),
  qualita_sonno = pmin(pmax(qualita_sonno, 1), 10),
  gruppo_stress = if_else(stress >= 25, "stress alto", "stress basso")
)

studenti
```

```
# A tibble: 80 x 7
   id genere anno      stress sonno_ore qualita_sonno gruppo_stress
  <int> <chr> <chr>      <dbl>      <dbl>        <dbl> <chr>
1     1 F    secondo      26        6.9          4.8 stress alto
2     2 F    secondo      30        6.2          6.5 stress alto
3     3 M    terzo       23        8.2          7   stress basso
4     4 M    primo       18        4.7          5   stress basso
5     5 M    primo       23        7.2          7.3 stress basso
6     6 F    secondo      21        6.4          5.3 stress basso
7     7 M    terzo       31        6.7          4.7 stress alto
8     8 M    terzo       32        4.9          5.8 stress alto
9     9 M    terzo       26        7.5          6.2 stress alto
10    10 F    primo       17        4.7          9.5 stress basso
# i 70 more rows
```

Le variabili principali sono:

- stress: punteggio numerico di stress accademico;
- sonno_ore: ore di sonno per notte;
- qualita_sonno: valutazione soggettiva della qualità del sonno da 1 a 10;
- genere, anno, gruppo_stress: variabili categoriali.

Prima di costruire grafici, controlliamo sempre la struttura dei dati:

```
glimpse(studenti)
```

```
Rows: 80
Columns: 7
$ id      <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 1~
$ genere  <chr> "F", "F", "M", "M", "M", "F", "M", "M", "M", "F", "F", "~
$ anno    <chr> "secondo", "secondo", "terzo", "primo", "primo", "second~
$ stress  <dbl> 26, 30, 23, 18, 23, 21, 31, 32, 26, 17, 17, 32, 28, 18, ~
$ sonno_ore <dbl> 6.9, 6.2, 8.2, 4.7, 7.2, 6.4, 6.7, 4.9, 7.5, 4.7, 5.1, 8~
$ qualita_sonno <dbl> 4.8, 6.5, 7.0, 5.0, 7.3, 5.3, 4.7, 5.8, 6.2, 9.5, 6.2, 7~
$ gruppo_stress <chr> "stress alto", "stress alto", "stress basso", "stress ba~
```

10.2. La grammatica minima di ggplot2

Un grafico ggplot2 combina tre elementi:


1. una tabella di dati;
2. una mappatura tra variabili e aspetti visivi del grafico;
3. una geometria, cioè il tipo di elemento grafico da disegnare.

La struttura minima è:

```
ggplot(dati, aes(x = variabile_x, y = variabile_y)) +  
  geom_qualcosa()
```

Per esempio:

```
ggplot(studenti, aes(x = stress, y = qualita_sonno)) +  
  geom_point()
```



Questa istruzione si legge così:

1. usa la tabella `studenti`;
2. metti `stress` sull'asse x;
3. metti `qualita_sonno` sull'asse y;
4. rappresenta ogni osservazione con un punto.

i Il simbolo +

In ggplot2 il simbolo + aggiunge strati al grafico. Non è la pipe |>. Una regola pratica: se stai trasformando una tabella, probabilmente userai |>; se stai costruendo un grafico, userai +.

10.3. Scegliere il grafico in base alla domanda

La scelta del grafico non dovrebbe partire da quello che l'AI propone, ma dalla domanda esplorativa.

Domanda	Variabili coinvolte	Grafico utile
Com'è distribuita una variabile numerica?	una numerica	istogramma
Ci sono valori estremi?	una numerica, eventualmente per gruppi	boxplot
I gruppi differiscono nella distribuzione?	una numerica + una categoriale	boxplot o punti per gruppo
Due variabili numeriche sono associate?	due numeriche	scatterplot
Quanti casi ci sono in ogni categoria?	una categoriale	grafico a barre
Il pattern cambia per sottogruppi?	variabili + gruppo	faceting

💡 Prima domanda

Prima di scrivere codice, formula la domanda in parole. Per esempio: “Voglio vedere se gli studenti con un livello di stress più alto tendono a riportare una qualità del sonno più bassa”. Solo dopo scegli il grafico.

10.4. Una variabile numerica: istogramma

Quando vogliamo osservare la distribuzione di una variabile numerica, un primo grafico utile è l'istogramma.

```
ggplot(studenti, aes(x = stress)) +
  geom_histogram(binwidth = 3) +
  labs(
    x = "Stress accademico",
    y = "Frequenza",
    title = "Distribuzione dello stress accademico"
  )
```





Figura 10.1.: Distribuzione dei punteggi di stress nel campione.

Questo grafico aiuta a porsi le seguenti domande:

- i valori sono concentrati in una zona oppure molto dispersi?
- la distribuzione è simmetrica o asimmetrica?
- ci sono valori inattesi?
- il range dei valori è plausibile rispetto allo strumento di misura?

⚠ Controllo

L'ampiezza degli intervalli (binwidth) modifica l'aspetto dell'istogramma. Se l'AI propone un istogramma, è sempre necessario controllare che la scelta dei bin non nasconda la forma dei dati.

10.5. Una variabile numerica per gruppi: boxplot

Se vogliamo confrontare una variabile numerica tra gruppi, il boxplot offre una sintesi compatta.

```
ggplot(studenti, aes(x = gruppo_stress, y = sonno_ore)) +
  geom_boxplot() +
  labs(
    x = "Gruppo di stress",
    y = "Ore di sonno",
    title = "Ore di sonno nei gruppi di stress"
  )
```




Figura 10.2.: Ore di sonno per gruppo di stress.

Il boxplot mostra:

- la mediana;
- la variabilità centrale dei dati;
- eventuali valori lontani dal resto della distribuzione.

Tuttavia, il boxplot può nascondere il numero effettivo di casi in ogni gruppo. Per i campioni piccoli, può essere utile mostrare anche i punti osservati.

```
ggplot(studenti, aes(x = gruppo_stress, y = sonno_ore)) +  
  geom_boxplot(outlier.shape = NA) +  
  geom_jitter(width = 0.15, alpha = 0.6) +  
  labs(  
    x = "Gruppo di stress",  
    y = "Ore di sonno",  
    title = "Distribuzione delle ore di sonno nei gruppi"  
  )
```




Figura 10.3.: Ore di sonno per gruppo di stress, con osservazioni individuali.

! Non trasformare il grafico in una conclusione

Un boxplot può suggerire una differenza tra gruppi, ma non dimostra da solo un effetto causale. In questa fase stiamo esplorando i dati, non concludendo che lo stress causa meno sonno.

10.6. Due variabili numeriche: scatterplot

Per studiare la relazione tra due variabili numeriche, il grafico più diretto è lo scatterplot.

```
ggplot(studenti, aes(x = stress, y = qualita_sonno)) +
  geom_point() +
  labs(
    x = "Stress accademico",
    y = "Qualita' del sonno",
    title = "Stress e qualità del sonno"
  )
```




Figura 10.4.: Relazione tra stress accademico e qualità del sonno.

Questo grafico permette di osservare:

- la direzione della relazione;
- la forza approssimativa dell'associazione;
- la presenza di casi insoliti;
- eventuali pattern non lineari.

Possiamo aggiungere una linea di tendenza, ma dobbiamo interpretarla con cautela.

```
ggplot(studenti, aes(x = stress, y = qualita_sonno)) +  
  geom_point() +  
  geom_smooth(method = "lm", se = TRUE) +  
  labs(  
    x = "Stress accademico",  
    y = "Qualita' del sonno",  
    title = "Associazione tra stress e qualità del sonno"  
  )
```




Figura 10.5.: Relazione tra stress e qualità del sonno con linea di tendenza.

⚠ Errore comune

Una linea di tendenza non trasforma un'associazione in una spiegazione causale. Se i dati sono di tipo osservazionale, il grafico può suggerire una relazione tra le variabili, ma non stabilisce da solo che una variabile produca l'altra.

10.7. Una variabile categoriale: grafico a barre

Quando la variabile è categoriale, il grafico a barre può mostrare quanti casi appartengono a ciascuna categoria.

```
ggplot(studenti, aes(x = anno)) +
  geom_bar() +
  labs(
    x = "Anno di corso",
    y = "Numero di studenti",
    title = "Composizione del campione per anno"
  )
```




Figura 10.6.: Numero di studenti per anno di corso.

Qui `geom_bar()` conta automaticamente quante righe appartengono a ogni categoria.

Se invece abbiamo già calcolato una sintesi, per esempio una media per gruppo, allora useremo `geom_col()`.

```
medie_sonno <- studenti |>
  group_by(anno) |>
  summarise(
    media_sonno = mean(sonno_ore, na.rm = TRUE),
    .groups = "drop"
  )

medie_sonno
```

```
# A tibble: 3 x 2
  anno   media_sonno
<chr>   <dbl>
1 primo     6.15
2 secondo   6.43
3 terzo     6.75
```

```
ggplot(medie_sonno, aes(x = anno, y = media_sonno)) +
  geom_col() +
  labs(
    x = "Anno di corso",
    y = "Ore di sonno medie",
    title = "Sonno medio per anno di corso"
  )
```




Figura 10.7.: Media delle ore di sonno per anno di corso.

i `geom_bar()` o `geom_col()`?


Usa `geom_bar()` quando vuoi contare le osservazioni presenti nei dati. Usa `geom_col()` quando la tabella contiene già i valori da rappresentare.

10.8. Mappare o impostare un'estetica

Una delle confusioni più comuni in `ggplot2` riguarda la differenza tra mappare una variabile e impostare una proprietà fissa.


```
# Il colore dipende dai dati: ogni gruppo può avere un colore diverso
ggplot(studenti, aes(x = stress, y = qualita_sonno, color = genere)) +
  geom_point()
```

10. Visualizzare i dati con ggplot2



Qui `color = genere` è dentro `aes()`: il colore è collegato a una variabile.

```
# Il colore è fisso: tutti i punti hanno la stessa proprietà'  
ggplot(studenti, aes(x = stress, y = qualita_sonno)) +  
  geom_point(color = "gray40")
```



Qui `color = "gray40"` è fuori da `aes()`: il colore non rappresenta una variabile.

💡 Controllo

Se l'AI produce un grafico con colori, forme o dimensioni diverse, chiediti se quella differenza visiva rappresenta davvero una variabile. Oppure è solo una scelta decorativa?

10.9. Faceting: lo stesso grafico per sottogruppi

Il faceting consente di ripetere lo stesso grafico per livelli diversi di una variabile categoriale. È utile quando si desidera verificare se un determinato modello cambia tra i sottogruppi.

```
ggplot(studenti, aes(x = stress, y = qualita_sonno)) +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE) +
  facet_wrap(~ anno) +
  labs(
    x = "Stress accademico",
    y = "Qualita' del sonno",
    title = "Stress e sonno nei diversi anni di corso"
  )
```




Figura 10.8.: Relazione tra stress e qualità del sonno, separata per anno.

Il faceting è utile, ma può anche frammentare troppo i dati. Se ogni pannello contiene pochi casi, il grafico può suggerire pattern instabili.

10.10. Titoli, assi e legenda

Un grafico deve poter essere letto da una persona che non ha seguito tutti i passaggi della nostra analisi. Per questo motivo, titoli, assi e legenda fanno parte dell'analisi e non sono semplici elementi decorativi.

```
ggplot(studenti, aes(x = stress, y = qualita_sonno, color = genere)) +
  geom_point() +
  labs(
```

```
title = "Stress accademico e qualità del sonno",
subtitle = "Ogni punto rappresenta uno studente",
x = "Punteggio di stress accademico",
y = "Qualita' del sonno percepita (1-10)",
color = "Genere"
)
```




Figura 10.9.: Grafico con etichette esplicite.


Una buona etichetta chiarisce:

- cosa rappresentano gli assi;
- quale unità di misura o scala viene utilizzata;
- cosa rappresentano i colori, le forme o i pannelli;
- quale campione o sottogruppo viene visualizzato.

10.11. Personalizzazione minima

ggplot2 offre molte possibilità di personalizzazione. In questo modulo ne useremo poche. La priorità è la chiarezza, non l'estetica fine a sé stessa.

```
ggplot(studenti, aes(x = stress, y = qualita_sonno)) +
  geom_point() +
  geom_smooth(method = "lm", se = TRUE) +
  labs(
    x = "Stress accademico",
    y = "Qualita' del sonno",
    title = "Associazione tra stress e qualità del sonno"
  ) +
  theme_minimal()
```




`theme_minimal()` rimuove alcuni elementi visivi non necessari. Va bene usarlo, ma non risolve problemi sostanziali: un grafico concettualmente sbagliato resta sbagliato anche se è esteticamente pulito.

10.12. Salvare un grafico

Per salvare un grafico in modo riproducibile è utile assegnarlo a un oggetto e poi usare la funzione `ggsave()`.

```
grafico_stress_sonno <- ggplot(studenti, aes(x = stress, y = qualita_sonno)) +
  geom_point() +
  geom_smooth(method = "lm", se = TRUE) +
  labs(
    x = "Stress accademico",
    y = "Qualità del sonno",
    title = "Stress e qualità del sonno"
  )

grafico_stress_sonno
```



```
ggsave(  
  filename = "output/grafico_stress_sonno.png",  
  plot = grafico_stress_sonno,  
  width = 7,  
  height = 5,  
  dpi = 300  
)
```

Nel codice sopra assumiamo che esista una cartella output/ nel progetto. Se la cartella non esiste, R restituirà un errore.

⚠ Controllo

Non salvare i grafici manualmente con gli screenshot. Usa un codice riproducibile, così il grafico può essere ricreato se i dati o il codice dovessero cambiare.

10.13. Usare l'AI con criterio

L'AI può essere molto utile con ggplot2. Per esempio, si può chiedere:

Scrivi codice R con ggplot2 per visualizzare la relazione tra stress accademico e qualità del sonno, distinguendo gli studenti per anno di corso.

Tuttavia, dopo aver ricevuto il codice, è necessario controllare almeno cinque cose:

1. il dataset usato è quello corretto?
2. le variabili esistono davvero e hanno il tipo corretto?
3. il grafico scelto è coerente con la domanda?
4. il codice elimina o aggrega casi senza dirlo chiaramente?
5. l'interpretazione suggerita dall'AI va oltre ciò che il grafico mostra?

! Mini-verifica

Quando si utilizza un codice grafico prodotto dall'AI, è necessario essere in grado di spiegare in parole semplici ogni riga: quali tabelle vengono utilizzate, quali variabili vengono messe sugli assi, quale geometria viene disegnata e cosa rappresentano eventuali colori o pannelli.

10.14. Errori frequenti

10.14.1. Scambiare una media per una distribuzione

Un grafico a barre delle medie può nascondere la variabilità dei dati. Quando possibile, osserva anche la distribuzione o i punti individuali.

10.14.2. Usare il grafico sbagliato per il tipo di variabile

Uno scatterplot richiede due variabili numeriche. Se una variabile è categoriale, un boxplot o un grafico a barre potrebbe essere più adatto.

10.14.3. Dimenticare i valori mancanti

Se alcune osservazioni mancano, ggplot2 può escluderle dal grafico. Leggi i messaggi di avviso e controlla quanti casi sono stati rappresentati.

10.14.4. Interpretare graficamente la causalità

Un grafico può mostrare un'associazione. La causalità richiede un disegno di ricerca adeguato e assunzioni esplicite.

10.15. Cosa portare ai capitoli EDA

Dopo questo capitolo, non devi conoscere tutte le funzioni di ggplot2. Devi però aver acquisito alcune abitudini:

- scegliere il grafico in base alla domanda e al tipo di variabili;
- leggere il codice grafico come una sequenza di decisioni;
- controllare che ogni elemento visivo rappresenti qualcosa di chiaro;
- distinguere i pattern esplorativi dalle conclusioni inferenziali.
- documentare i grafici in un file Quarto.

Queste abitudini verranno utilizzate nei capitoli successivi per esplorare distribuzioni, posizione, dispersione, correlazioni, relazioni causali e valori anomali.

10.16. Esercizi

10.16.1. Esercizio 1: leggere un grafico

Considera questo codice:

```
ggplot(studenti, aes(x = stress, y = sonno_ore)) +  
  geom_point() +  
  geom_smooth(method = "lm")
```

Rispondi:

1. quale variabile è sull'asse x?
2. quale variabile è sull'asse y?
3. che cosa rappresenta ogni punto?
4. che cosa aggiunge `geom_smooth()`?
5. quale conclusione causale non puoi trarre da questo grafico?

10.16.2. Esercizio 2: scegliere il grafico

Per ciascuna domanda, indica un grafico appropriato:

1. Come sono distribuiti i punteggi di stress?
2. Gli studenti del primo, secondo e terzo anno dormono un numero diverso di ore?
3. La qualità del sonno tende a diminuire quando lo stress aumenta?
4. Quanti studenti appartengono ai diversi anni di corso?

10.16.3. Esercizio 3: diagnosticare un errore

L'AI ha prodotto questo codice:

```
ggplot(studenti, aes(x = genere, y = anno)) +  
  geom_point()
```

Spiega perché questo grafico probabilmente non è molto informativo. Proponi un grafico migliore se la domanda è: “quanti studenti ci sono per genere e anno?”.

10.16.4. Esercizio 4: modificare codice

Parti da questo grafico:

```
ggplot(studenti, aes(x = stress, y = qualita_sonno)) +  
  geom_point()
```

Modificalo in modo da:

1. distinguere i punti per genere;
2. aggiungere una linea di tendenza;
3. aggiungere etichette chiare agli assi.

10.16.5. Esercizio 5: controllo AI

Chiedi a uno strumento di AI di generare un grafico ggplot2 per esplorare la relazione tra stress accademico e sonno. Poi valuta il codice ottenuto usando questa lista:

- usa il dataset corretto?
- usa variabili esistenti?
- il grafico è adatto alla domanda?
- l'interpretazione resta descrittiva?
- il codice può essere inserito in un documento Quarto?

10.17. Punti chiave

- ggplot2 costruisce grafici combinando dati, estetiche e geometrie.
- La scelta del grafico dipende dalla domanda e dal tipo di variabili.
- I grafici servono a esplorare, controllare e comunicare i dati.
- Un grafico non giustifica da solo conclusioni causali o inferenziali forti.
- L'AI può produrre codice, ma lo studente deve saperlo leggere e verificare.

11. Quarto

Introduzione

Quarto è il luogo in cui un'analisi diventa leggibile, controllabile e riproducibile. In un file `.qmd` non scriviamo soltanto codice, ma costruiamo un documento in cui domanda di ricerca, dati, trasformazioni, risultati e interpretazione sono presenti nello stesso spazio.

Questa idea è particolarmente importante oggi. Un assistente basato sull'intelligenza artificiale può generare rapidamente una pipeline `dplyr`, un grafico `ggplot2` o un modello statistico. Questo non rende inutile imparare a lavorare con R e Quarto, anzi, rende ancora più importante saper controllare ciò che il codice fa. Se il codice è generato dall'intelligenza artificiale, lo studente non deve necessariamente averlo scritto tutto a mano, ma deve saper dire:

- quali dati sono stati utilizzati;
- quali trasformazioni sono state applicate;
- quali casi sono stati esclusi;
- quali risultati sono stati ottenuti;
- quale interpretazione è giustificata e quale no.

Nel progetto complessivo di questo modulo, Quarto svolge quindi una funzione ben precisa: collegare la parte operativa dell'analisi con la responsabilità scientifica dell'interpretazione. L'obiettivo non è produrre un documento elegante, ma rendere visibile il percorso che porta dai dati a una conclusione.

Quarto si colloca nella tradizione del *literate programming*: il codice non viene separato dal ragionamento, ma inserito all'interno di una narrazione comprensibile. Per noi, questa idea ha una forma molto concreta:

Un risultato non dovrebbe essere soltanto ottenuto. Dovrebbe poter essere ricostruito, controllato e spiegato.

Questa è anche la ragione per cui Quarto è utile nell'epoca dell'intelligenza artificiale. L'AI può aiutare a scrivere il codice, ma non può assumersi la responsabilità dell'analisi. Quarto è il luogo in cui questa responsabilità diventa evidente.

Per approfondire

Questi materiali non sono prerequisiti obbligatori per seguire il capitolo, ma possono essere utili per chi vuole approfondire.

- *Reproducibility in the Classroom* (Dogucu, 2024).
- Documentazione ufficiale di Quarto: <https://quarto.org/docs/guide>.
- Appendice sulle formule: `?@sec-apx-latex-math`.

 Preparazione del Notebook

```
here::here("code", "_common.R") |> source()
```

 Obiettivi di apprendimento

Al termine di questo capitolo dovresti saper:

1. riconoscere le tre componenti di un file .qmd: intestazione YAML, testo Markdown e chunk di codice;
2. eseguire e controllare un chunk;
3. distinguere tra codice eseguito in Console e codice contenuto nel documento;
4. compilare un documento da una sessione R pulita;
5. inserire figure, tabelle, formule e citazioni essenziali;
6. usare un assistente AI dentro un flusso Quarto senza delegargli il giudizio.

11.1. L'anatomia di un file .qmd

Un documento Quarto ha estensione .qmd e contiene tre elementi principali.

1. **L'intestazione YAML**, delimitata da ---, contiene i metadati del documento: titolo, autore, formato di output, bibliografia.
2. **Il testo in Markdown** contiene la spiegazione: titoli, paragrafi, elenchi, enfasi, collegamenti.
3. **I chunk di codice** contengono il codice R che produce risultati, tabelle o figure.

Un esempio minimo:

```
---
title: "Analisi preliminare"
author: "Nome Cognome"
format: html
---

## Descrizione del campione

Il campione è composto da adulti reclutati online.

```{r}
#| label: descrittive
library(dplyr)
dati <- read.csv("dati/campione.csv")
summary(dati$eta)
```

L'età media è coerente con quanto atteso in un campione universitario.
```

Questo esempio contiene già tutto l'essenziale: un titolo, un breve testo, un chunk che carica e descrive i dati e una frase che interpreta il risultato.

i Editor visivo o editor sorgente?

RStudio offre due modalità. L'**editor visivo** assomiglia a un word processor ed è comodo per scrivere testo, tabelle e citazioni. L'**editor sorgente**, invece, mostra il Markdown grezzo. Quando qualcosa non funziona, l'editor sorgente è spesso più utile, perché mostra tutti i simboli che Quarto deve interpretare.

Una regola pratica: scrivi pure in modalità visuale, ma impara a controllare e correggere in modalità sorgente.

11.2. Il chunk: l'unità minima di controllo

Il chunk è il punto in cui il codice produce un risultato all'interno del documento. In Quarto, le opzioni del chunk si scrivono all'inizio con il prefisso `#|`.

```
```{r}
#| label: fig-eta
#| fig-cap: "Distribuzione dell'età nel campione."
#| echo: true
#| warning: false
ggplot(dati, aes(x = eta)) +
 geom_histogram(bins = 20)
```
```

Le opzioni più importanti sono poche.

| Opzione | Effetto | Quando usarla |
|--------------------------------|---|--|
| label | dà un nome al chunk | sempre: aiuta nei riferimenti e negli errori |
| echo: false | nasconde il codice, mostra il risultato | quando il lettore non ha bisogno di vedere il codice |
| eval: false | mostra il codice, ma non lo esegue | per esempi illustrativi |
| include: false | esegue il codice, ma non mostra nulla | per setup e caricamento pacchetti |
| warning: false, message: false | nasconde avvisi o messaggi | solo dopo averli letti e compresi |
| fig-cap, fig-width, fig-asp | controllano le figure | quando una figura entra nel report |

Un punto importante: `warning: false` non risolve un problema. Nasconde soltanto il messaggio. È possibile nascondere un avviso nel report finale, ma solo dopo aver compreso il suo significato.

! La regola d'oro

Se non sai spiegare a cosa serve un chunk, quel chunk non entra nel documento. Questo vale sia per il codice scritto da te, sia per quello copiato da un tutorial, sia per quello suggerito da un assistente AI.

11.3. Il flusso di lavoro riproducibile

Il valore di Quarto non sta nella sintassi in sé, ma nella disciplina che impone. Per iniziare, sono sufficienti quattro regole.

1. Un progetto, non file sparsi. Lavora dentro un *RStudio Project* (.Rproj) con una struttura semplice:

```
progetto/
  progetto.Rproj
  data/          # dati grezzi, mai modificati
  code/          # script e funzioni
  report.qmd
```

2. Percorsi relativi, non percorsi assoluti. Un percorso come `read.csv("/Users/corrado/Desktop/dati.csv")` funziona solo su un computer specifico. In un progetto riproducibile è meglio usare percorsi relativi alla cartella del progetto:

```
```{r}
#| eval: false
dati <- read.csv(here::here("data", "campione.csv"))
```
```

3. Il documento deve contenere tutto ciò che serve. Un errore frequente è creare un oggetto nella Console e poi usarlo in un chunk. Quando Quarto compila il documento, però, parte da una sessione R nuova: ciò che esiste solo nella Console non esiste per il documento.

4. Il test finale è il render da zero. In RStudio: *Session* → *Restart R*, poi *Render*. Se il documento compila, l'analisi è ricostruibile. Se funziona solo dopo aver eseguito manualmente alcuni comandi nella Console, non è ancora riproducibile.

Il punto centrale

Un'analisi non riproducibile è difficile da verificare. Ciò non significa, però, che un'analisi riproducibile sia automaticamente corretta: un errore può essere riprodotto perfettamente. Significa però che, se il percorso è esplicito, l'errore può essere individuato, discusso e corretto.

11.4. Figure, tabelle, formule, citazioni

Un report scientifico non contiene solo output. Deve anche consentire al lettore di ritrovare figure, tabelle, formule e fonti.

Figure e tabelle. Si etichettano e si richiamano nel testo. L'etichetta di una figura deve iniziare con `fig-`, quella di una tabella con `tbl-`.

```
```{r}
#| label: tbl-mtcars
#| tbl-cap: "Prime righe del dataset."
knitr::kable(head(mtcars))
```
```

11. Quarto

Come mostrato nella @tbl-mtcars, ...

Il risultato:

```
knitr::kable(head(mtcars))
```

Tabella 11.1.: Prime righe del dataset mtcars.

| | mpg | cyl | displacement | horsepower | drat | weight | qsec | vs | am | gear | carb |
|-------------------|------|-----|--------------|------------|------|--------|------|----|----|------|------|
| Mazda RX4 | 21.0 | 6 | 160 | 110 | 3.90 | 2.62 | 16.5 | 0 | 1 | 4 | 4 |
| Mazda RX4 Wag | 21.0 | 6 | 160 | 110 | 3.90 | 2.88 | 17.0 | 0 | 1 | 4 | 4 |
| Datsun 710 | 22.8 | 4 | 108 | 93 | 3.85 | 2.32 | 18.6 | 1 | 1 | 4 | 1 |
| Hornet 4 Drive | 21.4 | 6 | 258 | 110 | 3.08 | 3.21 | 19.4 | 1 | 0 | 3 | 1 |
| Hornet Sportabout | 18.7 | 8 | 360 | 175 | 3.15 | 3.44 | 17.0 | 0 | 0 | 3 | 2 |
| Valiant | 18.1 | 6 | 225 | 105 | 2.76 | 3.46 | 20.2 | 1 | 0 | 3 | 1 |

Formule. Le formule si scrivono in LaTeX, in linea ($\bar{x}$) o in display ($\dots$). I dettagli sono nell'@sec-apx-latex-math.

Citazioni. Servono due cose: un file .bib con i riferimenti e una riga nello YAML.

```
bibliography: references.bib
csl: apa.csl
```

Nel testo, @ceccarini2024age produce una citazione narrativa, come in Ceccarini et al. (2024). La forma [ceccarini2024age] produce invece una citazione fra parentesi (Ceccarini et al., 2024). La bibliografia finale viene generata automaticamente e contiene solo i lavori effettivamente citati.

i Approfondimenti tecnici

Questi aspetti sono utili, ma non sono necessari per iniziare.

- **Caching:** l'opzione cache: true salva i risultati di un chunk lento e li riutilizza se il codice non cambia. È utile per le analisi lunghe, ma può diventare pericoloso se non si capisce quando la cache è obsoleta. In caso di dubbio, cancellare la cartella _cache e ricompilare.
- **Stili bibliografici:** i file .csl si possono scaricare dallo [Zotero Style Repository](#).
- **Formati di output:** Quarto può produrre HTML, PDF, Word e slide. La documentazione è qui: <https://quarto.org/docs/output-formats>.

11.5. Quarto e l'AI: usare aiuto senza perdere controllo

In questo corso, l'uso dell'AI non è vietato. Fa parte del modo contemporaneo di lavorare con il codice. Tuttavia, l'uso dell'AI non esime dalla responsabilità dell'analisi. Significa spostare una parte del lavoro dalla produzione del codice alla verifica del codice.

È utile perché lascia una traccia di questa verifica. Un codice incollato nella Console può funzionare, ma poi sparisce. Un codice inserito in un chunk resta nel documento, può essere riletto, commentato, corretto e rieseguito.

11.5.1. Un protocollo di lavoro in quattro passi

1. **Formula il problema, non solo il comando.** Non chiedere soltanto “Scrivimi il codice”. Specifica il data frame, le variabili, il tipo di variabili, il risultato desiderato e i criteri di esclusione.
2. **Incolla il codice in un chunk, non nella Console.** Il chunk lascia traccia; la Console no.
3. **Verifica prima di accettare.** Usa la checklist qui sotto.
4. **Documenta.** Sotto il chunk scrivi una frase che spieghi cosa è stato fatto e perché.

11.5.2. La checklist di verifica

Prima di utilizzare un chunk generato con l'AI, chiediti:

1. Il codice fa davvero ciò che ho chiesto?
2. Usa le variabili corrette?
3. Sta eliminando casi senza che me ne accorga (`filter()`, `drop_na()`, `na.omit()`, join che perdono righe)?
4. Come tratta i valori mancanti? La scelta di impostare `na.rm = TRUE` non è un dettaglio tecnico.
5. Il grafico o la tabella sono coerenti con il tipo di variabile?
6. L'interpretazione è statisticamente e psicologicamente sensata?
7. Il documento è stato compilato da una sessione R pulita?

Un controllo semplice consiste nel stampare il numero di righe prima e dopo ogni trasformazione.

```
```{r}
#| eval: false
nrow(dati)
dati_puliti <- dati |> filter(!is.na(rt), rt < 3000)
nrow(dati_puliti)
```
```

Se il campione si riduce da 240 a 97 osservazioni, bisogna saperlo prima di interpretare i risultati.

Trasparenza sull'uso dell'AI

Quando si utilizzano strumenti AI in un report, una breve nota finale può essere sufficiente: indicare lo strumento utilizzato, le parti del report in cui è stato impiegato e come sono stati verificati i risultati. Non si tratta di un'ammissione di colpa, ma di una pratica di trasparenza simile alla dichiarazione del software statistico utilizzato.

11.6. Errori di compilazione: una diagnosi rapida

| Sintomo | Causa probabile |
|--|---|
| object 'dati' not found in fase di render,
ma funziona in Console | l'oggetto è stato creato in Console, non nel documento |
| cannot open file ... | percorso assoluto o cartella sbagliata: controlla <code>here::here()</code> |

| Sintomo | Causa probabile |
|---|--|
| there is no package called ... | il pacchetto non è installato |
| il documento mostra codice vecchio o risultati incoerenti | cache obsoleta: cancella <code>_cache</code> e <code>_files</code> , poi ricompila |
| errore in un chunk e non sai quale | assegna un <code>label</code> a ogni chunk |
| il chunk non viene eseguito | manca <code>{r}</code> dopo i backtick, oppure il chunk non è chiuso |

Riflessioni conclusive

Per iniziare con Quarto, è sufficiente una struttura YAML, un testo Markdown, alcuni chunk di codice, alcune opzioni essenziali e una regola di metodo: compilare da una sessione pulita. Questo poco, però, cambia il significato del lavoro prodotto.

Un risultato copiato dalla Console in un documento Word è solo un'affermazione. Lo stesso risultato all'interno di un documento Quarto che viene compilato da zero è un'affermazione accompagnata dal percorso che ha portato alla sua produzione. Ciò non garantisce che l'analisi sia corretta, ma la rende ispezionabile.

Questa distinzione diventa ancora più importante quando parte del codice è stata scritta con l'aiuto dell'AI. Lo strumento può proporre del codice, ma la responsabilità di comprenderlo, verificarlo e interpretarlo rimane dello studente. Quarto è il luogo in cui questa responsabilità si esercita.

Per approfondire, la documentazione ufficiale (<https://quarto.org>) è la fonte più aggiornata e completa. Sulla scrittura scientifica, Wickham et al. (2023) consigliano *Style: Lessons in Clarity and Grace* di Williams & Bizup e *The Sense of Structure* di George Gopen.

Esercizi

Esercizio 1 – Il documento minimo. Crea un progetto RStudio con una cartella `data/` e un file `report.qmd`. Il documento deve caricare un data frame, produrre una tabella descrittiva etichettata (`tbl-`), produrre un grafico etichettato (`fig-`) e richiamarli entrambi nel testo con `@tbl-...` e `@fig-...`. Verifica che compili dopo *Session* → *Restart R*.

Esercizio 2 – Il documento sabotato. Prendi il documento dell'Esercizio 1 e introduci, uno alla volta, questi tre errori. Per ciascuno: prevedi il messaggio di errore, poi verifica.

- sostituisci `here::here("data", "file.csv")` con un percorso assoluto;
- crea un oggetto in Console e usalo in un chunk senza definirlo nel documento;
- rimuovi `{r}` dall'intestazione di un chunk.

Esercizio 3 – Audit di codice AI. Chiedi a un assistente AI: “Scrivi il codice R per calcolare il tempo di reazione medio per gruppo sperimentale”. Incolla la risposta in un chunk e rispondi per iscritto alla checklist. In particolare: quante righe entrano nell'analisi? Come vengono trattati gli NA? Il codice fa un'assunzione che tu non avevi dichiarato?

Esercizio 4 – Il prompt migliore. Riscrivi la richiesta dell'Esercizio 3 specificando nomi e tipi delle variabili, criterio di esclusione dei trial e trattamento dei valori mancanti. Confronta il codice ottenuto con quello precedente. Che cosa è cambiato? Che cosa resta comunque responsabilità tua?

Esercizio 5 – Concettuale. In due paragrafi: perché un'analisi riproducibile non è automaticamente un'analisi corretta? E perché un'analisi non riproducibile non può essere verificata come corretta?

 Soluzioni (parziali)**Esercizio 2.**

- a. Error: cannot open file '/Users/.../file.csv': No such file or directory sulla macchina di chiunque altro, e sulla tua se sposti la cartella. Il percorso assoluto lega il documento a un computer specifico.
- b. Error: object 'x' not found. Il render avviene in una sessione R nuova: ciò che sta nel *Global Environment* non esiste per il documento.
- c. Il blocco viene trattato come testo preformattato: il codice appare nel documento ma non viene eseguito. Non sempre compare un errore, ed è proprio questo che lo rende insidioso.

Esercizio 3. Gli aspetti da controllare quasi sempre sono questi: (i) `mean(rt)` restituisce NA se esiste anche un solo valore mancante, a meno di `na.rm = TRUE`; (ii) `group_by()` su una variabile codificata come numerica anziché come `factor` produce raggruppamenti corretti ma etichette poco informative; (iii) un eventuale `filter()` sui tempi di reazione implica un criterio di esclusione che va giustificato.

Esercizio 5. Riproducibilità e validità sono diverse. Un errore di codifica riprodotto fedelmente resta un errore: la riproducibilità garantisce che i passaggi siano ispezionabili, non che siano giusti. Il punto è che senza ispezionabilità la correttezza non è nemmeno una domanda a cui si possa rispondere: si può solo credere al risultato sulla fiducia.

i Informazioni sull'ambiente di sviluppo


```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2        ggdist_3.3.3
#> [7] tidybayes_3.0.7      bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0       posterior_1.7.0
#> [13] loo_2.10.0           rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0          Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0     janitor_2.2.1          matrixStats_1.5.0
#> [22] modelr_0.1.11        tibble_3.3.1           dplyr_1.2.1
#> [25] tidyr_1.3.2          rio_1.3.0              here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8          tidyselect_1.2.1       farver_2.1.2
#> [4] S7_0.2.2              fastmap_1.2.0          tensorA_0.36.2.1
#> [7] digest_0.6.39         timechange_0.4.0       estimability_2.0.0
#> [10] lifecycle_1.0.5       magrittr_2.0.5         compiler_4.6.1
#> [13] rlang_1.3.0           tools_4.6.1            yaml_2.3.12
#> [16] knitr_1.51            bridgesampling_1.2-1    pkgbuild_1.4.8
#> [19] curl_7.1.0            RColorBrewer_1.1-3     abind_1.4-8
#> [22] purrr_1.2.2           grid_4.6.1             stats4_4.6.1
#> [25] xtable_1.8-8          inline_0.3.21          emmeans_2.0.3
#> [28] scales_1.4.0          cli_3.6.6              mvtnorm_1.4-1
#> [31] rmarkdown_2.31        generics_0.1.4         otel_0.2.0
#> [34] RcppParallel_5.1.11-2 cachem_1.1.0           stringr_1.6.0
#> [37] parallel_4.6.1        vctrs_0.7.3            V8_8.2.0
#> [40] Matrix_1.7-5          jsonlite_2.0.0         arrayhelpers_1.1-1
#> [43] glue_1.8.1            codetools_0.2-20       distributional_0.8.1
#> [46] lubridate_1.9.5       stringi_1.8.7          gtable_0.3.6
#> [49] QuickJSR_1.10.0       pillar_1.11.1          htmltools_0.5.9
#> [52] Brodingtonag_1.2-9    R6_2.6.1               textshaping_1.0.5
#> [55] rprojroot_2.1.1       evaluate_1.0.5         lattice_0.22-9
#> [58] backports_1.5.1       memoise_2.0.1          broom_1.0.13
#> [61] snakecase_0.11.1      rstantools_2.6.0       coda_0.19-4.1
#> [64] gridExtra_2.3.1      nlme_3.1-169           checkmate_2.3.4
#> [67] xfun_0.60             pkgconfig_2.0.3

```

Bibliografia

12. Pacchetti

Introduzione

In R, molte analisi non si effettuano utilizzando esclusivamente le funzioni già disponibili al momento dell'installazione. Si utilizzano anche i pacchetti, ovvero raccolte di funzioni, dati e documentazione preparate da altri utenti o gruppi di ricerca.

Per uno studente che inizia a lavorare con R, i pacchetti non sono un argomento secondario dal punto di vista tecnico. I pacchetti fanno parte del modo in cui un'analisi diventa comprensibile e riproducibile. Quando leggiamo un codice, dobbiamo sapere non solo cosa fa, ma anche da quale pacchetto provengono le funzioni che usa.

Questo è ancora più importante quando il codice viene suggerito da un sistema di IA. L'AI può suggerire funzioni corrette, ma può anche:

- usare pacchetti non installati;
- mescolare funzioni provenienti da pacchetti diversi.
- usare funzioni che hanno lo stesso nome, ma significati diversi;
- suggerire soluzioni più complicate del necessario;
- dimenticare di caricare il pacchetto richiesto.

In questo capitolo non faremo un catalogo dei pacchetti R, ma impareremo solo ciò che serve per lavorare in modo ordinato: **installare**, **caricare**, **riconoscere** e **documentare** i pacchetti usati in un'analisi.

12.1. Cosa imparerai

Alla fine del capitolo dovresti essere in grado di:

- distinguere tra installare e caricare un pacchetto;
- capire da quale pacchetto proviene una funzione;
- interpretare errori comuni legati ai pacchetti;
- usare la forma `pacchetto::funzione()` quando rende il codice più chiaro;
- controllare il codice prodotto con AI prima di usarlo in un report Quarto.

12.2. Che cos'è un pacchetto R

Un pacchetto R è un'estensione di R. In genere contiene:

- **funzioni**, cioè comandi già pronti per svolgere operazioni specifiche;
- **dataset**, spesso usati come esempi;
- **documentazione**, che spiega come usare le funzioni;
- talvolta **vignette**, cioè guide pratiche più estese.

Per esempio, nel percorso di questo modulo useremo spesso pacchetti come:

- `dplyr`, per trasformare e riassumere dati;
- `ggplot2`, per costruire grafici;
- `readr` o `rio`, per importare dati;
- `tibble`, per lavorare con tabelle ordinate;
- `quarto`, non come pacchetto principale di analisi, ma come ambiente per collegare testo, codice e risultati.

Non è necessario conoscere molti pacchetti. È più importante conoscere bene pochi strumenti e saperli usare in modo appropriato.

Idea chiave

Un pacchetto non è una magia esterna a R, ma codice scritto da qualcuno e distribuito in modo che altri possano utilizzarlo. Usare un pacchetto significa quindi affidarsi a uno strumento e per questo motivo è importante sapere quale strumento si sta utilizzando.

12.3. Installare e caricare: due operazioni diverse

Un errore molto comune è confondere **installare** e **caricare** un pacchetto.

| Operazione | Quando si fa | Cosa significa |
|---------------------------------|---|--|
| <code>install.packages()</code> | Di solito una sola volta | Scarica e installa il pacchetto sul computer |
| <code>library()</code> | Ogni volta che inizi una nuova sessione di lavoro | Rende disponibili le funzioni del pacchetto |

Per installare un pacchetto si usa:

```
install.packages("dplyr")
```

Le virgolette sono necessarie perché `"dplyr"` è il nome del pacchetto da scaricare.

Dopo averlo installato, per usarlo in una sessione di lavoro si scrive:

```
library(dplyr)
```

In questo caso le virgolette non sono necessarie.

Da ricordare

Installare un pacchetto non basta. Dopo l'installazione, il pacchetto deve essere caricato con `library()` ogni volta che apri una nuova sessione di R o renderizzi un documento Quarto.

12.4. Dove mettere `library()` in un documento Quarto

In un report Quarto è buona pratica caricare i pacchetti all'inizio del documento, in un chunk dedicato. In questo modo il lettore capisce subito da quali strumenti dipende l'analisi.

Per esempio:

```
library(dplyr)
library(ggplot2)
library(readr)
```

Le opzioni `message: false` e `warning: false` evitano che il documento mostri messaggi tecnici non necessari. Tuttavia, durante il lavoro è utile leggere quei messaggi almeno una volta: a volte contengono indicazioni importanti.

12.5. Usare una funzione senza caricare tutto il pacchetto

A volte, però, vogliamo usare una sola funzione di un pacchetto. In questi casi, è possibile scrivere il nome del pacchetto, due punti doppi e poi il nome della funzione.

```
readr::read_csv("data/questionario.csv")
```

La forma generale è:

```
pacchetto::funzione(argomenti)
```

Questa forma è utile perché rende esplicita l'origine della funzione. Per esempio, se scriviamo:

```
dplyr::filter(dati, gruppo == "sperimentale")
```

chi legge il codice capisce subito che `filter()` viene dal pacchetto `dplyr`.

Questo può essere importante perché pacchetti diversi possono contenere funzioni con lo stesso nome. Se R trova due funzioni con lo stesso nome, userà quella caricata più di recente. La forma `pacchetto::funzione()` elimina l'ambiguità.

Una buona abitudine

Quando il codice è breve e ha uno scopo didattico, è sufficiente scrivere `library(dplyr)` e poi `filter()`. Quando si vuole evitare ambiguità o si usa una funzione rara, `dplyr::filter()` rende il codice più trasparente.

12.6. Errori comuni

Gli errori legati ai pacchetti sono frequenti, soprattutto all'inizio. Alcuni messaggi possono rivelarsi più utili di quanto sembrano.

12.6.1. Il pacchetto non è installato

Se scrivi:

```
library(dplyr)
```

e R risponde con un errore simile a:

```
there is no package called 'dplyr'
```

significa che il pacchetto non è installato sul computer. La soluzione è:

```
install.packages("dplyr")
```

Poi puoi caricarlo:

```
library(dplyr)
```

12.6.2. Il pacchetto è installato ma non caricato

Se scrivi:

```
filter(dati, stress > 3)
```

e R dice che non trova la funzione, può essere che il pacchetto non sia stato caricato. In questo caso devi aggiungere:

```
library(dplyr)
```

oppure usare la forma esplicita:

```
dplyr::filter(dati, stress > 3)
```

12.6.3. Una funzione ha lo stesso nome in pacchetti diversi

A volte R segnala che una funzione è stata “mascherata” da un altro pacchetto. Ciò accade quando due pacchetti contengono funzioni con lo stesso nome.

Non è necessariamente un problema. Tuttavia, è un segnale: devi sapere quale funzione stai utilizzando. In caso di dubbio, usa `pacchetto::funzione()`.

12.7. Pacchetti e AI

L'AI può essere molto utile quando si lavora con i pacchetti. Può suggerire il pacchetto da utilizzare, spiegare un errore, riscrivere una pipeline o proporre un'alternativa più semplice.

Tuttavia, non devi accettare il codice senza prima controllarlo.

 Usare l'AI con criterio

Quando l'AI propone il codice R, controlla sempre:

1. i pacchetti richiesti sono indicati chiaramente?
2. sono già installati e caricati?
3. le funzioni esistono davvero?
4. il codice usa pacchetti coerenti con il resto del progetto?
5. esiste una soluzione più semplice che utilizzi gli strumenti che già conosci?

Un buon prompt non si limita a chiedere: “scrivi il codice”. Chiede un codice leggibile, coerente con gli strumenti che conosci e facile da controllare.

Per esempio:

Scrivi codice R usando dplyr e ggplot2, senza introdurre pacchetti aggiuntivi se non sono necessari. Commenta brevemente ogni passaggio.

Oppure:

Questo codice usa pacchetti che non conosco. Puoi riscriverlo usando solo dplyr, ggplot2 e readr?

Questi prompt aiutano a evitare codice inutilmente complesso.

12.8. Pacchetti e riproducibilità

Un'analisi è riproducibile se un'altra persona può eseguirla e ottenere gli stessi risultati. I pacchetti fanno parte di questa riproducibilità.

Per chiarire quali fattori influenzano un'analisi, è utile:

- caricare i pacchetti all'inizio del documento;
- evitare pacchetti non necessari;
- usare `pacchetto::funzione()` quando c'è ambiguità;
- indicare nel testo quali strumenti principali sono stati utilizzati;
- non consegnare un documento che funziona solo perché alcuni pacchetti sono caricati “per caso” nella propria sessione.

Alla fine di un'analisi più complessa può essere utile registrare le informazioni sulla sessione di lavoro:

```
sessionInfo()
```

Questa funzione mostra la versione di R e dei pacchetti caricati. Non è sempre necessario includerla in un report didattico breve, ma è utile sapere che esiste.

12.9. Una struttura minima per i tuoi report

Nei lavori di questo modulo, puoi usare una struttura semplice:

```
library(dplyr)
library(ggplot2)
library(readr)
```

Poi, quando usi una funzione meno comune, puoi rendere esplicito il pacchetto:

```
readr::read_csv("data/questionario.csv")
```

Questa combinazione è spesso sufficiente: pochi pacchetti caricati all'inizio e uso esplicito di `pacchetto::funzione()` quando serve chiarezza.

12.10. Checklist

Prima di consegnare un file Quarto, chiediti:

- il documento parte da una sessione pulita?
- tutti i pacchetti necessari sono caricati nel chunk iniziale?
- ci sono pacchetti installati ma mai usati?
- il codice introduce pacchetti non spiegati?
- il documento si renderizza senza errori?
- sono in grado di spiegare perché sto usando quei pacchetti?

Se la risposta a una di queste domande è negativa, il problema non è soltanto tecnico. Si tratta di un problema di trasparenza dell'analisi.

12.11. Esercizi

1. In un documento Quarto trovi questo codice:

```
library(dplyr)
dati |> filter(stress > 3)
```

Spiega che cosa fa `library(dplyr)` e perché è necessario.

2. L'AI ti propone questo codice:

```
janitor::clean_names(dati)
```

Che cosa devi controllare prima di usarlo?

3. Riscrivi il codice seguente usando la forma `pacchetto::funzione()`:

```
read_csv("data/questionario.csv")
```

4. Un compagno ti consegna un file Quarto che funziona sul suo computer ma non sul tuo. Il messaggio di errore dice che manca un pacchetto. Quali passaggi faresti per diagnosticare il problema?

5. Chiedi a un sistema di AI di scrivere una breve analisi con R. Poi controlla se ha introdotto pacchetti non necessari. Riscrivi il prompt chiedendo di usare solo i pacchetti già usati nel corso.

Per approfondire

Per approfondire l'uso dei pacchetti e del tidyverse, puoi consultare:

- [R for Data Science \(2e\)](#)
- [Introduction to Data Science: Data Wrangling and Visualization with R \(Irizarry, 2024\)](#)

Queste risorse sono utili, ma non sono prerequisiti per seguire il capitolo.

Bibliografia

Parte III.

EDA

Guardare i dati prima di modellarli.

Parte IV.

L'analisi esplorativa dei dati (EDA)

L'analisi esplorativa dei dati (EDA, dall'inglese *Exploratory Data Analysis*) è il processo di esplorazione e familiarizzazione con un dataset prima di intraprendere qualsiasi inferenza formale. Non si riduce alla semplice creazione di grafici, ma costituisce un **dialogo critico con l'evidenza empirica**: che cosa prevede la teoria? Che cosa mostrano effettivamente i dati? Le discrepanze osservate sono errori di misura, anomalie fortuite, o indicano piuttosto che il nostro modello teorico preliminare è incompleto o errato?

John Tukey, che formalizzò questo approccio negli anni '70, sottolineava l'importanza di **lasciare che siano i dati a parlare** prima di forzarli in strutture teoriche precostituite. È proprio durante l'esplorazione che possono emergere pattern inaspettati, relazioni non lineari ed errori sistematici: tutti quegli elementi che un'analisi puramente confermativa rischierebbe di trascurare o di non cogliere affatto.

L'EDA come controllo preliminare

L'esplorazione dei dati non sostituisce l'inferenza, ma la prepara. Prima di stimare un modello, è fondamentale interrogare i dati: la relazione tra le variabili ha una forma lineare o presenta curvature? Ci sono osservazioni anomale che potrebbero alterare le stime? Le distribuzioni sono compatibili con le assunzioni di base del modello? Nell'approccio bayesiano, in cui è necessario specificare le distribuzioni a priori, l'EDA fornisce un'evidenza empirica fondamentale per valutare se le scelte iniziali siano plausibili.

In questo senso, l'EDA rappresenta una forma intuitiva di *model checking*, un'anticipazione della diagnostica formale che, come avviene nel *posterior predictive checking* bayesiano, confronta sistematicamente i dati osservati con quelli simulati dal modello, per verificarne l'adeguatezza.

Cosa troverai in questa sezione

I capitoli che seguono sviluppano un percorso che parte dalla logica organizzativa di un progetto di analisi dati per arrivare ai concetti fondamentali che preparano l'inferenza statistica. Nello specifico, saranno trattati i seguenti argomenti:

- **struttura di un progetto di analisi:** organizzazione dei file, documentazione e flusso di lavoro riproducibile;
- **pulizia e preparazione dei dati:** gestione di valori mancanti, conversione di formati e correzione di errori sistematici;
- **variabili qualitative e quantitative:** analisi delle frequenze, esplorazione delle distribuzioni e scelta di visualizzazioni appropriate;
- **indicatori di sintesi statistica:** misurazioni di tendenza centrale (media, mediana) e di dispersione (varianza, deviazione standard), quantili e loro rappresentazione grafica;
- **la distribuzione normale:** proprietà fondamentali, processo di standardizzazione e ambiti di applicabilità;
- **relazioni tra variabili:** misura della correlazione, interpretazione degli scatterplot e limiti inferenziali;
- **causalità e associazione:** il divario tra correlazione e causalità, e i requisiti metodologici per un'inferenza causale valida;
- **gestione di outlier e trasformazioni:** identificazione di osservazioni influenti, criteri per la trasformazione delle variabili e relative implicazioni interpretative.

Collegamenti

L'EDA mette in pratica ciò che le altre sezioni preparano. I principi discussi nei *Fondamenti* – dalla scelta delle scale di misura alla validità degli strumenti, fino al disegno dello studio – orientano e danno significato a ciò che è opportuno calcolare e visualizzare. Parallelamente, gli strumenti introdotti nella sezione *R* – dalle funzioni base ai pacchetti specializzati, dalla sintassi alla logica della programmazione – costituiscono il mezzo operativo attraverso cui l'esplorazione prende forma.

Trascurare questa fase per procedere direttamente alla modellazione è un errore metodologico frequente. Come ammoniva John Tukey: “È meglio rispondere in modo approssimativo a una domanda giusta, piuttosto che rispondere in modo esatto a una domanda sbagliata”. L'EDA è precisamente il processo che ci aiuta a formulare, riformulare e comprendere **qual è la domanda giusta da porre ai nostri dati**.

13. Organizzare un progetto di analisi dei dati

L'analisi esplorativa dei dati non inizia con un grafico o con una media. Inizia con una domanda più semplice: "Dove si trovano i dati, cosa rappresentano e quali passaggi li hanno trasformati nel risultato che sto osservando?"

In un progetto ben organizzato, un'altra persona dovrebbe poter capire:

- quali sono i dati originali;
- quali modifiche sono state apportate;
- quale codice produce ogni tabella o grafico;
- dove si trovano i risultati;
- quali decisioni sono state prese lungo il percorso.

Questa non è solo una questione di ordine. È una condizione di trasparenza scientifica. Se non siamo in grado di ricostruire il percorso che ci ha portato a un risultato, quel risultato diventa fragile, anche quando il codice funziona.

13.1. Perché partire dalla struttura del progetto

Quando si lavora con i dati psicologici, è facile concentrarsi subito sulle analisi: importare il file, calcolare una media, produrre un grafico e chiedere all'AI una pipeline `dplyr`. Tuttavia, prima di procedere con l'analisi, è necessario costruire un ambiente in cui le operazioni siano chiare e riproducibili.

Un progetto ben organizzato aiuta a evitare problemi comuni:

- modificare per errore il file originale;
- dimenticare quale versione del dataset è stata utilizzata;
- salvare grafici e tabelle in cartelle casuali;
- usare percorsi che funzionano solo sul proprio computer;
- copiare il codice prodotto dall'AI senza sapere quali file legge o modifica;
- non riuscire più a ricostruire i passaggi dell'analisi.

L'obiettivo di questo capitolo è quindi pratico: costruire una struttura minima per un progetto EDA. Non è necessario imparare strumenti avanzati di automazione. Prima di tutto, è necessario rendere visibile il percorso che collega la domanda di ricerca, i dati, il codice e i risultati.

13.2. Un esempio ricorrente

Useremo come riferimento un piccolo progetto immaginario:

Vogliamo esplorare la relazione tra lo stress accademico e la qualità del sonno in un gruppo di studenti universitari.

13. Organizzare un progetto di analisi dei dati

Il dataset contiene, per ciascuno studente:

- un identificativo anonimo;
- un punteggio di stress accademico;
- un punteggio sulla qualità del sonno;
- alcune informazioni descrittive, come l'età, il genere e l'anno di corso.

In questa fase non vogliamo ancora stimare un modello né trarre conclusioni causali. Vogliamo solo creare le condizioni per esplorare i dati in modo ordinato.

13.3. La struttura minima di un progetto

Una struttura semplice può essere questa:

```
stress_sonno/  
  stress_sonno.Rproj  
  data/  
    raw/  
      studenti_sonno_raw.csv  
    clean/  
      studenti_sonno_clean.csv  
  scripts/  
    01_clean_data.R  
  reports/  
    eda_stress_sonno.qmd  
  figures/  
  tables/  
  README.md
```

Non è l'unica struttura possibile, ma è sufficiente per iniziare. Il punto essenziale è separare ciò che ha funzioni diverse.

| Cartella o file | Funzione |
|-----------------|---|
| data/raw/ | Contiene i dati originali, da non modificare mai manualmente. |
| data/clean/ | Contiene i dati puliti o ricodificati tramite script. |
| scripts/ | Contiene il codice che prepara o trasforma i dati. |
| reports/ | Contiene i documenti Quarto con analisi, grafici e commenti. |
| figures/ | Contiene eventuali figure salvate. |
| tables/ | Contiene eventuali tabelle esportate. |
| README.md | Spiega che cosa contiene il progetto e come usarlo. |

Per un progetto didattico, questa struttura è più che sufficiente. Se il progetto dovesse crescere, sarà possibile aggiungere altre cartelle. All'inizio, però, è meglio una struttura semplice, comprensibile e usata con coerenza.

13.4. Dati grezzi e dati puliti

La distinzione più importante è tra dati grezzi e dati puliti.

I **dati grezzi** sono il file così come è stato ricevuto o esportato dallo strumento di raccolta. Per esempio, potrebbero contenere nomi di variabili poco chiari, codifiche non uniformi, valori mancanti indicati in modi diversi o colonne non necessarie.

I **dati puliti** sono il risultato di trasformazioni documentate: rinomina delle variabili, ricodifica delle categorie, gestione dei valori mancanti, controllo dei duplicati e, eventualmente, calcolo dei punteggi compositi.

La regola pratica è semplice:

! Importante

Non modificare mai manualmente il file in `data/raw/`.
Ogni trasformazione deve essere scritta in uno script o in un documento Quarto, in modo da poter essere ripetuta e controllata.

Per esempio, invece di aprire il file CSV e cambiare manualmente il nome di una colonna, è meglio scrivere una riga di codice.

```
studenti_clean <- studenti_raw |>
  dplyr::rename(stress = stress_accademico_totale)
```

In questo modo, la trasformazione rimane visibile. Chi legge il progetto può capire che la variabile `stress` deriva dalla colonna originale `stress_accademico_totale`.

13.5. Percorsi relativi

Un errore frequente è usare percorsi assoluti, come:

```
readr::read_csv("/Users/mario/Desktop/stress_sonno/data/raw/studenti_sonno_raw.csv")
```

Questo codice funziona solo sul computer di Mario. Su un altro computer, o anche sullo stesso computer dopo aver spostato la cartella, probabilmente non funzionerà più.

In un progetto R è preferibile usare percorsi relativi alla cartella del progetto. Il pacchetto `here` aiuta a farlo:

```
studenti_raw <- readr::read_csv(
  here::here("data", "raw", "studenti_sonno_raw.csv")
)
```

Questa istruzione dice di partire dalla cartella principale del progetto e di cercare il file all'interno della cartella `data/raw/`. In questo modo il codice diventa più portatile e più facile da condividere.

13.6. Il flusso minimo di lavoro

Un progetto EDA può seguire un flusso molto semplice:

```
Domanda di ricerca
  ↓
Dati grezzi in data/raw/
  ↓
Script di pulizia in scripts/
  ↓
Dati puliti in data/clean/
  ↓
Report Quarto in reports/
  ↓
Grafici, tabelle e interpretazione
```

Questa sequenza non serve a complicare il lavoro. È utile per evitare confusione. Se qualcosa va storto, sappiamo dove cercare: nei dati grezzi, nello script di pulizia, nel report o nell'interpretazione.

13.7. Un piccolo script di pulizia

Uno script di pulizia iniziale potrebbe avere una struttura come questa:

```
library(dplyr)
library(readr)
library(here)

studenti_raw <- read_csv(
  here("data", "raw", "studenti_sonno_raw.csv")
)

studenti_clean <- studenti_raw |>
  rename(
    id = participant_id,
    stress = stress_accademico_totale,
    sonno = qualita_sonno_totale
  ) |>
  mutate(
    genere = factor(genere),
    anno_corso = factor(anno_corso)
  )

write_csv(
  studenti_clean,
  here("data", "clean", "studenti_sonno_clean.csv")
)
```

Questo codice non è complesso, ma contiene già tre buone pratiche:

- legge i dati grezzi senza modificarli;

- rende esplicite le trasformazioni;
- salva un nuovo file pulito in una cartella separata.

Nel capitolo successivo vedremo più in dettaglio come controllare e pulire i dati. Qui il punto è capire dove collocare ogni passaggio.

13.8. Il ruolo del report Quarto

Il report Quarto è il luogo in cui testo, codice, grafici e interpretazione stanno insieme. Per esempio, nel file `reports/eda_stress_sonno.qmd` possiamo scrivere:

```
studenti <- readr::read_csv(
  here::here("data", "clean", "studenti_sonno_clean.csv")
)

ggplot2::ggplot(studenti, ggplot2::aes(x = stress)) +
  ggplot2::geom_histogram(bins = 20)
```

Subito sotto il grafico, però, dobbiamo anche interpretare ciò che vediamo. Un report riproducibile non è una sequenza di comandi ma una spiegazione documentata dell'analisi.

Una buona regola è chiedersi:

Una persona che non ha partecipato all'analisi può capire che cosa ho fatto, perché l'ho fatto e quali risultati ho ottenuto?

13.9. Cosa documentare sempre

Durante un progetto EDA, alcune decisioni devono essere documentate con particolare cura.

| Decisione | Perché va documentata |
|---------------------------------|---|
| Rimozione di casi | Cambia il campione analizzato. |
| Gestione dei valori mancanti | Può modificare medie, grafici e associazioni. |
| Ricodifica di categorie | Può cambiare il significato di una variabile. |
| Creazione di punteggi compositi | Collega item osservati a costrutti psicologici. |
| Esclusione di outlier | Può cambiare in modo sostanziale i risultati. |
| Scelta di un grafico | Influenza ciò che il lettore vede e interpreta. |

Non è necessario scrivere pagine di spiegazione per ogni scelta. Tuttavia, le decisioni importanti devono lasciare una traccia.

13.10. Usare l'AI con criterio

Gli strumenti di IA possono essere molto utili nella costruzione di un progetto. Per esempio, si può chiedere:

Crea una struttura di cartelle per un progetto EDA in R su stress accademico e sonno.

Oppure:

Scrivi il codice R per leggere un file CSV da `data/raw/`, rinominare alcune variabili e salvare il risultato in `data/clean/`.

Queste richieste sono legittime. Tuttavia, l'AI non conosce automaticamente il tuo progetto, i tuoi file, il significato delle variabili e le decisioni metodologiche che hai preso. Per questo motivo, devi sempre controllare:

- il codice legge il file corretto?
- il codice salva il risultato nella cartella giusta?
- il file originale resta intatto?
- le variabili rinominate corrispondono davvero a ciò che significano nel questionario?
- il codice elimina righe o colonne senza dirlo?
- Il report spiega le scelte fatte?

L'AI può aiutare a scrivere il codice. Tuttavia, non può assumersi la responsabilità scientifiche dell'analisi.

13.11. Una checklist prima di iniziare l'EDA

Prima di produrre grafici o statistiche descrittive, verifica che il progetto includa almeno i seguenti elementi:

- una cartella principale del progetto;
- un file `.Rproj`;
- i dati originali in `data/raw/`;
- uno script o un documento che descriva le trasformazioni;
- i dati puliti in `data/clean/`, se sono state apportate delle modifiche;
- un report Quarto in cui il codice e l'interpretazione sono collegati;
- percorsi relativi, non percorsi assoluti;
- nomi di file e variabili comprensibili;
- una breve descrizione del progetto in `README.md`.

Consiglio

Una struttura semplice, se ben utilizzata, è preferibile a una struttura complessa che nessuno riesce a comprendere.

13.12. Strumenti avanzati: per ora non servono

Nei progetti più grandi è possibile utilizzare strumenti come `targets`, GNU Make, GitHub Actions o pipeline automatizzate. Questi strumenti sono utili soprattutto quando molte analisi dipendono l'una dall'altra.

In questo tutorial, però, il nostro obiettivo è più elementare: imparare a costruire un progetto leggibile, riproducibile e controllabile. Prima di automatizzare un flusso di lavoro, è necessario saperlo descrivere.

13.13. Cosa portare al capitolo successivo

Il capitolo successivo affronta il tema della pulizia dei dati. La struttura del progetto ci permetterà di mantenere separati tre livelli:

1. i dati originali;
2. le trasformazioni documentate;
3. il dataset usato per l'esplorazione.

Questa distinzione è fondamentale. Senza questa distinzione, non potremmo sapere se un pattern osservato nei dati dipende dal fenomeno psicologico che stiamo studiando o da una decisione nascosta presa durante la preparazione del dataset.

Esercizi

Esercizio 1

Immagina di avere ricevuto un file chiamato `questionario_studenti.csv` con risposte su stress, sonno e benessere.

Progetta una struttura minima di cartelle per analizzarlo in R. Specifica dove metteresti:

- il file originale;
- il file pulito;
- lo script di pulizia;
- il report Quarto;
- eventuali grafici esportati.

Esercizio 2

Considera questo percorso:

```
readr::read_csv("C:/Users/Giulia/Desktop/progetto/data/studenti.csv")
```

Perché questo percorso può creare problemi di riproducibilità? Riscrivilo usando una logica di progetto con `here::here()`.

Esercizio 3

L'AI ti propone questo codice:

```
studenti <- readr::read_csv("studenti.csv") |>
  tidyr::drop_na() |>
  dplyr::rename(stress = Q12)
```

Prima di usarlo, quali controlli dovresti fare? Indica almeno tre possibili problemi.

Soluzioni sintetiche

Esercizio 1. Una possibile struttura è:

```
progetto_studenti/
  progetto_studenti.Rproj
  data/
    raw/
      questionario_studenti.csv
    clean/
  scripts/
    01_clean_data.R
  reports/
    eda_studenti.qmd
  figures/
```

Esercizio 2. Il percorso dipende dal computer di Giulia. Una versione più riproducibile è:

```
readr::read_csv(here::here("data", "raw", "studenti.csv"))
```

Esercizio 3. Bisogna controllare almeno: dove si trova davvero il file, che cosa comporta `drop_na()` e quante righe elimina, se Q12 corrisponde davvero allo stress, se conviene documentare la rinomina, e se il dataset originale resta intatto.

14. Pulizia dei dati

Dai dati grezzi a un dataset documentato

14.1. Perché questo capitolo

L'analisi esplorativa dei dati precede la creazione di grafici e statistiche descrittive. Inizia quando apriamo un file e ci chiediamo se i dati in esso contenuti sono comprensibili, coerenti e pertinenti alla domanda di ricerca.

La pulizia dei dati non è una fase puramente tecnica. Ogni correzione, esclusione, ricodifica o trasformazione è una **decisione metodologica**. Alcune decisioni sono semplici, come correggere un nome di variabile scritto in modo incoerente. Altre decisioni sono più delicate, come ad esempio cosa fare con i valori mancanti, le risposte impossibili o le osservazioni duplicate.

In questo capitolo useremo un principio semplice:

! Principio fondamentale

Non modificare mai i dati grezzi.

I dati originali devono restare intatti. Tutte le trasformazioni devono essere eseguite tramite codice e salvate in un nuovo file documentato.

Al termine del capitolo dovresti essere in grado di:

- distinguere i dati grezzi da quelli puliti;
- ispezionare la struttura iniziale di un dataset;
- riconoscere i problemi più comuni dei dati;
- applicare semplici operazioni di pulizia;
- verificare che il dataset pulito sia coerente;
- documentare le decisioni prese durante la pulizia;
- valutare criticamente il codice di pulizia prodotto con l'aiuto dell'AI.

14.2. La logica generale: quattro fasi

Useremo una sequenza in quattro fasi.

| Fase | Domanda guida | Obiettivo |
|------------------|----------------------------|--|
| Ispezione | Che cosa contiene il file? | Capire struttura, variabili, tipi di dato e problemi iniziali. |

| Fase | Domanda guida | Obiettivo |
|------------------|--------------------------------|--|
| Pulisci | Che cosa deve essere corretto? | Rinominare, ricodificare, gestire duplicati, missing e formati errati. |
| Valida | Il dataset è coerente? | Controllare che i valori rispettino vincoli plausibili. |
| Documenta | Che cosa è stato fatto? | Rendere esplicite e riproducibili tutte le decisioni. |

Questa sequenza non va intesa come una ricetta rigida. Nella pratica si torna spesso indietro: un controllo può rivelare un problema che richiede una nuova correzione. L'importante è che il processo sia trasparente.

14.3. Un esempio ricorrente: stress e sonno

Supponiamo di aver raccolto dati da studenti universitari per studiare la relazione tra stress accademico e qualità del sonno. Il file grezzo contiene una riga per ogni studente e le seguenti variabili:

| Variabile | Significato atteso |
|-------------------|--|
| id | Identificatore anonimo dello studente |
| eta | Età in anni |
| genere | Categoria dichiarata dallo studente |
| stress | Punteggio di stress accademico, da 1 a 10 |
| sonno_ore | Ore medie di sonno per notte |
| qualita_sonno | Valutazione soggettiva del sonno, da 1 a 5 |
| data_compilazione | Data di compilazione del questionario |

Questo esempio ci accompagnerà nei capitoli successivi: prima controlleremo il dataset, poi esploreremo le singole variabili, visualizzeremo le distribuzioni, esamineremo la variabilità e, infine, studieremo le associazioni tra le variabili.

14.4. Prima regola: separare dati grezzi e dati puliti

Una struttura minima del progetto potrebbe essere:

```
progetto_eda/
  data_raw/      # dati originali, mai modificati
  data_clean/    # dati puliti prodotti dal codice
  reports/       # file Quarto e report finali
  scripts/       # eventuali script R separati
```

I dati grezzi devono essere conservati in `data_raw/`. Il dataset pulito deve essere salvato in `data_clean/`. In questo modo, se qualcosa va storto, è sempre possibile ricostruire il percorso dall'inizio.

⚠ Errore comune

Aprire un file .csv in Excel, correggere qualche cella manualmente e salvare il file sopra quello originale sembra un'operazione veloce, ma rende difficile verificare l'analisi.

La domanda da porsi è: **Un'altra persona potrebbe ricostruire esattamente ciò che ho fatto?**

14.5. Fase 1: ispezione

La prima cosa da fare è guardare il dataset senza modificarlo.

```
library(readr)
library(dplyr)

stress_raw <- read_csv("data_raw/stress_sonno.csv")

glimpse(stress_raw)
```

In questa fase non cerchiamo ancora di correggere tutto. Cerchiamo piuttosto di capire che cosa abbiamo davanti.

Domande utili:

- Il numero di righe è plausibile?
- Le variabili attese sono presenti?
- I nomi delle colonne sono comprensibili?
- Le variabili numeriche sono state importate come numeriche?
- Le categorie sono scritte in modo coerente?
- Ci sono codici speciali per i valori mancanti, come 999, -99, NA, N/A, non so?

Un controllo iniziale può essere effettuato con funzioni semplici.

```
nrow(stress_raw)
ncol(stress_raw)
names(stress_raw)
summary(stress_raw)
```

Se usi pacchetti come `skimr`, puoi ottenere una panoramica più ricca.

```
skimr::skim(stress_raw)
```

i Che cosa guardare subito

Durante l'ispezione iniziale presta attenzione soprattutto a:

- valori mancanti;
- valori impossibili, come `stress = 99` su una scala da 1 a 10;
- categorie duplicate per errore, come F, femmina, Femmina;
- date lette come testo;
- variabili numeriche lette come caratteri;

- righe duplicate;
- colonne che contengono informazioni identificative.

14.6. Fase 2: pulisci

Dopo l'ispezione si costruisce una versione pulita del dataset. La pulizia deve avvenire tramite codice, non manualmente.

14.6.1. Rinominare le variabili

I nomi chiari riducono gli errori. È utile usare nomi brevi, descrittivi e coerenti.

```
stress <- stress_raw |>
  janitor::clean_names()
```

Dopo questa operazione è opportuno controllare i nuovi nomi.

```
names(stress)
```

14.6.2. Eliminare informazioni identificative

Se il dataset contiene nomi, indirizzi email, matricole o altre informazioni personali, queste devono essere rimosse o sostituite da identificatori anonimi prima dell'analisi.

```
stress <- stress |>
  select(-email, -nome, -cognome)
```

Naturalmente questo codice è solo un esempio: le colonne da rimuovere dipendono dal dataset reale.

14.6.3. Gestire duplicati

I duplicati non devono essere eliminati automaticamente. Bisogna prima capire perché esistono.

```
stress |>
  count(id) |>
  filter(n > 1)
```

Se uno studente ha compilato il questionario due volte, dobbiamo decidere quale riga conservare. Per esempio, potremmo tenere in considerazione l'ultima compilazione.

```
stress <- stress |>
  arrange(id, data_compilazione) |>
  distinct(id, .keep_all = TRUE)
```

Questa scelta deve essere documentata. Non è sufficiente scrivere il codice, ma è necessario spiegare perché è stata presa quella decisione.

14.6.4. Ricodificare valori incoerenti

Spesso i dati provenienti dai questionari contengono categorie scritte in modi diversi.

```
stress <- stress |>
  mutate(
    genere = case_when(
      genere %in% c("F", "f", "Femmina", "femmina") ~ "femmina",
      genere %in% c("M", "m", "Maschio", "maschio") ~ "maschio",
      TRUE ~ "altro_o_non_indicato"
    )
  )
```

Dopo ogni ricodifica è necessario controllare il risultato.

```
stress |>
  count(genere)
```

14.6.5. Gestire valori mancanti

I valori mancanti sono una delle parti più delicate della pulizia dei dati. Non indicano sempre la stessa cosa. Una risposta mancante può indicare che lo studente ha saltato la domanda, che la domanda non era pertinente, che c'è stato un errore di inserimento o che il dato è stato rimosso per motivi di privacy.

Prima di decidere come procedere, è necessario quantificare il problema.

```
stress |>
  summarise(across(everything(), ~ sum(is.na(.))))
```

A volte i valori mancanti sono codificati con numeri o stringhe particolari.

```
stress <- stress |>
  mutate(
    stress = na_if(stress, 999),
    sonno_ore = na_if(sonno_ore, -99)
  )
```

Non cancellare i missing troppo presto

Molte funzioni R eliminano automaticamente i casi con valori mancanti o richiedono opzioni come `na.rm = TRUE`.

Prima di eliminare osservazioni, chiediti:

- quanti casi sto perdendo?
- i casi eliminati sono simili agli altri?
- la perdita di dati può modificare le conclusioni?
- devo dichiarare questa scelta nel report?

Per un capitolo introduttivo è sufficiente sapere che esistono diverse strategie: l'esclusione dei casi incompleti, l'analisi dei pattern di missing, l'imputazione semplice e l'imputazione multipla. La scelta dipende dal disegno dello studio, dalla quantità di dati mancanti e dalla plausibilità delle assunzioni.

In questa sede, l'aspetto più importante non è imparare una tecnica avanzata di imputazione, ma non considerare i valori mancanti come un dettaglio trascurabile.

14.7. Fase 3: valida

Dopo la pulizia, è necessario verificare che il dataset rispetti vincoli plausibili.

Per esempio:

- `stress` deve essere compreso tra 1 e 10;
- `qualita_sonno` deve essere compresa tra 1 e 5;
- `sonno_ore` non deve essere negativa;
- ogni id dovrebbe comparire una sola volta;
- le categorie di genere dovrebbero essere quelle previste.

Alcuni controlli possono essere eseguiti con semplici filtri.

```
stress |>
  filter(stress < 1 | stress > 10)

stress |>
  filter(sonno_ore < 0 | sonno_ore > 16)
```

Possiamo anche sintetizzare i controlli in una piccola tabella.

```
stress |>
  summarise(
    n = n(),
    id_duplicati = n() - n_distinct(id),
    stress_fuori_range = sum(stress < 1 | stress > 10, na.rm = TRUE),
    sonno_fuori_range = sum(sonno_ore < 0 | sonno_ore > 16, na.rm = TRUE),
    missing_stress = sum(is.na(stress)),
    missing_sonno = sum(is.na(sonno_ore))
  )
```

Per progetti più complessi, è possibile utilizzare pacchetti dedicati alla validazione dei dati. Per questo percorso introduttivo, però, è più importante acquisire l'abitudine al controllo piuttosto che conoscere molti strumenti.

14.8. Fase 4: documenta

La documentazione è parte integrante della pulizia, non un'aggiunta finale.

Per ogni trasformazione importante, il report o lo script dovrebbe spiegare:

| Decisione | Che cosa documentare |
|--------------------------------|--|
| Rimozione di duplicati | Quale criterio è stato usato? |
| Ricodifica di categorie | Quali valori sono stati uniti o rinominati? |
| Gestione dei missing | Quanti valori mancavano? Come sono stati trattati? |
| Esclusione di osservazioni | Quanti casi sono stati rimossi? Perché? |
| Rimozione di identificatori | Quali informazioni personali sono state eliminate? |
| Salvataggio del dataset pulito | Dove si trova il file finale? |

Un esempio di annotazione nel report potrebbe essere il seguente.

Esempio di decisione documentata

Nel dataset grezzo erano presenti 3 studenti con due compilazioni del questionario. Per ciascuno di questi studenti è stata conservata la compilazione più recente, identificata tramite `data_compilazione`. Dopo questa operazione il dataset contiene una sola riga per studente.

Il dataset pulito può essere salvato in `data_clean/`.

```
readr::write_csv(stress, "data_clean/stress_sonno_clean.csv")
```

14.9. Usare l'AI con criterio

L'intelligenza artificiale può essere molto utile per la pulizia dei dati. Può suggerire il codice per importare i file, individuare i duplicati, ricodificare le categorie, calcolare i valori mancanti o produrre controlli di validazione.

Tuttavia, non può decidere al posto tuo il significato di una risposta mancante, se una riga duplicata sia un errore o se un valore estremo sia impossibile o solo raro.

Prompt utile

Puoi chiedere all'AI:

Ho un dataset con variabili `id`, `stress`, `sonno_ore`, `qualita_sonno` e `genere`.
Scrivi il codice R con `dplyr` per controllare duplicati, valori mancanti e valori fuori range. Non eliminare nulla automaticamente: produci solo tabelle di controllo.

Questo prompt è migliore di:

Pulisci il dataset.

perché chiede controlli espliciti e impedisce trasformazioni automatiche non documentate.

Dopo aver ricevuto il codice dall'AI, controlla sempre:

- quali righe vengono eliminate;
- quali variabili vengono trasformate;
- quali valori vengono ricodificati;

- se i missing vengono rimossi senza avviso;
- se il codice modifica i dati grezzi;
- se il risultato viene salvato in un nuovo file.

14.10. Checklist finale

Prima di passare all'analisi esplorativa vera e propria, verifica che:

- i dati grezzi siano conservati senza modifiche;
- il dataset pulito sia stato prodotto tramite codice;
- i nomi delle variabili siano chiari e coerenti;
- i tipi di dato siano appropriati;
- i duplicati siano stati controllati;
- i valori mancanti siano stati quantificati;
- i valori fuori range siano stati identificati;
- eventuali esclusioni o ricodifiche siano documentate;
- il dataset pulito sia salvato in una cartella separata;
- il report permetta a un'altra persona di ricostruire il processo.

! Messaggio chiave

Pulire i dati non significa renderli “belli” o eliminare ciò che disturba. Significa costruire un dataset che sia coerente con la domanda di ricerca, controllabile da altri e adatto alle analisi successive.

14.11. Collegamento con il capitolo successivo

Nel prossimo capitolo useremo il dataset pulito per iniziare l'analisi esplorativa vera e propria. Inizieremo analizzando una variabile alla volta: distribuzioni, frequenze, valori mancanti, valori inattesi e primi segnali di struttura nei dati.

15. Esplorare una variabile alla volta

Capire i dati prima di cercare relazioni

15.1. Perché questo capitolo

L'analisi esplorativa dei dati inizia con una domanda semplice: **Che cosa contiene ciascuna variabile?**

Prima di studiare le correlazioni, confrontare i gruppi o stimare i modelli, è necessario conoscere le variabili una alla volta. Una variabile può presentare valori mancanti, categorie riportate in modo incoerente, distribuzioni asimmetriche, gruppi molto sbilanciati o valori inattesi. Se non li osserviamo all'inizio, rischiamo di costruire analisi apparentemente corrette su dati che non abbiamo davvero compreso.

In psicologia, questa fase è particolarmente importante. Le variabili possono rappresentare caratteristiche sociodemografiche, risposte a item, punteggi di scala, tempi di reazione, valutazioni soggettive o indicatori fisiologici. Ogni variabile ha un significato teorico e un'origine empirica. Esplorare una variabile non significa soltanto produrre un grafico, ma anche chiedersi cosa quel grafico ci dice del fenomeno osservato.

Al termine del capitolo dovresti essere in grado di:

- distinguere le variabili categoriali da quelle numeriche;
- controllare i valori mancanti e quelli inattesi;
- scegliere rappresentazioni grafiche semplici e appropriate;
- leggere frequenze, proporzioni, istogrammi e boxplot;
- evitare interpretazioni premature;
- controllare criticamente il codice e i commenti prodotti con l'aiuto dell'AI.

! Idea guida

L'analisi univariata non permette di trarre conclusioni. Serve per **orientarsi**. Prima di domandarci se due variabili sono associate, dobbiamo capire come si comporta ciascuna variabile da sola.

15.2. Una sequenza minima

Quando esploriamo una variabile, possiamo seguire una sequenza molto semplice.

| Passo | Domanda guida | Esempio di controllo |
|-----------------------------|---|---|
| 1. Identificare | Che tipo di variabile è? | Categoriale, ordinale, numerica, punteggio di scala |
| 2. Controllare | Ci sono valori mancanti o impossibili? | NA, valori fuori scala, categorie inattese |
| 3. Contare o riassumere | Dove si concentrano i valori? | Frequenze, proporzioni, minimo, massimo, mediana |
| 4. Visualizzare | Quale grafico mostra meglio la distribuzione? | Barre, istogramma, boxplot |
| 5. Interpretare con cautela | Che cosa posso dire e che cosa no? | Descrizione, non ancora spiegazione causale |

Questa sequenza verrà ripresa più volte nei capitoli successivi. L'EDA è un processo iterativo: spesso un grafico rivela un problema che ci costringe a tornare alle fasi di controllo o di pulizia.

15.3. Un esempio ricorrente: stress e sonno

Useremo un piccolo dataset didattico su studenti universitari. Ogni riga rappresenta uno studente. Le variabili principali sono:

| Variabile | Tipo | Significato |
|---------------|----------------------|--|
| genere | categoriale | genere dichiarato |
| anno | categoriale/ordinale | anno di corso |
| stress | numerica discreta | stress accademico, da 1 a 10 |
| sonno_ore | numerica continua | ore medie di sonno per notte |
| qualita_sonno | ordinale | qualità soggettiva del sonno, da 1 a 5 |

Nel capitolo precedente abbiamo visto che un dataset deve essere controllato e documentato. Qui si assume di avere già una versione pulita, ma si continuerà comunque a controllare ciò che si fa.

```
library(dplyr)
library(ggplot2)
library(tibble)

set.seed(123)

stress_sonno <- tibble(
  id = 1:120,
  genere = sample(c("F", "M", "Altro/non dichiarato"),
    size = 120,
    replace = TRUE,
    prob = c(.58, .38, .04)),
  anno = sample(c("Primo", "Secondo", "Terzo"),
    size = 120,
    replace = TRUE,
    prob = c(.42, .34, .24)),
  stress = pmin(pmax(round(rnorm(120, mean = 6.2, sd = 1.8)), 1), 10),
```



```

sonno_ore = round(rnorm(120, mean = 7.0, sd = 1.1), 1),
qualita_sonno = pmin(pmax(round(rnorm(120, mean = 3.1, sd = 1.0)), 1), 5)
)

# Introduciamo alcuni valori mancanti per rendere l'esempio realistico.
stress_sonno$sonno_ore[c(7, 48, 91)] <- NA
stress_sonno$qualita_sonno[c(13, 62)] <- NA

```

```
glimpse(stress_sonno)
```

```

Rows: 120
Columns: 6
$ id          <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 1~
$ genere      <chr> "F", "M", "F", "M", "M", "F", "F", "M", "F", "F", "M", "~
$ anno        <chr> "Secondo", "Primo", "Primo", "Primo", "Primo", "Terzo", ~
$ stress       <dbl> 6, 4, 5, 6, 10, 5, 7, 6, 4, 6, 9, 7, 6, 5, 3, 8, 4, 8, 1~
$ sonno_ore    <dbl> 6.1, 6.4, 8.6, 5.7, 6.8, 9.1, NA, 5.5, 6.3, 7.5, 6.6, 6.~
$ qualita_sonno <dbl> 3, 4, 3, 4, 4, 3, 3, 2, 4, 3, 5, 1, NA, 4, 4, 3, 2, 3, 3~

```

15.4. Primo controllo: valori mancanti e valori inattesi

Prima di creare i grafici, è consigliabile verificare che le variabili non presentino valori mancanti o valori fuori scala.

```

stress_sonno |>
  summarise(
    across(
      everything(),
      ~ sum(is.na(.x))
    )
  )

```

```

# A tibble: 1 x 6
  id genere anno stress sonno_ore qualita_sonno
<int> <int> <int> <int>    <int>      <int>
1     0     0     0     0        3          2

```

Questo controllo risponde a una domanda pratica: **quante osservazioni potrei perdere se una funzione elimina automaticamente i valori mancanti?**

Per le variabili con scale definite, controlliamo anche i valori minimo e massimo.

```

stress_sonno |>
  summarise(
    stress_min = min(stress, na.rm = TRUE),
    stress_max = max(stress, na.rm = TRUE),
    sonno_min = min(sonno_ore, na.rm = TRUE),
    sonno_max = max(sonno_ore, na.rm = TRUE),
  )

```

15. Esplorare una variabile alla volta

```
qualita_min = min(qualita_sonno, na.rm = TRUE),  
qualita_max = max(qualita_sonno, na.rm = TRUE)  
)
```

```
# A tibble: 1 x 6  
  stress_min stress_max sonno_min sonno_max qualita_min qualita_max  
    <dbl>    <dbl>    <dbl>    <dbl>    <dbl>    <dbl>  
1         3        10        4.3        9.8         1         5
```

⚠ Errore comune

Non partire dalla media. Inizia chiedendoti se i valori sono plausibili.

Una media può essere calcolata anche quando una variabile contiene codici errati, valori fuori scala o valori mancanti trattati in modo scorretto.

15.5. Variabili categoriali: contare prima di interpretare

Una variabile categoriale assegna ogni osservazione a una categoria. Esempi tipici sono il genere, il gruppo sperimentale, la diagnosi, la condizione o l'anno di corso.

La prima analisi da effettuare è il conteggio delle categorie.

```
stress_sonno |>  
  count(genere)
```

```
# A tibble: 3 x 2  
  genere      n  
  <chr>    <int>  
1 Altro/non dichiarato    3  
2 F                      69  
3 M                      48
```

I conteggi assoluti sono utili, ma spesso vogliamo anche le proporzioni.

```
stress_sonno |>  
  count(genere) |>  
  mutate(proporzione = n / sum(n))
```

```
# A tibble: 3 x 3  
  genere      n proporzione  
  <chr>    <int>    <dbl>  
1 Altro/non dichiarato    3    0.025  
2 F                      69    0.575  
3 M                      48    0.4
```

Le proporzioni aiutano a comprendere la composizione del campione. Tuttavia, non risolvono da sole il problema della rappresentatività. Se il campione è di convenienza, una proporzione descrive **questi dati**, non necessariamente la popolazione degli studenti universitari.

15.5.1. Grafico a barre

Per una singola variabile categoriale, il grafico più semplice è il grafico a barre.

```
ggplot(stress_sonno, aes(x = genere)) +
  geom_bar() +
  labs(
    x = "Genere dichiarato",
    y = "Numero di studenti",
    title = "Quante osservazioni ci sono in ciascuna categoria?"
  )
```




Figura 15.1.: Distribuzione del genere dichiarato nel campione didattico.

Questo grafico risponde a una domanda descrittiva: qual è la composizione del campione rispetto a questa variabile?

Non risponde a domande causali e non è sufficiente per stabilire se il campione sia rappresentativo.

15.5.2. Due variabili categoriali

A volte, vogliamo vedere come due variabili categoriali interagiscono tra loro. Per esempio, potremmo chiederci come si distribuiscono gli anni di corso nei diversi gruppi di genere.

```
stress_sonno |>
  count(genere, anno)
```

A tibble: 8 x 3

| genere | anno | n |
|--------|-------|-------|
| <chr> | <chr> | <int> |

15. Esplorare una variabile alla volta

| | | | |
|---|----------------------|---------|----|
| 1 | Altro/non dichiarato | Primo | 2 |
| 2 | Altro/non dichiarato | Terzo | 1 |
| 3 | F | Primo | 29 |
| 4 | F | Secondo | 27 |
| 5 | F | Terzo | 13 |
| 6 | M | Primo | 24 |
| 7 | M | Secondo | 16 |
| 8 | M | Terzo | 8 |

```
ggplot(stress_sonno, aes(x = genere, fill = anno)) +  
  geom_bar(position = "fill") +  
  labs(  
    x = "Genere dichiarato",  
    y = "Proporzione",  
    fill = "Anno di corso",  
    title = "La composizione per anno è simile nei gruppi?"  
  )
```




Figura 15.2.: Distribuzione dell'anno di corso per genere dichiarato.

Usando l'opzione `position = "fill"`, tutte le barre hanno la stessa altezza. Questo rende più facile il confronto delle proporzioni interne, ma nasconde il numero assoluto di osservazioni in ciascun gruppo. Per questo motivo, quando le numerosità sono molto diverse, è opportuno considerare sia i conteggi sia le proporzioni.

15.6. Variabili numeriche: guardare forma, centro e variabilità

Una variabile numerica assegna a ogni osservazione un valore su una scala quantitativa. Esempi di variabili numeriche sono i punteggi di scala, i tempi di reazione, le ore di sonno, l'età o il numero di errori.

Le prime domande da porsi riguardo a una variabile numerica sono:

- quali sono i valori minimo e massimo?
- dove si concentrano i valori?
- la distribuzione è simmetrica o asimmetrica?
- Ci sono valori molto lontani dagli altri?
- la media è un riassunto sensato o sarebbe meglio usare la mediana e i quartili?

15.6.1. Riassunti numerici iniziali

```
stress_sonno |>
  summarise(
    n = sum(!is.na(sonno_ore)),
    missing = sum(is.na(sonno_ore)),
    minimo = min(sonno_ore, na.rm = TRUE),
    q25 = quantile(sonno_ore, .25, na.rm = TRUE),
    mediana = median(sonno_ore, na.rm = TRUE),
    media = mean(sonno_ore, na.rm = TRUE),
    q75 = quantile(sonno_ore, .75, na.rm = TRUE),
    massimo = max(sonno_ore, na.rm = TRUE)
  )
```

```
# A tibble: 1 x 8
      n missing minimo  q25 mediana media  q75 massimo
<int>  <int>  <dbl> <dbl>   <dbl> <dbl> <dbl>   <dbl>
1   117      3    4.3   6.4     7.1  7.08  7.8     9.8
```

Questa tabella non sostituisce il grafico. È utile per farsi un'idea iniziale: quante osservazioni sono disponibili, qual è l'intervallo dei valori e quanto la media differisce dalla mediana.

15.6.2. Istogramma

L'istogramma mostra la forma della distribuzione raggruppando i valori in intervalli.

```
ggplot(stress_sonno, aes(x = sonno_ore)) +
  geom_histogram(binwidth = 0.5, boundary = 0) +
  labs(
    x = "Ore medie di sonno per notte",
    y = "Numero di studenti",
    title = "Dove si concentrano le ore di sonno?"
  )
```




Figura 15.3.: Distribuzione delle ore medie di sonno.

L'istogramma è sensibile alla scelta dell'ampiezza dei bin. Modificare il parametro "binwidth" può rendere la distribuzione più frastagliata o più liscia. Per questo motivo, l'istogramma deve essere considerato uno strumento esplorativo e non un'immagine definitiva della realtà.

```
ggplot(stress_sonno, aes(x = sonno_ore)) +
  geom_histogram(binwidth = 1, boundary = 0) +
  labs(
    x = "Ore medie di sonno per notte",
    y = "Numero di studenti",
    title = "Stessi dati, bin più larghi"
  )
```




Figura 15.4.: La scelta del binwidth può modificare l'aspetto dell'istogramma.

i Cosa osservare in un istogramma

Quando guardi un istogramma, chiediti:

- la distribuzione presenta un solo picco o più picchi?
- è circa simmetrica o asimmetrica?
- ci sono valori isolati?
- ci sono limiti artificiali dovuti alla scala di misura?
- la forma suggerisce che una media possa essere fuorviante?

15.6.3. Boxplot

Il boxplot riassume la distribuzione dei dati utilizzando la mediana, i quartili e i valori potenzialmente estremi.

```
ggplot(stress_sonno, aes(y = sonno_ore)) +
  geom_boxplot() +
  labs(
    x = NULL,
    y = "Ore medie di sonno per notte",
    title = "Mediana, quartili e valori estremi"
  )
```




Figura 15.5.: Boxplot delle ore medie di sonno.

Il boxplot è compatto e robusto, ma fornisce meno dettagli sulla forma. Per questo motivo, è utile come complemento dell'istogramma e non come suo sostituto.

15.7. Variabili ordinali: numeri che non sono sempre quantità continue

Molte variabili psicologiche vengono raccolte tramite scale di risposta ordinate, ad esempio da 1 a 5 o da “per niente” a “moltissimo”. Questi valori sono numeri, ma non sempre è possibile trattarli come misure continue senza riflettere.

Nel nostro esempio, “qualità del sonno” va da 1 a 5. Possiamo contare le sue frequenze come se si trattasse di una variabile categoriale ordinata.

```
stress_sonno |>
  count(qualita_sonno)
```

```
# A tibble: 6 x 2
  qualita_sonno      n
      <dbl> <int>
1             1      9
2             2     18
3             3     47
4             4     35
5             5      9
6            NA      2
```



```
ggplot(stress_sonno, aes(x = factor(qualita_sonno))) +
  geom_bar() +
  labs(
    x = "Qualità soggettiva del sonno",
    y = "Numero di studenti",
    title = "Come si distribuiscono le risposte ordinali?"
  )
```




Figura 15.6.: Distribuzione della qualità soggettiva del sonno.

Per scale ordinali con pochi livelli, un grafico a barre è spesso più leggibile di un istogramma. La scelta del grafico deve seguire il significato della variabile, non soltanto il modo in cui R la codifica.

15.8. Confrontare una variabile numerica tra gruppi

L'esplorazione univariata può includere un primo confronto descrittivo tra i gruppi. Per esempio, si può osservare la distribuzione delle ore di sonno nei diversi anni di corso.

```
stress_sonno |>
  group_by(anno) |>
  summarise(
    n = sum(!is.na(sonno_ore)),
    mediana = median(sonno_ore, na.rm = TRUE),
    media = mean(sonno_ore, na.rm = TRUE),
    q25 = quantile(sonno_ore, .25, na.rm = TRUE),
    q75 = quantile(sonno_ore, .75, na.rm = TRUE),
    .groups = "drop"
  )
```

15. Esplorare una variabile alla volta

```
# A tibble: 3 x 6
  anno      n mediana media  q25  q75
<chr> <int>   <dbl> <dbl> <dbl> <dbl>
1 Primo    53     6.9   6.90  6.3   7.7
2 Secondo  42     7.1   6.97  6.32  7.65
3 Terzo    22     7.85  7.69  6.9   8.3
```

```
ggplot(stress_sonno, aes(x = anno, y = sonno_ore)) +
  geom_boxplot() +
  labs(
    x = "Anno di corso",
    y = "Ore medie di sonno per notte",
    title = "La distribuzione del sonno cambia tra anni di corso?"
  )
```




Figura 15.7.: Ore medie di sonno per anno di corso.

Questo grafico può suggerire delle differenze tra i vari gruppi, ma non dimostra che l'anno di corso sia la causa delle differenze nel sonno. Ci potrebbero essere molte altre variabili in gioco: il carico di lavoro, l'età, il lavoro part-time, la salute, il periodo dell'anno o la selezione del campione.

⚠ Non saltare alla causalità

Un boxplot tra gruppi può mostrare differenze descrittive. Tuttavia, ciò non è sufficiente per concludere che il gruppo abbia prodotto tali differenze.

La distinzione tra associazione e causalità verrà ripresa nel capitolo dedicato.

15.9. Quale grafico scegliere?

Non esiste un grafico migliore in assoluto. Esiste un grafico più adatto alla domanda che stai ponendo.

| Situazione | Prima scelta ragionevole | Domanda a cui risponde |
|---------------------------------------|-------------------------------|--|
| Una variabile categoriale | Grafico a barre | Quante osservazioni ci sono in ogni categoria? |
| Due variabili categoriali | Barre proporzionali o tabella | Le proporzioni cambiano tra gruppi? |
| Una variabile numerica | Istogramma | Qual è la forma della distribuzione? |
| Variabile numerica con valori estremi | Boxplot | Ci sono valori lontani dal centro? |
| Variabile ordinale con pochi livelli | Grafico a barre | Come si distribuiscono le risposte? |
| Numerica per gruppi | Boxplot o punti + boxplot | Le distribuzioni differiscono tra gruppi? |

I grafici più complessi, come i density plot, i violin plot o i beeswarm plot, possono essere utili, ma non devono diventare obbligatori. Prima è necessario saper leggere bene i grafici semplici.

15.10. Usare l'AI con criterio

Gli strumenti di IA possono generare rapidamente codice per tabelle e grafici. Questo è utile, ma non esime gli studenti dalle loro responsabilità.

Cosa puoi chiedere all'AI

Puoi chiedere, per esempio:

Scrivi codice R con `ggplot2` per visualizzare la distribuzione delle ore di sonno e controllare se ci sono valori mancanti.

Oppure:

Spiega riga per riga questo codice `dplyr` e dimmi quali osservazioni vengono escluse.

Cosa devi controllare tu

Quando l'AI propone del codice o delle interpretazioni, è sempre necessario controllare:

- se la variabile esiste davvero nel dataset;
- se il grafico è adatto al tipo di variabile;
- se i valori mancanti vengono eliminati automaticamente;
- se il codice trasforma una variabile ordinale in numerica senza discuterne la possibilità;
- se l'interpretazione confonde descrizione, associazione e causalità;
- se il testo prodotto dall'AI va oltre le informazioni fornite dai dati.

15. Esplorare una variabile alla volta

Un buon esercizio consiste nel chiedere all'AI di produrre un grafico e poi scrivere una spiegazione di tre frasi.

1. che cosa rappresenta ogni asse;
2. quale è il pattern principale che si osserva;
3. quale conclusione sarebbe invece prematura.

15.11. Cosa portare al capitolo successivo

Dopo l'esplorazione univariata, dovresti avere un'idea più chiara di ciascuna variabile:

- quali valori assume;
- quali valori mancano;
- quale forma ha la distribuzione;
- quali categorie sono frequenti o rare;
- quali grafici sono più appropriati;
- quali decisioni richiedono documentazione.

Nel capitolo sulla visualizzazione dei dati, riprenderemo questi strumenti da una prospettiva più generale: non solo quale grafico produrre, ma anche come costruire grafici che aiutino a capire senza distorcere.

Esercizi

! Esercizio 1: leggere una variabile categoriale

Usa il dataset `stress_sonno` creato nel capitolo.

1. Conta le frequenze della variabile `anno`.
2. Calcola le proporzioni.
3. Costruisci un grafico a barre.
4. Scrivi due frasi: una descrittiva e una che dica quale conclusione non puoi trarre da questo grafico.

! Esercizio 2: leggere una variabile numerica

Esplora la variabile `stress`.

1. Calcola minimo, massimo, media e mediana.
2. Costruisci un istogramma.
3. Costruisci un boxplot.
4. La media sembra un riassunto adeguato? Motiva la risposta guardando la distribuzione.

! Esercizio 3: controllare codice prodotto con AI

Chiedi a uno strumento di AI:

Scrivi codice R per visualizzare la distribuzione di `qualita_sonno`.

Poi controlla:

1. Il codice tratta `qualita_sonno` come variabile ordinale o come continua?
2. Il grafico scelto è appropriato?
3. I valori mancanti sono gestiti in modo esplicito?
4. L'interpretazione proposta resta descrittiva o suggerisce conclusioni non giustificate?

Punti chiave

Da ricordare

- Prima di cercare relazioni tra variabili, esplora ogni variabile da sola.
- Per le variabili categoriali, inizia da conteggi e proporzioni.
- Per le variabili numeriche, guarda forma, centro, variabilità e valori estremi.
- Per variabili ordinali con pochi livelli, spesso un grafico a barre è più adatto di un istogramma.
- Nessun grafico parla da solo: va interpretato in relazione alla domanda di ricerca, al disegno dello studio e alla misurazione.
- L'AI può aiutare a scrivere codice, ma sei tu a dover controllare se il codice e l'interpretazione sono appropriati.

16. Principi della visualizzazione dei dati

Grafici chiari, onesti e utili per l'EDA

Un grafico non è una semplice decorazione. È un modo per pensare con i dati. In un'analisi esplorativa dei dati, una buona visualizzazione aiuta a individuare distribuzioni, confronti, relazioni, valori inattesi e possibili errori. Una cattiva visualizzazione, invece, può nascondere proprio ciò che dovremmo controllare. In questo capitolo non impareremo nuove tecniche di programmazione. La sintassi di `ggplot2` è stata introdotta nella parte dedicata a R. Qui ci concentriamo su una domanda più importante: **Quale grafico più è adatto alla domanda che stiamo ponendo ai dati?**

16.1. Perché visualizzare i dati

Le statistiche riassuntive sono utili, ma non bastano. Una media, una deviazione standard o una correlazione possono dare l'impressione di aver compreso i dati, anche quando la distribuzione è asimmetrica, presenta valori estremi, mostra sottogruppi o suggerisce relazioni non lineari.

Prima di scegliere un riassunto numerico, è meglio guardare i dati.

Idea guida

Un grafico utile non deve necessariamente essere spettacolare. Deve aiutare a rispondere a una domanda precisa senza distorcere ciò che i dati permettono di dire.

Nel contesto di questo modulo, la visualizzazione serve soprattutto a quattro scopi:

1. **controllare i dati**, per individuare valori mancanti, errori, codifiche inattese e outlier;
2. **descrivere le variabili**, osservando distribuzioni, frequenze e differenze tra gruppi;
3. **esplorare relazioni**, prima di calcolare coefficienti o stimare modelli;
4. **comunicare risultati**, rendendo trasparente ciò che è stato osservato.

16.2. Un piccolo dataset didattico

Useremo un esempio semplice, coerente con i capitoli precedenti. Immaginiamo di avere dei dati relativi agli studenti universitari, con misure di stress accademico, qualità del sonno e sintomi depressivi.

```
library(dplyr)
library(ggplot2)
library(tibble)

set.seed(123)

eda_studenti <- tibble(
  id = 1:120,
  gruppo = rep(c("Controllo", "Intervento"), each = 60),
  stress = c(
    rnorm(60, mean = 61, sd = 10),
    rnorm(60, mean = 54, sd = 11)
  ),
  sonno = 8.2 - 0.045 * stress + rnorm(120, 0, 0.7),
  depressione = 5 + 0.22 * stress - 0.70 * sonno + rnorm(120, 0, 3)
) |>
mutate(
  stress = round(stress, 1),
  sonno = round(pmax(pmin(sonno, 10), 3), 1),
  depressione = round(pmax(depressione, 0), 1)
)

head(eda_studenti)
```

```
# A tibble: 6 x 5
   id gruppo    stress sonno depressione
<int> <chr>    <dbl> <dbl>      <dbl>
1     1 Controllo  55.4   5.8       10.8
2     2 Controllo  58.7   4.9        13
3     3 Controllo  76.6   4.4       23.3
4     4 Controllo  61.7   5.2       11.5
5     5 Controllo  62.3   6.7       13.5
6     6 Controllo  78.2   4.2       24.9
```

Questo dataset è artificiale, ma abbastanza realistico da poter discutere i principi generali. L'obiettivo non è ottenere una conclusione sostanziale, ma imparare a costruire grafici che aiutino a controllare e comprendere i dati.

16.3. Tre principi pratici

La letteratura sulla visualizzazione dei dati è molto ampia. Per questo modulo, possiamo ridurla a tre principi operativi.

16.3.1. 1. Fedeltà ai dati

Un grafico deve rappresentare i dati in modo fedele. Non dovrebbe nascondere distribuzioni, valori estremi, numerosità diverse tra gruppi o trasformazioni di scala.

Domande da porsi:

16. Principi della visualizzazione dei dati

- il grafico mostra i dati osservati o solo un riassunto?
- la scala degli assi è dichiarata?
- sono visibili eventuali outlier?
- il grafico suggerisce differenze più grandi o più piccole di quelle reali?

16.3.2. 2. Chiarezza percettiva

Non tutti i modi di rappresentare un numero sono ugualmente leggibili. Le persone confrontano bene posizioni e lunghezze; confrontano molto peggio angoli, aree e volumi.

Per questo motivo, quando l'obiettivo è confrontare delle quantità, in genere sono preferibili:

- punti su una scala comune;
- barre ordinate;
- linee per serie temporali;
- boxplot o punti individuali per confrontare le distribuzioni.

Sono invece da usare con cautela:

- grafici a torta;
- grafici tridimensionali;
- bolle molto grandi;
- doppio asse verticale;
- colori usati come unica fonte di informazione.

16.3.3. 3. Onestà interpretativa

Un grafico può essere tecnicamente corretto, ma comunque fuorviante. Ciò accade quando il grafico induce il lettore a trarre una conclusione più forte di quella giustificata dai dati.

Esempi comuni:

- un grafico suggerisce una causalità laddove c'è solo un'associazione;
- un asse troncato amplifica una piccola differenza;
- due serie sovrapposte su assi diversi sembrano correlate;
- una media nasconde distribuzioni molto diverse;
- i colori o le etichette possono orientare l'interpretazione in modo emotivo.

! Responsabilità di chi costruisce il grafico

Chi produce un grafico non è responsabile solo del codice, ma anche dell'interpretazione che il grafico stesso suggerisce.

16.4. Scegliere il grafico in base alla domanda

La scelta del grafico deve partire dalla domanda esplorativa e non dal desiderio di usare una tecnica particolare.

| Domanda | Grafico utile | Cosa controllare |
|---|------------------------------|---|
| Quanti casi ci sono in ogni categoria? | barre | categorie ordinate, etichette chiare |
| Com'è distribuita una variabile numerica? | istogramma, densità, boxplot | asimmetria, valori estremi, multimodalità |
| Due gruppi differiscono? | punti + boxplot, violin plot | sovrapposizione, numerosità, outlier |
| Due variabili variano insieme? | scatterplot | forma della relazione, sottogruppi, outlier |
| Una variabile cambia nel tempo? | line plot | scala temporale, unità osservate, trend individuali |

16.5. Mostrare la distribuzione, non solo la media

Un errore molto frequente è quello di mostrare soltanto una media per gruppo. Questo è problematico, perché gruppi con la stessa media possono avere distribuzioni molto diverse.

```
media_stress <- eda_studenti |>
  group_by(gruppo) |>
  summarise(media = mean(stress), .groups = "drop")

ggplot(media_stress, aes(x = gruppo, y = media)) +
  geom_col(width = 0.55) +
  labs(
    x = NULL,
    y = "Stress medio",
    title = "Grafico poco informativo",
    subtitle = "La media non mostra dispersione, sovrapposizione e outlier"
  ) +
  theme_minimal()
```




Figura 16.1.: Una media per gruppo nasconde la distribuzione dei dati.

Questo grafico non è sbagliato in senso stretto, ma è povero: comunica un solo numero e nasconde quasi tutto il resto.

Una versione più informativa mostra anche i dati osservati.

```
ggplot(eda_studenti, aes(x = gruppo, y = stress)) +  
  geom_jitter(width = 0.12, alpha = 0.45, size = 1.8) +  
  geom_boxplot(width = 0.35, outlier.shape = NA, alpha = 0.25) +  
  labs(  
    x = NULL,  
    y = "Stress accademico",  
    title = "Grafico più informativo",  
    subtitle = "I dati individuali rendono visibile la variabilità entro ciascun gruppo"  
  ) +  
  theme_minimal()
```




Figura 16.2.: Mostrare i punti aiuta a valutare distribuzione, sovrapposizione e valori estremi.

Questo secondo grafico non sostituisce l'analisi statistica. Tuttavia, aiuta a capire meglio cosa dovrà spiegare un eventuale modello.

16.6. Grafici fuorvianti comuni

16.6.1. Grafici a barre con errore standard

I grafici a barre con errore standard sono molto diffusi in psicologia, ma spesso non sono adatti all'EDA. Mostrano la media e la misura di incertezza o variabilità, ma nascondono la distribuzione dei dati.

Sono particolarmente problematici quando:

- il campione è piccolo;
- la distribuzione è asimmetrica.
- ci sono outlier;
- i gruppi hanno numerosità diverse;
- la sovrapposizione tra i gruppi è rilevante.

Quando possibile, è meglio mostrare i dati individuali e una sintesi robusta.

💡 Regola pratica

Se il grafico serve per esplorare i dati, prova a mostrare i dati osservati. Se mostri solo le medie, spiega cosa stai nascondendo.

16.6.2. Grafici a torta

I grafici a torta costringono il lettore a confrontare angoli e aree. Questo è difficile, soprattutto quando le categorie sono più di due o tre.

Confrontiamo due rappresentazioni della stessa informazione.

```
frequenze <- tibble(
  livello = c("Basso", "Medio", "Alto"),
  n = c(28, 63, 29)
) |>
  mutate(livello = factor(livello, levels = c("Basso", "Medio", "Alto")))

p_torta <- ggplot(frequenze, aes(x = "", y = n, fill = livello)) +
  geom_col(width = 1) +
  coord_polar(theta = "y") +
  labs(title = "Grafico a torta", fill = "Stress") +
  theme_void()

p_barre <- ggplot(frequenze, aes(x = livello, y = n)) +
  geom_col(width = 0.65) +
  labs(title = "Barre ordinate", x = "Livello di stress", y = "Numero di studenti") +
  theme_minimal()

p_torta
p_barre
```

Grafico a torta




Figura 16.3.: Le barre ordinate rendono il confronto più chiaro di un grafico a torta.




Figura 16.4.: Le barre ordinate rendono il confronto più chiaro di un grafico a torta.

Nel secondo grafico, il confronto è più diretto: basta confrontare le lunghezze su una scala comune.

16.6.3. Assi troncati

Un asse troncato può essere legittimo in alcuni casi, ma deve essere dichiarato chiaramente. Nei grafici a barre, troncare l'asse verticale è spesso fuorviante, in quanto la lunghezza della barra viene interpretata come proporzionale al valore.

```
confronto <- tibble(  
  gruppo = c("A", "B"),  
  media = c(52, 56)  
)  
  
ggplot(confronto, aes(x = gruppo, y = media)) +  
  geom_col(width = 0.55) +
```

```
coord_cartesian(ylim = c(50, 57)) +
labs(
  x = NULL,
  y = "Punteggio medio",
  title = "Attenzione agli assi troncati",
  subtitle = "La differenza appare più grande perché l'asse non parte da zero"
) +
theme_minimal()
```




Figura 16.5.: Un asse troncato può amplificare visivamente differenze modeste.

Il problema non è che il grafico sia sempre vietato. Il problema è che il lettore deve capire subito che la scala è stata ristretta.

16.6.4. Doppio asse verticale

I grafici con due assi verticali permettono di sovrapporre serie misurate su scale diverse. Il rischio è che due linee sembrano collegate solo perché le scale sono state scelte in modo opportuno.

Per confrontare variabili su scale diverse, di solito è meglio:

- usare pannelli separati;
- standardizzare le variabili;
- dichiarare esplicitamente che le scale non sono confrontabili;
- evitare di suggerire causalità o correlazione da una semplice somiglianza visiva.

16.6.5. Effetti tridimensionali

Gli effetti tridimensionali sono raramente utili nei grafici EDA. Spesso, invece, deformano le lunghezze e le aree, rendono meno leggibili i valori e attirano l'attenzione sulla forma del grafico piuttosto che sui dati.

Regola pratica: se la terza dimensione non rappresenta una variabile, non serve.

16.7. Colore: usare poco, usare bene

Il colore può aiutare a distinguere gruppi, indicare un ordine o evidenziare un valore importante. Ma può anche confondere.

Tre usi frequenti:

1. **Categorie distinte:** colori diversi per gruppi senza ordine naturale.
2. **Valori ordinati:** gradiente chiaro-scuro per quantità crescenti.
3. **Deviazioni da un riferimento:** due colori divergenti intorno a un valore centrale.

Errori comuni:

- usare troppi colori;
- usare il colore solo come elemento decorativo.
- usare solo il rosso e il verde come distinzione;
- usare palette arcobaleno per dati ordinati;
- non verificare la comprensibilità del grafico in scala di grigi.



Controllo rapido

Se il grafico diventa incomprensibile senza colori, probabilmente il colore svolge un lavoro eccessivo. Usa anche la posizione, la forma, le etichette o i pannelli.

16.8. Trasformazioni di scala

Le trasformazioni di scala possono essere utili. Una scala logaritmica, per esempio, può rendere leggibili variabili molto asimmetriche o relazioni moltiplicative.

Tuttavia, ogni trasformazione deve sempre essere dichiarata. In caso contrario, può diventare una forma di manipolazione visiva.

Una trasformazione è ragionevole quando:

- rende visibile un pattern che nella scala originale era nascosto;
- è coerente con la natura della variabile;
- è chiaramente indicata negli assi o nella didascalia.
- non viene utilizzata per far sembrare più forte una conclusione.



Da ricordare

Una scala trasformata non è sbagliata. È sbagliato usarla senza spiegarla.

16.9. Usare l'AI con criterio

Gli strumenti di IA possono produrre rapidamente il codice per i grafici, suggerire palette di colori, correggere gli errori sintattici e proporre alternative. Questo è utile, ma non esime dalla responsabilità di valutare il grafico.

Quando l'AI propone un grafico, è sempre necessario controllare:

- le variabili usate esistono davvero nel dataset?
- il grafico è adatto al tipo di variabile?
- sono stati eliminati i casi con valori mancanti? Quanti?
- il grafico mostra i dati o solo i loro riassunti?
- le scale sono oneste e dichiarate?
- il titolo interpreta correttamente il risultato?
- il grafico suggerisce una causalità laddove c'è solo un'associazione?

! Prompt utile

Dopo aver chiesto all'AI di produrre un grafico, chiedi anche:

Spiega riga per riga che cosa fa questo codice e indica tre possibili modi in cui il grafico potrebbe essere fuorviante.

16.10. Checklist per valutare un grafico

Prima di includere un grafico in un report, usa questa checklist.

💡 Checklist

16.10.1. Domanda

- ☐ Il grafico risponde a una domanda chiara?
- ☐ Il titolo aiuta a capire che cosa guardare?
- ☐ Le variabili sono nominate in modo comprensibile?

16.10.2. Dati

- ☐ Il grafico mostra i dati osservati quando è utile farlo?
- ☐ Sono visibili outlier o valori inattesi?
- ☐ La numerosità dei gruppi è chiara o ricavabile?
- ☐ I valori mancanti sono stati gestiti in modo documentato?

16.10.3. Forma grafica

- ☐ Il tipo di grafico è adatto al tipo di variabile?
- ☐ Le categorie sono ordinate in modo sensato?
- ☐ Le scale sono dichiarate e non fuorvianti?
- ☐ Si evitano effetti tridimensionali, doppio asse e decorazioni inutili?

16.10.4. Interpretazione

- ☐ Il grafico non suggerisce causalità senza disegno adeguato?

- ☐ Le trasformazioni di scala sono dichiarate?
- ☐ Il colore non è l'unico modo per distinguere informazioni importanti?
- ☐ Il grafico rimane comprensibile anche senza spiegazioni orali?

16.11. Cosa portare al capitolo successivo

Una buona visualizzazione non serve solo a comunicare risultati già noti. È utile anche per decidere quali riassunti numerici sono più appropriati.

Prima di calcolare la media, la mediana, la deviazione standard o gli intervalli, dobbiamo chiederci:

- la distribuzione è simmetrica o asimmetrica?
- ci sono valori estremi?
- i gruppi hanno forme simili o diverse?
- Un singolo numero riassume davvero ciò che vediamo?

Il capitolo successivo utilizzerà queste domande per discutere la tendenza centrale e la variabilità.

Esercizi

! Esercizio 1: leggere un grafico

Scegli un grafico prodotto in un report, in un articolo o online.
Rispondi:

1. Qual è la domanda a cui il grafico dovrebbe rispondere?
2. Quali variabili sono rappresentate?
3. Che tipo di confronto viene richiesto al lettore?
4. Il grafico mostra i dati o solo un riassunto?
5. C'è qualcosa che potrebbe indurre a un'interpretazione eccessiva?

! Esercizio 2: migliorare un grafico

Prendi un grafico a barre con una media per gruppo.
Costruisci una versione più informativa che mostri anche:

1. i dati individuali;
2. una sintesi della distribuzione;
3. etichette chiare degli assi;
4. un titolo che descriva la domanda, non solo la variabile.

Scrivi due frasi per spiegare perché la nuova versione è migliore.

! Esercizio 3: controllare un grafico prodotto con AI

Chiedi a uno strumento di AI di produrre un grafico per confrontare due gruppi.
Poi valuta il risultato con la checklist del capitolo. In particolare, controlla:

1. se il codice usa le variabili corrette;

2. se il grafico è adatto alla domanda;
3. se i dati mancanti sono gestiti in modo esplicito;
4. se il titolo o la descrizione suggeriscono una conclusione troppo forte.

17. Indicatori di tendenza centrale e variabilità

Nel capitolo precedente abbiamo visto come scegliere e leggere un grafico. In questo capitolo faremo un passo avanti: impareremo a sintetizzare una distribuzione con pochi numeri, senza perdere di vista la sua forma.

Le statistiche descrittive non sostituiscono i grafici. Sono utili per riassumere ciò che abbiamo osservato nei dati quando il riassunto è appropriato.

Perché questo capitolo è centrale

Quando descriviamo una variabile psicologica, spesso vogliamo rispondere a due domande:

1. **Dove si concentrano i valori?**

Questa è la domanda sulla *tendenza centrale*.

2. **Quanto sono diversi tra loro i valori?**

Questa è la domanda sulla *variabilità*.

Per esempio, se misuriamo la qualità del sonno in un gruppo di studenti, non basta dire che il punteggio medio è 6.8. Dobbiamo anche chiederci:

- tutti gli studenti dormono più o meno allo stesso modo, oppure ci sono grandi differenze?
- la distribuzione è simmetrica o asimmetrica?
- ci sono valori estremi?
- la media rappresenta bene i dati, oppure sarebbe più prudente usare la mediana?
- la deviazione standard descrive bene la variabilità, oppure è meglio usare l'intervallo inter-quartile o il MAD?

Questo capitolo segue quindi l'esplorazione univariata e precede la distribuzione normale. Prima analizziamo i dati, poi scegliamo un riassunto e solo dopo possiamo chiederci se un modello, come la distribuzione normale, sia una rappresentazione utile.

Obiettivi del capitolo

Al termine del capitolo dovresti essere in grado di:

- distinguere moda, mediana e media;
- capire quando la media è informativa e quando può essere fuorviante;
- distinguere range, IQR, deviazione standard e MAD;
- scegliere riassunti coerenti con la forma della distribuzione;
- leggere e controllare il codice R usato per calcolare le statistiche descrittive;
- evitare interpretazioni automatiche prodotte da AI senza prima controllare i dati.

💡 Idea guida

Non esiste una statistica descrittiva sempre migliore delle altre. Esiste una statistica più o meno adatta alla domanda, al tipo di variabile e alla forma della distribuzione.

17.1. Preparazione

Useremo un piccolo dataset didattico. I dati sono simulati, ma rappresentano un caso realistico: studenti universitari, stress accademico, qualità del sonno e ore di sonno.

```
studenti <- data.frame(
  id = 1:60,
  stress = round(pmin(pmax(rnorm(60, mean = 6.2, sd = 1.5), 1), 10), 1),
  sonno_qualita = round(pmin(pmax(rnorm(60, mean = 6.5, sd = 1.3), 1), 10), 1),
  ore_sonno = round(pmin(pmax(rnorm(60, mean = 7.1, sd = 0.9), 4), 10), 1)
)

# Aggiungiamo alcuni valori plausibili ma estremi.
studenti$ore_sonno[c(4, 17)] <- c(4.1, 9.8)
studenti$stress[c(22, 49)] <- c(9.7, 9.9)

head(studenti)
```

| | id | stress | sonno_qualita | ore_sonno |
|---|----|--------|---------------|-----------|
| 1 | 1 | 4.4 | 7.4 | 6.9 |
| 2 | 2 | 6.6 | 9.8 | 6.4 |
| 3 | 3 | 7.8 | 6.5 | 9.0 |
| 4 | 4 | 2.7 | 5.6 | 4.1 |
| 5 | 5 | 6.8 | 6.5 | 8.7 |
| 6 | 6 | 7.0 | 8.8 | 7.2 |

17.2. Prima regola: guardare prima di riassumere

Prima di calcolare media, mediana o deviazione standard, guardiamo la distribuzione.

```
ggplot(studenti, aes(x = ore_sonno)) +
  geom_histogram(bins = 12, boundary = 0) +
  labs(
    x = "Ore di sonno",
    y = "Frequenza"
  )
```




Figura 17.1.: Distribuzione delle ore di sonno nel campione didattico.

Il grafico ci aiuta a capire se i dati sono concentrati, dispersi, simmetrici, asimmetrici o se presentano valori insoliti. Senza questa informazione, una statistica descrittiva rischia di diventare un numero isolato.

🔥 Errore comune

Un errore frequente è calcolare automaticamente `mean()` e `sd()` per ogni variabile numerica. Questo può essere utile per una prima esplorazione, ma non basta: è sempre necessario verificare che la distribuzione giustifichi quel tipo di riassunto.

17.3. Tendenza centrale: qual è il valore tipico?

Gli indicatori di tendenza centrale cercano di individuare un valore rappresentativo della distribuzione.

I tre indicatori principali sono:

- **moda**: il valore più frequente;
- **mediana**: il valore che divide i dati ordinati in due metà;
- **media**: la somma dei valori divisa per il numero di osservazioni.

17.3.1. Moda

La **moda** è il valore che compare più spesso. È particolarmente utile per le variabili categoriali.

Per esempio, se si chiede agli studenti quale strategia usano più spesso per gestire lo stress, la moda indica la risposta più frequente.

```
strategie <- c(
  "studio", "sonno", "sport", "studio", "amici", "studio",
  "sport", "sonno", "studio", "amici", "studio"
)

table(strategie)
```

```
strategie
 amici  sonno  sport studio
      2     2     2     5
```

In questo caso la moda è la categoria con frequenza più alta.

i Quando usare la moda

La moda è utile quando si vuole descrivere la categoria più comune. È meno utile quando i valori sono molti e ciascuno compare poche volte, come spesso accade con le variabili continue.

17.3.2. Mediana

La **mediana** è il valore centrale dei dati ordinati. Il 50% delle osservazioni è minore o uguale alla mediana e il restante 50% è maggiore o uguale.

```
median(studenti$ore_sonno)
```

```
[1] 7.1
```

La mediana è robusta, ovvero non cambia molto se sono presenti pochi valori estremi. Per questo motivo, è spesso adatta a distribuzioni asimmetriche o con outlier.

17.3.3. Media

La **media aritmetica** si calcola sommando tutti i valori e dividendo il risultato per il numero di osservazioni.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

In R:

```
mean(studenti$ore_sonno)
```

```
[1] 7.19
```

La media utilizza tutti i valori, pertanto è molto informativa quando la distribuzione è abbastanza simmetrica e priva di valori estremi. Proprio perché utilizza tutti i valori, però, è sensibile agli outlier.

17.4. Media e mediana a confronto

Confrontiamo la media e la mediana di alcune variabili del dataset.

```
studenti |>
  summarise(
    media_stress = mean(stress),
    mediana_stress = median(stress),
    media_sonno = mean(ore_sonno),
    mediana_sonno = median(ore_sonno)
  )
```

| | media_stress | mediana_stress | media_sonno | mediana_sonno |
|---|--------------|----------------|-------------|---------------|
| 1 | 5.706667 | 5.4 | 7.19 | 7.1 |

Quando la media e la mediana sono simili, la distribuzione è spesso abbastanza bilanciata. Quando sono molto diverse, è meglio tornare al grafico e chiedersi il perché.

17.4.1. L'effetto dei valori estremi

Consideriamo due piccoli insiemi di dati. Il secondo contiene un valore molto alto.

```
sonno_a <- c(6.2, 6.5, 6.8, 7.0, 7.1, 7.3, 7.5)
sonno_b <- c(6.2, 6.5, 6.8, 7.0, 7.1, 7.3, 12.0)

data.frame(
  scenario = c("senza valore estremo", "con valore estremo"),
  media = c(mean(sonno_a), mean(sonno_b)),
  mediana = c(median(sonno_a), median(sonno_b))
)
```

| | scenario | media | mediana |
|---|----------------------|----------|---------|
| 1 | senza valore estremo | 6.914286 | 7 |
| 2 | con valore estremo | 7.557143 | 7 |

La media cambia più della mediana. Ciò non significa che la media sia sbagliata. Significa che la media risponde a una domanda diversa: tiene conto anche dell'intensità del valore estremo.

Regola pratica

Se la distribuzione è simmetrica e non presenta valori estremi, la media e la deviazione standard possono essere un buon riassunto. Se la distribuzione è asimmetrica o presenta valori estremi, la mediana e l'intervallo interquartile (IQR) sono spesso più affidabili.

17.5. Variabilità: quanto differiscono i valori?

Un valore centrale non basta. Due distribuzioni possono avere la stessa media, ma una variabilità molto diversa.

Immaginiamo due gruppi di studenti con una media simile di ore di sonno. Nel primo gruppo tutti dormono circa sette ore, mentre nel secondo alcuni dormono pochissimo e altri molto. La media può essere la stessa, ma il significato psicologico è diverso.

17.5.1. Range

Il **range** è la differenza tra valore massimo e valore minimo:

$$\text{range} = \max(x) - \min(x).$$

```
range(studenti$ore_sonno)
```

```
[1] 4.1 9.8
```

```
diff(range(studenti$ore_sonno))
```

```
[1] 5.7
```

Il range è semplice, ma dipende solo da due valori. Per questo è molto sensibile agli estremi.

17.5.2. Quartili e intervallo interquartile

I **quartili** dividono la distribuzione in quattro parti. L'intervallo interquartile, o **IQR**, è la differenza tra il terzo quartile e il primo quartile:

$$IQR = Q_3 - Q_1.$$

L'IQR descrive l'ampiezza della metà centrale dei dati.

```
quantile(studenti$ore_sonno, probs = c(.25, .50, .75))
```

```
25% 50% 75%  
6.5 7.1 7.7
```

```
IQR(studenti$ore_sonno)
```

```
[1] 1.2
```

L'intervallo interquartile (IQR) è utile quando si desidera ottenere una misura robusta della variabilità, meno influenzata dai valori estremi rispetto al range.

17.5.3. Deviazione standard

La **deviazione standard** descrive quanto i valori tendono a distanziarsi dalla media.

```
sd(studenti$ore_sonno)
```

```
[1] 1.06177
```

La deviazione standard è espressa nella stessa unità di misura della variabile. Se la variabile è misurata in ore, anche la deviazione standard sarà espressa in ore.

In R, la funzione `sd()` calcola la deviazione standard campionaria, utilizzando al denominatore $n - 1$. Questo è coerente con l'idea che stiamo utilizzando un campione per descrivere una popolazione più ampia.

Interpretazione intuitiva

La deviazione standard può essere interpretata come la distanza tipica dei valori dalla media. Questa lettura è più affidabile quando la distribuzione è abbastanza simmetrica e non presenta valori estremi marcati.

17.5.4. Varianza

La **varianza** è il quadrato della deviazione standard:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

In R:

```
var(studenti$ore_sonno)
```

```
[1] 1.127356
```

```
sd(studenti$ore_sonno)^2
```

```
[1] 1.127356
```

La varianza è importante in molti modelli statistici, ma è meno intuitiva della deviazione standard, in quanto è espressa in unità al quadrato. Per la descrizione iniziale dei dati, di solito è più interpretabile la deviazione standard.

17.5.5. MAD: una misura robusta di variabilità

La **deviazione mediana assoluta**, o **MAD**, misura la distanza tipica dei valori dalla mediana:

$$MAD = \text{mediana}(|x_i - \text{mediana}(x)|).$$

In R:

```
mad(studenti$ore_sonno)
```

```
[1] 0.88956
```

Il MAD è robusto rispetto agli outlier. È utile quando la deviazione standard risulterebbe troppo influenzata da pochi valori estremi.

17.6. Un confronto visivo

Mettiamo insieme il grafico e le statistiche descrittive.

```
studenti |>
  summarise(
    n = n(),
    media = mean(ore_sonno),
    mediana = median(ore_sonno),
    sd = sd(ore_sonno),
    iqr = IQR(ore_sonno),
    mad = mad(ore_sonno),
    minimo = min(ore_sonno),
    massimo = max(ore_sonno)
  )
```

| | n | media | mediana | sd | iqr | mad | minimo | massimo |
|---|----|-------|---------|---------|-----|---------|--------|---------|
| 1 | 60 | 7.19 | 7.1 | 1.06177 | 1.2 | 0.88956 | 4.1 | 9.8 |

```
ggplot(studenti, aes(y = ore_sonno)) +
  geom_boxplot() +
  labs(
    x = NULL,
    y = "Ore di sonno"
  )
```




Figura 17.2.: Distribuzione delle ore di sonno con boxplot.

Il boxplot mostra la mediana, i quartili e i possibili valori estremi. Per questo motivo è particolarmente utile quando si vuole mettere in relazione la tendenza centrale e la variabilità.

17.7. Quale riassunto scegliere?

La scelta non dipende solo dalla praticità del calcolo. Dipende dalla variabile, dalla distribuzione e dalla domanda.

| Situazione | Riassunto consigliato | Motivo |
|--|---------------------------------|--|
| Variabile categoriale | Frequenze e moda | La media non ha significato |
| Distribuzione numerica simmetrica | Media e deviazione standard | Riassumono bene centro e dispersione |
| Distribuzione asimmetrica | Mediana e IQR | Sono più robusti |
| Presenza di valori estremi | Mediana, IQR, MAD | Riduce l'influenza degli outlier |
| Confronto tra gruppi | Centro + variabilità per gruppo | La sola media può nascondere differenze importanti |
| Scala ordinale breve, come molti item Likert | Frequenze, mediana, IQR | Le distanze tra categorie non sono sempre interpretabili come uguali |

! Non riportare mai solo un numero

Un riassunto numerico dovrebbe essere accompagnato da almeno una descrizione della distribuzione. Dire “la media è 6,8” è molto meno informativo rispetto a “la distribuzione è abbastanza simmetrica, senza outlier evidenti; per questo motivo riportiamo la media e la deviazione standard”.

17.8. Descrivere gruppi senza dimenticare gli individui

In psicologia, lavoriamo spesso con le medie di gruppo. Questo è utile, ma può diventare fuorviante se dimentichiamo la variabilità individuale.

```
studenti <- studenti |>
  mutate(
    gruppo_stress = if_else(stress >= median(stress), "stress alto", "stress basso")
  )

studenti |>
  group_by(gruppo_stress) |>
  summarise(
    n = n(),
    media_sonno = mean(ore_sonno),
    mediana_sonno = median(ore_sonno),
    sd_sonno = sd(ore_sonno),
    iqr_sonno = IQR(ore_sonno),
    .groups = "drop"
  )
```

```
# A tibble: 2 x 6
  gruppo_stress      n media_sonno mediana_sonno sd_sonno iqr_sonno
  <chr>         <int>      <dbl>         <dbl>      <dbl>      <dbl>
1 stress alto     31        7.22           6.9        1.03        1.4
2 stress basso    29        7.16           7.2        1.11        0.8
```

```
ggplot(studenti, aes(x = gruppo_stress, y = ore_sonno)) +
  geom_boxplot() +
  geom_jitter(width = 0.12, alpha = 0.6) +
  labs(
    x = NULL,
    y = "Ore di sonno"
  )
```




Figura 17.3.: Ore di sonno nei gruppi a stress basso e alto.

Il confronto tra i gruppi è più informativo quando affianchiamo alla media o alla mediana la dispersione dei valori. Due gruppi possono differire nella media, ma sovrapporsi molto. Oppure possono avere una media simile, ma una variabilità diversa.

i Nota epistemologica

La media di un gruppo non descrive necessariamente ogni singolo individuo. Questo punto è particolarmente importante in psicologia, dove i processi individuali possono differire notevolmente anche quando la media aggregata sembra chiara.

17.9. Usare l'AI con criterio

L'AI può aiutare a scrivere il codice necessario per calcolare le statistiche descrittive. Per esempio, può generare una tabella con la media, la mediana, la deviazione standard e l'intervallo interquartile per più variabili.

Questo è utile, ma non sufficiente. Lo studente deve controllare che le variabili siano del tipo corretto.

- se le variabili sono del tipo corretto;
- se i valori mancanti sono gestiti esplicitamente;
- se la media è appropriata per la distribuzione osservata;
- se l'AI sta usando la funzione `sd()` senza spiegare che cosa misura;
- se vengono esclusi i casi con NA senza documentarlo;
- se il riassunto numerico è accompagnato da un grafico.

 Prompt utile

Chiedi all'AI: "Scrivi il codice R per calcolare la media, la mediana, la deviazione standard, l'intervallo interquartile e il numero di valori mancanti per queste variabili. Spiegami poi quali controlli devo fare prima di interpretare la media".

 Controllo obbligatorio

Non accettare una tabella descrittiva prodotta dall'AI senza prima aver guardato almeno un grafico della distribuzione. L'AI può calcolare numeri corretti, ma suggerire comunque un riassunto poco adatto.

17.10. Collegamento con la distribuzione normale

Il capitolo successivo introduce la distribuzione normale. Questo collegamento è naturale, in quanto la distribuzione normale è descritta da due parametri: la media e la deviazione standard.

Tuttavia, l'obiettivo non è verificare meccanicamente se i dati sono "normali". L'obiettivo è capire quando la media e la deviazione standard sono un riassunto adeguato e quando, invece, la distribuzione richiede strumenti più robusti o modelli diversi.

La distribuzione normale è un modello utile in molti contesti, ma non è una legge che i dati devono rispettare.

Checklist finale

Prima di riportare le statistiche descrittive, chiediti:

- Ho verificato la distribuzione?
- La variabile è categoriale, ordinale o numerica?
- Ci sono valori mancanti?
- Ci sono valori estremi o inattesi?
- La media e la mediana sono simili o molto diverse?
- La deviazione standard è interpretabile per questa distribuzione?
- Sarebbe meglio riportare la mediana e l'intervallo interquartile?
- Ho documentato eventuali esclusioni o ricodifiche?
- Il riassunto risponde davvero alla domanda di ricerca?

Esercizi

 Problemi

1. Lettura concettuale

Spiega la differenza tra media e mediana. Perché la mediana è più robusta in presenza di valori estremi?

2. Scelta del riassunto

Una variabile misura il numero di ore settimanali dedicate allo studio. La distribuzione è

molto asimmetrica: molti studenti studiano poche ore, pochi studenti studiano moltissime ore. Quale riassunto useresti? Perché?

3. Interpretazione della variabilità

Due gruppi hanno la stessa media di qualità del sonno, ma il primo ha deviazione standard molto più alta. Come interpreteresti questa differenza?

4. Controllo del codice AI

L'AI propone questo codice:

```
studenti |>
  summarise(across(c(stress, sonno_qualita, ore_sonno),
                    list(media = mean, sd = sd)))
```

Quali controlli mancano prima di interpretare i risultati?

5. Modifica del codice

Modifica il codice precedente in modo da includere anche mediana, IQR e numero di valori mancanti.

6. Interpretazione prudente

In un report leggi: “La media dello stress è 6.2, quindi gli studenti sono moderatamente stressati”. Perché questa frase è incompleta?

Soluzioni orientative

1. La media usa tutti i valori ed è sensibile agli estremi. La mediana dipende dalla posizione dei valori ordinati ed è quindi più stabile quando pochi valori sono molto grandi o molto piccoli.
2. In una distribuzione molto asimmetrica è spesso preferibile riportare mediana e IQR, accompagnati da un grafico. La media potrebbe essere trascinata dai valori molto alti.
3. La stessa media non implica la stessa esperienza individuale. Nel gruppo con deviazione standard più alta gli studenti sono più eterogenei: alcuni dormono molto meglio o molto peggio di altri.
4. Mancano il controllo dei valori mancanti, il confronto con la mediana, una misura robusta come IQR o MAD, e soprattutto un grafico della distribuzione.
5. Una possibile soluzione:

```
studenti |>
  summarise(across(
    c(stress, sonno_qualita, ore_sonno),
    list(
      n_missing = ~sum(is.na(.x)),
      media = ~mean(.x, na.rm = TRUE),
      mediana = ~median(.x, na.rm = TRUE),
      sd = ~sd(.x, na.rm = TRUE),
      iqr = ~IQR(.x, na.rm = TRUE)
    )
  ))
```

6. La frase non dice come sono distribuiti i valori, quanta variabilità c'è, se esistono gruppi molto diversi o valori estremi. Inoltre interpreta la media come se rappresentasse automaticamente tutti gli studenti.

i Informazioni sull'ambiente di sviluppo

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
```

```
Platform: aarch64-apple-darwin23
```

```
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Rome
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
other attached packages:
```

```
[1] ggplot2_4.0.3 dplyr_1.2.1
```

```
loaded via a namespace (and not attached):
```

```
[1] vctrs_0.7.3      cli_3.6.6        knitr_1.51       rlang_1.3.0
[5] xfun_0.60        otel_0.2.0       generics_0.1.4   S7_0.2.2
[9] jsonlite_2.0.0   labeling_0.4.3   glue_1.8.1       htmltools_0.5.9
[13] scales_1.4.0     rmarkdown_2.31  grid_4.6.1       evaluate_1.0.5
[17] tibble_3.3.1     fastmap_1.2.0   yaml_2.3.12      lifecycle_1.0.5
[21] compiler_4.6.1   RColorBrewer_1.1-3 pkgconfig_2.0.3  farver_2.1.2
[25] digest_0.6.39    R6_2.6.1         utf8_1.2.6       tidyselect_1.2.1
[29] pillar_1.11.1    magrittr_2.0.5   withr_3.0.3      tools_4.6.1
[33] gtable_0.3.6
```

Bibliografia

18. Introduzione alla distribuzione normale

La distribuzione normale è uno dei modelli più importanti della statistica. In questo capitolo, tuttavia, la useremo con cautela, non come una legge che i dati devono rispettare, ma come una forma di riferimento utile per descrivere alcune distribuzioni, interpretare la media e la deviazione standard, riconoscere i valori anomali e preparare il passaggio alla modellizzazione. L'idea centrale è semplice: in alcuni casi, una distribuzione normale può essere una buona approssimazione, ma molti dati psicologici reali sono asimmetrici, discreti, limitati da scale di risposta, presentano valori mancanti o sono influenzati dal disegno dello studio. Prima di assumere la normalità, è necessario osservare i dati.

Cosa imparerai

Al termine del capitolo dovresti essere in grado di:

- riconoscere la forma di una distribuzione normale;
- comprendere il ruolo della media e della deviazione standard;
- usare la regola 68-95-99,7 per dare un significato intuitivo alla variabilità;
- interpretare uno z-score come posizione relativa di un valore;
- usare istogrammi e QQ-plot per valutare se una distribuzione è compatibile con un modello normale;
- spiegare perché la distribuzione normale è un modello utile, ma non un obbligo.

Prerequisiti

Per seguire il capitolo è utile avere letto:

- il capitolo sulla misurazione;
- il capitolo sull'esplorazione univariata;
- il capitolo su media, mediana, deviazione standard e variabilità.

Non è necessario conoscere la formula matematica della distribuzione normale. Qui useremo soprattutto grafici, intuizioni e piccoli esempi in R.

18.1. Perché parlare di distribuzione normale in EDA?

Nell'analisi esplorativa dei dati la distribuzione normale serve soprattutto come **modello di confronto**.

Quando una variabile continua presenta una distribuzione approssimativamente normale, la media e la deviazione standard diventano riassunti particolarmente informativi. Se invece la distribuzione è fortemente asimmetrica, presenta code pesanti, valori estremi o limiti artificiali, la media e la

deviazione standard potrebbero non essere rappresentative e potrebbero essere preferibili la mediana, l'intervallo interquartile (IQR) o grafici più dettagliati.

La domanda, quindi, non è:

I dati sono normali?

ma:

La distribuzione normale è una descrizione sufficientemente utile per lo scopo di questa analisi?

Questa differenza è importante. Cercare la normalità perfetta è inutile, perché i dati reali raramente la mostrano. Valutare se la normalità è un'approssimazione ragionevole è invece una competenza centrale dell'EDA.

! La normale è un modello

Una distribuzione normale non è una proprietà magica dei dati. Si tratta di un modello, una rappresentazione semplificata della variabilità. Può essere utile, ma deve essere confrontata con i dati osservati.

18.2. La forma della normale

La distribuzione normale ha una forma a campana. È:

- **simmetrica** intorno alla media;
- **unimodale**, ovvero presenta un solo picco;
- più alta al centro e progressivamente più bassa verso le code;
- è descritta da due parametri: la media e la deviazione standard.

La **media** stabilisce dove si trova il centro della distribuzione. La **deviazione standard** stabilisce quanto i valori sono dispersi intorno al centro.

```
x <- seq(-6, 10, length.out = 1000)

normal_curves <- tibble(
  x = x,
  `media = 0, sd = 1` = dnorm(x, mean = 0, sd = 1),
  `media = 3, sd = 1` = dnorm(x, mean = 3, sd = 1),
  `media = 3, sd = 2` = dnorm(x, mean = 3, sd = 2)
) |>
  tidyr::pivot_longer(~x, names_to = "distribuzione", values_to = "densita")

ggplot(normal_curves, aes(x = x, y = densita, colour = distribuzione)) +
  geom_line(linewidth = 1) +
  labs(
    x = "Valore",
    y = "Densità",
    colour = NULL
  ) +
  theme_minimal()
```




Figura 18.1.: Tre distribuzioni normali con media e deviazione standard diverse.

Nel grafico:

- spostare la media sposta la curva a destra o a sinistra;
- aumentare la deviazione standard rende la curva più larga e più bassa;
- ridurre la deviazione standard rende la curva più stretta e più alta.

i Densità, non frequenza

Nei grafici della distribuzione normale l'asse verticale indica una densità, non il numero di osservazioni. L'informazione importante non è l'altezza di un singolo punto, ma l'area sotto la curva in un intervallo. La probabilità totale sotto la curva è pari a 1.

18.3. Un esempio psicologico: punteggi di stress

Supponiamo di aver raccolto il punteggio di stress accademico di un gruppo di studenti. Il punteggio varia da 0 a 100. In questo esempio simulato, la distribuzione è abbastanza simmetrica: molti studenti hanno valori intermedi, mentre pochi hanno valori molto bassi o molto alti.

```
normal_reference <- tibble(
  stress = seq(min(eda_stress$stress), max(eda_stress$stress), length.out = 300),
  densita = dnorm(stress, mean = stress_media, sd = stress_sd)
)

ggplot(eda_stress, aes(x = stress)) +
  geom_histogram(aes(y = after_stat(density)), bins = 18, fill = "grey85", colour = "white") +
  geom_line(data = normal_reference, aes(y = densita), linewidth = 1) +
```

```
labs(
  x = "Punteggio di stress",
  y = "Densità"
) +
theme_minimal()
```




Figura 18.2.: Distribuzione simulata dei punteggi di stress e curva normale con stessa media e deviazione standard.

Il grafico non dimostra che i dati siano “normali”. Mostra soltanto che una curva normale con la stessa media e la stessa deviazione standard segue abbastanza bene la forma generale dell’istogramma. Per l’EDA questo è spesso sufficiente: fornisce una prima indicazione su come interpretare il centro, la variabilità e i valori estremi.

18.4. La regola 68–95–99.7

Se una variabile segue una distribuzione normale, allora:

- circa il **68%** dei valori si trova entro una deviazione standard dalla media;
- circa il **95%** dei valori si trova entro due deviazioni standard dalla media;
- circa il **99.7%** dei valori si trova entro tre deviazioni standard dalla media.

Questa regola rende più concreta la deviazione standard. Non si tratta solo di un numero astratto, ma di una distanza tipica dalla media.

```

standard_normal <- tibble(
  z = seq(-4, 4, length.out = 1000),
  densita = dnorm(z)
)

ggplot(standard_normal, aes(x = z, y = densita)) +
  geom_line(linewidth = 1) +
  geom_area(data = filter(standard_normal, z >= -1, z <= 1), fill = "grey70", alpha = .60) +
  geom_area(data = filter(standard_normal, z < -1, z >= -2), fill = "grey80", alpha = .55) +
  geom_area(data = filter(standard_normal, z > 1, z <= 2), fill = "grey80", alpha = .55) +
  geom_area(data = filter(standard_normal, z < -2, z >= -3), fill = "grey90", alpha = .55) +
  geom_area(data = filter(standard_normal, z > 2, z <= 3), fill = "grey90", alpha = .55) +
  geom_vline(xintercept = -3:3, linetype = "dashed", linewidth = .3) +
  annotate("text", x = 0, y = .22, label = "68%") +
  annotate("text", x = 1.5, y = .10, label = "95%") +
  annotate("text", x = 2.5, y = .035, label = "99.7%") +
  scale_x_continuous(breaks = -3:3, labels = c("-3 sd", "-2 sd", "-1 sd", "media", "+1 sd", "+2 sd", "+3 sd")) +
  labs(x = "Distanza dalla media", y = "Densità") +
  theme_minimal()

```




Figura 18.3.: La regola 68–95–99.7 nella normale standard.

Nel nostro esempio, la media del punteggio di stress è 55.3 e la deviazione standard è 11.9. Se la distribuzione normale è una buona approssimazione, ci si aspetta che la maggior parte degli studenti abbia valori compresi tra:

| Intervallo | Limite_inferiore | Limite_superiore | Proporzione_attesa |
|------------------|------------------|------------------|--------------------|
| media $\pm$ 1 sd | 43.4 | 67.2 | circa 68% |
| media $\pm$ 2 sd | 31.4 | 79.1 | circa 95% |
| media $\pm$ 3 sd | 19.5 | 91.0 | circa 99.7% |

⚠ La regola vale per la normale

La regola 68-95-99.7 è utile solo quando la distribuzione è ragionevolmente simmetrica e compatibile con una distribuzione normale. Se i dati sono molto asimmetrici, presentano limiti rigidi o presentano valori estremi, questi intervalli possono risultare fuorvianti.

18.5. Z-score: valori su una scala comune

Uno **z-score** indica quante deviazioni standard separano un valore dalla media:

$$z = \frac{x - \mu}{\sigma}.$$

Se un punteggio ha uno z-score pari a 0, coincide con la media. Se ha uno z-score pari a 1, si trova una deviazione standard sopra la media. Se lo z-score è pari a -2, il valore si trova due deviazioni standard sotto la media.

Gli z-score sono utili perché permettono di confrontare valori misurati su scale diverse. Per esempio, un punteggio di stress pari a 70 e un punteggio di sonno pari a 6 ore non sono direttamente confrontabili. Dopo la standardizzazione, entrambi i valori sono espressi come distanza dalla rispettiva media.

```
studentessa <- tibble(
  variabile = c("stress", "sonno_ore"),
  valore = c(70, 6),
  media = c(mean(eda_stress$stress), mean(eda_stress$sonno_ore)),
  sd = c(sd(eda_stress$stress), sd(eda_stress$sonno_ore)),
  z = (valore - media) / sd
)

studentessa |>
  mutate(across(where(is.numeric), ~ round(.x, 2))) |>
  knitr::kable()
```

| variabile | valore | media | sd | z |
|-----------|--------|-------|-------|-------|
| stress | 70 | 55.27 | 11.92 | 1.24 |
| sonno_ore | 6 | 7.25 | 1.14 | -1.10 |

In questo esempio, il punteggio di stress è superiore alla media del gruppo, mentre le ore di sonno sono inferiori alla media. Lo z-score non indica se questo valore sia clinicamente rilevante o teoricamente importante. Indica solo dove si colloca un valore rispetto alla distribuzione osservata.

i Standardizzare non significa spiegare

Uno z-score aiuta a confrontare le posizioni relative. Tuttavia, non spiega il motivo per cui una persona abbia quel valore, non trasforma una variabile debole in una misura valida e non elimina i problemi legati al campionamento o alla misurazione.

18.6. Come valutare se la normale è una buona approssimazione

Nell'EDA, è preferibile valutare la normalità tramite grafici piuttosto che con un rituale automatico. Due strumenti semplici sono:

1. un istogramma o una densità per vedere la forma generale;
2. un QQ-plot per confrontare i quantili osservati con quelli attesi sotto una distribuzione normale.

18.6.1. Istogramma con curva normale

Come abbiamo già visto, sovrapporre una curva normale all'istogramma aiuta a valutare rapidamente se la forma generale è compatibile con una distribuzione normale. Non si tratta di una prova formale, ma è spesso più istruttiva di un singolo valore- p .

18.6.2. QQ-plot

Un **QQ-plot** confronta i quantili dei dati osservati con i quantili teorici di una distribuzione normale. Se i dati sono approssimativamente normali, i punti tendono a disporsi vicino alla linea diagonale.

```
ggplot(eda_stress, aes(sample = stress)) +  
  geom_qq() +  
  geom_qq_line(linewidth = 1) +  
  labs(  
    x = "Quantili teorici della normale",  
    y = "Quantili osservati"  
  ) +  
  theme_minimal()
```




Figura 18.4.: QQ-plot dei punteggi di stress.

Un QQ-plot va letto soprattutto agli estremi. Piccole deviazioni sono normali. Deviazioni sistematiche possono indicare asimmetria, code pesanti o valori estremi.

```
set.seed(2027)
qq_examples <- tibble(
  normale = rnorm(400),
  asimmetrica = exp(rnorm(400)),
  code_pesanti = rt(400, df = 3)
) |>
  tidyr::pivot_longer(everything(), names_to = "tipo", values_to = "valore")

ggplot(qq_examples, aes(sample = valore)) +
  geom_qq(alpha = .7) +
  geom_qq_line() +
  facet_wrap(~ tipo, scales = "free_y") +
  labs(x = "Quantili teorici", y = "Quantili osservati") +
  theme_minimal()
```




Figura 18.5.: Tre pattern comuni nei QQ-plot: normale, asimmetria positiva e code pesanti.

Come guida molto pratica:

- punti vicini alla linea: compatibilità ragionevole con la normale;
- curva sistematica: possibile asimmetria;
- punti che si allontanano molto dalle code: code più pesanti del normale o valori estremi;
- pochi punti isolati molto lontani: possibili outlier o errori da controllare.

18.7. E i test di normalità?

Esistono test formali di normalità, come il test di Shapiro-Wilk. Possono essere utili in alcuni contesti, ma spesso forniscono informazioni meno dettagliate rispetto a un grafico.

Il motivo è semplice:

- con campioni piccoli, il test potrebbe non rilevare deviazioni importanti;
- con campioni grandi, il test può segnalare come “significant” deviazioni minime e irrilevanti;
- il risultato non indica quale sia il problema: asimmetria, code pesanti, outlier o discrepanze locali.

Per questo motivo, nell’EDA è meglio porsi le seguenti domande:

Che cosa vedo nella distribuzione? La normale è una descrizione utile? Le eventuali deviazioni cambiano le conclusioni?

Errore comune

Non usare il test di normalità come interruttore automatico: se $p < .05$, allora tutto è vietato; se $p > .05$, allora tutto è permesso. Questa è una semplificazione fuorviante. La normalità è una questione di adeguatezza del modello rispetto allo scopo dell'analisi.

18.8. Usare l'AI con criterio

L'AI può essere molto utile in questo capitolo. Può generare codice per:

- calcolare la media e la deviazione standard;
- disegnare un istogramma con curva normale.
- calcolare lo z-score.
- creare un QQ-plot;
- spiegare l'aspetto di una distribuzione.

Tuttavia, non bisogna delegare il giudizio metodologico. Quando l'AI produce codice o interpretazioni, è necessario controllare sempre:

- se ha usato la variabile corretta;
- se ha rimosso valori mancanti senza dirlo;
- se interpreta un test di normalità in modo meccanico;
- se confonde “approssimativamente normale” con “perfettamente normale”;
- se propone delle trasformazioni senza spiegare il perché;
- se assume che la normalità dei dati sia sempre necessaria.

Un buon prompt non chiede solo codice. Chiede anche di effettuare dei controlli:

Crea in R un istogramma e un QQ-plot per questa variabile. Poi spiegami quali aspetti devo controllare per decidere se la normalità è una buona approssimazione. Non usare il test di normalità come unico criterio.

18.9. Collegamento con l'inferenza bayesiana

La normale tornerà spesso nei modelli statistici e bayesiani, ma con ruoli diversi.

Può essere utilizzata per rappresentare:

- la distribuzione di una variabile continua;
- la variabilità degli errori intorno a una previsione;
- l'incertezza su un parametro;
- la variabilità tra individui, gruppi o studi.

Il punto importante è che, in un modello bayesiano, la distribuzione normale non è “vera” per definizione. È una scelta di modellazione. Se produce implicazioni poco compatibili con i dati, è possibile sostituirla con un'altra distribuzione o con un modello più robusto.

Questa idea prepara il terreno a due concetti che incontreremo più avanti:

- i **posterior predictive checks**, ovvero il confronto tra i dati osservati e i dati simulati dal modello.
- i **modelli robusti**, utili quando i dati presentano outlier o code più pesanti della distribuzione normale.

Il collegamento essenziale

In questo modulo non dobbiamo ancora costruire modelli bayesiani. Dobbiamo però imparare a pensare come modellizzatori: ogni distribuzione è una scelta e ogni scelta ha delle conseguenze. I dati devono sempre essere osservati prima di essere interpretati.

Cosa portare al capitolo successivo

Da questo capitolo dovresti portare con te quattro idee:

1. la distribuzione normale è una forma di riferimento utile, non una legge dei dati;
2. la media e la deviazione standard sono molto informative quando la distribuzione è approssimativamente simmetrica;
3. gli z-score esprimono valori diversi su una scala comune;
4. gli QQ-plot e gli istogrammi aiutano a capire se la distribuzione normale è una buona approssimazione.

Nel capitolo sulla correlazione useremo queste idee per ragionare non più su una sola variabile, ma sulla relazione tra due variabili.

Esercizi

Esercizi

18.9.1. Comprensione concettuale

1. Spiega con parole tue perché la distribuzione normale va considerata un modello e non una legge.
2. In quali situazioni media e deviazione standard sono riassunti informativi? In quali situazioni possono essere meno adatti?
3. Che cosa significa dire che un valore ha z-score pari a 2?
4. Perché un QQ-plot può essere più informativo di un test di normalità?

18.9.2. Applicazione

5. Un questionario di ansia ha media 50 e deviazione standard 10. Assumendo una distribuzione approssimativamente normale:
 - quale intervallo contiene circa il 68% dei punteggi?
 - quale intervallo contiene circa il 95% dei punteggi?
 - come interpreteresti un punteggio pari a 72?
6. Una studentessa ottiene:

- 115 in un test con media 100 e deviazione standard 15;
- 62 in un test con media 50 e deviazione standard 8.

Calcola i due z-score. In quale test la studentessa si colloca più lontano dalla media?

7. L'AI produce questa frase: "Il test di Shapiro-Wilk è significativo, quindi non possiamo analizzare questi dati". Perché questa affermazione è troppo semplicistica?

18.9.3. Lettura critica di codice

8. Considera questo codice:

```
media <- mean(dati$stress, na.rm = TRUE)
sd_stress <- sd(dati$stress, na.rm = TRUE)

ggplot(dati, aes(x = stress)) +
  geom_histogram(aes(y = after_stat(density)), bins = 20) +
  stat_function(fun = dnorm, args = list(mean = media, sd = sd_stress))
```

- Che cosa fa il codice?
- Perché usa `na.rm = TRUE`?
- Che cosa dovresti controllare prima di interpretare il grafico?

i Informazioni sull'ambiente di sviluppo

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
Platform: aarch64-apple-darwin23
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Rome
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
other attached packages:
```

```
[1] tibble_3.3.1 dplyr_1.2.1 ggplot2_4.0.3
```

```
loaded via a namespace (and not attached):
```

```
[1] vctrs_0.7.3      cli_3.6.6        knitr_1.51        rlang_1.3.0
[5] xfun_0.60        otel_0.2.0       purrr_1.2.2       generics_0.1.4
```

| | | | | |
|------|-----------------|--------------------|-----------------|------------------|
| [9] | S7_0.2.2 | jsonlite_2.0.0 | labeling_0.4.3 | glue_1.8.1 |
| [13] | htmltools_0.5.9 | scales_1.4.0 | rmarkdown_2.31 | grid_4.6.1 |
| [17] | evaluate_1.0.5 | fastmap_1.2.0 | yaml_2.3.12 | lifecycle_1.0.5 |
| [21] | compiler_4.6.1 | RColorBrewer_1.1-3 | pkgconfig_2.0.3 | tidyr_1.3.2 |
| [25] | farver_2.1.2 | digest_0.6.39 | R6_2.6.1 | tidyselect_1.2.1 |
| [29] | pillar_1.11.1 | magrittr_2.0.5 | withr_3.0.3 | tools_4.6.1 |
| [33] | gtable_0.3.6 | | | |

Bibliografia

19. Relazioni tra variabili

Nell'EDA non ci interessa soltanto sapere come è fatta una variabile presa da sola. Vogliamo anche capire se due variabili cambiano insieme: per esempio, gli studenti che riportano più stress dormono meno? Chi dorme meno mostra punteggi più alti di disagio? La correlazione aiuta a descrivere queste associazioni, ma non basta a spiegarne il motivo.

Panoramica del capitolo

In questo capitolo impareremo a:

- distinguere associazione, correlazione e causalità;
- leggere uno scatterplot prima di calcolare un coefficiente;
- interpretare la direzione, la forma e la forza di una relazione;
- calcolare e interpretare la correlazione di Pearson e di Spearman;
- riconoscere le situazioni in cui la correlazione può essere fuorviante.
- usare l'AI per produrre codice senza delegare l'interpretazione.

Idea guida

Prima di calcolare una correlazione, è sempre necessario esaminare i dati. Un coefficiente riassume una nuvola di punti, ma non può sostituirla.

19.1. Perché studiare relazioni tra variabili?

Molte domande psicologiche riguardano le relazioni tra variabili:

- lo stress accademico è associato alla qualità del sonno?
- il supporto sociale è associato a sintomi depressivi meno intensi?
- Il tempo di reazione aumenta quando il compito diventa più difficile?
- due scale psicometriche che dovrebbero misurare lo stesso costrutto producono punteggi simili?

Queste domande sono diverse da quelle univariate viste nei capitoli precedenti. Non ci si chiede più soltanto:

Che forma ha questa distribuzione?

Ma anche:

Come cambiano insieme due variabili?

Questa domanda è importante, ma va formulata con cautela. Una relazione statistica può essere un indizio, non una spiegazione completa. In particolare, una correlazione non dimostra che una variabile causi l'altra. Questo punto sarà ripreso nel capitolo successivo sulla causalità.

19.2. Associazione, correlazione, causalità

Nel linguaggio comune, spesso usiamo i termini “relazione”, “associazione” e “correlazione” come se fossero sinonimi. Nel lavoro scientifico, invece, è meglio distinguerle.

- “Associazione” è il termine più generale: conoscere una variabile ci dice qualcosa, almeno in parte, sull'altra.
- “Correlazione” è una misura specifica dell'associazione, di solito riferita alla tendenza di due variabili numeriche a variare insieme.
- La causalità riguarda una domanda diversa: cosa accadrebbe a una variabile se intervenissimo sull'altra?

Per esempio, se gli studenti che dormono meno riportano più stress, c'è un'associazione. Tuttavia, da questa associazione non possiamo ancora dedurre se lo stress riduce il sonno, se il sonno ridotto aumenta lo stress, se entrambe le variabili dipendono da un terzo fattore o se tutte e tre le spiegazioni sono parzialmente vere.

⚠ Correlazione non significa causalità

La correlazione descrive come due variabili si presentano insieme nei dati osservati. La causalità richiede una domanda diversa: cosa cambierebbe se potessimo modificare una variabile mantenendo sotto controllo il resto?

19.3. Un esempio ricorrente: stress e sonno

Useremo un piccolo dataset didattico. Ogni riga rappresenta uno studente. Le variabili principali sono:

- **stress**: punteggio di stress accademico, da 0 a 40;
- **sonno**: ore medie di sonno per notte;
- **supporto**: supporto sociale percepito, da 0 a 30;
- **anno**: anno di corso.

```
library(dplyr)
library(ggplot2)
```

```
set.seed(42)

n <- 120

eda_stress <- tibble::tibble(
  id = seq_len(n),
  anno = sample(c("Primo", "Secondo", "Terzo"), n, replace = TRUE),
  supporto = round(rnorm(n, mean = 20, sd = 5), 1),
  stress = round(28 - 0.45 * supporto + rnorm(n, mean = 0, sd = 5), 1),
  sonno = round(8.2 - 0.09 * stress + rnorm(n, mean = 0, sd = 0.7), 1)
) |>
mutate(
  supporto = pmax(pmin(supporto, 30), 0),
  stress = pmax(pmin(stress, 40), 0),
```

```

    sonno = pmax(pmin(sonno, 10), 3)
  )

glimpse(eda_stress)

```

```

Rows: 120
Columns: 5
$ id      <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18~
$ anno    <chr> "Primo", "Primo", "Primo", "Primo", "Secondo", "Secondo", "Se~
$ supporto <dbl> 22.3, 20.6, 15.7, 15.4, 17.6, 15.5, 18.9, 19.8, 14.5, 21.2, 2~
$ stress   <dbl> 10.8, 18.9, 19.9, 14.9, 16.9, 19.6, 20.5, 22.0, 16.4, 22.3, 9~
$ sonno    <dbl> 7.6, 5.7, 7.1, 7.2, 6.4, 7.4, 7.5, 6.6, 6.7, 5.3, 7.0, 7.6, 6~

```

Questo dataset è artificiale. È stato creato solo per mostrare il ragionamento.

19.4. Prima il grafico: lo scatterplot

Quando le variabili sono numeriche, il primo strumento da utilizzare è quasi sempre lo **scatterplot**. Ogni punto rappresenta un caso. La posizione del punto indica il valore della prima variabile sull'asse orizzontale e della seconda variabile sull'asse verticale.

```

ggplot(eda_stress, aes(x = stress, y = sonno)) +
  geom_point(alpha = 0.7) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Stress accademico",
    y = "Ore di sonno",
    title = "Stress e sonno"
  )

```




Figura 19.1.: Relazione tra stress accademico e ore di sonno. Ogni punto rappresenta uno studente.

Prima di calcolare qualsiasi indice, è necessario porsi alcune domande:

1. **Direzione:** la relazione sembra positiva o negativa?
2. **Forma:** la relazione sembra approssimativamente lineare?
3. **Forza:** i punti sono vicini a una tendenza comune o molto dispersi?
4. **Anomalie:** ci sono punti isolati che potrebbero influenzare in modo rilevante il risultato?
5. **Gruppi:** ci sono sottogruppi che dovrebbero essere distinti?

Nel grafico precedente, la relazione sembra negativa: a valori più alti di stress tendono a corrispondere meno ore di sonno. Tuttavia, la relazione non è perfetta: studenti con lo stesso livello di stress possono dormire un numero diverso di ore.

19.5. Descrivere la relazione: direzione, forma e forza

Una relazione tra due variabili può essere descritta utilizzando tre concetti.

19.5.1. Direzione

Una relazione è **positiva** quando valori alti di una variabile tendono ad accompagnarsi a valori alti dell'altra. È **negativa** quando valori alti di una variabile tendono ad accompagnarsi a valori bassi dell'altra.

19.5.2. Forma

Una relazione è **lineare** quando può essere riassunta abbastanza bene da una linea retta. Molte relazioni psicologiche, però, non sono perfettamente lineari: possono essere curve, avere soglie, appiattirsi o cambiare direzione.

19.5.3. Forza

Una relazione è più forte quando i punti sono vicini a una tendenza comune. È più debole quando i punti sono molto dispersi.

! Il coefficiente di correlazione di Pearson riassume la forza di una relazione lineare

La correlazione di Pearson riassume soprattutto la forza di una relazione lineare. Se la relazione non è lineare, se ci sono gruppi nascosti o se pochi punti estremi dominano il grafico, il coefficiente può essere poco informativo.

19.6. La covarianza: variare insieme

La **covarianza** è una prima misura del fatto che due variabili variano insieme. L'idea è semplice: si osserva se gli scarti dalla media di una variabile tendono ad avere lo stesso segno degli scarti dalla media dell'altra.

La covarianza campionaria tra due variabili X e Y è:

$$s_{XY} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

Se i valori sopra la media di X tendono ad accompagnarsi a valori sopra la media di Y , e i valori sotto la media di X a valori sotto la media di Y , la covarianza è positiva. Se accade il contrario, la covarianza è negativa.

```
cov(eda_stress$stress, eda_stress$sonno)
```

```
[1] -2.488824
```

Nel nostro esempio, la covarianza è negativa, coerentemente con lo scatterplot: un livello più alto di stress tende ad accompagnarsi a un numero inferiore di ore di sonno.

La covarianza, però, ha un limite: dipende dalle unità di misura. Cambiare la scala di una variabile modifica anche il valore numerico della covarianza. Per questo motivo, nella pratica, si usa più spesso la correlazione.

19.7. La correlazione di Pearson

La **correlazione di Pearson** è una versione standardizzata della covarianza. Assume valori compresi tra -1 e +1.

$$r = \frac{s_{XY}}{s_X s_Y}.$$

Il valore di r indica:

- il **segno** della relazione lineare: positivo o negativo;
- la **forza** della relazione lineare;

- non le unità di misura, perché il coefficiente è standardizzato.

```
cor(eda_stress$stress, eda_stress$sonno)
```

```
[1] -0.5346193
```

Un valore vicino a -1 indica una relazione lineare negativa molto forte. Un valore vicino a +1 indica una relazione lineare positiva molto forte. Un valore vicino a 0 indica l'assenza di una relazione lineare, ma non necessariamente l'assenza di una relazione in generale.

i Come interpretare la grandezza di r ?

Non esiste una soglia universale per stabilire se una correlazione è “piccola”, “media” o “grande”. Il suo significato dipende dal contesto, dalla qualità della misura, dalla variabilità del campione, dal disegno della ricerca e dalla teoria psicologica.

19.7.1. Leggere il coefficiente insieme al grafico

Il coefficiente di correlazione è utile, ma non deve mai essere letto da solo. Nel report EDA, è consigliabile accompagnarlo sempre con uno scatterplot e con un'interpretazione prudente.

```
eda_stress |>
  summarise(
    n = n(),
    r_stress_sonno = cor(stress, sonno),
    media_stress = mean(stress),
    media_sonno = mean(sonno)
  )
```

```
# A tibble: 1 x 4
      n r_stress_sonno media_stress media_sonno
<int>      <dbl>      <dbl>      <dbl>
1  120      -0.535      18.2       6.57
```

Una formulazione corretta potrebbe essere:

Nel campione osservato, lo stress accademico e le ore di sonno mostrano un'associazione lineare negativa: gli studenti con punteggi più alti di stress tendono a dormire meno. Tale associazione, tuttavia, non dimostra che lo stress causi una riduzione del sonno.

19.8. Correlazione di Spearman

La correlazione di Pearson è sensibile alla forma della relazione e ai valori estremi. Quando la relazione è monotona, ma non lineare, oppure quando le variabili sono ordinali, può essere utile la **correlazione di Spearman**.

Spearman non lavora direttamente sui valori originali, ma sui loro ranghi. Per questo motivo, la correlazione di Spearman descrive se, al crescere di una variabile, l'altra tende ad aumentare o diminuire, senza richiedere una relazione lineare perfetta.

```
cor(eda_stress$stress, eda_stress$sonno, method = "spearman")
```

```
[1] -0.4436756
```

Nel nostro esempio, i coefficienti di Pearson e Spearman sono simili, perché la relazione è abbastanza regolare. In altri casi, invece, possono differire di più.

19.9. Quando Pearson può ingannare

La correlazione di Pearson è utile, ma riassume solo un aspetto dei dati. Esaminiamo tre casi in cui il coefficiente può essere fuorviante.

19.9.1. Relazioni non lineari

Una correlazione vicina a zero non implica necessariamente l'assenza di una relazione. Consideriamo, ad esempio, una relazione a U: i valori intermedi di stress possono associarsi a un certo esito, mentre i valori molto bassi e molto alti possono associarsi a esiti diversi.

```
set.seed(123)
nonlinear <- tibble::tibble(
  attivazione = seq(-3, 3, length.out = 120),
  prestazione = 8 - attivazione^2 + rnorm(120, 0, 0.7)
)

cor(nonlinear$attivazione, nonlinear$prestazione)
```

```
[1] -0.01420328
```

```
ggplot(nonlinear, aes(x = attivazione, y = prestazione)) +
  geom_point(alpha = 0.7) +
  geom_smooth(se = FALSE) +
  labs(
    x = "Attivazione",
    y = "Prestazione",
    title = "Una relazione non lineare"
  )
```




Figura 19.2.: Esempio di relazione non lineare. La correlazione lineare può essere vicina a zero anche quando esiste un pattern chiaro.

In questo esempio, il coefficiente lineare non riassume bene la struttura del grafico. Lo scatterplot rivela un modello che il numero da solo non riesce a mostrare.

19.9.2. Valori estremi

Un singolo valore estremo può cambiare molto una correlazione, soprattutto in campioni piccoli. Per questo motivo, quando calcoliamo una correlazione, dobbiamo sempre osservare il grafico e chiederci se alcuni punti abbiano un'influenza sproporzionata.

```
set.seed(321)
con_outlier <- tibble::tibble(
  x = rnorm(30),
  y = rnorm(30)
) |>
  bind_rows(tibble::tibble(x = 5, y = 5))

cor(con_outlier$x, con_outlier$y)
```

```
[1] 0.3081906
```

```
ggplot(con_outlier, aes(x = x, y = y)) +
  geom_point(alpha = 0.8) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Variabile X",
    y = "Variabile Y",
    title = "Effetto di un valore estremo"
  )
```




Figura 19.3.: Un valore estremo può produrre o rafforzare una correlazione apparente.

Un valore estremo non va eliminato automaticamente. Potrebbe trattarsi di un errore, ma potrebbe anche rappresentare un caso reale e significativo. La decisione deve essere documentata, come discusso nel capitolo sugli outlier.

19.9.3. Gruppi nascosti e paradosso di Simpson

Un'associazione osservata nell'intero campione può cambiare quando si distinguono i gruppi. Questo fenomeno è noto come **paradosso di Simpson**.

```
set.seed(11)

gruppo_a <- tibble::tibble(
  gruppo = "A",
  x = rnorm(60, mean = 3, sd = 0.7),
  y = 7 + 0.6 * x + rnorm(60, sd = 0.6)
)

gruppo_b <- tibble::tibble(
  gruppo = "B",
  x = rnorm(60, mean = 7, sd = 0.7),
  y = 2 + 0.6 * x + rnorm(60, sd = 0.6)
)

simpson <- bind_rows(gruppo_a, gruppo_b)

cor(simpson$x, simpson$y)
```

```
[1] -0.7590601
```

```

simpson |>
  group_by(gruppo) |>
  summarise(r = cor(x, y), .groups = "drop")

# A tibble: 2 x 2
  gruppo      r
  <chr>   <dbl>
1 A       0.462
2 B       0.597

ggplot(simpson, aes(x = x, y = y, shape = gruppo)) +
  geom_point(alpha = 0.7) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "X",
    y = "Y",
    shape = "Gruppo",
    title = "Gruppi nascosti e associazione complessiva"
  )

```




Figura 19.4.: Associazioni nei gruppi e associazione complessiva possono raccontare storie diverse.

Questo esempio mostra perché l'EDA deve considerare il disegno dello studio e le variabili di gruppo. Una correlazione complessiva può essere diversa dalle correlazioni osservate nei sottogruppi.

19.10. Una procedura pratica per l'EDA bivariata

1. Controllare il significato delle variabili: che cosa misurano? Si tratta di punteggi, tempi, frequenze o categorie ordinate?

2. Controllare i dati mancanti: la correlazione viene calcolata sugli stessi casi per entrambe le variabili?
3. Disegnare uno scatterplot: la relazione sembra lineare, monotona, curva o assente?
4. Cercare i valori estremi: pochi punti dominano la relazione?
5. Considerare i gruppi: la relazione è simile in tutti i sottogruppi rilevanti?
6. Calcolare un coefficiente:
 - Pearson se la relazione è approssimativamente lineare;
 - Spearman se la relazione è monotona o le variabili sono ordinali.
7. Interpretare con cautela: l'associazione non implica la causalità.

19.11. Usare l'AI con criterio

L'AI può essere molto utile per generare codice R, proporre grafici o spiegare gli errori. Per esempio, si può chiedere:

Scrivi del codice R con ggplot2 per visualizzare la relazione tra lo stress accademico e le ore di sonno e per calcolare la correlazione di Pearson e Spearman.

Tuttavia, lo studente deve controllare alcuni punti.

Cosa devi controllare tu

- Le variabili indicate dall'AI sono presenti davvero nel dataset?
- I casi con valori mancanti sono stati esclusi? Quanti sono?
- Il grafico prodotto è adatto al tipo di variabili?
- La relazione sembra lineare o solo monotona?
- La correlazione è calcolata sull'intero campione o per gruppi?
- L'AI sta interpretando una correlazione come se fosse una causa?

Un buon esercizio non consiste solo nell'ottenere il codice, ma anche nel saperlo spiegare. Dopo aver usato l'AI, proviamo sempre a rispondere:

Quale domanda risponde questo codice? Quali casi utilizza? Quale relazione mostra?
Quale conclusione non posso trarre?

19.12. Dal coefficiente al modello

La correlazione è uno strumento descrittivo. Ci aiuta a capire se due variabili cambiano insieme, ma non ci dice quale processo abbia generato tale associazione. Per passare dalla descrizione alla spiegazione sono necessari una teoria, un disegno di ricerca, il controllo dei confondenti e modelli statistici più espliciti.

Questa distinzione prepara il terreno per il capitolo successivo: l'EDA può suggerire ipotesi causali, ma non può fondarle da sola.

Riepilogo

- Lo scatterplot precede il coefficiente.
- La correlazione di Pearson descrive la forza e la direzione di una relazione lineare.
- La correlazione di Spearman descrive relazioni monotone usando i ranghi.
- Una correlazione vicina a zero non esclude relazioni non lineari.
- I valori estremi e i gruppi nascosti possono modificare fortemente il coefficiente.
- La correlazione è un risultato descrittivo, non una prova causale.

Esercizi

💡 Esercizio 1: leggere uno scatterplot

Usa il dataset `eda_stress`. Crea uno scatterplot tra `supporto` e `stress`.

1. La relazione sembra positiva o negativa?
2. Sembra lineare?
3. Ci sono punti anomali?
4. Quale interpretazione psicologica prudente puoi proporre?

💡 Esercizio 2: Pearson e Spearman

Calcola la correlazione di Pearson e quella di Spearman tra `supporto` e `stress`.

```
cor(eda_stress$supporto, eda_stress$stress)
```

```
[1] -0.4139405
```

```
cor(eda_stress$supporto, eda_stress$stress, method = "spearman")
```

```
[1] -0.363757
```

I due valori sono simili? Che cosa suggerisce questa somiglianza o differenza?

💡 Esercizio 3: controllare il codice prodotto dall'AI

Supponi che l'AI produca questo codice:

```
eda_stress |>
  summarise(r = cor(stress, sonno, use = "complete.obs"))
```

```
# A tibble: 1 x 1
      r
  <dbl>
1 -0.535
```

Rispondi:

1. Che cosa fa `use = "complete.obs"`?

2. Quanti casi sono usati nel calcolo?
3. Il codice basta per interpretare la relazione?
4. Quale grafico aggiungerei prima di commentare il risultato?

 Esercizio 4: correlazione e causalità

Scrivi tre possibili spiegazioni alternative dell'associazione negativa tra stress e sonno:

1. stress causa minore sonno;
2. minore sonno aumenta lo stress;
3. una terza variabile influenza entrambe.

Per ciascuna spiegazione, indica quale informazione aggiuntiva servirebbe per valutarla.

20. Dalla correlazione alla causalità

Nel capitolo precedente abbiamo visto come descrivere l'associazione tra due variabili. A questo punto, è naturale chiedersi se una variabile possa essere la causa dell'altra. Questa domanda è importante, ma richiede cautela: una correlazione può indicare una possibile pista di ricerca, ma non dimostra da sola una relazione causale.

Messaggi chiave

- L'**associazione** descrive come due variabili variano insieme.
- Una **relazione causale** riguarda ciò che cambierebbe se intervenissimo su una variabile.
- Il **confondimento** può far apparire causale una relazione che non lo è.
- La **randomizzazione** è uno strumento potente perché rende i gruppi comparabili in media.
- L'EDA può suggerire ipotesi causali, ma non può fondarle da sola.

20.1. Perché questo capitolo è qui

L'analisi esplorativa dei dati serve a osservare i dati prima di costruire modelli o trarre conclusioni. In psicologia, però, il passo dall'associazione alla spiegazione è spesso molto seducente. Osserviamo che due variabili sono correlate e siamo tentati di raccontare subito una storia causale.

Per esempio:

- gli studenti che dormono meno riportano più stress;
- chi usa di più lo smartphone ha punteggi più alti di ansia.
- chi riceve supporto sociale mostra meno sintomi depressivi.
- chi studia di più ottiene voti migliori.

Tutte queste frasi descrivono associazioni possibili. Tuttavia, ciascuna di esse può essere interpretata in modi diversi. Il sonno scarso può aumentare lo stress, ma lo stress può anche peggiorare la qualità del sonno. L'uso dello smartphone può contribuire all'ansia, ma gli studenti più ansiosi potrebbero usare di più lo smartphone. Il supporto sociale può proteggere dal disagio, ma le persone con meno disagio possono anche avere più energie per mantenere relazioni sociali.

Questo capitolo introduce quindi una distinzione fondamentale:

una associazione osservata nei dati non coincide necessariamente con un effetto causale.

L'obiettivo non è imparare tecniche avanzate di inferenza causale. L'obiettivo è più modesto, ma importante per l'EDA: imparare a non interpretare troppo rapidamente le associazioni che osserviamo.

```
library(dplyr)
library(ggplot2)
```

20.2. Associazione e causalità rispondono a domande diverse

Una **domanda associativa** chiede se due variabili tendono a comparire insieme.

Per esempio:

Gli studenti con più stress dormono meno?

Questa domanda può essere affrontata con uno scatterplot, una correlazione o una regressione descrittiva. In questo caso, stiamo osservando come due variabili si dispongono nei dati.

Una **domanda causale**, invece, chiede che cosa accadrebbe se intervenissimo su una variabile.

Per esempio:

Se riducessimo lo stress degli studenti, migliorerebbe la qualità del loro sonno?

Questa seconda domanda non riguarda solo ciò che osserviamo. Riguarda anche ciò che sarebbe accaduto in una condizione alternativa. Per questo motivo, la causalità richiede un ragionamento più forte della semplice descrizione dei dati.

Domanda da tenere sempre presente

Quando osserviamo una relazione tra due variabili, dobbiamo chiederci:

Sto descrivendo una associazione oppure sto facendo un'affermazione causale?

Molti errori interpretativi nascono quando una frase associativa viene trasformata, senza alcuna giustificazione, in una frase causale.

20.3. L'idea controfattuale

Il modo più semplice per capire la causalità è pensare a un confronto tra due scenari.

Immaginiamo uno studente che usa una tecnica di rilassamento prima di un esame. La domanda causale è:

La tecnica di rilassamento ha ridotto la sua ansia?

Per rispondere in modo esaustivo, dovremmo osservare due versioni dello stesso studente, nello stesso momento e nelle stesse condizioni:

1. lo studente usa la tecnica di rilassamento;
2. lo stesso studente non usa la tecnica di rilassamento.

La differenza tra i due livelli di ansia sarebbe l'effetto causale della tecnica.

Il problema è evidente: nella realtà, osserviamo solo uno dei due scenari. O usa la tecnica o non la usa. L'altro scenario rimane non osservato. Si chiama **controfattuale**: riguarda ciò che sarebbe potuto accadere, ma che non si è verificato nel mondo osservato.

Il problema fondamentale

Per una singola persona, non è possibile osservare contemporaneamente ciò che accade con un intervento e ciò che sarebbe accaduto senza di esso. Questo è il motivo per cui l'inferenza causale è difficile.

Nella ricerca empirica, però, non è possibile risolvere questo problema a livello individuale. Possiamo però cercare di confrontare gruppi che siano, per quanto possibile, comparabili.

20.4. Perché i gruppi osservati possono essere diversi

Supponiamo di voler valutare se una tecnica di rilassamento riduce l'ansia. Osserviamo due gruppi:

- studenti che hanno usato la tecnica;
- studenti che non l'hanno usata.

Se il primo gruppo mostra un livello di ansia inferiore, possiamo concludere che la tecnica è efficace?

Non necessariamente.

Forse gli studenti che scelgono questa tecnica sono anche quelli più motivati, più informati, più abituati a gestire lo stress o meno ansiosi di partenza. In questo caso, il confronto tra i gruppi mescola due cose:

1. l'eventuale effetto della tecnica;
2. le differenze preesistenti tra chi la usa e chi non la usa.

Queste differenze preesistenti sono il cuore del problema del **confondimento**.

20.5. Il confondimento

Una variabile è un **confondente** quando è collegata sia alla possibile causa sia all'esito.

Esempio:

```
Motivazione ---> Studio pomeridiano
      |
      v
Rendimento al test
```

Se gli studenti più motivati studiano di più e ottengono risultati migliori, potremmo osservare una relazione positiva tra lo studio pomeridiano e il rendimento, anche se lo studio pomeridiano, di per sé, non ha alcun effetto specifico. La motivazione genera una parte dell'associazione osservata.

Confondimento

Il confondimento si verifica quando una terza variabile crea o altera l'associazione tra una possibile causa e un esito. In presenza di confondimento, l'associazione osservata può essere fuorviante.

20.5.1. Un esempio simulato

Costruiamo un piccolo esempio. Immaginiamo che la motivazione influenzi sia la probabilità di studiare nel pomeriggio sia il rendimento nel test. In questa simulazione, però, lo studio pomeridiano non ha alcun effetto causale diretto sul rendimento.

```
set.seed(123)
n <- 300

motivazione <- rbinom(n, size = 1, prob = 0.50)
studio_pomeridiano <- rbinom(n, size = 1, prob = 0.25 + 0.45 * motivazione)
rendimento <- rnorm(n, mean = 60 + 15 * motivazione, sd = 8)

dati_conf <- tibble(
  motivazione = factor(motivazione, labels = c("bassa", "alta")),
  studio_pomeridiano = factor(studio_pomeridiano, labels = c("no", "si")),
  rendimento = rendimento
)

dati_conf |>
  group_by(studio_pomeridiano) |>
  summarise(
    n = n(),
    rendimento_medio = mean(rendimento),
    .groups = "drop"
  )
```

```
# A tibble: 2 x 3
  studio_pomeridiano      n rendimento_medio
  <fct>              <int>          <dbl>
1 no                 157             64.8
2 si                 143             70.1
```

Se si confronta chi studia nel pomeriggio con chi non lo fa, sembra che studiare nel pomeriggio sia associato a un rendimento più alto.

```
ggplot(dati_conf, aes(x = studio_pomeridiano, y = rendimento)) +
  geom_boxplot(width = 0.45, outlier.alpha = 0.4) +
  geom_jitter(width = 0.08, alpha = 0.35) +
  labs(
    x = "Studio pomeridiano",
    y = "Rendimento al test"
  )
```




Figura 20.1.: Associazione osservata tra studio pomeridiano e rendimento.

Ma sappiamo come sono stati generati i dati: la differenza nasce dalla motivazione. Se analizziamo separatamente gli studenti con bassa e alta motivazione, la relazione si riduce drasticamente.

```
dati_conf |>
  group_by(motivazione, studio_pomeridiano) |>
  summarise(
    n = n(),
    rendimento_medio = mean(rendimento),
    .groups = "drop"
  )
```

```
# A tibble: 4 x 4
  motivazione studio_pomeridiano     n rendimento_medio
  <fct>        <fct>             <int>           <dbl>
1 bassa      no                113            60.8
2 bassa      si                 42            59.4
3 alta       no                 44            74.9
4 alta       si                101            74.6
```

```
ggplot(dati_conf, aes(x = studio_pomeridiano, y = rendimento)) +
  geom_boxplot(width = 0.45, outlier.alpha = 0.4) +
  geom_jitter(width = 0.08, alpha = 0.35) +
  facet_wrap(~ motivazione) +
  labs(
    x = "Studio pomeridiano",
    y = "Rendimento al test"
  )
```




Figura 20.2.: Quando si considera la motivazione, l'associazione cambia.

Questo esempio non dimostra che la motivazione sia sempre il confondente giusto. Mostra un principio generale: prima di interpretare un'associazione come causale, dobbiamo chiederci se i gruppi confrontati erano comparabili.

20.6. Il ruolo della randomizzazione

La randomizzazione è uno strumento potente perché assegna il trattamento in modo indipendente dalle caratteristiche iniziali delle persone.

Se gli studenti vengono assegnati casualmente all'uso o meno di una tecnica di rilassamento, i due gruppi possono comunque differire per caso, ma non dovrebbero differire sistematicamente. In media, la motivazione, l'ansia iniziale, la preparazione e altre caratteristiche saranno distribuite in modo simile nei due gruppi.

Ciò rende più plausibile interpretare la differenza osservata tra i gruppi come effetto del trattamento.

💡 Perché la randomizzazione aiuta

La randomizzazione non rende gli individui identici. Rende però i gruppi comparabili in media, soprattutto quando il campione è sufficientemente ampio. Per questo motivo, gli esperimenti randomizzati sono particolarmente importanti quando vogliamo rispondere a domande causali.

20.6.1. La stessa simulazione, ma con assegnazione casuale

Ripetiamo la simulazione. La motivazione continua a influenzare il rendimento, ma lo studio pomeridiano viene assegnato in modo casuale.

```

set.seed(456)
n <- 300

motivazione <- rbinom(n, size = 1, prob = 0.50)
studio_pomeridiano <- rbinom(n, size = 1, prob = 0.50)
rendimento <- rnorm(n, mean = 60 + 15 * motivazione, sd = 8)

dati_rand <- tibble(
  motivazione = factor(motivazione, labels = c("bassa", "alta")),
  studio_pomeridiano = factor(studio_pomeridiano, labels = c("no", "si")),
  rendimento = rendimento
)

dati_rand |>
  group_by(studio_pomeridiano) |>
  summarise(
    n = n(),
    rendimento_medio = mean(rendimento),
    .groups = "drop"
  )

```

```

# A tibble: 2 x 3
  studio_pomeridiano      n rendimento_medio
  <fct>              <int>          <dbl>
1 no                 147            68.5
2 si                 153            69.2

```

```

ggplot(dati_rand, aes(x = studio_pomeridiano, y = rendimento)) +
  geom_boxplot(width = 0.45, outlier.alpha = 0.4) +
  geom_jitter(width = 0.08, alpha = 0.35) +
  labs(
    x = "Studio pomeridiano assegnato casualmente",
    y = "Rendimento al test"
  )

```





Figura 20.3.: Con assegnazione casuale, i gruppi sono più comparabili.

La differenza tra i gruppi ora è molto più piccola. Questo non significa che la motivazione non conti più, ma che non è più strettamente legata allo studio pomeridiano.

20.7. Studi osservazionali ed esperimenti

La distinzione tra studi osservazionali ed esperimenti è fondamentale.

In uno studio osservazionale, il ricercatore osserva ciò che accade, ad esempio chi studia di più, chi dorme meno, chi usa un'app di mindfulness o chi riceve supporto sociale. Questi studi sono preziosi, ma le associazioni osservate possono dipendere da differenze preesistenti tra le persone.

In un esperimento, invece, il ricercatore interviene attivamente: assegna una condizione, manipola una variabile e controlla il contesto. Quando l'assegnazione è casuale, l'interpretazione causale è più solida.

Tipo di studio	Cosa permette bene	Cosa richiede cautela
Osservazionale	Descrivere associazioni reali nei dati	Interpretare le associazioni come effetti causali
Sperimentale non randomizzato	Valutare effetti in contesti controllati	Escludere differenze iniziali tra gruppi
Sperimentale randomizzato	Stimare effetti causali medi con maggiore credibilità	Generalizzare automaticamente a tutte le popolazioni

La randomizzazione aiuta a risolvere i problemi di causalità interna, ma non li risolve completamente. Un esperimento condotto su studenti universitari volontari può fornire una stima accurata dell'effetto in quel contesto, ma non garantisce che lo stesso effetto valga per altre popolazioni.

20.8. Il paradosso di Simpson

Il paradosso di Simpson mostra che un'associazione osservata nel campione totale può cambiare direzione quando si analizzano i sottogruppi.

Nel nostro contesto, ciò può accadere quando un gruppo significativo è distribuito in modo diverso tra le condizioni.

```
set.seed(789)
n <- 800

ansia_iniziale <- rbinom(n, size = 1, prob = 0.50)
condizione <- ifelse(
  ansia_iniziale == 1,
  rbinom(n, size = 1, prob = 0.75),
  rbinom(n, size = 1, prob = 0.25)
)

# In entrambi i gruppi la condizione riduce leggermente l'esito.
effetto_vero <- -3
ansia_finale <- 45 + 18 * ansia_iniziale + effetto_vero * condizione + rnorm(n, 0, 6)

dati_simpson <- tibble(
  ansia_iniziale = factor(ansia_iniziale, labels = c("bassa", "alta")),
  condizione = factor(condizione, labels = c("controllo", "intervento")),
  ansia_finale = ansia_finale
)

dati_simpson |>
  group_by(condizione) |>
  summarise(ansia_media = mean(ansia_finale), .groups = "drop")
```

```
# A tibble: 2 x 2
  condizione ansia_media
  <fct>       <dbl>
1 controllo    49.0
2 intervento    55.5
```

Nel campione totale, l'intervento può sembrare associato a un'ansia finale maggiore, perché gli studenti con un'alta ansia iniziale sono sovrarappresentati nel gruppo di intervento.

```
dati_simpson |>
  group_by(ansia_iniziale, condizione) |>
  summarise(ansia_media = mean(ansia_finale), .groups = "drop")
```

```
# A tibble: 4 x 3
  ansia_iniziale condizione ansia_media
  <fct>          <fct>       <dbl>
1 bassa        controllo    44.7
2 bassa        intervento    42.2
```

3	alta	controllo	63.0
4	alta	intervento	60.0

All'interno di ciascun livello di ansia iniziale, tuttavia, l'intervento è associato a una riduzione dell'ansia finale.

```
ggplot(dati_simpson, aes(x = condizione, y = ansia_finale)) +
  geom_boxplot(width = 0.45, outlier.alpha = 0.35) +
  geom_jitter(width = 0.08, alpha = 0.25) +
  facet_wrap(~ ansia_iniziale) +
  labs(
    x = "Condizione",
    y = "Ansia finale"
  )
)
```




Figura 20.4.: Il confronto aggregato può essere fuorviante quando i gruppi non sono comparabili.

⚠ Lezione del paradosso di Simpson


Prima di interpretare un'associazione aggregata, è necessario chiedersi se esistono sottogruppi importanti. La media complessiva può nascondere strutture diverse nei dati.

20.9. Confondimento, mediazione e moderazione

Molte difficoltà nascono dal fatto che parliamo genericamente di “terze variabili”. Una terza variabile, infatti, può avere ruoli diversi.

20.9.1. Confondimento


Un confondente è una variabile che precede la possibile causa e l'esito, ed è collegata a entrambi.



Esempio: la motivazione può influenzare sia lo studio che il rendimento. Se non se ne tiene conto, la relazione tra studio e rendimento può risultare distorta.

20.9.2. Mediazione


Un mediatore è parte del meccanismo attraverso il quale una causa produce un effetto.



Esempio: lo stress può peggiorare il sonno e un sonno di scarsa qualità può ridurre il rendimento. In questo caso, il sonno non è semplicemente un disturbo da eliminare, ma una possibile spiegazione del processo.

20.9.3. Moderazione

Un moderatore indica quando e per chi un effetto è più forte o più debole.



Un esempio è rappresentato da un intervento di rilassamento, che può rivelarsi più efficace per gli studenti con un'ansia iniziale alta rispetto a quelli con un'ansia iniziale bassa.



Tre domande diverse

- **Confondimento:** la relazione osservata è distorta da una terza variabile?
- **Mediazione:** attraverso quale processo si produce l'effetto?
- **Moderazione:** l'effetto cambia a seconda delle persone o delle condizioni?

Queste distinzioni sono importanti perché suggeriscono approcci analitici diversi. Un confondente deve essere preso in considerazione per evitare una stima distorta. Un mediatore non va rimosso se si vuole studiare l'effetto totale. Un moderatore va modellato se vogliamo capire per chi l'effetto cambia.

20.10. Cosa può fare l'EDA e cosa non può fare

L'EDA è indispensabile nella riflessione causale, ma presenta dei limiti precisi. Può aiutare a:

- individuare associazioni interessanti;
- riconoscere gruppi o sottogruppi rilevanti;
- individuare relazioni non lineari;
- scoprire i valori estremi che influenzano un'associazione;
- generare ipotesi sui possibili fattori confondenti;
- verificare se una storia causale è almeno compatibile con i dati osservati.

Non può, da sola:

- dimostrare che una variabile causa un'altra;
- escludere tutti i confondenti non osservati;
- trasformare uno studio osservazionale in un esperimento;
- sostituire un disegno di ricerca adeguato;
- giustificare conclusioni causali forti quando i dati non le supportano.

Collegamento con il progetto

Nel manuale principale, l'inferenza bayesiana verrà utilizzata per quantificare l'incertezza e per confrontare i modelli. Tuttavia, nessun modello statistico, bayesiano o frequentista, può trasformare automaticamente un'associazione osservazionale in una prova causale. Rimangono fondamentali il disegno dello studio, la misurazione e le assunzioni causali.

20.11. Usare l'AI con criterio

L'AI può essere utile per generare codice, produrre grafici, proporre simulazioni o spiegare concetti. Tuttavia, è particolarmente rischiosa quando si tratta di causalità, in quanto tende spesso a trasformare le associazioni in spiegazioni causali fluide e convincenti.

Controlli da fare quando usi l'AI

Quando l'AI commenta una relazione tra variabili, controlla sempre:

- usa parole causali come “influenza”, “determina”, “produce”, “riduce” o “aumenta”?
- il disegno dello studio giustifica davvero l'uso di una frase causale?
- Sono stati considerati possibili fattori confondenti?
- il codice elimina casi o gruppi senza documentarlo?
- il grafico mostra sottogruppi importanti o li nasconde?
- L'AI distingue associazione, mediazione, moderazione e confondimento?

Un buon uso dell'AI non consiste nel chiederle semplicemente “Interpreta questa correlazione”. È meglio formulare prompt che mantengano esplicita la cautela metodologica.

Esempio:

Ho osservato una correlazione negativa tra stress e qualità del sonno in uno studio osservazionale. Aiutami a interpretarla senza fare affermazioni causali non giustificate. Elenca possibili spiegazioni alternative e possibili fattori confondenti.

Esercizi

! Esercizio 1

In uno studio osservazionale, gli studenti che usano un'app di meditazione riportano meno ansia. Scrivi tre interpretazioni alternative di questa associazione.

! Esercizio 2

Considera la relazione tra uso dei social media e sintomi depressivi. Proponi:

1. un possibile confondente;
2. un possibile mediatore;
3. un possibile moderatore.

Spiega perché ciascuna variabile ha quel ruolo.

! Esercizio 3

L'AI produce questa frase:

Il supporto sociale riduce i sintomi depressivi, come mostra la correlazione negativa tra le due variabili.

Riscrivila in modo più corretto per uno studio osservazionale.

! Esercizio 4

Nel codice sul paradosso di Simpson, modifica la probabilità di assegnazione all'intervento nei due gruppi di ansia iniziale. Osserva come cambia il confronto aggregato.

20.12. Cosa portare al capitolo successivo

Prima di proseguire, tieni a mente tre punti.

1. **Associazione ≠ causalità.** Un legame anche forte e stabile non implica un nesso causale: occorre sempre chiedersi se variabili terze o meccanismi alternativi possano spiegarlo.
2. **Il disegno dello studio definisce i confini dell'inferenza.** Gli RCT offrono basi più solide per la causalità rispetto agli studi osservazionali, ma richiedono comunque attenzione a misurazione, campionamento e generalizzabilità. In ogni caso, è il disegno a stabilire cosa possiamo affermare.
3. **L'EDA è esplorativa, non confermativa.** Grafici e sintesi rivelano pattern e anomalie, ma ogni intuizione nata in questa fase resta un'ipotesi e va verificata con metodi inferenziali o nuovi dati.

💡 Informazioni sull'ambiente di sviluppo

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
Platform: aarch64-apple-darwin23
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
```

```
locale:
```

```
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
```

```
time zone: Europe/Rome
```

```
tzcode source: internal
```

```
attached base packages:
```

```
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
other attached packages:
```

```
[1] ggplot2_4.0.3 dplyr_1.2.1
```

```
loaded via a namespace (and not attached):
```

```
[1] vctrs_0.7.3      cli_3.6.6        knitr_1.51        rlang_1.3.0
[5] xfun_0.60        otel_0.2.0        generics_0.1.4    S7_0.2.2
[9] jsonlite_2.0.0   labeling_0.4.3    glue_1.8.1        htmltools_0.5.9
[13] scales_1.4.0     rmarkdown_2.31    grid_4.6.1        evaluate_1.0.5
[17] tibble_3.3.1     fastmap_1.2.0     yaml_2.3.12       lifecycle_1.0.5
[21] compiler_4.6.1   RColorBrewer_1.1-3 pkgconfig_2.0.3    farver_2.1.2
[25] digest_0.6.39    R6_2.6.1          utf8_1.2.6        tidyselect_1.2.1
[29] pillar_1.11.1    magrittr_2.0.5    withr_3.0.3       tools_4.6.1
[33] gtable_0.3.6
```

21. Valori inattesi e outlier

Nelle analisi reali, capita spesso di incontrare osservazioni che non assomigliano alle altre. Possono trattarsi di errori di inserimento, valori impossibili o casi estremi, ma reali, oppure segnali che il fenomeno è più complesso di quanto pensassimo.

In questo capitolo useremo il termine “outlier” in senso prudente: un outlier non è necessariamente un dato “sbagliato”. È prima di tutto un dato che richiede attenzione. La domanda non è “come lo elimino?”, ma:

Che cosa rappresenta questo valore e quale decisione è giustificata?

21.1. Perché chiudere l’EDA con gli outlier?

L’analisi degli outlier è un buon punto di conclusione per la sezione EDA, in quanto costringe a mettere insieme molti temi già affrontati.

- la struttura del progetto e la documentazione delle decisioni;
- la pulizia dei dati;
- la visualizzazione;
- la forma delle distribuzioni;
- le misure di tendenza centrale e variabilità;
- la correlazione;
- i limiti delle conclusioni causali.

Un valore anomalo può modificare la media, la deviazione standard, la correlazione o la regressione. Tuttavia, può anche rappresentare il caso più interessante del dataset. Per questo motivo, non deve essere trattato con una regola automatica.

In questo capitolo imparerai a

- distinguere valori impossibili, valori inattesi e outlier statistici;
- usare grafici semplici per individuare valori anomali;
- applicare criteri univariati come IQR e MAD;
- riconoscere quando un valore è anomalo solo rispetto a una relazione tra variabili;
- decidere se correggere, mantenere, escludere o trattare un valore estremo;
- documentare le decisioni in modo trasparente.

Idea guida

Un outlier non è una diagnosi, ma un invito a fare domande.

Prima di rimuovere un dato, chiediti:

1. è un valore impossibile?
2. è un errore documentabile?

3. è un caso estremo ma plausibile?
4. cambia in modo sostanziale il risultato?
5. la decisione è stata documentata?

21.2. Un piccolo dataset didattico

Useremo un dataset simulato su stress accademico e sonno. Alcuni valori sono stati modificati intenzionalmente per mostrare situazioni diverse:

- un valore impossibile nella variabile `stress`, perché la scala va da 1 a 10;
- un valore molto basso di `sonno_ore`;
- un valore molto alto di `sonno_ore`.

```
library(dplyr)
library(ggplot2)
library(tibble)

set.seed(123)

n <- 120

dati_outlier <- tibble(
  id = sprintf("S%03d", 1:n),
  stress = round(pmin(pmax(rnorm(n, mean = 6, sd = 1.4), 1), 10), 1),
  sonno_ore = round(pmin(pmax(8.2 - 0.28 * stress + rnorm(n, 0, 0.7), 3), 10), 1),
  benessere = round(pmin(pmax(72 - 3.5 * stress + rnorm(n, 0, 8), 20), 95), 0)
) |>
  mutate(
    stress = replace(stress, id == "S102", 99),
    sonno_ore = replace(sonno_ore, id == "S017", 1.2),
    sonno_ore = replace(sonno_ore, id == "S083", 13.5)
  )

dati_outlier
```

```
# A tibble: 120 x 4
  id      stress sonno_ore benessere
<chr>   <dbl>   <dbl>   <dbl>
1 S001     5.2     6.8     47
2 S002     5.7     5.9     48
3 S003     8.2     5.6     55
4 S004     6.1     6.3     42
5 S005     6.2     7.8     49
6 S006     8.4     5.4     58
7 S007     6.6     6.5     48
8 S008     4.2     7.1     46
9 S009      5      6.1     49
10 S010     5.4     6.6     57
# i 110 more rows
```

Il dataset è piccolo e artificiale, ma consente di analizzare casi che si riscontrano anche nei dati reali: errori, valori estremi e osservazioni difficili da interpretare.

21.3. Prima distinzione: impossibile, inatteso, estremo

Non tutti i valori anomali sono dello stesso tipo.

Tipo di valore	Esempio	Cosa fare prima
Valore impossibile	stress = 99 su una scala 1–10	controllare codicebook, questionario o file originale
Valore inatteso	13.5 ore di sonno	verificare se è plausibile nel contesto
Valore estremo ma possibile	1.2 ore di sonno	capire se è un caso reale o un errore
Outlier rispetto a una relazione	molto stress e molto sonno, contro il pattern generale	guardare la relazione tra variabili

Questa distinzione è importante perché il trattamento non può essere lo stesso. Un valore impossibile può essere corretto o trasformato in mancante se non è recuperabile. Un valore estremo ma plausibile, invece, non dovrebbe essere eliminato solo perché “disturba” l’analisi.

21.4. Controllare prima i valori impossibili

Il primo controllo non è statistico. È un controllo di tipo sostantivo: i valori sono compatibili con il modo in cui la variabile è stata misurata?

Nel nostro esempio, `stress` è una scala da 1 a 10. Il valore 99 non è un outlier psicologico, ma un valore impossibile per quella variabile.

```
dati_outlier |>
  filter(stress < 1 | stress > 10 | sonno_ore < 0 | sonno_ore > 24)
```

```
# A tibble: 1 x 4
  id      stress sonno_ore benessere
<chr>  <dbl>    <dbl>    <dbl>
1 S102      99      6.8      57
```

In un’analisi reale dovremmo controllare il file originale. Se scopriamo che 99 era un codice usato per indicare “risposta mancante”, dobbiamo ricodificarlo come NA.

```
dati_controllati <- dati_outlier |>
  mutate(
    stress = if_else(stress < 1 | stress > 10, NA_real_, stress)
  )

dati_controllati |>
  filter(is.na(stress))
```

```
# A tibble: 1 x 4
  id    stress sonno_ore benessere
<chr> <dbl>   <dbl>   <dbl>
1 S102    NA     6.8     57
```

! Non tutto è un problema statistico


Un valore impossibile deve essere considerato come un problema di qualità del dato, non come un outlier da identificare con IQR, z-score o MAD.

Prima si devono controllare i vincoli della misurazione. Solo dopo ha senso applicare criteri statistici.

21.5. Guardare la distribuzione

Dopo i controlli di plausibilità, torniamo all'EDA. Prima di calcolare le soglie, osserviamo la distribuzione.


```
ggplot(dati_controllati, aes(x = sonno_ore)) +
  geom_histogram(binwidth = 0.5, boundary = 0) +
  labs(
    x = "Ore di sonno",
    y = "Frequenza",
    title = "Distribuzione delle ore di sonno"
  )
```



Un istogramma permette di capire se la distribuzione è simmetrica, asimmetrica, concentrata o dispersa. Consente anche di notare i valori isolati.

Il boxplot offre invece un riassunto più compatto.

```
ggplot(dati_controllati, aes(y = sonno_ore)) +
  geom_boxplot() +
  labs(
    x = NULL,
    y = "Ore di sonno",
    title = "Boxplot delle ore di sonno"
  )
```



I punti mostrati al di fuori dei baffi del boxplot non sono automaticamente valori da eliminare. Meritano un controllo.

21.6. Il criterio IQR

Il criterio più comune per individuare gli outlier univariati si basa sull'intervallo interquartile (IQR).

L'intervallo interquartile (IQR) è la distanza tra il terzo e il primo quartile:

$$IQR = Q_3 - Q_1.$$

Una regola pratica segnala come potenziali outlier i valori inferiori a

$$Q_1 - 1.5 \times IQR$$

o superiori a

$$Q_3 + 1.5 \times IQR.$$

```

q1 <- quantile(dati_controllati$sonno_ore, 0.25, na.rm = TRUE)
q3 <- quantile(dati_controllati$sonno_ore, 0.75, na.rm = TRUE)
iqr_sonno <- IQR(dati_controllati$sonno_ore, na.rm = TRUE)

limite_basso_iqr <- q1 - 1.5 * iqr_sonno
limite_alto_iqr <- q3 + 1.5 * iqr_sonno

tibble(
  q1 = q1,
  q3 = q3,
  iqr = iqr_sonno,
  limite_basso = limite_basso_iqr,
  limite_alto = limite_alto_iqr
)

```

```

# A tibble: 1 x 5
      q1    q3  iqr limite_basso limite_alto
  <dbl> <dbl> <dbl>      <dbl>      <dbl>
1     6  7.1  1.1         4.35         8.75

```

```

outlier_iqr <- dati_controllati |>
  filter(
    sonno_ore < limite_basso_iqr |
    sonno_ore > limite_alto_iqr
  )

outlier_iqr

```

```

# A tibble: 2 x 4
  id    stress sonno_ore benessere
  <chr> <dbl>    <dbl>    <dbl>
1 S017   6.7      1.2      57
2 S083   5.5     13.5     42

```

Il criterio IQR è semplice e robusto rispetto alla media e alla deviazione standard. Tuttavia, non si tratta di una verità assoluta. In distribuzioni molto asimmetriche, infatti, può segnalare molti valori in una coda, anche quando questa coda rappresenta una parte reale del fenomeno.

21.7. Il criterio MAD

Un altro criterio robusto usa la mediana e la deviazione assoluta mediana, o MAD (*Median Absolute Deviation*).

L'idea è semplice:

1. si calcola la mediana;
2. si calcola quanto ogni valore si allontana dalla mediana;
3. si prende la mediana di questi allontanamenti.

```

mediana_sonno <- median(dati_controllati$sonno_ore, na.rm = TRUE)
mad_sonno <- mad(dati_controllati$sonno_ore, constant = 1, na.rm = TRUE)

dati_mad <- dati_controllati |>
  mutate(
    z_robusto = 0.6745 * (sonno_ore - mediana_sonno) / mad_sonno
  )

dati_mad |>
  filter(abs(z_robusto) > 3.5) |>
  select(id, sonno_ore, z_robusto)

```

```

# A tibble: 2 x 3
  id      sonno_ore z_robusto
<chr>    <dbl>    <dbl>
1 S017      1.2     -7.01
2 S083     13.5      9.58

```

Il valore `z_robusto` è una versione robusta dello z-score. Una soglia spesso utilizzata è `|z_robusto| > 3.5`, ma anche questa è una regola operativa, non una decisione automatica.

i I criteri non decidono al posto nostro

L'IQR e il MAD aiutano a individuare i valori che meritano attenzione. Non decidono autonomamente se un'osservazione debba essere rimossa. La decisione richiede sempre una giustificazione sostanziale e una documentazione adeguata.

21.8. Quanto cambia il riassunto?

Un modo utile per capire l'influenza degli outlier è confrontare i riassunti con e senza i valori segnalati.

```

dati_senza_outlier_iqr <- dati_controllati |>
  anti_join(outlier_iqr |> select(id), by = "id")

bind_rows(
  "con tutti i valori plausibili" = dati_controllati,
  "senza outlier IQR" = dati_senza_outlier_iqr,
  .id = "analisi"
) |>
  group_by(analisi) |>
  summarise(
    n = n(),
    media = mean(sonno_ore, na.rm = TRUE),
    mediana = median(sonno_ore, na.rm = TRUE),
    sd = sd(sonno_ore, na.rm = TRUE),
    iqr = IQR(sonno_ore, na.rm = TRUE),
    .groups = "drop"
  )

```

```
# A tibble: 2 x 6
  analisi n media mediana sd iqr
  <chr> <int> <dbl> <dbl> <dbl> <dbl>
1 con tutti i valori plausibili 120 6.52 6.4 1.08 1.1
2 senza outlier IQR 118 6.51 6.4 0.731 1.1
```

Questo confronto mostra perché gli outlier sono importanti: alcuni riassunti sono sensibili ai valori estremi, altri lo sono meno.

In generale:


- la media e la deviazione standard sono sensibili agli outlier;
- la mediana e l'IQR sono più robusti;
- il MAD è costruito specificamente per descrivere la dispersione in modo robusto.

21.9. Outlier rispetto a una relazione

Un'osservazione può non essere estrema su una singola variabile, ma risultare inattesa rispetto alla relazione tra due variabili.

Per esempio, se nel dataset chi riporta più stress tende a dormire meno, un partecipante con un livello di stress molto alto e molte ore di sonno può rappresentare un caso interessante, anche se nessuna delle due variabili è estrema di per sé.

```
ggplot(dati_controllati, aes(x = stress, y = sonno_ore)) +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Stress accademico",
    y = "Ore di sonno",
    title = "Relazione tra stress e sonno"
  )
```



Questo tipo di controllo collega il capitolo sugli outlier a quello sulla correlazione. Un singolo punto può cambiare la direzione o l'intensità di una relazione. Per questo motivo, quando osserviamo una correlazione, dobbiamo sempre considerare anche lo scatterplot.

21.10. Cosa fare con un outlier?

Dopo aver individuato un valore anomalo, ci sono diverse possibilità.

Situazione	Decisione possibile	Esempio
Errore documentabile	correggere	un valore 99 indica risposta mancante
Valore impossibile non recuperabile	codificare come NA	30 ore di sonno in un giorno
Valore estremo ma plausibile	mantenere	una notte di sonno quasi assente prima di un esame
Valore plausibile ma molto influente	analisi di sensibilità	risultati con e senza quel caso
Distribuzione con code pesanti	usare metodi robusti	mediana, IQR, MAD, modelli robusti
Valori estremi attesi dal fenomeno	cambiare modello	distribuzione asimmetrica o errore non normale

La rimozione è solo una delle opzioni, e spesso non è la prima.

Errore comune

Non rimuovere un valore solo perché rende il risultato meno “pulito”. Una decisione sugli outlier è giustificata se riguarda la qualità del dato, la sua coerenza con la misura o la scelta di un modello più adeguato. Non è giustificata se serve solo a ottenere un risultato più conveniente.

21.11. Documentare la decisione

Ogni scelta relativa agli outlier deve essere tracciabile. Una buona documentazione dovrebbe indicare:

- quale variabile è stata controllata;
- il criterio utilizzato;
- quali soglie sono state applicate;
- quali osservazioni sono state segnalate;
- cosa è stato deciso;
- perché quella decisione è coerente con la domanda di ricerca;
- se i risultati cambiano con una decisione alternativa.

Ecco un esempio di tabella di documentazione:


```
decisioni_outlier <- tibble(
  id = c("S102", "S017", "S083"),
  variabile = c("stress", "sonno_ore", "sonno_ore"),
  problema = c(
    "valore impossibile per una scala 1-10",
    "valore molto basso",
    "valore molto alto"
  ),
  decisione = c(
    "ricodificato come NA",
    "mantenuto e segnalato",
    "mantenuto e segnalato"
  ),
  motivazione = c(
    "il valore 99 non è interpretabile come punteggio di stress",
    "1.2 ore di sonno è raro ma possibile",
    "13.5 ore di sonno è raro ma possibile"
  )
)

decisioni_outlier
```

```
# A tibble: 3 x 5
  id      variabile problema      decisione      motivazione
<chr> <chr>      <chr>      <chr>      <chr>
1 S102 stress    valore impossibile per una scala 1-10 ricodificat~ il valore ~
2 S017 sonno_ore valore molto basso      mantenuto e~ 1.2 ore di~
3 S083 sonno_ore valore molto alto      mantenuto e~ 13.5 ore d~
```

Questa tabella non è un dettaglio burocratico. Fa parte dell'analisi.

21.12. Analisi di sensibilità

Quando non è chiaro se un valore estremo vada mantenuto o escluso, una strategia onesta è mostrare quanto cambino i risultati.

```
cor_con_tutti <- cor(
  dati_controllati$stress,
  dati_controllati$sonno_ore,
  use = "complete.obs"
)

cor_senza_outlier <- cor(
  dati_senza_outlier_iqr$stress,
  dati_senza_outlier_iqr$sonno_ore,
  use = "complete.obs"
)

tibble(
```

```
analisi = c("con tutti i valori plausibili", "senza outlier IQR"),
correlazione = c(cor_con_tutti, cor_senza_outlier)
)
```

```
# A tibble: 2 x 2
  analisi                correlazione
  <chr>                  <dbl>
1 con tutti i valori plausibili    -0.283
2 senza outlier IQR                -0.357
```

Se la conclusione cambia molto, il risultato è fragile. Ciò non significa necessariamente che una versione sia “vera” e l’altra “falsa”. Significa che il lettore deve sapere che la conclusione dipende da una scelta analitica.

21.13. Usare l’AI con criterio

L’AI può essere utile per scrivere codice che individua gli outlier, costruisce i boxplot o calcola le soglie IQR e MAD. Tuttavia, tende anche a proporre soluzioni automatiche, come “rimuovi tutti gli outlier”, senza considerare il significato di quei valori.

Cosa puoi chiedere all’AI

Puoi chiedere all’AI:

- di scrivere il codice R per calcolare IQR o MAD;
- di spiegare un boxplot;
- di costruire una tabella dei casi segnalati;
- di confrontare risultati con e senza outlier;
- di suggerire una struttura per documentare le decisioni.

Cosa devi controllare tu

Devi controllare personalmente:

- se le soglie sono adeguate alla variabile;
- se il valore è impossibile o solo raro;
- quanti casi vengono esclusi;
- se la decisione modifica i risultati;
- se l’AI sta trasformando una scelta metodologica in una procedura automatica;
- se l’interpretazione è coerente con la domanda psicologica.

Una buona pratica è chiedere all’AI non solo il codice, ma anche i controlli:

Questo codice rimuove delle osservazioni? Quante? Quali? Come posso confrontare i risultati con e senza questi casi?

21.14. Collegamento con la modellizzazione

Gli outlier non sono solo un problema di pulizia dei dati. A volte, infatti, sono un segnale che il modello che abbiamo in mente è troppo semplice.

Per esempio:

- una distribuzione molto asimmetrica può richiedere una trasformazione o un modello diverso;
- code pesanti possono suggerire un modello robusto;
- un singolo caso influente può indicare che la relazione non è uguale per tutti;
- una popolazione eterogenea può richiedere modelli per gruppi o modelli gerarchici.

Nel manuale bayesiano incontreremo modelli che permettono di rappresentare in modo più esplicito l'incertezza, la variabilità tra gli individui e la presenza di osservazioni influenti. L'EDA non sostituisce questi modelli, ma aiuta a capire quando potrebbero essere utili.

21.15. Cosa ricordare

Gli outlier non sono fastidi da cancellare. Sono un'opportunità per comprendere meglio i dati.

Al termine di questo capitolo, dovresti ricordare che:

- un valore impossibile è un problema di qualità del dato;
- un valore estremo può essere reale e informativo;
- i criteri statistici segnalano casi da controllare, non decisioni già prese;
- la media, la deviazione standard e la correlazione possono essere molto sensibili agli outlier;
- le decisioni devono essere motivate e documentate;
- quando una decisione modifica il risultato, bisogna mostrarlo.

! Esercizi

1. Nel dataset didattico, quali valori sono impossibili e quali sono solo estremi?
2. Usa il criterio IQR sulla variabile `benessere`. Quali casi vengono segnalati?
3. Confronta media e mediana di `sonno_ore` prima e dopo l'esclusione degli outlier IQR.
4. Calcola la correlazione tra `stress` e `sonno_ore` con e senza i casi segnalati. Cambia molto?
5. Scrivi una breve nota metodologica che documenti una decisione sugli outlier.
6. Chiedi a un sistema AI di individuare gli outlier nel dataset. Quali controlli devi fare prima di fidarti della risposta?

i Informazioni sull'ambiente di sviluppo

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24)
```

```
Platform: aarch64-apple-darwin23
```

```
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
```

```
LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
```

```

locale:
[1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8

time zone: Europe/Rome
tzcode source: internal

attached base packages:
[1] stats      graphics  grDevices  utils      datasets  methods   base

other attached packages:
[1] tibble_3.3.1  ggplot2_4.0.3 dplyr_1.2.1

loaded via a namespace (and not attached):
 [1] vctrs_0.7.3      nlme_3.1-169      cli_3.6.6         knitr_1.51
 [5] rlang_1.3.0      xfun_0.60         otel_0.2.0        generics_0.1.4
 [9] S7_0.2.2         jsonlite_2.0.0    labeling_0.4.3    glue_1.8.1
[13] htmltools_0.5.9  scales_1.4.0      rmarkdown_2.31    grid_4.6.1
[17] evaluate_1.0.5   fastmap_1.2.0     yaml_2.3.12       lifecycle_1.0.5
[21] compiler_4.6.1   RColorBrewer_1.1-3 pkgconfig_2.0.3   mgcv_1.9-4
[25] lattice_0.22-9   farver_2.1.2      digest_0.6.39     R6_2.6.1
[29] utf8_1.2.6       tidyselect_1.2.1  splines_4.6.1     pillar_1.11.1
[33] magrittr_2.0.5   Matrix_1.7-5      withr_3.0.3       tools_4.6.1
[37] gtable_0.3.6

```

Bibliografia

Parte V.

Epilogo

Considerazioni conclusive

Questo sito ha gettato le basi per affrontare l’inferenza statistica bayesiana. Abbiamo percorso tre tappe: *pensare* (i concetti), *fare* (gli strumenti) e *guardare* (l’esplorazione). È il momento di fare un bilancio di quanto abbiamo appreso e di cosa ci aspetta.

Cosa hai imparato

Un modo di pensare. Prima ancora delle tecniche, hai incontrato un approccio, l’idea che l’analisi dei dati non sia una sequenza meccanica di operazioni, ma un dialogo critico tra domande di ricerca, strumenti di misura e osservazioni empiriche. Hai imparato che la misurazione non è mai neutrale, che le scale hanno proprietà diverse e che le conclusioni dipendono dal modo in cui i dati sono stati raccolti.

Un linguaggio. R non è solo un software, ma un modo per esprimere operazioni sui dati in modo preciso e riproducibile. La sintassi che hai imparato — oggetti, funzioni e pipeline con dplyr — è il vocabolario minimo per comunicare con il computer e con altri ricercatori. Il codice che scrivi oggi potrà essere riletto, verificato e riutilizzato in futuro.

Un’abitudine. L’analisi esplorativa non è un optional da sbrigare in fretta prima dei “veri” test statistici. È il momento in cui scopri se i tuoi dati hanno senso, se le assunzioni che stai per fare sono plausibili e se ci sono anomalie che richiedono attenzione. Hai imparato a visualizzare le distribuzioni, a identificare gli outlier e a verificare le relazioni: sono competenze che ti saranno utili in ogni progetto di ricerca.

Cosa non abbiamo trattato

Questo sito è volutamente propedeutico. Non abbiamo discusso:

- **Inferenza statistica:** come trarre conclusioni su una popolazione a partire da un campione, come quantificare l’incertezza, come aggiornare le proprie credenze alla luce dei dati. Questo è il tema centrale del manuale *“Inferenza bayesiana in psicologia: Ragionare con l’incertezza. Fondamenti, workflow e applicazioni”*.
- **Modelli statistici:** regressione, modelli gerarchici, modelli per dati longitudinali. Questi strumenti ti permetteranno di rispondere a domande di ricerca complesse.
- **Programmazione avanzata:** funzioni personalizzate, simulazioni, ottimizzazione del codice. Queste competenze diventeranno utili man mano che i tuoi progetti cresceranno in complessità.
- **Stan e i metodi computazionali:** il motore probabilistico che rende possibile l’inferenza bayesiana su modelli realistici.

Tutti questi argomenti sono trattati nel manuale principale, che presuppone le competenze acquisite qui.

Il passo successivo

Il manuale “*Inferenza bayesiana in psicologia: Ragionare con l’incertezza. Fondamenti, workflow e applicazioni*” prosegue dove questo sito si conclude. Ecco cosa troverai:

Parte	Contenuto
I-II	La crisi di replicabilità e i limiti del paradigma frequentista
III	I fondamenti della probabilità bayesiana come misura di credenza razionale
IV	L’inferenza bayesiana operativa: distribuzioni, MCMC, workflow
V	Applicazioni: regressione, confronto tra gruppi, modelli multilivello
VI	Modelli formali del comportamento e validazione cross-studio
VII	Riflessioni epistemologiche e Open Science

Il sito *companion* (ccaudek.github.io/utet-companion) contiene il codice R e Stan per tutti gli esempi del manuale.

Continuità, non discontinuità

Il passaggio dall’esplorazione all’inferenza non rappresenta una discontinuità, ma un’estensione naturale. L’EDA che hai praticato qui diventerà il *posterior predictive checking*, ovvero il confronto tra le previsioni del modello e i dati effettivi. Le distribuzioni che hai visualizzato diventeranno distribuzioni di probabilità con un’interpretazione ben precisa. Le domande che ti sei posto sui dati diventeranno ipotesi formalizzate in modelli. La correlazione che hai calcolato diventerà un coefficiente di regressione con un intervallo di credibilità.

Un’ultima raccomandazione

La statistica si impara facendola. I capitoli che hai letto, gli esercizi che hai svolto e il codice che hai scritto sono solo l’inizio, non la fine. Ogni dataset che incontrerai nella tua carriera sarà diverso e presenterà problemi nuovi che richiederanno soluzioni creative.

L’atteggiamento che ti sarà più utile non è quello di chi cerca la “procedura giusta” da applicare meccanicamente, ma quello di chi si chiede: “Cosa mi stanno dicendo questi dati?”, “Le mie assunzioni sono ragionevoli?”, “Le mie conclusioni sono robuste?”.

Questo atteggiamento curioso, critico e onesto è ciò che distingue l’analisi dei dati rigorosa dalla semplice produzione di numeri. È anche ciò che rende questo lavoro intellettualmente stimolante.

Buon proseguimento.



Risorse per continuare

- **Manuale principale:** ccaudek.github.io/utet-companion
- **Teoria della probabilità:** ccaudek.github.io/utet-prob
- **Repository GitHub:** github.com/ccaudek

- Bechtel, W. (2009). Looking down, around, and up: Mechanistic explanation in psychology. *Philosophical Psychology*, 22(5), 543–564.
- Ceccarini, F., Colpizzi, I., & Caudek, C. (2024). Age-dependent changes in the anger superiority effect: Evidence from a visual search task. *Psychonomic Bulletin & Review*, 1–10.
- Dogucu, M. (2024). Reproducibility in the Classroom. *Annual Review of Statistics and Its Application*, 12.
- Henrich, J., Heine, S. J., & Norenzayan, A. (2010). The weirdest people in the world? *Behavioral and Brain Sciences*, 33(2-3), 61–83.
- Huntington-Klein, N. (2021). *The effect: An introduction to research design and causality*. Chapman; Hall/CRC.
- Irizarry, R. A. (2024). *Introduction to Data Science: Data Wrangling and Visualization with R*. CRC Press.
- Johnson, A. A., Ott, M., & Dogucu, M. (2022). *Bayes Rules! An Introduction to Bayesian Modeling with R*. CRC Press.
- Lilienfeld, S. O., & Strother, A. N. (2020). Psychological measurement and the replication crisis: Four sacred cows. *Canadian Psychology/Psychologie Canadienne*, 61(4), 281–288.
- Marr, D. (2010). *Vision: A computational investigation into the human representation and processing of visual information*. MIT press.
- Maul, A., Irribarra, D. T., & Wilson, M. (2016). On the philosophical foundations of psychological measurement. *Measurement*, 79, 311–320.
- McElreath, R. (2020). *Statistical rethinking: A Bayesian course with examples in R and Stan* (2nd Edition). CRC Press.
- Peterson, R. A., & Merunka, D. R. (2014). Convenience samples of college students and research reproducibility. *Journal of Business Research*, 67(5), 1035–1041.
- Povich, M. (2025). Mechanistic Explanation in Psychology. In H. Stam & H. Looren de Jong (A c. Di), *The SAGE Handbook of Theoretical Psychology*. SAGE Publications.
- Soto, F. A., Vogel, E. H., Uribe-Bahamonde, Y. E., & Perez, O. D. (2023). Why is the Rescorla-Wagner model so influential? *Neurobiology of Learning and Memory*, 204, 107794.
- Stevens, S. S. (1946). On the theory of scales of measurement. *Science*, 103(2684), 677–680.
- Wickham, H., Çetinkaya-Rundel, M., & Golemund, G. (2023). *R for data science*. " O'Reilly Media, Inc."
- Youyou, W., Yang, Y., & Uzzi, B. (2023). A discipline-wide investigation of the replicability of Psychology papers over the past two decades. *Proceedings of the National Academy of Sciences*, 120(6), e2208863120.